引文格式:杨必胜,陈一平,邹勤.从大模型看测绘时空信息智能处理的机遇和挑战[J].武汉大学学报(信息科学版),2023,48(11):1756-1768.DOI:10.13203/j.whugis20230378

Citation:YANG Bisheng,CHEN Yiping,ZOU Qin.Opportunities and Challenges of Spatiotemporal Information Intelligent Processing of Surveying and Mapping in the Era of Large Models[J].Geomatics and Information Science of Wuhan University,2023,48(11):1756-1768.DOI:10.13203/j.whugis20230378

从大模型看测绘时空信息智能处理的机遇和挑战

杨必胜[1] 陈一平[2] 邹 勤[3]

1 武汉大学测绘遥感信息工程国家重点实验室,湖北 武汉,430079

2 中山大学测绘科学与技术学院,广东 珠海,519082

3 武汉大学计算机学院,湖北 武汉,430072

摘 要:当前,时空信息、定位导航服务已成为重要的新型基础设施,在通用人工智能的驱动下,大模型引领的智能时代已经到来,越来越强大的大模型将在测绘时空信息智能处理与应用中发挥越来越重要的作用。以大模型为研究范式,总结大模型在测绘时空信息智能处理的现状与进展,分析大模型在测绘时空信息智能处理面临的挑战,阐述多模态融合与理解架构设计、提示工程优化微调以及人在回路引导决策3个核心方面在时空信息测绘大模型中的关键作用。针对行业理解深度、数据安全隐患、内容可信度保障以及训练部署成本优化4个方面,展望时空信息测绘大模型面临的挑战与发展趋势。

关键词:时空信息;大模型;多模态;提示工程;人在回路;智能化测绘

中图分类号:P208 **文献标识码**:A **收稿日期**:2023-10-07

DOI:10.13203/j.whugis20230378 **文章编号**:1671-8860(2023)11-1756-13

Opportunities and Challenges of Spatiotemporal Information Intelligent Processing of Surveying and Mapping in the Era of Large Models

YANG Bisheng[1] *CHEN Yiping*[2] *ZOU Qin*[3]

1 State Key Laboratory of Information Engineering in Surveying, Mapping and Remote Sensing, Wuhan University, Wuhan 430079, China

2 School of Geospatial Engineering and Science, Sun Yat-Sen University, Zhuhai 519082, China

3 School of Computer Science, Wuhan University, Wuhan 430072, China

Abstract: Currently, spatiotemporal information, positioning and navigation have become important new infrastructures. Driven by general artificial intelligence, the era of intelligence led by large models has arrived. The increasingly powerful large models will play a more and more important role in the intelligent processing and applications of spatiotemporal information. First, this paper uses large models as the research paradigm and summarizes the current status and progress of large models in intelligent processing of spatiotemporal information in surveying and mapping. In addition, it analyzes the challenges faced by large models in intelligent processing of spatiotemporal information in surveying and mapping. We elaborate three key technologies in spatiotemporal information large models for surveying and mapping, including multi-modal fusion and understanding architecture design, prompt engineering optimization by fine-tuning, and human-in-the-loop guidance for decision-making. Finally, the depth of industry understanding, data security risks, content credibility, and training deployment cost optimization are addressed to predict the development trend of spatiotemporal information large models.

Key words: spatiotemporal information; large model; multi-modal; prompt engineering; human-in-the-loop; smart surveying and mapping

---

基金项目:国家自然科学基金(42130105,62171324);国家重点研发计划(2022YFB3904100)。

第一作者:杨必胜,博士,教授,研究方向为三维地理信息获取与分析。bsyang@whu.edu.cn

通讯作者:陈一平,博士,副教授。chenyp79@mail.sysu.edu.cn

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

近年来,随着新一轮科技革命和产业变革的深入发展,智能化转型已经成为大势所趋。人工智能(artificial intelligence,AI)大模型成为人工智能迈向通用智能的里程碑技术,将加速与测绘时空信息以及遥感技术的耦合。构建时空信息测绘大模型,释放以数据为核心要素的生产力,夯实数字中国建设和数字经济发展的数据基础,推动数字化测绘到智能化测绘的转型升级势在必行。

人工智能大模型的学习、理解和推理能力,凸显了其理解垂直领域问题的巨大潜力,对时空信息测绘大模型的提出和发展具有启发性的指导意义。利用通用人工智能大模型,结合测绘地理信息行业数据,使得预训练大模型能够适用于测绘地理信息行业的专业需求。在此基础上,结合行业细分场景和特定下游任务,利用其组合创新能力、评估评价能力、复杂任务分解和规划能力以及推理能力等,建立服务于细分行业和场景的统一平台(如图1所示),对智能化测绘具有重要意义。

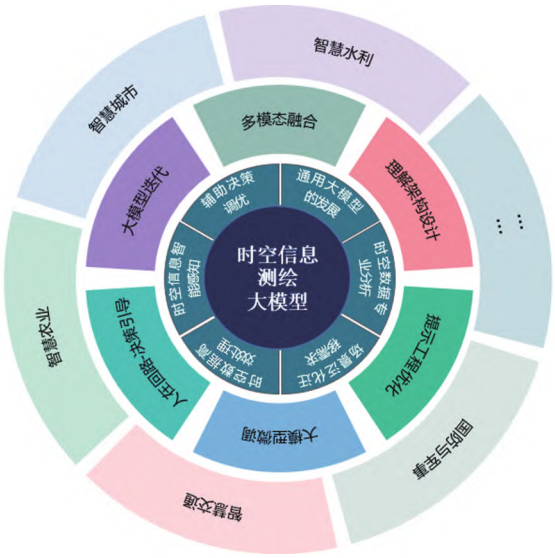

图1　时空信息测绘大模型驱动力

Fig. 1　Driven Forces of Spatiotemporal Information Large Models for Surveying and Mapping

1　通用人工智能大模型的研究进展

深度学习推动了人工智能在智能感知方面的飞速进展,特别是自从Transformer[1]架构问世以来,预训练大模型在自然语言处理和视觉智能领域的崭露头角,将感知能力提升到认知层面。传统的人工智能开发方式通常是一个场景对应一个模型,存在数据质量不佳、样本匮乏以及模型精度不足的缺陷,应用场景也相对单一。相较之下,人工智能大模型代表着大数据、强大算力和出色算法的结合,内含了大规模数据的隐含知识。通过大规模数据的训练,学习出特征和规则,微调后可在多种不同的下游任务中表现出强大的泛化能力。ChatGPT[2]的出现进一步推动了人工智能大模型技术的蓬勃发展,在大规模数据的支持下,涌现了一系列语言大模型、视觉大模型、视频大模型、三维大模型、多模态大模型以及科学计算大模型,通过不断演进,从最初只支持文本或图像的单一模态和任务,逐渐拓展到支持跨媒体智能的多种模态和多种任务,已经成为通用人工智能的核心技术。图2展示了目前测绘遥感领域内典型的大模型发展情况。

1.1　语言大模型

早期的语言模型建立在2017年提出的引入自注意力机制而成功关注输入序列不同部分获得性能提升的Transformer架构之上,包括BERT[3]、T5[4]、GPT-1[5]、GPT-2[6]以及BERT的各种变体[7]。随着这些模型参数量从初期的几亿增长到数十亿甚至几千亿,相应的能力也得到了显著提升。这一发展使得语言模型不再局限于简单的文本问答,而是具备了更强大的符号式语言推理能力。其中,GPT-3[2]标志着重要的里程碑,从GPT-2的13亿参数提升到GPT-3的1 750亿参数,并引入了上下文学习能力,可以通过完成输入文本的词序列生成测试实例的预期输出,初步展示了智能推理的潜力。在这一进程中,GPT-4[8]代表了语言模型的重要进展,参数量达到了1.8万亿,在多模态方面进行了性能优化。PaLM[9]的出现在深度和广度上扩展了语言模型的规模,将语言模型与思维链相结合,展现出在困难任务中的语言理解和生成的突破性能力。而LLaMA[10]则采用了不同的方法,通过奖励偏好来提高模型对数据输出的一致性评价,使得模型在训练和改进过程中逐渐提高。也有单独针对某种语言的对话大模型,如百度研发的增强大语言模型文心一言,主要针对高质量中文场景的对话任务。随着越来越多的语言模型相继问世,通过上下文学习、指令遵循和逐步推理等技术,使得语言模型具备了更强大、更灵活的涌现能力,带来了前所未有的机遇和潜力。

1.2　视觉大模型

视觉任务需要深入理解和推理视觉场景的各个组成特性。视觉大模型的研究起始于将Transformer框架从自然语言处理领域迁移到视

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

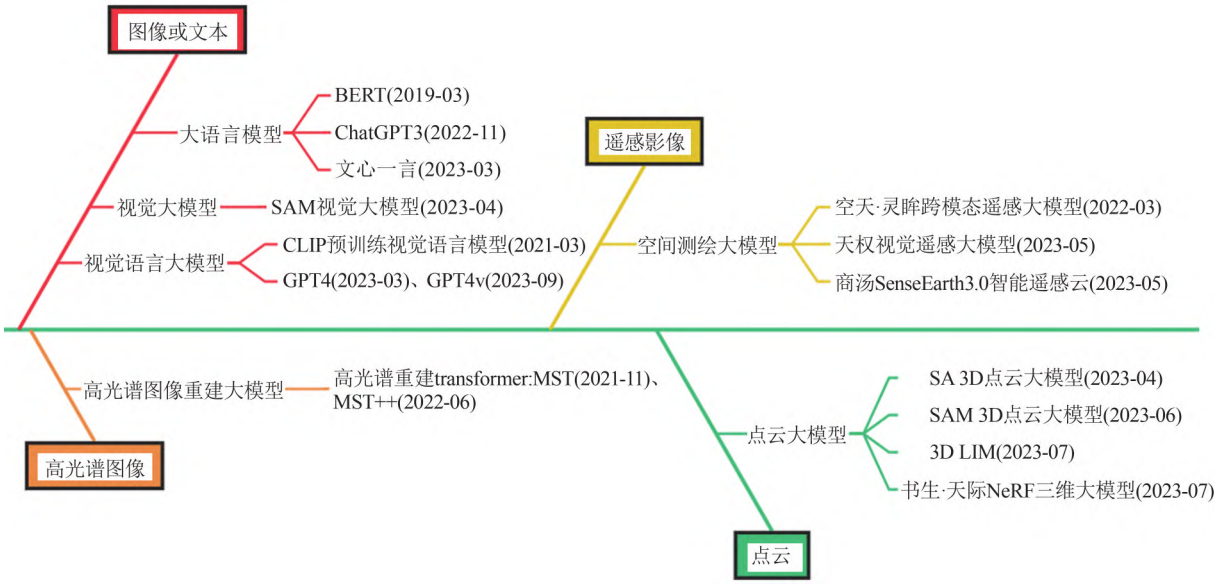

图2 时空信息测绘大模型发展

Fig. 2 Development of Spatiotemporal Information Large Models for Surveying and Mapping

觉领域,这一创新开创了以Transformer为基础的视觉模型Vision Transformer,即ViT[11]。由Google Research在2020年提出的ViT完全使用了原始BERT(bidirectional encoder representations from transformers)的Transformer架构,在使用大规模数据集进行训练时取得了优于卷积神经网络的性能。V-MoE[12]在ViT的基础上包含多个同质的ViT模块,让模型中每个模块学习数据的某个子集,由此构建大型视觉模型。MAE(masked autoencoder)采用自然语言领域完型式方式进行训练,即在预训练阶段随机遮蔽句子中的一部分词汇,并尝试预测这些遮蔽词汇,该方法有助于模型学习上下文信息。将输入数据映射到低维稠密的特征空间,实现数据的压缩和重构,这一无监督学习方法对后续的视觉大模型研究产生了深远影响。Meta AI基于强大的LLaMA 2大型语言模型发布了通用图像分割模型Segment Anything(SAM)[13],该模型通过提示工程的有效概括解决不同的分割任务,其模块化设计支持多种提示格式,开创了解决复杂图像处理的新趋势。与此同时,面向多任务的视觉大模型不断面世,如百度文心UFO 2.0视觉多任务模型[14]、华为盘古视觉大模型[15]、商汤书生INTERN大模型[16]等。

视频相对于文本和图像的独特之处在于其本身包含多模态信息,包括音频、文字和图像等多种数据类型,这使得视频理解需要同时利用视觉和语言模型以完成相应的任务。Video-BERT[17]是一个重要的视觉语言模型,将Transformer扩展到了视频语言模型的训练中,学习了视频数据的分层矢量量化以及语音识别后计算联合分布;ActBERT[18]和HERO[19]则通过视频帧堆叠来扩展视频的序列性学习;Video MAE[20]系列方法通过建立自监督学习范式,减少时间冗余性带来的运动表示稀释问题;VPT[21](visual prompt tuning)则利用大量无标注的视频数据进行预训练,实现了预训练和强化学习的结合;阿里达摩院提出的文本生成视频大模型VideoComposer[22],将文本特征映射到视频隐空间以生成视频,同时实现了视频在时间和空间两个维度上的可控性。尽管通用视觉大模型已经取得了显著进展,但仍面临着多种挑战,包括高效解决多种类型的下游任务、降低模型部署成本以及进一步改进图像语义理解等方面的问题。

1.3 三维大模型

在通用视觉大模型的基础上,许多工作已经开始从二维视觉领域扩展到了三维视觉领域。SAM3D[23]利用了SAM视觉模型,首先预测了图像的分割掩码,然后将二维图像掩码投影到三维点云中,并将其合并到三维场景中。这一思想随后被应用在了多个领域,包括三维点云目标检测和三维人脸重建中。结合SAM和NeRF[24]的SA3D[25]将语义信息融入到三维重建过程中,从单目RGB图像中恢复室内场景的三维结构,并提高了三维重建任务的精度和鲁棒性;VS-SLAM[26]建立了一个大规模的三维语义地图模型,利用视觉SLAM和大规模环境的语义分割信息,实现了三维环境的重建。这一模型还结合了

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

GPS数据、地图再利用、实时重定位和基于地标的定位,将现实世界地标与三维点云相关联,提供了更加立体化的表征;ARGUS 3D[27]模型具有36亿参数规模,能够根据输入的类别信息生成三维形状,生成的质量、三维结构和细节表达都比传统方法更完整和流畅。上海人工智能实验室联合香港中文大学、上海市测绘院于2023年7月发布了全球首个城市级NeRF实景三维大模型INTERN[28]的书生·天际,在CityNeRF[29]的基础上融合不同高度的影像,实现了大范围、高精度、可编辑的三维大模型。3D-LLM[30]将三维世界的知识注入到大型语言模型中,以三维点云及其特征作为输入,执行包括三维场景描述生成、三维辅助对话以及三维导航等任务。三维大模型目前正处于萌芽阶段,这些模型有望为人们更深入地理解、分析和利用时空信息提供强大的工具和技术支持。

1.4　多模态大模型

多模态大模型指的是将文本、图像、视频、音频、三维点云等多模态信息联合起来进行训练的模型,可适用于多种应用场景并提高模型的性能。多模态大模型的发展代表了人工智能领域的一个重要进展,有望实现对多种信息模态的统一认知和理解,进一步拓宽了人工智能的应用领域。GPT-4是OpenAI GPT系列中的多模态大模型,可接受图像和文本作为输入,并在专业学习和学术基准上表现出接近人类水平的性能。OpenAI发布的开创性视觉语言模型CLIP[31],通过对比学习来对齐图像和文本之间的关联性,为多模态技术的理解和应用带来了重大突破。该模型启发了后续的一系列方法如CLIP[32]、CLIP4Clip[33]和ActionCLIP[34]。由微软发布的COCA[35]作为CLIP的延伸,由于引入了交互,不仅可以应用在图像-文本对齐任务中,还可以处理图像-文本的多模态理解任务,如图像字幕生成和视觉问答等。

然而,传统的多模态模型难以学习到外部知识,因此一些模型采用了冻结语言模型的策略,将多模态模型设计向语言模型靠拢,将视觉作为提示。Flamingo[36]模型连接了强大的预训练视觉和语言模型,最为关键的突破在于该模型无缝将摄取图像或视频作为输入,并训练和处理任意交错的大规模多模态视觉和文本数据序列,即类似于人类类比学习的决策过程,可举一反三。由谷歌研究院发布的PaLI[37]模型则通过重复使用并链接单模态大模型,将图像-语言任务转换为问答任务,实现了跨任务的迁移学习,增强了图文理解能力,具有强大的扩展性。“紫东太初”跨模态[38]人工智能大模型是全球首个具备图像、文本、音频预训练能力的模型,具备跨模态的理解和生成能力,并可以快速迁移到不同领域数据,为各种下游任务提供支撑。而微软提出的NÜWA[39]模型实现了文本-图像-视频之间的生成、转换和编辑功能,为行业大模型的嵌入提供了更加有效的解决思路。

1.5　科学计算大模型

目前,人工智能大模型正在迈向多模态数据融合、知识融入、可解释性以及学习理论等多个方向。各个领域的研究人员正在努力构建科研超算平台,结合人工智能技术加速科学原理的发现和技术突破,推动科学计算大模型的发展。科学计算是人工智能领域的一个重要且充满挑战的方向,其旨在运用数学模型和计算机算法,从海量数据中发现规律,模拟和求解复杂的科学问题,从而揭示科学规律和现象,大幅提高计算效率。如盘古气象大模型[15]作为人工智能预报方法,成功突破了中长期气象预报的难题,其预测精度在1 h～7 d均超过了传统数值方法,同时提供了秒级全球气象预报,大大提高了预测速度。此外,复旦大学联合阿里云打造CFFF(computing for the future at Fudan)异构智算超算平台[40],旨在构建中短期天气预报大模型、生命科学大模型、材料科学大模型、大气科学大模型和集成电路大模型等。科学计算大模型正在开启科学计算领域的新纪元,为各行各业带来了巨大的价值和机遇。

2　时空信息测绘大模型驱动力分析

目前,大模型经历了单语言预训练模型、多语言预训练模型和多模态预训练模型的发展历程,处理的内容从自然语言扩展到多样化语言,并能够进行文字、图片、音乐和视频的同步处理,实现多任务目标的处理。通用人工智能大模型已经具备了高水平的交互、生成和分析能力。在通用大模型的基础上,通过测绘领域的专业数据、信息和知识作为提示进行训练,并学习领域专业软件工具以微调模型,有望进一步深化在领域中的应用,以解决行业中的痛点问题。时空信息测绘大模型利用目前通用的人工智能模型,如自然语言大模型、视觉大模型和多模态大模型,

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

通过充分学习公开可用的测绘地理信息行业知识、政策、消息和数据进行训练和微调,构建测绘领域的大模型,并具备人机交互的能力,包括数据采集、生产、治理、分析和应用等服务,提供知识问答、内容生成以及深入不同场景和应用的业务处理和辅助决策等核心功能。

2.1 时空信息智能感知

随着人工智能技术与对地观测技术、卫星导航定位技术、云计算技术和大数据技术的高度融合,时空信息获取的自动化和应用的智能水平得到了极大提升。时空信息测绘大模型的时空数据涵盖了可见光数据、高光谱数据、激光雷达点云和毫米波雷达等二、三维基础空间数据,覆盖倾斜摄影三维模型、数字高程模型、数字表面模型、数字正射影像与激光点云模型等地理场景数据类型。在数据采集和处理的过程中,需要进行专业和复杂的实体化、轻量化、高质量纹理贴图、高保真渲染等操作。时空信息测绘大模型通过对数据生产及处理等专业软件工具以及可靠性算法的学习,进而能够在理解以自然语言、音频、图像等信号提示的基础上自动配置算力资源,执行测绘数据生产和处理等任务,大幅降低操作过程中的专业门槛。同时,领域大模型技术在数据智能处理的基础上,还可以执行对处理软件工具的重构,提升处理数据的效率和精细化水平,革新生产力。时空信息测绘大模型将在文本生成、语言理解、知识问答、逻辑推理、生成能力和多模态支持等方面,拓宽时空信息获取对象的范围,提升海量时空数据存储、处理、开发利用的效率,增强测绘地理信息应用的智能化和个性化,改变现有的信息获取方式、革新内容生产模式,加速智能化测绘的发展。

2.2 场景泛化迁移与辅助决策调优

大模型具有的庞大参数量和复杂结构使其具备强大的学习和泛化能力。将不同模态标注数据输入预训练模型中,模型学习到数据的特征和变化规律,通过微调能够在其他数据上表现出较好的泛化能力。当前,测绘地理信息领域拥有海量的数据源,因为时空数据的复杂性,对数据进行标注需要丰富的先验知识且工作繁重。首先,大模型在预训练阶段使用大量的未标注数据,将庞大的训练数据与测绘地理信息数据相结合,并可无视数据分布与顺序,进行多种任务,充分挖掘不同格式和内容数据的信息及其之间的内在联系,学习和表示数据的复杂特征,更好地拟合复杂的数据分布和任务要求,减少对数据标注的依赖。其次,预训练阶段的通用语义理解能力使得模型可以迁移到测绘各细分任务和场景中,产生可靠的预测结果,使得大模型具有更好的泛化迁移能力。最后,利用大模型,通过对海量数据进行空间关系分析和可视化,可直观感受时空对象的分布、变化、关联和相互作用影响,帮助理解时空环境变化趋势。基于以上的分析和理解,时空信息测绘大模型可提供准确、可靠的智能推荐和优化建议,以辅助做出更好的决策。

2.3 数据专业分析

在测绘地理信息技术数据服务中,对跨平台、跨模态数据资源的融合汇聚和管理,以及对数据资产的时空可视化检索、分析,长期以来依赖于专业的数据库技术。如何从多源、异构、多时相、跨平台的大数据中建立数据间的潜在关系,以及对交叉学科领域的政策文件、技术标准、行业参考资料设计统一参考模式,是提升对于空间地理信息的规律、趋势的预测分析能力,是时空信息测绘大模型释放数据要素价值的重要功能。时空信息测绘大模型应构建以向量数据库为支撑的数据服务引擎,让使用者无需学习专业的数据库知识以及交叉学科行业资料,以自然语言需求统筹数据治理任务,开展空间分析、趋势预测等多样化的数据分析工作,也可以对自然语言提问给出准确的回答和参考出处,利用大模型强大的逻辑推理能力生成数据报告,在满足业务需求和数据分析成果的基础上,为下一步决策提供更全面的知识储备,而下一步决策也将为大模型提供进一步的数据支撑。

3 时空信息测绘大模型关键技术

时空信息测绘大模型的关键技术组成如图3所示,以大模型+专业工具与行业知识+管理决策为路径,构建行业大模型和场景精调大模型,形成数据处理、分析、服务、应用、管理的一体化人工智能平台。因此,时空信息测绘大模型总体包括3项关键技术,分别是多模态融合与理解架构设计、提示工程优化测绘大模型微调、决策引导的测绘大模型迭代,其中核心功能为专业领域模型设计、多模态数据对齐与语义关联、基于提示和决策的自监督学习、模型适配与轻量化。

3.1 多模态融合与理解架构设计

随着传感器的不断发展、丰富,且传感器获取数据的能力不断提升,时空数据种类越来越多

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

样化,仅依靠单一的数据类型无法明确地对不同地物类别进行定义,通过对具有不同特征和空间信息的多模态数据进行融合,强化地物差异,达到更好的模型训练、数据处理、数据分析效果,被广泛应用于测绘领域。而在人工智能领域已经产生了一系列具有里程碑意义的多模态数据融合框架,对时空信息测绘大模型带来富有启发性的指导。在测绘大模型中需要建立多模态学习的框架,用来处理和关联来自多种数据模态的信息。如何减少各种数据之间的固有差距和时空数据异质性以及如何建立不同平台、不同源、不同时相数据之间的耦合机制是当前测绘大模型亟需解决的关键问题。

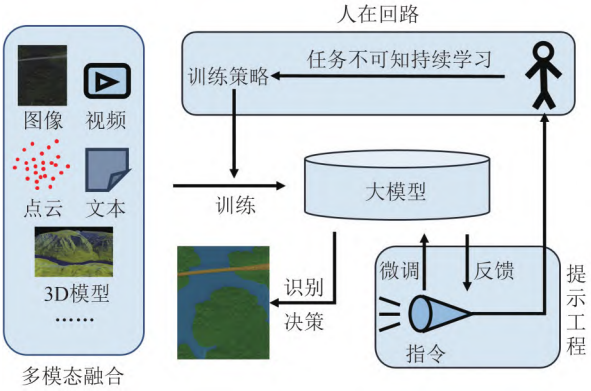

图 3　时空信息测绘大模型关键技术组成

Fig. 3　Key Technologies of Spatiotemporal Information Large Models for Surveying and Mapping

多模态联合大模型将改变单一模型处理单一任务的现状,为不同的任务创建统一的共性平台技术,具有广阔的前景。时空信息测绘大模型多模态框架应当充分利用多源、多平台、多时相时空数据的冗余性、互补性和合作性,对模型在测绘领域的特定任务进行训练和微调,使其获取更加精细和丰富的数据信息,同时还可以利用新数据进行持续学习以更好地服务于专业需求。

预训练语言大模型出现以来,开启了人工智能发展的热潮,引入跨模态信息的融合与交互以补足语言模型的短板,形成多模态大模型,是由限定领域的弱人工智能迈向通用人工智能的关键。因此,测绘领域多样的数据框架天然适合多模态技术的应用,主要分为3类工作:以语言大模型为基础调动不同模块完成多模态任务、利用视觉和语言模型融合、直接编码跨模态数据与语言模型进行融合,并利用语言模型存储、检索、推理知识库。Visual ChatGPT[41]将语言大模型作为核心组件,根据用户交互提示调动外部视觉模块完成任务。HuggingGPT[42]在 Visual ChatGPT 的基础上将外部提示从视觉专家模型扩展为视觉、语言、音频专家模型的集合。KOSMOS-1[43]通过对其视觉编码器和语言编码器共同解码训练任务以实现多模态交互。然而,测绘领域大模型的数据源多种多样,因此如果只结合视觉和语言信息难以有效表征丰富的时空信息,同时基于光学影像的视觉数据不足以反映多种信号形式,需要结合多源信号下的数据融入大模型架构才能适应多样化的下游任务。

通过直接编码跨模态数据结合语言模型可以充分利用语言模型的推理能力与庞大的知识库。Forzen[44]和 Flamingo 冻结语言模型参数直接编码视觉数据,并利用不同模块加强跨模态的信息交互。BLIP-2[45]利用 BLIP[46]的思想,首先使用传统的预训练学习视觉和语言的映射关系,直接学习由文本知识引导的跨模态数据隐式编码,而后利用语言模型剔除无关的跨模态信息,用于后续的下游任务处理。LLaMA-Adapter[47]和 ML-MFSL[48]同样也是直接编码跨模态数据,利用跨模态数据可学习的特征加强与语言模型的关联关系。编码多模态数据形成可学习的特征后与语言模型进行关联,将有效表征难以直接获取的空间信息。

然而,与传统多模态数据不同的是,测绘时空数据具有地理异质性和时间异质性,而且通常涵盖了大范围空间,因此需要构建有效的特征对齐与匹配机制。因传感器和观测方式不同,所获取的空间信息差异较大,需要将不同源的数据进行关联,例如建模跨模态数据的相关性,利用对比学习将数据特征进行匹配,尤其是不同维度的数据需要建立不同的特征空间,在特征空间中进行转化和匹配。一方面可以将大模型拆分为不同数据或不同观测的方式的小模型,应用于特定场景和需求的下游任务,另一方面可以集合所有特征映射进行关联分析,以不同数据上下文形成交互,弥补不同数据的固有缺陷和不足,进行统一的分析和应用。时空信息测绘大模型应当具备整体观测能力,即面对时空空间高度异质性和时相差异时,可以结合时空知识图谱与带有时空标记的时序网络,形成场景级-城市级-对象级的跨尺度、跨时空的特征,对空间中不同位置的地物要素,从微观和宏观两个视角形成交互,增强大模型的感知和理解。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

3.2 提示工程优化测绘大模型微调

提示工程简称提示，就是给大模型的输入信息。提示可能是问题，可能是描述，也可能是带有参数的描述。提示工程就是设计、改进、完善提示的学问和技术。通过设计和优化输入提示，使模型能够更准确、可靠地回答问题、执行任务以及提供更有价值的信息。微调大模型涉及在特定的领域或任务数据集上对模型进行训练，以适应特定的领域或任务。微调是以预训练的通用人工智能大模型为基础起点，根据人工提示、数据和参数，对网络的权重将根据特定于任务的数据进一步优化，有助于更好地理解模型对于当前任务的特定模式和上下文先验知识。随着大模型的发展，提示工程扮演了越来越重要的角色，精心设计的提示能够有效指导下游任务，为了突破特定领域的限制，就需要整合多样化数据集，结合跨学科方法扩大知识的广度。如何构建提示工程对时空信息测绘大模型进行微调，是大模型适用于专业领域特定需求任务，以及具有涌现能力的一项重要问题。

在自然语言处理领域，提示工程主要通过附加上下文输入对预训练模型进行调优，以缩小预训练模型和下游任务之间的差距。其提示分为两类：一类是完型提示，存在于文本中间；另一类是前缀提示，存在于文本末尾。早期的提示利用手工设计的尝试定义应对特定的下游任务，但是预先设计的提示通常不是最优的提示，难以有效应对许多复杂和困难的任务。因此许多研究人员通过稀疏监督设计自动学习以生成最优提示，分为离散提示和连续提示两类。离散提示是自然文本的上下文，自动搜索与相应短语相关的离散空间，查找与训练输入和输出有关的提示。连续提示不再将提示限制在离散空间中，而是在连续文本嵌入空间中自动构建所需的提示，利用序列-序列进行搜索过程，可以在下游任务中自适应地进行优化。提示工程需要适应不同任务的上下文需求，成为了大模型泛化的关键因素。许多工作任务领域专家知识作为优先提示可能为复杂场景提供有效的解决方案，SAM-Adapter将专有领域的知识注入到原始的SAM模型中，SAA+[49]利用特定领域的专业知识和来自目标图像的上下文信息构造正则化提示。Visual ChatGPT以外部视觉专家模型构建提示，外部提示包括ControlNet[50]和Stable Diffusion[51]等。时空信息的语言描述通常带有既定的方位、坐标和各种属性信息，因此对时空信息测绘大模型构建的文本提示应当具有随机适应性。时空信息测绘大模型的文本提示，以完型提示方式附加在空间数据之上，同时以自学习的能力对数据上下文进行搜索，对空间属性和信息进行完善，才能使模型对特定场景和数据具有更强的学习能力。

在视觉大模型中，最早的视觉提示是交互式分割，需要根据用户输入指导算法识别对象边界。CLIP采用人工提示的策略建模图像和文本对象的关联性，然而手工提示的方式对结果高度敏感。近年来，研究人员开始探索将提示定义为针对特定视觉任务的连续向量，以提示作为视觉任务的指导信号进行微调。以知识的链式结构作为提示可以帮助模型理清思路、分析问题，从而给出更符合预期的输出。CoOP[52]引入了自动提示的概念，该策略将下游任务的提示表示为一个可训练的连续向量，以增强提示的灵活性和可调节性。同时，利用图像编码器的输出结合可训练的提示符，设计为以图像特征作为条件的动态提示，实现了更好的泛化性。DenseCLIP[53]使用了类似的策略，构建上下文感知提示，以捕捉图像像素和文本之间的语义关联性，将图像-文本匹配问题转化为像素-文本匹配问题，从而提升模型性能。

对于测绘领域而言，最好的专有领域知识之一即数据本身。大模型针对特定领域的数据集，在基础预训练模型的基础上进一步进行训练，即为基于数据提示的微调模式。根据任务需求不同、观测方式不同和空间不同，不同的数据集往往具有特殊性，尤其是具有特定标注的数据集可以使模型对于特定标注具有更好的拟合能力。但是这种微调依赖于用例，并且随着训练时间的推移会出现过拟合和数据漂移等问题，需要在重复的过程中保持数据集的增长。

依赖单一模态的提示会导致模型失衡，而集成多种提示进行微调，通过在同一任务上训练的多个提示，为一个任务创建多个单独的模型，同时在整个过程中共享核心的通用预训练参数，可使领域内多任务协同的推理更加有效。因此，建模跨模态连续提示的多模态提示学习（multi-model prompt learning，MaPLe）增加了模型结果的性能。Imagic[54]作为一种文图扩散模型，引入了复杂的基于文本的语义编辑，在保留图像原始特征的基础上，依据文本操作图像中的对象姿态和组合。PTP（position-guided text prompt）[48]设

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

计为一种位置引导提示,将视觉任务定义为空白填充问题。研究人员认为在保留现有知识的基础上对模型进行微调,提示才能够有效地适应特定任务需求,因此 ViPT[55]提出一种提示调优策略对基本模型的参数进行微调,利用嵌入在预训练模型中的先验知识促进图像和辅助模态数据的特征提取。DAM-VP[56]为了解决不同数据分布之间传递知识困难的问题,引入多样性感知提示,将下游数据集划分为更小的同质子集进行单独优化,自适应地利用下游数据集中的多样性,进行有效的迁移学习以提升泛化性。Text2Seg[57]利用文本生成边界框指导 SAM 分割掩码,而后利用 CLIP 生成热图,将热图中的点作为提示代入 SAM 进行语义分割。Caption Anything[58]集成了 SAM 和 ChatGPT,将视觉-语言模式进行合并,首先利用点提示或边界框对输入图像形成交互式操作,然后利用语言模型进一步细化输出指令,确保输出与用户的预期含义有效对齐。测绘地理信息领域的多样化数据为多模态提示学习提供了可能,多样化的数据可以完善大模型训练中数据的固有缺陷和不足,例如三维立体观测的引入弥补了二维数据的空间维度的深度缺失,不同信号源的数据又可以弥补空间数据属性的差异。

面对大模型和海量数据,全参数微调明显不现实,必须要引入高效的微调方法。最早的参数高效微调方法是 Adapter[59],在 Transformer 中添加更多层并只对新添加层进行微调,而不是对整个模型进行微调。此外,低秩近似训练 LoRA[60]的原理是修改神经网络中可更新参数的训练和更新方式。因为预训练神经网络的权重矩阵是满秩的,这意味着每个权重都是唯一且不能通过组合其他权重进行制作。当通用预训练模型调整为新模型时,预训练过程已经捕获了大部分必要的信息,则可以利用具有较低秩的矩阵表示更新权重,在微调期间仅进行特定任务的调整。P-Tuning[61]根据提示构建小型的编码器网络将优化模式传递给模型。Prefix-Tuning[62]在 P-Tuning 的基础上添加了可学习参数提高模型对微调任务的拟合能力。Huggface 结合上述 4 类方法构造参数高效微调库,LLM-Adapters[63]在 Huggface 的基础上扩增了 MAD-X[64]和 Parallel[65],可针对不同的任务执行不同的微调。在基础大模型上添加额外的适配器进行微调会引入额外的计算量,从而带来推理延迟。因为时空信息测绘大模型相较于通用人工智能大模型,其数据量更大,数据形式、结构及属性涵盖的信息更广,时空信息测绘大模型进行微调时需要对更多的参数进行微调的同时引入更多的额外参数,因此必须要将全量微调进行一般化处理,进行高效参数微调,以恢复全量微调的表现力。此外,时空信息测绘大模型在对领域内不同任务进行微调时,由于任务的专业知识和数据存在一般性,在部署时可明确计算和存储模型的权重矩阵并正常执行推理。当需要切换到具体下游任务时,如果将初始权重固定,仅训练归纳和偏置对模型进行快速微调可减少内存的开销。同时,在模型优化的过程中不需要存储已固定的优化器状态,可减少大量参数的梯度计算,以更低的成本切换任务。

3.3　人在回路-决策引导的测绘大模型迭代

尽管以提示进行微调可以充分利用人工智能强大的逻辑推理能力,但是长期仅仅依赖提示,模型将会出现高延迟、幻觉和结果不明显的问题。例如,当载入需要链接的长提示,模型将会出现等待延迟;或者当模型失去提示后,会因为没有上下文支撑而难以得到有效的输出;在没有新数据的情况下,依靠提示提供的竞争优势将会逐渐消失。同时,许多领域大模型得到预训练过程通常从头开始,或是难以依靠特定领域和下游任务的专业知识进行训练,并不能解决模型在领域中的特殊性问题。如果一直以静态知识库进行训练,则可能因为知识库的过时而生成不准确或不恰当的内容。时空信息测绘大模型需要应对现实场景中的需求和挑战,能够在不同的环境、条件下自主地学习新的知识,更需要学会人类的决策手段以优化自身,适应新的地理空间变化。首先,通过人在回路的训练方法可解决主观意志无法确定情况下如何行动的问题。通过人的力量,帮助人工智能实现进化,让模型可顺应变化的环境,人的智能让大模型变得更加智能化。在训练过程中,除了人在回路方法之外,为了解决灾难性遗忘问题,持续学习构建了具备持续学习的智能体,能够具有良好的可塑性和稳定性,即对旧知识进行记忆并对新知识进行持续学习。因此,模型微调和训练不仅需要依靠提示,还需要保持持续学习,并能够学习人类决策行为,而后自己决策如何进行下一步的迭代更新,实现终身学习。

人的决策是引导模型迭代的一项关键因素。大模型要和人类进行交互,交互的过程也是大模

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

型学习的过程。大模型可以在交互的过程中，对人类的行为进行建模，强调在不同数据、不同条件下人类趋向于获取何种信息，在不同场景、不同任务下人类趋向于得出何种结论，做出何种决策。大模型的智能表现在应对海量数据训练出的模型可以拟出泛化性极好的结果。时空信息测绘大模型应具有动态接收新数据、新结构的能力，在模型中加入新的知识可能会引起数据分布的变化，因此需要再训练与静态知识库分布不同的新的知识和数据时，需要重新增加学习率，加快模型对新数据的适应能力，以提高计算效率。同时，尽管增加学习率可能引起初始阶段损失的增加，但在长期任务中则可以学习到更好的表示和特征，可提高下游任务的表现。

然而，测绘数据的形态、属性变化复杂，使用新数据和新结构对模型进行持续学习会对已有知识产生干扰。由于地理空间数据不会是一成不变的，所面对的场景和任务也是多种多样的，无法将面向的场景和任务具体化，那么就需要任务不可知持续学习。因此，测绘大模型需要能够适应环境的变化，依靠人的智能决策引导提升模型智能化水平。人在回路类似于人类辅助模型的思想，模型利用主动学习寻求对数据的标注分析并给出置信度，模型也需要在训练中不断地进行人机交互，对模型自主的决策进行修正和引导。这将再次结合多模态融合与理解以及提示工程，共同辅助模型进行有效的终身学习。

4 时空信息测绘大模型的挑战

随着硬件技术的进步和算法的优化，通用大模型将继续向更大型、更复杂、更智能的方向发展，在发展其广泛性的同时，与各个行业的特点和需求相结合，在行业领域的许多场景下解决复杂的决策任务，在城市、行业和企业数字化转型到智能化的过程中具有巨大潜力。时空信息测绘大模型可为智慧城市、智慧交通、智慧水利、智慧农业等典型应用提供智能分析支撑，同时也存在行业理解不深、消耗能量大、数据安全度低、数据处理难度大等挑战。

4.1 行业理解深度

目前人工智能大模型已成功应用于图像识别等领域，并具有高超的自然语言处理技术。大模型的落地与开发需要较高的技术成本。而利用其解决测绘地理信息的实际问题，将大模型与测绘产业融合，保障大模型应用的准确性和可靠性，更需要大模型本身具备对空间测绘的深入理解和应用能力。目前的大模型已具有可观的泛理解能力，面对一个问题，大模型可以用各种方式来回答，但是否能够真正理解人想问的问题仍然是一个难点。而且，大模型在输出时，上下文有没有一致性、大模型内部有没有对已经认知的事件做建模，都是需要探索和解决的。特别是面对特定行业专业问题时，这一挑战显得尤为重要。需要对模型做出改进，针对性提高模型对该行业的理解深度。

4.2 数据安全隐患

基础测绘地理信息数据具有极高的保密性，数据安全的重要性毋庸置疑。然而，大模型自身的特点使其具有数据隐私泄露、数据滥用等方面极大的风险。例如，全球范围内目前已发生多起因使用大语言模型ChatGPT导致的数据泄露事件。意大利个人数据保护局已宣布禁止ChatGPT的使用，并限制OpenAI公司处理意大利用户信息。针对隐私安全的质疑，OpenAI公司也做出收集到的数据只会用于模型训练、不用以营利的回应。而在时空信息测绘大模型的实际应用中，势必会有大量时空信息数据的输入。时空信息具有定位准、精度高、涉密广等安全特征，其在存储、传输、计算过程中将会面临很大的安全风险，由大模型引起的数据安全隐患不容忽视。

4.3 内容可信度保障

目前，不断创新的大模型表现出越来越强大的涌现能力。将多模态、多元化的地理空间大数据进行融合训练，对空间数据进行快速处理、精确分析。然而，由于时空信息在空间上的异质性，大模型的泛化能力和迁移能力面临挑战，其内容的可信度无法保障。在一个区域特定时段训练的模型，被迁移到另外一个区域和新的时间阶段具有地理空间相似性区域的模型，一般表现较好，但是如果其环境影响因子不相似，模型表现就较差。如果用海量的数据如全球尺度的数据训练地学空间大模型，或许才能解决空间异质性的问题。除此之外，时空信息测绘大模型目前处在数字化向智能化转型的应用初期，应用场景划分尚不清晰，数据资源普遍以不同的行业标准和不同的文件格式分散在跨单位、跨源、跨地域的服务器中，未能经过统筹治理形成标准统一的数据资产，为大模型的训练和微调提供可靠、高质量的数据支撑具有一定的难度。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.4 训练部署成本优化

目前,大模型的训练部署依然具有高昂的成本。伴随着参数规模增速的不断提升,大模型的训练成本依然存在瓶颈,并有较大的优化空间。华为大模型负责人田奇称,大模型开发和训练一次需要1 200万美元,大模型的两大开支(算力和电力)的降本增效已迫在眉睫。而据国盛证券报告《ChatGPT需要多少算力》估算,大型语言模型GPT-3训练一次的成本约为140万美元,对于一些更大的语言模型,训练成本则介于200万～1 200万美元之间。模型部署需要合理把控成本、功耗和性价比三大因素,将模型部署到硬件上的成本将极大限制用户的业务承受能力。与人类脑力消耗相比,大训练的训练成本之高,可推断目前不是最优解。在追求大模型于测绘地理信息实际应用的同时,考虑训练以及部署成本,如何进行降本增效,同样是各企业及科学家面临的挑战之一。

5 时空信息测绘大模型的发展趋势

目前,以数据密集型计算为特征、以人工智能为主要技术手段的通用人工智能技术,为测绘地理信息提供了解决行业挑战的变革性理论、方法和技术。测绘地理信息行业处在科技前沿,行业科技进步与人工智能技术发展进程密不可分。时空信息涵盖了所有涉及空间、时间分布的事物和现象,其研究对象和应用领域与各行各业紧密关联。人工智能技术已经成为了智能化测绘的主要技术之一,智能化测绘通过相应技术和理论,随时随地解决各行各业时空信息方面的实际问题,满足用户对地理信息的需求。时空信息测绘大模型如空天·灵眸、天权视觉、书生·天际和商汤SenseEarth3.0等已经出现,参数规模分别为10 B、30 B和200 B。其中,商汤SenseEarth3.0可对多个省份的建筑、物体进行建模,覆盖范围大;天际大模型能够对城市级别区域进行高精度建模,同时也支持下游视觉任务如目标捕捉、物体的追踪识别等。智能化测绘通过多模态数据融合、专业领域知识提示工程与决策引导的模型迭代,实现环境感知、空间认知等高级测绘技术。

时空信息测绘大模型将提供实时化、动态化的数据保障,自动化、智能化的数据处理,知识化、智慧化的分析和决策,同时也将可以从传统测量仪器的几何信息获取拓展到泛在智能传感器支撑的动态感知,从以模型、算法为主的数据处理转化为以知识为引导的通用领域人工智能平台,将单一任务、场景的单项化测绘工作集成为统一平台、面向全行业的技术体系。未来,通过人工智能对时空数据进行采集、处理、分析、计算,并进行智能决策,突破综合多模态融合与理解架构、提示工程优化和决策引导模型迭代等理论方法,建立通用的时空信息测绘大模型,将创新地理信息科技思维,发现新知识和新规律,加速智能化测绘发展。

参 考 文 献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[J]. *Advances in Neural Information Processing Systems*, 2017, 30:1706.03762.

[2] OpenAI Team. ChatGPT: Optimizing Language Models for Dialogue [EB/OL]. (2022-09-20) [2023-09-27]. https://openai.com/blog/chatgpt/.

[3] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [EB/OL]. (2018-10-11) [2023-09-20]. https://arxiv.org/abs/1810.04805.

[4] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer [J]. *Journal of Machine Learning Research*, 2020, 21(1): 5485-5551.

[5] Radford A, Narasimhan K. Improving Language Understanding by Generative Pre-training. [EB/OL]. (2018-05-16) [2023-09-27]. https://blog.openai.com/language-unsupervised.

[6] Radford A, Wu J, Child R, et al. Language Models Are Unsupervised Multitask Learners[J]. *OpenAI Blog*, 2019, 1(8): 9.

[7] Zhao W X, Zhou K, Li J Y, et al. A Survey of Large Language Models[EB/OL]. (2023-03-31) [2023-09-22]. https://arxiv.org/abs/2303.18223.

[8] OpenAI. GPT-4 Technical Report [EB/OL]. (2023-03-15) [2023-09-27]. https://arxiv.org/abs/2303.08774.

[9] Chowdhery A, Narang S R, Devlin J, et al. PaLM: Scaling Language Modeling with Pathways [EB/OL]. (2022-04-05) [2023-09-25]. https://arxiv.org/abs/2204.02311.

[10] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and Efficient Foundation Language Models [EB/OL]. (2023-02-27) [2023-09-20]. https://arxiv.org/abs/2302.13971.

[11] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale[EB/OL]. (2020-10-22) [2023-09-28]. https://arxiv.org/abs/2010.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

11929.

[12] Riquelme C, Puigcerver J, Mustafa B, et al. Scaling Vision with Sparse Mixture of Experts[EB/OL]. (2021-11-10) [2023-09-18]. https://arxiv.org/abs/2106.05974.

[13] Kirillov A, Mintun E, Ravi N, et al. Segment Anything [EB/OL]. (2023-04-05) [2023-09-22]. https://arxiv.org/abs/2304.02643.

[14] Darmé L, Degrande C, Duhr C, et al. UFO 2.0: The Universal Feynman Output Format[EB/OL]. (2023-04-19) [2023-09-27]. https://arxiv.org/abs/2304.09883.

[15] Bi K F, Xie L X, Zhang H H, et al. Accurate Medium-Range Global Weather Forecasting with 3D Neural Networks [J]. *Nature*, 2023, 619(7970): 533-538.

[16] InternLM Team. Internlm: A Multilingual Language Model with Progressively Enhanced Capabilities. [EB/OL]. (2023-01-06) [2023-09-27]. https://github.com/InternLM/InternLM.

[17] Sun C, Myers A, Vondrick C, et al. VideoBERT: A Joint Model for Video and Language Representation Learning[C]//IEEE/CVF International Conference on Computer Vision (ICCV), Seoul, South Korea, 2019.

[18] Zhu L C, Yang Y. ActBERT: Learning Global-Local Video-Text Representations [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, USA, 2020.

[19] Li L J, Chen Y C, Cheng Y, et al. HERO: Hierarchical Encoder for Video+Language Omni-representation Pre-training [EB/OL]. (2021-05-01) [2023-09-24]. https://arxiv.org/abs/2005.00200.

[20] Feichtenhofer C, Fan H Q, Li Y H, et al. Masked Autoencoders as Spatiotemporal Learners [EB/OL]. (2022-11-01) [2023-09-27]. https://arxiv.org/abs/2205.09113.

[21] Jia M L, Tang L M, Chen B C, et al. Visual Prompt Tuning[C]//European Conference on Computer Vision, Cham, Switzerland, 2022.

[22] Wang X, Yuan H J, Zhang S W, et al. VideoComposer: Compositional Video Synthesis with Motion Controllability[EB/OL]. (2023-06-03) [2023-09-20]. https://arxiv.org/abs/2306.02018.

[23] Zhang D Y, Liang D K, Yang H C, et al. SAM3D: Zero-Shot 3D Object Detection via Segment Anything Model [EB/OL]. (2023-06-04) [2023-09-23]. https://arxiv.org/abs/2306.02245.

[24] Mildenhall B, Srinivasan P P, Tancik M, et al. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis [J]. *Communications of the ACM*, 2022, 65(1): 99-106.

[25] Cen J Z, Zhou Z W, Fang J M, et al. Segment Anything in 3D with NeRFs[EB/OL]. (2023-04-24) [2023-09-22]. https://arxiv.org/abs/2304.12308.

[26] Zhao Z R, Mao Y J, Ding Y, et al. Visual-based Semantic SLAM with Landmarks for Large-Scale Outdoor Environment[C]//The 2nd China Symposium on Cognitive Computing and Hybrid Intelligence (CCHI), Xi'an, China, 2019.

[27] Cardinali R, Anniballi E, Bongioanni C, et al. ARGUS 3D: Security Enhancements Through Innovative Radar Technologies[C]//International Conference on Availability, Reliability and Security, Regensburg, Germany, 2013.

[28] Shao J, Chen S Y, Li Y G, et al. INTERN: A New Learning Paradigm Towards General Vision [EB/OL]. (2021-11-16) [2023-09-29]. https://arxiv.org/abs/2111.08687.

[29] Xiangli Y B, Xu L N, Pan X G, et al. Bungee-NeRF: Progressive Neural Radiance Field for Extreme Multi-Scale Scene Rendering[C]//European Conference on Computer Vision, Cham, Switzerland, 2022.

[30] Hong Y N, Zhen H Y, Chen P H, et al. 3D-LLM: Injecting the 3D World into Large Language Models [EB/OL]. (2023-07-24) [2023-09-26]. https://arxiv.org/abs/2307.12981.

[31] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models from Natural Language Supervision [C]//International Conference on Machine Learning, Baltimore, USA, 2021.

[32] Li L H, Zhang P, Zhang H, et al. Grounded Language-Image Pre-training [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022.

[33] Luo H S, Ji L, Zhong M, et al. CLIP4Clip: An Empirical Study of CLIP for End to End Video Clip Retrieval and Captioning [J]. *Neurocomputing*, 2022, 508: 293-304.

[34] Wang M M, Xing J Z, Liu Y. ActionCLIP: A New Paradigm for Video Action Recognition[EB/OL]. (2021-09-17) [2023-09-20]. https://arxiv.org/abs/2109.08472.

[35] Zhou L D, Schneider F B, Van Renesse R. COCA: A Secure Distributed Online Certification Authority [J]. *ACM Transactions on Computer Systems*, 2002, 20(4): 329-368.

[36] Alayrac J B, Donahue J, Luc P, et al. Flamingo: A Visual Language Model for Few-Shot Learning[EB/

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

OL]. (2022-11-01) [2023-09-20]. https://arxiv.org/abs/2204.14198.

[37] Chen X, Wang X, Changpinyo S, et al. PaLI: A Jointly-Scaled Multilingual Language-Image Model [EB/OL]. (2022-09-14) [2023-09-20]. https://arxiv.org/abs/2209.06794.

[38] Institute of Automation, Chinese Academy of Sciences. The "Zidong Taichu" Full Modal Large Model has Been Officially Released [EB/OL]. (2023-06-16) [2023-09-20]. https://mp.weixin.qq.com/s/BLg6mqZ2Hi8JiplKsDD77g. (中国科学院自动化研究所. "紫东太初"全模态大模型正式发布 [EB/OL]. (2023-06-16) [2023-09-20]. https://mp.weixin.qq.com/s/BLg6mqZ2Hi8JiplKsDD77g.)

[39] Wu C F, Liang J, Ji L, et al. NÜWA: Visual Synthesis Pre-training for Neural Visual World Creation [C]//European Conference on Computer Vision, Cham, Switzerland, 2022.

[40] Fudan University. Computing for the Future at Fudan [EB/OL]. (2023-09-15) [2023-09-22] http://cfff.fudan.edu.cn/home.

[41] Wu C F, Yin S M, Qi W Z, et al. Visual ChatGPT: Talking, Drawing and Editing with Visual Foundation Models [EB/OL]. (2023-03-08) [2023-09-22] https://arxiv.org/abs/2303.04671.

[42] Shen Y L, Song K T, Tan X, et al. HuggingGPT: Solving AI Tasks with ChatGPT and Its Friends in Hugging Face [EB/OL]. (2023-03-30) [2023-09-25]. https://arxiv.org/abs/2303.17580.

[43] Huang S H, Dong L, Wang W H, et al. Language Is not All You Need: Aligning Perception with Language Models [EB/OL]. (2023-02-27) [2023-09-27]. https://arxiv.org/abs/2302.14045.

[44] Tsimpoukelli M, Menick J L, Cabi S, et al. Multimodal Few-Shot Learning with Frozen Language Models [J]. *Advances in Neural Information Processing Systems*, 2021, 34: 200-212.

[45] Li J N, Li D X, Savarese S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models [EB/OL]. (2023-06-30) [2023-09-26]. https://arxiv.org/abs/2301.12597.

[46] Li J N, Li D X, Xiong C M, et al. BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation [C]//International Conference on Machine Learning, Xiamen, China, 2022.

[47] Zhang R R, Han J M, Liu C, et al. LLaMA-Adapter: Efficient Fine-tuning of Language Models with Zero-init Attention [EB/OL]. (2023-03-28) [2023-09-20]. https://arxiv.org/abs/2303.16199.

[48] Wang J P, Zhou P, Shou M Z, et al. Position-Guided Text Prompt for Vision-Language Pre-training [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023.

[49] Cao Y K, Xu X H, Sun C, et al. Segment Any Anomaly Without Training via Hybrid Prompt Regularization [EB/OL]. (2023-05-18) [2023-09-25]. https://arxiv.org/abs/2305.10724.

[50] Zhang L, Rao A, Agrawala M. Adding Conditional Control to Text-to-Image Diffusion Models [C]//IEEE/CVF International Conference on Computer Vision, Paris, France, 2023.

[51] Rombach R, Blattmann A, Lorenz D, et al. High-Resolution Image Synthesis with Latent Diffusion Models [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, USA, 2022.

[52] Zhou K Y, Yang J K, Loy C C, et al. Learning to Prompt for Vision-Language Models [J]. *International Journal of Computer Vision*, 2022, 130(9): 2337-2348.

[53] Rao Y M, Zhao W L, Chen G Y, et al. DenseCLIP: Language-Guided Dense Prediction with Context-Aware Prompting [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, USA, 2022.

[54] Kawar B, Zada S, Lang O, et al. Imagic: Text-based Real Image Editing with Diffusion Models [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023.

[55] Zhu J W, Lai S M, Chen X, et al. Visual Prompt Multi-modal Tracking [C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023.

[56] Huang Q D, Dong X Y, Chen D D, et al. Diversity-Aware Meta Visual Prompting [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023.

[57] Zhang J L, Zhou Z L, Mai G C, et al. Text2Seg: Remote Sensing Image Semantic Segmentation via Text-Guided Visual Foundation Models [EB/OL]. (2023-04-20) [2023-09-25]. https://arxiv.org/abs/2304.10597.

[58] Wang T, Zhang J R, Fei J J, et al. Caption Anything: Interactive Image Description with Diverse Multimodal Controls [EB/OL]. (2023-05-04) [2023-09-22]. https://arxiv.org/abs/2305.02677.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[59] Houlsby N, Giurgiu A, Jastrzebski S, et al. Parameter-Efficient Transfer Learning for NLP[C]//International Conference on Machine Learning, California, USA, 2019.

[60] Hu E J, Shen Y L, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[EB/OL]. (2021-06-17)[2023-09-20]. https://arxiv.org/abs/2106.09685.

[61] Liu X, Zheng Y, Du Z, et al. GPT Understands, Too [EB/OL]. (2021-07-20) [2023-09-25]. https://arxiv.org/abs/2103.10385.

[62] Li X L, Liang P. Prefix-Tuning: Optimizing Continuous Prompts for Generation[EB/OL]. (2021-01-01) [2023-09-20]. https://arxiv.org/abs/2101.00190.

[63] Hu Z Q, Lan Y H, Wang L, et al. LLM-Adapters: An Adapter Family for Parameter-Efficient Fine-Tuning of Large Language Models [EB/OL]. (2023-04-04) [2023-09-20]. https://arxiv.org/abs/2304.01933.

[64] Pfeiffer J, Vulić I, Gurevych I, et al. MAD-X: An Adapter-based Framework for Multi-Task Cross-Lingual Transfer[EB/OL]. (2020-04-30)[2023-09-22]. https://arxiv.org/abs/2005.00052.

[65] He J X, Zhou C T, Ma X Z, et al. Towards a Unified View of Parameter-Efficient Transfer Learning [EB/OL]. (2021-10-08)[2023-09-26]. https://arxiv.org/abs/2110.04366.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net