引用格式:段雨希,陈碧宇,李岩,等. 地理知识图谱推理研究进展与展望[J]. 地球信息科学学报,2025,27(1):41-59. [Duan Y X, Chen B Y, Li Y, et al. Reasoning on geographical knowledge graph: Advances and perspectives[J]. Journal of Geo-information Science,2025,27(1):41-59.] **DOI:**10.12082/dqxxkx.2025.240460; **CSTR:**32074.14.dqxxkx.2025.240460

地理知识图谱推理研究进展与展望

段雨希[1,2],陈碧宇[1,2*],李　岩[1,2],张雪英[3,4,5],林　黎[1,2]

1. 武汉大学测绘 遥感信息工程国家重点实验室,武汉 430079; 2. 武汉大学社会地理计算联合研究中心,武汉 430079; 3. 南京师范大学地理科学学院,南京 210023; 4. 南京师范大学 虚拟地理环境教育部重点实验室,南京 210023; 5. 江苏省地理信息资源开发与利用协同创新中心,南京 210023

Reasoning on Geographical Knowledge Graph: Advances and Perspectives

DUAN Yuxi[1,2], CHEN Biyu[1,2*], LI Yan[1,2], ZHANG Xueying[3,4,5], LIN Li[1,2]

1. State Key Laboratory of information Engineering in Surveying , Mapping and Remote Sensing, Wuhan University, Wuhan 430079, China; 2. The Geo-Computation Center for Social Sciences, Wuhan University, Wuhan 430079, China; 3. School of Geography, Nanjing Normal University, Nanjing 210023, China; 4. Key Laboratory of Virtual Geographic Environment, Ministry of Education, Nanjing Normal University, Nanjing 210023, China; 5. Jiangsu Center for Collaborative Innovation in Geographical Information Resource Development and Application, Nanjing 210023, China

Abstract: [Objectives] With the application of knowledge graph techniques in the field of Geographical Information Science (GIS), the Geographical Knowledge Graph (GeoKG) has become a key research direction. GeoKGs often lack sufficient geographic knowledge coverage, which can negatively impact downstream applications. Therefore, reasoning techniques are essential for GeoKG to complete missing knowledge, identify inconsistencies, and predict trends in geographic phenomena. Unlike reasoning techniques applied to general knowledge graphs, reasoning on GeoKGs must handle the unique and complex spatial and temporal characteristics of geographic phenomena. This paper comprehensively introduces and summarizes recent advances in GeoKG reasoning. **[Analysis]** First, it introduces the relevant concepts and problem definitions of GeoKG reasoning. Second, it analyzes the two core tasks of GeoKG reasoning: knowledge completion and prediction. The reasoning model for knowledge completion primarily fills gaps in the graph to ensure knowledge integrity, while the reasoning model for prediction aims to forecast future trends based on existing geographic data. These two models are optimized for different application scenarios, with different focuses in processing geographic data. **[Prospect]** Finally, the paper explores future development trends in GeoKG reasoning, highlighting areas such as processing complex relationships in spatiotemporal data, reasoning with multi-scale geographic knowledge, fusing multimodal data, and enhancing the interpretability and intelligence of reasoning models. Additionally, the integration of GeoKGs with large-scale pre-trained models is expected to become a key area of focus.

Key words: GeoKG; geographic knowledge reasoning; research progress; geographic knowledge expression;

收稿日期:2024-08-19;**修回日期:**2024-11-01.

基金项目:国家重点研发计划项目(2021YFB3900903);国家自然科学基金项目(42271473)。[**Foundation items:** National Key Research and Development Project, No.2021YFB3900903; National Natural Science Foundation of China, No.42271473.]

作者简介:段雨希(1998—),女,广西桂林人,博士生,主要从事地理知识图谱研究。E-mail: yuxiduan@whu.edu.cn

***通讯作者:**陈碧宇(1980—),男,福建霞浦人,教授,主要从事交通地理信息系统、时空大数据挖掘、城市空间信息学。E-mail: chen.biyu@whu.edu.cn

中国知网 https://www.cnki.net

spatiotemporal data reasoning
***Corresponding author:** CHEN Biyu, E-mail: chen.biyu@whu.edu.cn

摘要：【目的】随着知识图谱技术在GIS领域应用和发展，地理知识图谱（GeoKG）近年来逐渐成为GIS领域的重要研究方向。GeoKG往往无法确保涵盖所有知识，知识的缺失和不一致性严重影响应用性能，需要采用GeoKG推理技术来自动补全缺失知识、识别矛盾知识、预测地理现象未来发展趋势。区别于通用知识图谱推理技术，GeoKG推理技术需要着重考虑地理知识的复杂时空特性。本文对近年来GeoKG的推理工作进行了全面介绍和总结。**【分析】**首先，介绍了GeoKG推理的相关概念与问题描述；其次，本文分析了GeoKG推理的二大核心任务：① 面向知识补全的推理模型，主要用于填补图谱中的空白，确保知识的完整性；② 面向预测任务的推理模型，旨在通过已有地理数据预测未来的趋势。两类模型各自针对不同的应用场景进行优化，并在地理数据的处理中各有侧重。**【展望】**展望了GeoKG推理的未来发展趋势，指出未来GeoKG推理技术的发展将更加关注时空数据的复杂关系处理、多尺度地理知识的推理、多模态数据的融合，以及提高推理模型的可解释性与智能化。此外，GeoKG与大规模预训练模型的结合也将成为关键方向。

关键词：地理知识图谱；地理知识推理；研究进展；地理知识表达；时空数据推理

1 引言

知识推理是指在已有的知识基础上，推导出新的知识或验证现有知识的一种智能化活动过程；它是人类智能活动的重要组成部分，一直以来也是人工智能的核心研究内容之一[1]。在知识图谱出现之前，知识推理方法主要包括逻辑推理、规则推理、概率推理等形式化方法自从2012年谷歌率先提出知识图谱概念以来，业界构建了大量开放的大型知识图谱工程（包括YAGO, DBpedia, Probase, NELL, Zhishi.me等），成为当前人工智能应用的主要知识载体和重要知识基础设施[2]。知识图谱通过结构化的三元组形式（实体–关系–实体）来表达客观世界中的概念、实体及其相互关系，形成了一种语义网络。知识图谱的结构化、语义关联和可扩展性特性使其成为知识推理的主要实现路径之一。知识图谱推理（KG Reasoning）通过将KG中的实体及其关系转化为低维向量空间，利用推理技术在知识库中推导出隐含的事实，补全缺失的三元组，从而提升知识图谱的完备性和应用效能，在知识搜索、智能问答、个性化推荐、预测决策等领域中取得了成功应用[3]。

地理知识不同于一般知识，后者更注重时间、空间和变化的知识[4]。因此，地理知识推理需要依赖于地理领域的知识图谱来进行处理和表达。作为知识图谱与地理信息科学（Geographic Information Science, GIS）结合的产物，地理知识图谱（Geographical Knowledge Graph 或 Geospatial Knowledge Graph，以下简称 GeoKG）近年来逐渐成为GIS领域的重要研究方向[5]。GeoKG是一种以地理时空分布特征为核心的知识图谱，通过计算机形式化描述来表达地理概念、实体及其相互关系，进而支持地理时空分布相关知识检索与推理，是将传统地理信息服务拓展到地理知识服务的关键[6]。一方面，GeoKG通过结合GIS空间建模技术，扩展了通用知识图谱的内涵，建模了地理要素的时空演化特征和地理学“人地”互动规律特点。另一方面，GeoKG通过引入知识图谱的语义表达能力，实现了从聚焦地理空间实体几何形态表达到时空与语义一体化建模的GIS能力拓展。在这一框架下，GeoKG不仅继承了通用知识图谱的语义推理能力，还集成了地理空间信息处理能力，能够有效支持时空分析、地理信息查询等GIS任务。具体来说，GeoKG推理主要通过引入空间和时间的维度，在传统知识图谱推理的基础上，扩展了空间拓扑关系和地理要素的时空动态演化模型，为GIS提供了可解释性的地理人工智能(Explainable Geographical Artificial Intelligence, X-GeoAI)的重要实现路径，有效辅助地理知识理解和发现。

国内外研究团队已经在GeoKG领域取得了一定的成果，并在此基础上初步探索了地理知识图谱的相关应用。国内的研究主要集中在GeoKG的构建及其与GIS时空数据的结合[6]，并通过将空间拓扑关系和时间动态特征引入知识图谱推理技术，为地理现象的时空分析提供支持。同时多个国际研究团队也围绕空间语义建模、时空数据推理等方面展开了深入研究[7-10]。例如，Google Earth Engine中的时空数据处理，以及美国国家地理空间情报局（NGA）在空间大数据推理方面的尝试，都是地理知识推理应用的具体体现。这些研究不仅为地理知识的自动化推理提供了坚实的技术基础，也为

中国知网 https://www.cnki.net

GeoKG的未来发展指明了方向。

尽管很多学者对通用知识图谱推理技术进行了总结和综述[3,5-7]，目前仍缺乏GeoKG推理技术的梳理和总结。GeoKG的推理不仅需要考虑传统的语义关系，还需要结合空间和时间的维度，这使得GeoKG推理技术在方法论上与通用知识图谱推理存在显著差异。例如，地理要素的时空动态演化模型、空间拓扑关系等复杂性使得地理知识推理技术的要求更加复杂。国外的相关研究虽然已经初步尝试了将时空信息引入知识图谱推理，但这些方法大多尚处于理论探索阶段，缺乏对时空关系及地理学规律的深入结合。因此，针对GeoKG推理的系统性总结和技术梳理是非常必要的。基于此，本文将在现有研究的基础上进一步拓展和总结GeoKG推理的最新算法以及应用进展，重点分析其在时空关系建模和推理方面的独特性与挑战。此外，本文也将结合作者团队此前的研究成果[7]，对GeoKG推理技术在地理时空分析中的应用进行更为全面的探讨。在此过程中，我们将特别关注GeoKG推理技术与通用知识图谱推理的共通性和独特性，探索其在实际应用中的潜力和局限性。最后，本文还将讨论当前GeoKG推理面临的挑战以及未来可能的研究方向，为相关领域的研究人员提供参考。

2 地理知识图谱推理相关概念

2.1 地理知识图谱概念

地理知识图谱（GeoKG）是通用知识图谱技术与地理信息科学（Geographic Information Science, GIS）的结合产物，旨在通过知识图谱的形式化技术，将地理知识表示为计算机可解释、可复用、可推理的知识网络[5]。地理知识不仅涵盖通用知识的语义特征，还具有明显的时空分布、多尺度和多模态特征。因此，GeoKG不仅遵循了通用知识图谱技术框架，还引入了地理实体的时间、空间和语义维度，支持地理要素的时空动态演化和多模态地理信息的关联表示[7]通常GeoKG采用（头节点、关系、尾节点）的三元组方式表达地理知识[7]，而由于GeoKG的时空性，也有研究认为GeoKG更遵循STKG（Spatial- temporal Knowledge Graph）框架中的实体五元组模型，采用（头节点、关系、尾节点、[时间域]、[空间域]）表示地理知识的实体、属性、时间域以及空间域，也有研究将GeoKG等同于STKG[11]。GeoKG还支持多源异构时空大数据的多模态表达，包括文本数据、地图数据、兴趣点（Point of interest, POI）数据、交通网络数据、个体轨迹数据、街景数据、遥感影像数据等。

图1以语义轨迹为例说明GeoKG地理知识表示。如图1(a)所示，语义轨迹需要一体化表达个体的时空位置序列和出行活动语义（如：出行交通模式、出行速度、活动类别等），关联多模态的地理实体，如各类POI、道路和公交网络、天气状况、遥感影像、街景照片等。GeoKG以一种统一的方式表示地理知识定义(Schema)和地理知识实例(Instances) 2个层次的知识。如图1(b)所示，Schema定义了一组地理知识的概念定义，也称为地理本体定义。例如SemPerson本体定义了个体的定义，它包括一系列个体社会经济属性（性别、年龄、职业、工作地等）和语义轨迹对象(SemPath)；SemPath本体定义了一系列属性（外出活动时长、外出活动次数等）和出行对象（SemTrip）与活动对象(SemActivity)。出行和活动本体表达三维时空（2维空间+1维时间）中的折线段，除了包含相应的出行活动语义外，还包括一些列时空直线段SemSeg对象。SemSeg本体表示在路网空间中匀速运动，包含2个时空点对象（GeoPoint）。时空点的三维坐标作为属性值存储。如图1(c)所示，Instances定义了一个家庭中两个个体的语义轨迹实例，包括各类地理实体实例（如：SemHousehold1、SemPerson1、SemPerson2等）、地理关系实例（如：HouseholdMember关系、Owner关系）和属性实例（如：经度、纬度、时刻、地铁站点POI、街景等）。通过以上实例，可以发现GeoKG能够一体化表达地理实体语义、时间与空间等多维度信息，快速关联多模态地理信息。

GeoKG往往具有时态信息，因此兼具时态知识图谱(Temporal Knowledge Graph, TKG)特点。从时态角度，地理知识可以分为：瞬时知识、区间知识和无时态知识。瞬时性知识表示瞬发性的知识，存储了知识的时刻点（如图1中的GeoPoint2）。区间知识表示有一定持续性的知识，存储了知识的开始和结束时间（如图1中的SemSeg1）。无时态知识是不具备时间信息（如图1中的黄浦路地铁站POI），被视为可观察时间域内永久有效的知识。同时，这些时态知识也往往伴随空间信息的变化，因此GeoKG不仅具备时态知识图谱的特点，还包含了对地理实体的空间位置的建模（如图1中的“114.31 °E, 30.61 °N”的经纬度信息）。这使得时空知识图谱推理成为GeoKG推理中的一个重要组成部分。时空推

中国知网 https://www.cnki.net

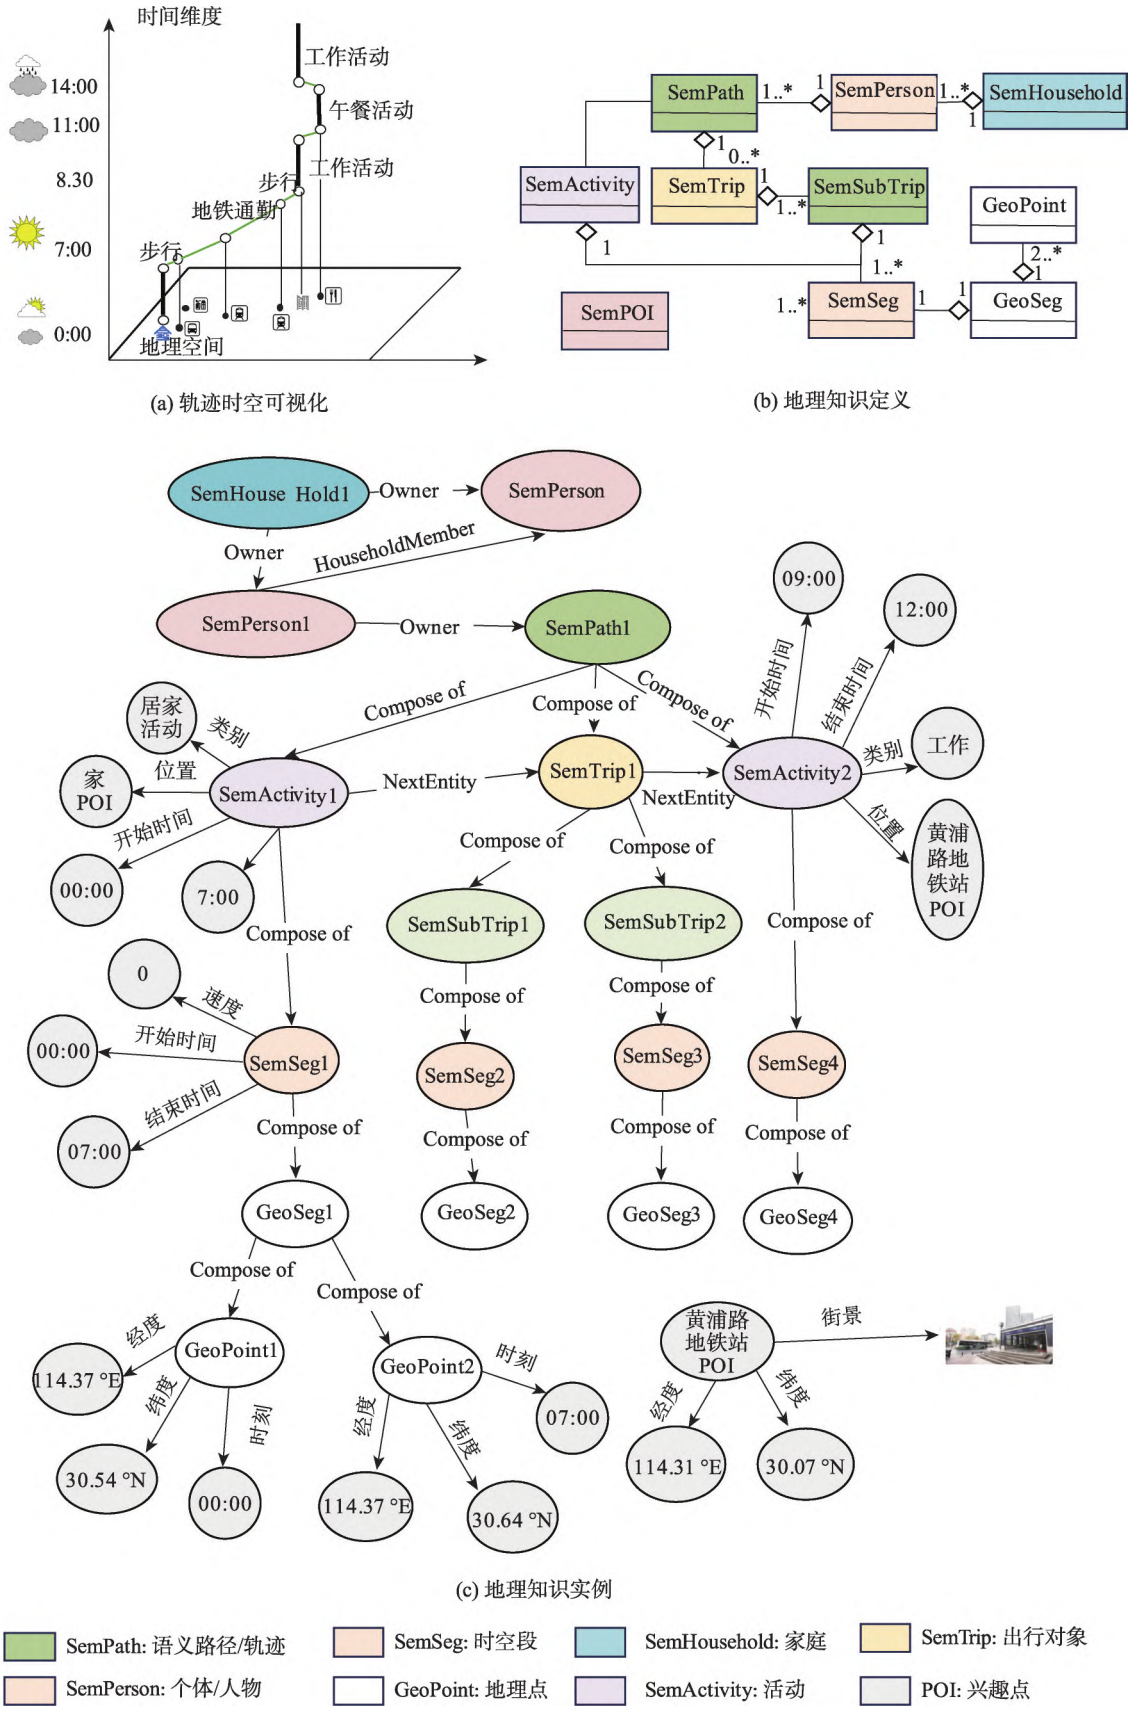

图1 地理知识图谱表达语义轨迹示例

Fig. 1 Illustrative example of representing semantic trajectories using GeoKG

中国知网 https://www.cnki.net

理不仅要处理地理实体在时间维度上的动态变化，还要结合空间上的位置信息与拓扑结构来进行联合推理。在诸如交通流量预测、灾害预警等任务中，时空知识图谱推理展现出核心作用，能够通过捕捉时间和空间信息的相互作用，提升地理事件预测的准确性与及时性。在之后的讨论中将会把时空知识图谱推理算法包含在地理知识图谱推理算法中讨论。

2.2 地理知识图谱推理任务

GeoKG知识推理（GeoKG Reasoning）是指利用GeoKG中实体、属性和关系等已有地理知识，通过构建智能化的推理算法，推导出新的地理知识或者验证现有知识的有效性，来更好地支撑GeoKG的下游应用任务。GeoKG的核心任务可以由式（1）定义。

$$f_{GeoKG}: GeoKG \times Q \rightarrow A \tag{1}$$

式中：$GeoKG$表示地理知识图谱；Q表示推理问题（例如需要补全的三元组或要验证的知识）；A表示推理的答案。GeoKG推理通过对地理实体（nodes）、属性（attributes）和关系（relations）进行时空推理，推导出新的知识或验证已有知识。

由于地理知识的时空特性，GeoKG推理可以认为是在通用知识图谱推理技术基础上拓展空间推理能力，并引入时态知识图谱技术形成时空知识的推理能力。基于图谱数据完整性、准确性以及时空动态特征的内在逻辑性。GeoKG推理任务可以分为图谱补全（GeoKG Completion），图谱去噪（GeoKG Denoising）以及图谱预测（GeoKG Prediction）。图谱补全任务用于填补图谱中缺失的知识，确保知识的完整性。补全任务依赖于现有三元组中的关联信息，通过推理补充缺失的实体或关系，例如在地理信息系统（GIS）中，自动补全道路网络和兴趣点（POI）的属性数据，可为城市规划和导航系统提供更精确的地理基础支持。图谱去噪任务侧重于判断图谱中现有三元组的有效性，排除错误或不一致的知识，这是保证GeoKG准确性的关键步骤，通常适用于交通监测系统的异常检测和历史地理信息的真实性验证。图谱预测任务用于推测未来知识的生成或关系的演变趋势，尤其在时间维度上的外推性预测，通过历史数据推断未来的发展，广泛应用于交通流量预测、自然灾害预警和气候变化分析等领域。

图谱补全专注于填补GeoKG中的缺失知识，解决数据不完整的问题。工业界大型的知识图谱往往存在较高的知识缺失比例。据统计，在Freebase知识库中有75%的人缺少国籍信息，DBpedia知识库中有60%的人缺少出生地信息[3]。知识的缺失严重影响GeoKG在下游应用的性能。虽然可以通过人工标注方式来完成小型GeoKG的知识补全，但是在大型GeoKG中的人工标注成本非常高。因此，需构建自动化的知识推理方法来实现大型GeoKG补全任务。根据缺失知识的类别，图谱补全任务可以进一步细分为实体补全和关系补全。实体补全是指给定（头节点、关系?），利用已有知识，推理出尾节点来构成完整的三元组，其具体任务可以由式（2）定义。关系补全任务的核心是通过已有的实体和关系信息，推理出缺失的关系，从而形成完整的三元组。同实体补全不同的是，关系补全除了可以推理三元组内部缺失的关系，还可以推理多个相关三元组之间的关系。三元组内部的关系补全是指给定（头节点、尾节点），推理出头尾节点间的关系来补全三元组，其核心任务可以由式（3）定义。相关三元组之间的关系补全主要涉及从多个相关的三元组中推理出新的关系。这种补全任务通常依赖于已有的三元组，通过逻辑推理、关系链等方式，推导出新的三元组，并补全其中的关系。例如给定2个或多个三元组，如(A, LocatedIn, B)和(B, LocatedIn, C)，通过已有的关系链，可以推理出A与C之间的关系LocatedIn，从而补全新的三元组(A, LocatedIn, C)。这种补全任务可以由式（4）定义。

$$f_{\mathrm{GeoKGC}}(h,r,?) = t \tag{2}$$

$$f_{\mathrm{GeoKGC}}(h,?,t) = r \tag{3}$$

$$f_{\mathrm{GeoKGC}}(h_1,r_1,t_1) \wedge f_{\mathrm{GeoKGC}}(t_2,r_2,t_3) \Rightarrow f_{\mathrm{GeoKGC}}(t_1,?,t_3) = r_3 \tag{4}$$

式中：$GeoKG$表示地理知识图谱补全；h代表头节点；r代表关系；t代表尾节点。

图谱去噪任务专注于GeoKG中已有三元组有效性的判断，用于识别错误或矛盾的知识。错误的知识可能会导致GeoKG下游任务的失败或知识辅助决策的误导。因此，需要构建智能化的知识推理方法来完成大型GeoKG去噪任务。举个例子，假设GeoKG中存在(CityA, locatedIn, CountryX)以及(CityA, locatedIn, CountryY)2个三元组，这里显然存在矛盾的知识（假设CityA为唯一值），因为同一个城市不能位于2个国家，这时图谱去噪任务就可以通过推理和验证机制来检测到这个冲突，并消除其中错误的三元组。图谱去噪任务与补全任务具有很强的关联性，比如在补全的过程中需要同时验证推理出的三元组是否符合已有的知识约束，这一个步骤也

中国知网 https://www.cnki.net

是去噪的核心任务。同时，去噪系统可能通过推理出某个合理的三元组，来对现有的矛盾三元组进行修正或删除。在这一过程中，去噪机制实际上也在执行补全任务，即利用推理验证现有三元组的有效性。所以本质上这2个任务都是关于三元组有效性（可能性）的评估，现有通用知识图谱推理的综述论文也大都将二者合并起来进行总结和分析[1,3]。

图谱预测任务专注于利用GeoKG中已有的地理知识，预测未来知识存在概率和过程演化趋势。由于要预测的知识在GeoKG时间域外，该任务只能利用历史知识演化规律，也被称为外插式推理。图谱预测任务根据预测对象可以细分为：实体预测、关系预测以及时空属性预测。实体预测任务关注的是基于已有的历史知识，预测未来时刻可能出现的新的实体。这些实体可能是全新的地理对象，也可能是在不同时间或空间范围内出现的现有实体，其核心任务可以由式(5)定义。关系预测任务的重点在于通过已有的实体和历史关系信息，推测未来实体之间可能会出现的新关系，比如随着地理环境、社会、经济等方面的变化，不同地理实体之间的关系也会发生变化，其核心任务可以由式(6)定义。时空属性预测任务关注的是实体或关系的属性值随时间或空间的变化，其核心任务可以由式(7)定义。这类任务常用于预测地理实体的时空状态或属性，例如预测未来某个地区的气温、海拔变化，或者预测城市的人口密度、经济发展状况等。相比于实体和关系的预测，时空属性预测更关注于连续性数据或多维属性的演化。

$$f_{\text{EntityPrediction}}\left(GeoKG_{\text{history}}, t_{\text{future}}\right) \rightarrow \left\{h_1, h_2, \cdots, h_n\right\} \quad (5)$$

$$f_{\text{RelationPrediction}}\left(h, ?, t_{\text{future}}\right) = r \quad (6)$$

$$f_{\text{AttributePrediction}}\left(h, r, ?, t_{\text{future}}\right) = x \quad (7)$$

式中：$\left\{h_1, h_2, \cdots, h_n\right\}$表示预测的实体集合；$r$表示实体关系；$x$表示实体属性。

总的来说图谱补全和去噪共同作用于提升当前知识图谱的质量，而图谱预测则在此基础上进行时间和空间的推测。除此之外，GeoKG推理还可能包括关系发现、模式识别等其他推理任务。

3 地理知识图谱推理方法

基于Google Scholar搜索如表1所示的中英文关键词来获取相关文献，共计得到230篇相关论文。

表1 基于Google Scholar搜中英文关键词

Tab. 1 Chinese and English keywords based on Google Scholar search

中文关键词	英文关键词
地理知识图谱	Geographical Knowledge Graph; Geospatial Knowledge Graph; GeoKG
时空知识图谱	Spatiotemporal Knowledge Graph
知识图谱补全	Knowledge Graph Completion
知识图谱去噪	Knowledge Graph Denoising
知识图谱预测	Knowledge Graph Prediction

为了确保GeoKG推理的准确性，采用多组关键词进行检索，包括"地理知识图谱"、"时空知识图谱"、"知识图谱补全"、"知识图谱去噪"、"知识图谱预测"等。具体关键词如表1所示。经过去除重复文献、非相关领域文献（如不涉及地理信息系统或GeoKG推理的文献）以及没有全文可用的文献这一清洗过程后，得到与GeoKG推理高度相关的文献44篇。

根据2.2节的GeoKG推理任务分类，将GeoKG推理方法分类为面向补全的GeoKG推理方法，面向去噪的GeoKG推理方法以及面向预测的GeoKG推理方法，其中面向去噪的GeoKG推理方法在本文中归于面向补全的GeoKG推理方法综述中。面向补全的GeoKG推理方法主要分为基于转移表示的推理方法，基于规则的推理方法以及基于神经网络的推理方法。面向预测的GeoKG推理方法主要分类为基于深度学习的预测方法以及基于概率模型的预测方法。每类算法的文献数目如图2所示。

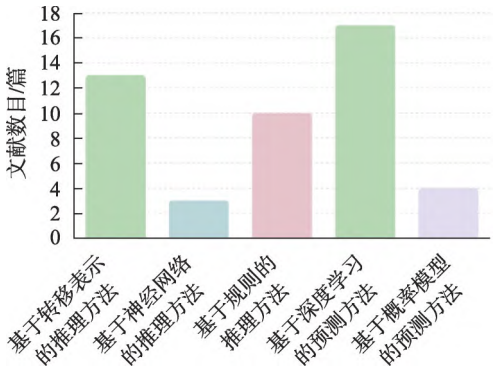

图2 地理知识图谱推理各类算法计量

Fig. 2 Measurement of various algorithms for geographic knowledge graph reasoning

3.1 面向补全的地理知识图谱推理

面向补全的地理知识图谱推理算法旨在填补GeoKG中的缺失知识，发现和补全图谱中未显现但

中国知网 https://www.cnki.net

存在的地理实体，关系以及属性。其关键任务是使模型理解可观察时间域内的空间信息，并将其整合至GeoKG语义中进行推理，旨在提高给定GeoKG中关于尾节点缺失事实，头节点缺失事实和关系缺失的推理能力。主要分为基于转移表示的推理方法、基于神经网络的推理方法以及基于规则的推理方法。基于转移表示的推理方法通过将地理实体和关系嵌入到空间向量中，捕捉地理实体的空间特征和关系以补全GeoKG实体、关系或者属性。基于神经网络的推理方法是指利用神经网络（例如GEO-GCN等）对地理知识图谱中的空间结构进行编码，使用图神经网络对节点特征进行更新和聚合，从而推理出缺失的知识。基于规则的推理方法通过显式符号表达空间推理规则，通过GeoKG中已有的空间知识，对缺失的知识进行推理。表2列举了面向补全任务的主流GeoKG推理方法。

表2 面向补全的主流地理知识图谱推理方法对比

Tab. 2 Comparison of mainstream geographic knowledge graph reasoning methods for completion

算法类别	具体模型/用途	优点	缺点
基于转移表示的推理方法	TransE-GDR, TransR-GDR, TransD-GDR[12]	引入地理空间距离限制，提高GeoKG的嵌入表示	TransE-GDR不善于处理复杂关系，TransR-GDR训练时间较长，TransD-GDR计算成本高，更换数据集需要精细调参
	GEUKE[13]	结合空间和结构特征，性能优于传统模型	需要大量的训练数据，缺乏灵活性与通用性
	MSEN-GRP[14]	构建多层相似性增强网络，显著提升补全性能	需要复杂的网络结构和算法，属性相似性网络补全效果不显著
	VerE-TransE, VerE-TransD, VerE-TransR[15]	利用注意力机制处理时间嵌入，效果显著	VerE-TransE不适合复杂关系，VerE-TransR训练时间长
	DT-WE[16]	集成时间和空间嵌入模块，提高预测概率	计算复杂度较高，训练时间较长
	HyperRotatE[17]	结合平移和旋转思想，有限训练数据下表现出色	高维表示需要较大的计算量，模型受数据噪声影响大
	RotateS2F[18]	通过旋转操作表示实体和关系，捕捉复杂关系特性	需要复杂的数学运算，有可能生成常识错误的负样本
	HyperQuaternionE[19]	捕捉不同关系特性，隐式学习概念邻域	计算过程复杂，需要解决不同空间的调和问题
	Dihedron Algebra[20]	使用高超复数代数操作降维推理补全	算法复杂，理解和实现难度较高，训练时间长
	DistMult[21]	利用向量表示将语义信息嵌入低维空间，基于文本数据推理	对结构信息的捕捉不够精确
	ComplEx[22]	利用向量表示将语义信息嵌入低维空间，基于文本数据推理	对结构信息的捕捉不够精确
基于神经网络的推理方法	ST-GCN[23]	结合时间信息和空间结构进行特征提取	对数据质量要求较高
	STSE, S-TSE[24]	利用递归神经网络获取时空感知关系嵌入，补全知识图谱	模型复杂度高，训练和推理速度较慢
基于规则的推理方法	领域语义规则[25]	利用领域知识规则进行森林火灾知识图谱补全	规则定义需要领域专家知识，推广性不足
	瓦斯事故时空图谱[26]	通过本体模型及推理规则库实现隐性知识推理	规则和本体模型复杂，构建成本高
	作物病虫害诊断[27]	基于预定义规则推理作物病虫害诊断	规则定义需要领域专家知识，灵活性不足
	水利信息知识图谱[28]	利用隐藏知识实现智能数据补全	需要大量领域知识和规则，推广性不足
	供应链可视性[29]	使用OWL定义和构建供应链可视性领域语义模型	OWL复杂度高，构建和维护成本高
	滑坡知识图谱[30]	结合深度学习与OWL进行预测补全	深度学习模型复杂，训练成本高
	时空知识图谱补全[31]	定义合并时间中心和位置中心的三元概念规则进行补全	规则定义复杂，适应性不足
	岛屿知识图谱[32]	使用实体词典和规则模式提取实体和关系，补全缺失知识	依赖预定义规则，灵活性不足

中国知网 https://www.cnki.net

3.1.1 基于转移表示的GeoKG推理方法

基于转移表示的GeoKG推理方法通过时空嵌入等技术，将地理实体和关系编码为低维空间的向量表示，从而捕捉复杂的空间特征和时空关系，并运用评分函数和图结构信息来完成知识推理任务，通过嵌入技术可以有效提升地理实体补全、空间关系预测和地理事件推理的效果，尤其是在地理知识稀疏的场景中表现尤为突出。现有方法大都采用如图3所示的流程进行知识推理。首先通过嵌入函数将空间信息以及时间信息映射到低维向量空间（例如：地理实体+时间域+空间域≈时空实体）；第二步通过得分函数筛选高分数三元组；最后通过查找满足f(头节点,关系,尾节点)的最小尾节点来实现知识补全。现有基于转移表示的推理方法根据采用的时空嵌入模型，可以分为两大类：① 基于平移距离的嵌入式表示，② 基于语义的嵌入式表示[16]。

（1）基于平移距离的时空嵌入。该方法是在通用知识图谱推理中基于平移距离的推理算法基础上引入地理空间距离限制进行空间甚至时空的推理。该类算法首先将GeoKG中的实体和关系表示为低维向量，集成地理空间信息，通过计算实体间的地理距离，定义地理权重以调整目标函数，接着使用优化算法（如随机梯度下降）最小化目标函数，学习实体和关系的向量表示，最后根据学习到的向量表示和地理空间距离限制，进行实体和关系的推理，从而实现更准确的GeoKG补全。

TransE-GDR、TransR-GDR 和 TransD-GDR 模型在通用知识图谱推理方法中引入了地理空间距离限制，以细化链接稀疏GeoKG中地理知识的嵌入表示，将地理空间信息和语义信息融合到低维向量空间中，但是它们在实现方式和性能上有所不同。TransE-GDR基于传统的TransE[34]模型，利用实体和关系向量的平移操作进行知识图谱补全，适用于简单关系但在复杂关系上表现一般。TransR-GDR通过在实体和关系空间中分别构建嵌入表示（基于TransR[35]），每个关系都有一个投影矩阵，将实体嵌入投影到关系空间，更好地处理多语义和复杂关系，但训练时间较长。TransD-GDR引入了动态映射矩阵（基于TransD[36]），为每个实体和关系定义2个向量，一个表示意义，另一个用于动态映射，提高了处理多语义和复杂关系的效率，同时减少了参数数量。在性能上，TransD-GDR优于TransR-GDR和TransE-GDR，且训练时间较短，是地理知识图谱补全任务中的首选模型[6]，但是其计算过程复杂，并且动态映射矩阵会导致模型在不同数据集上的表现不稳定，需要精细调参。这些模型通过结合空间距离显示，有效补全了GeoKG中的关系，常被应用于城市交通网络的时空推理、灾害预警中的空间关系补全等任务。

GEUKE模型[13]基于空间特征和结构特征的统一向量空间训练后对TransE模型进行能量函数改进，其在链接预测和三元分类任务上表现出更高的性能，优于TransE、TransH、TransD和TransE-GDR。该模型保留了地理实体的固有特征，包括位置、邻域和结构属性，并确保了点、线和多边形三种实体类型的空间数据表示的一致性；但是该模型性能依赖于高质量和丰富的地理数据，如果数据不完整或不准确，可能会影响补全效果；除此之外，统一向量空

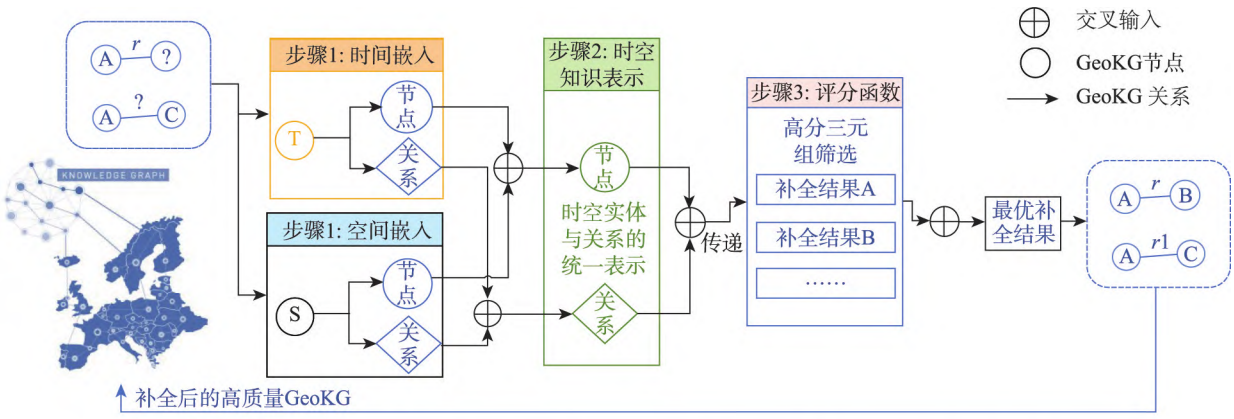

注：r为存在关系；？为缺失关系；$r1$为推理补全后关系；A,B,C为已存在实体；S为空间向量；T为时间向量。

图3 基于转移表示的GeoKG推理流程

Fig. 3 GeoKG reasoning process based on transfer representation

中国知网 https://www.cnki.net

间可能在处理一些特殊或边缘案例时缺乏灵活性，不能完全适应所有地理信息的多样性和复杂性。

MSEN-GRP 模型[14]通过构建多层相似性增强网络，显式地包含每个地理实体的词义、空间、结构和属性，解决了地理知识图谱中由于关系稀疏导致知识表示学习效果不佳的问题。该模型通过 DeepWalk 算法的混合路径采样方法学习长距离的关系依赖关系，显著提升了平均互易排序和 Hits@10 指标；其中，空间相似性网络对地理关系补全的增强效果最为显著，但是属性相似性网络对地理关系补全的增强效果并不显著。

VerE-TransE、VerE-TransD 和 VerE-TransR [15]模型将连续时间嵌入到向量空间中，利用注意力机制将地理实体转换为相应的版本，并在版本相似性正则化的约束下计算时空知识得分，在未知时间的情况下能够很好地进行地理实体的补全。其中，VerE-TransD 模型通过引入动态映射矩阵，能够更灵活地捕捉实体和关系间复杂语义且训练时间较短，是地理知识图谱补全任务的首选模型，VerE-TransR 模型虽然在处理复杂关系时性能较好，但训练时间较长，VerE-TransE 模型结构简单，参数少，适合处理简单关系，但在复杂关系和时空嵌入方面表现不及前两者。

DT-WE 模型[16]集成了时间和空间嵌入 2 个模块，用于学习时间域和空间域嵌入表示，并将其送入评分模块进行计算，最后将结果值相加以计算预测概率推理出地理实体关系，但是计算复杂度较高，训练时间较长。

此外，HyperRotatE [17]，RotateS2F[18]以及 HyperQuaternionE[19]等基于旋转的嵌入方法，在捕捉复杂的地理关系特性（如对称关系、反对称关系、复合关系等）方面表现优异。尤其是 RotateS2F 模型在火灾知识图谱的补全任务中，结合多源数据展现了较高的预测准确性。不过，这些模型在生成负样本时需要考虑逻辑约束，以避免生成常识错误的样本，这增加了模型的实现复杂性。

在现阶段的基于平移距离的 GeoKG 推理研究中，TransE-GDR、TransR-GDR 和 TransD-GDR 等模型被广泛应用于地理实体补全、空间关系预测、以及地理事件推理等任务中，尤其是在地理知识稀疏或关系复杂的领域表现优异。近年来，GEUKE 和 MSEN-GRP 等模型进一步提升了时空信息的嵌入效果，并在具体的如城市交通、气候预测、灾害预警等领域有了较好的应用[10-11]。虽然基于平移距离的模型在地理知识补全上具备显著优势，尤其在处理简单空间关系时表现良好。然而，这类模型对于复杂、多语义的关系推理存在一定局限性。未来的研究应更多地集中于动态地理场景中的多维度嵌入建模，并通过自适应优化算法提高训练效率。

（2）基于语义的时空嵌入。该类模型主要关注语义信息，并且基本没有算法上的改进，通常基于通用知识图谱推理中的 DistMult 以及 ComplEx 等模型，模型核心在于通过向量表示将知识图谱中的语义信息嵌入到低维空间中，在 GeoKG 中的应用多数基于文本数据建立图数据库并进行推理，如 Pasquale 等[21]建立 GTMiner，使用 DistMult 从文本挖掘地理空关系，王焕东等[22]建立时空城市知识图谱（STKG），并且使用 ComplEx 模型对图数据库进行推理。基于语义的时空嵌入模型在处理文本和结构化数据中的地理关系时表现良好，特别是在缺乏空间数据的场景中具有重要应用价值。然而，这类模型的主要限制在于其空间信息整合不足，未来的发展应更多集中于融合多模态数据，提高模型的语义表达能力及推理的准确性。

总的来说，基于转移表示的 GeoKG 推理方法在地理实体补全和空间关系推理中取得了一定的的进展，特别是在时空信息的嵌入方面表现尤为突出。然而，这些模型在处理复杂多语义关系和大规模数据集时的表现还有待优化。未来的研究方向应更多关注如何通过自适应优化算法提升模型的训练效率，并在多维度时空嵌入建模中进一步突破。

3.1.2 基于神经网络的推理

该类模型是指利用神经网对 GeoKG 中的空间结构进行编码，使用图神经网络对节点特征进行更新和聚合，从而推理出缺失的知识。对于包含时间信息的地理知识图谱，可以使用时空图卷积网络（ST-GCN[23]），将时间信息与空间结构结合起来进行特征提取。STSE 和 S-TSE[24]利用递归神经网络(RNN)获取时空感知关系嵌入，通过最终评分函数评估获取推理节点或者关系，有效地补全了地理知识图谱。

相对于基于平移的推理，基于神经网络的推理在处理复杂的时空关系和多语义关系时表现出色，能够自动捕捉节点间的复杂依赖性，尤其在时空动态特征的建模上具有优势。然而，相较于基于平移的模型（如 TransE 等），神经网络的计算复杂度更

中国知网 https://www.cnki.net

高，训练时间较长，对大规模数据的处理效率较低。此外，基于平移的模型在处理简单关系时更为高效，且实现相对简单，适合结构较为明确的场景，而神经网络则更适合处理复杂、非线性和时空依赖性强的任务，但对数据质量和计算资源的要求也更高。

因此基于神经网络的GeoKG推理方法常用于复杂地理场景的知识补全与预测任务，特别是在城市交通流量预测、灾害预警、环境监测、个体轨迹分析和公共安全监控等领域。它通过时空感知的建模，能够捕捉动态时空关系与多维依赖性，有助于提升地理知识图谱在实际应用中的精度和效果。

3.1.3 基于规则的推理方法

基于规则的推理方法通过预定义的规则和逻辑推理机制，对GeoKG进行补全。规则可分为两大类别，一是空间邻近规则，利用地理实体的空间邻近关系来进行推理，例如有2个实体A和B，规则定义为"如果A和B相邻，则A和B具有某种关系R"。二是空间层级规则，利用地理实体的层级关系进行推理。例如推理出某个城市属于某个国家。在GeoKG中这部分推理依赖于预先定义的规则以及逻辑，算法首先提取GeoKG中的地理实体及其关系，定义基于空间邻近关系和层级关系的推理规则，随后依次应用这些规则，检查并补全所有满足条件的实体对的关系和层级。通过迭代推理，持续应用规则，直到不再产生新的关系或层级，最终生成补全后的地理知识图谱(图4)。

Ge等[25]将森林火灾分析的领域专业知识定义为知识图谱的语义规则，提出一种基于规则的推理方法获取对应数据，对森林火灾知识图谱进行补全推理。刘鹏等[26]通过构建本体模型及推理规则库基于瓦斯事故时空图谱实现从根源危险源到基本事件的隐性知识推理。于合龙等[27]基于水稻时空知识图谱，基于预定义的规则推理等方式进行作物病虫害诊断对实体关系进行补全。冯钧等[28]提出基于推理规则的知识推理方法，利用隐藏在水利信息知识图谱中的知识实现智能数据补全更新。Silvia等[29]使用OWL来定义和构建供应链可视性领域的语义模型，从而支持供应链可视性地理空间知识补全。Chen等[30]结合深度学习与OWL对滑坡知识图谱进行预测补全。Yang等[31]通过定义合并时间中心和位置中心的三元概念规则，基于时空知识图谱补全总结性知识。Qi等[32]使用预定义的规则和模式，基于实体词典和规则模式从多源数据中提取实体和关系，补全岛屿知识图谱中缺失的知识。虽然基于规则的推理方法对于特定领域的GeoKG推理有一定的优势，但是基于预定义规则的GeoKG推理需要大量领域专家知识，推广性和灵活度都不高，并且具有一定复杂度，构建和维护成本高。唐曾杨等[33]将建筑群场景的格网模式表达为知识图谱的规则，在建筑群知识图谱上基于NoSQL语言进行推理，验证了地理知识图谱在空间推理上的作用和在领域问题研究中的良好适应性，为地理知识图谱在空间认知领域应用提供了思路。

综上所述，基于转移表示的推理方法和基于神经网络的推理方法在处理复杂关系和大规模数据

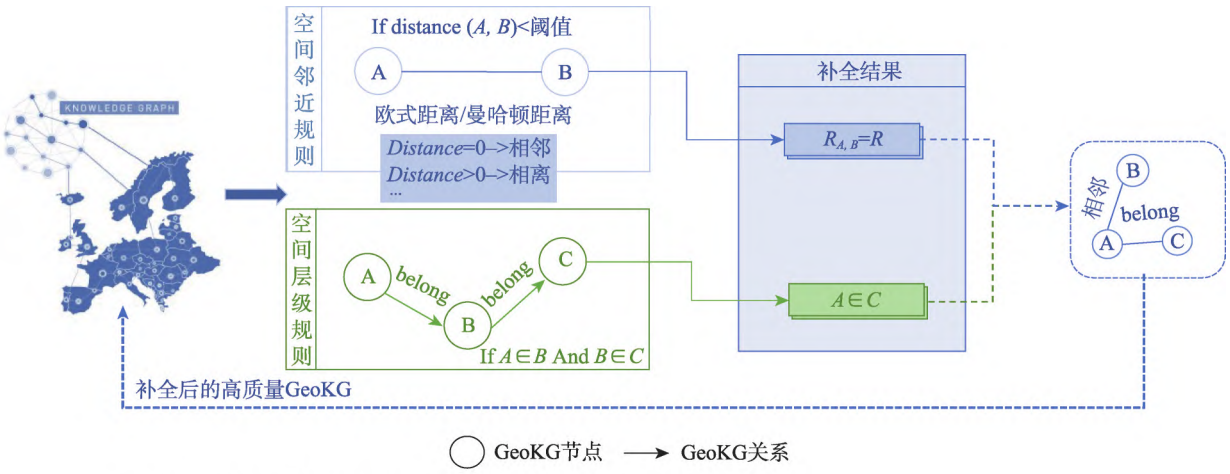

注：Distance指节点之间的距离；∈=belong。

图4 基于规则的推理方法

Fig. 4 Rule-based reasoning method

中国知网 https://www.cnki.net

方面表现优异，但计算成本较高，训练时间长。基于规则的推理方法简单直接，但灵活性和适应性不足，依赖于领域知识和规则定义。结合多种方法的模型（如结合神经网络和规则推理）可以在准确性和效率之间取得平衡，适用于不同应用场景。

3.2 面向预测的地理知识图谱推理

面向预测的地理知识图谱推理算法旨在利用知识图谱中的关系和数据来估计地理事件的可能性，并基于实体在图谱中的属性和连接来预测其空间位置，分析演化趋势，可进一步分类为基于深度学习的预测方法以及基于概率模型的预测方法。基于深度学习的预测方法主要依赖于卷积神经网络（CNN）、循环神经网络（RNN）和GAT等模型，通过自动提取和学习地理数据中的复杂特征来进行预测；而基于概率模型的预测方法则利用隐马尔可夫模型（HMM）、动态贝叶斯网络（DBN）等统计方法，通过建模地理实体和关系的概率分布来推断未来的演化趋势。表3对比了面向预测的主流GeoKG推理方法。

3.2.1 基于深度学习的预测方法

基于深度学习的预测方法通过构建和训练深度神经网络模型，利用知识图谱中的丰富关系和属性信息，对未来地理知识进行预测。这些方法主要包括图卷积网络（GCN），图注意力网络（GAT），基于递归神经网络（RNN）及其变体的预测。

（1）基于图卷积网络的预测：图卷积神经网络（GNN）通过层级结构对节点特征进行更新和聚合，逐步构建出节点的嵌入表示，最终利用最后一层的节点嵌入进行预测任务，如关系预测或属性预测。由于GNN能够有效捕捉地理实体间的复杂空间拓扑结构及其时空动态特性，基于GNN的预测模型在GeoKG推理中得到了广泛应用，尤其是在交通流量预测和出租车需求预测等子领域。通过融合交通知识图谱中的时空动态信息，GNN模型能够充

表3 面向预测的地理知识图谱推理方法对比

Tab. 3 Comparison of geographic knowledge graph reasoning methods for prediction

算法类别	具体模型	优点	缺点
基于深度学习的预测方法	KST-GCN[37]	结合知识和交通特征，提高预测性能，适用性较高	对数据质量较为依赖
	KG-ST-CNN[38]	结合知识图谱和深度时空卷积神经网络，提高城市拥堵预测准确性	计算复杂，模型的转移性有待进一步验证
	STKGN[39]	利用连续时间动态图神经网络，模拟和预测实体演变过程	计算开销大，影响模型实时性应用
	KGR-STGNN[40]	结合图卷积网络（GCN）和时间卷积网络（TCN），有效捕捉地铁交通流量的时空动态特征	计算复杂度高
	KatGCN[41]	能够预测多个共生事件的不同类型	对数据质量依赖较大
	HIT-GCN[42]	结合道路网络特性，显著提高短期和长期预测的准确性	模型复杂，训练和推理速度较慢
	ODT-GCN[43]	结合交通知识图谱，Trans-R模型和GCN，提高出租车需求预测的准确性	模型转移性较差
	Graph-Flashback[44]	根据用户的历史轨迹推荐最有可能访问的下一个POI	对用户历史数据依赖性强
	DynAttGraph2Seq[45]	能够处理动态时空数据，进行序列到序列的预测	对时空数据质量和数量要求高，计算效率低
	GeoNN[46]	专为地理空间表示学习而设计的模型，可有效捕捉地理空间实体之间的空间属性和交互	需要大量计算资源和高质量数据
	Geo-RippleNet [47]	专为地理社交网络设计的POI推荐模型	–
	MFGAT[48]	提取丰富的结构信息，扩展到时空版本，预测TKG中的缺失链接	模型复杂并且训练GAT可能需要大量资源
	FDSA-STG[49]	改进注意力机制，提取流量特征	
	RAG-GAT[50]	捕捉图结构中的丰富信息，灵活建模时间维度相关性	
	Bi-LSTM[51]	结合小麦病虫害知识图谱，预测准确率为93.21%	模型复杂度高，训练成本大
	Know-Evolve[52]	通过深度进化网络捕捉地理实体动态演化	调参数复杂
	ConvRL-KGM[53]	结合LSTM和ConvR对时空数据进行预测	存在过拟合风险
基于概率模型的预测推理	暴雨灾害链预测[54]	预测暴雨灾害链中次生灾害与衍生后果强度或等级的概率地学数据	计算复杂度高，训练成本大
	KG-MTKF[55]	处理和预测非线性动态系统中的地理知识	可解释性和用户接受度较差

中国知网 https://www.cnki.net

分利用图谱中复杂的地理关系和属性，有效捕捉空间拓扑结构与时间序列数据的相互作用，从而提升预测精度。在实际应用中，结合GeoKG的GNN模型已成功应用于城市交通流量预测、出租车需求预测等任务，在数据丰富且时空依赖性强的场景中展现了较好的效果。

KST-GCN [37]基于交通时空知识图谱，利用知识融合单元（KF-Cell）将知识和交通特征结合起来作为时空图卷积主干网络的输入，提高了主干网络在各个预测范围内的预测性能，是第一项构建和利用知识图谱进行交通预测的研究。模型通过多层GRU和GCN的交互，提高了模型在捕捉时空动态和综合特征方面的能力，从而提升了预测精度。其模型框架设计使得KST-GCN能够适用于其他基于图神经网络和递归神经网络的交通预测模型，但是也存在对数据质量依赖性强的问题。

KG-ST-CNN[38]在KST-GCN模型的基础上进一步结合了深度时空卷积神经网络（ST-CNN），对城市拥堵区域进行实体空间域上的状态预测，其预测结果不仅考虑了知识图谱和空间关系，还增加了时间维度的信息捕获，增强了模型的综合预测能力，但是相比于KST-GCN计算更为复杂，并且模型的转移性有待进一步验证。STKGN[39]通过构建空间–时间事件图来处理跨区域影响和连续演变过程的建模问题，模型首先将每个区域表示为节点，并通过双向边反映跨区域影响，接着使用事件驱动的记忆网络表示每个实体的状态，并通过新出现的事件不断更新状态嵌入，最后使用广播网络传播图中的局部变化，以获得高阶原因。

STKGN展示了跨区域影响的可解释性，并且通过捕捉事件的连续性，提高GeoKG的预测效果，但是构建和更新空间–时间事件图以及记忆网络的计算开销较大，可能影响模型的实时性应用。Kat-GCN[41]通过构建时间事件图对多事件进行预测，模型首先将社会事件建模为时间事件图，并从事件内容中提取背景信息和主题关键词，增强事件图的语义表达，接着设计了知识感知注意力的图聚合方法，捕捉多种并发事件的结构依赖性，最后利用LSTM对时间相邻事件进行时间编码，捕捉时间依赖性，进行多事件预测，但是模型性能依赖于数据的完整性和准确性，数据缺失或不准确可能影响预测效果。

KGR-STGNN[40]模型通过构建地铁交通知识图谱，将天气、事件、POI等多种外部因素纳入预测模型，结合GCN（图卷积网络）和TCN（时间卷积网络），有效捕捉地铁交通流量的时空动态特征，增强了模型对复杂交通模式的理解，然而知识图谱的构建和表示学习以及多层卷积网络的计算复杂性较高，增加了模型的训练和推理时间。HIT-GCN[42]针对交通预测领域中路网节点携带的属性信息异构性问题，构建交通知识图谱进行推理，模型构建同构邻接矩阵，结合了道路网络的拓扑结构和节点异构信息的相似性，从而优化了图卷积网络的传播路径，使模型更能反映节点的空间特征，显著提高短期和长期预测的准确性，但是同构邻接矩阵的计算过程复杂，增加了模型的计算负担。

ODT-GCN[43]通过整合外部因素的复杂关系和动态变化，解决了大城市出租车需求预测中的时空变化和多维外部因素的影响，模型首先使用TransR知识图谱模型将外部因素之间的复杂关系映射为实体三元组，然后动态融合单元整合交通需求与外部因素之间的语义信息，捕捉外部因素的动态变化并更新交通需求信息，最后将更新后的交通需求信息与区域邻接矩阵结合输入到时空预测模型中，进行出租车需求预测。在北京的神州专车订单数据集上的测试表明，ODT-GCN在预测精度、可解释性和鲁棒性方面均优于其他基线模型，但是仍然存在模型转移性较差的问题。

Graph-Flashback[44]在POI转换图上应用了简化的GCN(图卷积网络) 根据用户的历史轨迹，推荐最有可能访问的下一个POI，从而提升推荐效果，但是模型的性能在很大程度上依赖于历史用户行为数据，对于新用户或缺乏历史数据的用户，推荐效果可能较差。DynAttGraph2Seq[45]将动态注意力机制与图到序列学习相结合，以增强GeoKG预测，模型通过根据不断发展的图结构动态调整注意力权重来有效捕捉时空关系，确保在预测过程中优先考虑相关特征。该模型能够管理复杂、随时间变化的空间数据，从而提高预测准确性和鲁棒性，但是动态注意力计算较为复杂，以及模型需要大量训练数据才能准确捕捉各种时间模式，因此存在计算效率的问题。

上述基于图卷积网络的GeoKG推理预测大多是基于通用的GCN模型结合时空数据特性进行的模型研发或者是模型的直接使用，而GeoNN模型[46]是一种专为地理空间表示学习而设计的模型，可有效捕捉地理空间实体之间的空间属性和交互。它利用传导（GeoNN-T）和归纳（GeoNN-I）方法来学

中国知网 https://www.cnki.net

习保留实体的空间关系和相对位置的表示。该模型在各种下游任务（例如兴趣点推荐、交通分析和空间关系挖掘）中能够实现精准的GeoKG预测。类似地，Geo-RippleNet作为原始RippleNet模型的扩展，最初用于社交网络中的关系推荐，但通过引入地理位置信息和时空特性，Geo-RippleNet在GeoKG中同样展现了良好的预测效果[47]。该模型结合了用户的社交关系与地理位置，通过多层传播网络推理，为用户提供更加个性化的兴趣点推荐。这表明，通过将社交网络模型与地理信息结合，Geo-RippleNet能够进一步提升地理知识图谱推理的精度，特别是在地理兴趣点推荐等任务中。

综上，在现有基于GNN的GeoKG推理研究中，交通预测和出租车需求预测等时空数据密集的领域是主要应用场景。GNN凭借其强大的时空动态信息捕捉能力，能够有效整合交通知识图谱中的复杂关系，实现更精确的时空预测。具体算法包括KST-GCN、KG-ST-CNN和STKGN等模型，它们通过结合GNN和递归神经网络（RNN）的能力，显著提升了交通流量和出租车需求的预测精度。尤其是ODT-GCN等模型，通过将外部因素（如天气、事件等）和交通特征深度融合，表现出更高的鲁棒性和泛化能力。然而，这些模型的普遍挑战在于对数据质量和计算资源的高度依赖。比如，KST-GCN和HIT-GCN等模型需要高质量且丰富的时空数据，才能保证预测效果。而对于大规模的知识图谱数据集，计算开销的增加也使得模型的实时性应用受限。

（2）基于图注意力网络的预测：图注意力网络通过引入注意力机制，对邻居节点赋予不同的权重，以捕捉节点之间的重要关系，并且GAT能够自适应地学习节点间的关系强度，提高预测精度。由于其灵活性和可扩展性，GAT已经在GeoKG推理中得到广泛应用，特别是在交通时空数据预测和关系推理任务中表现出色。与基于图卷积网络的预测有所不同，图神经网络（GNN）通常对邻居节点进行等权处理，而图注意力网络（GAT）会对不同邻居节点分配不同的权重，因此可以根据不同道路、车辆、交通设施等节点的动态关系，重点关注对预测结果影响较大的节点。这使得GAT在处理复杂且动态的交通数据时，比GNN更具灵活性和精确性，但由此产生的计算开销巨大。GNN通常适用于关系简单、结构稳定的网络，例如城市中固定的交通网络，它能够有效捕捉空间拓扑结构，并通过简单的层级更新节点特征来进行预测。GAT更适合用于关系复杂、动态变化的网络，如自动驾驶中的实时交通预测、动态的交通流量变化等。以下是对现有GeoKG中GAT算法的简要描述。MFGAT[48]从每个实体的自我中心网络中提取丰富的结构信息，并与现有的静态KG完成方法相结合，将它们扩展到时空版本，以预测TKG中的缺失链接，同时考虑其固有的图结构和时间演化特性。FDSA-STG[49]通过使用GAT（图注意网络）改进注意力机制，结合交通知识图谱来提取近期周期性、每日周期性和每周周期性的流量特征。RAG-GAT[50]模型有效地利用了图谱中的情境信息，通过为邻接节点的贡献分配不同的重要性来捕获不同节点（例如，道路使用者及其行为）之间的依赖关系，并且通过注意力机制关注图的相关部分，与平等对待所有节点的传统方法相比，RAG-GAT模型提高了GeoKG预测的准确性。GAT的引入能够有效地处理大型GeoKG，使其适用于自动驾驶等动态环境中的实时应用，但是训练GAT可能需要大量资源，尤其是在大规模图谱上，需要大量的计算能力和内存。尽管GAT模型在大规模GeoKG和复杂时空数据中的预测任务表现出色，但也存在若干限制。首先，GAT的计算复杂度较高，尤其是在处理大规模知识图谱时，需要大量的计算能力和内存资源。此外，GAT在时空依赖性较强的数据环境中，尽管能够处理节点之间的重要关系，但对长距离依赖性和跨区域影响的处理仍然存在局限性。因此，在动态环境下，如自动驾驶和实时城市交通预测，GAT的训练和推理时间可能会成为瓶颈。未来研究应着眼于提高GAT模型的计算效率，特别是在处理大规模GeoKG时的训练时间和内存消耗问题。一种可能的解决方案是通过分布式计算和并行化机制来加速训练过程，同时引入稀疏注意力机制，以减少计算开销。此外，随着GeoKG在自动驾驶、智慧城市等实时环境中的广泛应用，强化学习与GAT的结合可能成为未来研究的一个重要方向。通过结合实时数据流的GAT推理模型，能够更好地处理动态环境中的时空依赖性，提升预测的实时性和准确性。另一个趋势是跨模态的知识融合，即结合GAT与其他类型的深度学习模型，如CNN和RNN，以更好地利用多模态地理大数据（如卫星图像、传感器数据、社交媒体数据）中的异构信息进行预测推理。这不仅可以提升GeoKG模型的预测精度，还能够增强模型对复杂地

中国知网 https://www.cnki.net

理关系的理解和解释能力。

(3)基于递归神经网络(RNN)及其变体的预测:RNN的循环结构使其能够利用历史数据建模复杂的时间依赖性,这是地理知识图谱(GeoKG)推理预测中的关键特性。RNN现主要应用于农业病虫害预测和出租车需求预测方面例如,张善文等[51]通过构建小麦病虫害知识图谱,利用Bi-LSTM模型开展小麦条锈病预测,其预测准确率达93.21%。Know-Evolve[52]通过深度循环神经网络(RNN)学习实体的非线性演化表示,使其能够捕捉复杂的时间和关系依赖性,并且使用多元点过程建模事件的发生,通过关系得分调节强度函数,使得模型可以捕捉到地理实体间的复杂交互,但是由于模型的复杂性,调节超参数以达到最佳性能可能需要大量实验和经验。ConvRL-KGM[53]通过使用SLSTM和自注意力机制保留历史信息,并且结合ConvR嵌入和动态策略空间修剪,提高了路径选择的准确性和效率,模型结构允许其有效处理大规模GeoKG,更适用于大规模数据集,但是SLSTM组件仍存在过拟合的风险,可能影响模型对新数据的泛化能力。综上,RNN及其变体在GeoKG时空推理中表现出色,尤其适用于处理带有强时间依赖性的时空数据,适用于气候变化、交通流量预测、农业病虫害预测等领域的应用。但是标准RNN在处理长时间序列时,可能会出现梯度消失或爆炸问题。未来可以着重解决RNN及其变体在GeoKG推理中的计算效率和泛化能力问题。

综上,基于深度学习的GeoKG预测方法广泛应用于交通流量预测、出租车需求预测、灾害预警、环境监测等时空数据密集的领域。图卷积网络(GCN)在捕捉复杂的空间拓扑结构和时空动态特性方面表现出色,适合处理交通等固定结构的网络;图注意力网络(GAT)则通过灵活的注意力机制处理动态变化的节点关系,更适用于实时交通预测和复杂关系推理;而递归神经网络(RNN)及其变体在捕捉时间依赖性方面表现优异,广泛应用于气候、农业等领域的时序预测。总体而言,这些模型通过结合时空依赖性和多维特征,提高了地理知识图谱的预测精度和实用性,但在计算效率和大规模数据处理方面仍面临挑战,未来应继续优化模型以适应实时和复杂的应用场景。

3.2.2 基于概率模型的预测方法

基于概率模型的GeoKG预测方法利用统计和概率方法,通过构建概率模型来估计地理实体和关系的未来演化趋势。这些方法主要依赖于对历史数据的概率分布建模,并通过推断和预测来进行知识图谱的补全和扩展。首先,收集和预处理包含地理实体和关系的历史数据,去除噪声并填补缺失值。接着,根据数据特点和任务需求选择合适的概率模型(如隐马尔可夫模型或动态贝叶斯网络),并提取关键特征进行模型训练。通过最大似然估计或贝叶斯估计等方法估计模型参数。然后,将数据集划分为训练集和验证集,使用准确率、召回率等评估指标验证模型性能,并根据验证结果调整模型参数。使用训练好的模型对新数据进行推断和预测,生成地理实体和关系的未来状态,并将预测结果用于知识图谱的补全和扩展。最后,通过实际数据反馈和模型改进,不断优化模型,提高预测的准确性和实用性。

王志华等[56]针对地理实体的跨尺度关联关系强弱不同的问题,认为引入概率机制进行概率推理,从而消除地学领域中的MAUP问题。此外,基于概率的推理方法还广泛用于地学领域中的应急事件发生概率预测。黄晶等[54]使用基于概率推理方法对暴雨灾害链预测模型进行构建,在已知暴雨灾害链中原生灾害父节点状态(证据)的情况下,计算次生灾害或灾情影响子节点不同状态下的发生概率。该模型能够预测出暴雨灾害链中次生灾害与衍生后果强度或等级的概率地学数据,提高了暴雨灾害链预测的准确性与可靠性。KG-MTKF模型[55]结合了卡尔曼滤波(Kalman Filter, KF)技术和多重状态估计的方法,用于处理和预测非线性动态系统中的地理知识,适用于复杂的地理实体状态估计和预测任务,但是结合多种高级技术(如KF和多重状态估计)的KG-MTKF模型结构复杂,对模型内部工作机制的理解和解释难度较大。这可能会影响模型在实际应用中的可解释性和用户接受度。

综上,基于概率模型的预测方法则利用隐马尔可夫模型、动态贝叶斯网络等统计方法,通过建模地理实体和关系的概率分布来推断未来的演化趋势,具有良好的解释性和鲁棒性,适用于处理带有不确定性和稀疏数据的任务。然而,这些方法的参数调优和实现复杂度较高,计算成本较大,在处理高度非线性和复杂系统时表现不佳。

中国知网 https://www.cnki.net

4 总结与展望

4.1 总结

本文系统梳理了地理知识图谱（GeoKG）推理技术的最新研究进展与应用。首先，本文介绍了GeoKG的基本概念与推理任务，主要包括三大任务：地理知识的补全、去噪以及预测任务，深入探讨了GeoKG推理与通用知识图谱推理的共通性与差异性。其次，本文将GeoKG推理方法分为两大类：面向知识补全的推理方法和面向预测的推理方法。在面向补全的推理方法中，本文将其进一步分为三类：基于嵌入的推理方法、基于神经网络的推理方法和基于规则的推理方法。基于嵌入的方法主要包括TransE-GDR、TransR-GDR、TransD-GDR等算法，通过时空嵌入技术编码地理实体和关系以捕捉复杂的空间特征；基于神经网络的推理方法则主要依靠图神经网络（GNN）、时空卷积网络（ST-GCN）等技术，对GeoKG的空间结构进行编码；基于规则的推理方法依赖于预定义的规则，应用领域如森林火灾分析和瓦斯事故时空图谱。

在面向预测的推理方法中，本文主要探讨了基于深度学习和基于概率模型的2类方法。基于深度学习的预测方法包括图卷积网络（GCN）、图注意力网络（GAT）和递归神经网络（RNN）及其变体，这些方法通过自动提取和学习GeoKG中的复杂时空特征，用于交通流量预测、灾害预警等任务；基于概率模型的预测方法则利用隐马尔可夫模型（HMM）、动态贝叶斯网络（DBN）等概率统计方法，建模地理实体和关系的概率分布，以推断未来的演化趋势。

综上所述，地理知识图谱（GeoKG）推理技术是地理信息科学（GIS）与知识图谱技术深度融合的重要研究方向，具有极高的学术价值和应用潜力。通过本文的系统梳理可以看出，GeoKG推理在地理知识补全、去噪和预测任务等方面已取得显著进展。基于嵌入、神经网络和规则的多种推理方法有效提高了地理知识的表达和推理能力，尤其在处理复杂时空关系、多模态数据及动态场景预测方面表现出色。同时，GeoKG推理技术也为地理事件的智能预测和科学决策提供了有力支持。

4.2 展望

尽管GeoKG推理技术在近年来已经取得了一系列重要进展，但在多个方面仍然面临挑战，亟待进一步研究与优化。现阶段GeoKG推理的研究多局限于模型和技术本身，未来应深入领域场景，聚焦其在实际地理问题中的应用价值。具体来说，未来GeoKG推理技术的发展可针对以下几个关键点进行突破。

（1）结合时空嵌入模型和GIS空间计算工具处理地理知识的复杂时空关系

地理知识具有多样化、复杂的时空关系，不仅可以进一步细分为距离关系、方位关系、空间拓扑关系、时间拓扑关系等，而且每种细分关系还存在不同的定义。例如，两点间的距离除了可以采用欧式距离，还可以采用曼哈顿距离、切比雪夫距离、路网距离、时间距离等定义。针对时空关系本身的推理问题，我们认为可以从地理知识表达入手，构建以GIS时空计算基础的有效解决方法。首先通过关联GIS时空底座，拓展通用知识图谱的时空表达能力，来显式地存储地理知识的时空属性。在此基础上，通过成熟的GIS空间计算功能，计算地理要素间的时空关系。

时空关系深刻影响着地理现象形成和演化过程。例如，地理学第一定律所述，地理现象之间的影响作用随着距离增大而减弱（即距离效应）。再如，不用方位的农作物接收到太阳辐射量具有显著差异，进而显著影响农作物种植类型、生长速度和产量。如何在GeoKG推理技术中有效地考虑距离关系、方位关系等时空关系具有挑战性。现有GeoKG推理技术（如TransE-GDR等）已尝试建模距离效应的影响作用。然而，现有GeoKG推理技术还未能充分考虑距离效应的动态性、空间异质性、非线性、非对称性等复杂特征。此外，还需要进一步扩展现有GeoKG推理技术，以充分考虑方位关系、空间拓扑关系、时间拓扑关系等时空关系对于地理现象形成和演化过程的影响作用。

（2）构建多层次GeoKG模型应对地理知识的多尺度特征

现有GeoKG推理技术大都关注单一尺度的推理任务，较少考虑多尺度情形下的地理知识推理问题。然而，地理现象具有显著的多尺度特征，在不同尺度上表现出不同表现特征和演化规律（也称为尺度效应）。例如，气候系统在全球尺度上表现为大气、陆地、海洋、冰雪圈和生物圈之间的相互作用；在区域尺度上表现为不同区域的气候类型、降水量、温度等要素上的显著差异；在局地尺度上表

中国知网 https://www.cnki.net

现更为具体和微观，如城市相较于农村的热岛效应。在不同尺度上气候变换的影响因素和演化机理还存在显著地差异。因此，如何在GeoKG推理中准确地描述和选择适宜尺度、构建顾及尺度依赖的推理技术，是一个具有挑战性的任务。

此外，不同尺度上的地理现象存在相互作用，特别是大尺度上的地理现象往往对小尺度上的现象产生影响。例如，研究城市气候变换时除了需要考虑局地尺度上的要素（如建筑物、绿地分布、风道情况、热岛效应），还需要考虑区域乃至全球尺度的气候背景（如大气环流等）。因此，需要进一步研究跨尺度的GeoKG推理技术，建模不同尺度上地理要素的相互作用机制。未来可以考虑通过先建立构建具有多尺度特征的多层GeoKG，在不同尺度上进行联合推理和协同分析，提升跨尺度地理知识的推理能力，提高推理的准确性和智能性。

（3）引入基于概率图模型和模糊逻辑的GeoKG推理方法解决地理知识的不确定性问题

现有GeoKG推理技术大都基于确定性的实体和关系开展推理任务，较少考虑地理现象的不确定性问题。然而，由于数据获取或处理的误差、地理现象本身的复杂性等因素，地理现象可能存在不同程度的不确定性，包括地理要素边界模糊性、地理位置的不确定性、空间关系的不确定性等。例如，在城乡结合部，城区和乡村的边界往往是一个模糊的过渡区域，该区域可能同时具有城区和乡村的特点，导致划分城市边界时存在不确定性。再如，由于遥感影像空间分辨率限制，多类型地物可能落在同一个像素内，形成混合像元。这些地理现象的不确定性将导致GeoKG中部分实体、关系、属性存在相应的不确定性，给GeoKG推理技术带来了挑战。未来可以借鉴概率图模型和模糊逻辑技术，构建更加灵活的推理方法，处理地理实体和关系的不确定性问题。这将进一步提升GeoKG推理技术在现实地理场景中的表现。

（4）构建多模态GeoKG模型适应地理知识的多模态特性

现有GeoKG推理技术主要侧重于从文本或矢量数据中抽取的单模态地理知识，还未能有效支撑多模态地理大数据（如社交媒体数据、街景照片、手机数据、公交卡数据等）的推理任务。多模态地理知识涉及不同格式、结构和特征，无法直接采用传统的单模态技术实现推理任务，对GeoKG推理技术提出了新的挑战。如何整合多模态地理知识，建模跨模态地理实体的关联关系，形成一体化的多模态GeoKG，建立多模态实体和关系特征的统一表示空间，实现地理知识的跨模态推理，还需要深入研究。

（5）构建可解释的混合推理模型增强地理知识推理的可解释性

GeoKG的可解释性是指GeoKG推理结果能够以人类认识、理解的方式给人类提供解释的能力。现有主流GeoKG推理技术大都基于连接主义的深度学习技术和表示学习技术，具有强大的非线性学习能力，取得了良好的地理知识推理效果；但是深度学习技术的黑盒特性使得推理结果具有较弱的可解释性。另一方面，传统基于符号主义的推理技术（本体推理、规则推理等），通过学习逻辑规则表示进行地理知识推理，具有白盒特性和很强的可解释性；但是规则学习的能力较弱、缺乏复杂地理知识推理能力。如何结合连接主义和符号主义模式的优点，构建新的混合推理模式，是重要的GeoKG推理研究方向。

（6）GeoKG与大模型的结合

随着大规模预训练模型（如GPT-4等语言模型）的快速发展，GeoKG与大模型的结合成为未来GeoAI发展的关键方向。大模型具备强大的知识表示学习能力，能够处理大规模的自然语言文本信息。未来，GeoKG可以充分利用大模型在知识获取、推理和生成方面的优势，将多源、多模态地理知识与大规模语言模型相结合，提升GeoKG推理的智能性和泛化能力。此外，结合大模型的自适应学习能力，GeoKG推理有望进一步优化推理过程，提高推理的准确性与效率。

（7）GeoKG数据集推理的局限与未来发展方向

当前GeoKG推理技术在多个方面面临局限，特别是在数据集的多样性和标准化方面。现有GeoKG数据集大多集中于城市或交通等领域，涵盖面相对狭窄，未来应开发更具多样性和广泛适用性的数据集，以支持更加广泛的地理推理任务。此外，在测试和评估标准方面，GeoKG推理领域尚缺乏统一的基准数据集和标准化评估指标，这也限制了不同模型之间的对比和优化。未来研究应从数据集构建、评估指标标准化以及领域应用等方面进行拓展，以推动GeoKG推理技术更好地适应实际地理应用。

中国知网 https://www.cnki.net

利益冲突：Conflicts of Interest

所有作者声明不存在利益冲突。

All authors disclose no relevant conflicts of interest.

作者贡献：Author Contributions

段雨希参与文献收集总结与论文写作；陈碧宇参与论文的写作和修改；李岩、林黎参与论文收集与计量分析；张雪英参与论文的修改。所有作者均阅读并同意最终稿件的提交。

DUAN Yuxi participated in literature collection and summary and thesis writing; CHEN Biyu participated in thesiswriting and revision; LI Yan and LIN Li participated in thesis collection and quantitative analysis; and ZHANG Xueyingparticipated in thesis revision. All authors read and approved the final manuscript for submission.

参考文献(References):

[1] 夏毅,兰明敬,陈晓慧,等.可解释的知识图谱推理方法综述[J]. 网络与信息安全学报,2022,8(5):1-25. [Xia Y, Lan M J, Chen X H, et al. Survey on explainable knowledge graph reasoning methods (in Chinese)[J]. Chinese Journal of Network and Information Security, 2022, 8(5): 1-25.] DOI:10.11959/j.issn.2096-109x.2022063

[2] 张雪英,张春菊,吴明光,等.顾及时空特征的地理知识图谱构建方法[J]. 中国科学(信息科学),2020,50(7):1019-1032. [Zhang X Y, Zhang C J, Wu M G, et al. Spatio-temporal features based geographical knowledge graph construction (in Chinese) [J]. Science in China Information Sciences, 2020, 50(7): 1019-1032.] DOI:10.1360/SSI-2019-0269

[3] 侯中妮,靳小龙,陈剑赟,等.知识图谱可解释推理研究综述[J]. 软件学报,2022,33(12):4644-4667. [Hou Z N, Jin X L, Chen J Y, et al. Survey of Interpretable Reasoning on Knowledge Graphs (in Chinese) [J]. Journal of Software, 2022, 33(12): 4644-4667.] DOI: 10.13328/j. cnki. jos.006522

[4] 陆锋,诸云强,张雪英.时空知识图谱研究进展与展望[J]. 地球信息科学学报,2023,25(6):1091-1105. [Lu F, Zhu Y Q, Zhang X Y. Spatiotemporal knowledge graph: Advances and perspectives (in Chinese)[J]. Journal of Geo-information Science, 2023,25(6):1091-1105.] DOI: 10.12082/dqxxkx.2023.230154

[5] Wang S, Zhang X, Ye P, et al. Geographic knowledge graph (GeoKG): A formalized geographic knowledge representation[J]. ISPRS International Journal of Geo-Information, 2019,8(4):184. DOI:10.3390/ijgi8040184

[6] 陆锋,余丽,仇培元.论地理知识图谱[J]. 地球信息科学学报,2017,19(6):723-734. [Lu F, Yu L, Qiu P Y. On geographic knowledge graph (in Chinese)[J]. Journal of Geo-Information Science, 2017,19(6):723-734.] DOI:10.3969/j.issn.1560-8999.2017.06.001

[7] Chen X, Jia S, Xiang Y. A review: Knowledge reasoning over knowledge graph[J]. Expert systems with applications, 2020, 141: 112948. DOI: https://doi. org/10.1016/j. eswa.2019.112948

[8] Du J, Wang S, Ye X, et al. GIS-KG: Building a large-scale hierarchical knowledge graph for geographic information science[J]. International Journal of Geographical Information Science, 2022, 36(5): 873-897. DOI:10.1080/13658816.2021.2005795

[9] Potnis A, Durbha S S, Shinde R, et al. Geospatial knowledge graph construction workflow for semantics-enabled remote sensing scene understanding[M]//Durbha S S, Sanyal J, Yang L, et al. Advances in Scalable and Intelligent Geospatial Analytics. Boca Raton, FL, USA: CRC Press, 2023:81-98. DOI:10.1201/9781003270928-6

[10] Vinasco-Alvarez D. Leveraging standards in model-centric geospatial knowledge graph creation[C]// Groth P, Rula A, Schneider J, et al. The Semantic Web: ESWC 2022 Satellite Events: Vol. 13384. Crete, Greece: Springer International Publishing, 2022: 224-233. DOI:10.1007/978-3-031-11609-4_37

[11] Liu J, Qian Q. Reinforcement learning-based knowledge graph reasoning for aluminum alloy applications [J]. Computational Materials Science, 2023, 221: 112075. DOI:10.1016/j.commatsci.2023.112075

[12] Qiu P, Gao J, Yu L, et al. Knowledge embedding with geospatial distance restriction for geographic knowledge graph completion[J]. ISPRS International Journal of Geo-Information, 2019,8(6):254. DOI:10.3390/ijgi8060254

[13] Yang Y, Kong D, Cao M, et al. GEUKE : A geographic entities uniformly explicit knowledge embedding model[J]. Transactions in GIS, 2024, 28(5): 1313-1325. DOI:10.1111/tgis.13191

[14] Huang Z, Qiu P, Yu L, et al. MSEN-GRP: A geographic relations prediction model based on multi-layer similarity enhanced networks for geographic relations completion [J]. ISPRS International Journal of Geo-Information, 2022,11(9):493. DOI:10.3390/ijgi11090493

[15] Zhao X, Zhang J, Cao Y, et al. Spatio-temporal knowledge embedding method considering the lifecycle of geographical entities[J]. International Journal of Applied Earth Observation and Geoinformation, 2024,131: 103967. DOI:10.1016/j.jag.2024.103967

[16] Xu X, Jia W, Yan L, et al. Spatiotemporal knowledge graph completion via diachronic and transregional word embedding[J]. Information Sciences, 2024, 667: 120477. DOI:

中国知网 https://www.cnki.net

10.1016/j.ins.2024.120477

[17] Cai L, Janowicz K, Zhu R. Automatically discovering conceptual neighborhoods using machine learning methods[J]. Leibniz International Proceedings in Informatics, 2022, 240(3):1-14. DOI:10.4230/LIPICS.COSIT.2022.3

[18] Chen J, Yang Y, Peng L, et al. Knowledge graph representation learning-based forest fire prediction[J]. Remote Sensing, 2022,14(17):4391. DOI:10.3390/rs14174391

[19] Cai L, Janowicz K, Zhu R, et al. HyperQuaternionE: A hyperbolic embedding model for qualitative spatial and temporal reasoning[J]. Geoinformatica, 2023, 27(2): 159-197. DOI:10.1007/s10707-022-00469-y

[20] Nayyeri M, Vahdati S, Khan M T, et al. Dihedron algebraic embeddings for spatio-temporal knowledge graph completion[C]//Groth P, Vidal M E, Suchanek F, et al. The Semantic Web: Vol. 13261. Crete, Greece: Springer International Publishing, 2022: 253-269. DOI: 10.1007/978-3-031-06981-9_15

[21] Balsebre P, Yao D, Cong G, et al. Mining geospatial relationships from text[J]. Proceedings of the ACM on Management of Data, 2023,1(1):1-26. DOI:10.1145/3588947

[22] Wang H, Yu Q, Liu Y, et al. Spatio-temporal urban knowledge graph enabled mobility prediction[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2021,5(4):1-24. DOI:10.1145/3494993

[23] Yang R, Salim F D, Xue H. SSTKG: Simple spatio-temporal knowledge graph for intepretable and versatile dynamic information embedding[C]//Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024: 551-559. DOI:10.1145/3589334.3645441

[24] Jia W, Wang X, Shan J, et al. Sequence encoder-based spatiotemporal knowledge graph completion[J]. Journal of Web Engineering, 2022, 21(6): 1913-1936. DOI: 10.13052/jwe1540-9589.2166

[25] Ge X, Yang Y, Peng L, et al. Spatio-temporal knowledge graph based forest fire prediction with multi source heterogeneous data[J]. Remote Sensing, 2022, 14(14): 3496. DOI:10.3390/rs14143496

[26] 刘鹏,景江波,魏卉子,等.基于时空约束的瓦斯事故知识库构建及预警推理[J].煤炭科学技术,2020,48(7):262-273. [Liu P, Jing J B, Wei H Z, et al. Construction of knowledge base and early warning inference of gas accident based on time-space constraints (in Chinese) [J]. Coal Science and Technology, 2020, 48(7): 262-273.] DOI:10.13199/j.cnki.cst.2020.07.028

[27] 于合龙,沈金梦,毕春光,等.基于知识图谱的水稻病虫害智能诊断系统[J]. 华南农业大学学报,2021,42(5):105-116. [Yu H L, Shen J M, Bi C G, et al. Intelligent diagnostic system for rice diseases and pests based on knowledge graph (in Chinese)[J]. Journal of South China Agricultural University, 2021,42(5):105-116.] DOI:10.7671/j.issn.1001-411X.202101010

[28] 冯钧,徐新,陆佳民.水利信息知识图谱的构建与应用[J].计算机与现代化,2019(9):35-40. [Feng J, Xu X, Lu J M. Construction and application of water conservancy information knowledge graph (in Chinese) [J]. Computer and Modernization, 2019(9):35-40.] DOI:10.3969/j.issn.1006-2475.2019.09.007

[29] Dopler S, Scholz J. A prototypical geospatial knowledge graph and spatio-temporal question answering for supply chain visibility[J]. University of California preprint, 2021. DOI:10.25436/E2JS3V

[30] Chen L, Ge X, Yang L, et al. An improved multi-source data-driven landslide prediction method based on spatio-temporal knowledge graph[J]. Remote Sensing, 2023, 15 (8):2126. DOI:10.3390/rs15082126

[31] Yang E, Hao F, Gao J, et al. Entity spatio-temporal evolution summarization in knowledge graphs[C]//2020 IEEE International Conference on Knowledge Graph (ICKG). Nanjing, China: IEEE, 2020: 181-187. DOI: 10.1109/ICBK50248.2020.00035

[32] He Q, Yu C, Song W, et al. ISLKG: The construction of island knowledge graph and knowledge reasoning[J]. Sustainability, 2023,15(17):13189. DOI:10.3390/su151713189

[33] 唐曾杨,艾廷华,徐海江.地理知识图谱下的建筑群空间分布模式推理[J].地球信息科学学报,2023,25(6):1202-1214. [Tang Z Y, Ai T H, Xu H J. Reasoning of spatial distribution pattern of building cluster based on geographic knowledge graph (in Chinese)[J]. Journal of Geo-Information Science, 2023, 25(6): 1202-1214.] DOI:10.12082/dqxxkx.2023.220761

[34] Bordes A, Usunier N, García-Durán A, et al. Translating embeddings for modeling multi-relational data[C]// Burges C J C, Bottou L, Ghahramani Z, et al. Advances in Neural Information Processing Systems: Vol. 26. Lake Tahoe, NV, USA: NeurIPS, 2013:2787-2795.

[35] Lin Y, Liu Z, Sun M, et al. Learning entity and relation embeddings for knowledge graph completion[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2015,29(1). DOI:10.1609/aaai.v29i1.9491

[36] Ji G, He S, Xu L, et al. Knowledge graph embedding via dynamic mapping matrix[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Beijing, China: Association for Computational Linguistics, 2015:687-696. DOI:10.3115/v1/P15-1067

[37] Zhu J, Han X, Deng H, et al. KST-GCN: A knowledge-

中国知网 https://www.cnki.net

driven spatial-temporal graph convolutional network for traffic forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(9): 15055-15065. DOI: 10.1109/TITS.2021.3136287

[38] Zhou G, Chen F. Urban congestion areas prediction by combining knowledge graph and deep spatio-temporal convolutional neural network[C]//2019 4th International Conference on Electromechanical Control Technology and Transportation (ICECTT). Guilin, China: IEEE, 2019: 105-108. DOI:10.1109/ICECTT.2019.00031

[39] Huai Z, Zhang D, Yang G, et al. Spatial-temporal knowledge graph network for event prediction[J]. Neurocomputing, 2023,553:126557. DOI:10.1016/j.neucom.2023.126557

[40] Wang S, Lv Y, Peng Y, et al. Metro traffic flow prediction via knowledge graph and spatiotemporal graph neural network[J]. Journal of Advanced Transportation, 2022, 2022: 1-13. DOI:10.1155/2022/2348375

[41] Song X. KatGCN: Knowledge-aware attention based temporal graph convolutional network for multi-event prediction[C]//The 33rd International Conference on Software Engineering and Knowledge Engineering. Virtual Event, 2021:417-422. DOI:10.18293/SEKE2021-089

[42] Xiong H, Shen G, Lan X, et al. HIT-GCN: Spatial-temporal graph convolutional network embedded with heterogeneous information of road network for traffic forecasting[J]. Electronics, 2023, 12(6): 1306. DOI:10.3390/electronics12061306

[43] Tong N, Yu X, Li X, et al. Knowledge-infused spatio-temporal graph convolution network for megacity origin-destination taxi demand forecasting[J]. Social Science Research Network preprint 4850585, 2024. DOI:10.2139/ssrn.4850585

[44] Chen W, Wan H, Guo S, et al. Building and exploiting spatial-temporal knowledge graph for next POI recommendation[J]. Knowledge-Based Systems, 2022, 258: 109951. DOI:10.1016/j.knosys.2022.109951

[45] Chowdhury T. Cross domain reasoning based on graph deep learning[D]. Fairfax, VA, USA: George Mason University, 2023.

[46] Lee W J, Lauw H W. Latent representation learning for geospatial entities[J]. ACM Transactions on Spatial Algorithms and Systems, 2024:3663474. DOI:10.1145/3663474

[47] 高嘉良,仇培元,余丽,等.基于旅游知识图谱的可解释景点推荐[J].中国科学(信息科学),2020,50(7):1055-1068. [Gao J L, Qiu P Y, Yu L, et al. An interpretable attraction recommendation method based on knowledge graph (in Chinese) [J]. Science in China (Information Sciences), 2020,50(7):1055-1068.] DOI:10.1360/SSI-2019-0268

[48] Gao H, Kim J, Sakurai Y. Database systems for advanced applications: Vol. 9645[M]. Cham, Switzerland: Springer International Publishing, 2016. DOI: 10.1007/978-3-319-32055-7

[49] Duan Y, Chen N, Shen S, et al. FDSA-STG: Fully dynamic self-attention spatio-temporal graph networks for intelligent traffic flow prediction[J]. IEEE Transactions on Vehicular Technology, 2022, 71(9): 9250-9260. DOI: 10.1109/TVT.2022.3178094

[50] Hussien M M, Melo A N, Ballardini A L, et al. RAG-based explainable prediction of road users behaviors for automated driving using knowledge graphs and large language models[J]. arXiv preprint arXiv: 2405.00449, 2024. DOI:10.48550/arXiv.2405.00449

[51] 张善文,王振,王祖良.结合知识图谱与双向长短时记忆网络的小麦条锈病预测[J].农业工程学报,2020,36(12): 172-178. [Zhang S W, Wang Z, Wang Z L. Prediction of wheat stripe rust disease by combining knowledge graph and bidirectional long short term memory network (in Chinese)[J]. Transactions of the Chinese Society of Agricultural Engineering, 2020, 36(12): 172-178.] DOI:10.11975/j.issn.1002-6819.2020.12.021

[52] Trivedi R, Dai H, Wang Y, et al. Know-evolve: Deep temporal reasoning for dynamic knowledge graphs[C]//Proceedings of the 34th International Conference on Machine Learning. Sydney, NSW, Australia: JMLR. org, 2017:3462-3471.

[53] Guo J, Zhang X, Liang K, et al. Memory-enhanced knowledge reasoning with reinforcement learning[J]. Applied Sciences, 2024,14(7):3133. DOI:10.3390/app14073133

[54] Huang J, Wu X, Wang H. Mining and forecasting of rainstorm disaster chain based on knowledge map[C]//15th International Conference on Hydroinformatics. Beijing, China: The International Association for Hydro-Environment Engineering and Research (IAHR), 2024: 544-545. DOI:10.3850/iahr-hic2483430201-490

[55] 贺汪延,张巍,李厚芝,等.知识图谱优化卡尔曼滤波预测库岸滑坡位移[J].高校地质学报, 2023,29(3):372-381. [He W Y, Zhang W, Li H Z, et al. Deformation prediction of reservoir landslides using knowledge graph optimized Kalman filter (in Chinese)[J]. Geological Journal of China Universities, 2023, 29(3): 372-381.] DOI: 10.16108/j.issn1006-7493.2022068

[56] 王志华,杨晓梅,周成虎.面向遥感大数据的地学知识图谱构想[J].地球信息科学学报, 2021, 23(1): 16-28. [Wang Z H, Yang X M, Zhou C H. Geographic knowledge graph for remote sensing big data (in Chinese) [J]. Journal of Geo-information Science, 2021, 23(1): 16-28.] DOI:10.12082/dqxxkx.2021.200632

■ 本文图文责任编辑：蒋树芳 黄光玉

中国知网 https://www.cnki.net