计算机科学与探索
Journal of Frontiers of Computer Science and Technology
1673-9418/2024/18(10)-2594-22
doi: 10.3778/j.issn.1673-9418.2407038

基于大语言模型的命名实体识别研究进展

梁　佳,张丽萍+,闫　盛,赵宇博,张雅雯
内蒙古师范大学 计算机科学技术学院,呼和浩特 010022
+通信作者 E-mail: cieczlp@imnu.edu.cn

摘　要:命名实体识别旨在从非结构化的文本中识别出命名实体及类型,是问答系统、机器翻译、知识图谱构建等自然语言处理技术中一项重要的基础任务。随着人工智能技术的发展,基于大语言模型的命名实体识别技术成为一大研究热点。对基于大语言模型的命名实体识别最新研究进展进行综述,概述大语言模型和命名实体识别的发展历程,简要介绍命名实体识别任务常用的数据集和评估方法,从基于规则和字典、基于统计机器学习和基于深度学习的命名实体识别方法这三方面对目前传统命名实体识别研究工作进行梳理。按照模型架构详细阐述不同大语言模型如何应用于不同领域的命名实体识别任务,并对存在的问题和改进的方向进行分析。总结当前基于大语言模型的命名实体识别任务面临的挑战,并展望未来的研究方向。

关键词:大语言模型;命名实体识别;神经网络;深度学习
文献标志码:A　　**中图分类号:**TP183

Research Progress of Named Entity Recognition Based on Large Language Model

LIANG Jia, ZHANG Liping+, YAN Sheng, ZHAO Yubo, ZHANG Yawen
College of Computer Science and Technology, Inner Mongolia Normal University, Hohhot 010022, China

Abstract: Named entity recognition aims to identify named entities and their types from unstructured text, which is an important basic task in natural language processing technologies such as question answering system, machine translation and knowledge graph. With the development of artificial intelligence, named entity recognition based on large language model has become a hot research topic. This paper reviews the latest research progress of named entity recognition based on large language model. Firstly, the development process of large language model and named entity recognition is summarized, and the commonly used datasets and evaluation methods for named entity recognition tasks are briefly introduced. This paper sorts out the traditional research work on named entity recognition from three aspects: rule-based and dictionary-based, statistical machine learning-based and deep learning-based. Secondly, how to apply different big language models to different fields of named entity recognition tasks is described in detail according to the model architecture, and the existing problems and improvement directions are analyzed. Finally, the challenges faced by named entity recognition tasks based on big language models are summarized, and future research directions are prospected.

Key words: large language model; named entity recognition; neural network; deep learning

基金项目:国家自然科学基金(61462071);内蒙古自然科学基金(2023LHMS06009,2024MS06020);内蒙古自治区教育科学研究“十四五”规划2023年度课题(2023NGHZXZH119,NGJGH2023234)。
This work was supported by the National Natural Science Foundation of China (61462071), the Natural Science Foundation of Inner Mongolia (2023LHMS06009, 2024MS06020), and the Subject of the “14th Five-Year Plan” of Educational Science Research in Inner Mongolia Autonomous Region in 2023 (2023NGHZXZH119, NGJGH2023234).
收稿日期:2024-07-01　　**修回日期:**2024-08-21

中国知网 https://www.cnki.net

2022年11月，OpenAI发布一款名为ChatGPT（chat generative pre-trained transformer）的聊天对话软件，其不仅能根据用户的询问进行即时的、个性化的回答，还能结合对话的上下文语义进行分析，从而提供更加精准、符合用户期待的答案。ChatGPT的横空出世，使得人们对大语言模型（large language model，LLM）有全新的认识，大型语言模型是指包含数千亿参数的语言模型，这些参数通常基于大量文本数据进行训练。大语言模型以其强大的表征学习能力，通过在海量数据上进行监督学习，极大地提高了自然语言处理任务的性能和效率，具有广泛的应用前景，为自然语言处理任务带来革命性的变革。

命名实体识别（named entity recognition，NER）作为自然语言处理中的一个重要任务，旨在从文本中识别出具有特定意义的实体，并将其分类为预先定义的命名实体类别，例如人名、地名、组织机构等。通过实现命名实体识别任务，能够从非结构化文本中提取有价值的信息，这些信息可应用于信息提取[1]、问答系统[2]、机器翻译[3]、知识图谱构建[4]、生物医学[5]、舆情分析[6]等许多自然语言处理下游任务中。

大语言模型因其庞大的规模和先进的深度学习技术，能够捕捉到语言的细微差别和复杂模式，对命名实体识别任务产生显著的影响。陈光等人[7]围绕大语言模型介绍了人工智能的技术内涵、行业应用与挑战，阐述了大语言模型在训练架构、训练策略等技术层面的内涵以及在不同领域的应用前景。孙凯丽等人[8]综述了各类语言模型如何应用于自然语言处理任务，重点讨论了包括大语言模型在内的大语言模型对信息提取、情感分析、问答系统等五个自然语言处理任务的贡献及面临的挑战。蔡睿等人[9]介绍了大模型的Transformer架构和人类反馈强化学习技术等核心技术，研究了大模型的发展，深入研究了其架构和训练方法以及其在不同领域的应用。但是现有文章大多围绕大语言模型，广泛地介绍大语言模型如何应用于自然语言处理任务，缺乏深入介绍对于其子任务命名实体识别的重要性以及研究现状。因此，本文主要对近年来基于大语言模型的命名实体识别的相关研究工作进行全面梳理与综述。

本文在对大语言模型的发展历程概述的基础上，将大语言模型按主流架构分为Encoder-only、Decoder-only、Encoder-Decoder等。从基于规则和字典、基于统计机器学习和基于深度学习的NER方法这三方面对目前NER研究工作进行梳理，归纳总结每一种NER方法的关键思路、优缺点和具有代表性的模型。重点介绍在人工智能飞速发展下，大语言模型的产生有望解决基于传统方法的NER任务中存在的不足，按照模型架构详细阐述不同大语言模型如何应用于NER任务，并指出其存在的问题、优缺点以及可以改进的方向，期望借助大语言模型进一步提高命名实体识别任务的效率和准确性，使其更好地应用于下游任务。

1　大语言模型与命名实体识别概述

1.1　大语言模型概述

大语言模型也称大型语言模型，由具有许多参数（通常数十亿个权重或更多）的人工网络组成，目前的大语言模型通常采用Transformer架构[10]和预训练目标，与小模型的主要区别在于模型大小、训练数据和计算资源的不同。大语言模型具有很强的学习能力，通过在大规模的语言数据集上进行训练以学习，并从大规模的语料中自动学习单词之间的关系，包括语法、语义、上下文信息等，从而生成自然流畅的文本序列[11]。大语言模型同样具有较强的迁移学习能力，可以针对特定的任务进行微调，使模型能够利用其一般的语言理解，迅速适应新的领域，从而减少对特定任务数据和训练时间的需求。

大语言模型的产生可以追溯到2017年Transformer架构的提出，Transformer引入注意力机制，能够同时考虑输入序列中的所有位置，从而提高模型的并行计算能力和捕捉长距离依赖的能力，Transformer的出现为大语言模型的产生奠定了基础。2018年提出的ELMO（embeddings from language models）模型[12]是一个典型的自回归预训练模型，解决同一词语在不同语境中含义不同的问题；OpenAI提出基于多层Transformer架构的GPT-1，采用预训练和微调两个阶段的模型训练形式；Google提出的BERT（bidirectional encoder representation from transformer）模型[13]，基于多层Transformer架构，对训练集进行双向训练，BERT-Base版本参数量为1.1亿。2019年，GPT-2模型发布；Google也发布参数规模为110亿，同时含有Encoder和Decoder的T5模型[14]，善于翻译、知识问答等给定话题的输入输出。BART（bidirectional and auto-regressive transformers）[15]，预训练时首次使用噪声破坏文本，然后通过模型重新构建原始文本。2020年，GPT-3发布，模型参数达到1 750亿。2023年，GPT-4发布，模型包含1.8万亿参数，其规模

中国知网　https://www.cnki.net

是GPT-3的10倍以上[16]。国内也相继推出一系列大语言模型，包括ERNIE（enhanced representation through knowledge integration）[17]、XLNet[18]等。

训练一个高质量的大语言模型通常需要大量的语言数据和计算资源，甚至需要使用成千上万的GPU，以及超过数十亿规模的文本数据集。早期，学者们主要使用Penn Treebank[19]、Wikidata[20]等经典数据集，但这些数据集规模比较小，限制大语言模型的表现。随着互联网的不断发展，人们开始从网上采集海量的文本数据，如WebText[21]、BookCorpus[22]、Common Crawl等。这些数据集的规模达到数十亿甚至上百亿个单词，为训练大语言模型提供充足的数据基础。

Transformer是一种基于自注意力机制的序列模型，常用于解决自然语言处理中的序列建模问题。该模型使用自注意力机制代替循环神经网络（recurrent neural network，RNN）和卷积神经网络（convolutional neural network，CNN），能够解决传统模型中长距离依赖捕捉和并行计算限制等问题，从而可以在更短的时间内获得更好的结果。因此，Transformer作为基础单元应用于所有的大语言模型中。

Transformer依赖注意力机制[23]，其模型架构如图1所示。通过多头注意力机制构建编码层和解码层。其编码器（encoder）由6个编码块（block）组成，每个块由自注意力机制和前馈神经网络组成，解码器（decoder）由6个解码块组成，每个块由自注意力机制、Encoder-Decoder attention以及前馈神经网络组成。Transformer模型通过参数矩阵映射，进行Attention操作，并将该过程重复多次，最后将结果聚合起来，即可直接获取全局特征。

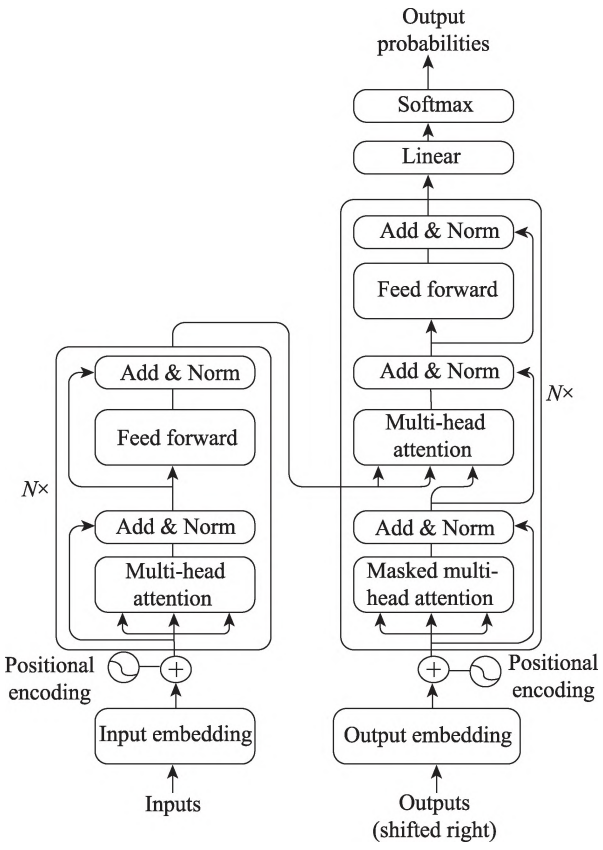

图1 Transformer模型架构

Fig.1 Transformer model architecture

将大语言模型根据其架构特点进行分类，主要可分为Encoder-only、Decoder-only、Encoder-Decoder三类[8]，如图2所示。其中，x 表示原始输入序列，$x_t(t=1,2,\cdots,T)$ 表示第 t 个标记，T 为序列长度，$M(x)$ 是 x 的掩膜标记，S 表示序列嵌入的开始标记。P_n $(n=1,2,3,4)$ 表示第 n 个位置嵌入标记，P 是条件概率。i 和 j 表示编码器输入的起始索引和结束索

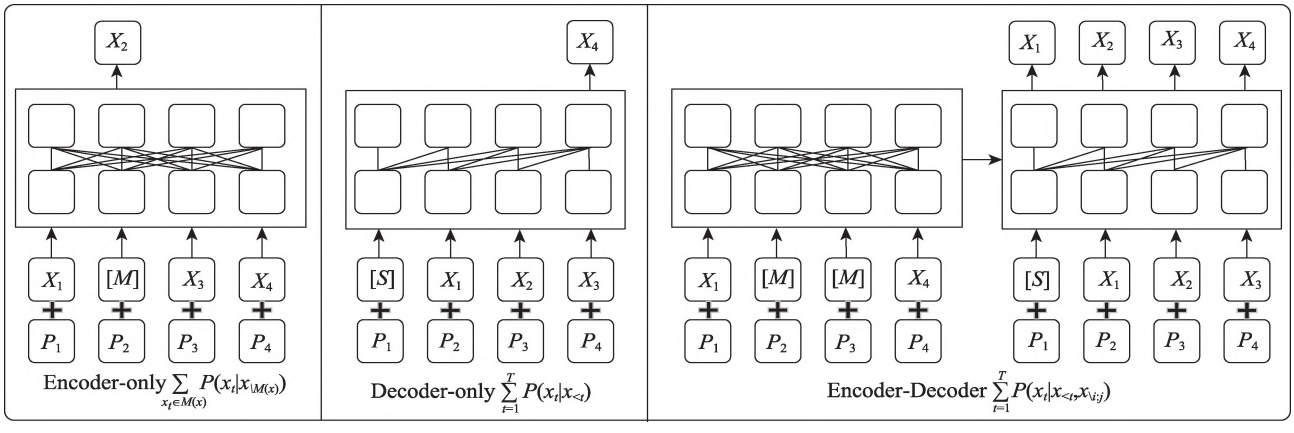

图2 三种主流模型训练框架

Fig.2 Training frameworks of three mainstream models

中国知网 https://www.cnki.net

引。$P(x_t|x<t)$ 表示在历史信息 $(x<t)$ 的条件下，预测出下一条标记 x_t 的条件概率。$x_{\backslash M(x)}$ 表示除了掩膜标记外的所有标记，$P(x_t|x_{\backslash M(x)})$ 表示在给定序列中除掩膜标记外的所有标记，对 x_t 预测的条件概率。$x_{\backslash i:j}$ 表示从位置 i 到 j 的序列。

Encoder-only模型如BERT，专注于理解输入文本，适用于自然语言理解任务；Decoder-only模型如GPT，主要用于文本生成等任务，通过预测下一个词来生成连贯文本；Encoder-Decoder模型如T5，则适用于处理输入输出有强烈依赖关系的任务，如机器翻译。此外，还有一些特殊架构的模型XLNet，其结合不同架构的优点，专为特定任务而设计。

1.2　命名实体识别概述

1995年，命名实体识别任务在MUC-6（the sixth Message Understanding Conference）[24]中首次提出，其主要目标是确定实体的边界和类型，从自然语言文本中识别出具有特定意义的实体，并能够准确识别它们的类型。命名实体一般被划分成实体类、时间类、数字类三大类和人名、地名、组织机构名、时间、日期、货币量、百分数七小类[25]。

命名实体识别技术主要划分为四个阶段：早期的基于规则和字典的方法；最大熵模型（maximum entropy model，MEM）[26]、隐马尔可夫模型（hidden Markov model，HMM）[27]、支持向量机（support vector machine，SVM）[28]、条件随机场（conditional random field，CRF）[29]为代表的统计机器学习方法；以RNN-CRF和CNN-CRF为代表的深度学习的方法；基于融合其他研究方向先进技术的思想，如自然语言处理子任务“机器翻译”提出的注意力机制，以及近期火热的大语言模型。命名实体识别技术发展路线如图3所示。

1.2.1　数据集及评价指标

命名实体识别数据集即用于命名实体识别任务的标注数据集，通常由文本数据和对应的标注数据组成。文本数据是来自不同领域的文本，比如医疗、金融、教育、新闻等，不同的文本数据集对应着不同的语言和文化背景。标注数据则是用于记录每个文本中的命名实体出现位置和对应的实体类型，标注数据中通常会包含开始位置、结束位置和实体类型等信息。常用的命名实体识别数据集如表1所示，并对数据集的语料来源、实体类型数量、数据集规模进行对比。

除数据资源以外，命名实体识别模型在训练过程中使用优化器来优化损失函数，从而更新模型的参数。在命名实体识别任务中，常用的优化器包括随机梯度下降（stochastic gradient descent，SGD）、Adam、Adadelta和Adagrad等[30]。

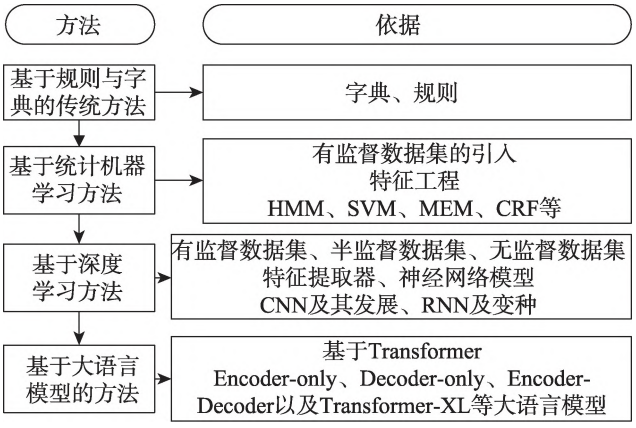

图3　命名实体识别技术发展路线

Fig.3　Technical development route of named entity recognition

命名实体识别的评价指标包含准确率（accuracy）、精确率（precision）、召回率（recall）、F1值、混淆矩阵（confusion matrix）、特异度（specificity）、假正率（false positive rate，FPR）等。

混淆矩阵是一个用于评估分类模型性能的重要工具，其展示了不同类别的预测结果与实际标签之间的关系，包括真正例（TP）、假负例（FN）、假正例（FP）和真负例（TN）。TP是数据集中实际为命名实体，模型正确识别的实体数；FP是数据集中实际为非命名实体，模型错误地预测为命名实体数；FN为数据集中实际为命名实体，模型错误地预测为非命名实体的数量。

准确率是指正确识别出的实体数量占总实体数量的比例。精确率是指模型预测为实体的部分中，实际为实体的比例。召回率也称为敏感度，指所有实际实体中被模型正确识别的比例。特异度是一个衡量模型对负样本分类准确度的指标，表示正确识别出的非实体数量占所有实际非实体的比例。假正率是指所有实际为非实体但被错误预测为实体的数量占所有实际为非实体的比例。其计算公式如式（1）~（6）所示。

评估NER模型时，通常需要根据精确度、召回率和F1值来评估模型的性能。

$$Accuracy=\frac{TP+TN}{TP+TN+FP+FN} \tag{1}$$

中国知网　https://www.cnki.net

表1 常用的命名实体识别数据集

Table 1 Common named entity recognition datasets

数据集	语言	语料来源	实体类型数量	数据集规模	特点	下载地址
OntoNotes	英文等	新闻、文学、采访等	人名、机构名、地名、时间、数值等18类	超过100万个句子	数据量大，标注质量高，多语言特性	https://catalog.ldc.upenn.edu/L
WikiNER	英文等	从维基百科网站中采集的数据	人名、地名、机构名等18类	超过200万个句子	数据量大	https://github.com/dice-group/FOX/tree/master/input/Wikiner
CoNLL-2003	英文	英语新闻文本	人名、组织机构名、位置名等4类	约14 000个句子	广泛认可，数据量小和实体类型有限	https://www.clips.uantwerpen.be/con
People's Daily News Corpus	中文	中文新闻语料库	人名、地名、机构名共3类	3亿多个字	缺乏多样性	https://github.com/InsaneLife/C
MSRA	中文	中文新闻文本	人名、地名、机构名共3类	约1万个句子	标注质量高，数据多样性不足	https://tianchi.aliyun.com/data
GENIA	英文	生物医学领域	基因、蛋白质、细胞和分子等36种细粒度类别	1 999条Medline的摘要	生物医学领域重要数据集，专业性强	http://www.geniaproject.org/home
Resume	中文	新浪财经网关于上市公司的高级经理人的简历	人名、国籍、籍贯等8类	1 027份简历	数据量小且专业化	https://tianchi.aliyun.com/data
ACE 2005	中文、英文、阿拉伯文	情报领域	人名、枪支、化学品和地下通道等7类	约7 000个文档	丰富的语义信息，适用于负责的命名实体识别任务	https://catalog.ldc.upenn.edu/L
CLUENER2020	中文	清华大学开源的文本分类数据集	组织、人名、地址等10类	约13 000个句子	实体类别分布均衡，细粒度	https://www.cluebenchmarks.com/introduce.html
CCKS 2017	中文	电子病历	症状体征、检查检验、疾病诊断等5类	数千份电子病历	标注语料匮乏，实体类别不平衡，实体结构复杂，术语表达不规范	https://www.biendata.xyz/competition/CCKS2017_2/
CCKS 2018	中文	电子病历	解剖部位、症状描述、药物等5类	数千份电子病历		https://www.biendata.xyz/competition/CCKS2018_1/
CCKS 2019—2020	中文	电子病历	疾病和诊断、检查、药物等6类	数千份电子病历		https://www.biendata.xyz/competition/ccks_2020_2_1/

$$Precision = \frac{TP}{TP + FP} \tag{2}$$

$$Recall = \frac{TP}{TP + FN} \tag{3}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{4}$$

$$Specificity = \frac{TN}{TN + FP} \tag{5}$$

$$FPR = \frac{FP}{FP + TN} \tag{6}$$

1.2.2 相关工作

（1）基于规则和字典的方法

基于规则和字典的命名实体识别是比较早期的一种方法，它不需要标注数据，主要依靠专家、语言学者等人工制定规则，选取统计信息、标点符号、关键字、指示词、位置词和中心词等为特征，通过匹配规则，以模式和字符串相匹配为主要手段对文本进行命名实体抽取[31-33]。该方法虽然能在命名实体识别任务中达到很好效果，但是其规则制定比较耗时，覆盖范围有限，系统移植性较差，难以迁移到其他领域并且不适用于大规模、复杂的文本数据。表2对上述提到的基于规则和字典的NER方法进行总结。

表2 基于规则和字典的NER方法

Table 2 NER method based on rules and dictionaries

方法	数据集	代表文献	F1/%	优点	缺点
人名和地名规则	MUC-6	[31]	96.42	在特定领域具有较好的识别效果	规则制定成本高、移植性差、不适用于大规模语料库
公司名规则	金融新闻数据集	[32]	89.13		
机构名规则	中国内地、中国香港、中国台湾三地实际语料	[33]	97.30		

（2）基于统计机器学习的方法

基于统计机器学习的方法[34-38]能有效解决基于

中国知网 https://www.cnki.net

规则和字典方法存在的不足，但其依赖于高质量的大规模标注数据且需要具有可迁移性的特征模板。而特征模板虽然能够提高NER的准确率，但其构建过程开销巨大，同样依赖于特征工程。基于统计机器学习的NER方法比较如表3所示。

（3）基于深度学习的方法

深度学习技术提供了解决复杂庞大的特征工程问题的方案，能够让机器自动找出潜在的特征模板集合。深度学习源于对人工神经网络的研究，其概念最早由Hinton[39]于2006年提出。深度学习模型往往首先对外部输入数据进行逐层特征提取，其次通过非线性激活函数从数据中学习复杂的特征，最后完成多层神经网络的训练和预测任务。基于深度学习的NER方法一般分为四步[40]：Sequence，将输入序列进行预处理；Word embedding，将输入序列转换成固定长度的向量表示；Context encoder，将词嵌入进行语义编码；Tag decoder，对标签进行解码。该过程如图4所示。

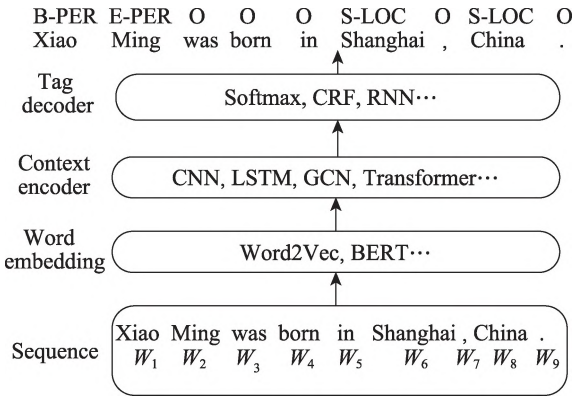

图4　基于深度学习的NER流程

Fig.4　NER process based on deep learning

在命名实体识别任务中，基于深度学习方法通过已标注的输入文本数据和对应的命名实体标签数据来训练模型，从而实现更准确的命名实体识别。基于深度学习的方法主要分为卷积神经网络（CNN）、循环神经网络（RNN）、图神经网络（graph neural network，GNN）等。

Collobert等人[41-46]将CNN应用于NER任务中，该模型不需要人工输入特征，只需要在大量大部分未标记的训练数据的基础上学习内部表征，即可很好地捕捉局部特征，具有良好性能。但是该方法对于捕捉长距离依赖关系的能力较差，这是因为该方法在处理不同长度的输入时，往往进行填充或截断，很有可能导致重要信息的丢失。RNN是一种深度学习模型，主要应用于序列数据的处理和文本生成等任务，能够解决CNN无法记忆上下文信息的问题。相比于传统的前馈神经网络，RNN具有一定的记忆和动态特性，可以处理动态的输入和输出序列。基于此，学者们[47-51]提出了多种不同方法实现命名实体识别。但该方法未能完全解决长依赖问题，导致其在处理长文本时性能下降，并且在训练过程中容易出现梯度消失和梯度爆炸的问题，影响模型的训练稳定性和性能。

传统的深度学习模型（如RNN、CNN等）主要针对向量或张量类型的数据，而命名实体和实体之间的关系可以用图模型直观地表达出来，将实体看作节点，将实体之间的关系看作边，从而形成一个图结构。传统的深度学习模型难以直接处理图结构数据，因此图结构模型应运而生。

图结构模型主要包括图卷积神经网络（graph convolutional network，GCN）、图注意力网络（graph attention networks，GAT）、图自编码器（graph auto en-

表3　基于统计机器学习的NER方法比较

Table 3　Comparison of NER methods based on statistical machine learning

模型方法	特点	代表文献	F1/%	优点	缺点
MEM	对转移概率和表现概率建立联合概率，统计的是条件概率	[34]	88.80	能够处理复杂的特征和标记依赖关系，灵活地建模和调整上下文特征	对于标记序列之间的长距离依赖关系，效果可能不如其他方法，需要大量的特征工程
HMM	基于马尔可夫链，对转移概率和表现概率直接建模，统计共现概率	[35-36]	95.40	简单有效，能够处理标记序列之间的依赖关系	可能忽略更长的上下文依赖，无法处理特征之间的相关性
SVM	特征空间上的间隔最大的线性分类器	[37]	90.03	能够处理高维特征空间，具有良好的泛化能力	无法进行多分类，对于标记序列之间的依赖关系无法建模
CRF	统计全局概率，不仅在局部归一化，考虑数据在全局的分布	[38]	84.04	能够建模标记序列的全局依赖关系，对于特征的选择和建模比较自由，具有良好的解释性	需要手动定义特征函数，计算复杂度较高

中国知网　https://www.cnki.net

coder，GAE）等。这些模型主要针对图结构数据进行特征提取、表示学习等任务，通过考虑节点的上下文信息和全局信息，能够更好地捕捉图结构数据中的关系和模式，从而获得更精确的识别和分类结果。

Cetoli等人[52]首次使用GCN来解决NER任务，在传统的BiLSTM-CRF模型中增加GCN层，Bi-GCN层通过GCN将节点信息传递给最近的节点，通过将N层图堆叠在一起，该网络结构可以传播最多相距N跳的节点特征。对于中文NER，缺乏词界信息被视为开发高性能中文NER系统的主要障碍。针对这一不足，Sui等人[53]提出CGN（collaborative graph network），首次将GAT网络和自动构建语义图引入中文NER，并将三种构图方式在融合层进行合并，该模型不仅提升了准确率，还提高了运算效率。Gui等人[54]针对链结构的特征和缺乏全局语义导致基于RNN的模型容易受到单词歧义的影响这一不足，通过引入具有全局语义的基于词典的图神经网络来解决这一问题，使该模型在不同数据集上取得显著的改进。Tang等人[55]提出一种新的字符图卷积网络（word-character graph convolution network，WC-GCN）。该网络使用交叉GCN模块同时处理两个方向的字符有向无环图（directed acyclic graph，DAG），引入全局注意力GCN模块来学习以全局上下文为条件的节点表示。该模型无须在额外的语料库上进行训练，只需要外部词典及相应的预训练字符和词嵌入。

基于深度学习的NER方法比较如表4所示。

2 基于大语言模型的命名实体识别

大语言模型在对话、理解和推理方面展现出良好的性能，推动了自然语言处理领域的发展，特别是对命名实体识别任务产生巨大的影响。首先，大语言模型通过在大规模文本数据上进行预训练，学习丰富的语言表示和语境信息，使其具备了更好的泛化能力和语义理解能力。这种强大的语言表示能力为命名实体识别任务提供坚实的基础。其次，大语言模型可以通过微调或迁移学习的方式，将在预训练阶段学习到的知识和模式应用到命名实体识别任务中，从而在少量标注数据的情况下取得出色的性能。相比传统命名实体识别模型，基于大语言模型的方法能够更好地捕捉上下文信息，更准确地识别出命名实体，并且具有更强的泛化性。大语言模型为命名实体识别任务的发展同样提供了新的思路和解决方案，基于大语言模型的命名实体识别方法已成为当前自然语言处理领域的研究热点。下文将大语言模型按照Encoder-only、Decoder-only、Encoder-Decoder等架构进行分类，介绍不同架构的大语言模型在命名实体识别任务上的应用现状。

2.1 基于Encoder-only架构的大模型在命名实体识别任务上的应用

2.1.1 基于BERT模型的命名实体识别

BERT是一种基于Transformer Encoder架构的模型[56]，其模型架构如图5所示。与传统的从左至右语

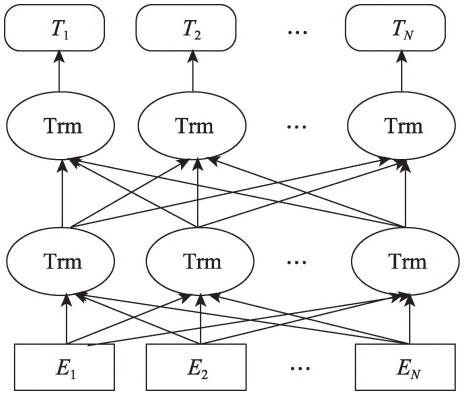

图5 BERT的架构

Fig.5 Architecture of BERT

表4 基于深度学习的NER方法比较

Table 4 Comparison of NER methods based on deep learning

模型方法	特点	参考文献	优点	缺点
CNN	CNN通过卷积层和池化层提取输入序列的局部特征，并通过全连接层进行分类。在命名实体识别中，CNN可以使用滑动窗口的方式对输入序列进行局部特征提取，然后通过Softmax函数进行标记预测	[41-46]	并行计算速度快，能够捕捉局部特征和上下文信息	对于长距离依赖关系的建模能力相对较弱
RNN	能够捕捉上下文信息和长距离依赖关系，通过全连接层进行标记预测	[47-51]	能够处理不定长的输入序列，可以建模序列之间的依赖关系	在长序列上的信息传递和梯度消失问题，顺序计算较慢，难以并行化
GNN	将输入序列建模为一个图，每个单词作为图中的节点，通过图卷积层对邻近节点进行信息传递和特征更新，然后通过全连接层进行标记预测	[52-55]	能够建模词之间的复杂关系，更高效地挖掘实体之间的关系	对于大规模图结构的计算开销较大，对图的构建和表示需要额外的处理

中国知网 https://www.cnki.net

言模型不同，BERT运用双向的Transformer编码器，这一创新使得模型能够对句子中的每个单词执行双向建模。通过这种方式，BERT能够同时参考每个单词前后的上下文信息，从而显著增强其对序列的表达能力。在构建输入序列模型时，BERT采用Transformer的Encoder部分，其每一层都由多头自注意力机制和前向全连接层组合而成。这种结构不仅使BERT能够捕捉到句子中所有单词之间的复杂交互关系，还能深入挖掘并理解上下文信息，从而实现更高效、更准确的自然语言处理。

在预训练任务中，BERT使用掩码语言模型（masked language model，MLM）和下句预测（next sentence prediction，NSP）进行训练。MLM随机遮挡输入序列中的一些单词并让模型预测这些被遮挡的单词，帮助模型学习到更丰富的语言表示，NSP则用于判断一对输入序列是否相互连续，帮助模型理解句子间的语义关系。

当BERT模型应用于NER任务时，通常需要对输入序列进行一定的转换和标注，以便让BERT模型能够更好地识别实体，常用的方法包括给实体标记开始标识和结束标识，以便让模型识别实体的边界；将标签转换成数字，将实体的类型转换成数字，以便让模型对不同的实体类型进行分类；分割输入序列，如果输入序列长度超过BERT的最大输入长度，需要将其拆分成多个子序列，并在每个子序列中进行预测。在微调阶段，通常使用交叉熵损失函数来训练BERT模型，并使用Adam优化算法对模型参数进行优化。

BERT模型已经广泛应用于医疗、化学、地理等不同领域的命名实体识别任务。陈娜等人[57]为改善中文电子病历NER任务中传统的静态词嵌入模型不能解决一词多义问题，提出一种结合注意力机制的BERT-BiGRU-Att-CRF模型。利用BERT预训练模型得到符合语境信息的动态字向量，并将该模型应用于CCKS19中文电子病历数据集。该数据集划分为6类实体类别，总计18 401个实体，获得84.11%的F1值。该模型结合了BERT的上下文理解能力、BiGRU的序列建模能力以及CRF的标签依赖性建模，提高了命名实体识别的准确性。但由于该数据集涉及中英文混写、医疗专业词汇较多、规模较小等问题，该模型对不同实体类型识别的效果不均衡，影像检查实体识别效果最好取得90.19%的F1值，手术实体仅取得73.45%的F1值。在今后的工作可以考虑结合对抗训练等方法解决实体分布不均衡的问题，通过利用轻量化的BERT模型ALBERT模型、TinyBERT等减少模型的训练时间和计算资源。陈观林等人[58]针对化学领域中危险化学品标签数据匮乏、实体识别精度不高等问题，提出BERT-BiLSTM-self-Attention-CRF模型。该模型引入BERT以获取危险化学品领域的文本字符级别编码，得到基于上下文信息的字向量，增强模型挖掘文本全局和局部特征的能力，在自建数据集上的F1值能够达到94.57%。该数据集来自《危险化学品目录（2015版）》[59]，共3 576条句子，划分4种实体类别，包含了13 213个实体。该模型具有较高的准确性和鲁棒性，特别是可以捕捉长距离依赖和复杂语义关系，但是由于BERT模型作为向量输入层，模型训练和推理时计算开销大，对硬件资源的要求较高。在今后的研究中可以考虑优化模型进一步减少计算资源的消耗。杨盈等人[60]针对现有模型实现地理领域的命名实体识别任务时存在标注语料库耗时费力、模型可解释性差等问题，结合人在回路机制推动模型利用少样本学习的特点，以少量标注的地理语料作为输入，基于BERT-BiLSTM-CRF模型进行训练并对未标注语料库进行识别。BERT模型通过在所有层的左右上下文上共同进行条件预处理，对从未标记的文本中预训练深层双向表示，从而更好地捕捉句子中的双向关系，最终形成标准地理命名实体数据集及人在回路强化后的抽取模型。实验结果表明，该模型对多数地理命名实体识别准确率达90%以上。通过引入人在回路机制为该模型提供了决策过程中的可解释性，但是存在部分地理命名实体类型识别错误，仍需在深度学习中融合语法规则与领域知识作为引导，由此还可能产生大量的人工成本。在后续的工作中可以进一步优化人在回路机制并探索自动化纠正机制，减少人工干预的依赖，探索结合地理空间数据和遥感影像等多模态数据，增强命名实体识别的上下文能力。

BERT模型除了在不同领域有广泛的应用，李代祎等人[61]将其应用于多模态数据中，针对多模态命名实体识别任务面临如何高效获取与文本中实体相关的视觉信息和如何减少图像冗余信息对命名实体识别的影响等问题，构建了一个BERT-BiLSTM-CRF实体识别模型。首先通过设计的BERT-BiLSTM模型获取包含深层语义信息的单词特征，充分考虑句子的全局信息和局部信息；其次设计一个由Token、实

中国知网 https://www.cnki.net

体和视觉对象组成的异构图网络，并设计多模态融合模型。该模型在公开数据集Twitter2015和Twitter 2017上分别获得75.26%和86.51%的F1值。该模型充分利用有效的视觉信息，减少图像噪声的影响，但是也因为数据集中存在图像和文本不匹配、实体类型分布不均和不同数据集的有偏标记等问题，导致该模型在某些类别的识别效果不如其他基线模型。未来可以充分利用大语言模型动态去除图像中的潜在噪声，提高数据集的图像和文本匹配度，构建高质量多模态数据集，训练更加强大的模型，提升命名实体识别的效果。

除此之外，BERT模型在嵌套命名实体识别任务中也具有广泛应用。Agrawal等人[62]针对嵌套命名实体识别效果差的问题，提出在两个嵌套数据集，即生物医学数据集GENIA和德语数据集GermEval 2014上使用迁移学习的方法对BERT模型进行微调，并将嵌套命名实体识别数据集中不同级别的注释连接在一起，以便将嵌套命名实体识别问题视为平面命名实体识别问题。实验结果表明，微调后的BERT模型在不需要任何外部资源和特征提取的情况下，在嵌套和非嵌套NER数据集上取得了比大部分现有模型更好的实验结果。接下来可以将该模型应用于命名实体识别以外不同的自然语言处理任务上，进一步测试其性能和泛化能力。

BERT模型具备出色的上下文理解能力，能够有效解决一词多义的问题，相较于传统的静态词嵌入模型，其能够生成与语境信息相契合的动态字向量从而更准确地呈现文本中的实体。但是在某些特定领域，该模型存在部分实体识别类型解析错误的问题，需要进一步融合语法规则和领域知识以提高准确性。此外，BERT模型相对复杂，需要消耗大量的计算资源进行训练和推理，已有学者尝试在保持BERT模型效果的同时，降低其训练所需的资源。一些模型如RoBERTa（robustly optimized BERT pre-training approach）[63]、ALBERT（a lite version of BERT）[64]、TinyBERT[65]、SpanBERT[66]等相继被提出。

2.1.2 基于ERNIE模型的命名实体识别

在英文大模型快速发展的同时，中文大模型也取得了一定的进展。2019年，百度研究院提出了大语言模型ERNIE[67]，其模型架构如图6所示。该模型将Transformer的Encoder部分作为模型的主干进行训练，通过大规模的无监督学习从海量的文本数据中学习语言模型的表示能力，对训练数据中的语法结构、词汇结构和语义信息进行统一建模，并通过有监督的学习将预训练的模型微调为特定任务的模型。其发展主要经历以下三个阶段：

ERNIE 1.0：于2019年推出的第一个版本，采用知识蒸馏（knowledge distillation，KD）的方法，将大规模的专业领域数据蒸馏到模型中，提升模型在特定领域任务上的性能。

ERNIE 2.0：于2019年底发布的升级版本，引入知识图谱的知识，通过引入实体关系和属性等知识，增强模型对文本的理解能力。

ERNIE 3.0：于2020年发布的最新版本，进一步增强知识融合和推理能力，采用多任务学习和多粒度建模的方法，通过在预训练过程中引入不同粒度的任务和目标，提升模型的性能。

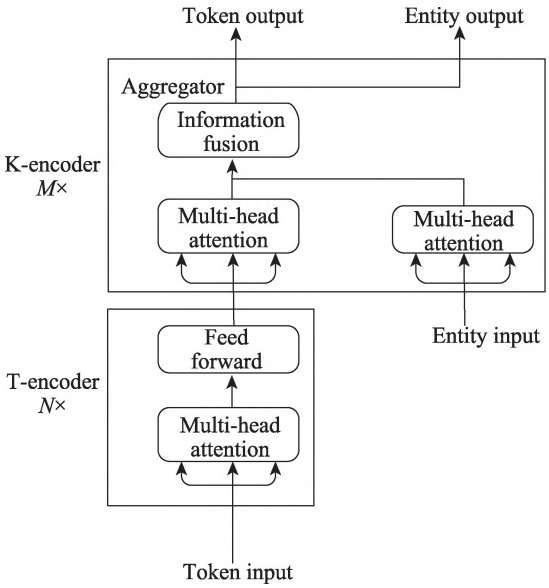

图6 ERNIE架构

Fig.6 Architecture of ERNIE

ERNIE模型适用于多种自然语言处理任务，包括文本分类、文本匹配、命名实体识别、情感分析、问答系统等。通过引入知识图谱等外部知识，增强模型对文本的理解和推理能力以及知识融合能力。该模型在特定领域任务中具有较好的效果，能够通过领域数据的蒸馏和微调适应不同领域，从而更好地处理金融、医疗、法律等特定领域的文本。

贾李睿智等人[68]针对BERT和RoBERTa等模型在中文嵌套命名实体识别任务效果差以及通过字符进行建模的方法不能学习到完整的语义表示等问题，提出基于分层ERNIE模型的命名实体识别。主要使用分层ERNIE模型对构建好的多层标签嵌套实

中国知网 https://www.cnki.net

体语料库的每一层标签进行中文嵌套命名实体识别的训练和测试。相较于BERT模型，ERNIE模型则是通过对中文实体语义单元的掩码，使模型学习完整概念的语义表示。将该模型应用于ACE2004和ACE2005两个中文嵌套命名实体数据集上，F1值分别达到了84.5%和85.9%。然而，该模型不能解决嵌套命名实体识别任务中存在实体标签分布不均和少标签的问题，后续工作可以将图卷积神经网络和ERNIE模型结合，使层和层之间的实体信息得以交互，从而解决标签分布不均和少标签问题。王刘坤等人[69]将ERNIE模型引入地理领域的命名实体识别任务，针对符号分割的命名实体、同一实体表达形式不同以及组合地质命名实体识别不全面等问题，提出GeoERNIE-BiLSTM-Attention-CRF模型。首先将ERNIE模型在地质领域预训练语料库中进行训练，得到预训练模型GeoERNIE模型；其次在GeoERNIE进行分词预处理时增加地质领域主体词表，提升模型对组合地质命名实体和符号分割的地质命名实体的识别准确率，最终取得了96.95%的F1值。该模型虽然在地质命名实体识别方面效果较好，但其适用领域相对单一，适用范围相对局限，需要进一步增加模型训练数据所涉及的领域，进而扩大该模型的适用范围和场景，还可以结合多任务学习实现地质命名实体和关系联合抽取。罗峦等人[70]针对中文命名实体识别问题，将ERNIE和改进的Transformer进行融合并提出中文命名实体识别模型ERIT（combining ERNIE with improved transformer）。该模型将ERNIE训练词向量作为嵌入层以减少对分词预处理过程的依赖，避免因分词有误以及信息缺失引起错误传播而导致准确率降低的情况，在《人民日报》公开数据集上取得79.41%的F1值。Wang等人[71]根据ERNIE更适用于中文NER的特点，提出一个基于ERNIE的联合模型——ERNIE-Joint。该模型通过联合训练NER任务和文本分类任务来利用句子级和标记级特征，同时使用原始NER数据集进行联合训练，不需要额外的注释，根据句子中的实体数量执行文本分类任务。在包含中国新闻数据和中国社交媒体数据的MSRA和微博两个公开数据集上进行实验，各项指标都取得优于其他模型的效果。但是该模型在计算损失时引入交叉熵损失函数，其运行时间高于ERNIE模型。

ERNIE模型通过改进的掩码语言模型，能够捕捉更完整的语义信息，有助于模型更准确地识别出文本中的实体，并理解它们在全局上下文中的意义。此外，由于ERNIE模型融合了外部知识，模型在识别命名实体时能够利用这些先验知识，提高了识别的准确率和鲁棒性。虽然ERNIE在对有限数据进行微调方面的性能优于BERT，但是该模型与BERT相比在小数据集上变得更加不稳定。

2.2　基于Decoder-only架构的大模型在命名实体识别任务上的应用

2.2.1　基于GPT模型的命名实体识别

GPT模型采用多层Transformer Decoder结构[72]，其模型架构如图7所示。通过堆叠多个Decoder层来增加模型的深度和表达能力。每一层Decoder都包含自注意力机制和前馈神经网络，这使得模型能够理解和生成自然语言文本。GPT模型是通过将预训练和微调相结合的方式来完成自然语言处理任务。预训练要求模型在海量的数据集上进行无监督学习，预测单词的下一个词，并通过训练来学习句子与上下文相互关联的规律。在微调过程中，将预训练模型迁移到特定的任务上，并通过有标注的数据进行监督学习，从而对自然语言领域任务进行处理。

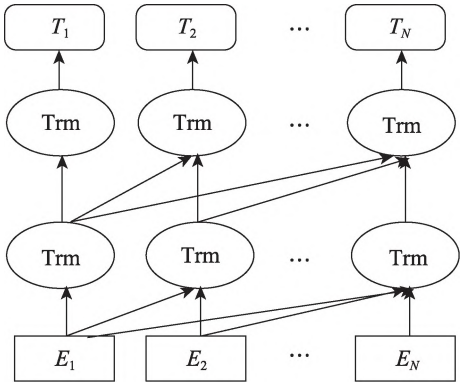

图7　GPT模型架构

Fig.7　Architecture of GPT model

GPT系列模型目前有4个版本，从GPT-1[73]、GPT-2[74]、GPT-3[75]直到GPT-4经历了参数量和性能的显著提升，其中最新版本GPT-4以1.8万亿参数量在多任务学习上展现了巨大进步。上述不同版本GPT模型的比较如表5所示。

GPT-3是OpenAI发布的延续GPT-1和GPT-2的基于Transformer Decoder的自回归语言模型结构，其参数规模将扩大至1 750亿，是GPT-2的100倍，以便于从大规模数据中吸收更多的知识。GPT-3提出了一种新的训练和推理方式，即In-Context Learning，改善了传统的zero-shot Learning可能存在数据多样性

中国知网　https://www.cnki.net

表5 不同版本的GPT模型的比较

Table 5 Comparison among different versions of GPT models

GPT	发布时间	参数数量/10^8	解码层层数	隐藏层层数	上下文窗口	预训练数据大小	数据来源	学习目标
GPT-1	2018年6月	1.17	12	768	512个token	约5 GB	BooksCorpus, Wikipedia	无监督学习
GPT-2	2019年2月	15	48	1 600	1 024个token	约40 GB	WebText	多任务学习
GPT-3	2020年5月	1 750	96	12 888	2 049个token	约45 TB	Common Crawl, etc	上下文学习
GPT-4	2023年3月	—	128	20 480	8 192个token	未公开	未公开	多模态学习

和噪声等问题。In-Context Learning需要相对于zero-shot Learning更多的算力和个性化参数，其基本思想是将模型的推理能力与特定的上下文环境相结合，使模型更好地适应上下文并从中学习到更多的信息，并在每个特定的上下文环境中对模型进行微调，以确保模型更好地适应不同环境。

在应用GPT模型于命名实体识别任务时，可以对其进行微调，然后训练GPT模型以输出单词序列中每个单词所对应的标签，例如实体名称、位置等。通常，将输入句子和对应的目标标签分别编码为序列，并将其传递给GPT模型，以产生序列上的输出，然后使用交叉熵损失函数计算模型预测和实际标签之间的差异，并使用反向传播算法更新模型参数。在输出GPT模型的标记序列之后，可以使用CRF等序列标注模型来对标记序列进行处理，以捕捉标记之间的依赖关系并使其更加合理，最终输出的结果就是NER任务的标注结果。

在现阶段，利用GPT模型实现命名实体识别任务的研究工作主要包括将GPT-2和CRF模型相结合，例如使用GPT-2模型预测文本的实体名，然后使用CRF模型改善命名实体的标注效果；或者基于GPT-2预测的标记进行微调，比如使用GPT-2模型对输入文本进行预测，接着使用该模型的输出对标记进行微调，以优化NER任务的性能；再或者基于GPT-3的微调，提高NER任务的表现，同时还可以将GPT-3与其他模型结合，如CRF模型等。

Li等人[76]针对开发临床医学自然语言处理系统面临临床文档存在隐私和安全等问题，建议开发生成合成临床笔记的方法。其应用4种先进的文本生成模型，CharRNN、Seg-GAN、GPT-2和CTRL（conditional transformer language），为病史和当前疾病部分生成临床文本。为比较自然语料库和合成语料库的效用，在3个语料库中训练命名实体识别模型，并评估不同模型在2个独立自然语料库上的表现。结果表明，利用GPT-2生成的合成语料库进行训练的NER模型在2个独立语料库上表现出更好的效果。这说明生成合成临床笔记已成为可能，有利于缓解隐私问题并提高数据可用性。鲍彤等人[77]将ChatGPT应用于MSRA、Weibo、Resume和CCKS2019等4个数据集进行零样本测试，ChatGPT在4个数据集的识别效果都与其他训练模型存在较大差距。相较而言，该模型在由人名、地名等构成的通用领域数据集上具备良好的识别能力。在电子病历的NER中，该模型的F1值只达到ERNIE的一半，主要是由于医学领域专有名词较多，实体组成成分复杂并且缺少中文医学的训练语料。ChatGPT模型在中文实体识别中仍然受到分词歧义和嵌套实体的影响，在特定领域的实体识别效果较差且受限于一词多义和语言表达的多样性，未来可以结合递归神经网络和图神经网络等能够识别和处理嵌套结构的模型结构，利用微调技术提升大模型的领域适应性，融合多模态学习提高实体识别的准确性等。Hu等人[78]针对传统的命名实体识别模型不适用于与灾难相关的社交媒体信息的问题，提出一种融合位置描述的地理知识的GPT模型。该方法仅使用少量编码地理知识的训练样例，与传统模型相比，地理知识引导的GPT模型的F1值在识别位置描述方面提高40个百分点，与默认、未融合地理知识的GPT模型相比，F1值提高76个百分点，在使用GPT-4模型时达到最好性能。虽然GPT模型在地理知识的引导下提高了命名实体识别的准确性，但是可能对非常规的地点识别能力有限，并且该模型需要大量的地理知识作为输入，这可能增加模型的复杂性和训练成本。后续可以充分集成更多的上下文信息，以便更好地处理非标准或模糊地点并进一步提高模型的鲁棒性和准确性。Hu等人[79]强调GPT-3.5和GPT-4在处理复杂的临床数据和以最少的训练数据提取有意义信息等方面具有潜力。为此，开发了一个临床任务特定的提示框架，包括带有任务描述和格式规范的基线提示、带有注释指南的提示、基于错误分析的指令以及小样本学习的注释样本，最终各项评价指标取得显著的提升，证明提示框架下的GPT模型的合理与有效性。但是GPT模型

中国知网 https://www.cnki.net

仍需要细致的提示工程和对特定任务知识的理解，未来可以利用GPT模型结合跨任务学习的方法，使模型能够从其他相关任务中学习并迁移知识，以改善在特定任务上的表现。

GPT模型能够有效地捕捉文本中的上下文，有助于更准确地识别实体。该模型能适应多种语言和通用领域的命名实体识别任务，但是在生物、地理、医学等领域性较强的命名实体识别任务上需要相关领域知识引导，并且由于GPT模型需要大量的训练数据和巨大的计算资源，会限制该模型在命名实体识别任务上的应用。

2.2.2　基于LLaMA模型的命名实体识别

LLaMA（large language model Meta AI）[80]是由Meta AI发布的开源大模型，与GPT系列模型类似，LLaMA采用了Decoder-only的架构，LLaMA使用自注意力机制处理输入序列，允许模型在生成输出时考虑到输入序列中的所有部分。为了捕捉序列中单词的位置信息，LLaMA采用了旋转嵌入（rotary positional embedding，RoPE）作为位置编码方案。为了提高效率，LLaMA的一些版本采用了分组查询注意力（grouped query attention，GQA）机制，这有助于减少计算量并加速模型的推理过程。

LLaMA-1于2023年2月发布，包含7.0×10^{9}、1.3×10^{10}、3.0×10^{10}和6.5×10^{10} 4个参数量版本，在超过1 TB token的语料上进行了预训练。LLaMA-2[81]于2023年7月发布，包含7.0×10^{9}、1.3×10^{10}、3.4×10^{10}和7.0×10^{10} 4个参数量版本，预训练的语料扩充到了2 TB token，模型的上下文长度从2 048翻倍到了4 096，引入了分组查询注意力机制（GQA）。LLaMA-3[82]发布于2024年4月，包含8.0×10^{9}和7.0×10^{10}两个参数量版本，还有4.05×10^{11}和多模态版本计划发布，使用了有监督微调（supervised fine-tuning，SFT）和人类反馈的强化学习（reinforcement learning with human feedback，RLHF），训练使用超过15 TB token的数据，是LLaMA-2数据集的7倍多，支持8 KB长文本，改进的tokenizer具有128 KB token的词汇量，训练效率比LLaMA-2提高了约3倍。上述不同版本LLaMA模型的比较如表6所示。

Keloth等人[83]针对大语言模型并不适用于被视为序列标注任务的命名实体识别问题，将LLaMA-7B模型引入生物医学领域，构建了BioNER-LLaMA模型，并在3个公开生物医学NER数据集上进行测试。结果表明BioNER-LLaMA在不同生物医学实体数据集上的F1值始终比GPT-4在少量样本学习能力高约5~30个百分点。通用领域的大语言模型可以与经过严格微调的PubMedBERT模型和PMC-LLaMA（生物医学特定语言模型）的性能相匹配。虽然该模型的F1值相较于GPT模型取得了显著的提升，但其对计算资源有较高的要求且对于特定领域术语的适应性较差。未来的研究可以考虑使用低秩适应（low-rank adaptation，LoRA），即在不改变模型主要结构的前提下，通过引入低秩矩阵来调整模型的权重，从而优化模型并使之能够适应特定的任务；还可以利用参数高效微调（parameter-efficient fine-tuning，PEFT）等技术减少计算和存储成本；或者通过计划、整合自指导（self-instruct）方法处理最少注释的实体，并采用大语言模型基于少量人类生成的指令示例生成额外的训练样本。

LLaMA模型能够理解和分析文本中的语法、语义和上下文信息，展现出了大型语言模型强大的表示能力和良好的泛化性。然而，该模型需要大量的计算资源和存储空间，部署和维护的成本较高，并且该模型在处理长文本时可能会出现重复和逻辑错误、对特定领域数据依赖性较强以及模型透明度和可解释性较差等问题。

2.3　基于Encoder-Decoder架构的大模型在命名实体识别任务上的应用

2.3.1　基于T5模型的命名实体识别

T5（text-to-text transfer transformer）[14]是Google团队于2019年提出的一种基于Transformer的Encoder-Decoder结构的通用文本生成模型，如图8所示。该模型将不同的任务转换成“Text-to-Text”问题，即在该

表6　不同版本的LLaMA模型的比较

Table 6　Comparison among different versions of LLaMA models

LLaMA	发布时间	参数数量/10^{9}	上下文	预训练数据大小	训练方法
LLaMA-1	2023年2月	7、13、30、65	2 048	1 TB token	自监督学习方法，没有特定任务的微调
LLaMA-2	2023年7月	7、13、34、70	4 096	2 TB token	有监督微调（SFT），基于人类反馈的强化学习（RLHF）
LLaMA-3	2024年4月	8、70	8 192	15 TB token	结合数据并行、模型并行和流水并行策略进行训练，微调阶段结合了SFT、拒绝采样、PPO和DPO

中国知网　https://www.cnki.net

模型中，输入和输出都是文本序列，通过多任务学习的方式对模型进行训练，使得模型的训练和使用更加简单并且能更好地展开迁移学习。无论是什么问题，其输入和输出是统一的，该模型在大规模的文本数据上进行预训练以学习通用的语言表示、获取丰富的语言知识。作为一个文本生成模型，具有强大的生成能力，可以输出高质量的文本。

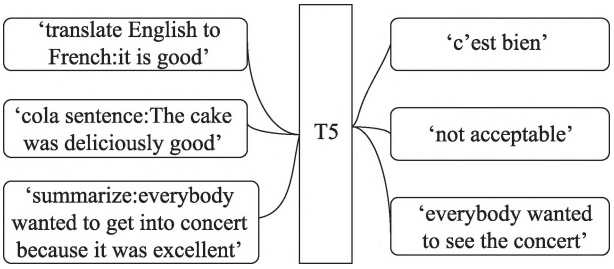

图8 T5模型

Fig.8 Model of T5

T5模型具有大规模的参数量和复杂的结构，因此需要较大的计算资源和训练时间进行预训练和微调，因在实时应用中可能存在较大的延迟，不适用于某些需要快速响应的场景[84]。作为BERT中引入的主要掩码语言建模的替代方案，T5模型引入了一个更通用的训练目标，即序列到序列的转换，更适合文本生成任务。T5模型的单语言变体仅限于资源丰富的语言，而大规模多语言T5模型支持101种语言[85]。

将低资源场景下训练所得的T5模型用于形态学丰富的斯洛文尼亚语，分析其在包含命名实体识别在内的八个分类任务上的表现，并将其与多语言模型mT5、mBART-50以及四种类似BERT的编码器模型，包括多语言BERT[86]、多语言XLM-RoBERTa[87]、三语言克罗地亚语-斯洛文尼亚语-英语BERT[88]和单语言斯洛文尼亚语RoBERTa模型[89]相对比。实验结果表明，该模型在分类任务上的效果落后于单语SloBERTa模型，BERT模型表现更为出色。对于文本生成任务，T5模型表现优秀，尽管结果获取于斯洛文尼亚语数据集，但是该模型可以推广到其他资源较少的语言从而提高实体识别和分类任务的精度。由于临床实践和研究所需要的放射学报告均以自由文本叙述的形式书写和存储，想要从中提取相关信息以进一步分析存在困难。针对这一问题和现有深度学习模型存在的不足，Moezzi等人[90]收集88自由文本格式的腹部和盆腔超声报告，对其进行注释，然后对T5和Scifive模型进行微调，以提取报告中的实体和关系。该模型通过并行处理整个序列提升了速度，微调的方式使其不必从零进行训练，且能够完成细粒度的NER。但是该模型局限于特定领域，主要针对腹部和盆腔超声报告，尚未在其他类型的放射学报告进行测试，可能会遗漏部分罕见的短语和特征描述。

总的来说，T5模型通过采用"Text-to-Text"统一框架，简化模型的适配过程，且由于其基于Transformer架构，能够在大规模语料库上开展无监督学习，从中捕捉文本中的语义信息。但该模型需要规模较大的数据集并且高度依赖于输入序列的质量和准确性，如果输入序列存在错误或噪声，模型的性能可能会受到影响，因此在缺乏大规模数据集的情况下实现NER任务是一项挑战。

2.3.2 基于BART模型的命名实体识别

BART[15]模型是由FAIR（Facebook AI research）于2019年提出的基于Encoder-Decoder架构的大语言模型，其结合了BERT模型的双向编码器和GPT模型的自回归解码器的特点，通过去噪自编码器的方式进行预训练，即模型随机破坏文本（例如随机打乱句子顺序、用特殊的mask标记替换文本片段等）后，训练模型重建原始文本。

针对现有研究很少同时考虑重叠和不连续的实体，Ji等人[91]将命名实体识别任务视为序列生成问题，使用机器阅读理解的方法来编码有关实体类别的重要信息。然后结合提及相关性注意力机制（mention relevance attention，MRA），通过问答模型预测给定源句子与查询的提及相关性，并将相关性得分整合至BART模型中，以增强实体识别的准确性。作者在平面、重叠和不连续三种不同类型的命名实体识别数据集上展开实验。结果表明基于BART的模型在重叠和不连续的两个数据集上优于当前表现最佳的基线模型，与目前最先进模型相比，其性能得到了大量提升。在BART模型基础上引入MRA机制能够有效解决重叠和不连续实体问题，但是由于BART是序列到序列模型，在推理时可能效率较低，尤其是在使用beam search等生成策略时其推理速度可能较慢，后续可以研究模型的变体，例如采用非自回归生成方法加速解码过程从而提高推理效率。Cui等人[92]针对在资源受限的情况下实现命名实体识别时，现有的基于相似度度量的方法无法充分利用命名实体识别模型参数中的知识转移的问题，提出一种基于模板的命名实体识别方法。其首先利用BART的序

中国知网 https://www.cnki.net

列到序列的能力，通过模板化的输入输出对训练BART模型，使其能够分类每个候选实体，然后在推理阶段根据对应的模板得分对每个候选跨度进行分类。实验结果表明，该方法在资源丰富的数据集CoNLL-2003上的F1值达到了92.55%，与现有方法相比，在低资源数据集（如MIT Movie、MIT Restaurant和ATIS）上的F1值分别提高了10.88个百分点、15.34个百分点和11.73个百分点。尽管该模型在不同类型数据集上的性能均得到了显著提升，但是该方法受限于模板质量。后续研究可以改进模板的设计方法或探索自动化模板生成技术，减少手动设计模板的工作量，还可以考虑引入外部知识库以增强模型识别命名实体的能力。Du等人[93]针对临床电子病历中由中文标注缺失导致的命名实体识别性能较差的问题，提出一种融合BART、Bi-LSTM和CRF的多医学实体识别模型（multimodels fusion for MNER，MF-MNER）。首先，在对电子病历进行清理、编码和分割后，采用BART模型对获得的语义表示进行动态融合；其次，使用Bi-LSTM网络捕获顺序信息；最后，利用CRF进行解码和输出多任务实体识别。实验结果表明，该模型在三个评价指标上均优于现有模型，这说明其能够整合BART、Bi-LSTM和CRF层的优势，以少量的标注显著提高下游命名实体识别任务的性能，在召回率方面达到优异的性能，具有一定的现实意义。但是该模型仅在CCKS2019数据集和100份真实临床数据上开展实验，需要进一步提升对真实医疗数据的实体识别性能，且不同医院之间的临床数据存在信息隔离问题，模型的泛化能力有待于提高。考虑到医疗数据具有隐私性和敏感性，未来可以收集并扩充医疗数据集，并在保护患者隐私的前提下，有效提取信息并训练模型。

简言之，BART模型以其先进的Transformer架构和预训练策略，在捕捉长距离依赖和提供丰富上下文信息方面具有显著优势，尤其适合处理复杂的语言现象。然而，该模型也面临计算资源消耗大、依赖特定领域标注数据以及长序列处理挑战等问题。此外，相比于一些更轻量级的模型，BART模型的推理速度较慢，当处于实时NER应用场景时有可能存在劣势。

2.4　基于其他架构的大模型在命名实体识别任务上的应用

XLNet[94]在架构上不完全符合以上三种分类，该模型采用Transformer-XL架构，主要采用自回归与自编码混合的方式，能够处理更长的输入序列并保持长期依赖关系，克服了BERT模型在MLM阶段忽略词之间的相互关联性和全局上下文无法建模的限制，同时解决了BERT中掩码造成的信息泄露问题。其中，在利用自回归的方式对XLNet进行预训练时，该模型通过自标签的方式逐步预测序列中的每个位置；在自编码预训练中，该模型通过随机掩码的方式，自编码每个位置的上下文，将此两种方式混合即可建立全局的上下文依赖关系。

已有很多学者结合XLNet的优势，将其应用于命名实体识别任务。姚贵斌等人[95]针对现有方法不能充分挖掘句子内部隐藏信息的问题，提出CAW-XLNet-BiGRU-CRF模型，将字向量和词向量特征整合输入到语言模型XLNet，经过BiGRU-CRF输出最优标签序列，在《人民日报》数据集上的F1值达到了95.73%。但是该模型在嵌套命名实体识别任务中仍存在不足，可以考虑将大语言模型与人工制定的规则结合起来，以便更好地应用于命名实体识别任务。沈宙锋等人[96]针对传统词向量模型文本语义表示不充分等问题，提出基于XLNet的中文临床电子病历命名实体识别模型XLNet-BiLSTM-MHA-CRF，将XLNet预训练语言模型作为嵌入层，生成病历文本的向量化表示，使用动态向量代替传统的静态向量，解决一词多义等问题，取得了91.64%的F1值。但是本实验采用的是数据集CCKS2017，其实体种类较少且数量不均衡，后续研究需要获取更多数据扩充其实体种类和数量。陈明等人[97]将命名实体识别任务应用于农业领域，针对农业领域的文本语义表达不足、缺乏语境特征、词向量多样性表达困难等问题，提出适用于农业领域的命名实体识别模型XLNet-IDCNN-CRF。其同样将XLNet应用于嵌入层对输入文本进行向量化表示，以丰富文本的语义信息，缓解一词多义的问题。XLNet的引入更好地传递语义之间的上下文信息，增强捕捉长距离依赖关系的能力，使模型更具语义表征能力，并在自构建的农业领域数据集上取得93.91%的F1值。Yan等人[98]基于XLNet提出一种新的神经网络模型XLNet-BiLSTM-CRF，利用已经预训练的XLNet提取句子特征，从而避免了由错误的语义特征导致的识别错误，并将提取的句子特征与BiLSTM-CRF相结合。将该模型应用于英文数据集CoNLL-2003和WNUT-2017数据集，相较于基线模型各项指标均显著提升。该模型充分利用了XLNet在句子表示中的优势，并使

中国知网 https://www.cnki.net

用CRF模型弥补了BiLSTM不能捕获不同标签之间关系的缺陷，进一步解决了小语料库中的命名实体识别问题。未来考虑根据特定的业务需求，充分利用XLNet模型识别出更多的实体类别，并将预训练好的XLNet应用于信息提取和机器翻译等自然语言处理任务。Chai等人[99]将深度神经网络应用于生物医学领域的命名实体识别任务，针对深度学习模型在预训练和微调过程中存在噪声干扰，并且没有有效的标签依赖性解码器，提出基于排列语言预训练模型XLNet编码和CRF解码的共享标签和动态拼接两种降噪模型。将该模型应用于15个生物医学命名实体识别数据集，该模型的平均F1值分别提升1.50个百分点和1.48个百分点。XLNet-CRF模型可以更好地捕捉生物医学文本中的长距离依赖关系，提高模型对噪声数据的鲁棒性，但是该模型需要消耗巨大的计算资源，并且其存在单任务学习泛化能力不足、多任务学习不稳定等问题。针对这一问题，Chai等人[100]提出将多任务学习与微调相结合的分层共享迁移学习方法，实现底层实体特征与上层数据特征之间的多层次信息融合。在多任务训练中，作者将XLNet-CRF模型的参数分为共享部分和任务特定部分。共享部分用于多任务学习，特定任务部分用于单任务学习从而提高对复杂语言结构的建模能力，以更好地捕捉实体标签的连续性。但是该模型可能会在训练过程中收敛到局部最优解，在未来的研究中可以考虑不同的切片率对模型性能的影响，以找到最优的参数分割策略，进而提升模型的整体性能。

总而言之，XLNet模型具有强大的数据驱动能力，在理解上下文和实体间的关系方面表现出色，双向上下文建模能力使其能更有效地捕捉长距离依赖关系，同时可以减少BERT模型在预训练阶段产生的输入噪声。但是由于XLNet模型的规模较大，在预训练和微调时需要大量的时空开销，并且XLNet的预训练过程涉及自回归和自编码两个步骤，相对于单一的自编码预训练，其过程较为复杂。

上述基于不同架构的大语言模型的NER方法比较如表7所示。

3 发展趋势与展望

以GPT模型为代表的大语言模型，对命名实体识别任务产生巨大影响，可以改进传统命名实体识别方法中存在的不足，进而推动自然语言处理任务的发展。下面将根据大语言模型应用于命名实体识

表7 基于大语言模型的NER方法比较

Table 7 Comparison of NER methods based on large language model

模型架构	模型方法	特点	代表文献	优点	缺点
Encoder-only	BERT	使用MLM和NSP进行双向联合训练	[57-62]	采用掩码语言模型对双向的Transformer进行预训练，以生成深层的双向语言表征	需要大量GPU和训练数据，无法处理长文本
	ERNIE	对训练数据中心的语法结构、词汇结构和语义信息进行统一建模	[68-71]	在对远程监督数据进行去噪和对有限数据进行微调方面的性能优于BERT	与BERT相比，在小数据集上的稳定性较差
Decoder-only	GPT	无监督的训练和有监督的微调	[76-79]	语义感知强，能理解上下文语境，可以通过微调适应不同领域的实体识别任务	生成式模型限制，需要更多的计算资源
	LLaMA	具有大规模参数能处理复杂的语言任务，多任务学习，上下文感知	[80-83]	高性能，泛化能力较强，资源消耗较低	潜在的数据偏见和错误，小样本学习能力有限，长文本处理能力较差
Encoder-Decoder	T5	采用统一的Text-to-Text框架，将所有的自然语言处理任务都统一为文本生成任务	[86-90]	可以多任务学习，使模型可以从不同任务中共享知识，提高模型泛化能力和效率	数据需求量大，模型复杂度高，计算资源消耗大
	BART	去噪自编码器、文本生成和理解，有效处理序列到序列的任务	[91-93]	在多种文本生成任务中表现出色，高效的预训练策略	模型复杂，需要较高的计算成本，泛化能力有限
Transformer-XL	XLNet	结合排列语言模型和双流自注意力机制，采用Transformer-XL架构和严格的自回归性质	[95-100]	能够考虑输入文本的全局上下文信息，解决长距离依赖关系，更好地理解文本的因果关系	数据需求量大，计算资源消耗大，模型复杂度高，过拟合风险

中国知网 https://www.cnki.net

别任务存在的问题和挑战进行讨论，并研究其未来方向。

（1）命名实体识别的可训练数据集稀缺问题

命名实体识别任务往往依赖于大量标注数据集从而对模型进行训练，但是获取大规模的标注数据集其时空开销可能较大，尤其对于一些特定领域，需要该领域的专家对数据进行标注，这样不仅消耗巨大的人力、财力，还不能保证数据集的质量，因此可训练的高质量数据集的稀缺对命名实体识别任务是一个巨大的难题。

对此，可以利用大语言模型的主动学习能力，主动学习通过一定算法可以查询到最有用的未标记数据，并交由专家进行标注，然后用此数据训练模型从而提高模型的精确度。同时，还可以选择对模型预测结果置信度低或不确定性高的样本进行标注，以有效解决标注数据稀缺，跨语种、跨领域命名实体识别模型泛化性差等问题。因此，在大语言模型的基础上引入主动学习方法，以此解决数据标注、领域适应性差的问题是一个值得探索的方向。

（2）命名实体识别在专业领域的泛化能力较差问题

专业领域中存在大量领域特定的术语和命名实体，这些术语在通用语料库中很少出现，并且专业领域的文本通常具有复杂的结构和领域内特定的语言模式，例如医学文献中的生物和化学术语、法律文件中的法律条款以及少数民族语料等。因此即使在数据充足的领域，模型可能仍然在泛化到未见过的数据或新领域上表现不佳，而数据集稀缺更加剧了泛化能力的不足。

针对这一问题，未来可以进一步利用大语言模型，在领域专业知识的指导下对其进行微调，通过迁移学习或领域自适应技术，提高识别专业领域词汇的准确性。同时可以针对特定领域，利用大语言模型的生成式特点构建包含领域内常见术语、实体和上下文信息的大规模命名实体识别数据集。并与领域专家合作，利用其丰富的领域知识指导NER任务的标注工作，从而解决模型难以处理的复杂情况和歧义性的问题，以此提升专业领域的命名实体识别的准确性。

（3）命名实体识别中存在多义词和命名实体歧义的问题

数据集稀缺可能导致模型在训练时无法充分学习到实体的多样性，并且由于泛化性不足可能导致模型在未见过的多义词或歧义实体时，无法准确识别其在特定上下文中正确意义。特别是在中文命名实体识别任务中，由于汉语中大部分词语都是含有多个语义的多义词，在不同语境中具有不同的含义和解释。比如“苹果”既可以是水果，也可以是公司的名字。并且由于中文没有明确的词边界，不存在词形变换等特征，中文命名实体识别更具有挑战性。

针对这一问题，随着多模态数据得以在各个领域的广泛应用，融合图像、视频、语音等多模态信息可以引导模型更好地学习单词表征、理解实体含义，使其预测相关词时更加准确。未来可以探索如何将大语言模型与图像、音频等多模态信息，偏旁、部首等多源信息进行融合，从而进一步提高命名实体识别在各个领域的表现。

（4）大语言模型应用于命名实体识别任务缺乏统一框架

在命名实体识别任务中，由于不同学者对命名实体识别任务的研究领域不同，涉及任务本身的复杂性和多样性、数据集和任务定义的差异、模型架构和特征选择的多样性以及评价指标的不一致性等方面，其根据自己的领域特性持有不同的研究思路、框架，因此基于大语言模型的命名实体识别任务缺乏统一的框架流程。

针对该问题，可以通过制定统一的命名实体识别任务定义，明确定义实体类型、标注标准和任务目标，并建立一个公开的标准数据集，构建公开的共享模型和工具库，包括各种命名实体识别模型的实现、训练代码等。积极开展学术界和工业界的合作，建立命名实体识别任务的标准化组织，推动相关标准的制定。

（5）大语言模型应用于命名实体识别任务上缺乏可解释性

大语言模型通常被视为“黑箱”，虽然能够提供良好的计算结果，但很难解释为什么会得到这些结果。这是因为模型的决策过程通常涉及复杂的神经网络层和大量的参数，这些参数如何相互作用并产生最终的NER结果往往是不透明的。当模型预测出现错误时，由于缺乏可解释性，开发者很难快速定位错误发生的原因，这使得模型的验证和调试变得困难。

针对大语言模型缺乏可解释性的问题，可以引入注意力机制，突出模型在作决策时所依赖的重要部分。此外，由于图神经网络擅长处理图结构数据，

中国知网 https://www.cnki.net

能够捕捉实体间复杂关系和整合实体的上下文信息，充分结合图神经网络有助于大模型充分理解和利用这些信息，并利用可视化技术展示哪些邻居节点对特定实体的识别起到了关键作用，从而提供决策过程的透明度，提高大语言模型的可解释性。

（6）大语言模型存在的错误传播问题

在大语言模型的预训练过程中，由于数据具有多样性和复杂性，同时存在标注错误、数据噪声、上下文歧义等问题，当这些错误信息被模型学习并应用于命名实体识别任务时，会导致该模型在命名实体识别任务中产生错误的预测。缺乏统一框架可能导致不同模型间的错误传播模式不一致，增加了问题的复杂性，而缺乏可解释性使得错误传播难以诊断和纠正。

对此，已有学者通过对训练数据进行清洗和纠错，降低错误标注和噪声数据对模型的影响。还可以引入对抗学习的思想，将错误的实体标注作为对抗样本，与模型进行对抗迭代训练，以减少错误传播的影响，同时提升模型的鲁棒性，提高对于错误标注的容错能力。此外，还能利用弱监督信号辅助命名实体识别任务，以在模型训练过程中解决错误传播问题。例如，可以利用外部的知识库、规则或领域专家的反馈提供额外的标注信息，以修正错误传播问题。

（7）大语言模型的计算资源需求高、训练成本大

虽然大语言模型在命名实体识别任务中取得了不错的成果，但由于大语言模型通常具有数十亿至数百亿个参数，需要大量的存储空间保存模型参数且需要巨大的计算资源进行训练和推断。其庞大的体量和高昂的资源消耗限制其进一步的发展。

未来，研究人员可以通过模型压缩技术，减少模型的大小和参数数量从而降低存储和计算成本，其中常见的方法包括模型剪枝、蒸馏、增量化学习等。

4 结束语

命名实体识别任务在自然语言处理中具有重要意义和应用价值，促进了文本理解和语义理解的发展，推动着自然语言处理和人工智能的进步。本文从大语言模型的角度出发，首先简要概述大语言模型与传统命名实体识别任务的发展脉络与研究现状。其次介绍了近年来具有代表性的大语言模型，重点论述了大语言模型在命名实体识别任务中的应用，尤其是在不同领域、数据集上的表现以及存在的不足和改进的思路。最后对基于大语言模型的命名实体识别任务作出展望，包括从专业领域词汇的识别问题、大语言模型的多任务联合学习、主动学习、多模态与多源信息融合、大模型轻量化与错误传播等问题入手，进一步优化命名实体识别技术。期望未来基于大语言模型的命名实体识别技术在知识图谱构建和其他自然语言处理任务中发挥更加重要的作用，为更多相关学科领域带来更多的发展机会，为人工智能的发展带来更大的推动力。

参考文献：

[1] XU D, CHEN W, PENG W, et al. Large language models for generative information extraction: a survey[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2312.17617.

[2] SUN G, LIANG L, LI T, et al. Video question answering: a survey of models and datasets[J]. Mobile Networks and Applications, 2021, 26(5): 1904-1937.

[3] CHAUHAN S, DANIEL P. A comprehensive survey on various fully automatic machine translation evaluation metrics [J]. Neural Processing Letters, 2023, 55(9): 12663-12717.

[4] PENG C, XIA F, NASERIPARSA M, et al. Knowledge graphs: opportunities and challenges[J]. Artificial Intelligence Review, 2023, 56(11): 13071-13102.

[5] 罗媛媛, 杨春明, 李波, 等. 融合机器阅读理解的中文医学命名实体识别方法[J]. 计算机科学, 2023, 50(9): 287-294.
LUO Y Y, YANG C M, LI B, et al. Chinese medical named entity recognition method incorporating machine reading comprehension[J]. Computer Science, 2023, 50(9): 287-294.

[6] WANG Z, ZHANG S, ZHAO Y, et al. Risk prediction and credibility detection of network public opinion using blockchain technology[J]. Technological Forecasting and Social Change, 2023, 187: 122177.

[7] 陈光, 郭军. 大语言模型时代的人工智能: 技术内涵、行业应用与挑战[J/OL]. 北京邮电大学学报 [2024-05-23]. https://doi.org/10.13190/j.jbupt.2024-035.
CHEN G, GUO J. Artificial intelligence in the era of large language models: technical significance, industry applications and challenges[J/OL]. Journal of Beijing University of Posts and Telecommunications [2024-05-23]. https://doi.org/10.13190/j.jbupt.2024-035.

[8] 孙凯丽, 罗旭东, 罗有容. 预训练语言模型的应用综述[J]. 计算机科学, 2023, 50(1): 176-184.
SUN K L, LUO X D, LUO Y R. Survey of applications of pretrained language models[J]. Computer Science, 2023, 50(1): 176-184.

[9] 蔡睿, 葛军, 孙哲, 等. AI预训练大模型发展综述[J/OL]. 小

中国知网 https://www.cnki.net

型微型计算机系统 [2024-05-23]. http://kns.cnki.net/kcms/detail/21.1106.tp.20240510.1900.010.html.
CAI R, GE J, SUN Z, et al. Overview of the development of AI pre-trained large models[J/OL]. Journal of Chinese Computer Systems [2024-05-23]. http://kns.cnki.net/kcms/detail/21.1106.tp.20240510.1900.010.html.

[10] HAN K, WANG Y, CHEN H, et al. A survey on vision transformer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(1): 87-110.

[11] 鲁超峰, 陶冶, 文连庆, 等. 融合大语言模型和预训练模型的少量语料说话人-情感语音转换方法[J/OL]. 计算机应用 [2024-05-23]. http://kns.cnki.net/kcms/detail/51.1307.TP.20240328.2243.020.html.
LU C F, TAO Y, WEN L Q, et al. Speaker-emotion voice conversion method with limited corpus based on large language model and pre-trained model[J/OL]. Computer Applications [2024-05-23]. http://kns.cnki.net/kcms/detail/51.1307.TP.20240328.2243.020.html.

[12] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1301.3781.

[13] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1810.04805.

[14] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21: 1-67.

[15] LEWIS M, LIU Y, GOYAL N, et al. BART: denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1910.13461.

[16] FLORIDI L, CHIRIATTI M. GPT-3: its nature, scope, limits, and consequences[J]. Minds and Machines, 2020, 30: 681-694.

[17] SUN Y, WANG S, LI Y, et al. ERNIE 2.0: a continual pre-training framework for language understanding[C]//Proceedings of the 2020 AAAI Conference on Artificial Intelligence. Menlo Park: AAAI, 2020: 8968-8975.

[18] XIANG S, DONG F, XU S. A hybrid neural network based on XLNet for rumor detection[C]//Proceedings of the 2022 IEEE 2nd International Conference on Power, Electronics and Computer Applications. Piscataway: IEEE, 2022: 1207-1211.

[19] MARCUS M, SANTORINI B, MARCINKIEWICZ M A. Building a large annotated corpus of English: the Penn Treebank[J]. Computational Linguistics, 1993, 19(2): 313-330.

[20] ERXLEBEN F, GUNTHER M, KROTZSCH M, et al. Introducing wikidata to the linked data web[C]//Proceedings of the 13th International Semantic Web Conference, Riva del Garda, Oct 19-23, 2014. Cham: Springer, 2014: 50-65.

[21] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners[J]. OpenAI Blog, 2019, 1(8): 9.

[22] ZHU Y, KIROS R, ZEMEL R, et al. Aligning books and movies: towards story-like visual explanations by watching movies and reading books[C]//Proceedings of the 2015 IEEE International Conference on Computer Vision. Washington: IEEE Computer Society, 2015: 19-27.

[23] DORDEVIC D, BOZIC V, THOMMES J, et al. Rethinking attention: exploring shallow feed-forward neural networks as an alternative to attention layers in transformers (student abstract)[C]//Proceedings of the 2024 AAAI Conference on Artificial Intelligence. Menlo Park: AAAI, 2024: 23477-23479.

[24] 马昂, 于艳华, 杨胜利, 等. 基于强化学习的知识图谱综述[J]. 计算机研究与发展, 2022, 59(8): 1694-1722.
MA A, YU Y H, YANG S L, et al. Survey of knowledge graph based on reinforcement learning[J]. Journal of Computer Research and Development, 2022, 59(8): 1694-1722.

[25] 祁鹏年, 廖雨伦, 覃飙. 基于深度学习的中文命名实体识别研究综述[J]. 小型微型计算机系统, 2023, 44(9): 1857-1868.
QI P N, LIAO Y L, QIN B. Survey on deep learning for Chinese named entity recognition[J]. Journal of Chinese Computer Systems, 2023, 44(9): 1857-1868.

[26] ADAM L B, STEPHEN D P, VINCENT J D P. A maximum entropy approach to natural language processing[J]. Computational Linguistics, 1996, 22(1): 39-71.

[27] HU W, TIAN G, KANG Y, et al. Dual sticky hierarchical Dirichlet process hidden Markov model and its application to natural language description of motions[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(10): 2355-2373.

[28] CHEN P H, LIN C J, SCHOLKOPF B. A tutorial on ν-support vector machines[J]. Applied Stochastic Models in Business and Industry, 2005, 21: 111-136.

[29] LEE C, HWANG Y, OH H, et al. Fine-grained named entity recognition using conditional random fields for question answering[C]//Proceedings of the 2006 Asia Information Retrieval Symposium. Berlin, Heidelberg: Springer, 2006: 581-587.

[30] WANG L, WANG X, LI T, et al. SAdaBoundNc: an adaptive subgradient online learning algorithm with logarithmic

中国知网 https://www.cnki.net

regret bounds[J]. Neural Computing and Applications, 2023, 35(11): 8051-8063.

[31] KRUPKA G R. SRA: description of the SRA system as used for MUC-6[C]//Proceedings of the 6th Conference on Message Understanding, Columbia, Nov 6-8, 1995. Stroudsburg: ACL, 1995: 221-235.

[32] 王宁, 葛瑞芳, 苑春法, 等. 中文金融新闻中公司名的识别[J]. 中文信息学报, 2002, 16(2): 1-6.
WANG N, GE R F, YUAN C F, et al. Company name identification in chinese financial domain[J]. Journal of Chinese Information Processing, 2002, 16(2): 1-6.

[33] 张小衡, 王玲玲. 中文机构名称的识别与分析[J]. 中文信息学报, 1997(4): 22-33.
ZHANG X H, WANG L L. Identification and analysis of Chinese organization and institution names[J]. Journal of Chinese Information Processing, 1997(4): 22-33.

[34] BORTHWICK A, STERLING J, AGICHTEIN E, et al. NYU: description of the MENE named entity system as used in MUC-7[C]//Proceedings of the 7th Message Understanding Conference, Virginia, Apr 29-May 1, 1998. Stroudsburg: ACL, 1998: 1-7.

[35] FU G, LUKE K K. Chinese named entity recognition using lexicalized HMMs[J]. ACM SIGKDD Explorations Newsletter, 2005, 7(1): 19-25.

[36] 张华平, 刘群. 基于角色标注的中国人名自动识别研究[J]. 计算机学报, 2004, 27(1): 85-91.
ZHANG H P, LIU Q. Automatic recognition of Chinese personal name based on role tagging[J]. Chinese Journal of Computers, 2004, 27(1): 85-91.

[37] ISOZAKI H, KAZAWA H. Efficient support vector classifiers for named entity recognition[C]//Proceedings of the 19th International Conference on Computational Linguistics, Taipei, China, Aug 24-Sep 1, 2002. Stroudsburg: ACL, 2002: 1-7.

[38] MCCALLUM A, LI W. Early results for named entity recognition with conditional random fields, feature induction and web-enhanced lexicons[C]//Proceedings of the 7th Conference on Natural Language Learning, Edmonton, May 31-Jun 1, 2003. Stroudsburg: ACL, 2003: 188-191.

[39] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[40] LI J, SUN A X, HAN J L, et al. A survey on deep learning for named entity recognition[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(1): 50-70.

[41] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural language processing (almost) from scratch[J]. Journal of Machine Learning Research, 2011, 12: 2493-2537.

[42] YAO L, LIU H, LIU Y, et al. Biomedical named entity recognition based on deep neutral network[J]. International Journal of Hybrid Information Technology, 2015, 8(8): 279-288.

[43] STRUBELL E, VERGA P, BELANGER D, et al. Fast and accurate entity recognition with iterated dilated convolutions[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, Copenhagen, Sep 9-11, 2017. Stroudsburg: ACL, 2017: 2670-2680.

[44] WU Y H, JIANG M, LEI J B, et al. Named entity recognition in Chinese clinical text using deep neural network[C]//Proceedings of the 15th World Congress on Health and Biomedical Informatics, São Paulo, Aug 19-23, 2015: 624-628.

[45] WU F Z, LIU J X, WU C H, et al. Neural Chinese named entity recognition via CNN-LSTM-CRF and joint training with word segmentation[C]//Proceedings of the 2019 World Wide Web Conference, San Francisco, May 13-17, 2019. New York: ACM, 2019: 3342-3348.

[46] GUI T, MA R T, ZHANG Q, et al. CNN-based Chinese NER with lexicon rethinking[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence, Macao, China, Aug 10-16, 2019: 4982-4988.

[47] HUANG Z H, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1508.01991.

[48] XU Y X, HUANG H Y, FENG C, et al. A supervised multi-head self-attention network for nested named entity recognition[C]//Proceedings of the 35th AAAI Conference on Artificial Intelligence, the 33rd Conference on Innovative Applications of Artificial Intelligence, the 11th Symposium on Educational Advances in Artificial Intelligence, Feb 2-9, 2021. Menlo Park: AAAI, 2021: 14185-14193.

[49] ZHANG Y, YANG J. Chinese NER using lattice LSTM[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, Melbourne, Jul 15-20, 2018. Stroudsburg: ACL, 2018: 1554-1564.

[50] LIU W, XU T G, XU Q H, et al. An encoding strategy based word-character LSTM for Chinese NER[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis, Jun 2-7, 2019. Stroudsburg: ACL, 2019: 2379-2389.

[51] MA R T, PENG M L, ZHANG Q, et al. Simplify the usage of lexicon in Chinese NER[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Jul 5-10, 2020. Stroudsburg: ACL, 2020: 5951-5960.

[52] CETOLI A, BRAGAGLIA S, O'HARNEY A D, et al. Graph convolutional networks for named entity recognition

中国知网 https://www.cnki.net

[C]//Proceedings of the 16th International Workshop on Treebanks and Linguistic Theories, Prague, Jan 23-24, 2018. Stroudsburg: ACL, 2018: 37-45.

[53] SUI D, CHEN Y, LIU K, et al. Leverage lexical knowlege for Chinese named entity recognition via collaborative graph network[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hongkong, China, Nov 3-7, 2019. Stroudsburg: ACL, 2019: 3821-3831.

[54] GUI T, ZOU Y C, ZHANG Q, et al. A lexicon-based graph neural network for Chinese NER[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hongkong, China, Nov 3-7, 2019. Stroudsburg: ACL, 2019: 1040-1050.

[55] TANG Z, WAN B, YANG L. Word-character graph convolution network for Chinese named entity recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 1520-1532.

[56] KOROTEEV M V. BERT: a review of applications in natural language processing and understanding[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2103.11943.

[57] 陈娜, 孙艳秋, 燕燕. 结合注意力机制的BERT-BiGRU-CRF中文电子病历命名实体识别[J]. 小型微型计算机系统, 2023, 44(8): 1680-1685.
CHEN N, SUN Y Q, YAN Y. Named entity recognition for Chinese electronic medical record based on BERT-BIGRU-CRF and attention mechanism[J]. Journal of Chinese Computer Systems, 2023, 44(8): 1680-1685.

[58] 陈观林, 程钊, 邹凌, 等. 基于BERT的危险化学品命名实体识别模型[J]. 广西科学, 2023, 30(1): 43-51.
CHEN G L, CHENG Z, ZOU L, et al. Identification model of named entities for hazardous chemicals based on BERT [J]. Guangxi Science, 2023, 30(1): 43-51.

[59] 马英.《危险化学品目录(2015版)》即将实施[J]. 石油化工, 2015, 44(4): 488.
MA Y. Inventory of hazardous chemicals (2015)[J]. Petrochemical Technology, 2015, 44(4): 488.

[60] 杨盈, 邱芹军, 谢忠, 等. 人在回路学习增强的地理命名实体识别[J]. 测绘通报, 2023(8): 155-160.
YANG Y, QIU Q J, XIE Z, et al. Geographical named entity recognition based on human-in-the-loop learning enhancement[J]. Bulletin of Surveying and Mapping, 2023(8): 155-160.

[61] 李代祎, 张笑文, 严丽. 一种基于异构图网络的多模态实体识别方法[J/OL]. 小型微型计算机系统 [2024-05-23]. http://kns.cnki.net/kcms/detail/21.1106.TP.20230711.1048.002.html.
LI D Y, ZHANG X W, YAN L. A multimodal name entity recognition method based on heterogeneous graph network [J/OL]. Journal of Chinese Computer Systems [2024-05-23]. http://kns.cnki.net/kcms/detail/21.1106.TP.20230711.1048.002.html.

[62] AGRAWAL A, TRIPATHI S, VARDHAN M, et al. BERT-based transfer-learning approach for nested named-entity recognition using joint labeling[J]. Applied Sciences, 2022, 12(3): 976.

[63] LIU Y, OTT M, GOYAL N, et al. RoBERTa：a robustly optimized BERT pretraining approach[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1907.11692.

[64] LAN Z, CHEN M, GOODMAN S, et al. ALBERT: a lite BERT for self-supervised learning of language representations[C]//Proceedings of the 2020 International Conference on Learning Representations, Addis Ababa, Apr 26-30, 2020.

[65] JIAO X, YIN Y, SHANG L, et al. TinyBERT: distilling BERT for natural language understanding[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, Nov 16-20, 2020. Stroudsburg: ACL, 2020: 4163-4174.

[66] JOSHI M, CHEN D, LIU Y, et al. SpanBERT: improving pre-training by representing and predicting spans[J]. Transactions of the Association for Computational Linguistics, 2020, 8: 64-77.

[67] ZHANG Z, HAN X, LIU Z, et al. ERNIE: enhanced language representation with informative entities[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1905.07129.

[68] 贾李睿智, 刘胜全, 刘源, 等. 基于分层ERNIE模型的中文嵌套命名实体识别[J]. 东北师大学报(自然科学版), 2023, 55(1): 97-103.
JIALI R Z, LIU S Q, LIU Y, et al. Chinese nested named entity recognition based on layered ERNIE model[J]. Journal of North east Normal University (Natural Science Edition), 2023, 55(1): 97-103.

[69] 王刘坤, 李功权. 基于GeoERNIE-BiLSTM-Attention-CRF模型的地质命名实体识别[J]. 地质科学, 2023, 58(3): 1164-1177.
WANG L K, LI G Q. Geological named entity recognition based on GeoERNIE-BiLSTM-Attention-CRF model[J]. Chinese Journal of Geology, 2023, 58(3): 1164-1177.

[70] 罗峦, 夏骄雄. 融合ERNIE与改进Transformer的中文NER模型[J]. 计算机技术与发展, 2022, 32(10): 120-125.
LUO L, XIA J X. Research on Chinese named entity recognition combining ERNIE with improved Transformer[J].

中国知网 https://www.cnki.net

Computer Technology and Development, 2022, 32(10): 120-125.

[71] WANG Y, SUN Y, MA Z, et al. An ERNIE-based joint model for Chinese named entity recognition[J]. Applied Sciences, 2020, 10(16): 5711.

[72] LIU X, ZHENG Y, DU Z, et al. GPT understands, too[J/OL]. AI Open [2024-05-23]. https://doi.org/10.1016/j.aiopen.2023.08.012.

[73] RADFORD A. Improving language understanding by generative pre-training[EB/OL]. [2024-05-23]. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.

[74] QU Y, LIU P, SONG W, et al. A text generation and prediction system: pre-training on new corpora using BERT and GPT-2[C]//Proceedings of the 2020 IEEE 10th International Conference on Electronics Information and Emergency Communication. Piscataway: IEEE, 2020: 323-326.

[75] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems 33, Dec 6-12, 2020: 1877-1901.

[76] LI J, ZHOU Y, JIANG X, et al. Are synthetic clinical notes useful for real natural language processing tasks: a case study on clinical entity recognition[J]. Journal of the American Medical Informatics Association, 2021, 28(10): 2193-2201.

[77] 鲍彤, 章成志. ChatGPT中文信息抽取能力测评——以三种典型的抽取任务为例[J]. 数据分析与知识发现, 2023, 7(9): 1-11.
BAO T, ZHANG C Z. Extracting Chinese information with ChatGPT: an empirical study by three typical tasks[J]. Data Analysis and Knowledge Discovery, 2023, 7(9): 1-11.

[78] HU Y, MAI G, CUNDY C, et al. Geo-knowledge-guided GPT models improve the extraction of location descriptions from disaster-related social media messages[J]. International Journal of Geographical Information Science, 2023, 37(11): 2289-2318.

[79] HU Y, CHEN Q, DU J, et al. Improving large language models for clinical named entity recognition via prompt engineering[J/OL]. Journal of the American Medical Informatics Association [2024-05-23]. https://doi.org/10.1093/jamia/ocad259.

[80] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2302.13971.

[81] TOUVRON H, MARTIN L, STONE K, et al. LLaMA 2: open foundation and fine-tuned chat models[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2307.09288.

[82] YOON J, GUPTA A, ANUMANCHIPALLI G. Is bigger edit batch size always better?—an empirical study on model editing with LLaMA-3[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2405.00664.

[83] KELOTH V K, HU Y, XIE Q, et al. Advancing entity recognition in biomedicine via instruction tuning of large language models[J]. Bioinformatics, 2024, 40(4).

[84] DE-FITERO-DOMINGUEZ D, GARCIA-LOPEZ E, GARCIA-CABOT A, et al. Distractor generation through text-to-text transformer models[J]. IEEE Access, 2024, 12: 25580-25589.

[85] PIRES T, SCHLINGER E, GARRETTE D. How multilingual is multilingual BERT[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1906.01502.

[86] SCHWENK H, LI X. A corpus for multilingual document classification in eight languages[EB/OL]. [2024-05-23]. https://arxiv.org/abs/1805.09821.

[87] CHOURE A A, ADHAO R B, PACHGHARE V K. NER in Hindi language using transformer model: XLM-RoBERTa [C]//Proceedings of the 2022 IEEE International Conference on Blockchain and Distributed Systems Security. Piscataway: IEEE, 2022: 1-5.

[88] LIU C L, HSU T Y, CHUANG Y S, et al. A study of cross-lingual ability and language-specific information in multilingual BERT[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2004.09205.

[89] 徐月梅, 曹晗, 王文清, 等. 跨语言情感分析研究综述[J]. 数据分析与知识发现, 2023, 7(1): 1-21.
XU Y M, CAO H, WANG W Q, et al. Cross-lingual sentiment analysis: a survey[J]. Data Analysis and Knowledge Discovery, 2023, 7(1): 1-21.

[90] MOEZZI S A R, GHAEDI A, RAHMANIAN M, et al. Application of deep learning in generating structured radiology reports: a transformer-based technique[J]. Journal of Digital Imaging, 2023, 36(1): 80-90.

[91] JI L, YAN D, CHENG Z, et al. Improving unified named entity recognition by incorporating mention relevance[J]. Neural Computing and Applications, 2023, 35(30): 22223-22234.

[92] CUI L, WU Y, LIU J, et al. Template-based named entity recognition using BART[EB/OL]. [2024-05-23]. https://arxiv.org/abs/2106.01760.

[93] DU H, XU J, DU Z, et al. MF-MNER: multi-models fusion for MNER in Chinese clinical electronic medical records [J]. Interdisciplinary Sciences: Computational Life Sciences, 2024, 16: 489-502.

[94] ANG Z, DAI Z, YANG Y, et al. XLNET: generalized autore-

中国知网 https://www.cnki.net

gressive pretraining for language understanding[C]//Advances in Neural Information Processing Systems 32, Vancouver, Dec 8-14, 2019: 5754-5764.

[95] 姚贵斌, 张起贵. 基于XLnet语言模型的中文命名实体识别[J]. 计算机工程与应用, 2021, 57(18): 156-162.
YAO G B, ZHANG Q G. Chinese named entity recognition based on XLnet language model[J]. Computer Engineering and Applications, 2021, 57(18): 156-162.

[96] 沈宙锋, 苏前敏, 郭晶磊. 基于XLNet-BiLSTM的中文电子病历命名实体识别方法[J]. 智能计算机与应用, 2021, 11(8): 97-102.
SHEN Z F, SU Q M, GUO J L. Named entity recognition model of Chinese clinical electronic medical record based on XLNet-BiLSTM[J]. Intelligent Computer and Applications, 2021, 11(8): 97-102.

[97] 陈明, 顾凡. 基于XLNet的农业命名实体识别方法[J]. 河北农业大学学报, 2023(4): 111-117.
CHEN M, GU F. Agricultural named entity recognition method based on XLNet[J]. Journal of Hebei Agricultural University, 2023(4): 111-117.

[98] YAN R, JIANG X, DANG D. Named entity recognition by using XLNet-BiLSTM-CRF[J]. Neural Processing Letters, 2021, 53(5): 3339-3356.

[99] CHAI Z, JIN H, SHI S, et al. Noise reduction learning based on XLNet-CRF for biomedical named entity recognition[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2022, 20(1): 595-605.

[100] CHAI Z, JIN H, SHI S, et al. Hierarchical shared transfer learning for biomedical named entity recognition[J]. BMC Bioinformatics, 2022, 23: 1-14.

梁佳(2000—),女,内蒙古赤峰人,硕士研究生,CCF学生会员,主要研究方向为知识图谱、教育数据挖掘。
LIANG Jia, born in 2000, M.S. candidate, CCF student member. Her research interests include knowledge graph and educational data mining.

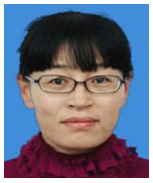

张丽萍(1974—),女,内蒙古呼和浩特人,硕士,教授,主要研究方向为软件工程、教育数据挖掘。
ZHANG Liping, born in 1974, M.S., professor. Her research interests include software engineering and educational data mining.

闫盛(1984—),男,内蒙古包头人,硕士,讲师,主要研究方向为计算机教育应用。
YAN Sheng, born in 1984, M.S., lecturer. His research interest is computer education applications.

赵宇博(1999—),男,内蒙古赤峰人,硕士研究生,主要研究方向为知识图谱、教育数据挖掘。
ZHAO Yubo, born in 1999, M.S. candidate. His research interests include knowledge graph and educational data mining.

张雅雯(1998—),女,内蒙古阿拉善人,硕士研究生,主要研究方向为教育数据挖掘、代码分析。
ZHANG Yawen, born in 1998, M.S. candidate. Her research interests include educational data mining and code analysis.

中国知网　https://www.cnki.net