测绘学报 2025 年 第 54 卷 第 10 期:1001—1595
Acta Geodaetica et Cartographica Sinica xb.chinasmp.com
中国测绘学会 Chinese Society for Geodesy Photogrammetry and Cartography
测绘出版社 SURVEYING AND MAPPING PRESS

# 智能驱动的并行地理计算引擎框架

高 凡[1],路 威[1],甘麟露[1],章 繁[1],荣凤娟[1],汤士涵[2]

1. 陆军工程大学通信工程学院,江苏 南京 210007;
2. 南京师范大学地理科学学院,江苏 南京 210023

收稿日期:2025-03-24;修回日期:2025-08-24 中图分类号:P208 文献标识码:A
文章编号:1001-1595(2025)10-1877-16
基金项目:国家自然科学基金(42301489);江苏省自然科学基金(BK20231030)
第一作者简介:高凡(1994—),男,博士,讲师,研究方向为高性能地理计算和地理边缘计算。 E-mail:fgao@aeu.edu.cn
通信作者:路威 E-mail:wlu@aeu.edu.cn

**摘 要**:地理空间计算特征的捕捉与强度预测是高性能地理计算领域中的核心问题,也是智能计算范式下的关键。经验知识驱动的研究范式存在难推广、难建模、低精度的问题,易造成负载失衡和资源浪费。因此,本文以"智"驱"计",整合地理计算元智能、感知智能、认知智能,提出一种智能驱动的并行地理计算引擎框架。在元智能层级,从形态结构、集合数量、空间分布和拓扑关联特征出发,构建了通用的地理空间计算域特征表达空间。在感知智能层级,引入定制化的机器学习和深度学习模型,支持地理空间域计算强度自动感知。在认知智能层级,提出了结合大强度任务优先和任务窃取的自适应动态调度策略。以多边形空间相交和可视域分析为例,验证了智能化并行地理计算引擎框架的可行性和高效性,结果表明本文方法在负载均衡性能上提升了 20 倍以上。

**关键词**:地理计算;智能计算;空间计算特征;空间计算强度;负载均衡

随着知识图谱、大语言模型和生成式人工智能等技术的发展,人类社会正加速向智能化时代迈进。然而,作为智能社会发展关键驱动力的计算资源,仍面临着资源稀缺和利用不足等挑战[1]。近年,智能社会的发展催生了一种全新的计算范式——智能计算[2-4]。不同于云计算、边缘计算、雾计算等技术,智能驱动的计算不仅强调计算性能的提升,更致力于通过机器智能感知数据、算法、算力的内在特征和联系,认知和推导任务需求与计算资源的最佳匹配,在减少人为干预的情况下以最低成本完成计算任务。智能驱动的计算范式在现有技术的基础上,融入了感知、认知、自主等理念,能够在有限的计算资源下实现大规模计算。DeepSeek 大模型近期取得的成功,正是其对模型架构和数据集参数等计算特征开展充分分析,对需求、任务与资源进行合理匹配,突破了大模型研究中的计算资源瓶颈问题[5]。智能驱动的计算范式在现有技术的基础上,融入了感知、认知、自主等理念,能够在有限的计算资源下实现大规模计算,为人类社会向智能化转型升级提供支撑。

然而,作为智能社会构建的时空基底,地理信息数据不仅具备信息领域中数据常规的海量、异构、异源等特性,还呈现出分布不均、结构杂乱、计算依赖的强异质性和关联性特点[6-8],这给地理计算特征建模带来了挑战。在地理空间计算域理论中[9-10],地理空间域被定义为一组具有不同计算强度的空间计算单元,计算单元通过不同的分解策略生成,如空间对象划分(decomposition based on object,

引文格式:高凡,路威,甘麟露,等.智能驱动的并行地理计算引擎框架[J].测绘学报,2025,54(10):1877-1892. DOI:10.11947/j.AGCS.2025.20250127.
GAO Fan, LU Wei, GAN Linlu, et al. An intelligent parallel geocomputation engine framework[J]. Acta Geodaetica et Cartographica Sinica,2025,54(10):1877-1892. DOI:10.11947/j.AGCS.2025.20250127.

中国知网 https://www.cnki.net

DBO)、空间网格划分(decomposition based on spatial grid,DSG)、空间索引划分(decomposition based on spatial index,DSI)、聚类特征划分(decomposition based on clustering feature,DCF)、图划分(decomposition based on graph,DBG)[11-15]。空间计算单元的计算强度被用于描述计算节点上承受的负载大小,受到数据、算法和硬件等多模态特征影响。基于该理论,高性能地理计算领域学者开展了大量关于计算特征建模方面的工作[16-19]。然而,这些工作普遍从经验知识驱动的研究范式出发,即完全基于经验知识捕捉数据和算法特征,从理论公式出发构建计算强度评估模型,存在难推广、难建模、低精度的问题,易造成任务调度负载失衡和资源浪费。

为克服经验知识驱动范式的不足,部分研究转向于基于动态调度的替代策略上[20-21]。动态调度旨在优化空间任务执行过程中的计算资源分配,当前主流的方法可分为两类:基于协调者-工作者的方法[22]和基于去中心化的方法[23]。前者采用集中控制机制来管理任务队列和资源分配,后者则通过任务重分配机制,使空闲进程协助过载进程完成任务执行。然而,这两类方法都对任务分解粒度极度敏感。粗粒度任务仍会导致负载失衡或高额的通信代价,细粒度任务虽然可以提升负载均衡性能,但会带来额外的划分和通信代价。因此,如何根据计算强度优化任务分解粒度又成为了动态调度中的关键问题。可见,地理计算特征和强度建模仍是实现高效并行地理计算的关键因素。

在智能计算范式中,智能被分为了经验知识驱动的元智能、赋能机器的数据智能、感知智能、认知智能和自主智能5个级别。元智能以人为核心,强调人类与生俱来的智慧;数据智能表达了机器具备的公式化存算能力;感知智能则赋予了机器数据获取、融合、提取的能力;认知智能进一步使得机器具备理解、思考、推理的能力;自主智能则是指机器具备类人脑的总结、应用和决策能力。在并行地理计算中,任务的计算特征捕捉、计算强度评估及调度是3个主要阶段。其中,感知智能可赋予机器自动学习地理计算特征并预测任务计算强度的能力。在任务调度阶段,认知智能则可使得机器通过对任务计算强度和可用计算资源的理解,推理最佳的任务分解和调度策略。据此,本文依托于智能计算范式,通过整合地理计算元智能、感知智能和认知智能,提出了一种智能驱动的并行地理计算引擎框架。在元智能层级,基于地理空间计算域的数据构成、分解粒度、计算依赖,从形态结构、集合数量、空间分布和拓扑关联特征出发,构建了通用的地理空间计算域特征表达空间。在感知智能层级,面向不同类型地理空间计算域,基于机器学习、深度学习卷积神经网络和图神经网络,设计了适应不同数据图层、数据类型、数据划分的地理空间计算域计算强度感知器。在认知智能层级,通过结合计算强度感知和在线任务窃取,实现了地理计算任务的自适应均衡调度。

## 1 地理空间计算流理论

复杂地学任务过程通常由一系列空间计算算法构成,即地理科学工作流。工作流中每一个环节的地理空间计算域都存在差异,体现在数据结构、空间特征、计算强度等。本文在地理空间计算域理论基础上,通过进一步融入工作流、特征挖掘、计算强度评估,提出了地理空间计算流理论。该理论将复杂的地学计算过程抽象为一个有序计算节点序列,该序列中的节点依据其计算依赖特性可划分为可并行化计算节点与非并行化计算节点两类。对于可并行化节点,其地理空间计算域特征由以下3个维度的属性协同作用共同定义。①数据构成:表征计算域内数据的组织形态,区分单一图层和复合图层;②计算依赖:定义计算单元(像素、要素、网络节点)之间的信息交互特点,包含本地、邻域、区域和全局型依赖;③计算异质因子:描述计算域内不同空间子区域执行相同计算操作时潜在负载差异的根源,由空间数据结构、集合数量、空间分布和拓扑特性影响。将上述多维计算域属性(特征空间)映射到具体计算强度(目标变量)本质上构成一个回归建模问题。实现此映射可采用理论公式建模、机器学习回归或神经网络回归方法。地理空间计算流理论适用于包含可数据并行或可任务并行计算节点的地理空间计算流程,该理论可为地理空间计算强度的形式化建模、并行地理计算任务的分解决策与优化调度提供理论基础。如图1所示,计算流上节点和地理空间计算域一一对应,每层地理空间计算域由若干层任务域和数据域构成,可表达为

$$F(I)=F_1(I_1)\times F_2(I_2)\times\cdots\times F_n(I_n)=F_1(I_1)\times F_2(O_1)\times\cdots\times F_n(O_{n-1}) \quad (1)$$

式中,$F$ 为地理空间计算流空间计算域上的任务域,由地理空间计算流各层任务域$\{F_1,F_2,\cdots,F_n\}$按顺序构成,“×”代表任务执行顺序。数据域区分输入和输出,$I$ 为输入数据域,$O$ 为输出数据域,第 $i$

中国知网 https://www.cnki.net

层任务域 $F_i$ 的输入域 $I_i$ 是上一层任务域 $F_{i-1}$ 的输出域 $O_{i-1}$。

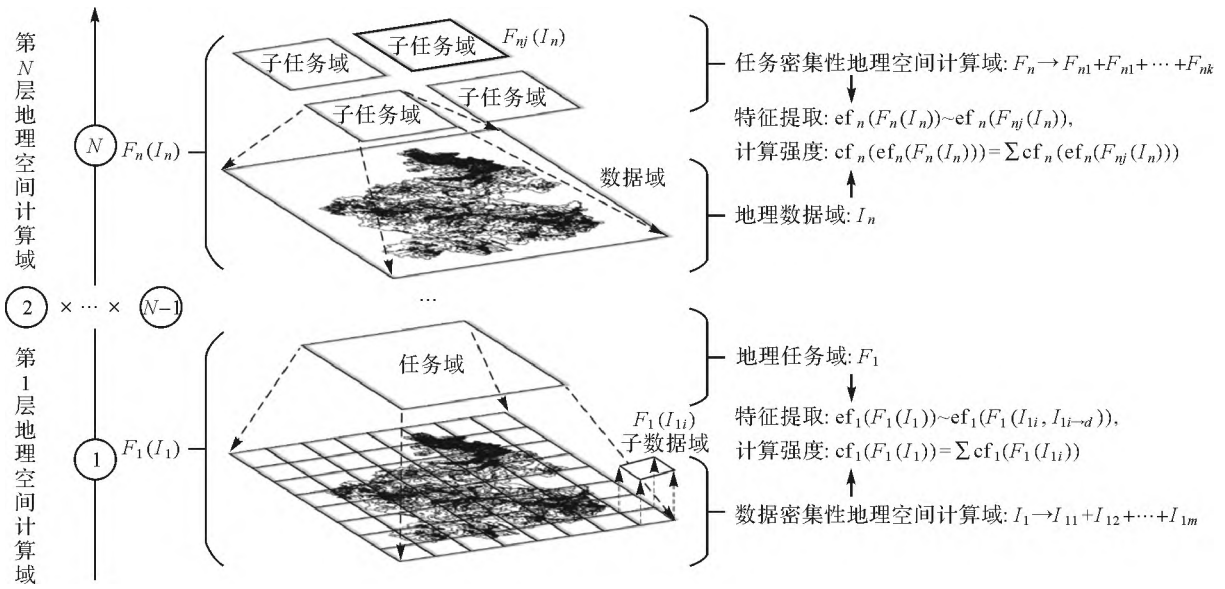


图 1　地理空间计算流理论

Fig. 1　Spatial computational workflow domain

根据数据和任务中心性，地理空间计算流空间计算域中每一层地理空间计算域区分数据密集型和任务密集型。针对数据密集型地理空间计算域，不同层数据域可根据计算依赖特点采用不同分解策略，如 DBO、DSG、DSI、DCF 和 DBG。数据密集型地理空间计算域的分解可表达为

$$F_i(I_i)\xrightarrow{D}F_i(I_{i1}+I_{i2}+\cdots+I_{im})=\mathrm{Aggr}\{F_i(I_{i1},I_{i1\rightarrow d}),F_i(I_{i2},I_{i2\rightarrow d}),\cdots,F_i(I_{im},I_{im\rightarrow d})\}$$
$$i\in[1,n],D\in\{\mathrm{DBO},\mathrm{DSG},\mathrm{DSI},\mathrm{DCF},\mathrm{DBG}\} \tag{2}$$

式中，$F_i(I_i)$ 为计算流中第 $i$ 层地理空间计算域；$I_{im}$ 为经过数据分解策略 $D$ 划分产生的第 $m$ 个子数据域；“+”根据数据分解策略可分为代数合并、空间合并、时间合并等；Aggr 函数表示对子域计算结果做聚合操作。根据计算过程中依赖特性，地理计算可划分为本地依赖、邻域依赖、区域依赖和全局依赖，式中 $I_{ij\rightarrow d}$ 即表示子域 $I_{ij}$ 的计算依赖域（$j\in[1,m]$）。

在地理空间计算域特征提取过程中，同一层域中子域的特征选用是相同的，因此面向该层地理空间计算域提取特征等价于面向子域提取特征。地理空间计算域特征提取可表达为

$$\mathrm{ef}_i(F_i(I_i))\sim\mathrm{ef}_i(F_i(I_{ij},I_{ij\rightarrow d})):F_i(I_{ij},I_{ij\rightarrow d})\rightarrow\boldsymbol{E}$$
$$i\in[1,n],j\in[1,m],\mathrm{ef}_i\in\{\mathrm{ExFE},\mathrm{MLFS},\mathrm{CNNFL},\mathrm{GNNFL}\} \tag{3}$$

式中，$\mathrm{ef}_i$ 为第 $i$ 层地理空间计算域特征提取函数；$I_{ij}$ 为第 $i$ 层地理空间计算域的第 $j$ 个子数据域；$I_{ij\rightarrow d}$ 为子域 $I_{ij}$ 的计算依赖域；$\boldsymbol{E}$ 为提取的特征向量。本文共总结了 4 种特征提取方法，包括经验提取（experience-based feature extraction，ExFE）、机器学习特征选择（machine learning feature selection，MLFS）、卷积神经网络特征学习（convolutional neural network feature learning，CNNFL）、图神经网络特征学习（graph neural network feature learning，GNNFL）。4 种特征提取方法在自动化程度、自身代价及精度方面都有所不同，在选用上需要结合每一层地理空间计算域的计算代价和异质性特点。在特征提取基础上，可进一步得到计算强度表达式

$$\mathrm{cf}_i(\mathrm{ef}_i(F_i(I_i))=\sum_{j=1}^{m}\mathrm{cf}_i(\mathrm{ef}_i(F_i(I_{ij}))=\sum_{j=1}^{m}\mathrm{cf}_i(\mathrm{ef}_i(F_i(I_{ij},I_{ij\rightarrow d}))$$
$$\mathrm{cf}_i\in\{\mathrm{EFE},\mathrm{MLE},\mathrm{NNE}\} \tag{4}$$

式中，$\mathrm{cf}_i$ 为第 $i$ 层地理空间计算域的计算强度。本文共总结了 3 种计算强度评估方法，包括经验公式评估（empirical formula evaluation，EFE）、机器学习评估（machine learning evaluation，MLE）、神经网络评估（neural network evaluation，NNE）。

任务密集型地理空间计算域可根据任务特性划分，其地理空间计算域的分解可表达为

$$F_i(I_i)\xrightarrow{T}(F_{i1}+F_{i2}+\cdots+F_{ik})I_i=\mathrm{Aggr}\{F_{i1}(I_i),F_{i2}(I_i),\cdots,F_{ik}(I_i)\}\quad i\in[1,n] \tag{5}$$

式中，$F_i(I_i)$ 为第 $i$ 层地理空间计算域；$F_{ik}$ 为经过

中国知网　https://www.cnki.net

任务分解策略 $T$ 划分产生的第 $k$ 个子任务域，这里的“+”为任务关系和；Aggr 函数表示对子域计算结果做聚合操作。同数据密集型相似，任务密集型地理空间计算域特征提取只需面向子任务域，即

$$\mathrm{ef}_i(F_i(I_i)) \sim \mathrm{ef}_i(F_{ij}(I_i)) : F_{ij}(I_i) \rightarrow \boldsymbol{E}$$
$$i \in [1,n], j \in [1,k], \mathrm{ef}_i \in \{\mathrm{ExFE}, \mathrm{MLFS}, \mathrm{CNNFL}, \mathrm{GNNFL}\} \quad (6)$$

式中，$F_{ij}$ 为第 $i$ 层地理空间计算域的第 $j$ 个子任务域。特征提取方法同样可采用经验提取、机器学习特征选择、卷积神经网络学习、图神经网络学习。对应计算强度评估可表达为

$$\mathrm{cf}_i(\mathrm{ef}_i(F_i(I_i)) = \mathrm{cf}_i(\mathrm{ef}_i(F_{i1}(I_i))) + \mathrm{cf}_i(\mathrm{ef}_i(F_{i2}(I_i))) + \cdots + \mathrm{cf}_i(\mathrm{ef}_i(F_{ik}(I_i)))$$
$$\mathrm{cf}_i \in \{\mathrm{EFE}, \mathrm{MLE}, \mathrm{NNE}\} \quad (7)$$

式中，“+”为代数和，即第 $i$ 层地理空间计算域的计算强度为子任务域计算强度之和。

## 2 智能地理计算引擎框架

智能地理计算引擎框架以地理空间计算流理论为基础，融入了元智能、感知智能、认知智能，其架构如图 2 所示。其中，元智能层级的地理空间计算域特征表示可用于经验知识驱动的方法，并作为机器学习方法的候选特征。位于智能感知层级的地理空间计算域计算强度预测，为后续地理空间计算域任务组合与调度提供依据。认知智能层级的任务调度结合计算强度及数据智能层级的计算环境，实现智能驱动的地理计算。

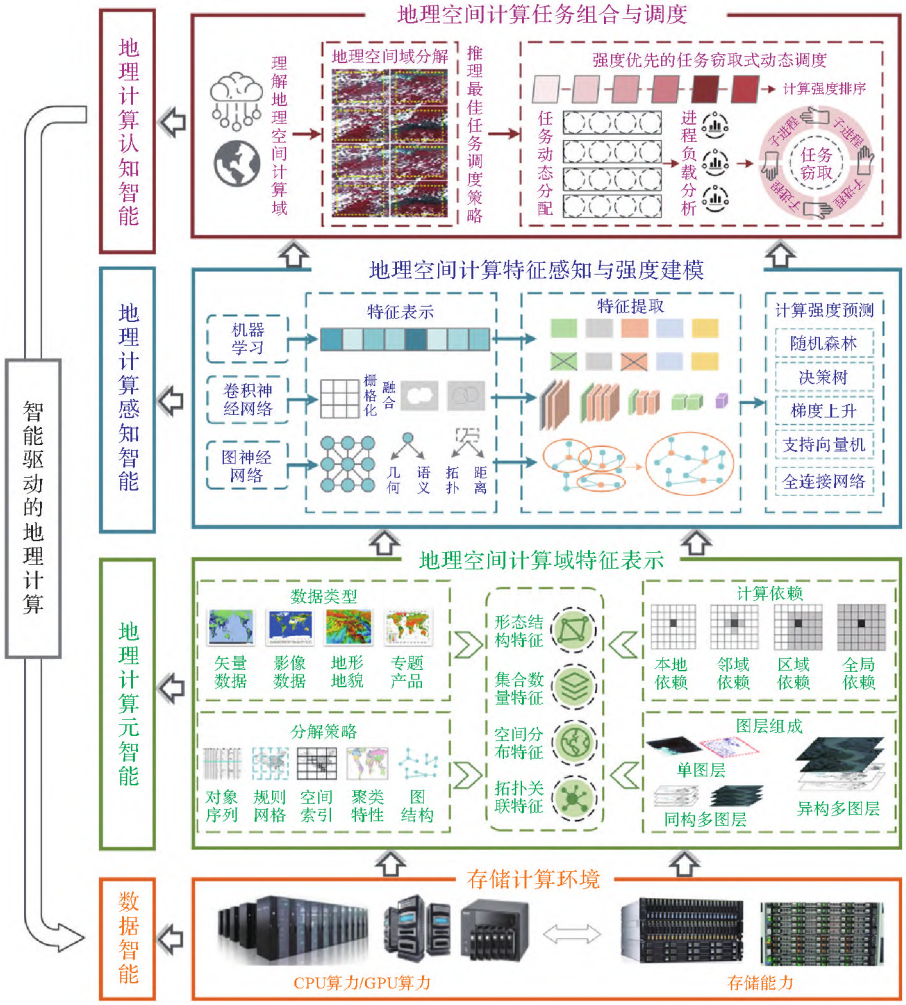


图 2 智能化并行地理计算引擎框架

Fig. 2 The framework of the intelligent parallel geocomputation engine

### 2.1 元智能驱动的地理空间计算特征表示

根据地理空间计算域数据类型（如矢量、栅格）、图层结构（如单图层、多图层）、计算依赖（如本地、邻域、区域、全局）、分解策略（如对象、网格、索引、聚类、图），本文总结出 4 类关键特征：形态结构特征、集合数量特征、空间分布特征和拓扑关联

中国知网 https://www.cnki.net

特征。

形态结构特征描述了待评估对象内部数据的形态结构特点，可分为基础结构特征和形态分布特征。基础结构特征描述对象内部的基本结构特点，如矢量对象的周长、面积、顶点数量、凹点数量和栅格单元的分辨率、通道及是否参与计算。形态分布特征描述对象内部数据的间接形态特点，如多边形平滑度、凹陷度、规则度、紧凑度、方向。

集合数量特征描述了待评估对象内部的特征统计信息，可分为总量特征、平均特征、最大最小特征。总量特征描述了对象内部特定形态结构特征的数量和，如分解子域空间范围、对象数量、矢量对象面积总和。平均特征描述了对象内部特定形态结构特征的平均数，如分解子域内多边形顶点数量平均、多边形平滑度平均、多边形方向平均。最大特征描述了对象内部特定形态结构特征的最大值，如分解子域内矢量对象周长最大值、多边形紧凑度最大值、凹陷度最大值。集合数量特征在形态结构特征的基础上，加入了统计信息。

空间分布特征描述了待评估对象的聚集、离散、相关性等分布规律，可分为常规度量性特征和分布相关性特征。常规度量性特征包括分布密度、方差、标准差、极差等，分布相关性描述的是分解子域内对象某些属性的自相关特性，如 Moran's I、Geary's C 和 G-statistic。空间分布特征对于蕴含分布规律分析的应用具有重要意义，如在反距离加权插值、克里金插值、多边形相交分析中，数据分布的密集程度明显影响计算代价。

拓扑关联特征描述了空间对象之间的拓扑关联关系，可分为拓扑特征和关联特征。拓扑特征描述的是空间对象之间的拓扑关系，基于九交模型可得到 6 类特征，包括分解子域内互相包含对数、重叠对数、相等对数、交叉对数、相离对数和相接对数。关联特征描述的是基于其他关系相关联后获取的特征，一般可利用图表示。如，图节点代表地理空间对象，边代表关联关系，这种关系可以基于距离相关属性，还可以基于其他属性相关联。基于关联关系可以得到分解子域内关联对数特征，同时还可以得到关联关系特征，如分解子域内距离总和。拓扑关联特征相较其他 3 类特征，计算代价整体偏高，但在一些计算密集的应用分析中（如矢量相交），拓扑关联特征是表征异质性的关键因素，可以有效提升整体计算性能。

## 2.2　感知智能驱动的地理空间计算强度预测

智能化并行地理计算引擎框架共提供 3 种基于机器智能的地理空间计算特征和强度建模方式（图 3），包括：①基于机器学习的地理空间计算特征选择与强度建模；②基于卷积神经网络的地理空间计算特征选择与强度建模；③基于图神经网络的地理空间计算特征选择与强度建模。然而，感知智能驱动的地理空间计算强度预测不仅限于这 3 种模式，本文主要聚焦于提供一个支持地理计算强度智能化预测（替代经验知识）的通用范式。

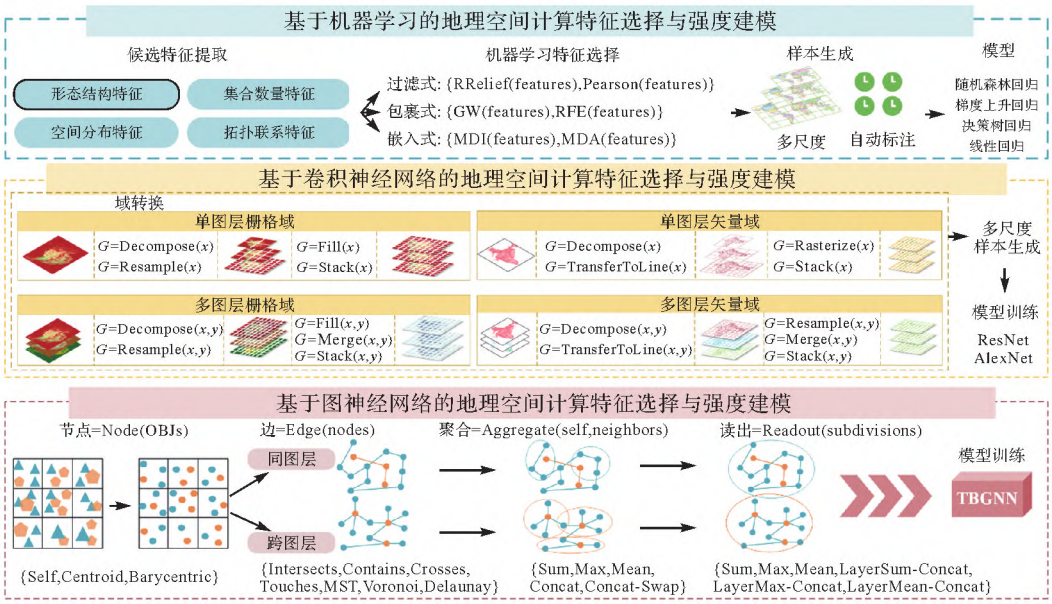


图 3　基于机器智能的地理空间计算特征和强度建模

Fig. 3　Spatial computational feature and intensity modeling based on machine intelligence

中国知网　https://www.cnki.net

#### 2.2.1 基于机器学习的特征选择和计算强度建模

基于机器学习的特征选择和计算强度建模模式主要包含4个阶段:候选特征提取、特征选择、样本生成及模型训练。首先,从地理空间域计算特征表达空间中选取候选特征,选取过程中根据算法计算依赖、分解策略、数据构成,按照应选尽选的原则,分别从形态结构特征、集合数量特征、空间分布特征和拓扑关联特征中粗略选择若干特征。然后,对比使用不同机器学习特征选择方法,包括过滤选择、包裹选择和嵌入选择。其中,过滤选择通过定义相关性函数来评价特征集合精度,如RRelief和Pearson算法。包裹选择和嵌入选择则通过结合回归模型来评价特征集合精度。包裹选择算法包括遗传包裹(genetic wrapper,GW)、递归特征消除(recursive feature elimination,RFW);嵌入选择算法包括平均纯度降低(mean decrease in impurity,MDI)和平均精度降低(mean decrease in accuracy,MDA)。最后,可通过对比特征子集在评价模型或函数中的精度,得到最优精选特征子集。在样本生成中,为了获得不同尺度特征,使用多种粒度大小网格对地理空间计算域进行划分。生成样本后,可分别使用线性回归、决策树回归、随机森林回归、梯度上升回归等方法,训练计算强度预测模型。

#### 2.2.2 基于卷积神经网络的特征学习和计算强度建模

基于卷积神经网络特征学习和计算强度建模,关键是如何将地理空间计算域转换为卷积神经网络输入形式。如图3所示,图中$G$代表一系列面向地理空间域的操作函数,当参数仅有$x$代表为单图层,当参数为$x$和$y$则代表面向不同图层。针对单图层地理空间栅格计算域,首先通过域分解操作(Decompose)得到分解子域,然后对分解子域分别执行重采样(Resample)、堆叠(Stack)和填充(Fill)操作,得到指定{高度×宽度×深度}的样本。针对多图层地理空间栅格计算域,每个图层可采用与单图层地理空间栅格计算域同样的操作,然后依次进行融合(Merge)和堆叠得到指定深度的样本。

针对地理空间矢量计算域,对单图层矢量域可先后执行域分解、栅格化(Rasterize)、堆叠操作,得到指定{高度×宽度×深度}的样本。如果矢量域上包含多边形对象,为了保留边界信息,需要在栅格化前执行面转线(TransferToLine)操作。针对多层图矢量域,只需对各图层按单图层转换方式处理后作合并操作。为了区别不同图层数据,需要在栅格化过程中赋予不同图层不同的像素值。随后同样通过堆叠操作得到指定{高度×宽度×深度}的样本。样本生成中,可采用不同的覆盖范围获取不同尺度的样本。最后,在卷积神经网络架构选择上,考虑到模型提取特征及预测计算强度的时间代价,建议使用相对轻量的架构,如ResNet18和AlexNet。

#### 2.2.3 基于图神经网络的特征学习和计算强度建模

基于图神经网络的特征学习和计算强度建模模式提供了若干面向地理空间域的构图方法(即节点和边表示)、聚合操作及读出操作。其中,面向栅格域的图神经网络表示研究较为丰富,然而针对矢量域的图神经网络表示研究则较为缺乏,其原因在于矢量数据结构的不规则性及拓扑关系的复杂性。本文以双图层矢量空间域为例,介绍了如何构图、聚合及读出(图3)。

在构图部分,将每个分解子域表示为一张图,即地理空间计算域上的图可基于序列块、网格块、聚类块或索引块生成。可使用矢量对象编号、重心或质心作为图节点,而边可基于拓扑关系或距离关系生成。拓扑关系包括相交、包含、交叉、相接,距离关系是指使得图上节点之间具有特定距离属性,如最小生成树(Minimum Spanning Tree)、Voronoi图、Delaunay图。拓扑和距离关系既可以面向多图层矢量域生成,也可以在单图层中生成。在多图层中,可基于不同图层对象间关系生成边,在单图层中则可根据图层内的对象关系生成边。聚合和读出是图神经网络模型中的两个关键过程,用于结合邻域节点信息和不同图层信息,如求和(Sum)、最大值(Max)和拼接(Concat)。

### 2.3 认知智能驱动的地理空间计算强度预测

静态调度的负载均衡性能对计算强度评估的准确性较为敏感,当模型预测不够准确时,仍然会导致负载失衡。因此,本文进一步提出了大强度任务优先的窃取式动态调度策略。如图4所示,该策略包含4个步骤。

(1) 将子域$\{T_1,T_2,\cdots,T_n\}$组合为数倍于计算单元数量的分区$\{P_1,P_2,\cdots,P_k\}$,并基于计算强度对分区排序,构成任务队列。其中,高计算强度分区位于队列头部,低计算强度分区位于队列尾部。

(2) 主进程将队列头部的$m$个分区调度到各子进程上执行,各子进程执行完毕后将空闲状态消息发送给主进程,主进程依次从任务队列中取出分区并发送给子进程,直到任务队列为空。

中国知网 https://www.cnki.net

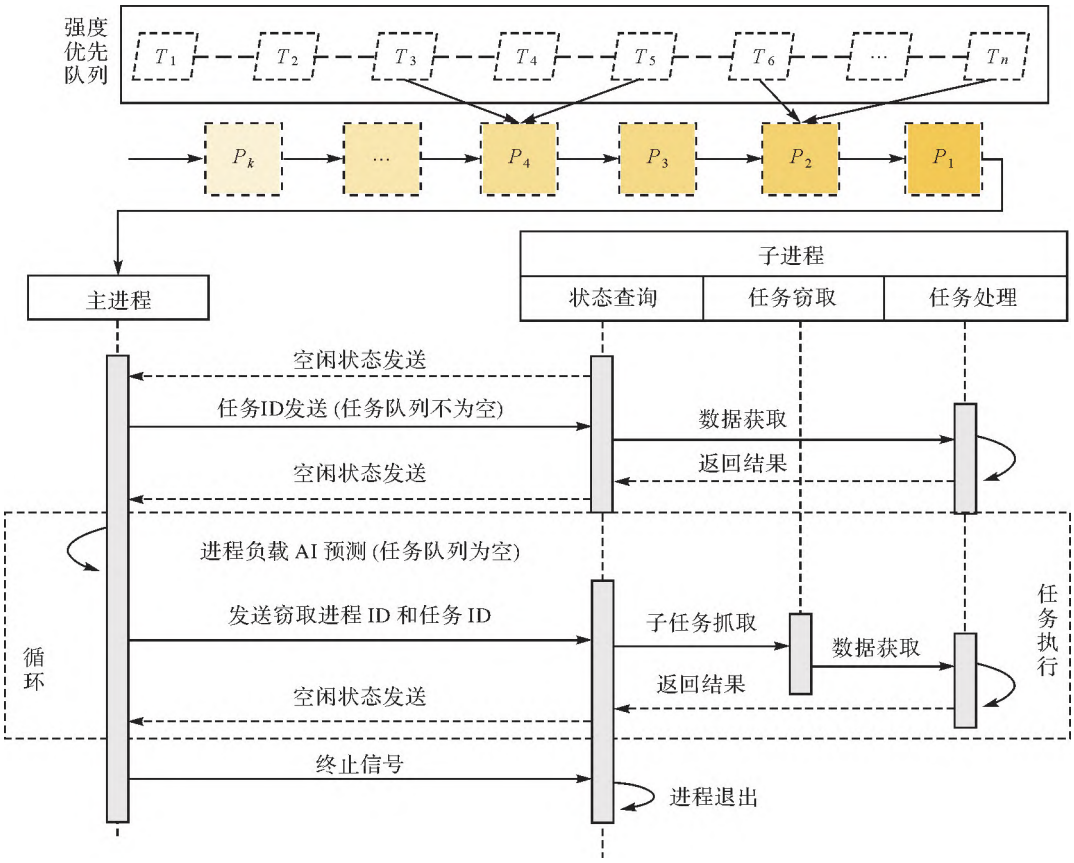


图 4　大强度任务优先的窃取式动态调度策略

Fig. 4　Task stealing incorporating posteriority scheduling for high-computational intensity tasks

(3) 当某个子进程执行完任务队列最后一个分区后，将空闲状态发送给主进程，主进程预测其他忙碌子进程上剩余任务的计算强度。

(4) 主进程确定剩余任务计算强度最大的子进程，并发出任务分裂消息，子进程将对当前执行任务进行均匀分裂操作，并将其中一个分裂任务包含的子域任务 ID 发送给主进程。

(5) 主进程将子域任务 ID 发送给空闲进程，空间进程进行数据抓取并执行任务。

(6) 循环执行步骤(3)—步骤(5)，直到所有子域任务执行完毕。

## 3　试验与结果

### 3.1　多边形空间相交分析

#### 3.1.1　案例与数据介绍

本文以矢量空间相交作为案例，验证智能化并行地理计算引擎框架的可行性和高效性。试验采用了基于空间聚合连接的并行化策略(partition based spatial-merge join，PBSM)[24]，该策略将空间相交分为两阶段：第一阶段(过滤)采用相同的分解策略对两图层矢量数据进行划分；第二阶段(精解)则在分解子域内对两图层数据求交。该策略有效降低了相交分析的时间复杂度，并且支持对两个阶段进行并行化处理。图 5 展示了基于 PBSM 的多边形相交分析的地理空间计算流，包括数据输入、过滤阶段、精解阶段、结果合并 4 个阶段。过滤和精解阶段是典型的不规律异质地理空间计算域，且精解阶段是相交分析中计算最为密集的阶段，本文拟采用 2.2 节中提出的 3 种机器智能方法分别进行计算强度预测模型建模。相对精解阶段，过滤阶段属于弱计算密集阶段，因此本文拟采用经验知识驱动的方法 ExFE 和 EFE 分别提取特征和预测计算强度。选取的特征包括两图层各自多边形数量，计算强度则直接采用两者的乘积。

试验采用了 3 组中国南部某地区的地理图斑与坡度图斑数据，见表 1。其中，数据集 1 包含约 18 万个地理图斑和 18 万个坡度图斑，数据集 2 包含约 31 万个地理图斑和 29 万个坡度图斑，数据集 3 包含约 113 万个地理图斑和 92 万个坡度图斑。相交分析的目的为找到与地理图斑相交面积最大的坡度图斑，并将坡度信息赋值给地理图斑。试验环境

中国知网　https://www.cnki.net

由 9 台电脑搭建的集群构成，其中 1 台电脑型号为联想 T14P，配备 Core i7-13700 处理器，16 GB 内存，20 个内核，用于创建主进程控制逻辑。另外 8 台电脑型号均为联想 E15，配备 Core i7-1165G7 处理器，32 GB 内存，8 个内核，用于创建子进程负责计算。矢量数据读取和求交采用了开源的 GEOS 库，并行化实现采用了消息传递接口库（message passing interface，MPI）。

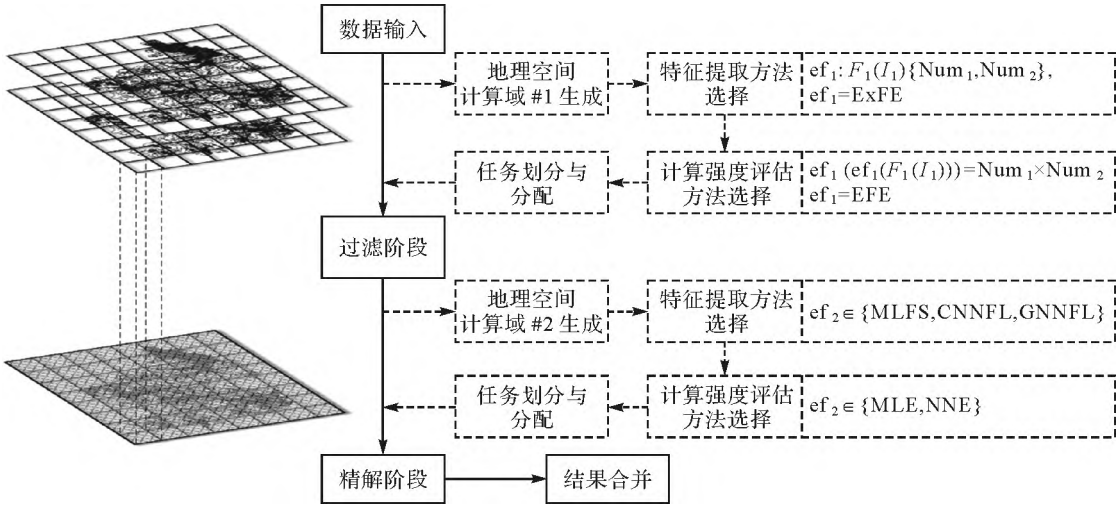


图 5 矢量相交计算流

Fig. 5 The spatial computational workflow domain of spatial intersection

**表 1 3 组试验数据集**

**Tab. 1 Three experimental datasets**

| 数据集 | 地理图斑分布 | 坡度图斑分布 | 地理图斑数量 | 坡度图斑数量 |
|---|---|---|---|---|
| 数据集 1 | | 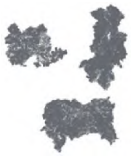 | 188 449 | 184 038 |
| 数据集 2 | 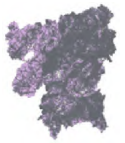 | | 312 989 | 296 986 |
| 数据集 3 | | | 1 138 641 | 926 294 |

### 3.1.2 计算强度预测模型精度

试验分别采用了 8 种模型对精解阶段计算强度进行建模，包括 5 种机器学习模型（随机森林回归、梯度上升回归、决策树回归、线性回归、Lasso 回归）、2 种卷积神经网络（ResNet、AlexNet）及 1 种图神经网络（TBN4SI）。各模型训练样本采用如下步骤生成。

（1）对 3 个数据集分别采用 32×32、64×64、128×128、256×256、512×512 不同尺度网格进行划分，以网格作为样本生成单元，统计每个网格内多边形相交时间作为该网格样本的标签，试验从中随机采样了约 20 万个网格。

（2）针对机器学习模型的训练样本，试验采用的特征包括两图层多边形数量、两图层多边形顶点数量、两图层多边形分布方差、两图层多边形均值中心点距离、参考点数量。

（3）针对卷积神经网络的训练样本，试验对网格内两图层多边形数据依次做了面转线、栅格化（两图层边界像素值分别为 1 和 2）、图层合并（栅格图层相加）操作，每个网格样本对应一张图片。

（4）针对图神经网络的训练样本，试验以网格为单元生成图，TBN4SI 模型中的图以两图层多边形相交关系作为边，节点特征采用面积、周长、顶点数、平滑度、形态指数。

8 种模型的计算强度预测精度见表 2，在机器学习模型中，随机森林回归和梯度上升回归的 $R^2$ 均超过 0.9，MAE、MSE 和 RMSE 分别低于 0.02 s、0.002 $s^2$、0.04 s，而决策树回归、线性回归和 Lasso 回归的精度整体较差。在卷积神经网络模型中，ResNet 模型的 $R^2$ 超过了 0.94，AlexNet 模型的 $R^2$ 则在 0.85 左右，相对较低。在图神经网络模型中，TBN4SI 的 $R^2$ 超过 0.9，整体精度较好。通过上述分析，随机森林回归、梯度上升回归、ResNet、AlexNet、TBN4SI5 个模型精度相对较高，试验将进一步对比 5 个模型在并行化计算中的性能。

中国知网 https://www.cnki.net

表 2　精解阶段计算强度预测模型精度

Tab. 2　Computational intensity prediction accuracy of different models

| 模型 | $R^2$ | MAE/s | MSE/$s^2$ | RMSE/s |
|---|---|---|---|---|
| 随机森林回归 | 0.905 9 | 0.012 3 | 0.001 3 | 0.036 1 |
| 梯度上升回归 | 0.907 1 | 0.012 6 | 0.001 3 | 0.036 1 |
| 决策树回归 | 0.811 4 | 0.017 1 | 0.002 6 | 0.051 0 |
| 线性回归 | 0.761 0 | 0.020 5 | 0.003 3 | 0.057 4 |
| Lasso 回归 | 0.569 7 | 0.184 5 | 0.209 1 | 0.457 2 |
| ResNet | 0.946 9 | 0.008 8 | 0.000 5 | 0.022 3 |
| AlexNet | 0.855 2 | 0.039 1 | 0.003 5 | 0.059 1 |
| TBN4SI | 0.929 0 | 0.021 2 | 0.002 6 | 0.051 0 |

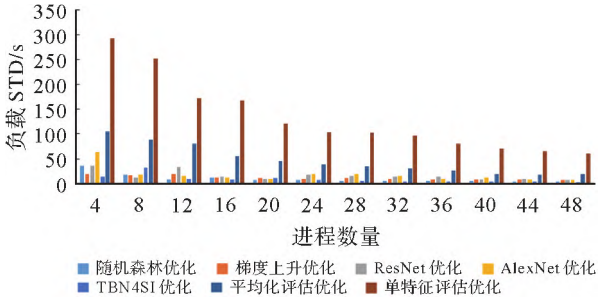


图 6　7 种方法负载均衡性能对比

Fig. 6　Comparison of load balancing performance among seven methods

### 3.1.3　并行计算性能

本文对比了 3.1.2 节中选取的 5 个模型及传统经验驱动方法在并行矢量相交中的性能。传统方法包括基于平均化评估计算强度和单特征评估计算强度的方法，前者假设地理空间计算域上计算强度处处相等，即忽略异质性，后者则直接以某个特征作为计算强度值，试验采用了网格内两图层多边形数量乘积。本文以数据集 1 为例，首先对比了在静态调度策略下，7 种方法使用不同进程数量下的负载均衡性能，性能指标采用了各进程执行时间的标准差(standard deviation，STD)。如图 6 所示，随机森林优化、梯度上升优化、ResNet 优化和 TBN4SI 优化性能较为优秀。随着进程数量增多，随机森林优化和 TBN4SI 优化的负载均衡性能优势愈发明显，在 48 进程时 TBN4SI 优化方法的 STD 指标降低到 3 s。梯度上升优化和 ResNet 优化性能紧随其后。相较而言，AlexNet 由于预测精度较低，其负载均衡性能也相对较差。然而，经验知识驱动的平均化评估和单特征评估方法的负载均衡性能在任意进程数下都表现最差，在 48 进程时 STD 指标仍超过 60 s。

图 7 展示了使用 7 种方法处理 3 组数据的时间和加速比。可以看出，在任意数据组和进程数量下，平均化评估和单特征评估方法的处理时间相较其他 5 种方法更长，相应加速比也最低。值得注意的是，单特征评估方法相较平均化评估方法获取了更高的加速比，尽管前者仅使用了一个特征来评估计算强度。基于图神经网络的 TBN4SI 优化方法及基于机器学习的随机森林优化和梯度上升优化方法三者的执行时间最短，加速比相应最高。基于卷积神经网络的 ResNet 优化和 AlexNet 优化方法的加速比相较更低。从结果上看，7 种方法并行计算性能和负载均衡性能并不呈严格的正相关关系，ResNet 模型的预测精度较高，其优化方法的负载均衡性能和随机森林优化方法相当，但其计算性能却更差。造成该现象的原因为在不同模型中，特征提取和计算强度预测代价有所差异。因此，试验进一步分析了并行计算过程中不同方法各主要阶段的时间开销和占比。

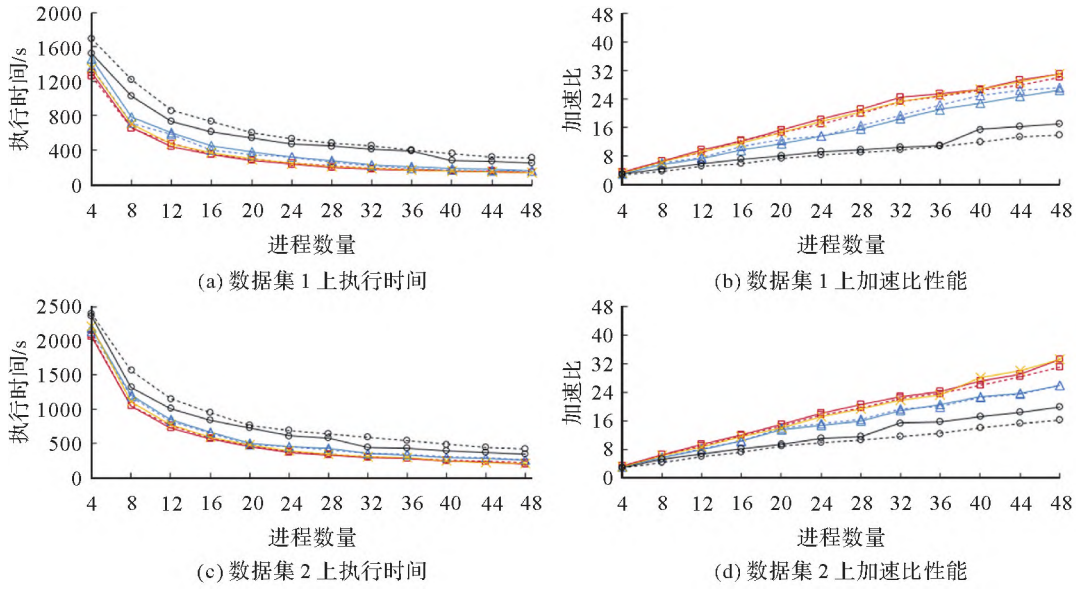


(a) 数据集 1 上执行时间

(b) 数据集 1 上加速比性能

(c) 数据集 2 上执行时间

(d) 数据集 2 上加速比性能

中国知网　https://www.cnki.net

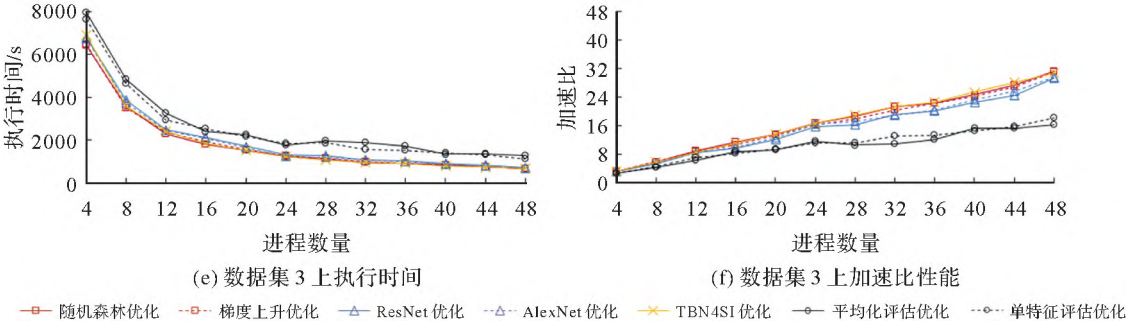


(e) 数据集 3 上执行时间　(f) 数据集 3 上加速比性能

图 7　7 种方法加速性能对比

Fig. 7　Comparison of computing performance among seven methods

基于机器学习的方法主要包括数据 I/O 和通信、过滤阶段、精解阶段、特征计算阶段、模型推理阶段，基于卷积神经网络的方法主要包括数据 I/O 和通信、过滤阶段、精解阶段、栅格化和合并、推理阶段，基于图神经网络的方法主要包括数据 I/O 和通信、过滤阶段、精解阶段、图构建阶段、推理阶段。图 8 以数据集 2 为例，展示了在不同进程数量下，5 种人工智能方法各阶段的时间占比情况。在机器学习方法中，特征计算和模型推理是评估计算强度的额外阶段。由于模型推理时间较短，因此图 8 将两阶段合并为推理阶段展示，该额外阶段的占比约为 10%。在卷积神经网络方法中，栅格化和合并、推理阶段是两个额外阶段，其中栅格化和合并在两种方法中占比为 7%～11%。ResNet 方法推理阶段占比为 8%～15%，AlexNet 方法由于模型结构更加简单，推理阶段占比仅为 6%～7%。在图神经网络方法中，构图和推理是两个额外阶段。TBN4SI 方法构图阶段占比为 6%～13%，推理阶段占比为 2%～3%，额外阶段共占比 9%～15%。整体来看，采用机器学习方法预测计算强度的代价最低，图神经网络方法的代价取决于其构图方法，而卷积神经网络方法的代价则最高。

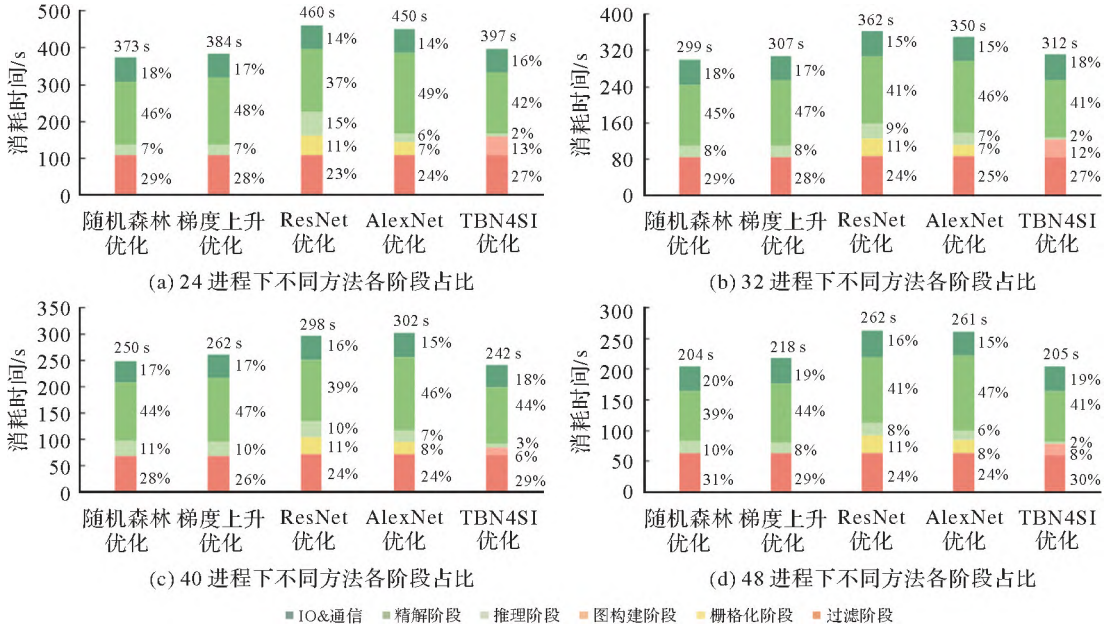


(a) 24 进程下不同方法各阶段占比　(b) 32 进程下不同方法各阶段占比

(c) 40 进程下不同方法各阶段占比　(d) 48 进程下不同方法各阶段占比

图 8　5 种方法不同进程数量下主要阶段时间占比

Fig. 8　Time proportion of major phases for five methods with varying process counts

先前试验均采用了静态调度策略，即将分解子域预先根据计算强度组合为等于进程数量的分区。这种策略的性能对计算强度预测精度较为敏感，因此本文进一步提出了大计算强度任务优先的任务窃取动态调度策略（优先动态调度＋任务窃取）。试验对比了该策略和传统 3 种动态调度策略共 4 种策略，传统动态调度策略包括大计算强度任务滞后的动态窃取调度策略（滞后动态调度＋任务窃取）、

中国知网 https://www.cnki.net

不包含任务窃取的大计算强度任务优先动态调度策略（优先动态调度）和滞后动态调度策略（滞后动态调度）。4 种动态调度策略和静态调度策略，分别结合随机森林回归和平均化评估两种计算强度预测方法，共有 10 种方法。其中，忽略异质性的平均化评估方法不存在大计算强度任务优先或滞后的情况，只区分非任务窃取式动态调度和任务窃取式动态调度，因此有 8 种方法。本文以数据集 1 为例，对比了这 8 种方法的负载均衡性能，其中静态调度中分区数量等于进程数量，动态调度中分区数量取进程数量的 3 倍。如图 9 所示，在采用任意模型预测计算强度时，结合了任务窃取的两种动态调度方法的进程执行时间标准差都接近于 0，而未结合任务窃取的动态调度方法的负载均衡性能相对较差。其中大计算强度任务优先的动态调度方法要比采用滞后调度的方法性能更好。在采用随机森林预测计算强度时，由于模型预测精度较高，因此静态调度方法和大计算强度任务优先调度的方法获得了相当的性能。但在采用忽略计算强度差异的平均化评估方法时，采用大计算强度任务优先调度的方法要比静态调度方法性能更好。

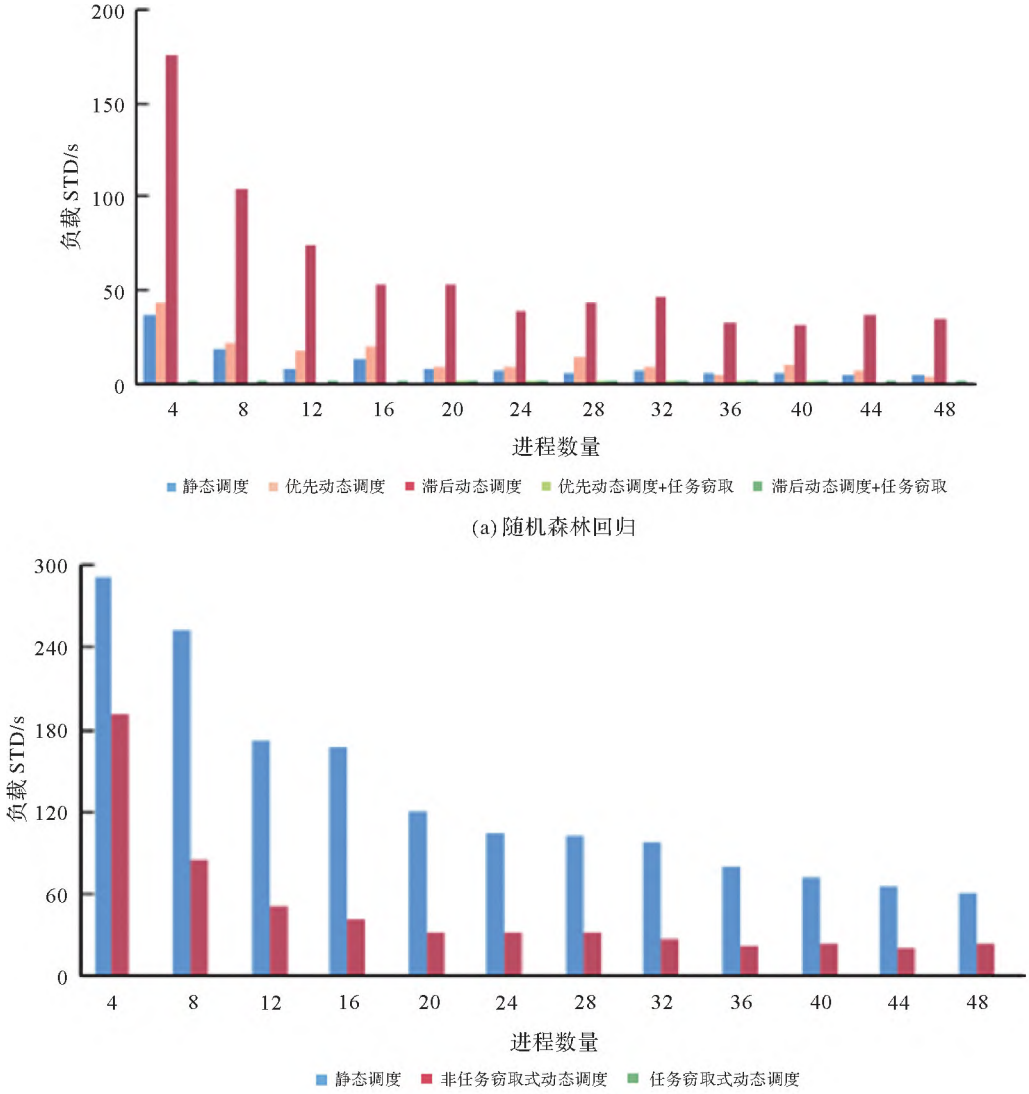


图 9　2 种计算强度评估方法结合 5 种任务调度策略下的负载均衡性能

Fig. 9　A comparative analysis of load balancing performance across two computational intensity evaluation methods when integrated with five task scheduling strategies

### 3.2　可视域分析

#### 3.2.1　案例与数据介绍

可视域分析隶属于通视分析大类，用于计算给定观察点对特定区域的可视范围。可视域分析算法众多，如 R3、R2、XDraw 和参考面算法。其中，R3 算法通过建立视点与目标点的视线，逐点比较地

中国知网　https://www.cnki.net

形剖面斜率来实现可视性判断，是当前唯一的精确类算法。同时，R3 算法计算也最为密集，存在明显的计算异质性。因此本文针对 R3 算法开展了并行优化。试验使用的数据如图 10 所示，数据来源于 NASA SRTM 数据集，区域位于中国江苏，数据集 4 和数据集 5 分别由 6 块和 9 块 1°×1°的 30 m 分辨率 DEM 瓦片拼接而成，单块瓦片大小为 3601×3601。并行策略方面，由于 R3 算法中各目标点的可视性判断均依赖于视线上的高程数据，因此本文以视点为中心，将数据划分成了诸多三角形状的分解子域，以保证存在计算依赖的数据被划分到相同分解子域中。

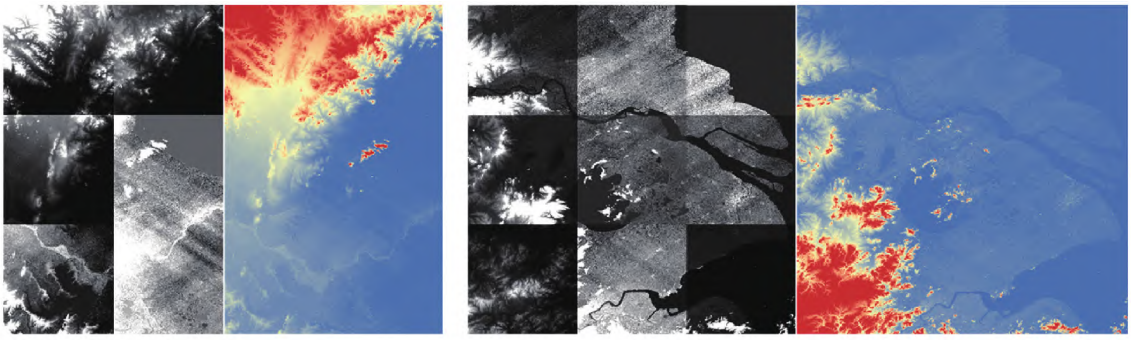

(a) 数据集 4　　(b) 数据集 5

图 10　可视域分析 DEM 数据

Fig. 10　Experimental DEM data for viewshed analysis

### 3.2.2　计算强度预测模型精度

针对该案例，试验采用了 4 种机器学习模型来预测算法计算强度，包括随机森林回归、梯度上升回归、决策树回归及线性回归。选用的特征包括分解子域内 DEM 网格点数量、斜率最大值、最小值、平均值和均方根，以及分解子域形态指数共六维特征，其中形态指数为分解子域的角平分线和开口角度比值。试验从数据集 5 中生成了约 8000 组样本，每条样本由对应分区数据的六维特征向量和在不同环境下的计算时间构成，其中计算时间作为样本标签。模型预测精度见表 3，其中随机森林回归、梯度上升回归和决策树回归的模型精度相当，拟合度 $R^2$ 均超过 0.9，MAE 均低于 1 s。线性回归的模型精度相对较差，$R^2$ 仅为 0.39。

**表 3　视域分析算法计算强度预测模型精度**

**Tab. 3　Computational intensity prediction accuracy in viewshed analysis**

| 模型 | $R^2$ | MAE/s | MSE/s$^2$ | RMSE/s |
|---|---|---|---|---|
| 随机森林回归 | 0.94 | 0.18 | 1.51 | 1.228 8 |
| 梯度上升回归 | 0.94 | 0.56 | 2.28 | 1.509 9 |
| 决策树回归 | 0.92 | 0.79 | 2.54 | 1.593 7 |
| 线性回归 | 0.39 | 22.69 | 1 472.67 | 38.375 4 |

### 3.2.3　并行计算性能

试验进一步对比了采用 3.2.2 节中 4 种方法及平均化评估方法预测计算强度优化下的并行计算性能。如图 11 所示，试验分别测试了进程数量从 1～24，5 种方法在 2 组数据集上的执行时间和加速比的变化情况。可见在任意进程数量下，平均化评估优化方法的性能都最差，峰值加速比不到 4，造成该现象的原因为其忽略算法计算异质性特点，造成了计算过程的负载失衡。4 种机器学习模型优化方法中，随机森林优化和梯度上升优化方法的计算性能较优，在 24 进程下加速比达到了 24。而线性回归模型由于较低的预测精度，其峰值加速比不到 8。

## 4　结　论

本文以智能计算范式为依托，将元智能、数据智能、感知智能和认知智能赋能地理计算，提出了一种智能驱动的并行地理计算引擎框架，旨在推动智能驱动的地理计算范式发展。首先，本文以空间计算域理论为基础，融入地理工作流概念，结合特征提取和计算强度评估，提出了地理空间计算域理论，作为地理计算智能化的理论基础。其次，针对基于元智能的特征工程方法，本文构建了面向不同地理计算依赖、分解策略和数据构成的地理空间计算域特征表达空间，包含形态结构特征、集合数量特征、空间分布特征和拓扑关联特征 4 大类特征以及细化的 9 小类特征。然后，本文结合地理空间计算流不同节点特点，分别提出了基于机器学习、深度学习卷积神经网络和图神经网络的地理空间计

中国知网 https://www.cnki.net

算域异质性感知策略。最后，本文以计算强度感知为基础，结合任务窃取策略，提出了大计算强度任务优先的任务窃取动态调度方法，进一步提高了地理计算负载均衡和并行计算性能。

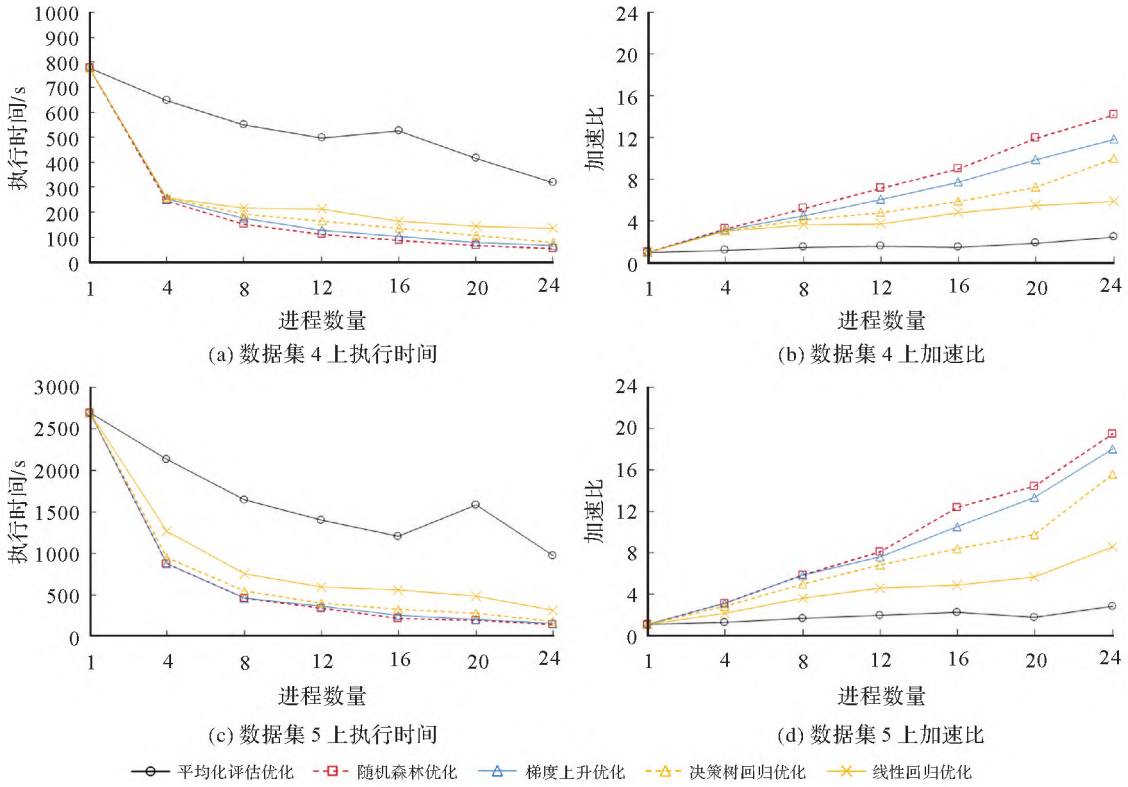


(a) 数据集 4 上执行时间　(b) 数据集 4 上加速比

(c) 数据集 5 上执行时间　(d) 数据集 5 上加速比

图 11　5 种计算强度评估方法的计算性能对比

Fig. 11　A comparative analysis of computing performance for five methods

本文以 GIS 领域中应用最为普遍的矢量相交分析和视域分析为例，验证了本文方法的可行性和高效性。在相交分析案例中，试验从机器学习、深度学习卷积神经网络和图神经网络中选取了共 8 种架构，用于训练矢量相交分析中精解阶段的计算强度预测模型。结果表明 3 类方法中均有模型可实现高精度预测。然后，试验从中选取了 5 个精度较高的模型，并对比传统忽略计算强度及利用单特征评估计算强度的方法。在此基础上结合静态调度策略优化矢量相交的并行化流程。结果表明模型精度与负载均衡性能呈正相关关系。最后，试验进一步选取了 2 种计算强度预测方法结合 4 种动态调度策略，对比了共 8 种组合方法的性能，结果表明结合了计算强度和任务窃取的方法性能占优。本文瞄准了传统专家驱动范式的局限性，通过利用人工智能机器学习和深度学习的能力，为地理计算领域提供了更加自动化和智能化的解决方案。视域分析案例中，本文选取了 4 种机器学习算法，用于训练视域分析计算强度预测模型，结果表明随机森林优化和梯度上升优化性能占优。在此基础上，试验进一步对比了不同方法的并行计算性能，结果证明了机器学习优化方法的优势。

然而，研究提出的并行地理计算引擎框架的智能化水平仍需提高。主要包括如下方面：①上述试验均在同构的计算环境中开展，即计算节点的性能相当。在异构环境下，还需要进一步评估不同计算节点的性能。②当前 3 种模式的选择仍依赖于经验知识，然而模式的选择本质上也是一个分类任务。例如，首先，建立一个地学算法库，列出各算法在并行化计算过程中的主要阶段。针对各阶段分别训练一个机器学习模型，用于预测各阶段的串行执行时间。其次，针对不同计算强度评估方法，可分别训练一个模型用于预测模型开销。例如，在基于卷积神经网络和图神经网络的方法中，模型评估代价主要来自栅格化、合并、构图，可选取特征对评估代价进行建模。然后，还需建立地理空间计算域分解代价模型。最后，基于阶段串行执行时间、评估代价、分解代价、计算强度预测模型精度，根据性能收益推荐计算强度评估方法和域分解方法。③尽管当前已整合了元智能、感知智能和认知智能，但大

中国知网　https://www.cnki.net

语言模型赋能的自主智能[25-26]，可进一步为非领域用户提供更便捷、高效的地理计算服务，这其中涉及到多方面的挑战，包括对用户语义的理解、地理工作流的构建、节点并行化的判断、分解策略的选择、特征提取与计算强度评估方法的决策、静态与动态调度方法的推荐，以及语言大模型和地理计算强度预测等小模型的协作，这都是未来可开展的研究方向。

## 参考文献


[1] WANG Kexian, ZHENG Shunyi, LI Rui, et al. A deep double-channel dense network for hyperspectral image classification[J]. Journal of Geodesy and Geoinformation Science, 2021, 4(4): 46-62.

[2] ZHU Shiqiang, YU Ting, XU Tao, et al. Intelligent computing: the latest advances, challenges, and future[J]. Intelligent Computing, 2023, 2: 6.

[3] 陈军，艾廷华，闫利，等. 智能化测绘的混合计算范式与方法研究[J]. 测绘学报，2024，53(6)：985-998. DOI：10.11947/j.AGCS.2024.20240131.
CHEN Jun, AI Tinghua, YAN Li, et al. Hybrid computational paradigm and methods for intelligentized surveying and mapping[J]. Acta Geodaetica et Cartographica Sinica, 2024, 53(6): 985-998. DOI: 10.11947/j.AGCS.2024.20240131.

[4] ARUTE F, ARYA K, BABBUSH R, et al. Quantum supremacy using a programmable superconducting processor[J]. Nature, 2019, 574: 505-510.

[5] LIU Aixin, FENG Bei, WANG Bin, et al. Deepseek-V2: a strong, economical, and efficient mixture-of-experts language model[EB/OL]. [2025-01-05]. https://arxiv.org/abs/2405.04434.

[6] 李德仁. 论时空大数据的智能处理与服务[J]. 地球信息科学学报，2019，21(12)：1825-1831.
LI Deren. The intelligent processing and service of spatiotemporal big data[J]. Journal of Geo-information Science, 2019, 21(12): 1825-1831.

[7] 李德仁，徐小迪，邵振峰. 论万物互联时代的地球空间信息学[J]. 测绘学报，2022，51(1)：1-8. DOI：10.11947/j.AGCS.2022.20210564.
LI Deren, XU Xiaodi, SHAO Zhenfeng. On geospatial information science in the era of IoE[J]. Acta Geodaetica et Cartographica Sinica, 2022, 51(1): 1-8. DOI: 10.11947/j.AGCS.2022.20210564.

[8] WANG Mi, ZHANG Zhiqi, DONG Zhipeng, et al. Stream-computing of high accuracy on-board real-time cloud detection for high resolution optical satellite imagery[J]. Journal of Geodesy and Geoinformation Science, 2019, 2(2): 50-59.

[9] WANG Shaowen, ARMSTRONG M P. A quadtree approach to domain decomposition for spatial interpolation in grid computing environments[J]. Parallel Computing, 2003, 29(10): 1481-1504.

[10] WANG Shaowen, ARMSTRONG M P. A theoretical approach to the use of cyberinfrastructure in geographical analysis[J]. International Journal of Geographical Information Science, 2009, 23(2): 169-193.

[11] AJI A, WANG Fusheng, VO H, et al. Hadoop-GIS: a high performance spatial data warehousing system over MapReduce[J]. Proceedings of the VLDB Endowment International Conference on Very Large Data Bases, 2013, 6(11): 1009.

[12] LI Zilong, CAO Zhipeng, YUE Peng, et al. Earth video cube: a geospatial data cube for multisource earth observation video management and analysis[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 4986-5000.

[13] ELDAWY A, ALARABI L, MOKBEL M F. Spatial partitioning techniques in SpatialHadoop[J]. Proceedings of the VLDB Endowment, 2015, 8(12): 1602-1605.

[14] SWARNDEEP S J, PANDYA S. An overview of partitioning algorithms in clustering techniques[J]. International Journal of Advanced Research in Computer Engineering & Technology, 2016, 5(6): 1943-1946.

[15] FAN Wenfei, HE Tao, LAI Longbin, et al. GraphScope: a unified engine for big graph processing[J]. Proceedings of the VLDB Endowment, 2021, 14(12): 2879-2892.

[16] GAO Fan, YUE Peng, CAO Zhipeng, et al. A multi-source spatio-temporal data cube for large-scale geospatial analysis[J]. Intertional Journal of Geographical Information Science, 2022, 36(9): 1853-1884.

[17] GUO Mingqiang, GUAN Qingfeng, XIE Zhong, et al. A spatially adaptive decomposition approach for parallel vector data visualization of polylines and polygons[J]. International Journal of Geographical Information Science, 2015, 29(8): 1419-1440.

[18] LI Guowen, LI Jingzhong. An adaptive-size vector tile pyramid construction method considering spatial data distribution density characteristics[J]. Computers & Geosciences, 2024, 184: 105537.

[19] MIAO Jinli, GUAN Qingfeng, HU Shujian. pRPL+pGTIOL: the marriage of a parallel processing library and a parallel I/O library for


中国知网 https://www.cnki.net

big raster data[J]. Environmental Modelling & Software, 2017, 96: 347-360.

[20] GUAN Qingfeng, CLARKE K C. A general-purpose parallel raster processing programming library test application using a geographic cellular automata model[J]. International Journal of Geographical Information Science, 2010, 24(5): 695-722.

[21] JIANG Yichuan. A survey of task allocation and load balancing in distributed systems[J]. IEEE Transactions on Parallel and Distributed Systems, 2016, 27(2): 585-599.

[22] REN Yibin, CHEN Zhenjie, CHEN Ge, et al. A hybrid process/thread parallel algorithm for generating DEM from LiDAR points[J]. ISPRS International Journal of Geo-Information, 2017, 6(10): 300.

[23] SCHMID M, FRITZ F, MOTTOK J. Fine-grained parallelism framework with predictable work-stealing for real-time multiprocessor systems[J]. Journal of Systems Architecture, 2022, 124: 102393.

[24] PATEL J M, DEWITT D J. Partition based spatial-merge join[J]. ACM Sigmod Record, 1996, 25(2): 259-270.

[25] WEI Cheng, ZHANG Yifan, ZHAO Xinru, et al. GeoTool-GPT: a trainable method for facilitating large language models to master GIS tools[J]. International Journal of Geographical Information Science, 2025, 39(4): 707-731.

[26] LI Zhenlong, NING Huan. Autonomous GIS: the next-generation AI-powered GIS[J]. International Journal of Digital Earth, 2023, 16(2): 4668-4686.

（责任编辑：侯　琳）

中国知网　https://www.cnki.net

# An intelligent parallel geocomputation engine framework

GAO Fan[1], LU Wei[1], GAN Linlu[1], ZHANG Fan[1], RONG Fengjuan[1], TANG Shihan[2]

1. *Institute of Communication Engineering, Army Engineering University, Nanjing* 210007, *China*;
2. *School of Geography, Nanjing Normal University, Nanjing* 210023, *China*

Abstract: The capture of spatial computational features and the prediction of their intensity are pivotal challenges in the field of high-performance geocomputation and are crucial under the paradigm of intelligent computing. Traditional expert knowledge-driven research paradigms are limited in scalability, modeling complexity, and accuracy, leading to load imbalance and resource wastage. Addressing these issues, this paper introduces an intelligent parallel geocomputation engine framework, synergizing meta-intelligence, perceptual intelligence, and cognitive intelligence in geocomputation. At the meta-intelligence level, a universal feature representation space for spatial computational domains is constructed, considering morphological structures, set quantities, spatial distributions, and topological relationships. The perceptual intelligence level incorporates customized machine learning and deep learning models to enable automatic perception of computational intensity in geospatial domains. At the cognitive intelligence level, an adaptive dynamic scheduling strategy is proposed, combining high-intensity task prioritization and task stealing. The efficacy and efficiency of the intelligent parallel geocomputation engine are validated through two cases, including polygon intersection and viewshed analysis, demonstrating a more than 20-fold improvement in load balancing performance.

Key words: geocomputation; intelligent computing; spatial computational features; spatial computational intensity; load balance

Foundation support: The National Natural Science Foundation of China (No. 42301489); Jiangsu Natural Science Foundation of China (No. BK20231030)

First author: GAO Fan (1994—), male, PhD, lecturer, majors in high-performance geocomputation and edge computing.
E-mail: fgao@aeu.edu.cn
Corresponding author: LU Wei
E-mail: wlu@aeu.edu.cn

中国知网 https://www.cnki.net