计算机科学与探索
Journal of Frontiers of Computer Science and Technology
ISSN 1673-9418,CN 11-5602/TP

《计算机科学与探索》网络首发论文

题目：　深度学习在兴趣点推荐中的应用综述
作者：　黄屏，王峰，刘广腾，吴中博，李晓丽，黄金洲
网络首发日期：　2025-07-03
引用格式：　黄屏，王峰，刘广腾，吴中博，李晓丽，黄金洲．深度学习在兴趣点推荐中的应用综述[J/OL]．计算机科学与探索．
https://link.cnki.net/urlid/11.5602.tp.20250702.1919.006

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-07-03 13:00:29　网络首发地址：https://link.cnki.net/urlid/11.5602.tp.20250702.1919.006

doi: 10.3778/j.issn.1673-9418.2503022

深度学习在兴趣点推荐中的应用综述

黄屏，王峰+，刘广腾，吴中博，李晓丽，黄金洲

湖北文理学院 计算机工程学院，湖北 襄阳 441053

+ 通信作者 E-mail: wangfeng@hbuas.edu.cn

摘　要：随着移动设备和位置服务的普及，基于位置的社交网络产生了海量的用户签到数据，兴趣点推荐作为重要的位置服务受到广泛关注。针对传统兴趣点推荐方法面临的数据稀疏性、时空因素复杂、用户兴趣动态变化、隐私保护和解释性不足等挑战，对基于深度学习的兴趣点推荐技术进行了全面综述。首先介绍了兴趣点推荐系统的形式化定义，构建了包含数据层、特征工程层、深度学习模型层和应用层的通用框架。系统梳理了循环神经网络、长短期记忆网络、门控循环单元、注意力机制、变换器和图神经网络等深度学习技术在兴趣点推荐中的应用原理和核心算法。深入分析了主流数据集的特点和评估指标的适用性，对基于序列建模、注意力机制、图结构、多模态融合以及特定任务导向的兴趣点推荐模型进行了详细分类和性能对比。通过实际应用案例分析，验证了深度学习驱动的兴趣点推荐系统在旅游景点推荐、餐饮推荐、城市服务点推荐、跨城市推荐和工业级应用中的有效性。系统分析了当前研究面临的技术挑战、数据挑战和应用挑战，包括计算复杂度与效率优化、用户偏好动态性建模、可解释性与用户信任、数据稀疏性与冷启动问题、多模态数据融合、隐私保护与公平性等关键问题。展望了兴趣点推荐技术向计算效率优化、动态偏好建模、内在可解释性、多模态融合和隐私保护方向的发展趋势。

关键词：兴趣点推荐；深度学习；图神经网络；注意力机制；时空建模；多模态融合

文献标志码：A　　**中图分类号：**TP391

Survey on Deep Learning Applications in Point of Interest Recommendation

HUANG Ping, WANG Feng+, LIU Guangteng, WU Zhongbo, LI Xiaoli, HUANG Jinzhou

College of Computer Engineering, Hubei University of Arts and Science, Xiangyang, Hubei 441053, China

Abstract: With the proliferation of mobile devices and location-based services, massive user check-in data from location-based social networks has generated widespread attention for point-of-interest (POI) recommendation as an important location service. Addressing challenges of data sparsity, complex spatiotemporal factors, dynamic user interest changes, privacy protection, and insufficient interpretability in traditional POI recommendation methods, this study comprehensively reviews deep learning-based POI recommendation techniques. The formal definition of POI recommendation systems is introduced, and a general framework comprising data layer, feature engineering layer, deep learning model layer, and application layer is constructed. Deep learning technologies including recurrent neural networks, long short-term memory networks, gated recurrent units, attention mechanisms, transformers, and graph neural networks are systematically analyzed for their application principles and core algorithms in POI

基金项目：国家自然科学基金(62306108)；湖北省自然科学基金创新发展联合基金项目(2022CFD101，2022CFD103)；湖北省教育厅科学研究计划重点项目(D20192602)；襄阳市高新领域重点科技计划项目(2022ABH006848)；湖北省高等学校优势特色学科群“新能源汽车与智慧交通”资助。

This work was supported by National Natural Science Foundation of China (62306108); Hubei Provincial Natural Science Foundation Innovation and Development Joint Fund Project (2022CFD101, 2022CFD103); Key Project of the Scientific Research Program of Hubei Provincial Department of Education (D20192602); Xiangyang High-Tech Key Science and Technology Program (2022ABH006848); Supported by the Advantageous and Characteristic Discipline Group of Hubei Higher Education Institutions – "New Energy Vehicles and Smart Transportation".

recommendation. Mainstream dataset characteristics and evaluation metric applicability are thoroughly analyzed. Detailed classification and performance comparison are conducted for POI recommendation models based on sequence modeling, attention mechanisms, graph structures, multimodal fusion, and specific task orientations. Through practical application case analysis, the effectiveness of deep learning-driven POI recommendation systems is validated in tourist attraction recommendation, dining recommendation, urban service point recommendation, cross-city recommendation, and industrial-scale applications. Current research challenges are systematically analyzed, including technical challenges, data challenges, and application challenges, covering key issues such as computational complexity and efficiency optimization, dynamic user preference modeling, interpretability and user trust, data sparsity and cold start problems, multimodal data fusion, privacy protection and fairness. Future development trends toward computational efficiency optimization, dynamic preference modeling, intrinsic interpretability, multimodal fusion, and privacy protection are prospected.

Key words: point-of-interest recommendation; deep learning; graph neural networks; attention mechanisms; spatiotemporal modeling; multimodal fusion

近年来，随着移动设备和位置服务的普及，基于位置的社交网络[1]（Location-Based Social Networks, LBSNs）产生了海量的用户签到数据。这些数据不仅记录了用户的时空轨迹，还蕴含着丰富的用户偏好和行为模式。兴趣点[2]（Point-of-Interest, POI）推荐作为一种重要的位置服务，旨在基于用户的历史访问记录，为其推荐可能感兴趣的新地点。有效的 POI 推荐不仅能够提升用户体验，也能为商家带来更多商业机会，因此受到学术界和工业界的广泛关注。

然而，POI 推荐面临着诸多独特的挑战[3]。首先，用户的签到数据通常呈现出严重的稀疏性，大多数用户仅访问过少量 POI，这使得传统的协同过滤方法难以准确建模用户偏好。其次，用户的 POI 访问行为受到复杂的时空因素影响[4]，例如时间周期性、地理距离限制、天气条件等，这要求推荐系统能够有效整合多维度的上下文信息。此外，用户兴趣的动态变化特性也给准确预测带来了挑战。值得注意的是，POI 推荐还面临着隐私保护的严峻问题，用户的位置数据极其敏感，如何在提供个性化推荐的同时保护用户隐私成为一个亟待解决的难题。最后，推荐系统的解释性不足也限制了用户对推荐结果的信任和接受度。

深度学习技术的快速发展为解决这些挑战提供了新的可能。相比传统方法，深度学习模型具有更强的特征表示和非线性建模能力，能够自动学习数据中的复杂模式。近期研究表明，循环神经网络（Recurrent Neural Network, RNN）及其变体可以有效捕捉用户的序列行为特征；注意力机制能够动态关注相关的历史信息；图神经网络（Graph Neural Networks, GNN）则善于建模用户-POI 之间的复杂交互关系。这些技术的创新应用显著提升了 POI 推荐的性能。图 1 展示了本文的研究框架，从基础概念与定义出发，通过核心网络架构、评估体系到模型分类，最终指向技术挑战与未来方向。

随着深度学习技术的快速发展，这一领域正在经历显著的变革。新的模型架构、训练方法和应用场景不断涌现，亟需从当前技术发展的高度重新审视和总结这一领域的最新进展。虽然已有一些研究对 POI 推荐进行了综述，如郭旦怀等人[5]和黄立威等人[6]的基于深度学习的推荐系统综述，但这些工作对深度学习在 POI 推荐中的应用并未提供完整的技术分析框架。根据郭旦怀等人的研究，深度学习应用于 POI 推荐主要可分为四类：POI 的向量化学习、深度协同过滤、从辅助内容中提取特征和利用循环神经网络进行序列推荐。黄立威等人的研究则提供了深度学习在推荐系统中更广泛的应用框架，包括自编码器、受限玻尔兹曼机、卷积神经网络和循环神经网络等模型在推荐系统中的应用。然而，这些综述未能充分反映最近几年的技术进步，特别是 GNN、Transformer 模型及大语言模型在 POI 推荐中的应用进展。此外，现有综述对多模态融合、隐私保护和可解释性等新兴挑战的讨论相对有限。

有鉴于此，本文旨在从深度学习的最新进展角度提供一个全面的技术综述，主要包括以下贡献：1）综述了近 3 年基于深度学习的 POI 推荐领域的最新研究进展，重点介绍了基于长短期记忆网络（Long Short-Term Memory Network, LSTM）、门控循环单元（Gated Recurrent Unit, GRU）、注意力机制、变换器和 GNN 等深度学习模型在 POI 推荐中的应用；2）对现有的基于深度学习的 POI 推荐算法中的关键技术进行了深入分析，不仅介绍了这些技术的优势，也客观评估了其局限性，为研究人员和实践者

提供更全面的参考；3）系统分析了当前 POI 推荐面临的主要挑战，如计算效率优化、数据稀疏性处理、动态兴趣建模、可解释性增强、多模态融合和隐私保护等问题，并从工业应用角度探讨了未来可能的研究方向。

本文的结构安排如下：首先介绍了 POI 推荐的背景、重要性及传统方法面临的挑战。接着，第 1 章节详细阐述了兴趣点推荐系统的形式化定义。第 2 章节介绍了基于深度学习的 POI 推荐系统通用框架，包括数据层、特征工程层、深度学习模型层和应用层四个主要层次。第 3 章节深入分析了深度学习的关键技术在 POI 推荐中的应用，包括循环神经网络、长短期记忆网络、门控循环单元、注意力机制、变换器和 GNN 等。第 4 章节对主流数据集（如 Foursquare、Gowalla 等）和评估指标（如召回率、归一化折损累计增益等）进行了系统分析。第 5 章节详细讨论了多种 POI 推荐模型，包括基于序列建模的方法、基于注意力机制的方法、基于图结构的方法、多模态融合方法以及特定任务导向方法，并探讨了它们在不同应用场景中的表现。最后，总结了当前研究面临的技术、数据和应用三大挑战，并展望了未来可能的研究方向。

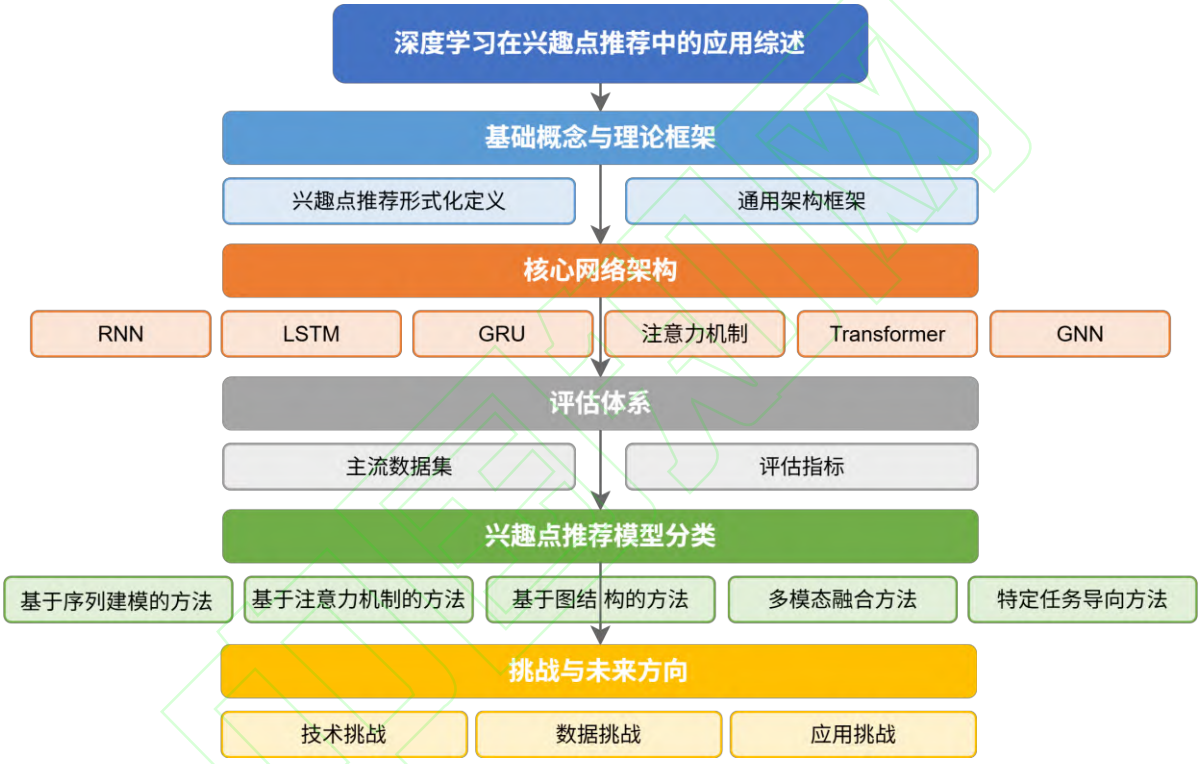

图 1 深度学习在 POI 推荐中的应用研究框架

Fig.1 A Research Framework for Deep Learning in POI Recommendations

1 POI 推荐系统的形式化定义

在 POI 推荐任务中，主要目标是基于用户的历史签到记录、地理位置信息、社交关系等多种因素，为用户推荐合适的 POI。POI 推荐问题可以形式化为以下几个核心任务：

1.1 定义 1（签到）

设 u 表示用户，l 表示 POI，t 表示时间戳，用户的签到行为可以表示为：

$$c=(u,l,t) \tag{1}$$

其中，c 表示用户 u 在时间 t 对兴趣点 l 的一次签到记录。所有签到数据集合可以表示为：

$$C=\{(u_i,l_i,t_i)\}_{i=1}^{N} \tag{2}$$

其中，N 为所有签到记录的数量。

1.2 定义 2（签到列表）

对每个用户 u，其签到历史可以表示为时间序列：

$$S_u=[(l_1,t_1),(l_2,t_2),\ldots,(l_m,t_m)] \tag{3}$$

其中，m 是用户 u 的签到次数，签到数据按时间顺序排列。目标是利用此签到序列预测用户未来可能访问的 POI。

1.3 定义 3（下一个 POI 推荐）

下一个 POI 推荐任务旨在预测用户 u 在时间 t+1 可能访问的 POI，即：

$$\hat{l} = f(S_u) \tag{4}$$

其中，f 为推荐模型，$\hat{l}$ 为预测的下一个 POI。

1.4 定义 4（时空感知 POI 推荐）

由于 POI 推荐涉及时间和地理信息，推荐模型需要结合时间衰减和空间距离进行建模。用户访问 POI 的概率可表示为：

$$P(p \mid C_u, T, L) = f(C_u, t_n, l_n) \tag{5}$$

其中，T 代表时间信息（如小时、星期），L 代表地理信息（如当前用户位置），$f(\cdot)$ 是一个深度学习模型，如 RNN、Transformer、GNN 等。

基于时空依赖，可以采用地理距离约束和时间衰减权重：

$$P(p \mid C_u) = \frac{e^{-\alpha d(p, p_n)}}{1 + e^{-\beta(t_n - t_i)}} \tag{6}$$

其中，$d(p, p_n)$ 代表 POI 之间的地理距离，α, β 为超参数，用于控制时间和空间影响的权重。

1.5 定义 5（POI 序列推荐）

POI 序列推荐任务关注用户未来一段时间的签到预测，即给定用户的签到历史 S_u，预测未来 T 个时间步的 POI 访问序列：

$$\hat{S}_u = [\hat{l}_{t+1}, \hat{l}_{t+2}, \ldots, \hat{l}_{t+T}] \tag{7}$$

目标是最小化预测序列与真实签到序列的误差，如使用交叉熵损失：

$$\mathcal{L} = -\sum_{t=1}^{T} \sum_{l \in \mathcal{L}} y_{u,t}^{l} \log p_{u,t}^{l} \tag{8}$$

其中，$y_{u,t}^{l}$ 是真实签到概率，$p_{u,t}^{l}$ 是模型预测的 POI 访问概率。

1.6 定义 6（多模态 POI 推荐）

在现代 POI 推荐系统中，不仅可以利用签到数据，还可以结合文本评论、图像、社交关系等多模态数据进行建模。假设不同模态数据的特征分别为：文本特征：$\boldsymbol{x}^{\text{text}}$、图像特征：$\boldsymbol{x}^{\text{image}}$、社交关系特征：$\boldsymbol{x}^{\text{social}}$。可以使用多模态融合模型，如注意力机制或 Transformer，将不同模态的信息整合：

$$\boldsymbol{x}^{\text{fusion}} = W_1 \boldsymbol{x}^{\text{text}} + W_2 \boldsymbol{x}^{\text{image}} + W_3 \boldsymbol{x}^{\text{social}} \tag{9}$$

其中，W_1, W_2, W_3 是可训练的权重参数。

2 基于深度学习的 POI 推荐系统通用框架

如图 2 所示，基于深度学习的 POI 推荐系统通用框架由四个主要层次组成：数据层、特征工程层、深度学习模型层和应用层。

2.1 数据层

数据层是 POI 推荐系统的基础，主要包含以下几类数据：1）用户-POI 交互数据：记录用户与 POI 之间的交互行为，包括签到、评分、评论等信息，是 POI 推荐的核心数据。2）时间信息：记录用户访问 POI 的时间点或时间段，可以体现用户行为的时间规律性和周期性。3）地理信息：包含 POI 的经纬度坐标、区域信息等，反映 POI 的空间分布特征和用户的地理移动模式。4）社交关系：记录用户之间的社交连接，如关注、好友等关系，可用于挖掘用户间的相似性和社交影响。5）上下文信息：包括天气状况、交通情况、POI 类别、人群密度等环境因素，提供推荐的情境依据。

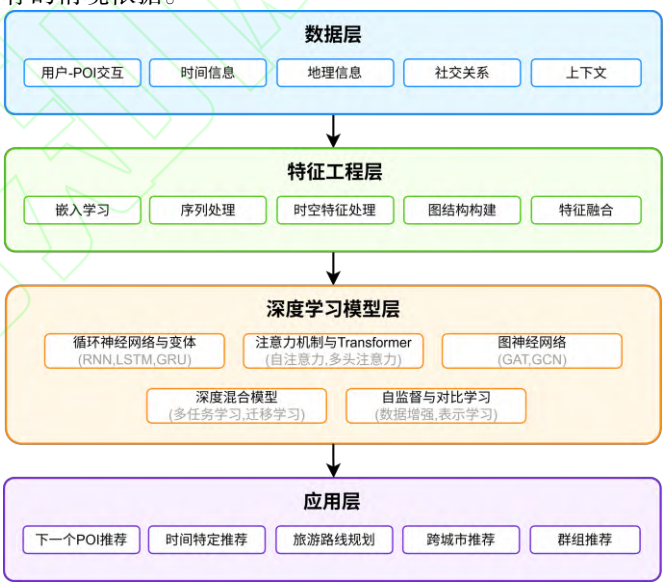

图 2 基于深度学习的 POI 推荐系统通用框架

Fig.2 A Generic Framework for POI Recommender Systems Based on Deep Learning

2.2 特征工程层

特征工程层负责将原始数据转换为适合深度学习模型处理的特征表示，主要包含以下技术：1）嵌入学习：将用户、POI 和其他类别特征映射到低维向量空间，以捕捉实体间的潜在关系。2）序列处理：将用户的历史签到序列进行预处理，包括时间排序、滑动窗口划分等，以准备序列建模。3）时空特征提取：从原始数据中提取时间特征（如小时、星期、季节）和空间特征（如距离、区域），以捕捉用户行为的时空模式。4）图结构构建：基于用户-

POI 交互、社交关系、POI 相似性等构建多种关系图，为 GNN 建模提供基础。5）特征融合：将多源异构特征进行整合，通过特征选择、交叉特征生成等方法提高特征表达力。

2.3 深度学习模型层

深度学习模型层是 POI 推荐系统的核心，负责学习用户偏好和 POI 特征，主要包含以下模型类型：1）循环神经网络与变体：包括 RNN、LSTM、GRU 等，主要用于建模用户签到序列中的时序依赖关系，捕捉用户的动态偏好变化。2）注意力机制与 Transformer：通过自注意力机制和多头注意力机制，自适应地给予相关历史行为更高的权重，有效处理长期依赖关系。3）图神经网络：包括图注意力网络(Graph Attention Network， GAT)、图卷积网络(Graph Convolutional Network, GCN)等，通过在图结构上的信息传递和聚合，学习节点（用户/POI）的表示，捕捉高阶交互模式。4）深度混合模型：结合多任务学习、迁移学习等技术，同时优化多个相关任务，或将知识从数据丰富区域迁移到数据稀疏区域。5）自监督与对比学习：通过数据增强和表示学习等技术，在无标签或弱标签场景下提高模型的学习能力，缓解数据稀疏问题。

2.4 应用层

应用层将深度学习模型的输出转化为具体的 POI 推荐服务，主要包含以下应用场景：1）下一个 POI 推荐：根据用户的当前位置和历史轨迹，推荐用户下一个可能访问的 POI。2）时间特定推荐：在特定时间点（如早餐、午餐、周末）为用户推荐合适的 POI。3）旅游路线规划：为旅游用户规划一系列 POI 组成的旅游路线，满足用户的时间预算和偏好。4）跨城市推荐：基于用户在熟悉城市的行为，为其在不熟悉城市中推荐合适的 POI。5）群组推荐：同时考虑多个用户的偏好，为用户群体推荐共同感兴趣的 POI。

3 网络架构基础

3.1 循环神经网络

在 POI 推荐中，用户的签到序列天然具有时序特征，循环神经网络[13]能够有效地捕获这种时序模式和用户的序列偏好。如图 3 所示，RNN 的基本结构展示了序列数据的处理过程：h_0 表示初始隐藏状态；x_1,x_2,x_3,x_4 是输入序列，在 POI 推荐场景中可以表示用户在不同时间点访问的 POI 特征；h_1,h_2,h_3,h_4 是隐藏状态序列，每个隐藏状态既保存了当前输入信息，也包含了之前时间步的历史信息；y_1,y_2,y_3,y_4 是输出序列，可以表示模型对下一个可能访问 POI 的预测。RNN 的核心优势在于其递归结构：当前时刻的隐藏状态 h_t 不仅依赖于当前输入 x_t，还依赖于前一时刻的隐藏状态 h_{t-1}。这种结构使得 RNN 能够捕获用户访问 POI 的时序依赖关系，学习用户的长期和短期兴趣偏好，并模拟用户真实的行为序列模式。

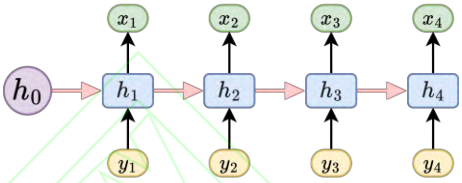

图 3 RNN 基本结构

Fig.3 Basic structure of RNN

3.2 长短期记忆网络

长短期记忆网络[7]是一种特殊的循环神经网络结构，由 Hochreiter 和 Schmidhuber 于 1997 年提出。与传统 RNN 相比，LSTM 能够有效解决长序列训练过程中的梯度消失问题，更好地捕获序列数据中的长期依赖关系。

LSTM 的核心是其特殊的记忆单元结构，如图 4 所示，主要包含一个记忆单元和三个门控机制。在图 4 中，C_{t-1} 和 h_{t-1} 分别表示上一时刻的细胞状态和隐藏状态，x_t 表示当前时刻的输入。通过这些门控机制的配合，LSTM 能够实现对历史信息的选择性遗忘和保留。图 4 中的计算流程展示了如何从输入 x_t 和前一时刻状态 h_{t-1}，通过各个门控单元的处理，最终得到当前时刻的输出 h_t 和更新后的细胞状态 C_t。绿色方块表示不同的激活函数(Sigmoid 和 Tanh)，黄色圆圈表示点乘操作，加号表示矩阵加法操作。

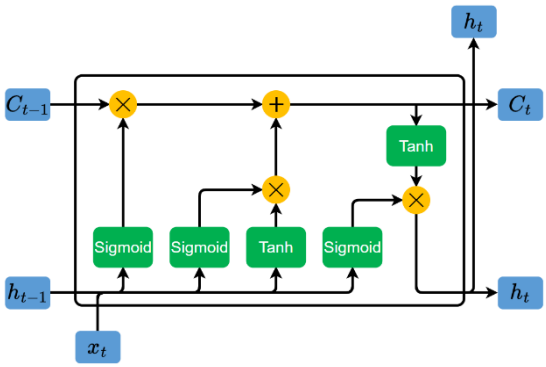

图 4 LSTM 基本结构

Fig.4 Basic structure of LSTM

3.3 门控循环单元

门控循环单元是一种特殊的循环神经网络结构，由 Cho 等人[14]在 2014 年提出。作为 LSTM 的一种变体，GRU 通过门控机制来解决传统 RNN 中的梯度消失问题，同时保持了更简单的结构。

在 POI 推荐中，GRU 能够有效地捕获用户的时序检查记录中的顺序依赖关系。图 5 展示了 GRU 的内部结构，其中左侧的 r_t 代表重置门，通过 sigmoid 函数控制前一时刻隐藏状态的保留程度；中间的 z_t 代表更新门，同样通过 sigmoid 函数控制信息更新的比例；右侧的 $\tilde{h}_t$ 经过 tanh 激活函数生成候选隐藏状态；最终的输出 h_t 是通过更新门 z_t 对前一时刻隐藏状态 h_{t-1} 和候选隐藏状态 $\tilde{h}_t$ 的加权组合。

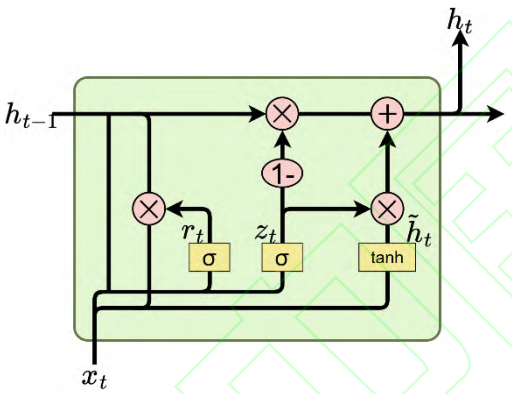

图 5 GRU 内部结构

Fig.5 GRU internal structure

3.4 注意力机制

注意力机制[25]（Attention Mechanism）能够有效地捕捉用户兴趣的动态变化和 POI 之间的复杂关系。如图 6 所示，POI 推荐中的注意力机制主要包含三个关键层次：输入层、注意力计算层和输出层。

在输入层，系统主要处理三类信息：用户的历史 POI 访问序列、候选 POI 的特征信息以及时间、天气等上下文信息。这些异构信息共同构成了注意力机制的基础输入。注意力计算层是整个机制的核心，它采用查询-键-值的框架进行计算。其中，查询向量通常由用户的历史行为序列和当前上下文信息生成，用于表达用户当前的兴趣状态；键向量和值向量则由候选 POI 的特征信息构建，分别用于计算注意力分数和生成最终的特征表示。在注意力计算过程中，系统首先计算查询向量与各个键向量之间的相似度，得到注意力分数。这些分数经过权重归一化处理后，转化为权重系数，用于对值向量进行加权聚合。这种机制确保了系统能够根据当前用户兴趣，动态地关注不同 POI 的特征信息。在输出层，注意力加权后的特征与其他相关特征进行融合，形成最终的特征表示，用于后续的推荐评分计算。

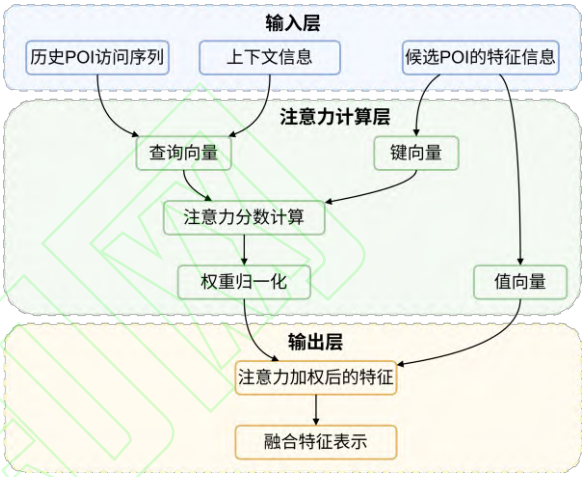

图 6 注意力机制数据流动过程

Fig.6 Attention mechanism data flow process

3.5 变换器

变换器[40]（Transformer Neural Network, Transformer）的基本架构主要包含编码器和解码器两个部分。其中编码器结构的底层包含 Token Embedding 层，将输入的 POI 序列转换为密集向量表示，并结合位置编码（Positional Encoding）来保留序列的位置信息。随后通过多头注意力机制（Multi-Head Attention）捕捉 POI 序列中的空间-时间依赖关系，再经过 Position-wise 前馈神经网络（Feedforward Neural Network, FNN）进行特征转换。其中 Add & Norm 层包含残差连接和层归一化，有助于模型训练的稳定性。解码器结构与编码器相似，但增加了 Masked Multi-Head Attention 层。该层通过 mask 机制确保预测时只能看到历史 POI 信息，避免信息泄露。最后通过 Linear 层和 Softmax 层输出下一个可能访问的 POI 概率分布。从图 7 中可以看出典型的 Transformer 结构中，左侧为编码器，右侧为解码器，两者都重复堆叠了 L 层。

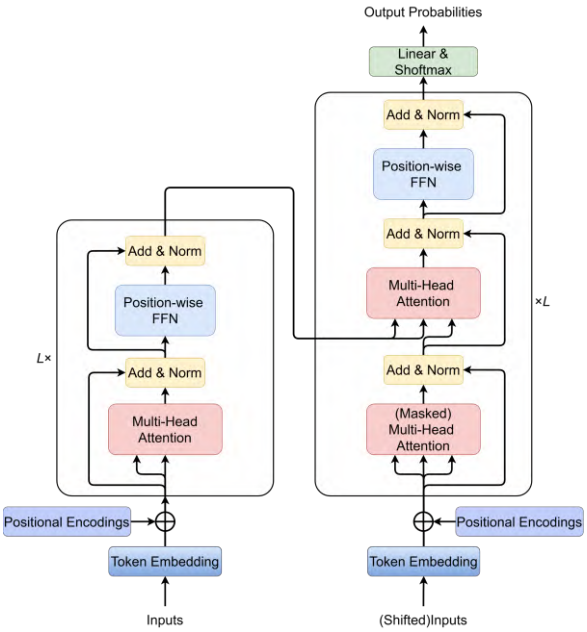

图 7 Transformer 结构

Fig.7 Transformer structure

3.6 图神经网络

图神经网络[75]（Graph Neural Networks, GNN）通过节点间的信息传递和聚合，学习节点的表示，从而实现对图数据的分析和预测。图 8 展示的是一个典型的 GNN 结构。该网络由输入层（Input）、多个隐藏层（Hidden Layer）和输出层（Output）组成。输入层接收图的节点特征，每个节点通过边与其他节点相连。隐藏层通过图卷积操作，将节点的特征与其邻居节点的特征进行聚合，从而更新节点的表示。图 8 中使用了 ReLU（Rectified Linear Unit）激活函数，增加网络的非线性表达能力。经过多个隐藏层的迭代更新，节点的特征表示逐渐丰富，最终在输出层生成每个节点的最终表示，用于后续的任务，如节点分类或图分类。

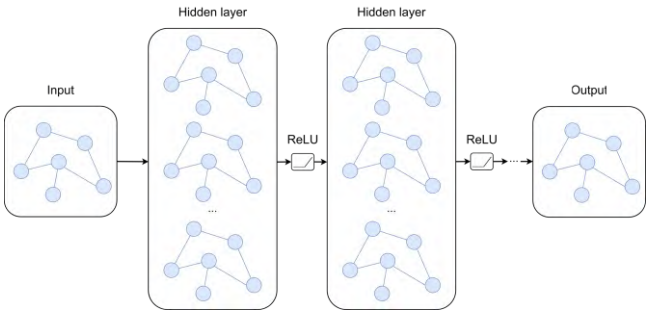

图 8 GNN 基本结构

Fig.8 Basic Structure of GNN

4 数据集和评估指标

4.1 数据集描述

图 9 显示了至少被两项研究使用过的公开数据集的使用比例。值得注意的是，目前可供下载的数据集主要来源于位置服务社交网络。由图 9 可知，在使用公开数据集的研究中，超过一半的研究使用了 Foursquare 和 Gowalla 平台的数据。相比之下，来自其他平台的数据在 POI 推荐中的应用相对有限。需要指出的是，这些平台提供的数据集在时间跨度、地理覆盖范围及其他特征方面存在不同的版本。

表 1 对比分析了 POI 推荐研究中常用的六种主要数据集，包括 Gowalla、Foursquare、Yelp、Weeplaces、Brightkite 和美团。从表 1 可以看出，这些数据集在内容结构、地理覆盖范围和特点上各有不同。其中 Gowalla 和 Foursquare 因其广泛的地理覆盖和丰富的签到信息成为研究中最常用的数据集；Yelp 提供了更多评价文本和评分数据，适合多模态研究；而美团数据集则因其覆盖中国多个城市的本地化特征，在国内研究中具有独特价值。

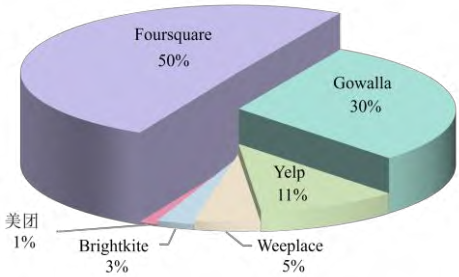

图 9 数据集使用比例

Fig.9 Percentage of data sets used

表 1 POI 推荐研究中常用数据集对比分析

Table 1 Comparative analysis of commonly used datasets in POI recommendation studies

数据集	来源平台	主要内容	地理覆盖范围	特点	适用研究
Gowalla[7]	Gowalla 社交网络平台	用户签到记录，包含用户 ID、签到时间、地点地理坐标和 POI 信息	全球多个地区	1)数据分布具有显著的地理和时间依赖 2)用户签到行为存在较大的个体差异 3)数据稀疏性较高	用户-POI 交互建模，地理和社交关系研究
Brightkite[9]	Brightkite 位置分享服务	用户签到行为，包含用户 ID、签到时间、地点 ID 及地理坐标，以及用户间的社交连接	全球范围	1)签到行为具有显著的地理依赖性 2)包含用户间的社交网络信息 3)数据稀疏性较高，但包含时间和位置特性	空间兴趣偏好研究，社交关系对 POI 推荐影响分析

Foursquare[17]	Foursquare 位置服务平台	用户签到记录，包含用户 ID、签到时间、地点 ID、地理坐标，部分版本含社交关系和地点类别信息	多个城市甚至国家	1)地点种类丰富，涵盖餐饮、购物、娱乐等多类别 2)地理分布广泛 3)包含时间、地理和社交等多层次关联性	个性化推荐，地理偏好建模，社交关系影响研究
Yelp[25]	Yelp 商户评价平台	用户对商家的评价信息，包含用户 ID、商家 ID、评分、评论文本、地理位置、时间戳等，以及图片、标签等辅助信息	主要覆盖北美地区	1)丰富的用户行为数据，如评分和评论文本 2)数据中地理和时间因素明显 3)商家类别和用户评价多样性高	多模态推荐，细粒度推荐，评论情感分析
Weeplaces[35]	多平台整合（Foursquare 等）	用户签到记录，包含用户 ID、签到时间、地点 ID、地理位置和 POI 类型	多个国家和地区	1)用户签到数据具有时间序列特性 2)地理位置分布广泛 3)数据稀疏性较高，包含隐含的社交关系和地理依赖性	用户时空偏好研究，基于上下文的推荐
美团[45]	中国美团本地生活服务平台	用户历史行为记录，包含用户 ID、POI ID、访问时间、地理位置信息、商家类别等，部分版本含评分、评论和商家标签	中国多个城市	1)数据量大且覆盖范围广 2)结合地理、时间和商家类别特征 3)多样化的商家类别和用户行为模式	个性化推荐，时空相关推荐，复杂场景研究

4.2 评估指标描述

图 10 展示了近三年内的 POI 推荐研究中常用的评估指标及其使用频率。从图 10 中可以看出，召回率（Recall）是最常用的评估指标，在研究中的使用比例达到 24.76%。其次是归一化折损累计增益（Normalized Discounted Cumulative Gain, NDCG），使用比例为 21.84%。平均倒数排名（Mean Reciprocal Rank, MRR）的使用比例为 14.56%。准确率（Accuracy）、命中率（Hit Rate, HR）和精确率（Precision）的使用比例分别为 11.17%、10.68%和 10.19%。此外，平均精度（Mean Average Precision, MAP）、曲线下面积（Area Under Curve, AUC）和均方根误差（Root Mean Squared Error, RMSE）的使用频率相对较低，为 0.97%。这些评估指标的选择反映了研究者在评估 POI 推荐系统性能时更关注推荐结果的相关性、排序质量和召回能力。

4.2.1 召回率

recall 反映了在用户实际访问的所有 POI 中，推荐系统成功预测出的 POI 比例，用于评估推荐系统发现用户 POI 的能力。对于用户 u，其召回率计算公式为：

$$Recall@K(u)=\frac{|R_u\cap T_u|}{|T_u|} \tag{10}$$

其中，K 表示推荐列表的长度，R_u 表示系统为用户 u 推荐的 Top-K 个 POI 集合，T_u 表示用户 u 在测试集中实际访问的 POI 集合，$|R_u\cap T_u|$表示推荐列表中命中用户实际访问 POI 的数量，$|T_u|$表示用户实际访问的 POI 总数。整体召回率为所有用户召回率的平均值：

$$Recall@K=\frac{1}{|U|}\sum_{u\in U}Recall@K(u) \tag{11}$$

其中 U 表示用户集合，$|U|$表示用户总数。

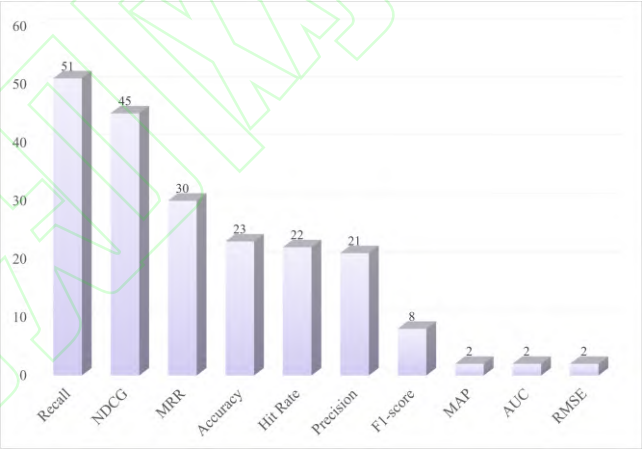

图 10 评估指标使用频率

Fig.10 Assessment of the frequency of use of indicators

4.2.2 归一化折损累计增益

NDCG 不仅考虑推荐是否准确，还考虑推荐结果的排序质量。该指标对排在前面的正确推荐给予更高的权重，体现了推荐系统对高相关性项的排序能力。对于用户 u，$NDCG$ 的计算分为两步：

首先计算 DCG（折损累计增益）：

$$DCG@K(u)=\sum_{i=1}^{K}\frac{2^{rel_i}-1}{\log_2(i+1)} \tag{12}$$

然后通过理想 DCG 值进行归一化：

$$NDCG@K(u)=\frac{DCG@K(u)}{IDCG@K(u)} \tag{13}$$

其中，K 表示截断位置，即考虑的推荐列表长度，i 表示推荐列表中的位置索引，rel_i 表示第 i 个推荐项的相关度分数，$IDCG@K(u)$ 表示理想情况下的 DCG 值，即将所有相关项按相关度降序排列后的 DCG 值，$\log_2(i+1)$ 是位置折损因子，用于降低排序靠后项的权重（$\log_2$—以 2

为底的对数）。

4.2.3 平均倒数排名

MRR 主要关注推荐系统将相关 POI 排在列表前面的能力，特别是第一个正确推荐的位置。该指标反映了用户找到第一个感兴趣 POI 所需要浏览的平均位置。计算公式为：

$$MRR = \frac{1}{|U|}\sum_{u\in U}\frac{1}{rank_u} \tag{14}$$

其中，$|U|$表示用户总数，U 表示用户集合，$rank_u$ 表示用户 u 的测试集中第一个 POI 在推荐列表中的排名位置，如果没有相关推荐，则该用户的倒数排名记为 0。

4.2.4 准确率

Accuracy 是一个全面衡量推荐系统预测准确程度的指标，它同时考虑了正确推荐和正确不推荐的情况。计算公式为：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \tag{15}$$

其中，TP 表示正确推荐的 POI 数量，TN 表示正确未推荐的 POI 数量，FP 表示错误推荐的 POI 数量，FN 表示错误未推荐的 POI 数量。

4.2.5 命中率

HR 衡量推荐系统至少预测对一个用户 POI 的能力，它反映了推荐系统的基本预测效果。计算公式为：

$$HR@K = \frac{1}{|U|}\sum_{u\in U} I(|R_u \cap T_u| > 0) \tag{16}$$

其中，K 表示推荐列表长度，$|U|$表示用户总数，U 表示用户集合，R_u 表示为用户 u 推荐的 POI 集合，T_u 表示用户 u 实际访问的 POI 集合，$I(\cdot)$为示性函数，当条件成立时取值为 1，否则为 0。

4.2.6 精确率

Precision 衡量推荐结果的准确性，它反映了推荐列表中有多大比例的 POI 是用户实际感兴趣的。对于用户 u，精确率的计算公式为：

$$Precision@K(u) = \frac{|R_u \cap T_u|}{|R_u|} \tag{17}$$

其中，符号含义表示同公式（1）。整体精确率为所有用户精确率的平均值：

$$Precision@K = \frac{1}{|U|}\sum_{u\in U} Precision@K(u) \tag{18}$$

其中$|U|$表示用户总数，U 表示用户集合。

4.2.7 其他评估指标

其他评估指标包括 F1 分数（F1-score）、MAP、AUC 和 RMSE。F1-score 是精确率和召回率的调和平均值，用于综合评估推荐系统的整体表现。MAP 计算多个查询的平均精度，再对所有查询求均值，以衡量推荐系统在多个用户上的整体精度。AUC 衡量模型区分正负样本的能力，表示 ROC 曲线下的面积，数值越大表明模型性能越好。RMSE 用于评估预测评分与真实评分的偏差，数值越小说明预测结果越接近真实值。

5 POI 推荐模型

5.1 基于序列建模的方法

5.1.1 基于 RNN 及其变体的模型（LSTM、GRU 等）

LSTM 和 GRU 能够有效处理用户的时序签到数据，学习用户的移动模式和位置偏好。表 2 总结了 RNN 及其变体在 POI 推荐中应用的优势、局限性及其相关工作。

Li 等人[7]提出的 BiLSTM-attention(Bidirectional Long Short-Term Memory- attention)模型通过嵌入层对用户签到序列和时空间隔信息进行向量化表示，并利用 BiLSTM 捕捉序列中的双向时序依赖。结合自注意力机制，模型对签到位置分配动态权重，从而优化用户偏好建模并输出包含三连贯位置的推荐序列。Lai 等人[8]提出的 AT-LSTM(Attention mechanism-Long Short-Term Memory)模型通过 LSTM 捕捉用户签到序列的时间特性，并引入注意力机制对短期偏好进行加权建模，从而融合用户的短期和长期兴趣特征。该模型有效缓解冷启动问题，提升了个性化推荐效果。Guo 等人[9]提出的 Deep-PR(Deep distributed-learning-based POI recommendation)模型通过混合自适应编码器和相关自适应编码器分别建模用户的局部和全局特征，并引入多轮迭代优化特征空间表达，从而提升推荐的精确性和鲁棒性。模型在移动边缘网络场景下实现高效的个性化 POI 推荐，并在多个真实数据集上显著优于传统基线方法。Wang 等人[10]提出的 DSDRec(Deep Semantic Diffusion Recommender)模型用于下一个 POI 推荐，该模型通过提示工程和预训练语言模型提取轨迹序列的深度语义特征，引入时空区域编码以捕捉全局时空关系，并改进扩散模型增强轨迹表示的抽象交互信息。结合语义信号和空间变换操作，模型实现更稳健的逆过程，显著提升推荐精度与鲁棒性。Sun 等人[11]提出的 STT(Spatiotemporal Trajectory)模型用于个性化下一个 POI 推荐。该模型通过

兴趣提取层编码用户时空轨迹特征，结合 LSTM 和注意力机制学习用户兴趣演变，并设计时空匹配层计算用户轨迹与候选 POI 的相关性。引入非线性信息衰减因子以反映用户兴趣随时间和距离的动态变化，显著提升推荐性能。Cai 等人[12]提出的 MMPAN(Multi-granular Mobility Preference Aware Network)模型通过多层网格划分将 POI 轨迹映射到不同尺度的区域，并结合 LSTM 建模用户的粗粒度（区域）和细粒度（POI）偏好。此外，该模型采用层次聚类对 POI 进行重新编码，以减少数据噪声，并通过 Beam Search 选择最佳推荐路径。

表 2 基于 RNN 及其变体的模型在 POI 推荐中的应用

Table 2 Application of RNN and its variants based models for POI recommendation

局限性	优势	相关工作
模型复杂度较高和存在隐私泄露风险	捕捉时空特征	BiLSTM-attention[7]
模型计算开销较大和社交关系未考虑	融合用户长期与短期偏好和捕捉时间序列特征	AT-LSTM[8]
模型计算复杂度高和依赖数据丰富度	深度融合内外特征和多轮迭代优化特征空间	Deep-PR[9]
模型计算复杂度较高手动配置提示模板	深度语义特征提取，时空区域编码和扩散模型增强	DSDRec[10]
模型计算复杂度较高和依赖时空信息的稀疏性	非线性时空信息建模和时空匹配模块设计	STT[11]
未考虑用户社交影响	多粒度用户偏好建模，轨迹噪声处理和动态区域偏好学习	MMPAN[12]
模型数据依赖性强和计算复杂度高	深度特征提取和注意力机制优化推荐	BERT-ACNN-GRU[13]
模型复杂度较高和未充分利用非结构化数据	将时空上下文与 GRU 结合有效缓解数据稀疏性问题	ATSD-GRU[14]
模型计算复杂度较高和对参数设置敏感	连续时间动态偏好建模，缓解数据稀疏性和噪声问题	CussCtpm[15]
时间因素处理不够精细	缓解数据稀疏性问题和提升特征提取能力	GSGRUN[16]
模型计算成本较高和依赖序列分割参数	融合时空与类别信息和序列分割与聚合	STCP[17]

Xia 等人[13]提出的 BERT-ACNN-GRU(Bidirectional Encoder Representations from Transformers-Attention-based Convolutional Neural Network-Gated Recurrent Unit)模型通过输入用户的 POI 签到序列（包含时间和位置信息），通过 BERT 提取文本的上下文特征，利用 ACNN 提取局部时空特征，结合 GRU 捕捉时序依赖关系，并通过注意力机制赋予关键特征更高权重，生成综合特征表示。最终，模型使用非线性激活函数计算 POI 分数并排序，输出 Top-N 推荐结果，提升推荐的精度和个性化。Jia 等人[14]提出的 ATSD-GRU(Attention-based Time Sequence and Distance Contexts Gated Recurrent Unit)模型通过结合时间序列和地理距离上下文信息，通过 GRU 捕捉用户在时空维度的个性化偏好，并引入注意力机制以动态赋权，重点关注用户行为中的主要意图。模型通过 Bayesian Personalized Ranking 框架训练，解决了数据稀疏问题。Qi 等人[15]提出的 CussCtpm(Counterfactual User Sequence Synthesis with Continuous Time Dynamic Preference Modeling)模型用于序列化 POI 推荐，结合连续时间动态偏好建模和反事实用户序列生成来应对数据稀疏和时间建模的挑战。通过将 GRU 与神经 ODE 结合，框架在连续时间空间中捕捉用户偏好的动态变化；同时，通过生成正反事实用户序列来增强数据表示的鲁棒性，并结合对比学习优化模型。Chang 等人[16]提出的 GSGRUN(Geographical-Spatiotemporal Gated Recurrent Unit Network)模型通过对用户签到数据的预处理与特征提取，模型引入对称矩阵分解以捕捉地理与类别静态特征，改进 CBOW 模型提取用户评论的语义特征，并结合历史签到数据动态建模用户偏好，从而显著提升推荐系统的精度与召回率。Peng 等人[17]提出的 STCP(Spatio-Temporal-Category Pattern)模型将用户签到数据的时空信息与类别序列进行融合，通过 GRU 捕捉长程依赖关系，并对序列进行分段与聚合，以提取子序列中的高阶语义信息。最终，利用 Softmax 和交叉熵损失函数进行预测优化。

基于 RNN 及其变体的模型在以下 POI 推荐场景中表现出色：1）时序依赖性强的场景：如连续 POI 推荐，用户的签到序列存在明显的时间依赖关系，LSTM 和 GRU 能有效捕捉长期和短期依赖；2）预测用户下一个可能访问位置的场景：模型可以学习用户的移动模式和偏好，适合旅游路线规划和日常出行推荐；3）结合时间感知的场景：如 AT-LSTM[8]模型适用于需考虑时间上下文的推荐任务，能够区分用户在不同时间段的偏好差异；4）资源受限环境：如移动边缘网络场景下，Deep-PR[9]等模型通过优化特征空间表达提供高效推荐。

5.1.2 基于 Transformer 的模型

表 3 总结了 Transformer 模型在 POI 推荐中应用的优势、局限性及其相关工作。

Zheng 等人[18]提出的 FCDT(Fine and Coarse grained user preferences with Dual-Transformer)模型用于同时捕捉用户的细粒度（POI 级别）和粗粒度（类别级别）移动偏好。该模型首先构建 POI 关系有向图，并使用 Gated Graph Neural Network 学习 POI 间的关联信息；随后，分别使用两个 Transformer 模块对 POI 序列和类别序列建模，并通过自适应加权方法融合两种偏好，以计算用户对 POI 的访问概率。Long 等人[19]提出的 DCPR(Diffusion-Based Cloud-Edge-Device Collaborative Learning for Next POI Recommendations)模型用于下一个 POI 推荐。该模型采用云-边-端协同架构，通过扩散模型捕捉用户的时空模式，在云端训练全局模型，并在区域边缘服务器进行本地化调整，随后将区域特定模型分发至用户设备进行个性化微调。该方法有效降低设备端计算负担，提高推荐的准确性、隐私保护能力和适应新用户与区域的能力。Jarrad 等人[20]提出的模型（本文称该模型为 EESM）利用 Word2Vec 生成 POI 的向量表示，并设计了 Jaccard Cosine 和 MRR Cosine 作为新的相似度度量，以更精确地计算轨迹间的相似性。在 Spark 分布式计算环境下进行实验，结果表明，基于嵌入的方法在推荐精度上优于传统基线方法，同时提高了数据稀疏情况下的鲁棒性。Xie 等人[21]提出的 STAR-HiT(Spatio-Temporal context AggRegated Hierarchical Transformer)模型采用分层 Transformer 结构，通过堆叠的层次化编码器递归编码时空上下文，并自适应地划分和聚合不同粒度的子序列，捕捉签到序列中的隐含层次结构。该模型结合全局注意力和局部注意力机制优化子序列表示，并利用 MLP 预测用户的下一个 POI 访问概率。Duan 等人[22]提出了一种基于双向 Transformer 的 POI 推荐模型 RTP-CM(Robust Travel Preference via Check-in Masking)，通过 check-in masking 策略提高模型的鲁棒性，以减少噪声数据的影响。该模型包含长短期偏好编码器，分别处理用户的长期出行习惯（采用随机 masking）和短期偏好（保留完整信息）。此外，引入区域预测辅助任务，利用 Geohash 层级地理编码预测用户的下一个活动区域，以缓解数据稀疏问题。Wang 等人[23]提出的 DSMR(Deep Semantic Model for the next POI Recommendation)模型用于学习离散轨迹数据的深层语义信息以优化 POI 推荐。该模型结合提示工程和预训练语言模型，通过自监督学习提取用户签到数据中的隐式语义特征，并结合时空信息编码提高轨迹嵌入质量。随后，利用自注意力网络预测用户的下一个 POI 访问概率。Wang 等人[24]提出的 STaTRL(Spatial-temporal and text representation learning)模型基于 Transformer 架构，通过整合用户签到序列中的时空信息和文本评论的情感分析结果，学习用户对 POI 的偏好。该模型采用多任务学习框架，同时进行未访问 POI 推荐和用户偏好学习，通过地理信息增强注意力机制，捕捉长期依赖关系，并利用情感分析挖掘用户对特定方面的偏好，从而提升推荐性能。

表 3 基于 Transformer 的模型在 POI 推荐中的应用

Table 3 Application of Transformer-based modeling to POI recommendations

局限性	优势	相关工作
模型模型复杂度高和依赖数据丰富度	捕捉用户的细粒度和粗粒度偏好	FCDT[18]
对区域划分的依赖	云边端协同架构和引入扩散模型	DCPR[19]
轨迹顺序依赖性和网格粒度敏感性	提高了数据密度和捕捉 POI 序列的上下文信息	EESM[20]
模型计算复杂度较高和依赖超参数设置	时空上下文融合建模和捕捉用户移动的层次化结构	STAR-HiT[21]
模型计算复杂度较高和依赖地理信息	噪声鲁棒性强和地理信息利用高效	RTP-CM[22]
模型计算复杂度较高和依赖预训练语言模型	深度融合语义信息和创新的时间间隔编码	DSMR[23]
模型计算复杂度高和文本处理受限	多模态融合和多任务学习	STaTRL[24]

基于 Transformer 的模型在以下 POI 推荐场景中表现出色：1）复杂长序列建模场景：当用户具有长期签到历史时，Transformer 的自注意力机制能够有效捕捉远距离依赖关系，适合旅游者长期行为分析；2）多粒度偏好建模场景：如 FCDT[18]模型适用于同时需要考虑用户细粒度（具体 POI）和粗粒度（POI 类别）偏好的场合；3）大规模分布式环境：如 DCPR[19]模型适用于云-边-端协同的推荐架构，适合资源差异化的实际部署环境；4）需要强语义理解的场景：如 DSMR[23]模型适合需要深度理解用户轨迹语义信息的推荐任务，例如跨城市旅游推荐；5）多模态融合场

景：如 STaTRL[24]模型适用于需要结合用户评论情感分析的 POI 推荐，例如餐厅和酒店推荐。

5.1.3 基于序列建模代表性方法的核心算法公式

BiLSTM-attention 模型[7]的核心工作原理：

$$\vec{h}_t = \mathrm{LSTM}(x_t, \vec{h}_{t-1})$$
$$\overleftarrow{h}_t = \mathrm{LSTM}(x_t, \overleftarrow{h}_{t-1}) \quad (19)$$
$$h_t = \omega_t \vec{h}_t + \varpi_t \overleftarrow{h}_t + b_t$$

其中，x_t 表示输入，指用户的历 u_z 史签到序列数据，$\vec{h}_t$ 表示前向 LSTM 的输出（箭头向右表示正方向），$\overleftarrow{h}_t$ 表示反向 LSTM 的输出（箭头向左表示负方向），$\vec{h}_{t-1}$ 表示前一时刻的前向 LSTM 状态，$\overleftarrow{h}_{t-1}$ 表示前一时刻的反向 LSTM 状态，h_t 表示 t 时刻的最终输出，即综合了前向和反向信息的隐藏状态，ω_t 表示前向输出的权重矩阵，ϖ_t 表示反向输出的权重矩阵，b_t 表示 t 时刻的偏置项/偏移量。

Deep-PR 模型[9]的核心工作原理：

1）局部特征编码公式：

$$\boldsymbol{L_{ij}} = \left[\boldsymbol{R_i^{(Co)(Q)}} \oplus \boldsymbol{R_j^{(Se)(Q)}} \right] \quad (20)$$

其中，$\boldsymbol{L_{ij}}$ 是用户和 POI 之间的参数代表向量，$\boldsymbol{R_i^{(Co)(Q)}}$ 是经过 Q 轮迭代后用户的上下文特征向量，$\boldsymbol{R_j^{(Se)(Q)}}$ 是经过 Q 轮迭代后 POI 的语义特征向量，⊕表示连接操作。

2）静态相关性公式：

$$F_3(u_i, u_z) = \sigma_1 \left[\alpha_{i,z}^{(st)} \cdot W_{G1} \cdot \| \boldsymbol{Q_i^{(st)}} - \boldsymbol{Q_z^{(st)}} \| + b_{G1} \right] \quad (21)$$

其中，$F_3(u_i, u_z)$ 是用户 u_i 和用户 u_z 之间的静态相关性，$\alpha_{i,z}^{(st)}$ 是他们之间的相关性权重，W_{G1} 是权重参数，b_{G1} 是偏置参数，$\boldsymbol{Q_i^{(st)}}$ 和 $\boldsymbol{Q_z^{(st)}}$ 是用户的静态特征向量，σ_1 是 ReLU 激活函数。

3）动态相关性公式：

$$F_4(u_i, u_z) = \sigma_1 \left[\alpha_{i,z}^{(dy)} \cdot W_{G5} \cdot \| \boldsymbol{X_i^{(dy)}} - \boldsymbol{X_z^{(dy)}} \| + b_{G5} \right] \quad (22)$$

其中，$F_4(u_i, u_z)$ 是用户 u_i 和用户之间的动态相关性，$\alpha_{i,z}^{(dy)}$ 是动态相关性权重，W_{G5} 是权重参数，b_{G5} 是偏置参数，$\boldsymbol{X_i^{(dy)}}$ 和 $\boldsymbol{X_z^{(dy)}}$ 是位置序列编码后的特征向量，σ_1 是 ReLU 激活函数。

4）预测交互结果公式：

$$\tilde{O}_{ij} = \sigma_2 \left\{ W_1 \cdot Z_L\left(u_i, p_j\right) \cdot \left[Z_g(u_i) \right]^T + b_1 \right\} \quad (23)$$

其中，$\tilde{O}_{ij}$ 是用户 u_i 和兴趣点 p_j 之间的预测交互结果，$Z_L\left(u_i, p_j\right)$ 是局部特征 MLP 编码后的结果，$Z_g(u_i)$ 是全局特征 MLP 编码后的结果，W_1 是权重参数，b_1 是偏置参数，σ_2 是 Sigmoid 激活函数。

5）待优化的目标函数：

$$B = \sum_{i=1}^{|u|} \sum_{j=1}^{|p|} \left\{ \lambda_3 \cdot \| \tilde{O}_{ij} - O_{ij} \|_F^2 + (1-\lambda_3) \cdot \| \Theta \|_F^2 \right\} \quad (24)$$

其中，B 是待优化的目标函数，$\tilde{O}_{ij}$ 是预测的交互结果，O_{ij} 是真实的交互结果，λ_3 是权衡参数(设为 0.6)，Θ 是模型参数集，$\|\cdot\|_F^2$ 是 Frobenius 范数。

5.2 基于注意力机制的方法

5.2.1 自注意力模型

在 POI 推荐任务中，自注意力模型可以有效地建模用户的历史轨迹序列，学习位置点之间的动态关联。表 4 总结了自注意力机制在 POI 推荐中应用的优势、局限性及其相关工作。

Xia 等人[25] 提出的模型（本文称该模型为 STEER-NPR）引入时空信息作为自注意力结构的偏置，以捕捉签到间的相对关系，并采用高效注意力计算策略，通过选择代表性查询项降低计算复杂度，从 $O(L^2)$ 降至 $O(LlnL)$（ln—以 e 为底的对数）。实验表明，该方法在提升推荐精度的同时，大幅减少内存和计算开销，使其更适用于移动设备环境。Du 等人[26]提出的 CTMR(Cross-Task Multimodal Reinforcement)模型用于解决长尾效应下的下一个 POI 推荐问题。该模型结合主任务和辅助任务中的区域信息，利用预训练编码器增强 POI 表示能力，并通过跨任务强化模块融合用户的全局偏好。轨迹编码器基于时空相关性学习用户的访问模式，同时结合注意力机制优化区域表示。Wang 等人[27]提出的 EEDN(Enhanced Encoder-Decoder Network)模型通过混合超图卷积编码器增强用户和 POI 的表示学习，避免冷启动用户传播低质量信息。解码器结合图结构和序列模式，捕捉本地和全局交互关系，以缓解隐式反馈问题。He 等人[28]提出的 ImNext(Irregular Interval Attention and Multi-task Learning for Next POI Recommendation)模型用于解决不规则时间间隔和数据稀疏问题。该模型采用 IrrAttention 机制捕捉签到序列中的

不规则时间和距离间隔信息，并结合 Edge-Attention Graph Attention Network 建模用户的时空-社交关系。通过多任务学习，模型同时优化时间、距离、历史访问模式及下一个 POI 推荐。Jiang 等人[29]提出的 LSPSL(Long- and Short-term Preferences via Self-supervised Learning)模型利用自监督学习优化用户行为表示，通过自注意力网络建模用户的长短期偏好，并结合上下文嵌入预训练增强数据表示能力。在训练过程中，引入关联上下文目标和遮蔽上下文目标，从时空信息中提取监督信号，以缓解数据稀疏问题。Tian 等人[30]提出的 MSAN(Multi-task and Self-Attention Network)模型结合空间-时间和语义序列模式，采用多任务学习框架，以用户访问意图预测作为辅助任务，优化 POI 推荐效果。模型通过层次语义编码器编码 POI 类别信息，并利用自注意力的空间-时间感知模块提取签到轨迹中的时空模式。最终，融合意图特征和轨迹特征进行推荐。Cheng 等人[31]提出的 BSA-ST-Rec(Point-of-Interest Recommendation based on Bidirectional Self-Attention Mechanism by Fusing Spatio-Temporal Preference)模型首先提取用户签到序列的时间间隔与空间距离信息，并通过嵌入层转换为时空融合表示。随后，利用双向自注意力机制捕捉用户动态兴趣，并结合多输入 Transformer 层进行特征建模，增强对全局和局部偏好的理解。Wu 等人[32]提出的 HAT(Hierarchical Attention Transformer)模型结合词级注意力和属性级注意力机制，以捕捉用户偏好的细粒度特征，并根据情感得分生成多样化的推荐理由。这种可解释性设计使用户能够理解推荐背后的逻辑，如"推荐这家餐厅是因为它的服务和氛围受到了高度评价"。模型采用 Transformer 结构，使用 BERT 词向量进行初始化，通过多头自注意力学习 POI 相关文本的特征表示，并结合情感分类实现情感多样性。Yang 等人[33]提出的 ExNext(An Ante-hoc Self-Explainable Framework for Next POI Recommendation)模型旨在同时提高推荐准确性和可解释性。该模型基于信息瓶颈理论，通过压缩冗余的时空轨迹数据来学习紧凑的表示，同时保持关键信息。ExNext 采用 Transformer 结构，结合时空编码、信息瓶颈模块和变分方法来学习子轨迹，从而减少无关信息，提高推荐效果。Ma 等人[34]提出的 SH-Rec(Sequential-Hierarchical Attention Neural Network based Recommendation)模型旨在建模用户的层次化意图特征和序列行为特征。SH-Rec 通过 LSTM 结合自注意力机制进行特征学习，捕捉用户历史签到数据中的层次化意图表示。同时，该模型使用记忆网络提取用户的序列偏好特征，并采用多任务学习策略，在优化目标中同时学习意图预测和签到预测，从而提升推荐性能。

自注意力模型在以下 POI 推荐场景中表现出色：1）高效推荐场景：如 STEER-NPR[25]模型适用于计算资源受限的移动设备环境，可降低计算复杂度；2）长尾分布数据场景：如 CTMR[26]模型适用于处理 POI 分布极度不均衡的情况，例如非热门旅游地区的推荐；3）冷启动场景：如 EEDN[27]模型通过混合超图卷积网络，适用于新用户和新 POI 的推荐任务；4）不规则访问模式场景：ImNext[28]模型适合处理用户签到间隔不规律的情况，如偶尔出行的用户；5）需要可解释性的场景：如 HAT[32]和 ExNext[33]模型适用于需要提供推荐理由的场合，例如商业 POI 推荐；6）需要建模层次化用户意图的场景：如 SH-Rec[34]模型适用于具有明确层次结构的推荐环境，如购物中心内的店铺推荐。

表 4 自注意力机制在 POI 推荐中的应用

Table 4 Application of self-attention mechanism in POI recommendation

局限性	优势	相关工作
模型复杂度仍较高和依赖时空信息	空间与时间信息的深度融合	STEER-NPR[25]
模型计算复杂度较高和依赖预训练编码器	跨任务多模态信息融合和长尾效应缓解	CTMR[26]
模型计算复杂度较高和依赖于图结构	处理冷启动问题和缓解曝光偏差问题	EEDN[27]
未处理冷启动问题和未解决数据不平衡问题	不规则间隔建模和多任务联合学习	ImNext[28]
模型计算复杂度较高和依赖预训练数据质量	深度挖掘时空上下文信息和统一建模长短时偏好	LSPSL[29]
模型复杂度较高和依赖高质量语义信息	时空语义融合和多任务学习框架	MSAN[30]
模型计算复杂度较高和依赖时空信息的准确性	时空信息融合和有效避免信息融合过程中的信息丢失	BSA-ST-Rec[31]
数据依赖性较强和新主题适应性有限	情感多样性增强和个性化推荐理由生成	HAT[32]
模型计算复杂度较高和信息压缩的平衡挑战	实现自我可解释性，提升准确率和降低冗余	ExNext[33]
模型计算复杂度较高和数据依赖性强	融合层次意图与序列行为和多任务学习优化推荐性能	SH-Rec[34]

5.2.2 多头注意力模型

在 POI 推荐中，多头注意力通过将注意力机制分为多个"头"，使模型能够并行地学习用户-POI 交互的多个表示空间，从而捕捉用户兴趣的多样性。表 5 总结了多头注意力机制在 POI 推荐中应用的优势、局限性及其相关工作。

现有研究基于多头注意力的优势提出了多种创新模型。Wang 等人[35]提出的 CCDSA(Context- and Category-aware Double Self-Attention)模型通过双重自注意力机制，同时捕捉用户的细粒度 POI 偏好（用户签到行为中的 POI 偏好）和粗粒度类别偏好（POI 的类别信息）。模型结合用户签到行为和 POI 类别信息，缓解数据稀疏问题，并利用上下文信息（时间、地理等）进行个性化推荐。此外，CCDSA+进一步引入稀疏自注意力机制，提升训练效率。Qian 等人[36]提出的 STSCL (Enhancing Spatio-Temporal Semantics with Contrastive Learning)模型通过预训练-微调架构，结合时空对比学习来提升 POI 推荐性能。模型首先通过时空信息划分用户签到序列，生成更具连贯性的子序列，并利用三种对比学习目标（POI 之间的空间语义、子序列之间的时间语义、序列转换的上下文一致性）来优化 POI 表示，从而有效提升推荐准确性并缓解数据稀疏问题。Cao 等人[37]提出的 TGSTAN(Trajectory Graph enhanced Spatial–Temporal aware Attention Network)模型结合轨迹感知动态图卷积网络和间隔感知自注意力机制，通过构建局部轨迹图来建模 POI 之间的结构特征，并利用图卷积网络进行动态用户偏好学习。此外，TGSTAN 采用双线性插值方法处理空间-时间信息，以增强 POI 之间的相关性，并通过目标感知交叉注意力机制优化推荐精度。Kong 等人[38]提出的 KGNext(Knowledge-Graph-Enhanced Transformer)模型用于处理带有不确定签到记录的下一个 POI 推荐。KGNext 通过构建过渡-交互知识图，结合用户、POI 及 POI 类别信息，利用知识图嵌入生成过渡和交互图，捕捉用户偏好和 POI 之间的层次关系。随后，模型采用图卷积网络进行特征提取，并使用 Transformer 编码用户轨迹信息进行 POI 推荐。Li 等人[39]提出的 LLAMA2-7b 利用预训练的 LLM 处理 LBSN 数据中的丰富上下文信息。该模型将 POI 推荐任务转换为问答任务，采用轨迹提示保持异构数据的原始格式，并结合键-查询相似性以解决冷启动问题。模型使用监督微调优化 LLM，使其理解 POI 之间的时空关系。Zheng 等人[40]提出的 MUPT(Modeling Multi-factor User Preferences based on Transformer)模型采用全局 POI 关系建模、本地多因素用户偏好建模和预测模块三部分。首先，使用门控图神经网络构建 POI 关系图，学习全局 POI 语义。其次，利用三个 Transformer 编码器分别建模用户在 POI、类别和时间层面的偏好，以学习个性化的移动模式。最后，采用自适应加权求和方法结合多个偏好，预测用户的下一个 POI。Cai 等人[41]提出的 PAPR(Periodic Aware Spatial temporal Network for POI Recommendation)模型基于 Transformer 结构，采用多头注意力机制建模用户访问 POI 的复杂转移模式，并引入周期感知间隔矩阵作为注意力机制的归纳偏置，以显式捕捉用户的周期性行为。此外，模型提出了一种地理距离损失函数，通过优化 POI 推荐的地理空间一致性，提高推荐精度。Liu[42]提出的模型（本文称该模型为 MHA）将 POI 特征分为固有属性（地理位置、类别）和语义相关特征（用户访问行为），分别通过约束矩阵分解和词向量模型提取特征，并融合成 POI 表示。随后，利用多头注意力机制提取用户偏好，并通过深度学习框架建模用户与 POI 之间的非线性交互。Zhang 等人[43]提出 DTCN-EFFN-Transformer(Depthwise Temporal Convolutional Network-Expand Factor Feed-Forward Network-Transformer)利用深度时间卷积网络提取用户签到记录的局部特征，并通过 Transformer 的多头自注意力机制捕捉全局特征，同时扩展因子前馈网络通过扩展中间层维度增强模型的非线性表达能力，提高长距离依赖建模能力。最终，模型结合用户偏好、地理位置和 POI 热度，生成精准的 POI 推荐列表。Niu 等人[44]提出了一种结合时空信息和社交信息的 POI 群组推荐(STSPGR(Spatial, Temporal, and Social fused POI Group Recommendation)）模型，用于提升群体用户的 POI 访问预测能力。该模型整合用户的历史签到行为、社交关系、地理位置和时间因素，并采用 GNN 与注意力机制来建模用户偏好和群体决策。模型引入用户-POI 交互图，通过多层图卷积网络提取特征，并利用注意力机制加权群体偏好，最终生成个性化 POI 推荐。

多头注意力模型在以下 POI 推荐场景中表现出色：1）多维度信息融合场景：如 CCDSA[35]模型适用于需要同时考虑 POI 偏好和类别偏好的场合，例如旅游景点分类推荐；2）数据稀疏环境：如 STSCL[36]模型通过时空对比学习，适用于用户签到数据稀疏的情况；3）动态轨迹建模场

景：如 TGSTAN[37]模型适合捕捉用户轨迹中的动态变化，适用于城市通勤路线推荐；4）不确定性签到场景：如 KGNext[38]模型适用于处理签到记录存在不确定性的情况，例如 GPS 定位误差较大的环境；5）低资源环境下的大模型应用：如 LLAMA2-7b[39]模型适用于需要深度语义理解但计算资源有限的场景；6）周期性行为建模场景：如 PAPR[41]模型适合捕捉用户的周期性访问模式，例如日常通勤和周末休闲场所推荐。

5.2.3 基于注意力机制代表性方法的核心算法公式

ExNext 模型的核心工作原理：

1）信息瓶颈理论基础公式：

$$Z = \arg\min_{Z} -I(Z;Y) + \beta I(Z;X) \tag{25}$$

其中，Z 表示输入数据 X 的表示，Y 表示目标（即下一个 POI），$I(Z;Y)$表示 Z 和 Y 之间的互信息，表示表示与目标之间的相关性，$I(Z;X)$表示 Z 和 X 之间的互信息，表示压缩程度，β 是拉格朗日乘子，用于平衡充分性和最小性的权衡参数。

2）POI 推荐的自解释公式：

$$T_{\mathrm{IB}}^{*} = \arg\min_{T_{\mathrm{IB}}} -I(T_{\mathrm{IB}};Y) + \beta I(T_{\mathrm{IB}};T) \tag{26}$$

其中，T 表示用户的轨迹，Y 表示标签（下一个 POI），T_{IB} 表示解释，由任务相关的签到和特征组成，$I(T_{\mathrm{IB}};Y)$ 表示解释与目标标签之间的互信息，$I(T_{\mathrm{IB}};T)$ 表示解释与完整轨迹之间的互信息，β 是用于平衡这两项的拉格朗日乘子。

表 5 多头注意力机制在 POI 推荐中的应用

Table 5 Application of multi-attention mechanism in POI recommendation

局限性	优势	相关工作
模型复杂度较高和对数据噪声敏感	双重视角偏好捕捉和高效稀疏性处理	CCDSA[35]
模型计算复杂度较高和对比学习依赖性强	多维度语义增强	STSCL[36]
模型复杂度高和信息泄露风险	捕捉用户轨迹中的时空依赖性和动态偏好变化	TGSTAN[37]
模型计算复杂度较高和依赖知识图谱质量	处理不确定签到记录和捕捉复杂交互模式	KGNext[38]
受限于上下文长度和预训练语料	缓解冷启动和短轨迹问题	LLAMA2-7b[39]
模型复杂度高和依赖数据质量	多因素偏好建模，全局与局部信息融合	MUPT[40]
模型计算复杂度较高和对稀疏数据适应性有限	捕捉用户访问的周期性规律和确保地理空间一致性	PAPR[41]
模型复杂度较高和未考虑时间因素	多特征融合与数据稀疏性缓解	MHA[42]
模型复杂度较高和未考虑情境信息	增强非线性表达能力，局部与全局特征融合	DTCN-EFFN-Transformer[43]
模型复杂度较高和数据稀疏性问题未充分解决	融合多源信息和动态聚合偏好	STSPGR[44]

3）总损失函数：

$$\begin{aligned}\mathcal{L}_{\mathrm{IB}} = \mathcal{L}_{ce}(Y, \mathbb{P}_{\Theta}(\hat{Y} \mid T_{\mathrm{IB}})) + \\ \beta \mathcal{L}_{KL}(\mathbb{Q}(T_{\mathrm{IB}} \mid T), \mathbb{P}(T_{\mathrm{IB}}))\end{aligned} \tag{27}$$

其中，$\mathcal{L}_{ce}$ 表示交叉熵损失，用于优化预测准确性，$\mathcal{L}_{KL}$ 表示散度损失，用于优化表示压缩，Y 表示真实的下一个 POI，$\hat{Y}$ 表示预测的下一个 POI，$\mathbb{P}_{\Theta}$ 表示参数化的预测模型，$\mathbb{Q}(T_{\mathrm{IB}} \mid T)$ 表示后验分布，$\mathbb{P}(T_{\mathrm{IB}})$ 表示先验分布，β 表示调节这两个损失项权重的超参数。

4）特征选择公式：

$$X_{\mathrm{IB}} = \{X_i \odot M_X, i = 1, \cdots, |X|\} \tag{28}$$

其中，X_{IB} 表示筛选后的签到特征，X_i 表示原始特征，M_X 表示可学习的二元特征掩码，$\odot$表示 Hadamard（元素级）乘积。

5）结构学习公式：

$$Seq_{\mathrm{IB}} = \{Seq_{u,v} \odot M_{Seq}, u, v = 1, \cdots, |X|\} \tag{29}$$

其中，Seq_{IB} 表示筛选后的序列结构，$Seq_{u,v}$ 表示原始序列结构中节点 u 和 v 之间的连接，M_{Seq} 表示可学习的连接掩码。

PAPR 模型的核心工作原理：

1）周期相关矩阵计算公式：

$$r_{ij} = \Delta wday + \Delta clock \tag{30}$$

其中，r_{ij} 表示第 i 次访问和第 j 次访问之间的周期相关度，$\Delta wday$ 表示星期间隔，$\Delta clock$ 表示小时间隔。

2）周期感知多头注意力机制：

$$A = Softmax\left(\frac{\boldsymbol{QK}^T}{\sqrt{d}} + \boldsymbol{R}\right)\boldsymbol{V} \tag{31}$$

其中，$\boldsymbol{Q}$ 是查询矩阵，$\boldsymbol{K}$ 是键矩阵，$\boldsymbol{V}$ 是值矩阵，$\boldsymbol{R}$ 是标准化后的周期相关矩阵，d 是隐藏层维度，A 是注意力输出。

3）目标感知注意力解码器：

$$\boldsymbol{S}=TAAD\left(\boldsymbol{F_n}\mid \boldsymbol{C}\right)=Attn(\boldsymbol{C},\boldsymbol{F_n},\boldsymbol{F_n}) \quad (32)$$

其中，$\boldsymbol{C}$ 是候选 POI 集的表征矩阵，$\boldsymbol{F_n}$ 是周期感知多头注意力模块的输出矩阵，$\boldsymbol{S}$ 是用户偏好的表征矩阵。

4）距离损失函数：

$$loss_{dist}=\sum_{S^u\in S}\sum_{i=1}^{n}(Pr\times dist(pred,tar,\Theta)) \quad (33)$$

其中，$pred$ 是预测的 POI，Pr 是预测 POI 对应的概率值，tar 是目标 POI，Θ 是当预测距离小于 1km 时的衰减权重，$dist(\cdot)$ 是计算目标 POI 和预测 POI 之间的地理距离。

5）总损失函数：

$$loss_{total}=loss_{cross}+\alpha\times loss_{dist} \quad (34)$$

其中，$loss_{cross}$ 是交叉熵损失，$loss_{dist}$ 是距离损失，α 是一致性权重，论文中取值为 0.01。

5.3 基于图结构的方法

5.3.1 静态图神经网络模型

静态图神经网络模型通过构建用户-POI 交互的固定拓扑结构，有效捕捉实体间的静态关联模式。表 6 总结了静态图神经网络模型在 POI 推荐中应用的优势、局限性及其相关工作。

Qin 等人[45]提出的 DisenPOI(Disentangled dual-graph framework for Point-of-Interest Recommendation)模型是一种用于 POI 推荐的双图 disentangled 框架，它分别构建了地理图和序列图，以显式建模 POI 访问的地理影响和序列影响。模型采用序列感知和地理感知的图传播机制，并利用对比学习实现两种影响的解耦。用户访问偏好由自监督信号指导，帮助模型生成可解释的 POI 推荐。Zhang 等人[46]提出的 HKGNN(Hyper-Relational Knowledge Graph Neural Network)模型是一种基于超关系知识图的神经网络模型，旨在提升下一个 POI 推荐的效果。该模型构建了一个超关系知识图，包含用户签到、社交关系及 POI 侧信息，并利用超图神经网络捕捉其中的高阶关系。此外，模型结合知识感知自注意力编码器和时空注意力解码器，提取用户的访问序列信息，以提高推荐的个性化和准确性。Wang 等人[47]提出的 IAGNN(Intent Aware Graph Neural Network)模型是一种基于意图感知的图神经网络模型，专用于 POI 嵌入和推荐。该模型首先将用户的签到序列建模为有向图，并利用门控图神经网络学习 POI 的嵌入表示。同时，设计了层次化注意力网络捕捉用户的全局和局部偏好，并引入基于可分解表示的用户意图感知模块，以挖掘用户的多重访问意图。最终，结合用户偏好和意图信息，实现个性化 POI 推荐。Liu 等人[48]提出的 ITGCN(Interaction-Enhanced and Time-Aware Graph Convolutional Network)模型是一种针对连续 POI 推荐的模型，专门用于旅游企业。模型首先构建用户-POI 交互图，并利用图卷积网络提取高阶连接信息。此外，ITGCN 结合自注意力聚合器，能够动态建模 POI 访问的时序信息，并优化用户偏好表示。Chen 等人[49]提出的 IRLM(Inductive Representation Learning Model)模型是一种归纳式表示学习模型，专门用于个性化 POI 推荐。该模型首先通过高斯混合模型提取 POI 的地理特征，随后利用图神经网络学习用户与 POI 之间的局部上下文信息。此外，IRLM 采用随机游走方法重构用户-POI 交互图，以缓解数据稀疏问题，并引入自注意力机制优化表示学习。Liu 等人[50]提出的 KDRank(Knowledge-driven user-aware POI Recommendation)模型是一种基于知识驱动的用户感知 POI 推荐模型。该模型首先构建用户-POI 知识图谱，利用交叉嵌入方法提取用户偏好低维表示，并通过知识聚合模块融合用户签到信息与偏好知识。此外，KDRank 通过构建用户-POI 知识图谱，不仅提升了推荐性能，还增强了模型的可解释性。模型能够追踪知识流动路径，展示推荐结果与用户历史行为之间的显式联系，从而为用户提供更透明的推荐理由。Wu 等人[51]提出的 MGAN(Multi-channel Graph Attention Network)模型是一种多通道图注意力网络。该模型首先构建多个基于用户签到数据的图，包括时间、地理、语义和社交图，以捕捉用户多维度的访问偏好。然后，MGAN 通过图注意力网络学习 POI 的嵌入表示，并利用多通道特征融合模块将不同维度的信息整合，最终通过用户签到历史及相似用户的偏好估算个性化 POI 推荐。Han 等人[52]提出的 NDRM(Neighbor-Discovery Recurrent Model)模型首先通过邻居发现机制利用 POI 的类别信息筛选邻近位置，以减少数据稀疏性影响。然后，NDRM 构建用户签到轨迹的图结构，并采用图卷积网络提取空间特征。同时，基于 LSTM 处理用户的时间序列行为，以增强 POI 推荐的时空一致性。Zhao 等人[53]提出了一种时间感知的图神经网络模型（本文称该模型为 STMGNN），旨在

通过建模用户的短期、中期和长期偏好，实现更精准的 POI 推荐。该模型利用知识图学习长期兴趣，使用 GAT 处理短期会话信息，并通过周图构建中期兴趣建模。最终，STMGNN 通过门控融合机制整合三种偏好信息，并通过注意力机制优化 POI 推荐。Liu 等人[54]提出的 CGNN-PRRG(Cooperative Graph Neural Networks for POI Recommendation for Random Groups)模型是一种基于合作图神经网络的 POI 推荐模型，专门用于随机群体。首先，模型利用拟合表示学习方法生成随机群体的表示，并通过余弦相似度选取相似用户的 POI 交互数据，以克服冷启动问题。随后，模型采用边学习增强的二分 GNN 学习相似用户的 POI 交互偏好，并结合基于会话的 GNN 建模 POI 迁移偏好。最终，通过整合群体表示和 POI 表示，实现精准 POI 推荐。Liu 等人[55]提出的 PriGCN(Privacy-preserving point-of-interest recommendation method based on simplified Graph Convolutional Network)模型是一种基于简化图卷积网络的 POI 推荐模型。首先，模型使用生成式方法合成包含用户偏好的 POI 数据，以替换原始数据中的敏感信息。随后，PriGCN 采用奇异值分解替代传统 GCN 计算，提高效率并缓解过度平滑问题。Lian 等人[56]提出的 GELS(Graph Autoencoders and Long Short-term preferences)模型是一种结合图自动编码器与长短期偏好建模的 POI 推荐模型。首先，该模型构建 POI 访问关系图，并利用 GAE 提取 POI 之间的潜在联系，以缓解数据稀疏问题。其次，GELS 采用多头自注意力机制提取用户长期偏好，同时使用双向 GRU 学习短期偏好，并通过加权融合策略综合两种信息。最后，基于 POI 嵌入和用户个性化偏好计算访问概率，生成推荐列表。Mo 等人[57]提出的 SEDC-GCN(Sampling-based Epoch Differentiation Calibrated Graph Convolution Network)模型是一种基于采样差异化的校准 GCN 模型，旨在提高 POI 推荐的准确性和校准性。该模型在 GCN 训练过程中引入分层采样机制，通过对 POI 访问分布进行近似，使推荐列表的类别或地理分布与用户历史访问习惯保持一致。模型由三层 GCN 组成，第一层代表用户的历史签到，第二层桥接用户的历史签到（第一层）与候选 POI（第三层），第三层包含候选 POI，并采用采样校准策略优化 POI 的类别和地理比例分布。

静态图神经网络模型在以下 POI 推荐场景中表现出色：1）关系解耦场景：如 DisenPOI[45]模型适用于需要区分地理影响和序列影响的场合，例如区分用户对 POI 的兴趣是源于地理便利还是真实偏好；2）丰富关联信息场景：如 HKGNN[46]模型适合整合签到、社交关系及 POI 侧信息的推荐任务，例如社交驱动的 POI 发现；3）多意图建模场景：如 IAGNN[47]模型适用于需要捕捉用户多重访问意图的场合，例如综合商场内的多功能区域推荐；4）连续 POI 推荐场景：如 ITGCN[48]模型专为旅游企业的连续景点推荐设计，适合旅游路线规划；5）冷启动场景：如 IRLM[49]模型通过归纳式表示学习，适用于处理新用户和新 POI 的推荐问题；6）需要可解释性的场景：如 KDRank[50]模型适合需要向用户提供透明推荐理由的任务；7）私密数据环境：如 PriGCN[55]模型适用于对用户位置隐私有严格要求的推荐场景，例如医疗机构或敏感场所推荐。

表 6 静态图神经网络模型在 POI 推荐中的应用

Table 6 Application of static graph neural network modeling to POI recommendation

局限性	优势	相关工作
模型训练复杂度高和依赖地理信息	解耦地理与序列影响和提升推荐可解释性	DisenPOI[45]
模型复杂度较高和依赖丰富侧信息	缓解数据稀疏性问题和捕捉复杂时空语义	HKGNN[46]
模型计算复杂度较高以及依赖数据质量和数量	用户意图感知和全局与局部偏好融合	IAGNN[47]
隐私保护缺失和数据稀疏性问题未解决	动态时效性建模和高阶交互关系捕捉	ITGCN[48]
模型计算复杂度较高和依赖地理分布假设	解决冷启动问题和缓解数据稀疏性问题	IRLM[49]
模型计算复杂度较高和依赖知识图谱质量	增强模型的可解释性和提升 POI 推荐的个性化与准确性	KDRank[50]
模型复杂度较高和依赖手工特征工程	多源信息融合和挖掘上下文信息的交互作用	MGAN[51]
模型计算成本较高和依赖数据质量	缓解数据稀疏性问题和提高 POI 推荐准确性	NDRM[52]
模型复杂度较高和数据时效性限制	整合长短中期偏好和提升 POI 推荐准确性	STMGNN[53]
未充分利用上下文信息和对新随机组的适应性有限	克服冷启动问题和解决随机组的 POI 推荐问题	CGNN-PRRG[54]
未解决冷启动问题和依赖数据预处理	隐私保护与个性化推荐兼顾，高效图卷积与抗过平滑能力	PriGCN[55]
模型计算复杂度较高和依赖图结构质量	解决数据稀疏性问题和融合长短时偏好	GELS[56]
模型时间复杂度较高和空间复杂度较大	灵活的跨领域适应性和直接优化校准与准确性	SEDC-GCN[57]

5.3.2 时空图神经网络模型

时空图神经网络模型能够同时捕捉用户行为序列中

的时间动态性和 POI 之间的空间地理关系，有效解决传统推荐模型难以处理复杂时空依赖关系的问题。表 7 总结了时空图神经网络模型在 POI 推荐中应用的优势、局限性及其相关工作。

Fang 等人[58]提出的 Graph-POIR(Graph-based POI Recommendation)模型首先构建用户-POI 交互图和用户社交图，结合用户的一阶和高阶社交关系，通过 GNN 学习用户和 POI 的嵌入向量。同时，采用谱聚类方法提取 POI 的地理位置特征，并与用户-POI 交互信息融合。最终，利用神经协同过滤进行评分预测，并筛选 Top-K POI 进行推荐。Wang 等人[59]提出的 AGRAN(Adaptive Graph Representation-enhanced Attention Network)是一种自适应图表示增强注意力网络模型。传统方法依赖预定义的 POI 关系图来建模用户偏好，但这种静态图结构往往难以准确刻画复杂的地理依赖关系。AGRAN 通过图结构学习，动态优化 POI 之间的地理关系图，生成更具表达能力的 POI 嵌入表示。同时，该方法结合自注意力机制，融合空间-时间信息建模用户动态偏好。此外，AGRAN 设计了一种图正则化机制，用于减少噪声并增强 POI 关系学习。Fu 等人[60]提出的 SLS-REC(Self-supervised Long-and Short-term)模型结合时空超图卷积网络捕捉用户的短期动态兴趣，并设计动态信息传播机制学习 POI 之间的不对称地理影响。此外，引入对比学习框架，通过细粒度节点丢弃策略增强短期和长期兴趣表示的互信息，并通过注意力机制自适应融合推荐任务与自监督任务。Lai 等人[61]提出的 DCHL(Disentangled Contrastive Hypergraph Learning)模型采用多视角解耦超图学习，构建协同超图、转换超图和地理超图，分别建模用户-POI 的协同关系、访问模式和地理依赖。然后，设计超图卷积网络，对用户和 POI 进行信息传播，解耦不同视角的兴趣表示。同时，DCHL 引入跨视角对比学习，通过自增强机制强化不同视角之间的互信息，以捕捉互补性推荐信号。最后，采用自适应融合机制，平衡不同视角的信息，生成用户的个性化嵌入表示。Qin 等人[62]提出的 DIG(Disentangled embedding of user Interest and POIs' Geographical information)是一种地理影响解耦的 POI 推荐方法，旨在区分用户兴趣和地理因素对 POI 推荐的影响。DIG 采用解耦表示学习，分别构建兴趣空间和地理空间，通过地理约束负采样策略筛选负样本以强化解耦效果。此外，模型设计了一种地理增强的软加权损失函数，自适应平衡兴趣因素和地理因素的影响。在用户-POI 交互图上，DIG 使用 GNN 传播信息，并通过内积评分机制生成 POI 推荐结果。Mo 等人[63]提出的 EPT-GCN(Edge propagation-based time-aware graph convolution network)模型通过时间子图挖掘，将用户签到数据划分为多个时间段的子图，以建模时间对 POI 访问的影响。同时，提出边传播模块，在不同时间子图间传播用户的时间偏好，以提升 POI 推荐的准确性。此外，模型采用无监督学习机制调整边的归属，提高时序信息的利用效率。Zeng 等人[64]提出的 CrossDR-Gen(Cross-sequence Location Disentanglement Representation learning method with explanation generation)模型是一种面向可解释性 POI 推荐的模型，采用跨序列时空解耦表示学习。它构建空间和时间关系图，并使用 GNN 提取全局 POI 过渡模式。该模型结合对比学习实现时空因素解耦，同时利用大语言模型生成伪用户档案，以增强推荐可解释性。最终，通过频域学习优化序列建模，结合用户个性化信息，提高 POI 推荐的准确性和可解释性，在冷启动场景下表现出色。Zeng 等人[65]提出的 HyperSE(Global and Local Hypergraph Learning Method with Semantic Enhancement)模型是一种结合超图神经网络和语义增强的 POI 推荐模型。该模型从全局和局部两个视角构建超图，以捕获用户群体的高阶行为模式和短期访问轨迹。它利用预训练语言模型（如 BERT 或 BART）提取 POI 语义信息，并通过融合语义和拓扑特征，优化用户行为建模。最终，模型结合超图卷积和序列建模，提高 POI 推荐的准确性和泛化能力，在多个基准数据集上表现优异。Wang 等人[66]提出的 GSTA-GNN(Global Spatio-Temporal Aware Graph Neural Network)模型通过全局空间图和全局时间图建模 POI 之间的关系，突破了传统方法仅考虑局部时空关系的限制。GSTA-GNN 首先将所有用户的轨迹数据整合，利用 GNN 学习全局 POI 表示。然后，引入时空权重矩阵，将 POI 之间的空间和时间间隔转化为权重，并在多头自注意力层中自适应地融合，以增强用户轨迹的个性化表示。Sun 等人[67]提出的 MARAN(Multiple Active Region Aware Network)模型通过构建中心化图结构建模用户的稳定日常出行模式，并结合短期轨迹模块捕捉用户最近的兴趣偏好。该模型设计了邻域感知负采样器，动态调整负样本候选区域，缓解数据稀疏性问题。此外，MARAN 采用图卷积网络和注意力机制聚合空间信息，并结合 LSTM 建模时

间序列特征。Gan 等人[68]提出的 MGCAN(Multi-Graph Convolutional Attention Network)模型采用多图卷积网络结合独立注意力网络，分别建模地理-时间因素、用户评论信息和 POI 热度特征等多个影响因素，形成多种序列模式。同时，模型使用上下文注意力机制区分不同因素对用户行为的影响，并结合用户的一般偏好优化 POI 推荐。Li 等人[69]提出的 MoveFormer(Spatial Graph Periodic Injection Network)模型在图卷积网络中引入周期特征注入机制，通过距离和方向编码，增强 POI 之间的空间关系建模能力。此外，MoveFormer 设计了用户偏好注意力网络，分别建模语义、空间和访问频率三种用户偏好，并通过快速傅里叶变换提取频率信息，以提升推荐准确性。最后，MoveFormer 采用扩展-聚合结构，整合多尺度信息并优化 POI 推荐。Tao 等人[70]提出的 CrossDR(Cross-sequence Location Disentanglement Representation)模型通过跨序列图学习解耦用户签到序列中的空间和时间影响，以捕捉更具全局视角的 POI 过渡模式。该模型首先构建空间关系图和时间关系图，通过 GNN 提取解耦特征，并采用自注意力机制优化空间和时间影响的区分度。此外，CrossDR 结合对比学习，进一步增强 POI 过渡的解耦效果，并通过频域学习去除噪声，提高推荐准确率。Yin 等人[71]提出的 SNPM(Sequence-based Neighbour search and Prediction Model)模型采用 RotatE 知识图嵌入和 Eigenmap 方法构建 POI 关系图，以挖掘签到数据中的潜在 POI 关系。然后，利用序列动态邻域图自适应地选择 POI 邻域信息，增强对 POI 之间关系的理解。此外，模型采用多步依赖预测，显式建模用户历史轨迹中的长期依赖关系，以优化 POI 推荐。Wang 等人[72]提出的 DRPR(Dynamic Reinforced POI Recommendation)是一种基于动态地理-人类交互学习的在线 POI 推荐模型，旨在实时建模用户和地理环境的交互关系。模型采用深度交互强化学习方法，将用户和地理实体（POI、POI 类别、功能区域等）构建为动态知识图，并通过表示学习模块捕捉环境状态，再由模仿学习模块模拟用户的访问行为，优化 POI 推荐。该模型利用基于元路径的 POI 候选集生成方法减少动作空间，并设计了退出机制动态维护知识图，降低计算复杂度。Xu 等人[73]提出的 MobGT(Mobility Graph Transformer)模型通过全局和局部图建模用户的出行模式，分别构建空间、时间和 POI 类别三种全局图，学习 POI 之间的地理、时间和语义关系。此外，该方法采用图变换器，用于捕捉局部出行图中的高阶依赖关系。为解决 POI 数据中的长尾问题，MobGT 设计了一种 Tail Loss 损失函数，以提升低频 POI 的推荐性能。Yan 等人[74]提出的 STHGCN(Spatio-Temporal HyperGraph Convolutional Network)模型采用超图神经网络建模用户轨迹，区分用户内部和跨用户轨迹协同关系，捕捉高阶 POI 访问模式。此外，该模型引入超图变换器，统一节点-超边和超边-超边信息传播，并利用时空编码模块结合时间间隔和地理距离优化嵌入表示。Liu 等人[75]提出的 STGIN(Spatial-Temporal Graph Interaction Network)一种时空图交互网络，用于大规模 POI 推荐的模型。STGIN 采用多视角子图表示学习，分别构建空间、时间、时空和全局子图，精准建模用户兴趣的动态变化。此外，该模型设计了一种工业级实时兴趣感知机制，结合用户历史行为序列与最新点击行为，自适应融合多视角兴趣信息，提高 POI 推荐的实时性。

时空图神经网络模型在以下 POI 推荐场景中表现出色：1）社交网络驱动场景：如 Graph-POIR 模型[58]适用于需要考虑用户社交关系影响的推荐，例如基于好友访问历史的 POI 发现；2）地理依赖性建模场景：如 AGRAN 模型[59]通过动态优化 POI 地理关系，适合城市区域内的近距离 POI 推荐；3）短期动态偏好场景：如 SLS-REC 模型[60]适用于捕捉用户短期兴趣快速变化的情况，例如旅游者在陌生城市的行为；4）解耦视角建模场景：如 DCHL[61]和 DIG[62]模型适合需要分离不同影响因素的推荐任务，例如区分用户对餐厅的偏好是基于口味还是便利性；5）冷启动跨域场景：如 CrossDR-Gen[64]模型适用于冷启动条件下的跨区域推荐，例如用户首次访问新城市；6）全局与局部信息融合场景：如 GSTA-GNN[66]和 MobGT[73]模型适合需要同时考虑全局地理规律和局部用户偏好的任务；7）实时动态推荐场景：如 DRPR[72]模型适用于要求实时响应用户位置变化的情境，例如导航中的即时 POI 推荐；8）工业级大规模应用场景：如 STGIN[75]模型适用于大规模电子商务平台的实时 POI 推荐，例如外卖和本地生活服务平台。

5.3.3 基于图结构代表性方法的核心算法公式

DisenPOI 模型的核心工作原理：

1）地理图传播层的消息构建公式：

$$m_{j\leftarrow i}^{(l)}=\frac{1}{\sqrt{|N_i||N_j|}}(\boldsymbol{W}_1^l h_i^k+w(d_{ij})\boldsymbol{W}_2^l h_i^k\odot h_j^k) \quad (35)$$

其中，$m_{j\leftarrow i}^{(l)}$ 是第 l 层从节点 i 到节点 j 的消息，$\boldsymbol{W_1}$,$\boldsymbol{W_2}$ 是可训练的权重矩阵，h^k 是上一层 GNN 的节点表示，$w(d_{ij})$ 是距离核函数，随着 POI i 和 j 之间距离 d_{ij} 的增加呈指数衰减，N_i, N_j 是分别表示 POI i 和 j 在地理图上的一阶邻居，$\odot$是元素级乘法。

2）序列图传播层的更新公式（基于 GGNN）：

$$\begin{aligned}
&h_v^{(1)} = [x_i^\top, 0]^\top \\
&a_v^t = A_{v:}^\top [h_1^{(t-1)\top}, \ldots, h_{|V|}^{(t-1)\top}]^\top + b \\
&z_v^t = \sigma(W^z a_v^{(t)} + U^z h_v^{(t-1)}) \\
&r_v^t = \sigma(W^r a_v^{(t)} + U^r h_v^{(t-1)}) \\
&h_v^{(t)} = \tanh(W_o a_v^{(t)} + U_o (r_v^t \odot h_v^{(t-1)})) \\
&h_v^{(t)} = (1 - z_v^t) \odot h_v^{(t-1)} + z_v^t \odot h_v^{(t)}
\end{aligned} \tag{36}$$

其中，$\boldsymbol{A_v}$ 是确定序列图中节点连接性的连接矩阵，W^z，W^r, W_o, U^z, U^r, U_o 是可训练参数，z_v^t 是更新门，r_v^t 是重置门，$h_v^{(t)}$ 是节点 v 的隐藏表示。

3）注意力机制生成地理嵌入：

$$\begin{aligned}
&w_i = \alpha_g^\top \sigma(\boldsymbol{Q_g} h_t + \boldsymbol{K_g} h_i) \\
&e_{g,u} = \sum_{i=1}^{|s_u|} w_i h_i
\end{aligned} \tag{37}$$

其中，α_g 是注意力向量，$\boldsymbol{Q_g}, \boldsymbol{K_g}$ 是查询和键矩阵，可训练参数，h_t 是目标 POI 的隐藏表示，h_i 是历史访问 POI 的隐藏表示，$e_{g,u}$ 是生成的地理嵌入。

4）自监督解耦对比损失：

$$L_{\text{con}} = f(e'_{g,u}, p'_{g,u}, p'_{s,u}) + f(e'_{s,u}, p'_{s,u}, p'_{g,u}) \tag{38}$$

其中，L_{con} 是对比损失函数，用于分离地理影响和序列影响的表示，$e'_{g,u}$ 是用户 u 的投影后的地理影响表示，$e'_{s,u}$ 是用户 u 的投影后的序列影响表示，$p'_{g,u}$ 是用户 u 的地理影响代理表示，通过对地理邻居进行平均池化获得，$p'_{s,u}$ 是用户 u 的序列影响代理表示，通过对用户历史访问序列进行平均池化获得，$f(\cdot)$ 是贝叶斯个性化排序损失函数。

5）模型预测和总损失函数：

$$\begin{aligned}
&\hat{y} = \sigma(\text{MLP}(\text{CONCAT}(e_{g,u}, e_{s,u}, x_t, h_t))) \\
&\mathcal{L}_{\text{rec}} = -\sum_{(u,v)} y \log \hat{y} + (1-y)\log(1-\hat{y}) \\
&\mathcal{L} = \mathcal{L}_{\text{rec}} + \beta * \mathcal{L}_{\text{con}}
\end{aligned} \tag{39}$$

其中，$\hat{y}$ 是点击率预测，log 是以 e 为底的对数，$e_{g,u}$，$e_{s,u}$ 分别为用户访问历史的地理和序列嵌入，x_t 是目标 POI 的初始嵌入，h_t 是目标 POI 的地理表示，$\mathcal{L}_{\text{rec}}$ 是二元交叉熵损失，β 是解耦权重。

表 7 时空图神经网络模型在 POI 推荐中的应用

Table 7 Application of spatio-temporal graph neural network modeling to POI recommendation

局限性	优势	相关工作
依赖参数调优和数据集依赖性	融合用户社交关系与地理信息和提升推荐准确性和预测性能	Graph-POIR[58]
依赖于超参数调整和锚点近似导致精度损失	解决预定义图结构的局限性和优化地理依赖关系的建模	AGRAN[59]
模型复杂度高和依赖高密度数据	缓解数据稀疏性问题和捕捉用户短期动态和长期静态兴趣	SLS-REC[60]
模型复杂度高和依赖超参数调优	解决用户偏好多样性与动态变化的问题	DCHL[61]
模型泛化能力受限，仅考虑地理和兴趣两大因素	显式地理建模	DIG[62]
模型计算复杂度较高，依赖时间信息的准确性和完整性	时间偏好高阶挖掘和时间信息的跨时段传播	EPT-GCN[63]
模型复杂度高和依赖预训练大语言模型	解决冷启动问题，增强模型的可解释性和鲁棒性	CrossDR-Gen[64]
依赖预训练模型的语义能力	有效整合全局用户群体行为模式和局部连续轨迹信息	HyperSE[65]
图结构复杂性高和对超参数敏感	全局时空关系捕捉和个性化轨迹表示增强	GSTA-GNN[66]
模型计算复杂度较高和依赖地理信息	缓解样本不平衡问题，捕捉用户行为的稳定性和不稳定性	MARAN[67]
模型复杂度高和依赖数据丰富度	多因素综合建模和细粒度模式区分	MGCAN[68]
模型复杂度较高和对数据稀疏性敏感	多维度特征建模	MoveFormer[69]
模型计算复杂度较高和依赖全局数据	缓解冷启动问题和时空解耦表示	CrossDR[70]
模型复杂度较高和超参数敏感性	稀疏数据下的 POI 关系挖掘和长序列依赖关系建模	SNPM[71]
模型计算复杂度高和依赖高质量数据	动态地理-人类交互建模和动态推荐与实时更新	DRPR[72]
模型计算复杂度较高和对稀疏数据适应性不足	长尾数据优化和多视角时空建模	MobGT[73]
模型复杂度高和对超参数敏感	时空信息融合和高阶关系建模	STHGCN[74]
模型计算复杂度高和依赖实时数据更新	多视图兴趣建模和实时兴趣感知	STGIN[75]

STGIN 模型的核心工作原理：

1）时间视图用户兴趣表示：

$$\boldsymbol{u}_{t_i} = GAT_A GG(\{p|\ p \in B_{t_i}^u\}) \tag{40}$$

其中，$\boldsymbol{u}_{t_i}$ 表示用户在特定时间视图 t_i 下的兴趣表示向量，$GAT_A GG$ 是图注意力网络聚合机制，$B_{t_i}^u$ 是用户 u 在时间 t_i 下的邻居集合，包含用户在时间 t_i 点击的 POI 以及短时间内被其他人共同点击的 POI。

2）时间视图注意力聚合：

$$\boldsymbol{u}_t = \sum_{i=1}^{T} \alpha_{t_i} \cdot \boldsymbol{u}_{t_i} \tag{41}$$

其中，$\boldsymbol{u}_t$ 是用户在所有时间视图下的总体兴趣表示，α_{t_i} 是对应时间视图的注意力权重，T 表示时间槽的总数量。

3）时间视图注意力计算：

$$\alpha_{t_i} = \frac{\exp(f(\boldsymbol{W_t^T}[e_{|t_i - t_q|} \| u_{t_i} \| u_g]))}{\sum_{k=1}^{T} \exp(f(\boldsymbol{W_t^T}[e_{|t_k - t_q|} \| u_{t_k} \| u_g]))} \tag{42}$$

其中，$f(\cdot)$ 是激活函数，$\|$ 表示向量连接操作，$e_{|t_i - t_q|}$ 表示查询时间 t_q 与对应时间视图 t_i 之间绝对差的嵌入向，u_g 是用户的全局视图兴趣表示，$\boldsymbol{W_t^T}$ 是权重矩阵。

4）多视图兴趣融合：

$$u_h = f(\boldsymbol{W_h^T}[u_g \| u_s \| u_t \| u_{st}]) \tag{43}$$

其中，u_h 是用户的多视图兴趣表示，u_g，u_s，u_t，u_{st} 分别是用户在全局视图、空间视图、时间视图和空间-时间视图下的兴趣表示，$\boldsymbol{W_h^T}$ 是权重矩阵。

5）实时兴趣感知：

$$u_r = \sum_{i=1}^{M} \alpha_{r_i} \cdot \boldsymbol{e}_{\boldsymbol{p}_{r_i}} \tag{44}$$

其中，u_r 是用户的实时兴趣表示，$\boldsymbol{e}_{p_{ri}}$ 是最近点击的 POI 的表示向量，M 是实时行为序列的长度，α_{ri} 是注意力权重。

6）最终查询表示：

$$\boldsymbol{e_q} = \alpha_1 \cdot u_h + \alpha_2 \cdot u_r + \alpha_3 \cdot [\boldsymbol{e}_{\boldsymbol{t_q}} \| \boldsymbol{e}_{\boldsymbol{s_q}}] \tag{45}$$

其中，$\boldsymbol{e_q}$ 是最终的查询表示向量，α_1，α_2，α_3 是通过 softmax 函数生成的融合权重，$\boldsymbol{e_{t_q}}$，$\boldsymbol{e_{s_q}}$ 分别是查询时间和查询位置的嵌入向量。

5.4 多模态融合方法

5.4.1 时空信息融合模型

时空信息融合模型通过融合用户的时间偏好与空间行为特征，构建更精确的用户移动模式表示。表 8 总结了时空信息融合模型在 POI 推荐中应用的优势、局限性及其相关工作。

Wu 等人[76]提出的 MGTIPM(Multi-granularity Time Intention Prediction Model)模型采用多粒度时间预测模块，结合时间意图建模，预测用户在未来时间段的签到行为，并通过注意力机制优化 POI 访问序列。此外，该模型引入再访 POI 平衡机制，利用用户签到时间的强相关性来识别可能再次访问的 POI，从而提升推荐精度。Feng 等人[77]提出的 ROTAN(Rotation-based Temporal Attention Network)是一种基于旋转的时间注意力网络，用于时间特定的下一个 POI 推荐模型。ROTAN 采用 Time2Rotation 技术，将时间信息编码为旋转向量，避免传统时间嵌入方法增加维度和改变空间结构的问题。该模型首先构建时间感知的 POI 过渡图，利用旋转操作捕捉 POI 之间的非对称时间影响。然后，ROTAN 通过用户偏好序列和 POI 影响序列进行独立建模，分别学习用户行为模式和 POI 的时间动态特征。最后，结合目标时间信息，ROTAN 生成个性化的 POI 推荐。Li 等人[78]提出的 STILSAN(Spatio-Temporal Intention Learning Self-Attention Network)模型采用偏好-意图模块，建模用户的长期兴趣偏好及特定 POI 的访问意图，以提升预测精度。此外，该模型引入空间编码模块，通过变分图自动编码器对 POI 进行聚类，学习 POI 的空间特征，从而模拟 POI 的空间聚类现象及邻近性。Zhang 等人[79]提出的 TN-MCE(Transformer Network with Multi-Correlational Embedding)是一种基于多粒度位置分组的时间感知 POI 推荐模型，用于时间特定的 POI 推荐。TN-MCE 采用多粒度 POI 分组方法，结合共访问模式和周访问模式，生成更精细的 POI 组，提高 POI 相关性。此外，该模型引入 Transformer 编码器，捕捉不同时间段的用户偏好变化，并通过注意力机制自适应调整时间依赖关系。Ren 等人[80]提出的 MPGI(Mining Preferences from Geographical and Interactive Correlations)模型通过设计 POI 相关性建模层，捕捉所有 POI 对之间的地理距离和交互相关性，并利用 Node2Vec 学习高质量的 POI 表示。同时，通过位置感知注意力单元和注意力网络动态选择有价值的签到信息，以建模用户的长期和短期偏好，最终通过预测层计算用户访问下一个 POI 的概率分布。Zhang 等人[81]提出 MHSTPP-a(Multivariate Hawkes Spatio-Temporal Point Process with attention)模型是一种基于多变量 Hawkes 时空点过程和注意力机制的 POI 推荐模型。该方法首先利用用户的历史签

到数据学习 POI 和用户的嵌入表示，然后通过 Hawkes 过程建模时空依赖关系，捕捉用户的长短期偏好。此外，引入注意力机制增强历史行为影响力，优化推荐精度。Huang 等人[82]提出的 RSTCN(Residual Spatio-Temporal Collaborative Network)是一种残差时空协同网络，用于下一个 POI 推荐的模型，以优化用户行为的长期与短期依赖建模。RSTCN 采用残差线性层进行时空协同信号投影，提升长时间序列中的用户偏好建模能力。此外，RSTCN 通过跳跃学习算法识别离散签到点的潜在关系，缓解传统 RNN 方法的序列约束问题。Zhang 等人[83]提出的 STS-POIRec(Spatio-Temporal Aware Self-Attention Network for Point-of-Interest Recommendation)模型采用自注意力机制结合地理距离、时间间隔和相对位置建模用户的动态时空偏好。此外，模型基于移动边缘计算环境，设计了联邦学习方法，以在不共享用户数据的情况下进行分布式训练，缓解梯度泄漏和非独立同分布问题。Wang 等人[84]提出的 TGVx(Time-Geographic-Visitors-Time Slot Number)是一种动态个性化 POI 深度推荐模型，旨在解决用户兴趣漂移、数据稀疏性和高阶非线性交互建模等挑战。TGVx 结合时间（T）、地理（G）和异地用户（V）信息，构建 x 个并行 TGV 子模型，分别针对不同时间段进行 POI 推荐。模型的核心组件包括 T-SemiDAE 网络（半监督深度自编码器），用于挖掘高阶非线性用户-POI 交互，并整合多源异构信息（地理、时间、社交、协作、语义）。此外，TGVx 通过 POI-Word 异构图嵌入，在城市间匹配相似 POI，并利用转移学习策略生成伪签到数据，缓解异地推荐的数据稀疏问题。Ou 等人[85]提出的 STA-TCN(Spatial-temporal Attention over Temporal Convolutional Network)模型通过时间卷积网络替代传统 RNN，提高模型的训练效率，并结合门控输入注入机制增强序列学习能力。此外，该模型设计了空间-时间注意力模块，融合网格差异学习和时间敏感学习，捕捉用户签到历史的全局空间-时间关联。Jiang 等人[86]提出的 TGAT(Temporal-Geographical Attention-based Transformer)模型采用混合序列采样策略，从用户签到记录构建的时间 POI 图和地理 POI 图中抽取 POI 序列，以保留不同上下文因素的相互作用。此外，该模型采用 Transformer 网络学习 POI 表示，并引入加权聚合策略融合来自不同上下文因素的 POI 表示。

时空信息融合模型在以下 POI 推荐场景中表现出色：1）重访行为建模场景：如 MGTIPM[76]和 STILSAN[78]模型适用于需要预测用户重复访问 POI 行为的任务，例如餐厅和咖啡店等日常消费场所推荐；2）定时推荐场景：如 ROTAN[77]模型特别适合时间特定的 POI 推荐，例如早餐、午餐或晚餐时段的餐厅推荐；3）多粒度位置推荐场景：如 TN-MCE[79]模型适用于需要考虑不同粒度（如商圈、街区、具体店铺）POI 组的场合；4）基于复杂时空相关性的场景：如 MHSTPP-a[81]模型适合建模具有明显时空依赖关系的 POI 推荐，例如交通换乘点推荐；5）城市服务推荐场景：如 TGVx[84]模型适用于解决用户兴趣漂移问题的城市服务推荐，例如异地出差用户的本地服务发现；6）高效实时推荐场景：如 STA-TCN[85]模型通过时间卷积网络提高训练效率，适合需要快速响应的实时推荐系统。

表 8 时空信息融合模型在 POI 推荐中的应用

Table 8 Application of spatio-temporal information fusion model in POI recommendation

局限性	优势	相关工作
上下文信息有限和数据稀疏性敏感	用户重访偏好建模和多粒度时间预测	MGTIPM[76]
模型计算复杂度较高和时间粒度固定	时间信息建模和个性化与上下文感知	ROTAN[77]
难以处理冷启动问题和对时空特征依赖较强	建模用户重访意图和优化空间特征学习	STILSAN[78]
计算复杂度较高和未有效缓解数据稀疏性问题	细粒度用户偏好建模和长期依赖与时间感知建模	TN-MCE[79]
依赖手工设置的地理和交互相关性阈值	全面捕捉 POI 相关性和动态建模用户长期和短期偏好	MPGI[80]
模型结构相对简单和对时空信息的依赖性较强	模型计算复杂度低和复杂时空依赖性建模	MHSTPP-a[81]
模型复杂度较高和依赖时空协同信号的完整性	有效整合时空协同信号和建模离散签到信息	RSTCN[82]
模型计算复杂度较高和收敛速度较慢	隐私保护能力较强和时空感知推荐精准	STS-POIRec[83]
对新 POI 的适应性有限和跨城市 POI 匹配的鲁棒性不足	有效缓解数据稀疏性和冷启动问题	TGVx[84]
模型复杂度较高和数据稀疏性问题未解决	高效序列建模和精细时空关联学习	STA-TCN[85]
非自适应聚合权重和固定长度采样序列	捕捉时空因素的交互	TGAT[86]

5.4.2 多源异构数据融合模型

多源异构数据融合模型通过融合用户签到数据、社交网络关系、文本评论、图像特征以及地理位置等多源异构数据，构建更全面的用户偏好和 POI 特征表示。表 9 总结

了多源异构数据融合模型在 POI 推荐中应用的优势、局限性及其相关工作。

Liu 等人[87]提出的 Mandari(Multi-Modal Temporal Knowledge Graph-aware Sub-graph Embedding approach)模型通过构建多模态时间知识图，整合用户签到序列、POI 文本评论、图像信息等多源数据，捕捉 POI 之间的隐式关联。此外，该模型使用图注意力网络建模空间-时间 POI 子图，并结合时间知识挖掘模块学习签到数据的分割性和周期性特征。最终，Mandari 采用融合预测机制，结合子图预测和时间预测结果，提高 POI 推荐准确性。Yu 等人[88]提出的 PRMF(Point of Interest Recommendation Method integrating Multiple Factors)是一种集成多因素的 POI 推荐模型，用于提升 POI 推荐的准确性。PRMF 结合用户偏好、地理位置影响和 POI 热度，构建统一的多因素 POI 推荐模型。模型采用多层感知机计算用户偏好，并基于用户历史签到数据计算活动中心，以衡量地理偏好。随后，引入 POI 热度偏好计算，结合线性融合策略，将上述三种因素统一建模，有效缓解了数据稀疏性问题。Cheng 等人[89]提出的 InfAM(Influence-Aware Successive Point-of-Interest Recommendation Model)模型通过多头注意力机制建模短期 POI 访问序列中的影响关系，并结合用户嵌入学习用户的个性化偏好。此外，该模型引入地理编码模块，缓解传统方法中的空间不对称问题，并通过时间周期建模捕捉用户签到行为的周期性规律。最终，InfAM 通过归一化与残差网络优化 POI 推荐效果。Zeng 等人[90]提出的 Neu-PCM(Neural-based Potential Correlation Mining for POI Recommendation)模型旨在解决 POI 推荐中的数据稀疏性问题，并挖掘用户与 POI 之间的深层潜在关联。该模型首先使用局部嵌入方法对用户和 POI 进行特征提取，并采用降维神经网络降低特征维度，同时保留核心信息。然后，Neu-PCM 通过联合网络将用户和 POI 的特征进行拼接，学习两者之间的潜在关联。最后，模型结合深度矩阵分解，进一步优化推荐结果，最终输出用户访问某个 POI 的概率。Huang 等人[91]提出的 BERT-CL(BERT-based Contrastive Learning aspect-based sentiment analysis model)模型利用 BERT 获取文本的语义嵌入表示，并通过对比学习拉近同类样本、推远不同类样本，增强特征表达能力。同时，采用对抗训练生成正负样本对，提升模型在小样本条件下的鲁棒性和分类性能，最终实现精准的情感分析，为 POI 推荐提供更准确的用户偏好和 POI 特征。

多源异构数据融合模型在以下 POI 推荐场景中表现出色：1）多模态数据场景：如 Mandari[87]模型适用于整合签到、文本评论、图像等多源数据的推荐任务，例如餐厅和旅游景点推荐；2）多因素综合建模场景：如 PRMF[88]模型结合用户偏好、地理位置影响和 POI 热度，适合平衡多种因素的综合推荐，例如城市热门景点推荐；3）影响力感知场景：如 InfAM[89]模型通过多头注意力机制建模影响关系，适用于社交影响力驱动的 POI 发现；4）数据稀疏环境：如 Neu-PCM[90]模型适合在用户-POI 交互极度稀疏的情况下进行推荐，例如小众景点推荐；5）情感驱动推荐场景：如 BERT-CL[91]模型利用对比学习增强情感分析能力，适用于需要考虑用户情感偏好的 POI 推荐，例如度假胜地和休闲场所推荐。

5.4.3 多模态融合代表性方法的核心算法公式

ROTAN 模型的核心工作原理：

1）Time2Rotation(T2R)公式：

$$T2R(h,r_t)=\boldsymbol{h}\circ r_t, where\,|r_t|=1 \tag{46}$$

其中，$\boldsymbol{h}$ 是嵌入向量，r_t 表示与时间槽 t 相关的旋转，"∘"表示 Hadamard(元素级)乘积，$|r_t|=1$ 表示 r_t 是单位复数(保持旋转特性)。

2）时间转换距离公式：

$$Dist_{quad_i}=\|T2R^{Src}(p_i,t_i)-T2R^{Tgt}(p_{i+1},t_{i+1})\| \tag{47}$$

其中，$T2R^{Src}(p_i,t_i)$ 表示旋转后的 POI 嵌入，$T2R^{Tgt}(p_{i+1},t_{i+1})$ 表示旋转后的 POI 嵌入，$\|\cdot\|$ 表示 L1 范数。

3）用户时间表示融合公式：

$$z^u=\alpha*z_d^u+(1-\alpha)*z_W^u \tag{48}$$

其中，z^u 是用户嵌入，融合了多周期时间信息，z_d^u 是用户的每日周期时间表示，z_W^u 是用户的每周周期时间表示，α 是权重参数，范围在[0,1]之间，表示每日周期性的权重。

4）最终推荐分数计算公式：

$$y=\beta*y^u+(1-\beta)*y^p \tag{49}$$

其中，y^u 是用户偏好分数，y^p 是 POI 影响分数，β 代表用户偏好的贡献，（1-β）表示 POI 影响的贡献。

Mandari 模型的核心工作原理：

1）多模态特征融合层公式：

$$e_l = \frac{1}{|N(l)|}\sum_{(l,r_m,m)\in N(l)} W_m[e_l \,||\, e_{rm} \,||\, e_m] \tag{50}$$

其中，e_l 是位置 l 的最终嵌入表示，$N(l)$ 表示与位置实体 l 相连的三元组，$[\cdot||\cdot]$表示连接操作，W_m 是可训练的参数，e_l, e_{rm}, e_m 是从多模态特征提取层获得的三元组(l,rm,m)的嵌入，其中 rm 表示不同的模态关系。

2）图注意力网络的注意力计算公式：

$$d_{ij} = \text{LeakyReLU}(\boldsymbol{a}^\top[\boldsymbol{W_s}e_i \,||\, \boldsymbol{W_s}e_j]) \tag{51}$$

其中，e_i, e_j 是子图节点的嵌入，$\boldsymbol{a}$ 是权重向量，$\boldsymbol{W_s}$ 是共享权重矩阵。

3）归一化注意力分数计算公式：

$$\psi_{ij} = \frac{\exp(d_{ij})}{\sum_{v_k\in N(v_i)}\exp(d_{ik})} \tag{52}$$

其中，ψ_{ij} 是归一化后的分数。

4）节点特征更新公式：

$$f_i = \sigma(\sum_{v_j\in N(v_i)} \psi_{ij}e_j) \tag{53}$$

其中，f_i 是更新后的节点 v_i 的特征。

5）位置节点表示融合公式：

$$l^{G_l} = l^{G_{l_t}} + l^{G_{l_s}} \tag{54}$$

其中，l^{G_l} 是融合后的位置节点表示，$l^{G_{l_t}}$ 是时间子图中的位置节点表示，$l^{G_{l_s}}$ 是空间子图中的位置节点表示。

6）子图预测分数计算公式：

$$\hat{s}_{i,j} = l^{G_l\top} u^{G_{u_t}} \tag{55}$$

其中，$\hat{s}_{i,j}$ 是下一个 POI 的分数，$l^{G_l\top}$ 是时间子图中的位置表示，$u^{G_{u_t}}$ 是用户-用户时间子图中的用户表示。

7）最终推荐得分计算公式：

$$\hat{y}_{i,j} = \alpha\hat{s}_{i,j} + \beta\hat{c}_{i,j} + \gamma\hat{g}_{i,j} \tag{56}$$

其中，$\hat{y}_{i,j}$ 是最终的组合概率，$\hat{s}_{i,j}$ 是子图预测模块的得分，$\hat{c}_{i,j}$ 是复制网络的预测概率，$\hat{g}_{i,j}$ 是生成网络的预测概率，α，β，γ 是权重系数，且 $\alpha+\beta+\gamma=1$。

8）模型优化的损失函数：

$$\mathcal{L} = -\frac{1}{|U|}\sum_{i=1}^{|U|}\sum_{j=1}^{|L|} y_{i,j}\log(\hat{y}_{i,j}) + \lambda\|\boldsymbol{\Theta}\|_2 \tag{57}$$

其中，$\boldsymbol{\Theta}$ 是所有可训练的参数，λ 是 L2 正则化参数。

表 9 多源异构数据融合模型在 POI 推荐中的应用

Table 9 Application of Multi-source Heterogeneous Data Fusion Modeling in POI Recommendation

局限性	优势	相关工作
多模态信息融合深度不足和时间规则挖掘的动态性有限	时空规则动态挖掘和多模态与时间信息深度融合	Mandari[87]
模型泛化能力有限和依赖多因素权重调整	多因素融合增强推荐效果和有效缓解数据稀疏性问题	PRMF[88]
依赖多头注意力机制和对新用户适应性有限	多视角影响力感知和缓解数据稀疏性问题	InfAM[89]
模型计算复杂度高和依赖数据质量	捕捉用户偏好和缓解数据稀疏性问题	Neu-PCM[90]
下游任务训练偏差	小样本条件下的情感分类性能提升和对抗训练增强鲁棒性	BERT-CL[91]

5.5 特定任务导向方法

5.5.1 序列化 POI 推荐模型

序列化 POI 推荐模型通过建模用户的签到序列来预测用户下一个可能访问的 POI，充分利用用户历史行为的时序信息。表 10 总结了序列化 POI 推荐模型在 POI 推荐中应用的优势、局限性及其相关工作。

Lim 等人[92]提出的 HMT-GRN(Hierarchical Multi-Task Graph Recurrent Network)是一种层次化多任务图递归网络，用于下一个 POI 推荐的模型，旨在解决用户-POI 矩阵的稀疏性问题。HMT-GRN 通过多任务学习，同时预测用户的下一个 POI 及其所属的地理区域，从而利用层次化信息降低搜索空间。此外，模型设计了层次化束搜索，在不同空间粒度上逐步缩小 POI 搜索范围，以提高推荐效率。HMT-GRN 还引入了选择性层，判断用户下一个访问的 POI 是否属于其历史访问记录，以平衡个性化和探索性推荐。最后，该模型结合联合三元组损失学习，同时学习用户访问过的 POI 关系和未访问 POI 关系，以进一步缓解数据稀疏性问题。Huang 等人[93]提出的 MTNet(Mobility Tree Network)模型通过构建移动树，将用户签到记录按照时间段进行层次化组织，以捕捉用户在不同时间段的个性化行为模式。该模型采用四步节点交互机制，逐层传播签到信息，并结合多任务学习策略，同时预测用户的下一个

POI、地理区域和 POI 类别，以增强模型的泛化能力。此外，MTNet 采用自适应加权损失函数优化不同任务的影响权重，并通过时间段细粒度划分提高推荐的时间适应性。Acharya 等人[94]提出的 LTPM-TRSP(Long-Term Preference Mining with Temporal Recency estimation and Spatial Proximity fusion)模型采用时间衰减增强的 LSTM 计算用户长期兴趣，并结合区域兴趣网格划分进行地理信息建模。该模型通过三元组损失的正交映射优化 POI 之间的距离学习，并结合多头注意力机制平衡空间、时间和类别特征。Wu 等人[95]提出的 SSTP(Social and Spatial-Temporal Aware Next Point-of-Interes)是一种社交与时空感知的下一个 POI 推荐模型，用于缓解数据稀疏和用户冷启动问题。SSTP 采用双层特征编码器，结合自注意力机制和门控循环单元，层次化建模用户的长短期签到行为。此外，引入随机邻域采样策略，挖掘社交关系，提高冷启动用户的推荐效果。同时，设计地理感知图注意力网络，增强 POI 之间的距离敏感性。Gan 等人[96]提出的模型（本文称该模型为 HIMDL）通过构建用户兴趣的超球模型（包含兴趣中心和兴趣半径）来描述用户偏好，并利用双向 LSTM、自注意力和记忆网络学习用户的历史签到模式。最终，通过计算候选 POI 与兴趣中心的欧几里得距离来优化推荐列表的排名分数，从而实现精准的个性化推荐。Long 等人[97]提出的 INSPIRE(Personalized INterest Sustainability modeling framework for sequential POI REcommendation)是一种个性化兴趣可持续性建模模型，用于序列化 POI 推荐。INSPIRE 通过预测用户在训练时间后仍然感兴趣的 POI，从而建模个性化兴趣的可持续性，而不仅仅依赖历史签到轨迹。为了解决用户签到历史数据的稀疏性问题，该模型采用地理增强、内在增强和外在增强三种数据增强策略，以丰富用户行为特征。此外，INSPIRE 采用时间敏感 POI 推荐任务，通过划分时间片来判断用户是否会继续访问某些 POI，并结合基于 LSTM 的时序建模技术，以更精细地捕捉兴趣持续性特征。Wang 等人[98]提出的 SCL POIRec(Self-Supervised Curriculum Learning for POI Recommendation)模型采用 GNN 进行下一个 POI 推荐，利用自监督学习解决数据稀疏问题，并结合课程学习逐步优化训练过程。该模型通过构建 POI 访问序列的图结构，使用 GNN 提取用户偏好，并引入对比学习进行自监督训练。数据增强方法（如序列重排、裁剪）用于生成不同视图以提升泛化能力。Lv 等人[99]提出的 OMPR(Online Meta-learning POI Recommendation)是一个在线元学习 POI 推荐模型。该模型包含两部分：一是基于位置的自注意力编码器，用于学习用户与 POI 之间的复杂关系；二是元学习基础的在线更新模块，通过结合历史和当前数据的知识迁移，快速适应用户偏好的变化，从而实现高效的在线 POI 推荐。

表 10 序列化 POI 推荐模型在 POI 推荐中的应用

Table 10 Application of Sequentialized POI Recommendation Model in POI Recommendation

局限性	优势	相关工作
模型计算复杂度较高和依赖区域划分精度	多任务学习与区域划分和缓解数据稀疏性问题	HMT-GRN[92]
模型时间复杂度较高和依赖时间槽划分	细粒度时间偏好建模和多任务学习增强鲁棒性	MTNet[93]
模型训练复杂度高和依赖时空信息	时空动态融合和长期偏好挖掘	LTPM-TRSP[94]
模型时间复杂度较高和依赖社交信息	缓解数据稀疏性问题和解决用户冷启动问题	SSTP[95]
模型参数敏感性高和推荐多样性受限	个性化兴趣建模	HIMDL[96]
模型较为复杂和对数据分布的敏感性	捕捉兴趣持续性和缓解数据稀疏性问题	INSPIRE[97]
模型训练过程复杂和依赖数据增强策略	捕捉用户长期和短期兴趣的时间依赖性，缓解数据稀疏性问题	SCL POIRec[98]
模型复杂度较高和依赖历史数据质量	地理与偏好综合建模，快速适应用户即时偏好变化	OMPR[99]

序列化 POI 推荐模型在以下 POI 推荐场景中表现出色：1）层次化推荐场景：如 HMT-GRN[92]模型通过多任务学习同时预测 POI 及其地理区域，适用于大规模商场或园区内的分区推荐；2）时间槽划分场景：如 MTNet[93]模型适合根据时间段建模用户行为的任务，例如早晨、中午和晚上的差异化推荐；3）地理与时间融合场景：如 LTPM-TRSP[94]模型适用于需要同时考虑长期兴趣和地理影响的推荐，例如城市规划中的设施布局推荐；4）社交感知推荐场景：如 SSTP[95]模型特别适合利用社交关系缓解数据稀疏和冷启动问题，例如基于朋友圈的 POI 发现；5）个性化兴趣建模场景：如 HIMDL[96]模型通过超球模型描述用户偏好，适合精准个性化推荐任务；6）兴趣持续性建模场景：如 INSPIRE[97]模型适用于预测用户长期稳定兴趣的场合，例如习惯性消费场所推荐；7）在线学习场景：如

OMPR[99]模型适合需要实时更新用户偏好的动态环境，例如旅游者在旅途中的实时推荐。

5.5.2 跨区域/跨城市 POI 推荐模型

跨区域推荐技术旨在解决用户在陌生区域或城市中的信息需求，帮助用户发现符合其兴趣偏好的新地点。表 11 总结了跨区域/跨城市 POI 推荐模型在 POI 推荐中应用的优势、局限性及其相关工作。

Tsubouchi 等人[100]提出的 UOPR(Unvisited Out-Of-Town POI Recommendation framework)是一种未访问的异地 POI 推荐模型，用于异地 POI 推荐，即针对用户未曾访问的区域进行 POI 推荐。UOPR 采用双重评分策略，分别计算用户基于本地行为和异地行为的偏好，并通过知识图注意力网络建模用户与 POI 的交互。此外，该模型引入掩码输入学习和用户嵌入迁移机制，优化 POI 之间的交互学习，缓解数据稀疏性问题。Yang 等人[101]提出的 UPTDNet(User Preference Transfer and Drift Network)是一种用户偏好转移与漂移网络，用于跨城市的下一个 POI 推荐模型。UPTDNet 通过建模长短期用户偏好，解决了跨城市 POI 推荐中的数据稀疏问题。模型采用双分支循环神经网络，分别建模短期偏好的转移和短期偏好的漂移，前者从游客当前城市的本地用户学习行为模式，后者则区分不同用户角色（如游客、本地人）。此外，UPTDNet 设计了一种长周期偏好映射函数，结合用户相似性计算模块，实现从用户家乡城市到目标城市的长期偏好转移。Li 等人[102]提出的 ST-TransRec(Spatial and Textual Transfer Learning Framework for Crossing-City POI Recommendation)模型通过整合用户与 POI 的交互数据和 POI 的文本描述，利用深度神经网络学习 POI 嵌入，并通过最大均值差异技术增强跨城市 POI 嵌入的可转移性。此外，该模型还采用重采样方法解决 POI 分布不均衡问题，最终通过多层感知机建模用户-POI 交互，输出推荐分数。Sun 等人[103]提出的 CATUS(Category-level Universal Transition pre-training model)模型通过设计“下一个类别预”和“下一个 POI 推荐”两个自监督任务，结合类别转换导向采样器和隐式与显式转移策略，将不同城市的通用类别转换知识迁移到具体 POI 中。在微调阶段，CATUS 进一步引入距离导向采样器，将 POI 表示更好地对齐到每个城市的本地上下文中，显著提升了跨城市预训练的效果。

表 11 跨区域/跨城市 POI 推荐模型在 POI 推荐中的应用

Table 11 Cross-regional/cross-city POI recommendation modeling in POI recommendation

局限性	优势	相关工作
对热门区域依赖性较强和区域间差异适应性不足	多区域同时学习，动态偏好捕捉和缓解数据稀疏性问题	UOPR[100]
模型复杂度较高和依赖于用户历史数据	缓解跨城市数据稀疏性问题和细粒度偏好建模	UPTDNet[101]
依赖文本描述和未考虑动态时空因素	缓解了跨城市 POI 推荐中的数据稀疏性和用户行为漂移问题	ST-TransRec[102]
依赖大规模预训练和新城市适应性差	跨城市知识转移和缓解数据稀疏性问题	CATUS[103]

跨区域/跨城市 POI 推荐模型在以下 POI 推荐场景中表现出色：1）异地 POI 推荐场景：如 UOPR[100]模型专为用户未曾访问的区域设计，适用于旅行目的地推荐；2）用户角色区分场景：如 UPTDNet[101]模型通过建模用户角色差异（如游客、本地人），适合为不同类型用户提供差异化推荐；3）跨城市知识迁移场景：如 ST-TransRec[102]模型适用于将用户在熟悉城市的行为模式迁移到新城市，例如商务差旅用户的本地服务推荐；4）大规模预训练环境：如 CATUS[103]模型通过预训练-微调框架，适合在多城市数据上进行知识共享，适用于全国性或全球性 POI 服务平台。

5.5.3 隐私保护和分布式 POI 推荐模型

传统 POI 推荐系统通常将用户数据集中存储和处理，这使得用户隐私面临泄露风险。为应对这一挑战，提出了多种隐私保护策略，包括数据加密、差分隐私和联邦学习等技术。特别是，分布式架构允许模型在保留数据本地化的同时实现有效的协作学习，既保护了用户敏感位置信息，又维持了推荐质量。表 12 总结了隐私保护和分布式 POI 推荐模型在 POI 推荐中应用的优势、局限性及其相关工作。

PriGCN[55]是一种将隐私保护与 GCN 相结合的创新模型。该模型通过设计隐私感知的 POI 选择机制，在原始用户数据上应用生成式技术创建合成数据，有效替换敏感信息，同时保留用户偏好模式。此外，PriGCN 采用了专门的隐私保护度量标准来评估信息泄露风险，在保持推荐质量的同时确保用户隐私安全，为隐私保护 POI 推荐提供了平衡隐私与性能的新思路。STS-POIRec[83]不仅是一种时空感知的推荐模型，同时在隐私保护方面做出了创新。该模型基于移动边缘计算环境，采用联邦学习框架，使用

户数据保持在本地设备上，只传输梯度信息，有效保护了用户隐私。此外，模型通过特殊的梯度处理机制减少信息泄露风险，并采用联邦平均算法解决非独立同分布数据问题，为 POI 推荐中的隐私保护提供了新思路。Long 等人[104]提出的 MAC(Model-Agnostic Collaborative Learning for On-device POI Recommendation)模型允许用户根据设备容量定制模型结构，通过基于物理距离、类别偏好和社交网络的邻居选择机制，结合知识蒸馏和互信息最大化，实现异构模型间的高效安全知识共享，从而提升本地推荐模型的性能，同时保护用户隐私。Rezaei 等人[105]提出的 FedDist-POIRec(Federated Distillation for Point-Of-Interest Recommendation)模型是一种基于联邦蒸馏的下一个 POI 推荐系统，结合了半同步学习框架，以提高推荐效率并降低通信成本。该模型通过知识蒸馏而非参数共享来进行联邦学习，使用户可以采用不同的模型架构，同时减少数据泄露风险。此外，它使用邻居知识聚合技术，结合具有相似偏好的用户知识，以缓解数据稀疏问题。

隐私保护和分布式 POI 推荐模型在以下 POI 推荐场景中表现出色：1）敏感位置推荐场景：如 PriGCN[55]模型特别适用于涉及敏感位置信息的推荐任务，例如医疗机构、金融场所等隐私敏感 POI 推荐；2）联邦学习环境：如 STS-POIRec[83]模型基于移动边缘计算环境，适合分布式设备上的隐私保护推荐，例如多设备协同的个人助手服务；3）异构设备协作场景：如 MAC[104]模型允许不同计算能力设备上的模型协同，适用于智能家居与移动设备结合的场景推荐；4）低通信成本环境：如 FedDist-POIRec[105]模型通过联邦蒸馏降低通信开销，适合网络条件受限的边缘计算环境，例如农村或远郊区域的 POI 服务。

表 12 隐私保护和分布式 POI 推荐模型在 POI 推荐中的应用

Table 12 Privacy Preserving and Distributed POI Recommendation Modeling in POI Recommendation

局限性	优势	相关工作
未解决冷启动问题和依赖数据预处理	隐私保护与个性化推荐兼顾，高效图卷积与抗过平滑能力	PriGCN[55]
模型计算复杂度较高和收敛速度较慢	隐私保护能力较强和时空感知推荐精准	STS-POIRec[83]
模型训练过程复杂和依赖参考数据质量	解决异构设备上的模型协作问题和保护用户隐私	MAC[104]
模型计算开销较高和依赖公共数据集	隐私保护，通信高效和资源异构性优化	FedDist-POIRec[105]

5.5.4 特定任务导向代表性方法的核心算法公式

HMT-GRN 模型的核心工作原理：

1）图循环网络模块的关键公式

空间图注意力权重计算公式：

$$\vec{\alpha}_{l_{t_{i-1}},j}=\frac{\exp(LeakyReLU(\mathbf{a}[\boldsymbol{W_p}\overrightarrow{l_{t_{i-1}}}\oplus\boldsymbol{W_p}\vec{j}]))}{\sum_{\vec{k}\in\hat{N}_G[l_{t_{i-1}}]}\exp(LeakyReLU(\mathbf{a}[\boldsymbol{W_p}\overrightarrow{l_{t_{i-1}}}\oplus\boldsymbol{W_p}\vec{k}]))} \tag{58}$$

其中，$l_{t_{i-1}}$ 表示前一个 POI 的嵌入向量，j 表示图中 POI 节点，$\boldsymbol{W_p}$ 是一个输入投影矩阵，$\hat{N}_G[l_{t_{i-1}}]$ 表示前一个 POI 节点的闭邻域（相邻节点和自身），$\oplus$表示连接操作。

图节点更新公式：

$$p_{t_i}=\sum_{\vec{j}\in\hat{N}_G[l_{t_{i-1}}]}\vec{\alpha}_{l_{t_{i-1}},j}\odot\boldsymbol{W_p}\vec{j} \tag{59}$$

其中，$\odot$ 表示 Hadamard 乘积（逐元素乘法）。

2）修改后的循环网络门控机制公式：

$$\begin{aligned}
i_{t_i}&=\sigma(W_i x_{t_i}+U_i h_{t_{i-1}}+b_i+\boldsymbol{V_i}p_{t_i}^{G_s}+\boldsymbol{Z_i}p_{t_i}^{G_t})\\
f_{t_i}&=\sigma(W_f x_{t_i}+U_f h_{t_{i-1}}+b_f+\boldsymbol{V_f}p_{t_i}^{G_s}+\boldsymbol{Z_f}p_{t_i}^{G_t})\\
o_{t_i}&=\sigma(W_o x_{t_i}+U_o h_{t_{i-1}}+b_o+\boldsymbol{V_o}p_{t_i}^{G_s}+\boldsymbol{Z_o}p_{t_i}^{G_t})\\
\tilde{c}_{t_i}&=tanh(W_c x_{t_i}+U_c h_{t_{i-1}}+b_c+\boldsymbol{V_c}p_{t_i}^{G_s}+\boldsymbol{Z_c}p_{t_i}^{G_t})
\end{aligned} \tag{60}$$

其中，i_{t_i}，f_{t_i}，o_{t_i} 分别是输入门、遗忘门和输出门，σ 是 sigmoid 激活函数，$p_{t_i}^{G_s}$ 是来自空间图的节点表示，$p_{t_i}^{G_t}$ 是来自时间图的节点表示，$\boldsymbol{V_i},\boldsymbol{V_f},\boldsymbol{V_o},\boldsymbol{V_c}$ 是空间图表示的权重矩阵，$\boldsymbol{Z_i},\boldsymbol{Z_f},\boldsymbol{Z_o},\boldsymbol{Z_c}$ 是时间图表示的权重矩阵。

3）层次化波束搜索的公式：

$$\begin{aligned}
tk_i^{\beta}=f(\{&\log\left(tk_{i-1,b}^{\beta}\right)+\\
&\log(tk_{i,j}),tk_{i,j}\in\mathcal{N}\left(tk_{i-1,b}^{\beta}\right),b\in\{1,2,\ldots,\beta\}\})
\end{aligned} \tag{61}$$

其中，tk_{i-1}^{β} 和 tk_i^{β} 分别是输入任务分布 tk_{i-1} 和 tk_i 的 top-β 部分解，β 是波束宽度，$\mathcal{N}\left(tk_{i-1,b}^{\beta}\right)$ 表示前一个输入任务分布中第 b 个波束的有向邻域，$f(\cdot)$ 是一个函数，用于只考虑 top-β 部分解。

4）联合三元组损失学习模块的损失函数：

$$J_{loss} = -\log\left(\sigma\left(u_h l_b^{\top}\right)\right) - \sum_{u_n \in l_b^{Neg}} \log\left(\sigma\left(-u_n l_b^{\top}\right)\right) \quad (62)$$

其中，u_h 表示访问过 POI 的用户嵌入，l_b 表示 POI 的嵌入（作为锚点），u_n 表示从未访问过 POI l_b 的用户集合中的负样本用户，σ 是 sigmoid 激活函数。

FedDist-POIRec 模型的核心工作原理：

1）POI 评分计算公式：

$$\boldsymbol{f}_i = F_{u_i}(\theta_i, p_h \in \mathbb{P} | \mathbb{S}(u_i)), \quad i \in \{1,\ldots,M\}, h \in \{1,\ldots,N\} \quad (63)$$

其中，$\boldsymbol{f}_i$ 是向量，表示用户 u_i 对各个 POI 的预测评分，F_{u_i} 是用户 u_i 的 POI 推荐模型，θ_i 是模型参数，p_h 是 POI，属于 POI 集合 P，$\mathbb{S}(u_i)$ 是用户 u_i 的签到序列，M 是用户数量，N 是 POI 数量。

2）优化目标公式：

$$\underset{\boldsymbol{\Theta}}{\operatorname{argmin}} \frac{1}{M} \sum_{u_i \in \mathbb{U}} \mathcal{L}_i(\boldsymbol{\theta}_i | D_i^{train}) \quad (64)$$

其中，$\boldsymbol{\Theta}$ 是所有用户的模型参数集合，$\mathcal{L}_i$ 是用户 u_i 的损失函数，D_i^{train} 是用户 u_i 的训练集，U 是用户集合。

3）损失函数公式：

$$\mathcal{L}_i(\theta_i | D_i^{train}) = -\frac{1}{|D_i^{train}|} \sum_{\mathbb{S}(u_i) \in D_i^{train}} \left(\log f_{i,j} + \sum_{h \in \{1,\ldots,N\}, h \neq j} \log(1 - f_{i,h}) \right) \quad (65)$$

其中，D_i^{train} 是用户 u_i 训练集中签到序列的数量，j 表示目标 POI，$f_{i,j}$ 是目标 POI 的预测评分，$f_{i,h}$ 是其他 POI 的预测评分。

4）模型参数更新公式：

$$\theta_i^t = \theta_i^{t-1} - \frac{\alpha \times \hat{m}^t}{\sqrt{\hat{v}^t} + \epsilon} \quad (66)$$

其中，θ_i^t 表示迭代 t 时用户 u_i 的模型参数，α 是学习率，$\hat{m}^t$ 和 $\hat{v}^t$ 分别是一阶和二阶矩的无偏估计，ϵ 是为了数值稳定性添加的小常数。

5）用户相似度计算公式：

$$\lambda_{ij} = \frac{1}{Q} \sum_{q=1}^{Q} \sum_{h=1}^{N} (f_{i,h}^q - f_{j,h}^q)^2 \quad (67)$$

其中，λ_{ij} 是用户预测结果的不相似度，Q 是公共数据集中的样本数量，$f_{i,h}^q$ 是用户对公共数据集中第 q 个序列的第 h 个 POI 的预测评分，$f_{j,h}^q$ 是用户对公共数据集中第 q 个序列的第 h 个 POI 的预测评分。

6）知识聚合公式：

$$\bar{f}_i^q = \frac{1}{M_n} \sum_{u_k \in \mathbb{U}_i} f_k^q \quad (68)$$

其中，$\bar{f}_i^q$ 是聚合后的评分，M_n 是邻居用户数量，$\mathbb{U}_i$ 是用户的邻居用户集合，f_k^q 是邻居用户 u_k 对公共数据集中第 q 个序列的预测评分。

7）微调损失函数：

$$\ell_i = -\frac{1}{Q} \sum_{\mathbb{S}_q \in D^{public}} \sum_{h=1}^{N} \bar{f}_h^q \log f_{i,h}^q \quad (69)$$

其中，ℓ_i 是用户的交叉熵损失，$f_{i,h}^q$ 是用户本地模型对公共数据集中第 q 个序列的第 h 个 POI 的预测评分，$\bar{f}_h^q$ 是第 q 个序列中第 h 个 POI 的聚合评分，D^{public} 是公共数据集。

5.6 Foursquare 数据集上的模型性能对比

表 13 和表 14 展示了不同模型在 Foursquare 数据集上的性能对比。性能指标选取了实际应用中最常用的 Recall@10、NDCG@5 以及 NDCG@10。

表 13 基于 Foursquare 数据集的模型评估指标 Recall@10

Table 13 Model Evaluation Metric Recall@10 Based on the Foursquare Dataset

模型	Recall@10	模型	Recall@10
Deep-PR[9]	0.1986	STCP[17]	0.3587
EEDN[27]	0.0843	BSA-ST-Rec[31]	0.3966
IAGNN[47]	0.5140	ITGCN[48]	0.5443
AGRAN[59]	0.3247	SLS-REC[60]	0.1490
InfAM[89]	0.2501	LTPM-TRSP[94]	0.3170
UPTDNet[101]	0.2700	RSTCN[82]	0.6551
TGAT[86]	0.2686	OMPR[99]	0.1210

表 14 基于 Foursquare 数据集的模型评估指标 NDCG@5 和 NDCG@10

Table 14 Model evaluation metrics NDCG@5 and NDCG@10 based on Foursquare dataset

模型	NDCG@5	模型	NDCG@10
STCP[17]	0.1972	STCP[17]	0.2246
DCPR[19]	0.1922	DCPR[19]	0.2913
EEDN[27]	0.0867	EEDN[27]	0.0882
BSA-ST-Rec[31]	0.3114	BSA-ST-Rec[31]	0.3258
ITGCN[48]	0.3235	ITGCN[48]	0.3612
CGNN-PRRG[54]	0.9100	CGNN-PRRG[54]	0.8100
AGRAN[59]	0.1828	AGRAN[59]	0.2066
TN-MCE[79]	0.1750	TN-MCE[79]	0.1604
RSTCN[82]	0.4864	RSTCN[82]	0.5055

STA-TCN[85]	0.3253	STA-TCN[85]	0.3659
INSPIRE[97]	0.7539	INSPIRE[97]	0.7753

从表 13 可以观察到，在 Recall@10 指标上，RSTCN[82]模型表现最佳，达到 0.6551，其次是 ITGCN[48]模型，达到 0.5443，以及 IAGNN[47]模型，达到 0.5140。这三个模型均采用了 GNN 结构，说明基于图结构的方法在捕捉用户-POI 交互模式方面具有显著优势。相比之下，EEDN[27]和 OMPR[99]的表现较弱，这可能与它们在处理稀疏数据方面的能力有限有关。

从表 14 的 NDCG 指标来看，CGNN-PRRG[54]和 INSPIRE[97]在 NDCG@5 和 NDCG@10 上均表现出色，分别达到了 0.9100/0.8100 和 0.7539/0.7753。NDCG 作为一种考虑排序质量的指标，这些模型的高分表明它们不仅能够准确推荐 POI，还能将最相关的 POI 排在推荐列表的前列。RSTCN[82]在 NDCG 指标上也保持了较好的表现，达到 0.4864/0.5055，进一步证实了其在 POI 推荐任务中的有效性。

值得注意的是，同一模型在不同指标上的表现可能存在差异。例如，BSA-ST-Rec[31]在 Recall@10 上表现中等（0.3966），但在 NDCG 指标上相对较好（0.3114/0.3258），说明该模型在推荐质量上有一定优势。相反，EEDN[27]在两个指标上都表现不佳，可能需要进一步改进其模型结构或训练方法。

在所分析的模型中，采用 GNN 架构的 RSTCN[82]、ITGCN[48]和 CGNN-PRRG[54]等模型在 Foursquare 数据集的部分评估指标上表现较为突出，特别是在捕捉用户-POI 交互关系方面。这说明有效融合图结构信息和时空特性是提升 POI 推荐性能的关键因素。同时，不同模型的性能差异也反映了它们在处理数据稀疏性、捕捉序列依赖关系以及整合上下文信息等方面的能力存在显著差异。

5.7 实际应用案例分析

本节将对前文介绍的深度学习模型在 POI 推荐实际应用中的效果和影响进行案例分析，结合实验数据和真实场景展示这些技术的实际表现。

5.7.1 旅游景点推荐实证分析

以 ITGCN 模型[48]为例，该模型专为旅游企业的连续 POI 推荐设计，在多个真实数据集上展现了显著的推荐效果。

ITGCN 通过构建用户-POI 交互二分图，并结合自注意力聚合器，有效捕捉了用户与 POI 之间的高阶连接关系和时间动态特性。研究人员在 Foursquare 和 Gowalla 数据集上进行了广泛实验，结果显示 ITGCN 在各项评估指标上均优于现有方法。表 15 和表 16 分别展示了 ITGCN 与 DSPR(Demand-aware Sequential POI Recommendation)[107]和 GSTN(Graph-enhanced Spatial-Temporal network)[108]模型在 Foursquare 和 Gowalla 数据集上的性能对比。

表 15 ITGCN 与 DSPR 模型在不同数据集上的性能对比

Table 15 Performance comparison of ITGCN and DSPR models on different datasets

数据集	评估指标	ITGCN 提升百分比
Foursquare	Recall@1	7.63%
	Recall@5	4.18%
	Recall@10	5.68%
	NDCG@1	5.11%
	NDCG@5	13.80%
	NDCG@10	7.23%
Gowalla	Recall@1	13.92%
	Recall@5	13.60%
	Recall@10	7.93%
	NDCG@1	14.14%
	NDCG@5	17.37%
	NDCG@10	15.08%

表 16 ITGCN 与 GSTN 模型在 Foursquare 数据集上的性能对比

Table 16 Performance comparison of ITGCN and GSTN models on Foursquare dataset

评估指标	ITGCN 提升百分比
Recall@1	8.68%
Recall@5	15.65%
Recall@10	20.27%
NDCG@1	9.64%
NDCG@5	12.16%
NDCG@10	13.66%

从表格数据可以看出，ITGCN 相比于 DSPR 模型，在各项评估指标上均有显著提升，特别是在 Gowalla 数据集上的表现更为突出。与 GSTN 模型相比，ITGCN 在 Foursquare 数据集上的优势更为明显，尤其是在 Recall@10 指标上提升高达 20.27%。

ITGCN 模型的优势主要体现在以下方面：1）高阶连接性捕捉：通过图卷积网络有效挖掘用户-POI 之间的间接关联，发现潜在 POI。2）时间动态表示：设计了独特的聚合器机制，能够自适应地融合交互位置和时间信息，生成动态的节点表示。3）交互增强能力：模型能有效建模用户与 POI 之间的交互行为，提升连续 POI 推荐的准确性。

此外，研究人员还对嵌入维度和自注意力层数等超参数进行了敏感性分析，结果显示当嵌入维度设置为 200 时，模型性能最优；而当自注意力层数设为 1 时，模型性能显著提升并趋于稳定。

5.7.2 餐饮推荐系统效果对比

以 Mandari 模型[87]为例，该模型通过整合用户签到、

餐厅评论文本和图像等多源数据，在真实餐饮推荐场景中取得了显著成效。表 17 展示了 Mandari 与其他模型(FPMC(Factorized Personalized Markov Chains)、ST-RNN(Spatial Temporal Recurrent Neural Networks)、DeepMove、LSTPM(Long-and Short-Term Preference Modeling)、STAN(Spatio-Temporal Attention Network)、MKGAT(Multi-modal Knowledge Graph Attention Network)以及 RE-NET(Relation Embedded deep model))在 NYC 和 Yelp 数据集上的性能对比：

表 17 Mandari 与其他模型在 NYC 和 Yelp 数据集上的性能对比

Table 17 Performance of Mandari vs. other models on NYC and Yelp datasets

模型	MRR	Hit@1	Hit@5	Hit@10
FPMC[109]	0.1801	0.1003	0.2026	0.2854
ST-RNN[110]	0.2293	0.1681	0.2813	0.3352
DeepMove[111]	0.2651	0.2044	0.2898	0.3487
LSTPM[112]	0.3312	0.2552	0.3164	0.3509
STAN[113]	0.3253	0.2531	0.3672	0.4712
MKGAT[114]	0.4043	0.2474	0.3516	0.3958
RE-NET[115]	0.3812	0.3551	0.4246	0.4802
Mandari[87]	0.4668	0.4165	0.5234	0.5724
提升百分比	15.5%	17.3%	23.3%	19.2%

Mandari 在多个关键指标上的表现均优于现有方法。通过引入时空子图和多模态融合技术，Mandari 模型在 NYC 数据集上的 MRR 指标较最佳基线提升了 15.5%，在 Hit@5 上提升了 23.3%。

Mandari 的有效性主要归功于其创新的架构设计：1）多模态融合能力，通过整合文本、图像和签到数据构建完整的用户偏好表示；2）时空知识挖掘能力，通过挖掘用户签到序列中的分段性和周期性规律，有效预测用户下一个可能访问的位置。

5.7.3 城市服务点推荐的实际效果

在城市服务领域，DisenPOI 模型[45]通过构建两个解耦图（地理图和序列图）来区分用户 POI 偏好的地理影响和序列影响，从而提供更准确的 POI 推荐。表 18 是 DisenPOI 模型与其他基线方法 DIN(Deep Interest Network)、DIEN(Deep Interest Evolution Network)、SR-GNN(Session-based Recommendation with Graph Neural Networks)、NGCF(Neural Graph Collaborative Filtering)、LightGCN(Light Graph Convolution Network)、GeoIE(Geographical Influence Model)、LSTPM 以及 GSTN 在多个城市服务数据集上的表现比较。

表 18 DisenPOI 与基线方法在不同数据集上的性能对比

Table 18 Performance comparison between DisenPOI and baseline methods on different datasets

模型	东京数据集		纽约数据集		美团数据集	
	AUC	Logloss	AUC	Logloss	AUC	Logloss
DIN[116]	0.8623	0.4174	0.8015	0.5203	0.5596	0.6920
DIEN[117]	0.8643	0.4544	0.8062	0.5582	0.5591	0.6891
SR-GNN[118]	0.8867	0.4481	0.8491	0.5262	0.5751	0.6844
NGCF[119]	0.8899	0.4436	0.8461	0.4788	0.5698	0.6857
LightGCN[120]	0.8998	0.4348	0.8729	0.4815	0.5682	0.6859
GeoIE[121]	0.9083	0.4203	0.8769	0.4810	0.5431	0.6926
LSTPM [112]	0.8745	0.4374	0.8568	0.4821	0.5637	0.6867
GSTN[108]	0.8906	0.4312	0.8521	0.5323	0.5807	0.6845
DisenPOI[45]	0.9246	0.3608	0.8941	0.4248	0.5823	0.6836

DisenPOI 在所有三个数据集上都表现出最佳性能，相比最强基线方法在 AUC 指标上分别提升了 1.7%（东京）、2.0%（纽约）和 0.3%（美团）；在 Logloss 指标上分别提升了 1.3%、1.1%和 0.2%。

表 19 DisenPOI 与 DIN 在推荐 POI 上的差异比较

Table 19 Comparison of DisenPOI and DIN Differences in Recommended POIs

DisenPOI[45]		DIN[116]	
距离(km)	类别	距离(km)	类别
0.310	道路	4.727	火车站
1.331	咖啡店	3.908	地铁
0.780	烟店	0.981	艺术博物馆
2.971	地铁	5.800	桥梁
0.462	礼品店	2.544	火车站
平均距离	ACC	平均距离	ACC
2.410	29.6%	5.970	28.3%

从表 19 中的 DisenPOI 与 DIN 模型推荐的 POI 对比可以看出，DisenPOI 推荐的 POI 平均距离用户当前位置更近（2.41km vs 5.97km），同时在类别准确率上略有提升（29.6% vs 28.3%）。这表明 DisenPOI 模型能够更好地平衡地理因素和用户兴趣偏好，为用户提供既符合兴趣又地理位置合理的 POI 推荐。

5.7.4 跨城市推荐实例分析

UPTDNet[101]和 CATUS[103]等跨城市推荐模型在解决用户异地旅行场景下的 POI 推荐问题上表现出色。表 20 是 UPTDNet 在跨城市数据集上的性能数据。

表 20 UPTDNet 模型在不同城市对上的性能表现

Table 20 Performance of UPTDNet model on different city pairs

方法	Dallas→Austin	Austin→Dallas
MRR	0.2772	0.2274
HR@5	0.3691	0.2929
HR@10	0.4607	0.4012
NDCG@5	0.1893	0.1452
NDCG@10	0.2193	0.1786

表 21 是 CATUS 跨城市预训练模型在 Foursquare 数据集上的表现。

表 21 CATUS 模型在 Tokyo 和 New York 城市间的性能表现
Table 21 Performance of CATUS model between Tokyo and New York cities

方法与指标	Tokyo	New York
HR@5	30.31	33.98
HR@10	35.80	38.23
NDCG@5	22.94	26.11
NDCG@10	24.72	27.51

UPTDNet 在实际应用中的优势主要体现在：1）用户偏好迁移：通过建模用户偏好的迁移与漂移，UPTDNet 能够有效捕捉长短期偏好，提高跨城市推荐准确性。2）长短期偏好融合：模型能够准确区分用户在异地的短期兴趣和基于家乡的长期偏好，推荐结果更符合用户实际需求。3）数据稀疏场景表现：在异地签到数据极为稀疏的情况下，UPTDNet 仍能维持相对稳定的推荐效果。

CATUS 模型则通过类别级通用转移知识预训练，在不同城市间有效转移知识，尤其在解决相对稀疏性问题方面表现突出。CATUS 通过两个自监督任务（下一个类别预测和下一个 POI 预测）以及类别转移导向采样器，将不同城市的通用类别转换知识迁移到具体 POI 中，显著提升了跨城市预训练的效果。

这些跨城市推荐模型的成功表明，通过有效建模城市间的共性与差异性，可以显著缓解跨城市 POI 推荐中的数据稀疏性和用户行为漂移问题，提供更精准的位置推荐服务。

5.7.5 工业级应用案例：美团 POI 推荐系统

美团作为中国领先的本地生活服务平台，其 POI 推荐系统是深度学习技术在工业界应用的典型案例。STGIN 模型[75]在美团大规模线上应用取得了显著成效。STGIN 模型在一个大型电子商务平台的实际 A/B 测试中的结果如表 22 所示：

表 22 在线 A/B 测试结果
Table 22 Online A/B test results

指标	相对提升
点击率	+1.1%
千次展示收入	+6.3%

STGIN 模型在美团的实际应用中具有以下技术优势：1）多视图兴趣建模：通过构建空间、时间、时空和全局四种视图的子图，精确刻画用户在不同场景下的兴趣偏好；2）实时兴趣感知：设计了工业友好的框架，能够追踪用户的最新兴趣，并与图表示学习结合，实现端到端的实时推荐；3）高效部署架构：受益于实时兴趣感知模块，图结构可以按照给定频率更新，而不需要实时推理。学习到的嵌入存储在键值表中，跳过图的实时推理，平均只需 5.6 毫秒即可完成一次在线推荐。

STGIN 模型的成功应用充分证明了深度学习驱动的 POI 推荐技术在大规模工业环境中的实用价值，不仅提升了用户体验，也为平台带来了可观的商业收益。

5.7.6 大型商场内导航推荐实例

SH-Rec 模型[34]在实际商场环境中应用效果突出，表 23 和表 24 展示了 SH-Rec 模型与其他基线模型 MAHAN(Memory Enhancement Hierarchical Attention Network)、ALSTMM(Attention-based Long-Short Term Memory Model)、RTPM(Real-time Preference Model)、Ka-MeMnn(key-array memory network)、ASLI(Attention-based Sequential Model of Latent Intention Learning) 以及 AAMN(Attention-based Adaptive Memory Network)在两个真实数据集上的表现：

表 23 SH-Rec 模型与基线模型在波士顿数据集上的性能比较（Top-5）
Table 23 Performance Comparison of SH-Rec Model and Baseline Model on Boston Dataset (Top-5)

模型	Precision	Recall	F-score	NDCG
MAHAN[122]	0.4736	0.5029	0.4878	0.6092
ALSTMM[123]	0.4758	0.4981	0.4867	0.6175
RTPM[124]	0.5023	0.5193	0.5107	0.6287
Ka-MeMnn[125]	0.5082	0.5303	0.5190	0.6594
ASLI[126]	0.5105	0.5317	0.5209	0.6508
AAMN[127]	0.5697	0.5267	0.5474	0.6926
SH-Rec[34]	0.5823	0.5406	0.5607	0.7235

表 24 SH-Rec 模型与基线模型在华盛顿数据集上的性能比较（Top-5）
Table 24 Performance Comparison of SH-Rec Model and Baseline Model on Washington Dataset (Top-5)

模型	Precision	Recall	F-score	NDCG
MAHAN[122]	0.4603	0.5045	0.4814	0.6158
ALSTMM[123]	0.4619	0.5113	0.4855	0.6209
RTPM[124]	0.5182	0.5209	0.5195	0.6368
Ka-MeMnn[125]	0.5355	0.5276	0.5315	0.6614
ASLI[126]	0.5407	0.5293	0.5348	0.6798
AAMN[127]	0.5489	0.5307	0.5396	0.6873
SH-Rec[34]	0.5799	0.5491	0.5641	0.7361

数据显示，SH-Rec 模型在所有四项评估指标上都明显优于基线方法，特别是在 NDCG 指标上的提升最为显著，表明该模型能够更精准地将用户可能感兴趣的 POI 排在推荐列表的前列。

SH-Rec 模型的特点在于：1）利用序列-层次化注意力网络同时捕捉用户兴趣的层次特性和序列依赖性；2）通过记忆网络提取用户历史行为中的序列偏好特征；3）采用多任务学习策略，同时进行兴趣预测和签到预测，互相促进性能提升。

该模型能有效区分用户的访问意图和偏好，通过层次化建模用户的高层意图（如"娱乐"）和具体意图（如"看电影"），同时考虑这些意图在用户行为序列中的依赖关系，从而提供更精准的推荐服务。

6 深度学习在 POI 推荐中的挑战与未来

6.1 技术挑战

6.1.1 计算复杂度与效率优化

深度学习模型在 POI 推荐任务中展现了强大的学习能力，但其高计算复杂度和资源消耗成为重要的瓶颈。综合文献所述模型可以发现，大多数基于 Transformer[18,23]、GNN[45]-[47]和多头注意力机制[35]-[42]的模型都面临计算开销大的问题。这一问题在资源受限的移动设备上尤为突出，限制了这些模型在实际应用中的部署。例如，DCHL[61]、CrossDR-Gen[64]和 IAGNN[47]等模型虽然表现优异，但其复杂的模型结构导致训练和推理过程耗时较长，难以满足实时推荐的需求。

随着数据规模的增长，模型的训练和推理过程变得更加耗时，尤其是在处理大规模签到数据时，计算和存储成本显著增加。在实际应用中，POI 推荐系统往往需要满足实时性要求，确保用户在最短时间内获得个性化的推荐结果，这进一步增加了对计算效率的需求。

未来的研究可以探索更高效的模型架构，例如轻量级 Transformer[18]、优化的 GNN[46]或稀疏注意力机制[53]，以减少计算成本。同时，结合分布式计算、模型剪枝、参数共享、蒸馏学习等优化策略，可以在降低计算复杂度的同时保持推荐性能。此外，针对在线推荐场景，可以开发增量学习或在线学习方法，使模型能够在动态环境中快速适应新数据，提高实时推荐的响应速度。

6.1.2 用户偏好动态性建模

用户的兴趣和偏好并非固定不变，而是随着时间、地点和环境变化不断调整。例如，用户可能在工作日和周末对 POI 的偏好不同，在旅行时的签到模式也与日常生活中的签到行为有所区别。虽然模型如 STMGNN[53]和 MGTIPM[76]尝试建模用户的长短期兴趣，但对突发事件、季节性变化等因素的适应性有限。特别是在快速变化的城市环境中，用户的 POI 偏好可能受多种因素影响而迅速改变，现有模型难以有效应对这种动态性。

传统的 POI 推荐模型通常依赖静态用户画像，难以捕捉用户兴趣的长期变化和短期偏好漂移。未来的研究可以引入时间序列建模方法，如循环神经网络[101]、长短期记忆网络[5]和 Transformer[18]，动态建模用户兴趣的变化。此外，动态 GNN 可以在 POI 交互图中建模时序变化，提高对用户行为的刻画能力。强化学习方法也可以用于 POI 推荐，通过构建用户偏好的动态演化策略，使推荐系统能够实时调整推荐内容，以更好地匹配用户的短期需求和长期兴趣。同时，在线学习或增量学习机制可以帮助模型在接收到新签到数据时快速更新，提升个性化推荐的时效性。

6.1.3 可解释性与用户信任

尽管深度学习驱动的 POI 推荐系统在预测准确性方面取得了显著进展，但其"黑箱"特性使得推荐结果难以解释，这限制了用户对系统的信任度。ExNext[33]和 CrossDR-Gen[64]等模型试图提升推荐的可解释性，但大多数 POI 推荐模型仍缺乏足够的可解释性。

目前的可解释性研究主要集中在以下几个方向：1）注意力可视化：一些基于注意力机制的模型如 HAT[32]和 ExNext[33]通过可视化注意力权重来展示模型关注的关键特征，但这种解释往往停留在技术层面，难以被普通用户理解；2）特征归因：IAGNN[47]等模型尝试通过分解用户兴趣来解释推荐结果，但这种解释通常是事后解释，而非模型决策过程的真实反映；3）自然语言解释：CrossDR-Gen[64]和 HAT[32]等模型利用大语言模型生成自然语言解释，但生成的解释与模型实际决策过程的一致性仍有待验证。

可解释性的缺乏不仅降低了用户对推荐系统的信任度，也限制了系统在特定应用场景中的使用。特别是在 POI 推荐这类涉及用户实际出行决策的应用中，不透明的推荐理由可能导致用户拒绝接受推荐结果。此外，可解释性的缺乏也使得开发者难以诊断和改进模型的性能，尤其是当模型表现不佳时，难以确定是哪些因素导致了错误推荐。

未来的研究可以探索内在可解释性技术，将可解释性设计融入模型架构本身，如可解释性 GNN 或注意力机制的改进，使模型决策过程更加透明。此外，因果推断方法可以帮助识别用户兴趣与 POI 特征之间的因果关系，提供更符合人类认知的解释。多层次解释策略也值得探索，针对不同用户提供不同复杂度的解释，从简单的"您可能喜欢这类餐厅"到详细的"根据您过去在周末访问意大利餐厅的历史，结合当前位置和天气情况，推荐这家餐厅"。自

然语言生成技术结合大语言模型可以生成更自然、更具情感共鸣的解释，增强用户对推荐系统的信任和接受度。

6.1.4 大模型与 POI 推荐的结合挑战

随着大型语言模型的快速发展，其在 POI 推荐中的应用前景广阔，但也面临诸多挑战。首先，大模型通常具有固定的知识截止日期，对于新开业的 POI 或城市新区域的发展可能缺乏最新信息。其次，大模型虽然具备丰富的常识性知识，但对特定区域的细粒度 POI 信息掌握有限，尤其是非英语语言环境下的本地 POI 数据。此外，大模型的地理空间推理能力仍有待提升，难以准确理解复杂的空间关系和距离概念。

大模型在 POI 推荐系统中的首要挑战是部署成本和资源消耗问题。现代大模型通常拥有数十亿甚至上千亿参数，需要强大的计算硬件支持，这对于资源有限的企业和开发者构成了巨大压力。推理延迟问题在实时 POI 推荐场景中尤为突出，用户通常期望在几百毫秒内获得推荐结果，而大模型的推理时间可能达到数秒甚至更长。此外，大模型产生的幻觉问题可能导致推荐错误的 POI 信息，如不存在的地点、错误的营业时间或过时的评价，这将严重影响用户体验和信任度。

未来研究可以探索知识增强技术，通过检索增强生成将最新的 POI 数据库与大模型结合，动态补充模型的知识。同时，可以开发专门的地理空间微调数据集，增强大模型对地理位置、距离和区域概念的理解。另一个有前景的方向是探索领域特定的预训练目标，如设计针对 POI 推荐的自监督学习任务，使大模型更好地理解用户移动轨迹数据的内在规律。最后，开发混合架构，结合大模型的语义理解能力和传统推荐模型的高效精确特性，可能是一个平衡计算效率和推荐质量的可行途径。

6.1.5 技术挑战的未来演进方向

从技术演进角度看，未来 POI 推荐系统的技术发展将沿着以下几条路径演进：

1）计算效率优化演进路线：POI 推荐模型可能会探索从简单的参数剪枝向结构化稀疏和动态稀疏方向发展。通过在训练过程中自动识别和保留对 POI 推荐任务至关重要的网络结构，同时剔除冗余结构，既能保持模型精度又能显著提高推理速度。同时，知识蒸馏技术将从简单模型压缩向任务特定化蒸馏和多老师蒸馏方向发展，将大型 POI 推荐模型的知识转移到适合边缘设备的小型模型中。

2）用户偏好动态建模演进路径：未来研究将从静态用户画像向实时动态偏好建模方向演进。具体而言，模型将整合短期兴趣、长期偏好和情境因素，构建多尺度时间窗口的用户兴趣表示，捕捉从即时兴趣到长期稳定偏好的完整谱系。元学习技术将使模型能够"学会如何适应"用户偏好的快速变化，使推荐系统在少量新数据的基础上迅速调整预测策略。

3）可解释性技术演进方向：POI 推荐的可解释性研究将从事后解释向内在可解释性方向演进。未来模型将设计具有透明决策过程的架构，如基于因果推断的模型和可解释的注意力机制，使推荐决策过程可被追踪和理解。同时，可解释性技术将走向个性化解释路线，根据用户的认知能力和专业背景提供不同复杂度的解释内容。

4）大模型与 POI 推荐融合技术路线：大模型在 POI 推荐中的应用将沿着多个方向发展。首先是"大模型理解用户意图+小模型执行精准推荐"的协同架构将逐步成熟，平衡用户体验和推荐效率。其次是模态融合将从单一文本向多模态方向演进，整合文本、图像、音频等信息，实现更全面的 POI 理解和推荐。

5）硬件感知算法设计路线：随着专用人工智能芯片的发展，POI 推荐算法设计将更加硬件感知，针对特定硬件平台优化模型结构和计算图，实现软硬件协同优化。异步分层推理架构将成为趋势，将推荐过程分解为多个异步执行的模块，根据实时性要求分配计算资源，实现更高效的实时推荐。

6.2 数据挑战

6.2.1 数据稀疏性与冷启动问题

POI 推荐系统通常面临数据稀疏性问题，尤其是签到数据呈现明显的长尾分布，大量 POI 仅有少量用户访问，这使得传统协同过滤方法难以有效建模[44]。虽然许多研究致力于解决数据稀疏性问题，但现有方法在处理极度稀疏的数据场景时仍显不足。如 PAPR[41]和 MobGT[73]在数据稀疏性严重的情况下适应性有限。

此外，对于新用户或新 POI，由于缺乏足够的历史交互数据，推荐系统难以提供准确的个性化推荐，这一问题被称为冷启动问题[8]。针对冷启动问题，虽有一些创新方法如 LLAMA2-7b[39]和 PriGCN[55]，但在没有任何历史交互信息的纯冷启动场景下，这些方法仍然表现不佳。特别是对于新用户和新 POI 的推荐，现有模型往往依赖于辅助信息，而这些信息在实际应用中可能并不总是可获取的。

未来的研究可以借助数据增强技术，如生成对抗网络

或数据插值方法，扩展训练数据以缓解数据稀疏性。此外，迁移学习和元学习[99]可以帮助模型从已有数据中迁移知识，以更快地适应新用户或新 POI。多模态数据融合[87]也是一个重要的方向，通过结合用户评论、POI 图像、社交关系、天气信息等多种数据源，增强对用户偏好的理解，提升冷启动情况下的推荐质量。此外，自监督学习[29]和对比学习技术[64]可以在无标签数据上进行特征学习，提高数据利用效率，缓解数据稀疏问题。

6.2.2 多模态数据融合

当前的 POI 推荐系统大多依赖用户的签到记录和位置信息，但现实生活中的用户行为受到多种因素的影响，如社交关系、天气、活动、兴趣爱好等[26]。虽然一些研究如 Mandari[87]和 BERT-CL[91]尝试融合文本、图像等多模态数据，但多模态信息的融合深度仍然不足。大多数模型只是简单地将不同模态的特征拼接或加权求和，缺乏对模态间复杂关系的建模。例如，InfAM[89]虽然考虑了多视角影响力，但对模态间的交互理解有限；PRMF[88]虽然整合了多因素，但模型的泛化能力有限，对新环境适应性不足。

单一数据源的推荐方法往往难以全面刻画用户的兴趣，导致推荐结果的准确性和多样性受限。未来的研究可以探索多模态数据融合技术，将文本、图像、视频、语音等不同类型的信息整合到 POI 推荐系统中。例如，结合用户评论和 POI 相关的图片，可以更精准地分析用户对 POI 的偏好；利用社交网络信息，可以挖掘用户之间的相似性，提高推荐的个性化程度。此外，跨领域推荐也是一个值得探索的方向，通过结合用户在不同领域（如电影、购物、旅游）的行为数据，提高 POI 推荐系统的泛化能力。为了更有效地处理多模态数据，自监督学习[29]和对比学习方法[64]可以用于自动学习不同模态之间的相关性，从而提高推荐质量。

6.2.3 数据挑战的未来演进方向

数据作为 POI 推荐系统的基础，其处理和利用技术的演进将决定推荐系统的未来发展方向：

1）数据稀疏性解决方案演进路径：未来处理数据稀疏性的技术将从简单的数据增强向自监督学习和图结构增强方向演进。自监督学习将通过设计 POI 推荐领域特定的预训练任务，如轨迹补全、POI 分类和用户行为预测等，从海量未标记数据中提取有价值的特征表示。同时，图结构增强技术将从静态图向动态演化图方向发展，通过建模用户-POI 交互的动态变化过程，挖掘潜在的高阶连接关系，缓解数据稀疏带来的冷启动问题。

2）多模态数据融合技术演进：多模态 POI 数据的融合技术将从简单特征拼接向深度语义对齐和跨模态表示学习方向演进。未来研究将开发专门的跨模态对比学习框架，使文本描述、图像特征、用户评论、位置信息等多源数据在统一的语义空间中进行表示和交互。同时，针对 POI 推荐的特定需求，将开发模态适应性融合机制，根据不同场景动态调整各模态信息的重要性权重，如在视觉导向场景中增强图像模态的权重。

3）数据表示学习演进方向：首先是自适应时空表示学习，POI 的表示将从静态向动态演进，根据时间、季节、社会事件等因素调整。其次是多粒度表示学习，同时建模城市、区域、街区和具体 POI 的特征，捕捉不同空间尺度的关联关系。此外，跨领域表示对齐技术将使不同城市、国家甚至文化背景下的 POI 表示具有可比性，实现更有效的知识迁移。最后，隐私保护表示学习将成为重要方向，通过差分隐私和联邦学习等技术，在保护用户位置隐私的同时提取有价值的表示。

4）动态标签系统演进路径：传统的静态 POI 分类体系将向动态标签系统演进，自动从用户行为、评论和社交媒体中提取新兴的 POI 类别和特征标签。这种演进将使推荐系统能够捕捉快速变化的城市动态和消费趋势，如新型餐饮概念、短期流行活动或季节性特色服务。同时，标签系统将从单一分类向多维度特征空间扩展，同时刻画 POI 的功能属性、情感氛围、社会特征等多方面特性。

6.3 应用挑战

6.3.1 隐私保护与公平性

随着 POI 推荐系统对用户数据的依赖性增加，用户隐私保护问题变得越来越重要[7]。POI 推荐涉及用户的地理位置、签到历史、行为轨迹等敏感信息，如果数据泄露，可能导致用户隐私被滥用或跟踪。虽然有如 PriGCN[55]和 STS-POIRec[83]等尝试在推荐中引入隐私保护机制的模型，但大多数研究仍未充分考虑隐私保护问题。现有的隐私保护方法如 MAC[104]和 FedDist-POIRec[105]往往会牺牲模型性能或增加计算复杂度，难以在保护隐私和保持推荐质量之间取得良好平衡。

此外，推荐系统的偏见和公平性问题也引起了广泛关注。例如，如果算法倾向于推荐热门 POI，而忽视小众 POI，

可能会导致用户体验不均衡。未来的研究可以结合隐私保护技术[55]，如差分隐私和同态加密，确保数据在不泄露用户隐私的前提下仍然可用于模型训练。此外，联邦学习[83]可以在用户设备端进行本地训练，无需上传个人数据，从而增强隐私保护能力。为了提升推荐的公平性，可以研究公平性调整算法，确保不同用户群体在推荐系统中获得平等的推荐机会。例如，可以设计基于公平性约束的优化目标，防止算法在性别、年龄、地区等方面产生过度偏向，从而提高推荐系统的社会责任感和可接受性。

6.3.2 实际部署与系统集成

深度学习驱动的 POI 推荐系统在实际应用中面临着系统集成和部署挑战[88]。这些模型通常需要大量计算资源，而移动设备和嵌入式系统的计算能力和存储容量有限，难以支持复杂模型的运行。此外，推荐系统需要与现有的业务系统无缝集成，以提供实时、个性化的推荐服务。

未来研究可以探索模型压缩技术，如知识蒸馏[104]、模型量化和模型剪枝，以减小模型规模和提高推理速度，适应移动端和嵌入式环境。此外，可以开发云-边-端协同架构[19]，将计算密集型任务放在云端，而将轻量级推理任务部署在终端设备上，以平衡计算效率和用户隐私。同时，设计灵活的 API 接口和中间件，使推荐系统能够与各种现有系统无缝对接，提高系统的可扩展性和可维护性。

6.3.3 大模型在 POI 推荐实际应用中的挑战

大模型在 POI 推荐系统中的应用虽然前景广阔，但需要解决一系列实际挑战才能实现其潜力。为了克服这些挑战，未来的应用研究可以探索模型压缩技术，如知识蒸馏[104]、量化和剪枝，将大型语言模型的知识转移到更小、更高效的模型中，以降低部署成本。同时，可以采用云-边-端协同架构[19]，在云端部署完整大模型处理复杂推理任务，在边缘节点或用户设备部署轻量级模型处理基本推荐功能，平衡性能和响应速度。针对幻觉问题，可以引入事实检验机制，将大模型生成的 POI 信息与可靠数据源进行核对，确保推荐信息的准确性和时效性。另一个重要方向是开发垂直领域的小型语言模型，这些模型专注于 POI 推荐领域，虽然参数规模较小，但通过针对性训练可以在特定任务上达到接近大模型的性能，同时大幅降低资源需求。

6.3.4 应用挑战的未来演进方向

随着技术的发展和社会需求的变化，POI 推荐应用将呈现以下演进趋势：

1）隐私保护与公平性技术演进：隐私保护技术将从基础的数据加密向隐私计算和可信执行环境方向演进。未来研究将开发基于联邦学习的分布式 POI 推荐架构，使用户数据能够留在本地设备，只有模型参数或梯度在网络中传输。同时，隐私保护将与可用性协同优化，如通过局部差分隐私技术在保护精确位置的同时保留足够的空间模式信息。公平性研究将从机会均等向多维度公平性演进，同时考虑用户群体公平、商家公平和区域资源分配公平，开发多目标优化框架平衡各方利益。

2）系统部署架构演进路径：POI 推荐系统的部署架构将从集中式向分布式和边缘智能方向演进。云-边-端协同架构将成为主流，复杂模型训练和更新在云端进行，边缘节点负责区域化特征提取和候选生成，终端设备执行个性化排序和即时推荐。这种架构演进将大幅降低通信延迟，提高系统响应速度，同时增强隐私保护能力。此外，推荐系统与操作系统和硬件的集成将更加紧密，如 POI 推荐功能将嵌入到智能手表、增强现实技术眼镜等可穿戴设备，提供实时情境感知的推荐服务。

3）跨场景应用整合演进：POI 推荐将从单一场景向多场景整合方向演进。未来系统将打破地图导航、社交网络、电子商务、旅游服务等应用间的壁垒，建立统一的用户兴趣模型，提供无缝的跨场景推荐体验。例如，用户在电商平台浏览咖啡器具后，导航应用可能推荐沿途的精品咖啡店；社交平台上关注的餐厅可能影响地图应用的 POI 排序。这种演进要求开发通用的用户兴趣表示方法和跨平台数据协议，支持不同应用之间的安全数据共享。

4）新兴应用场景演进趋势：在元宇宙环境下，推荐系统将跨越虚实边界，同时理解用户在物理世界和虚拟世界的行为偏好，推荐融合现实与虚拟体验的 POI。沉浸式 Augmented Reality 场景中，POI 推荐将结合用户的视野范围和注视方向，提供视觉增强的推荐体验。智慧城市生态下，推荐系统将与交通规划、能源管理等系统协同，优化城市资源分配。健康与可持续发展导向的推荐将考虑用户健康状况和环保意识，推荐有益身心健康的 POI 选择。

5）商业模式创新路径：POI 推荐商业模式将从简单的广告展示向多元价值创造方向演进。未来将出现基于用户实际到访的效果付费模式，商家只为带来实际客流的推荐服务付费；订阅式个性化推荐服务将为高端用户提供专属 POI 发现体验；数据价值变现将更加精细化，推荐系统可以在保护隐私的前提下，为城市规划、商业选址等提供匿名化的人群流动洞察。这些商业模式创新将推动 POI 推

荐从简单工具向价值平台转变。

7 结论

本文全面回顾了深度学习在 POI 推荐领域的最新研究进展。通过系统分析基于 LSTM、GRU、注意力机制、Transformer 和 GNN 等深度学习模型在 POI 推荐中的应用，发现这些方法在处理用户-POI 交互的复杂模式方面展现出显著优势。特别是，这些模型能够有效捕捉用户行为的时序依赖性、地理空间关联性以及多模态特征，从而提供更准确的个性化推荐。尤其是近期大型语言模型的快速发展为 POI 推荐系统带来了新的研究范式和技术路线，通过自然语言理解、多模态信息融合以及知识增强等技术，进一步提升了推荐系统的性能和用户体验。

然而，当前的 POI 推荐系统仍面临诸多挑战。本文详细梳理了这些挑战，包括计算复杂度和效率优化问题、数据稀疏性和冷启动问题、用户偏好的动态性建模、推荐结果的可解释性、多模态数据的有效融合以及隐私保护与公平性等问题。针对这些挑战，提出了未来研究方向，包括探索轻量级模型架构和优化策略、利用数据增强和迁移学习等技术缓解数据稀疏问题、开发动态兴趣建模方法、结合可解释性技术提升系统透明度、研究多模态数据融合方法、设计隐私保护机制等。同时，也探讨了大模型与传统推荐技术的融合方法，利用大模型的语义理解能力和知识推理能力增强 POI 推荐系统，并提出解决大模型在实际应用中面临的计算效率、知识时效性和推理准确性等挑战的可能途径。

从技术演进角度，预见未来 POI 推荐系统将向计算效率优化、动态偏好建模、内在可解释性、多模态融合和隐私保护方向发展。在应用层面，未来系统将更加注重跨场景整合、云-边-端协同架构和价值创造多元化，为用户提供更精准、更高效、更安全的位置服务体验。

总的来说，深度学习驱动的 POI 推荐是一个充满活力和挑战的研究领域。随着新技术的不断涌现和实际应用需求的推动，这一领域将继续发展并产生更多创新性的解决方案，为用户提供更优质的位置服务体验。

参考文献

[1]ISLAM M A, MOHAMMAD M M, DAS S S S, et al. A survey on deep learning based Point-of-Interest (POI) recommendations[J]. Neurocomputing, 2022, 472: 306-325.

[2]WERNECK H, SILVA N, VIANA M C, et al. A survey on point-of-interest recommendation in location-based social networks[C]//Proceedings of the Brazilian Symposium on Multimedia and the Web. 2020: 185-192.

[3]WANG Z, HÖPKEN W, JANNACH D. A survey on Point-of-Interest recommendations leveraging heterogeneous data[J]. Information Technology & Tourism, 2025: 1-45.

[4]SÁNCHEZ P, BELLOGÍN A. Point-of-interest recommender systems based on location-based social networks: a survey from an experimental perspective[J]. ACM Computing Surveys (CSUR), 2022, 54(11s): 1-37.

[5]郭旦怀, 张鸣珂, 贾楠, 等. 融合深度学习技术的用户兴趣点推荐研究综述[J]. 武汉大学学报 (信息科学版), 2020, 45(12): 1890-1902.
GUO D H, ZHANG M K, JIA N, et al. Survey on User Point of Interest Recommendation Combining Deep Learning Technology[J]. Geomatics and Information Science of Wuhan University, 2020, 45(12): 1890-1902.

[6]黄立威, 江碧涛, 吕守业, 等. 基于深度学习的推荐系统研究综述[J]. 计算机学报, 2018, 41(7): 1619-1647.
HUANG L W, JIANG B T, LÜ S Y, et al. Survey on recommendation systems based on deep learning[J]. Chinese Journal of Computers, 2018, 41(7): 1619-1647.

[7]LI A, LIU F. A BiLSTM-attention-based point-of-interest recommendation algorithm[J]. Journal of Intelligent Systems, 2023, 32(1): 20230033.

[8]LAI Y, ZENG X. A POI recommendation model for intelligent systems using AT-LSTM in location-based social network big data[J]. International Journal on Semantic Web and Information Systems (IJSWIS), 2023, 19(1): 1-15.

[9]GUO Z, YU K, KUMAR N, et al. Deep-distributed-learning-based POI recommendation under mobile-edge networks[J]. IEEE Internet of Things Journal, 2022, 10(1): 303-317.

[10]WANG Z, ZENG J, ZHONG L, et al. DSDRec: Next POI recommendation using deep semantic extraction and diffusion model[J]. Information Sciences, 2024: 121004.

[11]SUN X, LV Z. Exploring nonlinear spatiotemporal effects for personalized next point-of-interest recommendation[J]. Frontiers of Information Technology & Electronic Engineering, 2023, 24(9): 1273-1286.

[12]CAI L, WU S, LI H, et al. Multi-granular approach to learn user mobility preferences for next Point-of-Interest recommendation[J]. Expert Systems with Applications, 2025, 267: 126189.

[13]XIA D, LIU J, HE W, et al. A Personalized POI Recommendation Algorithm Using BERT-ACNN-GRU[J]. Journal of circuits, systems and computers, 2024, 33(02): 2450022.

[14]JIA Y. Attention-based time sequence and distance contexts gated recurrent unit for personalized POI recommendation[J]. International Journal of Information Technologies and Systems Approach (IJITSA), 2022, 16(2): 1-14.

[15]QI L, LIU Y, LIU W, et al. Counterfactual user sequence synthesis augmented with continuous time dynamic preference modeling for sequential POI recommendation[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial

Intelligence. 2024: 2306-2314.

[16]CHANG W, SUN D, DU Q. Intelligent sensors for POI recommendation model using deep learning in location-based social network big data[J]. Sensors, 2023, 23(2): 850.

[17]PENG J, SHI Y, WANG C. Next Points of Interest Recommendations Based on Spatio-Temporal-Category Pattern Information[C]//International Conference on Intelligent Computing. Singapore: Springer Nature Singapore, 2024: 324-333.

[18]ZHENG Y, ZHOU X. Capturing Fine and Coarse Grained User Preferences with Dual-Transformer for Next POI Recommendation[C]//Asia-Pacific Web (APWeb) and Web-Age Information Management (WAIM) Joint International Conference on Web and Big Data. Singapore: Springer Nature Singapore, 2024: 359-373.

[19]LONG J, YE G, CHEN T, et al. Diffusion-based cloud-edge-device collaborative learning for next POI recommendations[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 2026-2036.

[20]JARRAD S, NAACKE H, GANCARSKI S, et al. Embedding-Enhanced Similarity Metrics for Next POI Recommendation[C]//12th International Conference on Data Science, Technology and Applications. SCITEPRESS-Science and Technology Publications, 2023: 247-254.

[21]XIE J, CHEN Z. Hierarchical transformer with spatio-temporal context aggregation for next point-of-interest recommendation[J]. ACM Transactions on Information Systems, 2023, 42(2): 1-30.

[22]DUAN C, WEN J, ZHOU W, et al. Learning robust travel preferences via check-in masking for next POI recommendation[J]. Expert Systems with Applications, 2025, 267: 126106.

[23]WANG Z, ZENG J, WEN J, et al. Point-of-interest recommendation using deep semantic model[J]. Expert Systems with Applications, 2023, 231: 120727.

[24]WANG X, FUKUMOTO F, LI J, et al. STaTRL: Spatial-temporal and text representation learning for POI recommendation[J]. Applied Intelligence, 2023, 53(7): 8286-8301.

[25]XIA Q, HARA T, MAEKAWA T, et al. An effective and efficient self-attention based model for next poi recommendation[C]//2023 IEEE International Conference on Pervasive Computing and Communications Workshops and other Affiliated Events (PerCom Workshops). IEEE, 2023: 478-483.

[26]DU J, ZHOU S, YU J, et al. Cross-task multimodal reinforcement for long tail next poi recommendation[J]. IEEE Transactions on Multimedia, 2023.

[27]WANG X, FUKUMOTO F, CUI J, et al. Eedn: Enhanced encoder-decoder network with local and global context learning for poi recommendation[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2023: 383-392.

[28]HE X, HE W, LIU Y, et al. ImNext: Irregular Interval Attention and Multi-task Learning for Next POI Recommendation[J]. Knowledge-Based Systems, 2024, 293: 111674.

[29]JIANG S, HE W, CUI L, et al. Modeling long-and short-term user preferences via self-supervised learning for next poi recommendation[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 17(9): 1-20.

[30]TIAN J, ZHAO Z, DING Z. Next Point-of-Interest Recommendation Based on Joint Mining of Spatial–Temporal and Semantic Sequential Patterns[J]. ISPRS International Journal of Geo-Information, 2023, 12(7): 297.

[31]CHENG S, WU Z, QIAN M, et al. Point-of-interest recommendation based on bidirectional self-attention mechanism by fusing spatio-temporal preference[J]. Multimedia Tools and Applications, 2024, 83(9): 26333-26347.

[32]WU Y, ZHAO G, LI M, et al. Reason Generation for Point of Interest Recommendation Via a Hierarchical Attention-Based Transformer Model[J]. IEEE Transactions on Multimedia, 2023.

[33]YANG K, YANG Y, GAO Q, et al. Self-Explainable Next POI Recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 2619-2623.

[34]MA Y, GAN M. Sequential-hierarchical attention network: Exploring the hierarchical intention feature in POI recommendation[J]. World Wide Web, 2024, 27(6): 67.

[35]WANG D, WAN F, YU D, et al. Context-and category-aware double self-attention model for next POI recommendation[J]. Applied Intelligence, 2023, 53(15): 18355-18380.

[36]QIAN X, HAO Y, XIAN X, et al. Enhancing Spatio-temporal Semantics with Contrastive Learning for Next POI Recommendation[C]//Asia-Pacific Web (APWeb) and Web-Age Information Management (WAIM) Joint International Conference on Web and Big Data. Singapore: Springer Nature Singapore, 2024: 374-389.

[37]CAO G, CUI S, JOE I. Improving the spatial–temporal aware attention network with dynamic trajectory graph learning for next Point-Of-Interest recommendation[J]. Information Pro- cessing & Management, 2023, 60(3): 103335.

[38]KONG X, CHEN Z, LI J, et al. KGNext: Knowledge- Graph-Enhanced Transformer for Next POI Recommendation With Uncertain Check-Ins[J]. IEEE Transactions on Com- putational Social Systems, 2024.

[39]LI P, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 1463-1472.

[40]ZHENG Y, ZHOU X. Modeling multi-factor user preferences based on Transformer for next point of interest recommendation[J]. Expert Systems with Applications, 2024, 255: 124894.

[41]CAI H, WANG Z. PAPR: Periodic Aware Spatial temporal Network for POI Recommendation[C]//2023 19th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery (ICNC-FSKD). IEEE, 2023: 1-9.

[42]LIU X. POI recommendation model using multi-head attention in location-based social network big data[J]. International Journal of Information Technologies and Systems Approach (IJITSA), 2022, 16(2): 1-16.

[43]ZHANG J, LI B, ZHANG Y, et al. Research on the recommendation method of urban location point of interest based on DTCN-EFFN-Transformer[J]. The Journal of Supercomputing, 2025, 81(1): 221.

[44]NIU P, QU B, FENG J, et al. Utilization of Spatio-Temporal and Social Information for POI Group Recommendation[C]//2023 24th IEEE International Conference on Mobile Data Management (MDM). IEEE, 2023: 30-35.

[45]QIN Y, WANG Y, SUN F, et al. DisenPOI: Disentangling sequential and geographical influence for point-of-interest recommendation[C]//Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. 2023: 508-516.

[46]ZHANG J, LI Y, ZOU R, et al. Hyper-relational knowledge graph neural network for next POI recommendation[J]. World Wide Web, 2024, 27(4): 46.

[47]WANG X, WANG D, YU D, et al. Intent-aware Graph Neural Network for Point-of-Interest embedding and recommendation[J]. Neurocomputing, 2023, 557: 126734.

[48]LIU Y, WU H, REZAEE K, et al. Interaction-enhanced and time-aware graph convolutional network for successive point-of-interest recommendation in traveling enterprises[J]. IEEE Transactions on Industrial Informatics, 2022, 19(1): 635- 643.

[49]CHEN J, WANG M, ZHANG H, et al. Irlm: inductive representation learning model for personalized poi recommendation[J]. IEEE Transactions on Computational Social Systems, 2022, 10(5): 2827-2836.

[50]LIU Z, ZHANG D, ZHANG C, et al. KDRank: Knowledge-driven user-aware POI recommendation[J]. Knowledge-Based Systems, 2023, 278: 110884.

[51]WU Y, JIN X, HUANG H. Muti-channel graph attention networks for POI recommendation[J]. Journal of Intelligent & Fuzzy Systems, 2023, 44(5): 8375-8385.

[52]HAN S, MA Z, ZHAO W, et al. Neighbor-Discovery Recurrent Model for Point-of-Interest Recommendation[C]//Proceedings of the 2023 6th International Conference on Big Data Technologies. 2023: 52-59.

[53]ZHAO Y, ZHANG Y, AMAGATA D, et al. POI Recommendation by Learning Short-, Long-and Mid-Term Preferences through GNN[C]//2023 24th IEEE International Conference on Mobile Data Management (MDM). IEEE, 2023: 1-10.

[54]LIU Z, MENG L, SHENG Q Z, et al. POI recommendation for random groups based on cooperative graph neural networks[J]. Information Processing & Management, 2024, 61(3): 103676.

[55]LIU Y, ZHOU X, KOU H, et al. Privacy-preserving point-of-interest recommendation based on simplified graph convolutional network for geological traveling[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(4): 1-17.

[56]LIAN X, MI J, GAO C, et al. Research on Point-of-Interest Recommendation Method based on Graph Autoencoders and Long Short-Term Preferences[C]//Proceedings of the 4th International Conference on Artificial Intelligence and Computer Engineering. 2023: 864-869.

[57]MO F, FAN X, CHEN C, et al. Sampling-based epoch differentiation calibrated graph convolution network for point-of-interest recommendation[J]. Neurocomputing, 2024, 571: 127140.

[58]FANG J, MENG X, QI X. A top-k POI recommendation approach based on LBSN and multi-graph fusion[J]. Neurocomputing, 2023, 518: 219-230.

[59]WANG Z, ZHU Y, WANG C, et al. Adaptive Graph Representation Learning for Next POI Recommendation[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2023: 393-402.

[60]FU J, GAO R, YU Y, et al. Contrastive graph learning long and short-term interests for POI recommendation[J]. Expert Systems with Applications, 2024, 238: 121931.

[61]LAI Y, SU Y, WEI L, et al. Disentangled contrastive hypergraph learning for next POI recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 1452-1462.

[62]QIN Y, GAO C, WANG Y, et al. Disentangling geographical effect for point-of-interest recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(8): 7883-7897.

[63]MO F, YAMANA H. EPT-GCN: Edge propagation-based time-aware graph convolution network for POI recommendation[J]. Neurocomputing, 2023, 543: 126272.

[64]ZENG J, TAO H, WEN J, et al. Explainable next POI recommendation based on spatial–temporal disentanglement representation and pseudo profile generation[J]. Knowledge-Based Systems, 2025, 309: 112784.

[65]ZENG J, TAO H, TANG H, et al. Global and local hypergraph learning method with semantic enhancement for POI recommendation[J]. Information Processing & Management, 2025, 62(1): 103868.

[66]WANG J, YANG B, LIU H, et al. Global spatio-temporal aware graph neural network for next point-of-interest recommendation[J]. Applied Intelligence, 2023, 53(13): 16762-16775.

[67]SUN X, HUANG B, WANG X, et al. MARAN: Supporting awareness of users' routines and preferences for next POI recommendation based on spatial aggregation[J]. Expert Systems with Applications, 2024, 238: 121961.

[68]GAN M, TAN C. Mining multiple sequential patterns through multi-graph representation for next point-of-interest recommendation[J]. World Wide Web, 2023, 26(4): 1345-1370.

[69]LI Y, ZHANG Z, HUANG Z, et al. Moveformer: Spatial graph periodic injection network for next POI recommendation[C]// International Conference on Knowledge Science, Engineering and Management. Singapore: Springer Nature Singapore, 2024: 41-57.

[70]TAO H, ZENG J, WANG Z, et al. Next POI Recommendation Based on Spatial and Temporal Disentanglement Representation[C]//2023 IEEE International Conference on Web Services (ICWS). IEEE, 2023: 84-90.

[71]YIN F, LIU Y, SHEN Z, et al. Next POI recommendation with dynamic graph and explicit dependency[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(4): 4827-4834.

[72]WANG D, LIU K, XIONG H, et al. Online POI recommendation: Learning dynamic geo-human interactions in streams[J]. IEEE Transactions on Big Data, 2022, 9(3): 832- 844.

[73]XU X, SUZUMURA T, YONG J, et al. Revisiting Mobility Modeling with Graph: A Graph Transformer Model for Next Point-of-Interest Recommendation[C]//Proceedings of the 31st ACM International Conference on Advances in Geographic Information Systems. 2023: 1-10.

[74]YAN X, SONG T, JIAO Y, et al. Spatio-temporal hypergraph learning for next POI recommendation[C]//Proceedings of the 46th international ACM SIGIR conference on research and development in information retrieval. 2023: 403-412.

[75]LIU S, QI Y, LI G, et al. STGIN: Spatial-Temporal Graph Interaction Network for Large-scale POI Recommendation[C]// Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 4120-4124.

[76]WU J, LI H, YANG C, et al. MGTIPM: A Multi-granularity Time Intention Prediction Model for Next Point-of-Interest Recommendation[C]//2023 11th International Conference on Agro-Geoinformatics (Agro-Geoinformatics). IEEE, 2023: 1-5.

[77]FENG S, MENG F, CHEN L, et al. Rotan: A rotation-based temporal attention network for time-specific next poi recommendation[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2024: 759-770.

[78]LI H, YUE P, LI S, et al. Spatio-temporal intention learning for recommendation of next point-of-interest[J]. Geo-spatial Information Science, 2024, 27(2): 384-397.

[79]ZHANG H, BAI W, DING J, et al. Time-Aware POI Recommendation Based on Multi-Grained Location Grouping[C]// 2023 26th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2023: 1796- 1801.

[80]REN J, GAN M. Mining dynamic preferences from geographical and interactive correlations for next POI recommendation[J]. Knowledge and Information Systems, 2023, 65(1): 183-206.

[81]ZHANG X, WENG H, WEI Y, et al. Multivariate Hawkes Spatio-Temporal Point Process with attention for point of interest recommendation[J]. Neurocomputing, 2025, 619: 129161.

[82]HUANG Y, LAN P, LI X, et al. Residual Spatio-Temporal Collaborative Networks for Next POI Recommendation[C]// Pacific-Asia Conference on Knowledge Discovery and Data Mining. Singapore: Springer Nature Singapore, 2024: 144-155.

[83]ZHANG G, ZHANG X, QI L, et al. Spatio-Temporal Aware Next Point-of-Interest Recommendation with Privacy Preserving[C]//International Conference on Database Systems for Advanced Applications. Singapore: Springer Nature Singapore, 2024: 156-172.

[84]WANG X J, LIU T, FAN W. TGVx: Dynamic personalized POI deep recommendation model[J]. INFORMS Journal on Computing, 2023, 35(4): 786-796.

[85]OU J, JIN H, WANG X, et al. STA-TCN: Spatial-temporal attention over temporal convolutional network for next point-of-interest recommendation[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 17(9): 1-19.

[86]JIANG S, WU J. Temporal-geographical attention-based transformer for point-of-interest recommendation[J]. Journal of Intelligent & Fuzzy Systems, 2023 (Preprint): 1-11.

[87]LIU X, LI X, CAO Y, et al. Mandari: Multi-modal temporal knowledge graph-aware sub-graph embedding for next-POI recommendation[C]//2023 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2023: 1529-1534.

[88]YU T, ZHANG L, ZHANG Y. PRMF: point of interest recommendation method integrating multiple factors[J]. International Journal of Web Engineering and Technology, 2023, 18(1): 45-61.

[89]CHENG X, LI N, RYSBAYEVA G, et al. Influence-aware successive point-of-interest recommendation[J]. World Wide Web, 2023, 26(2): 615-629.

[90]ZENG J, TANG H, ZHAO Y, et al. Neu-PCM: Neural-based potential correlation mining for POI recommendation[J]. Applied Intelligence, 2023, 53(9): 10685-10698.

[91]HUANG S, WU X, WU X, et al. Sentiment analysis algorithm using contrastive learning and adversarial training for POI recommendation[J]. Social Network Analysis and Mining, 2023, 13(1): 75.

[92]LIM N, HOOI B, NG S K, et al. Learning Hierarchical Spatial Tasks with Visiting Relations for Next POI Recommendation[J]. ACM Transactions on Recommender Systems, 2023, 1(4): 1-26.

[93]HUANG T, PAN X, CAI X, et al. Learning Time Slot Preferences via Mobility Tree for Next POI Recommendation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(8): 8535-8543.

[94]ACHARYA M, MOHBEY K K, RAJPUT D S. Long-term preference mining with temporal and spatial fusion for point-of-interest recommendation[J]. IEEE Access, 2024.

[95]WU J, ZHANG Y, LI Y, et al. SSTP: social and spatial-temporal aware next point-of-interest recommendation[J]. Data Science and Engineering, 2023, 8(4): 329-343.

[96]GAN M, MA Y. Mapping user interest into hyper-spherical space: A novel POI recommendation method[J]. Information Processing & Management, 2023, 60(2): 103169.

[97]LONG Z, WANG L, LIU Q, et al. Personalized Interest Sustainability Modeling for Sequential POI Recommendation[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. 2023: 4145-4149.

[98]WANG L, ZHENG W, XIAO Y. Graph-based POI Recommendation through Self-Supervised Curriculum Learning[C]// 2024 27th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2024: 1140-1145.

[99]LV Y, SANG Y, TAI C, et al. Online meta-learning for POI recommendation[J]. GeoInformatica, 2023: 1-16.

[100]TSUBOUCHI R, HARA T, YONEKAWA K, et al. Unvisited Out-Of-Town POI Recommendation with Simultaneous Learning of Multiple Regions[C]//2023 IEEE International Conference on Big Data (BigData). IEEE, 2023: 915-924.

[101]YANG T, GAO Y, HUANG Z, et al. UPTDNet: A User Preference Transfer and Drift Network for Cross-City Next POI Recommendation[J]. International Journal of Intelligent Systems, 2023, 2023(1): 9091570.

[102]LI D, GONG Z. A deep neural network for crossing-city POI recommendations[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(8): 3536-3548.

[103]SUN K, QIAN T, LI C, et al. Pre-Training Across Different

Cities for Next POI Recommendation[J]. ACM Transactions on the Web, 2023, 17(4): 1-27.

[104]LONG J, CHEN T, NGUYEN Q V H, et al. Model-agnostic decentralized collaborative learning for on-device POI recommendation[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2023: 423-432.

[105]REZAEI E, SEYEDMOHAMMADI S J, ABOUEI J, et al. FedDist-POIRec: Federated Distillation for Point-Of-Interest Recommendation in Human Mobility Prediction[C]//2024 IEEE 4th International Conference on Human-Machine Systems (ICHMS). IEEE, 2024: 1-6.

[106]CHEN J, GUAN H, LI H, et al. PACIFIC: Enhancing Sequential Recommendation via Preference-aware Causal Intervention and Counterfactual Data Augmentation[C]//Pro- ceedings of the 33rd ACM International Conference on Information and Knowledge Management. 2024: 249-258.

[107]WANG H, LI P, LIU Y, et al. Towards real-time demand-aware sequential POI recommendation[J]. Information Sciences, 2021, 547: 482-497.

[108]WANG Z, ZHU Y, ZHANG Q, et al. Graph-enhanced spatial-temporal network for next POI recommendation[J]. ACM Transactions on Knowledge Discovery from Data (TKDD), 2022, 16(6): 1-21.

[109]RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized markov chains for next-basket recommendation[C]//Proceedings of the 19th international conference on World wide web. 2010: 811-820.

[110]LIU Q, WU S, WANG L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]//Pro-ceedings of the AAAI conference on artificial intelligence. 2016, 30(1).

[111]FENG J, LI Y, ZHANG C, et al. Deepmove: Predicting human mobility with attentional recurrent networks[C]//Proceedings of the 2018 world wide web conference. 2018: 1459-1468.

[112]SUN K, QIAN T, CHEN T, et al. Where to go next: Modeling long-and short-term user preferences for point-of-interest recommendation[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(01): 214-221.

[113]LUO Y, LIU Q, LIU Z. Stan: Spatio-temporal attention network for next location recommendation[C]//Proceedings of the web conference 2021. 2021: 2177-2185.

[114]SUN R, CAO X, ZHAO Y, et al. Multi-modal knowledge graphs for recommender systems[C]//Proceedings of the 29th ACM international conference on information & knowledge management. 2020: 1405-1414.

[115]YANG H, YIN L. Re-net: A relation embedded deep model for au occurrence and intensity estimation[C]//Proceedings of the Asian conference on computer vision. 2020.

[116]ZHOU G, ZHU X, SONG C, et al. Deep interest network for click-through rate prediction[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 1059-1068.

[117]ZHOU G, MOU N, FAN Y, et al. Deep interest evolution network for click-through rate prediction[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 5941-5948.

[118]WU S, TANG Y, ZHU Y, et al. Session-based recommendation with graph neural networks[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 346-353.

[119]WANG X, HE X, WANG M, et al. Neural graph collaborative filtering[C]//Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. 2019: 165-174.

[120]HE X, DENG K, WANG X, et al. Lightgcn: Simplifying and powering graph convolution network for recommenda-tion[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639-648.

[121]WANG H, SHEN H, OUYANG W, et al. Exploiting POI-specific geographical influence for point-of-interest recommendation[C]//IJCAI. 2018: 3877-3883.

[122]ZHENG C, TAO D, WANG J, et al. Memory augmented hierarchical attention network for next point-of-interest recommendation[J]. IEEE Transactions on Computational Social Systems, 2020, 8(2): 489-499.

[123]VISA M, PATEL D. Attention based long-short term memory model for product recommendations with multiple timesteps[C]//2021 5th International Conference on Computing Methodologies and Communication (ICCMC). IEEE, 2021: 605-612.

[124]LIU X, YANG Y, XU Y, et al. Real-time POI recommendation via modeling long-and short-term user preferences[J]. Neurocomputing, 2022, 467: 454-464.

[125]ZHU N, CAO J, LIU Y, et al. Sequential modeling of hierarchical user intention and preference for next-item recommendation[C]//Proceedings of the 13th international conference on web search and data mining. 2020: 807-815.

[126]TANJIM M M, SU C, BENJAMIN E, et al. Attentive sequential models of latent intent for next item recom-mendation[C]//Proceedings of The Web Conference 2020. 2020: 2528-2534.

[127]LIU W, LIN Z, ZHU H, et al. Attention-based adaptive memory network for recommendation with review and rating[J]. IEEE Access, 2020, 8: 113953-113966.

黄屏（2000—）,女，广西钦州人，湖北文理学院计算机工程学院硕士研究生，主要研究方向为推荐系统和深度学习。学生会员。

HUANG Ping, born in 2000, female, from Qinzhou, Guangxi, is a master's student at the School of Computer Engineering, Hubei University of Arts and Science. Her main research areas are recommendation systems and deep learning. Student membership.

王峰（1984—），男，湖北宜都人，湖北文理学院计算机工程学院副教授，硕士生导师，主要研究方向为人工智能，城市计算，工业互联网等。高级会员。

WANG Feng, born in 1984, male, from Yidu, Hubei, is an associate professor and master's supervisor at the School of Computer Engineering, Hubei University of Arts and Science. His main research areas are artificial intelligence, urban computing, and industrial internet. Senior member.

刘广腾（2000—），男，山东菏泽人，湖北文理学院计算机工程学院硕士研究生，主要研究方向为推荐系统和深度学习。学生会员。

LIU Guangteng, born in 2000. He is an M.S. candidate at school of Computer Engineering, Hubei University of Arts and Science. His research interests include recommender system and deep learning. Student membership.

吴中博（1980—），男，湖北襄阳人，湖北文理学院计算机工程学院教授，博士，主要研究方向为数据库和人工智能。普通会员。

WU Zhongbo, born in 1980. He is a Ph.D. Professor at the School of Computer Engineering, Hubei University of Arts and Science. His research interests include Databases and artificial intelligence. Ordinary membership.

李晓丽（1986—），女，河北石家庄人，湖北文理学院计算机工程学院副教授，硕士生导师，主要研究方向为联邦学习技术，人工智能。普通会员。

LI Xiaoli, born in 1986, female, from Shijiazhuang, Hebei, is an associate professor at the School of Computer Engineering, Hubei University of Arts and Science, and a master's supervisor. Her main research areas are federated learning technology and artificial intelligence. Ordinary membership.

黄金洲（1986—），男，湖北咸宁人，湖北文理学院计算机工程学院副教授，硕士生导师，主要研究方向为社交网络、云计算、智慧交通。普通会员。

HUANG Jinzhou, born in 1986, male, from Xianning, Hubei, is an associate professor and master's supervisor at the School of Computer Engineering, Hubei University of Arts and Science. His main research areas are social networks, cloud computing, and smart transportation. Ordinary membership.