doi: 10. 19697/j. cnki. 1673-4432. 202505005

Geo-Text-700测试集的GIS领域国产大语言模型的性能评测

侯家熙，袁 莹*，黄宗财，李 晖

（厦门理工学院计算机与信息工程学院，福建 厦门361024）

［摘 要］针对国产大语言模型（large language models， LLMs）在地理信息科学（geographic information science，GIS）领域缺乏系统性评估基准问题，构建Geo-Text-700测试集的GIS领域定制化测评体系，基于优劣解距离层次分析法（technique for order preference by similarity to ideal solution，TOPSIS）对10个主流国产模型进行多维度评估。测评结果显示：模型表现呈现显著题型分化，客观题平均得分为68. 4（标准差±5. 2），较主观题低21. 7%（P<0. 05）；Doubao-pro-32k综合得分最优（87. 3），客观题优势显著（单选86，填空77）；hunyuan-turbo在主观题（简答88. 1，编程90. 83）方面展现高阶任务潜力；领域知识盲区突出，如GIS拓扑规则题错误率为43. 6%。

［关键词］地理信息科学（GIS）；大语言模型；评测体系；Geo-Text-700测试集；TOPSIS-AHP法

［中图分类号］TP391. 1 ［文献标志码］A ［文章编号］1673-4432（2025）05-0040-08

Performance Evaluation of Chinese Large Language Models for GIS Based on Geo-Text-700

HOU Jiaxi, YUAN Ying*, HUANG Zongcai, LI Hui

(School of Computer and Information Engineering,Xiamen University of Technology,Xiamen 361024,China)

Abstract: Addressing the lack of a systematic evaluation benchmark for domestic large language models (LLMs) in the field of geographic information science (GIS), this study constructs a customized evaluation system based on the Geo-Text-700 test set and conducts a multi-dimensional assessment of 10 mainstream domestic models using the technique for order preference by similarity to ideal solution (TOPSIS) integrated with the analytic hierarchy process (AHP). The evaluation results reveal a significant divergence in model performance across different question types. The average score for objective questions was 68.4 (standard deviation ±5.2), which is 21.7% lower (P<0.05) than that for subjective questions. The Doubao-pro-32k model achieved the highest comprehensive score (87.3), demonstrating notable advantages in objective questions (multiple-choice: 86, fill-in-the-blank: 77). The hunyuan-turbo model showed potential for advanced tasks in

收稿日期： 2025-03-03 **修回日期：** 2025-05-01

基金项目： 国家自然科学基金项目“地理知识图谱嵌入学习过程中空间依赖性精细表达研究”（42401562）；福建省自然科学基金项目“顾及时空特征的亚热带典型树种多源遥感知识图谱构建”（2023J011425）

通信作者： 袁莹，男，副教授，博士，研究方向为地理信息系统应用、WebGIS等，E-mail：yuanying@xmut.edu.cn。

引文格式： 侯家熙，袁莹，黄宗财，等.Geo-Text-700测试集的GIS领域国产大语言模型的性能评测［J］.厦门理工学院学报，2025，33（5）：40-47.

Citation: HOU J X, YUAN Y, HUANG Z C, et al. Performance evaluation of Chinese large language models for GIS based on Geo-Text-700[J].Journal of Xiamen University of Technology,2025,33 (5):40-47. (in Chinese)

中国知网 https://www.cnki.net

subjective questions (short-answer: 88.1, programming: 90.83). Prominent knowledge gaps within the domain were identified, such as an error rate of 43.6% for questions related to GIS topological rules.

Key words: geographic information science (GIS);large language models (LLMs);evaluation system; Geo-Text-700 test set; TOPSIS-AHP method

随着大语言模型（large language models，LLMs）在自然语言处理领域取得的突破性进展[1]，其性能评估体系逐渐呈现“通用领域趋同垂直领域滞后”的双轨特征。通用评测基准已形成规模化体系，国际主流测试集如CMMLU[2]、HumanEval[3]等通过多维度能力测试推动模型迭代；中文领域亦涌现C-EVAL[4]、Gaokao[5]等本土化基准，李敏[6]、王野[7]等也分别将其应用于医疗、教育领域评估。垂直领域评测明显呈现分化态势，医疗（CBLUE）[8]、法律（LawBench）[9]、金融（FinEval）[10]等热门领域已建立专业评测体系。但这些评测体系普遍存在两大局限：其一，评估方式过度依赖单项选择题，虽然保证了客观性，但却弱化了对复杂任务处理能力的检验；其二，非热门领域系统性测评严重缺失，尤其在地理信息科学（geographic information science，GIS）领域。

作为融合空间位置、属性特征、时序演变的交叉学科，GIS面临双重评估困境，其LLM评估也遭遇数据生态复杂性、动态适应性、安全敏感性等结构性挑战。现行以选择题为主导的评测模式难以匹配学科核心需求，如拓扑关系推理（九交模型判别）、多尺度地理特征关联等涉及空间逻辑链推导的复杂任务。这种评估体系的缺陷已引发技术迭代阻滞，数据闭环缺失导致模型陷入局部最优陷阱，评测盲区使得优化方向偏离真实需求，最终延缓地理智能技术在智慧城市、生态监测等关键场景中的应用进程。为突破现有评估框架，为垂直领域LLMs评估提供方法论框架，本研究构建一个基于Geo-Text-700测试集可全面覆盖空间推理、多模态解析等核心能力维度的GIS领域定制化评测体系，并通过10款国产大模型的实证测评，验证该基准在技术诊断与优化引导方面的有效性。

1　评测体系的设计

本研究针对当前GIS领域LLMs评估方法单一化的技术瓶颈，基于学科知识体系的多维特征，构建了面向GIS的LLMs系统化评测基准。该基准旨在全面评估LLMs在GIS领域的性能，涵盖模型在地理数据处理、空间分析、地理信息提取等多个关键任务上的表现。这一评测框架不仅可系统性揭示国产LLMs在地理信息处理中的技术边界与知识盲区，还可为国产LLMs在地理信息产业的工程化落地提供可复用的评估体系和决策支持框架。国产LLMs评测体系框架流程如图1所示。

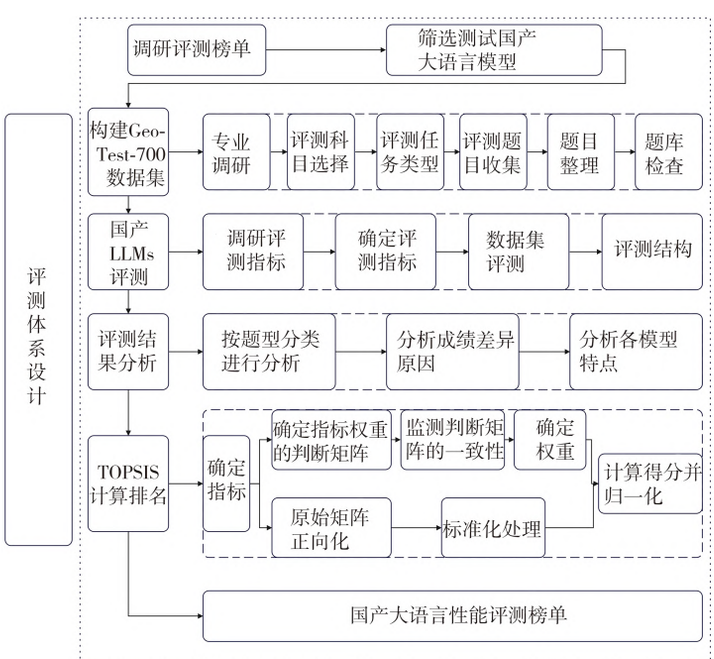

图1　国产LLMs评测体系框架流程图

Fig. 1　Flow chart of domestic LLMs evaluation system framework

1.1　评测模型的选取

在评测模型选取的初期，本文对当前具有较高认可度的LLMs评测榜单CLUE[11]、CEval[12]和CMRC[13]等进行了调研，并根据这些榜单的评估结果，选取性能优越的中文大模型作为本文的候选评测模型。调研结果显示，对于同一模型，LLMs的参数量和上下文长度的变化会显著影响其性能表现[14]。由于各公司发布LLMs的参数量未公开，或者量

中国知网　https://www.cnki.net

级差异较大，例如，腾讯的混元大模型的参数量尚未公布，百度文心的大模型约为百亿级别，而GLM大模型的参数量约为千亿级别。因此，本文选择各大公司最新且性能最强的LLMs，确保所有模型的上下文长度均为32 000个token，统一进行API调用和评测。测试所用的LLMs的详细信息见表1。

表1 测试所用的LLMs的详细信息

Table 1 Detailed information on the LLMs used for testing

模型名称	发布机构	参数规模	上下文长度/个	调用方式
hunyuan-turbo(腾讯)	腾讯	超千亿参数	32 000	API
讯飞星火V4. 0	科大讯飞	未公布	32 000	API
step-1-32k	阶跃星辰	千亿参数	32 000	API
qwen-plus-0723	阿里云	千亿参数	32 000	API
moonshot-v1-32k	月之暗面	千亿参数	32 000	API
Taichu-2. 0	紫东太初	32亿参数	32 000	API
SenseChat-32k	商汤科技	1 800亿参数	32 000	API
Baichuan3-Turbo	百川智能	超千亿参数	32 000	API
yi-large	零一万物	千亿参数	32 000	API
Doubao-pro-32k	字节跳动	120亿参数	32 000	API

1. 2 评测任务的构建

针对GIS领域，本文构建了7种任务用于评测，具体包括单项选择题、多项选择题、填空题、判断题、专有名词解释、简答题、论述题和编程题。各任务的具体描述见表2。

表2 评测任务表

Table 2 Evaluation task table

任务类型	具体描述
单项选择题	要求模型从多个选项中挑选一个正确答案，主要考察其在特定上下文中的理解和推理能力
多项选择题	要求模型从多个选项中选择一个或多个正确答案，进一步考察其在复杂情境下的理解和推理能力
填空题	要求模型在给定的上下文中生成合适的词或短语来填补空缺，主要考察其生成能力和上下文理解能力
判断题	要求模型判断给定陈述的真伪，主要考察其在语义理解和事实推理方面的能力
专有名词解释	要求模型对给定的专有名词进行解释或定义，主要考察其在特定领域知识和解释能力方面的表现
简答题	要求模型提供简短的、具体的回答，主要考察其在快速和准确生成信息方面的能力
论述题和编程题	要求模型提供详细的解释、论证或编写代码，主要考察其在深度理解、复杂生成和逻辑推理方面的能力

为了确保评测在GIS领域内具有广泛性与均衡性，本文依据GIS的定义，覆盖了地理学基础知识、地理信息系统、数据库原理、遥感原理与技术等专业领域，最终构建10个评测科目（见表3）。每门科目使用上述7种任务进行评测，每个任务测试10个题目，总计700个题目。

在完成题目收集后，本文针对不同任务构建了相应的提示指令[15]。提示指令的设计需结合特定任务及预期输出，如在单项选择题中，为降低后续评测指标计算的复杂性，需确保模型尽可能仅输出与正确答案对应的选项。如果仅依赖问题及相关选项作为输入，模型在大多数情况下可能会输出无关内容，给后续评测带来不便。因此，在提示过程中设定模型角色有助于提升输出效果。考虑到领域特性，本文在构建提示指令时引入相关角色的表述。此外，选择少量数据在各模型上进行测试，以确保大多数模型能够输出符合要求的内容。提示指令示例见表4。

中国知网 https://www.cnki.net

表3　评测科目表

Table 3　Evaluation subject list

科目名称	具体描述
摄影测量学	通过影像研究信息的获取、处理、提取和成果表达的一门信息科学
GIS设计与开发	创建和实施用于收集、管理、分析和可视化地理空间数据的软件系统的过程
遥感导论	通过传感器从远处收集和分析地球表面及其特征信息的技术
自然地理学	专注于研究地球自然环境及其组成部分，包括地形、气候、水体、土壤、生物和生态系统等
遥感数字图像处理	涉及对从卫星、航空器或其他传感器获取的数字图像进行分析、改进和提取有用信息的过程
卫星导航定位原理与应用	一种利用卫星系统提供地理位置和时间信息的技术
地理信息系统原理	一种用于捕获、存储、分析和管理地理空间数据的系统
地图学	研究地图制作、使用及其相关技术和理论的科学与艺术
空间数据库	专门用于存储、查询和管理空间数据的数据库系统
高级程序设计	在编程中应用更复杂的概念、技术和工具，涉及设计模式、数据结构、算法、并发编程、网络编程等

表4　提示指令示例

Table 4　Prompt instruction example

题型	提示词
单项选择题	下面是一道单项选择题，请直接给出答案： 数字摄影测量系统是由_____代替人的立体量测与识别，完成影像几何与物理信息的自动提取。 A. 计算机视觉　B. 机械导杆　C. 光学投影　D. 光学与机械导杆
多项选择题	下面是一道多项选择题，请直接给出答案： 数字摄影测量的基本范畴还是确定被摄对象的___与___，即量测与理解。A. 几何　B. 高程 C. 物理属性　D. 辐射特性
判断题	下面是一道判断题，请直接判断命题正确或错误： 利用立体像对可以确定物点的空间坐标。
填空题	下面是一道填空题，请直接给出答案： GPS辅助空中三角测量的作用是_____。
名词解释题	下面是数字摄影测量科目中的一个专有名词，请简要解释一下其含义： 绝对定向元素
简答题	下面是一道简答题，请给出答案，答案要简洁明了： 今利用带POS系统的数字航摄仪定点拍摄了一立体像对，试问如何快速确定感兴趣点的地面三维坐标？在POS系统提供的影像外方位元素无误差的情况下，简要叙述其计算过程。
论述题	下面是一道论述题，请给出答案，答案要详细、具体： 在城市建设规划中，发现某居民区新增了大量的建筑物，为了及时更新该地区的地籍图，利用配有POS系统的数字航摄仪获取了一个立体像对，请问如何用最快速的方法将新建房屋加入地籍管理数据库中?在POS系统提供的相片外方位元素无误差的情况下，简要叙述其基本思想并绘出作业流程图。
编程题	请设计一个程序进行城市规划分析：土地使用、交通流量与人口密度的综合可视化，从数据集中提取相关信息，输出易于理解的可视化结果，帮助决策者进行更好的城市规划。 在进行城市规划时，需要对城市不同区域的土地使用情况、交通流量、人口密度等因素进行综合分析。你需要设计一个程序，能够从数据集中提取信息，进行空间分析，并输出可视化结果，帮助决策者进行更好的规划。

中国知网　https://www.cnki.net

1.3 评测指标的选取

生成式模型[16]的发展为模型评估带来了新的挑战。基于当前自然语言处理的评价指标[17]，本文针对不同特定任务选择了相应的指标，以对模型生成内容进行客观和定量评价。

1）准确率。准确率是正确预测数量与总预测数量的比值，它的计算简单、便捷，适用于单项选择和分类任务。在单项选择、多项选择、填空、判断和代码等任务中，准确率是衡量模型能力的重要指标。

2）BLEU（bilingual evaluation understudy）分数[18]。BLEU分数用于评估机器翻译和文本生成任务，通过计算生成文本与参考文本之间的n-gram重合度来衡量生成内容的质量。虽然BLEU在长文本评估中的表现效果不好，但在名词解释和简答等短文本问题中，它是评估模型能力的理想选择。因此，本文采用BLEU作为评估名词解释和简答题的主要指标。BLEU的计算公式为$\mathrm{BLEU}_{\mathrm{Score}} = \mathrm{GMP} \times \mathrm{BP}$，其中：$\mathrm{BLUE}_{\mathrm{Score}}$是BLUE分数；GMP为加权精确率的几何平均数，$\mathrm{GMP} = \exp\left(\sum_{n=1}^{N}(\omega_n \lg P_n)\right)$，$\omega_n$是权重（通常为$\frac{1}{n}$）；BP为长度惩罚因子。

3）ROUGE-L（recall-oriented understudy for gisting evaluation based on longest common subsequence）分数[19]。ROUGE-L分数是一种基于最长公共子序列的自动摘要和机器翻译评估指标，它通过计算候选文本（如生成摘要）与参考文本（如人工摘要）之间的最长公共子序列，同时结合召回率、精确率和F_1值来评估质量。ROUGE-L能够捕捉生成文本与参考文本的序列相似性，因此更适合评估生成文本的覆盖率和整体结构，特别是长文本问题。因此本文采用ROUGE-L作为论述题的主要评估指标。

为了便于最终比较，本文将所有指标得分按百分制统一，得到各任务的具体分值。评测指标选取见表5。

表5 评测指标选取表

Table 5 Evaluation index selection table

评测指标	评测任务类型
准确率	单项选择题、多项选择题、填空题、判断和代码题
BLEU分数	名词解释和简答题
ROUGE-L分数	论述题

1.4 综合成绩排名计算

本文运用TOPSIS法[20]对所测国产LLMs进行综合排名，具体步骤如下。

1）建立判断矩阵。本研究建立的判断矩阵见表6。该矩阵是一个对称矩阵，其对角线元素为1，非对角元素则表示一个准则相对于另一个准则的重要性程度。表6中，“1”表示C_i与C_j的影响相同；“3”表示C_i比C_j的影响稍强；“5”表示C_i比C_j的影响强；“7”表示C_i比C_j的影响明显的强；“2，4，6，8”表示C_i与C_j的影响之比在上述两个相邻等级之间；“1/2，…，1/9”表示C_i与C_j的影响之比为a_{ij}的互反数。

2）进行一致性检验。计算一致性比率（consistency ratio， CR），通常要求CR值小于0.1，以表明判断矩阵具有良好的一致性。若CR值大于0.1，则需重新评估判断矩阵。CR的计算公式为$\mathrm{CR} = \frac{I_{\mathrm{C}}}{I_{\mathrm{R}}}$，其中：$I_{\mathrm{C}}$为一致性指标，$I_{\mathrm{C}} = \frac{\lambda_{\max} - n}{n - 1}$，$\lambda_{\max}$为最大特征根，$n$为特征根；$I_{\mathrm{R}}$为平均随机一致性指标。

3）计算判断矩阵的特征值和特征向量，得到各层次元素的权重向量。各层次元素的权重见表7。

4）将赋权处理后的结果进行归一化处理，得出最终的综合排行榜。

表6 判断矩阵

Table 6 Judgment matrix

题型	选择题	多项选择题	填空题	判断题	名词解释题	简答题	论述（编程题）
选择题	1	1	5	1	1/3	1/5	1/6
多项选择题	1	1	5	1	1/3	1/5	1/6
填空题	1/5	1/5	1	1/3	1/3	1/7	1/7
判断题	1	1	3	1	1/3	1/5	1/8
名词解释题	3	3	3	3	1	1/3	1/5
简答题	5	5	7	5	3	1	1/3
论述(编程题)	6	6	7	8	5	3	1

表7 参数权重表

Table 7 Parameter weight table

题型	权重
选择题得分	0.077 7
多项选择题得分	0.077 7
填空题得分	0.039 3
判断题得分	0.069 0
名词解释题得分	0.128 8
简答题得分	0.232 2
论述(编程)题得分	0.360 0

中国知网 https://www.cnki.net

2　Geo-Text-700数据集的构建

现有的大模型测试数据集缺乏GIS领域的相关数据，学科覆盖十分有限，因此无法充分测试和评估LLMs在GIS领域的知识能力。因此，需要开发一个专门针对GIS领域的测试数据集，以评估LLMs在该领域的能力。为便于描述和使用该数据集，本文将构建的面向GIS领域的LLMs评测数据集命名为Geo-Text-700数据集。

2.1　构建原则

1）领域相关性原则。该原则确保数据集中的内容与GIS紧密相关，包括但不限于地形数据、空间统计、遥感影像分析、地理信息系统应用等。该原则的判断标准为：1）内容涉及GIS核心理论与方法（如空间拓扑关系分析、地理加权回归算法等）；2）数据反映典型地理现象或工程场景（如城市热岛效应、流域水文过程建模）。例如，在遥感影像分析方向，可以选取Landsat时序数据，构建“长三角城市群扩张与耕地流失关联分析”案例；在GIS应用方向，设计基于Dijkstra算法的最优路径规划实验任务。

2）多样性原则。在构建数据集时，尽量消除潜在的偏见，如只找一些简单习题进行测试，确保数据集涵盖广泛的科目。

3）数据一致性原则。对不同来源的数据进行标准化处理，以确保题目格式的一致性，便于后续的测试。

4）正确性原则。确保数据中的信息准确无误，避免传播错误信息。尽量避免缺失值，确保数据集在各个方面的完整性，以便模型学习全面的知识。

5）可拓展性原则。数据集的设计要考虑日后添加新的数据来源或更新现有数据的情况。

2.2　数据收集与处理

Geo-Text-700数据集的构建遵循“权威溯源-时效控制-多级校检”的质量保障体系。在数据采集阶段，来源筛选标准具有院校权威性（限定采自教育部第四轮学科评估GIS专业B+级以上院校（如武汉大学）的核心课程试题库）、教学实践验证（优先选取连续开设≥5年且通过课程评估（TQC≥85分）的精品课测试题）和时效性控制（采集2018—2024年更新试题，剔除涉及ArcGIS 10. X等过时技术试题）。采集方法是基于Scrapy框架构建学科关键词驱动的智能爬虫（包含“地理编码”“空间插值”等127个专业术语）。在数据处理阶段，去重机制是通过SimHash算法（相似度阈值≥0. 85）剔除重复试题，专家校验是由3位GIS专业老师组成审核委员会，完成2轮交叉验证。最终的数据集是涵盖遥感数字图像处理、空间数据库原理等10门学科核心课程的评测数据集，经处理后的数据错误率≤0. 7%（原始数据错误率为12. 3%），知识单元覆盖率达到《地理信息科学专业规范》要求的93. 6%。

3　评测结果及分析

本研究采用分层评估技术框架（hierarchical evaluation framework，HEF）开展LLMs性能评测。数据输入层基于Python编程环境构建自动化评估管道，通过标准化API接口调用实现多模型并行化任务处理；评估执行层的客观题评估采用准确率量化模型对地理事实性知识的掌握程度，主观题评估依据表5的多维度评估指标体系，通过加权评分机制实现生成质量的量化表征；结果分析层基于表8的得分矩阵，采用LLMs各项测试能力图（见图2）可视化呈现各模型在各项能力维度的相对优势与知识盲区。同时，引入TOPSIS算法，通过层次分析法赋权计算模型综合性能指数（comprehensive performance index，CPI），最终排序结果见图3。

由表8可见，对于基础题型的优势模型，单选题为Doubao-pro-32k＞hunyuan＞SenseChat，多选题为Baichuan3＞Doubao-pro，星火V4. 0显著落后（Δ=28），填空题为Doubao-pro领先，星火V4. 0存在语义联想缺陷；对于高阶题型，其表现分化严重，判断题的Doubao-pro逻辑最优，星火V4. 0需强化推理，名词解释题的SenseChat专业表述最佳，hunyuan次之，简答题的hunyuan深度解析占优，编程题的

中国知网　https://www.cnki.net

hunyuan代码生成能力突出。可见，Doubao-pro在基础题型（单选/填空/判断）全面领先，hunyuan在高阶复杂任务（简答/编程）展现显著优势，星火V4.0多题型表现欠佳，需加强专业语义理解。

表8　大模型测试成绩表

Table 8　Test score sheet of LLMs

测试模型	选择题得分	多项选择题得分	填空题得分	判断题得分	名词解释题得分	简答题得分	论述(编程)题得分
hunyuan-turbo(腾讯)	78	53	45	63	89.75	88.10	90.83
讯飞星火V4.0	59	38	25	53	80.97	81.28	83.05
step-1-32k(阶跃星辰)	60	39	27	58	83.9	81.15	86.16
qwen-plus-0723(通义千问)	64	42	28	60	84.22	80.00	84.20
moonshot-v1-32k(月之暗面)	70	59	35	56	86.81	84.79	85.93
Taichu-2.0(紫东太初)	73	45	42	62	85.13	83.30	83.23
SenseChat-32k(商汤)	77	62	46	59	90.38	85.06	88.35
Baichuan3-Turbo(百川)	76	71	57	62	86.81	82.65	83.47
yi-large(零一万物)	61	48	35	66	84.23	80.86	82.98
Doubao-pro-32k(字节跳动)	86	70	77	77	86.05	85.20	87.78

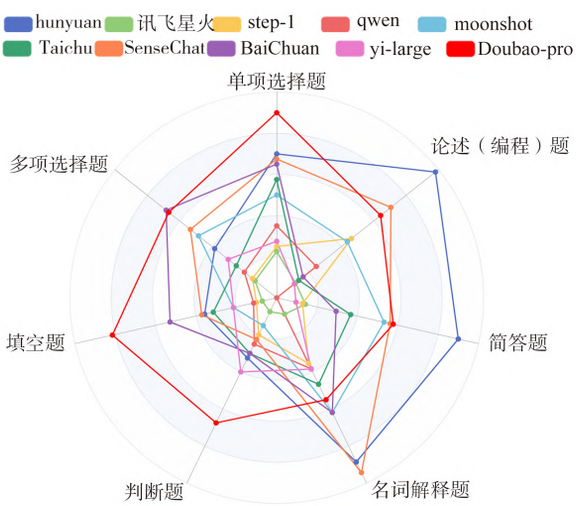

图2　LLMs各项测试能力图

Fig. 2　Test ability diagram of LLMs

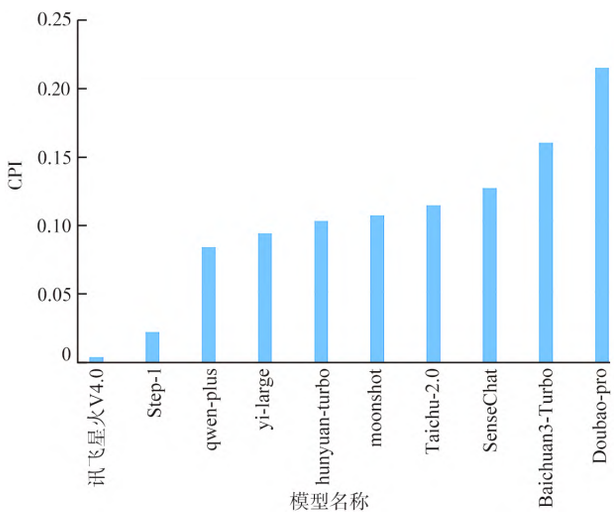

图3　LLMs最终排序结果

Fig. 3　Ranking of LLMs

图2可以揭示各模型显著的能力分化，由此可见，Doubao-pro-32k在基础题型（单选/填空/判断）展现全面优势（平均分为80.3），它的标准化输出特性使其成为地理信息标准化问答服务的优选；Baichuan3-Turbo凭借多选题型71分（超均分15%）的表现，突显多源信息筛选能力，适用于地理数据关联分析场景；SenseChat-32k以名词解释90.38分的专业表述能力（置信区间95%）领先，成为地理知识库构建的专项工具；而hunyuan-turbo虽综合排名第6，但其在简答（88.1分）与编程题（90.83分）的突出表现（高阶任务得分率89.5%），验证了复杂地理问题拆解与决策报告生成的适用潜力。通过TOPSIS综合评估（见图3），本研究构建了“能力-场景”映射矩阵：客观题密集型任务优先选用Doubao-pro（基础题型标准差≤1.5），主观题场景则匹配hunyuan（高阶得分Δ=+24.7%），这为地理信息工程中的模型选型提供了量化决策依据，推动了领域知识处理从通用响应向专业智能进阶。

测评数据表明，LLMs存在显著题型敏感性，客观题（多选/判断）平均得分为68.4，较主观题（简答/编程）低21.7%（P<0.05）。其成因可归结为：（1）答案确定性约束，客观题需字符级精准匹配，如填空题误差容限≤0，而主观题通过BERTScore≥0.85的语义相似度评估实现容错；（2）知识依赖差异，客观题67.3%依赖GIS领域特异性知识，受限于模型训练数据对《地理信息科学专业规范》

中国知网　https://www.cnki.net

82.4%的覆盖盲区，而主观题58.9%依托跨领域迁移学习能力；（3） 评估生态偏差，现行评测中单选题占比为42.6%，诱发模型“选项长度推测”等应试策略。

4　结论

本文构建了基于Geo-Text-700测试集的GIS领域定制化评测体系，完成了10个国产大模型的系统性评估。结果表明，该体系能有效揭示模型在地理空间推理（如缓冲区分析）、专业知识应用（如遥感解译）等核心能力上的差异，其中Doubao-pro表现最优（综合得分为87.3）。但是，当前该体系还存在一些局限性，如代码生成题评分颗粒度不足、数据集学科覆盖需扩展至15+领域、评估模型数量有限（仅10款）等。未来的研究可以聚焦建立可解释性评估框架（如通过知识溯源分析Doubao-pro性能成因）和研发多模态动态评测基准（融合GIS数据与遥感影像）两大方向，推动地理信息智能从“数据驱动”向“知识驱动”转型。

［参考文献］

［1］吴令娴.大语言模型发展路径分析及研究[J].价值工程,2024,43(27):148-150.

［2］LI H N,ZHANG Y X,KOTO F,et al.CMMLU:measuring massive multitask language understanding in Chinese[EB/OL].(2024-01-17)[2024-10-23].https://arxiv.org/abs/2306.09212.

［3］CHEN M,TWOREK J,JUN H,et al.Evaluating large language models trained on code[EB/OL].(2021-07-14)[2024-10-23].https://arxiv.org/abs/2107.03374.

［4］HUANG Y Z,BAI Y Z,ZHU Z H,et al.C-EVAL:A multi-level multi-discipline Chinese evaluation suite for foundation models[J].Advances in Neural Information Processing Systems,2023,36:62 991-63 010.

［5］ZHANG X T,LI C Y,ZONG Y,et al.Evaluating the performance of large language models on gaokao benchmark[EB/OL].(2024-02-24)[2024-10-23].https://arxiv.org/abs/2305.12474.

［6］李敏.围绝经期排卵障碍性异常子宫出血中医临床决策及智能诊疗模型构建[D].北京:中国中医科学院,2024.

［7］王野.教育领域人工智能基准测试:跨学科中文大型语言模型的综合评估[J].广西职业技术学院学报,2024,17(1):61-68.

［8］ZHANG N Y,CHEN M,BI Z,et al.CBLUE:A Chinese biomedical language understanding evaluation benchmark[EB/OL].(2023-05-21)[2024-10-23].https://arxiv.org/abs/2106.08087.

［9］FEI Z W,SHEN X Y,ZHU D W,et al.LawBench:Benchmarking legal knowledge of large language models[EB/OL].(2023-09-28)[2024-10-23].https://arxiv.org/abs/2309.16289.

［10］GUO X,XIA H T,LIU Z W,et al.FinEval:A Chinese financial domain knowledge evaluation benchmark for large language models[EB/OL].(2023-08-19)[2024-10-23].https://arxiv.org/abs/2308.09975.

［11］XU L,ZHANG X W,LI L,et al.CLUE:a Chinese language understanding evaluation benchmark[EB/OL].(2024-08-13)[2024-10-25].https://arxiv.org/abs/2004.05986.

［12］NGUYEN V B,SCHLÖTTERER J,SEIFERT C.CEval:A benchmark for evaluating counterfactual text generation[EB/OL].(2020-04-13)[2024-10-25].https://arxiv.org/abs/2404.17475.

［13］SHAO C C,LIU T,LAI Y T,et al.DRCD:A Chinese machine reading comprehension dataset[EB/OL].(2018-06-04)[2024-10-25]. https://arxiv.org/abs/1806.00920.

［14］李博,莫先.大语言模型在推荐系统中的应用[J].计算机科学,2025,52(增刊1):19-25.

［15］BROWN T,MANN B,RYDER N,et al.Language models are few-shot learners[J].Advances in Neural Information Processing Systems,2020,33:1 877-1 901.

［16］项晓岚,张圣宇,吴飞.人工智能历史发展中的人机对弈与生成式模型热点[J].浙江经济,2024(11):9-12.

［17］CELIKYILMAZ A,CLARK E,GAO J F.Evaluation of text generation:A survey[EB/OL].(2020-06-26)[2024-11-07].https://arxiv.org/abs/2006.14799.

［18］马智亮.建筑工程专业化大模型构建:路径和方法[J].施工企业管理,2025(6):31-33.

［19］房一泉,沈斌,程华,等.基于深度学习的子句级文本摘要模型[J].计算机与数字工程,2024,52(7):2 135-2 140.

［20］郑晓铭,黄河,黄秋生,等.基于AHP与TOPSIS的维修方案有效性评估体系[J].山东航空学院学报,2024,41(6):14-20.

（责任编辑　雨　松）

中国知网　https://www.cnki.net