東莞理工學院
DONGGUAN UNIVERSITY OF TECHNOLOGY

硕士研究生学位论文

（全日制学术型硕士研究生）

题目：基于大模型的交通数据分析研究

姓　　名：陈海天

学　　号：221115181

学　　院：计算机科学与技术学院（软件学院、网络空间安全学院）

学科专业：计算机科学与技术

研究方向：智能计算

导师姓名：丁烨

二〇二五年六月

中国知网 https://www.cnki.net

Research on Traffic data analysis based on large models

A Dissertation Submitted for the Degree of Master

Candidate：Chen Haitian

Supervisor：Prof. Ding Ye

Speciality: Computer Science and Technology

Research field: Intelligent Computing

Dongguan University of Technology

Dongguan, China

中国知网 https://www.cnki.net

分类号： **学校代号：11819**

学 号：221115181

东莞理工学院学术型硕士研究生学位论文

基于大模型的交通数据分析研究

作者姓名：陈海天 导师姓名、职称：丁烨、教授

学科专业：计算机科学与技术 研究方向：智能计算

论文答辩日期： 2025 年 5 月 18 日 论文提交日期： 2025 年 5 月 1 日

答辩委员会成员：

主席：田立伟

委员：余梓彤 王凯 肖禹亭 张宇辉

中国知网 https://www.cnki.net

摘要

随着城市化进程的加快，城市人口和车辆数量迅速增加，城市交通面临着日益严峻的挑战，智能交通系统的需求日益增长。但智能交通系统作为智慧城市的一个分支，是一个集成了计算机算法的交叉学科，其内含有复杂的算法逻辑，需要使用者理解其内部结构，使得其在实际应用中会受到制约。随着大模型的推广，其在各个领域优秀的表现力，尤其是其展现出来的卓越的推理及分析能力给智能交通管理带来了巨大的发展潜力。

大模型的核心价值在于其能够通过自然语言交互与多模态数据处理能力，将复杂的交通逻辑转化为直观的智能化服务。传统智能交通系统依赖结构化数据与人工规则设计，而大模型通过端到端的学习框架，可通过交通领域多源异构数据基于语义理解与推理能力生成决策方案。这种技术特性为解决交通系统的交互复杂性、任务动态性及场景多样性提供了全新范式。本文主要贡献如下：

（1）本研究构建了一个面向城市用户交通出行需求的智能交通智能体系统，基于 LangGraph 框架搭建具备循环控制、条件逻辑判断与状态持久化功能的智能体工作流。通过融合大语言模型与多源异构数据，结合地图服务接口与搜索引擎工具，构建了支持自然语言交互的决策链路。采用状态图建模与多智能体分层协作机制，实现任务动态调度，形成从语义理解到服务输出的闭环流程。该框架通过模块化设计降低开发复杂度，提升工具调用的精准性与系统可维护性，为智慧城市交通治理提供可扩展的智能化交互解决方案。

（2）针对城市交通环境中路网设计精细化与人工依赖性强的问题，本研究提出了一种基于生成式人工智能技术的城市交通路网自动生成方法，突破了传统路网设计的局限性。通过构建 ComfyUI 框架下的工作流，实现了从图像语义解析到路网拓扑优化的全流程智能化处理，利用多模态大模型解析图像语义特征，结合模型微调技术对生成模型进行领域适配，有效捕捉道路网络的拓扑关系与空间约束。针对生成结果设计拓扑优化算法，在保留原始连通性的基础上对路网结构进行简化重构，显著提升生成结果的实用性与可靠性。该方法为城市规划提供了可扩展的自动化工具，降低了传统路网设计对人工经验的依赖。

关键词：大模型，智能体，扩散模型，智能交通，路网生成

中国知网 https://www.cnki.net

ABSTRACT

With the acceleration of urbanization, rapid increases in urban population and vehicle numbers have posed increasingly severe challenges to urban transportation systems, driving growing demand for intelligent transportation systems (ITS). However, as a branch of smart cities, ITS involves complex algorithmic logic rooted in interdisciplinary computer science, requiring users to understand its internal structure, which constrains practical applications. The emergence of large language models (LLMs) demonstrates remarkable potential for intelligent transportation management through their outstanding reasoning and analytical capabilities across various domains.

The core value of large models lies in their ability to transform complex transportation logic into intuitive intelligent services through natural language interaction and multimodal data processing. While traditional ITS relies on structured data and manual rule design, large models employ end-to-end learning frameworks to dynamically integrate multi-source heterogeneous data in transportation domains, generating adaptive decision-making solutions based on semantic understanding and reasoning. This technological paradigm addresses the interactive complexity, task dynamics, and scenario diversity of transportation systems. The main contributions of this paper are as follows:

(1) This study constructs an intelligent transportation agent system for urban travel demands, establishing a workflow with cyclic control, conditional logic judgment, and state persistence based on the LangGraph framework. By integrating large language models with multi-source heterogeneous data and combining map service interfaces with search engine tools, it builds a decision-making chain supporting natural language interaction. The system employs state graph modeling and a multi-agent hierarchical collaboration mechanism to achieve dynamic task scheduling, forming a closed-loop process from semantic understanding to service output. This modular framework reduces development complexity while enhancing tool invocation precision and system maintainability, providing an expandable intelligent solution for smart city transportation governance.

(2) Addressing the challenges of labor-intensive refined road network design in urban environments, this research proposes an automated urban traffic network generation method using generative artificial intelligence. By constructing a ComfyUI-based workflow, it achieves full-process intelligent processing from image semantic analysis to road network topology optimization. The system utilizes multimodal large models to analyze image semantic features and adapts generative models through fine-tuning techniques, effectively

中国知网 https://www.cnki.net

capturing topological relationships and spatial constraints in road networks. Innovative topology optimization algorithms simplify network structures while preserving original connectivity, significantly improving practicality and reliability. This approach provides cities with scalable automated tools, reducing traditional road network design's dependence on manual expertise.

KEY WORDS: 3D measurement, Fringe Projection Profilometry, Non-Local Denoising Of Fringe Patterns, 3D Reconstruction Of Moving Objects, Point Cloud Processing

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 大语言模型智能体国内外研究现状.....3
1.2.2 路网生成方法国内外研究现状.....5
1.3 本文主要内容及创新点.....7
1.4 论文结构安排.....8
第二章 相关理论.....9
2.1 注意力机制.....9
2.2 Transformer.....10
2.3 LLM 智能体.....12
2.4 扩散模型.....13
2.5 模型微调.....15
2.6 本章小结.....17
第三章 基于大模型的交通智能体研究.....18
3.1 引言.....18
3.2 Lang Chain 架构.....19
3.3 Agent 框架搭建.....20
3.3.1 工具构建.....20
3.3.2 单智能体构建.....22
3.3.3 Multi-Agent 构建.....23
3.4 实验设置及结果分析.....25
3.4.1 单 Agent 系统实现.....25
3.4.2 Multi-agent 系统实现.....26
3.5 本章小结.....29
第四章 基于大模型的交通路网图生成研究.....30
4.1 引言.....30
4.2 ComfyUI 工作流图像生成框架构建.....31
4.2.1 图生文工作流.....31
4.2.2 LoRA 训练工作流.....32
4.2.3 文生图工作流.....33
4.3 图像优化.....34
4.3.1 图像编码及逆编码.....34
4.3.2 图像优化及连通性验证.....35

中国知网 https://www.cnki.net

4.4 实验设置及结果分析.....36
4.4.1 模型反推提示词.....36
4.4.2 训练 LoRA 模型.....36
4.4.3 模型整合生成图像.....38
4.4.4 图像优化.....38
4.5 本章小结.....40
第五章 结论及展望.....41
5.1 结论.....41
5.2 展望.....41
参考文献.....43

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

交通一直是人类历史上不可或缺的角色，随着计算机技术的发展，使用计算机辅助人类在智能交通上做出优化和决策成为了一项新颖的技术，为改善人类的生活带来了新的方向。比如在交通模拟、路线规划、智能调度等很多领域都有很多研究人员在不断应用新技术，为提高交通的高效便捷性做出了贡献。但是，智能交通作为一个交叉领域，需要研究参与人员了解过多的非自身领域的技术，这使得研究的门槛比较高，需要研究人员有一个长周期的学习，将人工智能应用在交通领域是一个热门领域。

在过去的几十年中，人工智能实现了从符号主义到连接主义的转变，为复杂任务的自动化处理提供了可能。机器学习和深度学习作为人工智能的核心分支，经历了从理论探索到广泛应用的快速发展历程。上世纪机器学习支持向量机、决策树、贝叶斯网络等经典算法被广泛研究和应用，奠定了机器学习的基础框架。进入二十一世纪，随着互联网的普及和数据量的爆发式增长，机器学习开始在数据挖掘、图像识别、自然语言处理等领域取得显著成果。而深度学习的出现又为机器学习带来了革命性突破。深度学习基于人工神经网络，模型能够自动学习数据的多层次特征表示，极大地提升了模型的性能，在语音识别、自然语言处理等任务中展现出卓越的能力。

随着人工智能技术的飞速发展，大语言模型及其应用框架在自然语言处理和多模态内容生成领域展现出巨大的潜力与价值。

一方面，大语言模型为智慧交通系统提供了强大的决策支持和交互能力。如TrafficGPT[1]通过将大语言模型与交通基础模型相结合，赋予了智能体查看、分析和处理交通数据的能力，为城市交通管理提供了富有洞察力的决策支持。这种结合不仅提升了交通管理系统的智能化水平，还为智慧城市[2]的发展提供了新的思路和可能性。Open-TI[3]通过增强语言模型的能力，实现了从地图数据获取到复杂模拟执行的全面交通分析。这一系统能够执行特定任务的实体化操作，如交通信号控制策略训练和交通需求优化。

另一方面，随着大模型应用近年来的不断成熟，大模型开发框架应运而生。从互联网公司训练和部署专属大语言模型以支持日常问答和科学研究，到普通用户通过自然语言随时与模型通畅交流，大语言模型无疑为现代社会的高速发展提供了有力支持。大模型的开发和部署涉及多个环节，包括数据预处理、模型训练、微调、推理优化以及应用集成。框架通过提供标准化的接口和模块化设计，降低了开发门槛，使开发者能够专注于核心业务逻辑，而无需从头实现复杂的底层功能。这些框架的出现旨在满

中国知网 https://www.cnki.net

足不同功能需求和应用场景，从而推动大模型技术的广泛应用与发展。

通用开发框架如 LangChain[4]和 Transformers[5]，分别专注于构建复杂的交互式应用和提供丰富的预训练模型支持，适用于多种自然语言处理任务。高效推理框架例如 vLLM[6]，主要通过优化内存管理和计算资源分配来实现高效的推理性能，适合高吞吐量和低延迟的应用场景。数据检索与问答框架如 LlamaIndex[7]和 Ollama[8]，侧重于高效索引和语义检索功能，适用于问答系统和数据检索任务。本地化与隐私保护框架如 LocalAI[9]则强调数据隐私和本地化部署，适合对数据安全要求较高的场景。

通用开发框架虽然功能强大，但在特定领域的优化能力上仍有待提升；高效推理框架在处理复杂任务时可能会受到资源限制；数据检索与问答框架在处理大规模数据时可能会面临效率瓶颈，而在 LangChain 基础上开发的智能体与多模态框架 LangGraph[10]，提供了一种创新的方法来增强 LLM（大语言模型）的语义理解和生成能力，通过构建和利用语言的图谱结构，LangGraph 有助于提高模型对语言细微差别的捕捉能力，从而在各种语言任务中实现更准确、更自然的表现。

图生文技术旨在将图像内容转化为自然语言描述，而文生图技术则通过文本提示生成视觉内容。传统图生文技术主要依赖于卷积神经网络[11]或其他图像处理技术，通过提取图像特征来生成文本描述。这些方法在处理简单场景时效果尚可，但在复杂场景下，生成的文本往往缺乏细节和准确性。随着大语言模型的引入，图生文技术得到了显著提升。例如，LlaVA[12]等多模态模型通过结合视觉编码器和强大的语言模型，能够生成更丰富、更准确的图像描述。此外，基于 Transformer[13]架构的模型利用自注意力机制，能够更好地捕捉图像中的细节信息，从而生成更符合人类语言习惯的文本。

传统的文生图技术主要基于生成对抗网络[14]（GAN）或变分自编码器[15]（VAE），这些方法在生成图像的多样性和质量上存在局限性。例如，GAN 可能会出现模式坍塌问题，导致生成的图像缺乏多样性。而基于扩散模型的文生图技术，通过逐步去噪的过程生成图像，不仅在图像质量上有了显著提升，还能够处理更复杂的文本提示。大语言模型的引入进一步增强了文生图技术的能力。例如，DALL-E2[16]和 SD[17]等模型结合了强大语言理解能力，能够根据复杂的文本描述生成高质量、多样化的图像。此外，新技术如 LoRA 和 IP-Adapter 等微调方法[18]，使得模型在特定风格或主题上的表现更加出色。

鉴于此，首先本文基于此框架实现了一个智能交通智能体，旨在利用现有框架的优势加强大语言模型的语义理解和生成能力。该智能体通过该框架将大语言模型与企业接口相结合，实现在城市交通中给予支持，为城市交通出行提供一系列可靠的帮助；基于该框架帮助 LLM 提高对交通规划任务的捕捉能力，将大预言模型与交通任务相结合通过自然语言对话辅助人类做出行抉择。其次，本研究将大模型的信息处理能力与扩散模型相结合，构建一个图像生成框架：首先利用大语言模型实现图生文任务，

中国知网 https://www.cnki.net

生成描述性文本；然后将该文本作为提示词输入扩散模型，生成高质量交通路网图像。这一方法不仅能够提升图像生成的内容更准确地符合用户需求，还为多模态生成任务提供了新的研究思路。

1.2 国内外研究现状

1.2.1 大语言模型智能体国内外研究现状

随着机器学习技术的兴起，尤其是监督学习和无监督学习方法的发展，语言模型开始从简单的统计方法向更复杂的模型过渡。机器学习方法通过特征工程和算法优化，能够更好地处理语言数据中的模式和结构。然而，这些方法在处理长距离依赖和复杂上下文时仍面临挑战。随着计算能力的提升和数据量的增加，深度学习技术逐渐崭露头角，为自然语言处理带来了新的突破。深度学习通过构建多层神经网络，能够自动学习数据中的特征表示，从而更有效地捕捉语言的复杂性。神经网络语言模型逐渐取代了传统统计方法，这些模型能够更好地捕捉上下文信息，并在机器翻译、语音识别等任务中取得显著进展。

2017 年，Transformer 架构的提出标志着大语言模型进入了一个新的阶段。其通过自注意力机制[19]（Self-Attention）解决了长距离依赖问题，显著提升了模型的语言理解和生成能力。基于 Transformer 的模型如 BERT[20]和 GPT[21]系列迅速成为主流，BERT 通过双向上下文理解提升了机器阅读理解能力，而 GPT 则通过自回归生成展现了强大的文本生成能力。而 GPT-3 的发布进一步推动了生成式 AI 的发展，其庞大的参数量和泛化能力使其能够完成多种复杂任务，如代码生成、问答系统和创意写作。

国内企业在大语言模型的基础技术研发上不断突破。例如，百度的“文心一言”、阿里巴巴的“通义千问”、腾讯的“混元”以及科大讯飞的“讯飞星火”等模型，均在自然语言处理、内容生成、知识问答等领域展现了强大的能力，这些模型不仅能够处理文本，还能理解和生成图像、视频等多模态内容，展现了强大的跨模态能力。这些模型不仅在技术上不断优化，还在多模态融合、实时处理能力等方面取得了显著进展。

当然，只有大语言模型是不够的，大语言模型智能体[22-25]（Agent）的研究和应用正迅速发展。传统智能体被专门设计用来解决特定问题，它们主要依赖预先被设定的算法或规则集，在为自己构建的任务上表现出色。然而这类系统在应对超出初始设计范畴的任务时，往往面临泛化能力不足和逻辑推理受限的困境。随着大型语言模型（LLMs）的引入，人工智能体的设计范式发生了根本性变革。这类基于海量文本数据训练的语言模型不仅具备卓越的自然语言理解和生成能力，更展现出强大的跨领域适应性，这种特性使其能够灵活集成各类工具，显著拓展了智能体的通用性边界。此外，在不断发展中大型语言模型还展现出令人瞩目的推理能力，这种能力支持其通过

中国知网 https://www.cnki.net

行为反馈进行持续优化。在构建大语言模型智能体时，大语言模型作为控制中心，负责统筹和管理完成任务或响应用户请求所需的整个流程，架构如图 1.1 所示。智能体通过调用大模型的能力来执行任务，并依赖于规划、记忆以及工具使用等关键模块来实现高效运作，助于智能体为未来行动做规划，管理智能体的历史行为和经验并调用工具与外部环境交互。

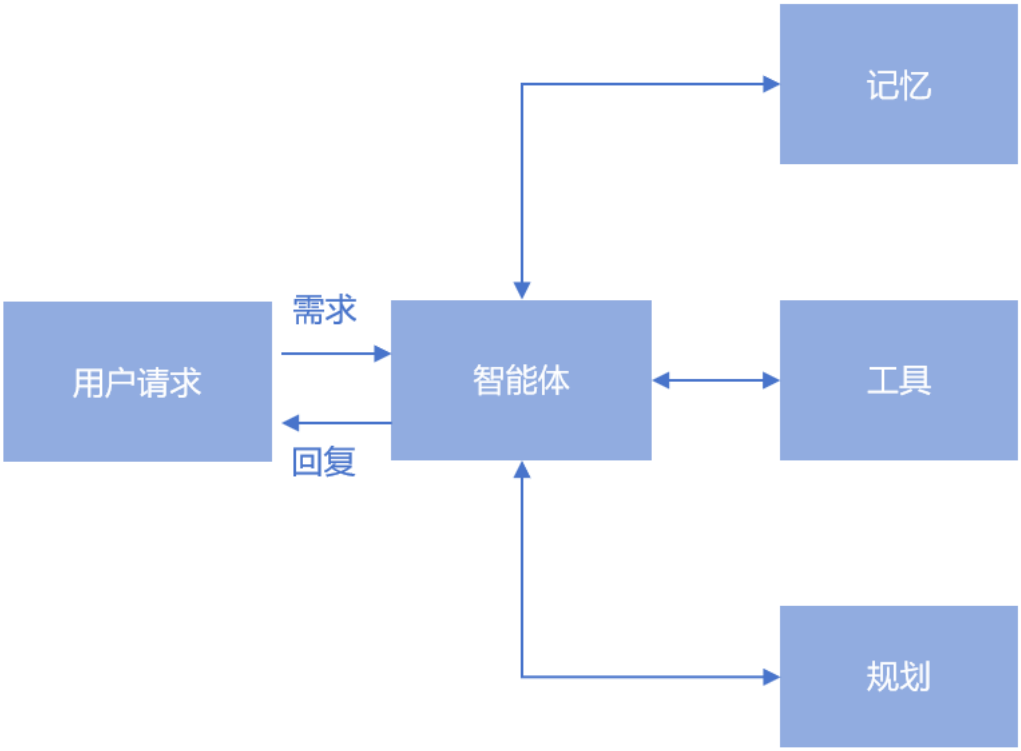

图 1.1 大模型智能体架构

关于大语言模型智能体的研究不仅聚焦于提升模型的语言理解和生成能力，还致力于将智能体应用于实际场景，如医疗客服、教育辅导和代码评审等[26-28]。此外，国内研究机构也在探索如何通过智能体技术解决复杂任务。近年来，大语言模型的发展趋势逐渐向多模态融合和智能体方向演进。

Hugging Face 发布的 Transformers 框架基于 Transformer 架构，专注于自然语言处理（NLP）任务。它提供了丰富的预训练模型和工具，支持模型训练、微调和推理。它的主要优势在于其底层访问和操作能力，能够处理文本生成、机器翻译、情感分析等任务。其灵活性使其成为开发和部署 NLP 应用的理想选择，尤其侧重于模型的训练和推理，提供了丰富的预训练模型和底层操作。LlamaIndex 则是一个专为高效数据检索和管理而设计的框架其专注于将私有或特定领域的数据与 LLM 结合，以增强模型的问答、数据提取和交互能力它通过使用基于语义相似性的算法对文档进行排序，在创建搜索和检索应用程序方面表现出色。LlamaIndex 通过 LlamaHub 提供不同的数据

中国知网 https://www.cnki.net

连接器，允许直接从各种来源摄取数据，而无需大量的转换过程。它尤其适用于需要准确、快速信息检索功能的知识管理系统和企业解决方案。

由 Harrison Chase 团队开发的 LangChain 是一个用于开发基于大型语言模型的应用程序的框架。它于 2022 年 10 月首次开源，最初聚焦于高效管理大语言模型的输入与输出，以及扩展的能力，例如连接外部知识库或工具链。LangChain 的出现旨在简化从开发到部署的整个生命周期，提供模块化的构建块和组件，支持与多种第三方服务的集成。其解决了开发者在构建复杂语言模型应用时面临的几个关键问题。首先，它通过模块化设计，简化了开发流程，使得开发者能够快速构建应用程序。其次，它提供了强大的上下文保留能力，这对于需要进行复杂对话的聊天机器人等应用来说非常重要。此外还支持链式逻辑，允许开发者设计复杂的操作序列，集成多个工具和模型，满足不同的特定需求。改框架的应用场景非常广泛，包括聊天机器人开发、内容生成与创作、复杂流程自动化系统等，特别适合需要复杂工作流和数据交互的应用。

姜[29]通过基于 LangChain 框架和大语言模型设计并实现了一个智能问答系统，该系统通过构建本地知识库和文档解析功能，解决了大语言模型在处理本地数据和文档时的局限性，如无法回答训练数据之外的问题、对本地文档内容的问答能力不足以及部署成本高昂等问题。其结合大语言模型与开发框架实现的基于本地知识库的智能问答系统，通过向量化检索技术和关键词提取，实现了对知识库内容的高效问答，准确率高且响应时间短。

1.2.2 路网生成方法国内外研究现状

城市路网生成技术是城市规划、交通管理和地理信息系统等领域的重要研究内容。近年来，国际上对城市路网生成技术的研究取得了显著的进展。早期的城市路网规划主要依赖于经验法则和手工制图，研究重点在于路网的拓扑结构和基本布局原则，这个阶段的研究为后续的计算机化方法奠定了基础。随着计算机技术的发展，国外学者开始探索将数学和物理模型应用于城市路网规划。这一时期出现了多种模型，如交通流分配模型、网络优化模型等，旨在通过数学方法优化路网设计。这些模型为路网设计的科学化提供了支持。地理信息系统技术的引入为城市路网规划带来了新的视角和方法。该技术能够处理和分析大量的空间数据，帮助规划者更好地理解和模拟城市交通系统。而智能交通系统的兴起进一步推动了城市路网生成方法的研究。智能交通系统（ITS）包括交通流量监测、数据采集与处理、智能控制等，能够提高交通系统的效率和安全性。这一阶段的研究重点在于如何将智能交通系统与路网规划相结合，优化交通流动。近年来，随着大数据及大模型等新兴技术的发展，研究人员开始探索这些技术在城市路网规划中的应用。

基于过程与规则的建模方法利用计算机算力自动化执行人工制定的逻辑过程与生

中国知网 https://www.cnki.net

成规则快速输出特定内容的生成方法。这种方法在计算机图形学领域的虚拟世界合成建模中有广泛应用，并在近年被应用于城市形态辅助设计和城市形态生成建模中。具体而言，Parish 和 Muller[30]在 2001 年将 L 系统引入城市设计建模领域，于 L 系统的生成方法通过扩展和改进，能够更好地模拟城市路网的复杂性和多样性，提出了方格、放射和分支三种道路模式。实现了一套城市路网生成建模方法，可以根据用户设定的参数，执行用户选定的系统内嵌普适城市路网生成规则，半自动生成相应的城市路网形态。Chen[31]实现了一种用于城市街道网络建模的交互式方法，它通过设计张量场来引导街道网络的生成，允许用户从头开始创建街道网络，或者对现有的街道网络进行修改。GaricDorado 等人[32]基于用户指定的交通行为（如道路占用率、旅行时间、排放等）实现了一种交互式设计工具，能够自动生成符合这些行为的三维城市模型，可以用于城市规划、交通设计以及虚拟环境内容生成，支持对大规模交通网络的快速仿真和优化。

在路网构建中也可以使用数学建模来实现，Sun[33]等人通过引入 Voronio 图，提出了一种基于图像衍生模板和规则的生成系统生成虚拟交通网络的新方法。使用二维图像作为输入地图，可以生成各种不同图案的道路地图，这种交通网络生成模型可以智能地自我调整，以避免受到地理区域或城市发展的限制。Aliaga[34]提出了一种基于示例的交互式城市布局合成系统，能够通过结构和图像数据的结合，利用连接、扩展和混合等操作，生成具有合理街道网络和航拍图像的新城市布局。系统通过结构合成算法创建街道和地块，利用图像合成方法填充地块图像，并提供交互工具无缝连接或混合不同风格的示例布局片段，为城市规划、虚拟环境等领域提供了高效灵活的布局生成方案。

基于地理信息技术生成道路网图也是一个传统道路建模方法，Wilkie[35]将地理信息系统（GIS）数据转换为适用于实时交通模拟和虚拟世界交互可视化的三维道路模型，能够自动处理道路网络的拓扑和几何细节，生成包含匝道、高速公路以及具有任意状态的交叉口等重要道路特征的模型。Karagiorgou[36]等人基于汽车运行 GPS 实现了一种将运动轨迹转换为分层运输网络的新方法。它利用一种改进的基于运动类的地图构建算法，使用不同地图构建算法构造不同得图层道路，然后对不同图层道路进行合并，形成完整得道路网图。Galin[41]则提出了一种基于加权各向异性最短路径算法的自动道路生成方法，能够根据输入场景中的自然障碍自动生成连接初始点和终点的道路，并通过沿路径挖掘地形和实例化通用参数化模型来创建道路、桥梁和隧道，生成的道路轨迹平滑且适应复杂地形，同时可通过调整成本函数参数灵活控制道路的生成方式。

基于深度学习的交通数据探索包括对交通流量的预测[38,39]及交通道路网络的设计[40,41]等，图神经网络（GNNs）在交通领域广泛应用，是因为交通系统本质上是一个

中国知网 https://www.cnki.net

复杂的图结构，其中节点（如交叉路口）和边（如道路段）之间存在丰富的空间和时间依赖性。GNNs 能够自然地表示和处理这种图结构数据，通过聚合邻域信息捕捉空间依赖性，结合时间序列数据处理动态变化，并融合多源数据以更全面地建模交通系统。GNNs 具有强大的预测能力、良好的可扩展性和泛化能力，能够适应复杂的网络结构，并支持多种交通相关任务，如流量预测、速度估计、事故检测和路径规划等。这些特性使得 GNNs 非常适合应用在交通领域中。Jepsen[42]介绍了一种新型的图卷积网络关系融合网络 RFN，它专门针对道路网络设计，用于提高智能交通应用中的机器学习性能。其结合了节点关系和边关系两种视图，通过在主图和对偶图上分别进行节点关系融合和边关系融合，从而同时利用节点、边和边之间的属性信息。

在当今数字化的时代背景下，人工智能生成内容（AIGC）的出现引发了全球范围内的广泛关注，在这之前，深度学习生成算法早已凭借机器视觉技术和自然语言处理技术，在图像生成、文本生成和人机对话等众多内容生成任务中得到了广泛的应用。然而深度学习生成算在城市规划设计这一专业领域的应用却相对较少。

基于人工智能生成，Hartmann[43]提出了一种基于生成对抗网络的城市道路网络合成方法，能够自动生成与给定样本风格一致的道路网络。该方法通过道路数据转换为图像，训练模型来学习道路网络的特征，从而生成新的道路网络图像，并通过后处理将其转换为可用的图表示。该方法的优势在于不需要领域专家知识，也不局限于预设的道路网络模板，能够生成多样化且符合特定风格的道路网络。然而，该方法在处理大型路网结构和控制图像生成输出方面还存在一些限制。

1.3 本文主要内容及创新点

本文主要研究如何将大语言模型应用于城市交通领域，以提升城市交通管理的效率和便捷性，并为相关的设计与实现提供有效的解决方案。

本文第一部分实现了一个基于 LangGraph 的智能交通系统，将大模型与交通企业提供的 API 接口相结合，提供模型调用的工具池，利用现有框架的优势加强大语言模型的语义理解和生成能力。大语言模型根据其语义理解能力对用户问题进行解析并从工具池中调用工具，从而为用户提出的与交通相关的任务提供支持。这种应用大模型开发框架为大模型集成相关功能来帮助其理解和分析相关问题和决策的方式，为大模型应用在交通领域上带来了更加简便、更加模块化的思路。

本文第二部分通过结合大模型的语义理解能力与扩散模型的多模态融合能力针对城市中的交通路网进行设计。首先利用大模型根据输入的交通路网图像生成自然语言描述的能力，反推并提取出与图像内容相关的提示词。利用 ComfyUI 构造工作流，融合提示词与训练图片对扩散模型进行针对性的 LORA 微调，并且对微调后生成的图片

中国知网 https://www.cnki.net

进行优化，使得模型能够输出与输入路网相类似的结构并保持路网之间的连通性。

1.4 论文结构安排

第一章为绪论部分。本章主要阐述和表明了研究工作的背景和意义，随着人工智能技术的不断发展，大模型已经成为一个热门研究领域。在这一领域中，无论是大语言模型的应用还是人工智能生成技术都是备受关注的方向。目前已经有很多学者在这些方向上做出了很多有意义的研究工作。本章先对这些研究工作进行了介绍和总结，以帮助读者更好地理解本文的研究内容和意义，接着本章总结并确定了本文的主要研究内容以及组织结构。

第二章介绍相关理论技术。本章介绍了大语言模型智能体及人工智能生成技术所需要用到得相关得技术理论原理，包含：注意力机制、Transformer 模型，大语言模型智能体，扩散模型及模型微调。

第三章介绍了交通智能体研究，主要包括相关智能体研究的引言，LangGraph 框架下智能体的构造及智能体所调用工具的定义与封装等。最后，通过实验展示了单智能体和多智能体在处理交通任务时的高效性，并比较了不同大语言模型在任务中的表现。

第四章介绍交通道路生成方法，主要包括人工智能生成技术理论，大模型微调工作流框架搭建及对图像进行的优化，实现了城市路网地图的高效生成。在实验部分展现了该方法下道路地图的图片质量及图像中道路的连通性。

第五章为结论部分，总结了本论文的研究工作及其贡献，并提出了未来可能的研究方向。

中国知网 https://www.cnki.net

第二章 相关理论

2.1 注意力机制

在注意力机制被广泛关注之前，循环神经网络通过引入循环结构，使得网络能够处理具有时间依赖关系的数据，并且能够捕获数据序列中存在的时间依赖性。然而，传统的循环神经网络在训练时容易出现梯度消失和梯度爆炸问题，这使得其在处理长时间序列时效果不佳。为了解决循环神经网络的梯度问题，在二十世纪末期提出的变体长短期记忆网络[44]（LSTM）及后续被提出的门控循环单元[45]（GRU），成为处理序列数据的主要方法。

长短期记忆网络通过引入门控机制来处理传统循环神经网络中出现的处理长序列数据梯度消失问题，它包含输入门、遗忘门和输出门，能够灵活地控制信息的流动，通过门控机制选择性保留历史信息，有效捕捉长期依赖关系。细胞状态负责长期记忆的传递和更新；遗忘门用以控制细胞状态遗忘程度，用以控制细胞状态中丢弃哪些信息；输入门控制当前输入信息和新候选值的更新，用以决定新信息的存储量；输出门基于细胞状态和当前输入，决定最终输出的隐藏状态来调节输出信息的强度。门控循环单元是长短期记忆网络的简化版本，通过引入更新门和重置门来控制信息的流动，合并了细胞状态和隐藏状态，减少了模型参数，提高了训练效率，但其在处理长序列数据时与长短期记忆网络性能相当。LSTM 和 GRU 虽在序列建模中具有里程碑意义，在自注意力机制被广泛应用于深度学习前，是提取长时序数据特征的主要方法，但其难以并行训练、捕捉长距离依赖关系的能力有限等缺陷催生了 Transformer 等新架构。自注意力机制通过其高效的内部序列建模能力，是处理复杂的序列数据问题的强大工具。

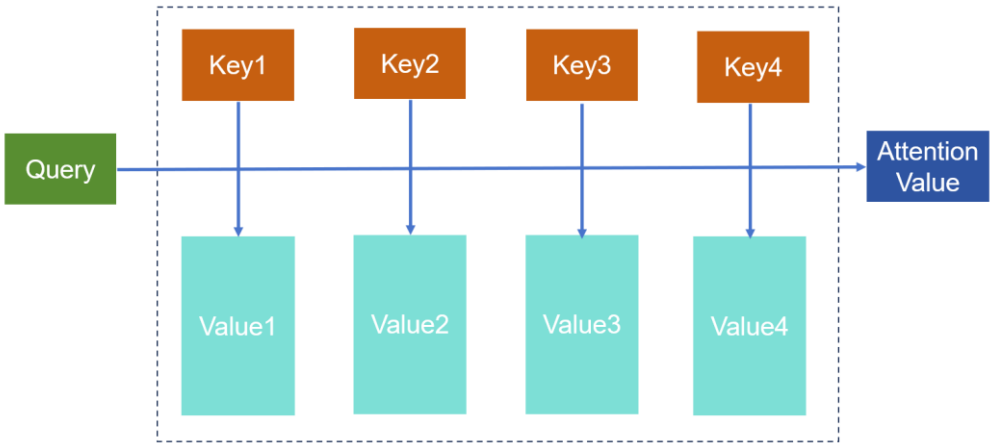

图 2.1 注意力机制结构

中国知网 https://www.cnki.net

注意力机制的概念最早可以追溯到 20 世纪 70 年代的神经网络研究，但直到 Transformer 架构被提出后才广泛应用于深度学习[46]，其结构如图 2.1 所示。它与人类注意力选择相似，都是通过将注意力集中在需要被重点关注的信息上，实现资源的高效利用，其核心目的是依靠有限的资源从众多信息中选择出对当前目标作用最大的关键信息。其实际上就是一个加权过程，注意力机制通过计算输入数据的不同部分与任务目标之间的关联程度，动态地为不同元素分配权重，从而决定模型在处理过程中需要重点关注哪些部分，适当抛弃哪些部位，相关计算公式见式（2.1）[19]。其基本组成包括三个关键元素矩阵：查询（Query）表示当前需要关注的内容、键（Key）表示输入数据中的每个元素，用于与查询进行匹配和值（Value）表示输入数据中每个元素的实际内容，用于生成最终的上下文表示，这些矩阵的维度为 dk，对注意力得分进行缩放，Softmax 函数将缩放后的注意力得分转换为概率分布，使得注意力分数都在 0 到 1 之间，分数的大小表示数据的关键性，所有注意力权重的和为 1，这一步确保了注意力权重在后续的加权求和中具有合理的比例。通过计算查询与键之间的相似性或相关性得分，再结合值进行加权求和，最终得到加权后的输出。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.1}$$

对比传统循环神经网络，注意力机制允许对整个序列进行并行处理，这一特性明显加快了训练速度。注意力机制在捕捉长距离依赖关系、增强模型性能和解释性等方面，相较于传统的循环神经网络也具有显著优势。这些优势使得注意力机制成为现代深度学习模型中不可或缺的一部分，其在自然语言处理、计算机视觉等领域的广泛应用，推动了相关领域的快速发展。

2.2 Transformer

由 Vaswani 等人在 2017 年提出的 Transformer 是一种基于注意力机制的深度学习模型，它的出现彻底改变了传统自然语言处理领域，并逐渐拓展到了计算机视觉领域。其核心是基于自注意力机制来处理序列数据，摒弃了传统循环神经网络和卷积神经网络的序列处理方式，实现并行化计算并捕获长距离依赖。

中国知网 https://www.cnki.net

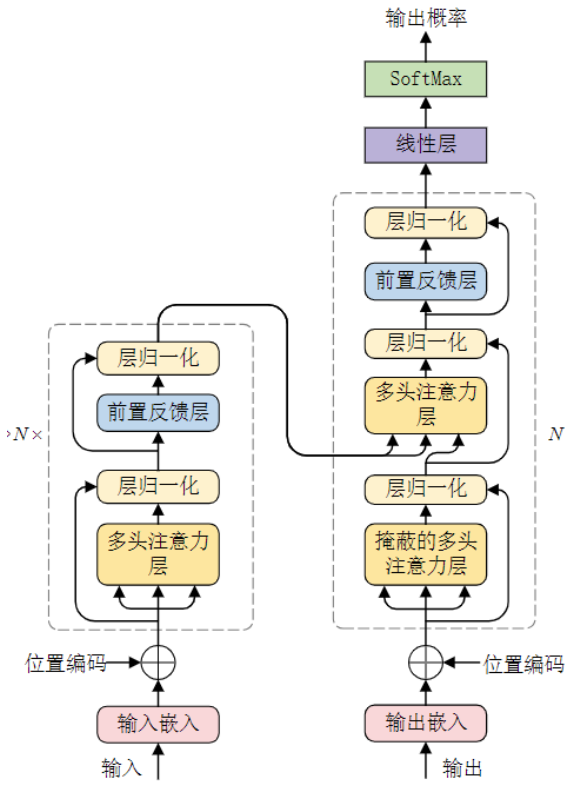

图 2.2 Transformer 模型结构图[19]

Transformer 由编码器（Encoder）和解码器（Decoder）堆叠组成，结构如图 2.2 所示，编码器的主要作用是将输入序列（如源语言句子）转换为一组上下文表示。这些上下文表示中包含了输入序列中每个位置的全局信息，能够捕捉到序列中的长距离依赖关系。编码器的输出将作为解码器的输入，帮助解码器生成目标序列。在 Transformer 的编码器中，多头自注意力机制用于捕捉输入序列中不同位置之间的复杂关系，其通过并行运行多个独立的注意力头，每个都有单独的注意力分数，能够同时关注输入序列的不同子空间信息。通过将输入嵌入映射到多个较小维度的子空间，每个子空间独立计算注意力，并通过最终的权重矩阵变换为期望的维度，编码器-解码器注意力的输出被传递到前馈神经网络，用于生成最终的目标序列。在解码器中，交互注意力层接收两个输入，一个是来自解码器自注意力层的输出（作为查询 Q），另一个是来自编码器的输出（作为键 K 和值 V），交互注意力层通过结合编码器的全局信息和解码器的局部信息，增强了模型的表达能力和生成能力。多图注意力计算公式如下所示[19]：

$$\mathrm{MultiHead}(Q, K, V) = \mathrm{Concat}(\mathrm{head}_1, \mathrm{head}_2, \ldots, \mathrm{head}_h)\, W^O \tag{2.2}$$

在多头注意力机制下不同头关注输入序列的不同方面，通过多个头并行处理，模型能够学习输入数据中不同层次和方面的特征用以捕捉复杂依赖关系。多头设计使得计算过程可以高效地在硬件上并行化，适合大规模数据处理；多头设计允许模型从不

中国知网 https://www.cnki.net

同的子空间中学习特征信息，增强了模型的表达能力和泛化能力。

Transformer 通过其多头注意力机制和编码器-解码器架构，是大模型高效、灵活且强大的基础。它不仅满足了大模型对计算效率、并行化能力和长距离依赖捕捉的需求，还通过其强大的表达能力和扩展性，推动了大模型在多个领域的广泛应用和持续发展。

2.3 LLM 智能体

基于大语言模型（LLM）的智能体构建技术是当前人工智能领域的研究热点，LLM 的引入极大地提升了智能体的自然语言处理能力和知识水平，使其能够更智能地理解和执行任务。大语言模型通过其强大的自然语言理解和生成能力，为智能体提供了强大的技术支持，使得智能体能够更好地理解和处理人类语言，从而更有效地执行任务[48]。例如，GPT-4 等先进的大语言模型在复杂推理、代码编写等多个领域展示了显著的能力，这为智能体在更广泛的应用场景中提供了可能性。

在智能体的构建中，推理和规划技术是实现高效任务执行的核心。ReAct 框架[49]通过大语言模型的推理能力，构建完整的行动系列以达成目标。ReAct 框架的核心思想是将推理和行动结合起来，形成一个智能体结构，并拥有与外部环境交互的能力。其通过将复杂的任务拆解成一系列更小、更明确的子任务，使得模型能够更容易理解和执行这些任务，但其效果高度依赖于模型的理解能力并且经验无法积累。函数调用（Function Call）[50]则通过调用预定义的功能来解决 ReAct 的缺点，支持复杂任务的执行，允许模型在生成响应时调用外部函数或 API。通过给模型提供一组预定义的函数以及用户提问，让大模型自主选择要调用的函数，并向该函数提供所需的输入参数。随后，模型可以在环境中基于生成的参数调用该函数，并将结果返回给大模型，细分步骤包括：用户输入、模型解析、生成函数调用、执行函数、处理函数结果。

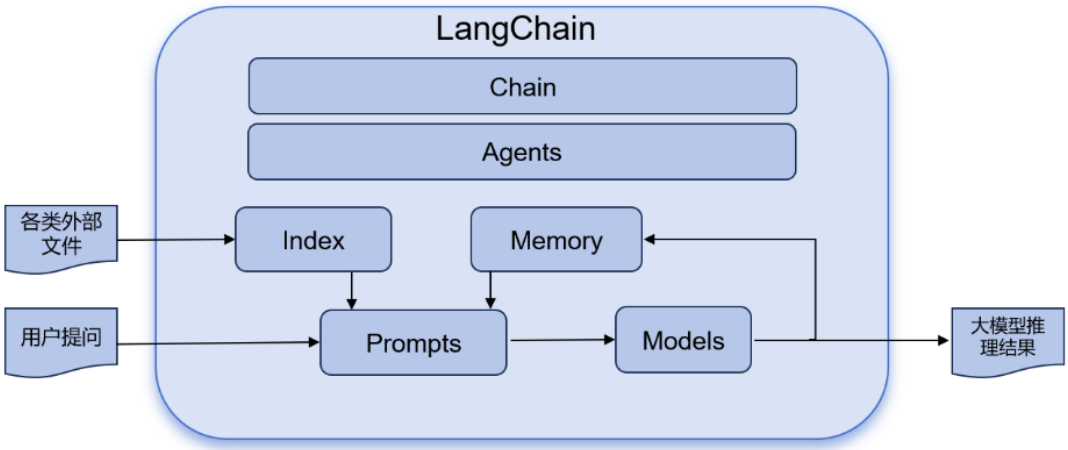

图 2.3 LangChain 链式构造图示

中国知网 https://www.cnki.net

LlamaIndex 和 LangChain 都是用于构建基于大语言模型（LLM）的应用程序的框架，但它们在设计理念和应用场景上有所不同，LlamaIndex 主要侧重于数据的检索和处理，适合需要快速访问特定领域知识的场景，LangChain 则是一个更通用的框架，用于构建复杂的语言模型应用。它通过链式组合多个组件，其链式构造如图 2.3 所示，包括语言模型和外部数据源，实现高级的自然语言处理任务，如信息检索、文本生成和知识图谱构建。

LangChain 利用 LLM 执行各种自然语言处理任务。它支持一系列 LLM 模型。用户可以在 LangChain 框架内灵活选择和使用最适合其特定需求的模型。其提供的工具和组件，帮助开发者构建由 LLM 驱动的智能体。LangChain 的核心架构包含：Models 提供与各种 LLM 交互的接口；Prompts 用以优化提示工程，引导 LLM 生成所期望的输出；Agents 赋予 LLM 调用外部工具（如搜索引擎、API）和内部工具的能力，使其能够自主完成任务；Chains 是将多个组件（如模型、提示词、代理）组合成一个链条，实现更复杂的任务流程；Memory 在对话过程中存储和检索信息，提升交互的连贯性和逻辑性，它会收集链上每次数据流动的信息。这些模块共同协作，使得 LangChain 能够支持从简单的问答到复杂的多步骤任务执行，极大地扩展了 LLM 的应用范围。

2.4 扩散模型

在 Stable Diffusion 诞生之前，在计算机视觉和机器学习领域最流行的模型是 GAN，它的核心思想是：通过生成器与判别器不断对抗进行训练，通过相互博弈实现渐进式的性能提升，最终当模型收敛时，将得到一个生成效果较好的生成器。但是随着研究的深入，GAN 逐渐暴露出一些瓶颈和问题，如图像生成缺乏多样性、模式崩溃、训练时间长以及由于其对抗性训练方式导致的训练不稳定性等。2015 年由 Sohl-Dickstein[53] 提出的深度生成模型，为扩散模型的诞生提供了理论基础，扩散模型（Diffusion Model）的基本数学框架主要基于概率生成模型，通过逐步添加和去除噪声来生成高质量的数据样本，与 GAN 中采用的对抗目标相比，扩散模型提供了更稳定的训练目标，并且在生成质量方面优于 VAE、EBM[54]和 NF[55]。

2020 年 6 月 Jonathan 提出的 DDPM[56]去噪扩散概率模型构成 SD 的理论基础，DDPM 在更加庞大的数据集上实现了与当时 GAN 模型相媲美的性能。

其核心思想是将数据视为一个随机过程的终点，从一个简单的先验分布开始，逐步添加噪声，最终达到数据的真实分布，然后再通过逆过程去除噪声，生成新的样本。前向扩散过程（Forward Diffusion Process）是指逐步向数据添加高斯噪声，直到数据变成纯噪声的过程。具体来说，每一步都会向原始数据添加随机噪声，噪声服从高斯分布，且随着扩散步骤的增加，噪声逐渐累积，最终形成一个纯噪声分布。反向去噪

中国知网 https://www.cnki.net

过程（Reverse Denoising Process）是前向扩散过程的逆过程，即从噪声数据逐步去除噪声，恢复出原始数据的过程。传播过程如图 2.4 所示。

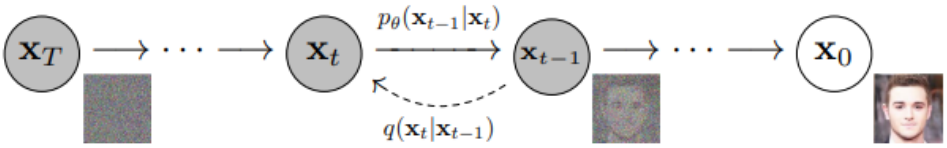

图 2.4 DDPM 传播过程图[56]

前向过程通过一系列步骤将数据逐步扩散到一个高斯分布。给定初始图像 X_0，向其中逐步添加高斯噪声，加噪声的过程持续 T 次，每一布都将生成一个带噪声的新图像 X_n，最终原始图像就丢失原始数据变成了一个随机噪音。由 X_{t-1} 加噪至 X_t 的过程中，所加噪声的方差为 β_t，其大小介于 0 到 1 之间，随扩散步数增加而逐渐增大的值，整个前向过程构成一个马尔可夫链。前向过程如式（2.3）[56]：

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I\right), q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1}) \tag{2.3}$$

逆向过程可以假设它也是一个高斯分布，但是无法逐步地去拟合分布，所以需要构建一个参数分布来做估计，在逆向传播中使用 UNet 网络预测噪声。即需要求出逆向过程中所需的 P(Xt-1|Xt)，实现从任意一个中间噪声 Xn 都能还原出前一项 Xn-1，最后得到随机生成的样本数据。逆向过程如式（2.4）[56]：

$$p_\theta(X_{0:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1} \mid x_t)^m, p_\theta(x_{t-1} \mid x_t) = \mathcal{N}\left(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)\right) \tag{2.4}$$

Latent Diffusion Models[57]（LDM）是一种结合了变分自编码器（VAE）和扩散模型的高效生成模型。其核心思想是将高维数据（如图像）通过预训练的自动编码器映射到低维潜在空间，并在该空间中执行扩散过程，从而显著降低计算成本，同时保持生成质量。其主体结构主要包括三个模型：VAE、CLIP[58]和 UNet[59]。VAE 由编码器和解码器两部分组成，编码器将输入图像压缩成一个潜在空间的向量，解码器则将这个向量重构回图像空间；CLIP text encoder 将文本输入提示转化为文本语义嵌入；UNet 主要在扩散循环中对高斯噪声矩阵进行迭代降噪，并且每次预测的噪声都由文本进行引导，将预测的噪声在随机高斯噪声矩阵上去除，最终将随机高斯噪声矩阵转换成图片的隐特征。模型结构图如图 2.5 所示。

中国知网 https://www.cnki.net

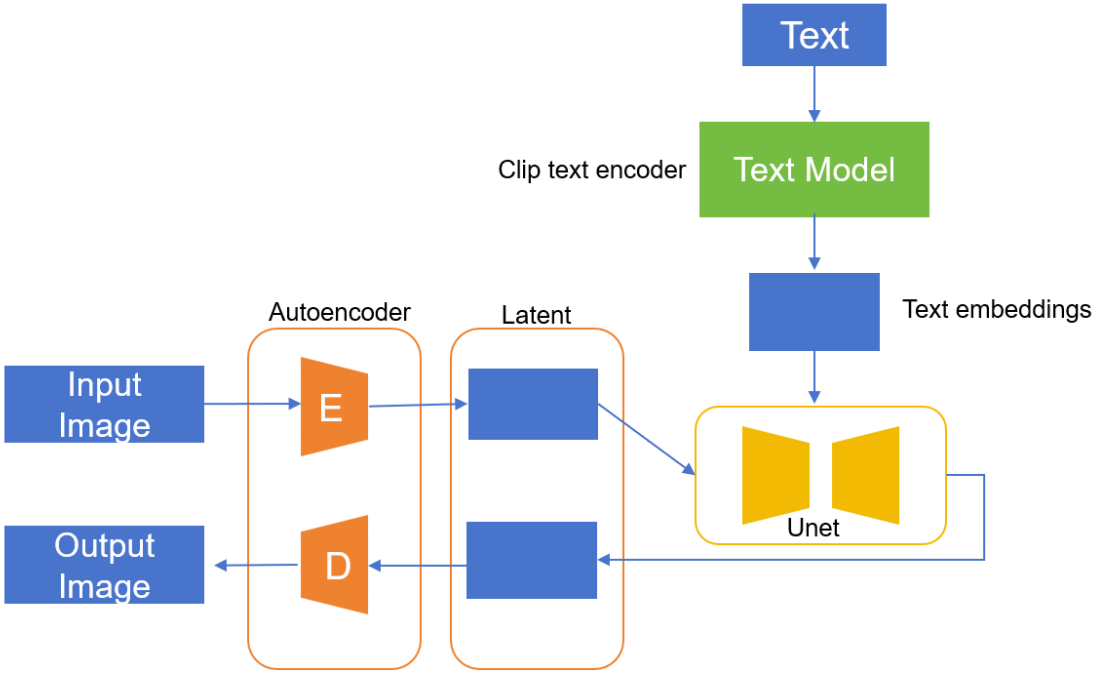

图 2.5 SD 模型结构图[56]

FLUX[60]是由推出 Stable Diffusion 3 的核心团队 Black Forest Labs 于 24 年 8 月开发的新开源扩散模型。Black Forest Labs 团队采用了 Flow Matching 的生成模型训练方法来改进扩散模型，这一技术让 FLUX.1 在图像细节、提示遵从性、风格多样性、文字和场景复杂性方面达到了文生图的新高度。采用混合多模态加并行扩散变换器架构，结合了多模态和并行扩散 Transformer 块。FLUX 还引入了流匹配训练方法、旋转位置嵌入和并行注意力层等技术创新，显著提升了模型性能和硬件效率，采用模块化设计，将模型、CLIP 和 VAE 分开为独立节点，支持更灵活的调整和优化，在速度、效率和质量方面表现优异，特别是在复杂场景和细节渲染方面超越了 SD，其高性能版本在视觉质量和提示遵循性方面优于 Midjourney 和 DALL-E[61]。

2.5 模型微调

模型微调是指在预训练模型的基础上，使用较小规模的特定领域数据集进行进一步训练的过程，其目的是提升模型在特定任务或领域上的性能表现。微调过程会对模型的原始参数进行修改调整，从而得到适应新任务的新模型。参数调整量的实现主要分为两种方式：

第一种方法是通过训练学习计算出每个参数的调整量，这种方法被称为全量微调。全量微调需要对模型的所有参数进行重新训练，因此对于大模型而言，其计算复杂度和资源消耗都较高。

中国知网 https://www.cnki.net

第二种方法是 LoRA[62]（Low-Rank Adaptatio）。其核心思想是冻结预训练模型的原始权重，同时在 Transformer 架构的每一层中引入可训练的低秩分解矩阵，从而显著减少下游任务中需要训练的参数量。在推理阶段，训练好的 LoRA 权重可以直接与原始预训练模型权重合并，因此不会引入额外的计算开销。

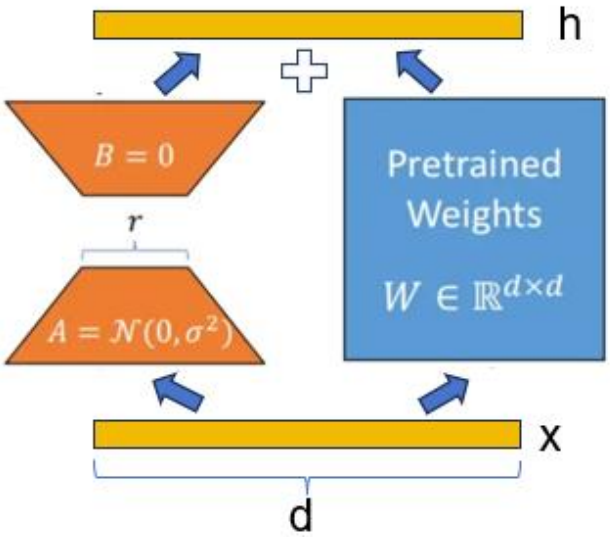

图 2.6 LoRA 模型结构[62]

如图 2.6 所示，LoRA 微调方法在应用时保持原有网络层的权重（蓝色部分）固定不变，同时额外引入一个可训练的 LoRA 模块，并将其输出与原始网络模块的输出相结合。在训练过程中，仅对 LoRA 模块的参数进行优化更新，而预训练模型的原始权重始终保持冻结状态。该技术主要由两大核心组件构成：Pretrained Weights（预训练权重），即原始网络的固定参数，在微调过程中完全冻结以保证其稳定性；LoRA 模块通过低秩分解技术设计，由两个可训练的低秩矩阵（A 和 B）的乘积构成，作为微调过程中唯一需要更新的参数部分，成为模型的核心模块。

$$h = W_0 x + \Delta W x = \left(W_0 + \Delta W\right) x = Wx + BAx \tag{2.5}$$

LoRA 低秩分解数学计算公式如公式（2.5）[62]，在模型的原始参数矩阵（W∈R^{d×k}）旁，通过插入一个与之并行且尺寸相同的新权值矩阵 ΔW∈R^{d×k}，并基于模型的低秩特性，进一步将 ΔW 通过低秩分解拆分为两个小矩阵：特征降维矩阵 A∈R^{r×k}和特征升维矩阵 B∈R^{d×r}（其中秩 r 远小于 d 和 k 的维度）。这种分解通过降低矩阵秩的维度，实现了对原始模型参数的高效调整。LoRA 技术通过其高效性和灵活性，为大模型的微调提供了一种新的思路，尤其适用于需要快速适应下游任务的场景。

中国知网 https://www.cnki.net

2.6 本章小结

本章对与本文研究相关的理论做了简单的介绍，介绍的内容包括设计思想、网络框架和主要应用，相关理论涵盖了大模型广泛应用的几个核心技术，包括注意力机制、Tranformer、LLM 智能体、扩散模型、模型微调等方面。

中国知网 https://www.cnki.net

第三章 基于大模型的交通智能体研究

3.1 引言

人工智能的发展与其自然语言处理的结合给智能交通领域带来了新的机遇，其中最具有代表性的大语言模型是 ChatGPT，它的出现带来了一波大语言模型的浪潮，强大的学习理解能力使其可以应用在各个领域。

传统智能交通系统通常由多个相对独立的子系统组成，子系统间交互有限，集成复杂度高，需大量定制开发实现数据共享与功能协同，且主要依赖结构化数据，需要在给定实验数据后对特定数据集进行建模训练，对非结构化数据处理能力不足，数据分析方法较传统，基于深度学习算法，深挖数据价值。这种方式需要研究人员从模型底层入手，针对各种特定任务来训练不同的模型，在最优路径规划、单车停放等问题上已经存在很多优秀的训练模型。在各种导航软件上，这些模型都被发挥到极致，为用户提供了一个可靠的参考。而大模型可以通过实现在与用户的对话中，分析用户需求，通过用户需求在已给的工具库中调用合适的工具，实现大模型发挥其高水平的语义分析理解及推理能力，像人类一样思考推理并做出决策。

大语言模型需要大量的开发工作和维护成本，各种大语言模型应用框架的出现使得大语言模型的应用难度降低，提高了开发效率和可维护性。在现代应用系统中往往需要与多种异构系统进行数据交换和功能协同，大模型应用框架提供了标准化的接口，简化了与各种系统（如数据库、API、ERP 系统等）的集成过程。通过提供统一的接口和工具，大语言模型应用框架可以大大减少开发者在集成大模型时的工作量，提高开发效率。大模型应用框架在集成复杂性、数据处理需求、性能优化、监控运维、标准化和一致性等方面提供了关键支持，通过框架内的模块化组件和接口，便于开发者根据具体要求自由组合。

本研究基于大模型应用框架构建了一个交通智能体系统，通过集成国内外先进的大语言模型与国内交通软件应用实现功能联动。该智能体采用 LangChain 框架作为核心架构，成功对接高德地图 API 接口[63]实现城市交通信息服务。在技术实现层面，为大语言模型定向开发了工具集成接口，依托其强大的语义理解能力，可自主选择并调用适配工具向用户输出精准决策信息。同时通过 LangGraph 框架构建的网络，进一步强化了系统在理解用户需求、调用分析工具以及生成解决方案方面的能力，形成闭环决策链路。这种集成设计不仅降低了传统 AI 系统开发的复杂度，还显著提升了开发效率和系统可维护性。在本章后续内容中，将详细阐述该框架的架构设计理念、关键技术实现路径以及实际应用效果，重点展示如何通过大语言模型与智慧城市交通系统的

中国知网 https://www.cnki.net

深度融合，为城市治理和服务创新提供智能化解决方案。

3.2 LangChain 架构

基于 LangChain 框架构建的链式结构，能够将大语言模型与外部接口系统化串联。其中 LCEL（LangChain Expression Language）作为链式组装的标准化表达方式，赋予构建的链式结构自动化的批量处理、流式输出、并行计算及异步处理等能力。此外，链可以进一步通过 LCEL 组装成更复杂的链和智能体。代理执行器（AgentExecutor）作为连接代理和工具的桥梁，通过解析输入指令与上下文语义，动态调度适配工具并协调智能体与工具间的交互逻辑，实现复杂任务的自动化执行。然而该框架下，代理执行器的循环操作机制虽支持迭代决策，但其黑盒化的决策过程缺乏透明控制，存在因逻辑死循环导致系统失控的风险，制约了复杂智能体系统的构建。

为突破上述限制，LangGraph 框架在 LangChain 基础上扩展出面向复杂场景的精细化控制能力。该框架通过状态图（StateGraph）建模与多角色协作机制，将 LangChain 的应用范畴拓展至多智能体领域。其核心价值体现在三个方面：协作式架构支持多链、多智能体及工具间的协同作业，强化 LLM 调用过程中的循环控制与智能体调度精度；通过中央状态对象（State）的动态维护，实现任务执行过程中节点状态的可视化追踪与精准控制；使用图式编程范式，基于状态图的编译执行机制，将复杂任务分解为节点（Nodes）、边（Edges）与状态变量的组合逻辑。

LangGraph 的图构建流程包含三个核心要素，分别为节点（Nodes）、边（Edges）和状态定义（State）。节点作为工作流的基础单元，可封装工具函数、智能体、决策链或嵌套子图；边用来定义节点间的流转逻辑，分为普通边（固定跳转路径）与条件边（基于状态的条件跳转），后者需配置条件判断函数动态确定下游节点；状态定义则是通过状态对象记录全流程的变量演化，LangGraph 简化了状态管理和中断处理，使开发人员能够专注于定义节点、边和状态结构。

StateGraph 作为该框架的核心类，通过多重机制构建高可靠系统架构：首先，作为状态容器，它集中存储任务执行过程中产生的多维变量，并通过标准化消息格式规范节点间的通信；其次，依托动态更新机制，每个节点执行后自动触发状态迭代更新，并通过预设的边连接将最新状态精准传递至下游节点，形成闭环数据流；此外，通过中断处理模块内置的状态异常检测机制，实时监控状态演化路径，有效拦截错误状态的传播，避免引发系统故障。这种架构设计通过状态驱动的模块化解耦，将复杂智能体系统拆分为可独立开发调试的组件单元，使开发者能够聚焦核心业务逻辑的构建，显著降低了多智能体系统的开发复杂度与后期维护成本。

中国知网 https://www.cnki.net

3.3 Agent 框架搭建

3.3.1 工具构建

在智能体构建中，需要实现智能体与工具（如 API、数据库、外部服务等）的集成和绑定。这种绑定是为了让智能体能够更高效地调用和利用外部资源，以完成复杂的任务。工具根据高德地图提供的 API 接口进行定义，封装了对城市区域编码，天气查询，经纬度查询，区域定位，步行路径规划，公交线路规划，自驾线路规划等功能。还通过百度的 APPbuilder[64]创建的百度搜索工具，并封装成系统的工具库，实现对百度搜索工具的调用。

在构建工具时，需要遵循一定的规范。工具（Tool）由装饰器进行定义，用于封装特定功能模块供智能体调用。工具注释需明确描述其功能定位、输入参数及返回值规范，这些语义信息在与大语言模型协同工作时，将作为关键数据帮助模型理解工具的应用场景与调用逻辑，从而支持模型在推理过程中准确选择并触发对应工具。以构建地址坐标解析工具为例（如表 3.1 所示），该工具通过@tool 装饰器声明，其注释中需清晰定义工具功能、输入参数及输出格式（经纬度坐标对象），形成完整的工具语义描述体系。

表 3.1 获取经纬度工具示例

```
@tool
def geo(city:str,add:str)-> str:
    """获取给定城市的具体位置的地理编码，即对应的经纬度，city 参数是城市名称,add 参数是城市的具体位置名称。返回的消息中包含的就是经纬度，经度在前，纬度在后"""
    url = 'https://restapi.amap.com/v3/geocode/geo?parameters'
    key_private = '高德 API-KEY'
    param ={
        'key':key_private,
        'address':add,
        'city':city,
        'output':'json'
    }
    response = requests.get(url,params=param)
    data = response.json()
    return data['geocodes'][0]['location']
```


中国知网 https://www.cnki.net

LangChain 对该工具的解析如表 3.2 所示：

表 3.2 LangChain 工具解析

StructuredTool(name='geo', description='获取给定城市的具体位置的地理编码，即对应的经纬度，city 参数是城市名称,add 参数是城市的具体位置名称。返回的消息中包含的是经纬度，经度在前，纬度在后',
args_schema=<class 'pydantic.v1.main.geoSchema'>, func=<function geo at 0x000001DF54671B20>)
属性 func：<function __main__.geo(city: str, add: str) -> str>
参数 schema：
{
'title': 'geoSchema',
'type': 'object',
'properties': {'city': {'title': 'City', 'type': 'string'},
'add': {'title': 'Add', 'type': 'string'}},
'required': ['city', 'add']
}

定义的各工具如表 3.3 所示如下：

表 3.3 工具列表

工具名	工具描述
GeoGet	获取给定城市的具体位置的地理编码，即对应的经纬度，city 参数是城市名称,add 参数是城市的具体位置名称。返回的消息中包含的就是经纬度，经度在前，纬度在后。
WeatherGet	获取给定城市区域编码的天气信息，参数 id 是对应的城市区域编码。
DistrictCoding	获取给定城市名称对应的城市编码，keywords 参数是对应的城市名称。
WalkRoute	步行路径规划，origin 参数表示起始位置的经纬度，destination 参数表示结束位置的经纬度，都是经度在前，纬度在后。
DriveRoute	驾车路径规划，origin 参数表示起始位置的经纬度，参数 destination 表示结束位置的经纬度，都是经度在前，纬度在后，如果具体要求使用哪种交通工具，优先考虑驾车。
BusRoute	公交车出行路径规划，参数 city 表示起始位置所在城市名称，参数 origin 表示起始位置的经纬度，参数 destination 表示结束位置的经纬度，都是经度在前，纬度在后。

中国知网 https://www.cnki.net

续表 3.3 工具列表

StaticmapGet	这是生成一幅标注对应位置的地图图片的工具，在地图图片上标注出对应位置名称，根据参数 location 提供的经纬度(经度在前，纬度在后)生成地图的图片，该经纬度位于地图图片的中央，参数 name 的值的即该经纬度坐标对应的位置名称，生成的地图图片保存在 output.png 文件中。
BusLine	这是标注对应公交线路的工具，生成的是对应城市公交线路沿途经过的各个站点所在的经纬度的组合，并在地图上标注出对应的公交线路图。输入参数是某地区的公交线路名称。生成的地图图片保存在对应公交线路名称.png 文件中。
Baidusearch	通过百度 appbuilder 创建的带百度搜索工具

3.3.2 单智能体构建

LangGraph 节点间的通信消息格式如表 3.4 所示。在构建 LangGraph 结构时，节点间的消息通常以 BaseMessage 列表的形式定义。每个节点执行后返回的数据会被封装成一个 BaseMessage 对象，并作为最新条目添加到消息列表中。

表 3.4 通信消息格式

```
class AgentState(TypedDict):
    messages: Annotated[Sequence[BaseMessage], operator.add]
```

单智能体的工作流如图 3.1 所示：

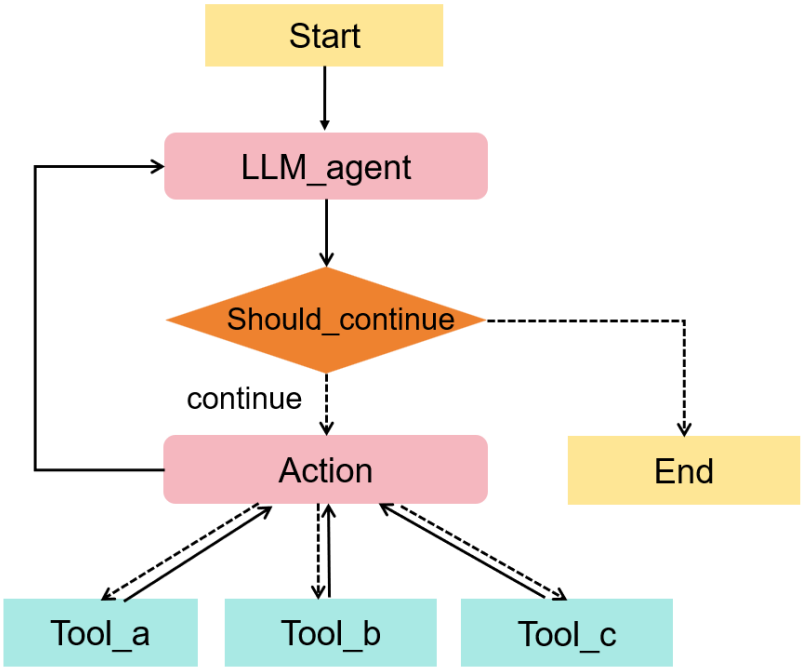

图 3.1 单智能体工作流程图

中国知网 https://www.cnki.net

LLM_agent 节点的核心操作是通过 call_model 方法调用大模型，如表 3.5 所示。调用时需传入执行过程中累积的完整消息列表，这是因为大模型必须基于 LangGraph 完整的消息链作为输入，才能准确解析当前需要执行的操作指令。调用完成后生成的结果会被封装成 AIMessage 对象，并作为新消息节点添加到当前消息列表中。

表 3.5 LLM_agent 节点构建

```
# Define the function that calls the model
def call_model(state):
    messages = state["messages"]
    response = model.invoke(messages)
    # We return a list, because this will get added to the existing list
    return {"messages": [response]}
```

条件执行判断节点定义如表 3.6 所示，该节点依据 LLM_Agent 返回的最新消息（即消息列表末端的记录）进行决策，通过检测其中是否包含工具调用来决定是否触发工具调用流程。当确认需要工具调用时，执行结果会被封装为 ToolMessage 对象并附加至消息列表末尾，该消息包含工具调用的响应内容、工具名称及工具 ID 等元数据。按照图结构定义的流程，工具调用结果将传递至下游的大模型节点，由大模型基于完整消息链重新进行推理生成响应。新生成的响应会再次提交至条件判断节点进行循环验证，直至输出的结果达到 LLM_agent 的预期目标。

表 3.6 条件执行判断节点构建

```
# Define the function that determines whether to continue or not
def should_continue(state):
    messages = state["messages"]
    message_last = messages[-1]
    if not last_message.tool_calls:
        return "end"
    else:
        return "continue"
```

3.3.3 Multi-Agent 构建

在单智能体架构中，所有工具调用均作用于同一智能体实例。当涉及大规模工具调用时，该架构存在局限性：可能因负载过载影响模型的任务语句理解能力导致工具调用失败。通过引入多智能体（Multi-Agent），可将不同功能模块的任务按逻辑解耦，分配给不同的智能体执行。这种架构具有功能边界清晰、隔离性强的优势，同时支持对用户请求的并行化处理。

在本研究中选择使用不同 LLM 来编排不同智能体，通过 Multi-Agent 实现不同任

中国知网 https://www.cnki.net

务，结构如图 3.2 所示。本研究集成多个智能体构建了一个 Agent Group，并将一个智能体作为监管者（supervise）承担任务分发职能。在图中所示的多任务执行框架中，监管者智能体负责解析初始请求并派发子任务，下层功能型智能体则专注执行绑定的工具操作。在此架构下，单个智能体仅需关联少量专用工具（可单工具绑定），并通过针对性提示词工程配置，即使性能较弱的 LLM 也能可靠完成特定子任务。当工具集规模较大时，通过智能体间的协同调用机制，既可实现复杂任务链式处理，又能规避单智能体因工具绑定过多导致的语义解析精度下降问题。通过不同 Agent 执行特定任务，各 Agent 任务相互独立，每个 Agent 携带的 tool 工具数量减少，调用工具时也不易产生歧义，完成任务的成功率更高。

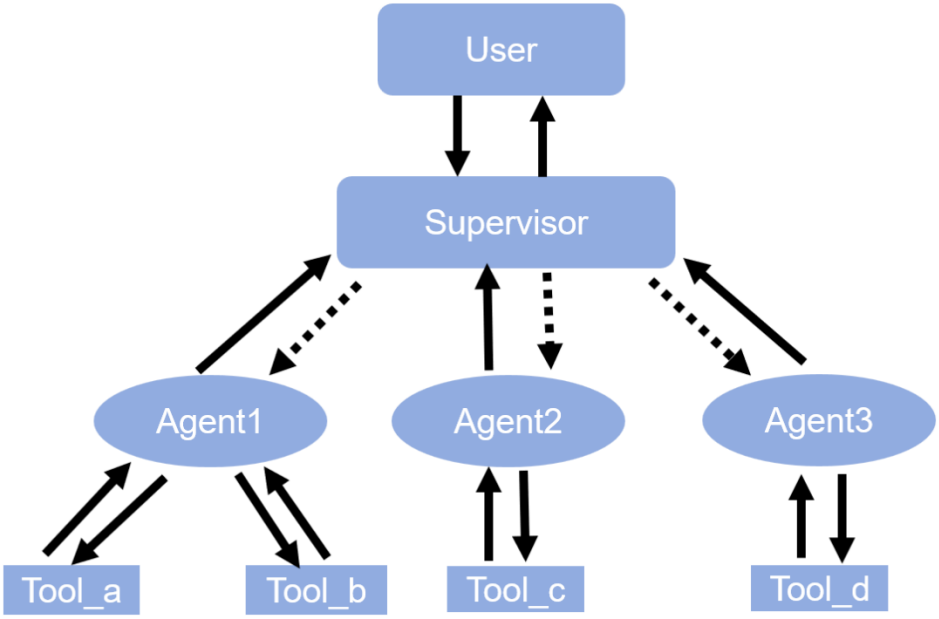

图 3.2 Multi-agent 结构图

在构建的多智能体结构中，执行具体任务的 Agent 功能与单 Agent 执行流程基本一致，其核心区别在于多 Agent 系统的交互机制。在任务执行过程中，Agent 输出的消息需要转换为带有 Agent 名称的信息流。通过这种消息转换机制，Supervisor 接收到的消息将被识别为用户输入，从而作为其决策的依据。Supervisor 的响应会通过状态参数 state 中的 next 字段指定后续节点，可能选择调用其他执行任务的 Agent 节点，也可能判断任务完成通过返回终止流程。这种设计既保持了消息传递的标准化，又确保了任务调度权的集中管控。

中国知网 https://www.cnki.net

3.4 实验设置及结果分析

3.4.1 单 Agent 系统实现

为了展示该框架在处理各种复杂交通任务时的高效性，实验提供了一个使用 ChatGPT（gpt-3.5-turbo）作为语言模型，并利用 LangGraph 来引导 LLM 操作的示例。以人工智能交通助手的身份与用户进行自然语言对话，支持多轮对话并根据用户指令执行基本任务，示例如下图 3.3 所示。

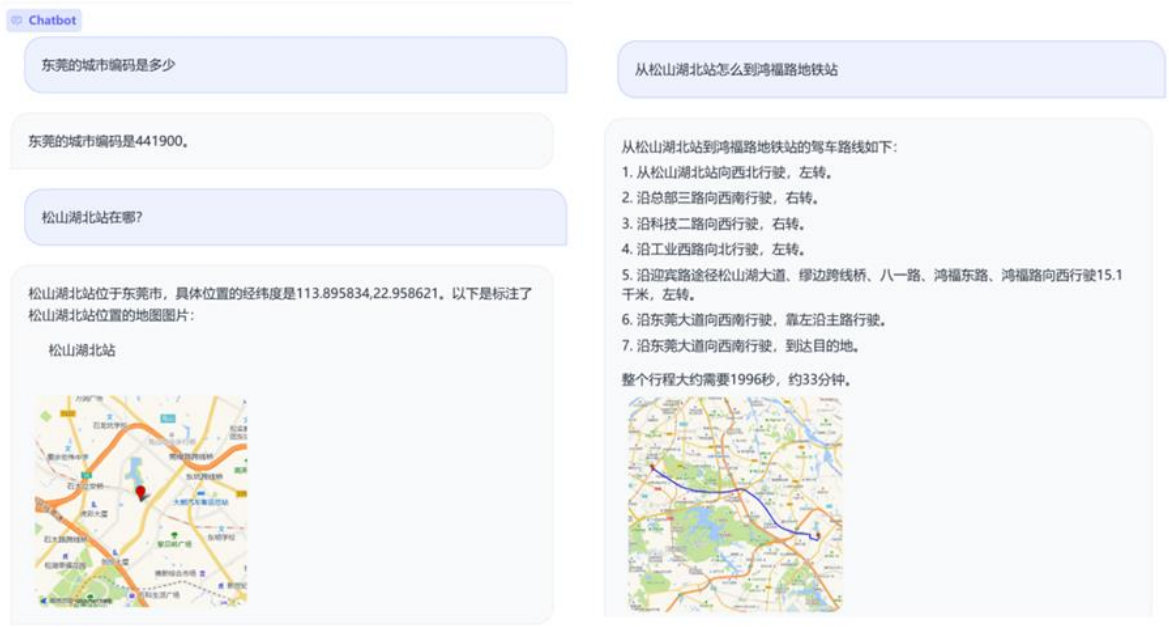

图 3.3 交通智能体可视化界面

本实验采用多模型对比研究框架，选取 gpt-3.5-turbo、glm-4、moonshot 及 qwen-max 四类大型语言模型，系统评估其在工具调用场景下的语义理解与任务解析能力，这些模型在多语言支持、上下文理解、长文本处理和多模态交互方面各有优势。

实验根据用户输入的问题复杂程度将问题分为两类：单工具调用任务和多工具调用任务。单工具调用任务要求模型完成单次语义解析与精准工具匹配；多工具调用任务则需模型实现连续决策，完成工具链的动态编排与顺序调用。针对每类测试场景，各模型均进行 20 轮以上的独立实验验证。

实验结果如图 3.4 所示。柱状图上的三个不同评估维度来展示。x 轴并列展示不同模型在两类任务中的表现，y 轴量化显示正确响应率指标。数据可视化结果表明，在单工具调用场景下，gpt-3.5-turbo、glm-4 与 qwen-max 呈现相近的理解和解析能力，而涉及多工具链式调用时，模型间的性能差异显著扩大，揭示出现有模型在复杂任务编排能力上的本质差异。

中国知网 https://www.cnki.net

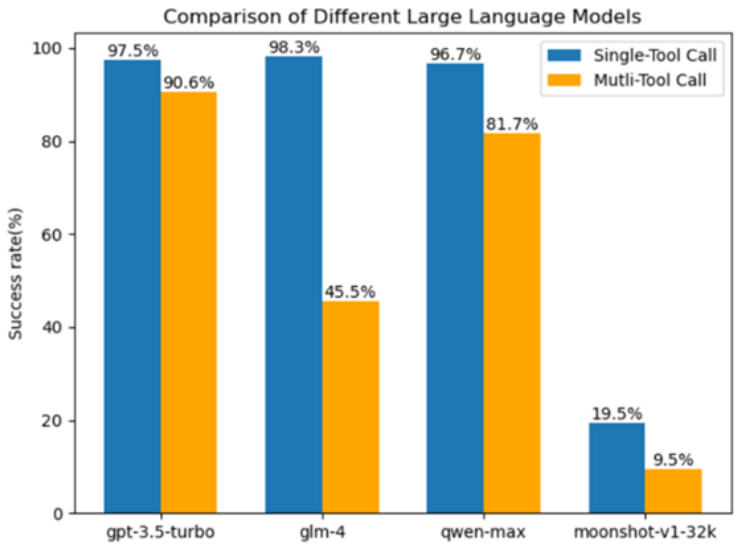

图 3.4 实验对比图

在实验过程中，观察到 gpt-3.5-turbo、glm-4 和 qwen-max 在处理仅需单个工具调用的问题时，展现出相近的理解与解析能力。然而，当面对需要调用多个工具的问题时，这些模型之间的性能差异显著。gpt-3.5-turbo 在处理多工具调用问题时表现出色，它能够按需逐一调用工具。相比之下，moonshot 会在选择工具时一次性调用所有所需工具，而 qwen-max 则因模型返回信息流中不携带 toolid，导致无法正常调用工具，但对代码进行调整后则返回正确。此外，glm-4 的理解能力较好，但对系统提示词和工具描述的要求较高，容易使得大模型调用错误工具影响任务完成度。总体而言，国产大模型在多工具调用任务的理解和泛化能力上相对较弱，任务完成成功率较低。

3.4.2 Multi-agent 系统实现

本研究基于 LangGraph 框架构建多智能体调度流程：创建 Supervisor 节点作为控制中枢，根据接收到的消息动态调度下一级智能体。系统提示词需明确定义各执行智能体的功能与名称，使 Supervisor 能够准确选择目标智能体。通过路由函数确定下一节点的调用逻辑，当任务执行智能体运行结束后，其输出结果返回至 Supervisor 节点继续流转。Supervisor 的系统提示词设计如表 3.7 所示：

表 3.7 Supervisor 系统提示词

您是一名主管，负责管理以下成员：。给出以下用户请求，与成员一起回答下一步动作 1. 若用户信息是关于天气情况或城市区域编码，则任务传递给成员 weather_agent 2. 若用户信息是关于查询经纬度，地理位置，在地图标注位置，则任务传递给成员 map_agent 成员都会执行任务后会以结果和状态做出回应。若您认为全部任务完成，请回复 FINISH

中国知网 https://www.cnki.net

Multi-agent 工具挂载型智能体示例如下表 3.8：

表 3.8 工具挂载智能体构建

天气查询智能体 weather_agent: 提示词：你是天气查询员,能够根据城市名称提供城市区域编码，能够根据城市区域编码查询天气。 工具绑定：集成 DistrictCoding 工具实现城市名称与行政区域编码的转换，通过工具 WeatherGet 执行气象数据检索 地理标注智能体 map_agent: 提示词：你是地理信息专家，能够获取地理位置经纬度，能够根据经纬度在地图上标注位置。 工具绑定：部署 GeoGet 工具进行地理位置坐标解析，结合 StaticmapGet 工具实现地图可视化标注

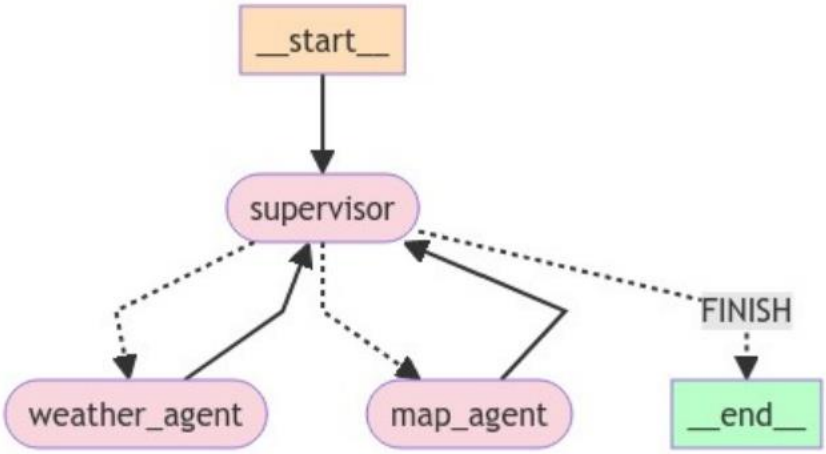

图 3.5 Multi_agent 结构图

实验构造的 Mutli_agent 结构如图所示，针对用户输入“深圳博物馆在哪里”，多智能体主管节点 supervisor 将消息路由至地图处理节点 map_agent。map_agent 节点首先调用地理信息工具 GeoGet 获取该地址的经纬度坐标，GeoGet 工具成功返回经纬度数据后，map_agent 节点随即调用静态地图生成工具 StaticmapGet。StaticmapGet 工具基于该经纬度坐标在地图上进行标注，并生成对应的位置示意图。最终，StaticmapGet 工具将生成的地图标注信息返回给 map_agent 节点，map_agent 节点再将完整的地理位置信息反馈给主管节点 supervisor，完成整个地理位置查询流程，整个任务流程如图 3.6 所示，得到位置图片如图 3.7 所示。

中国知网 https://www.cnki.net

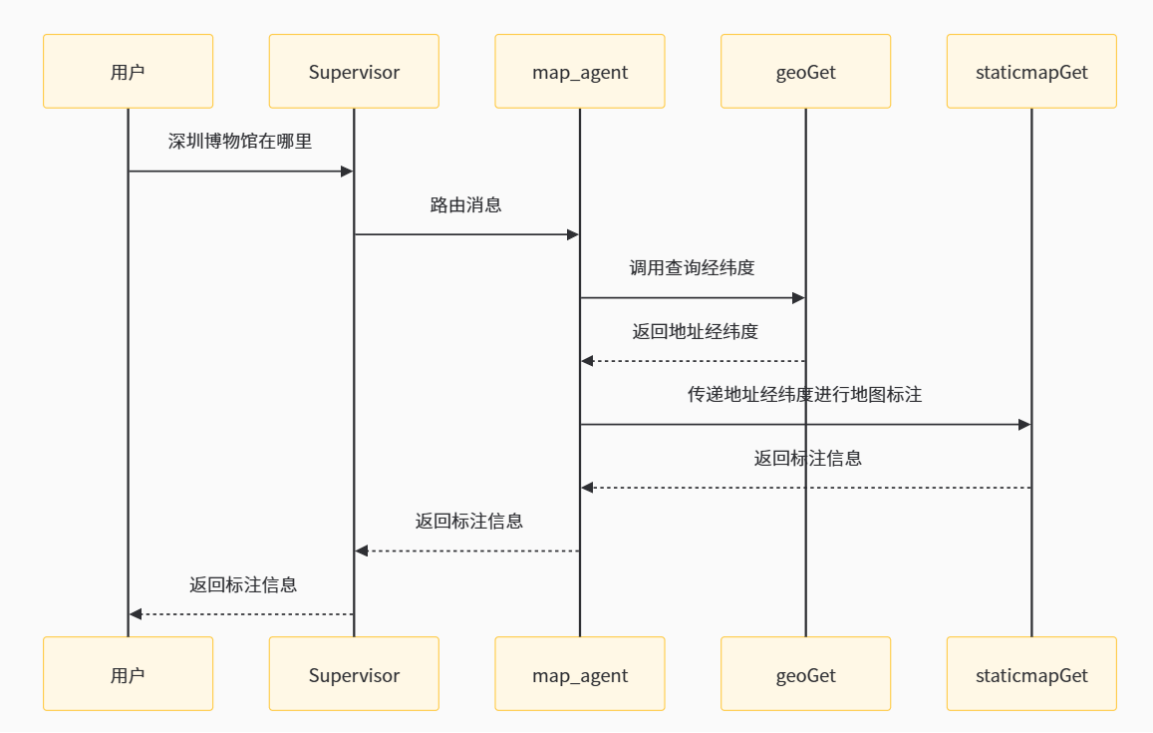

图 3.6 任务流程图

图 3.7 返回任务结果

中国知网 https://www.cnki.net

在 Multi-agent 结构下，将不同任务分派给不同 Agent 执行，虽然单一任务的成功率可能不及集中式单智能体系统，但多智能体架构通过差异化分工实现了显著优势：通过组建具备不同能力的 Agent，系统能够并行处理异构任务，利用各 Agent 的领域专长提升整体效率；同时，Agent 间通过信息共享、任务接力、结果校验等协作机制形成互补，提高了复杂任务流的容错性与鲁棒性。这种协作模式不仅增强了系统对多样化场景的适应性，还通过分布式架构降低了单点故障风险，最终实现大规模复杂问题的系统性解决能力。

3.5 本章小结

本章系统阐述了大语言模型与智能交通系统的深度融合，实现基于 LangGraph 框架的智能体系统构建方法。基于 LangChain 框架，利用 LCEL 实现链式结构与工具集成，并通过代理执行器协调任务调度。针对 LangChain 黑盒化决策的不足，引入 LangGraph 框架扩展多智能体协作能力：通过状态图建模，实现了任务流的可视化追踪、动态调度与容错控制。该架构显著降低了复杂系统的开发复杂度，支持模块化设计与并行处理。在技术实现层面，本章详细阐述了工具构建规范、单智能体及多智能体架构设计及实验验证。通过封装国内地图软件对外提供的 API，构建了包含地理编码、路径规划、天气查询等功能的工具库，并基于装饰器与语义描述实现模型与工具的高效协同。实验结果表明，单智能体系统在单工具调用场景下各模型性能相近，但在多工具链式调用中差异显著（如 gpt-3.5-turbo 表现最优），揭示了现有模型在复杂任务编排能力上的差距。多智能体系统通过分工协作，实现了异构任务的并行处理与容错优化，提升了复杂场景的适应性与鲁棒性。

本章最终验证了基于大模型的智能体框架在智能交通领域的应用价值：通过自然语言交互、多工具动态调度及多智能体协作机制，不仅降低了传统系统开发与维护成本，还为城市交通治理提供了可扩展、高可靠的智能化解决方案。

中国知网 https://www.cnki.net

第四章 基于大模型的交通路网图生成研究

4.1 引言

城市路网地图作为城市交通系统的基础，其生成技术的演进始终与城市发展需求紧密关联。传统上，城市路网图的设计和生成依赖于多种复杂的方法，包括地理信息系统（GIS）建模、计算机辅助设计（CAD）以及专家系统。这些方法通常需要大量的专业输入，如地形数据、交通流量、土地使用规划等，并且涉及多个阶段，包括数据收集、分析、设计迭代和评估。此外，传统方法往往需要城市规划师、交通工程师和地理信息专家的紧密合作，且更新和维护成本较高。

交通网络布局规划主要是对其空间布局合理性和有效性进行综合评价，在城市交通网络基本形态方面，方格网式、带状、放射状、环形放射状和自由式等形态是常见的城市交通网络形态。方格网式交通网具有各部分的可达性均等、秩序性和方向感较好，易于辨别，网络可靠性较高，有利于城市用地的划分和建筑的布置。带状交通网是由一条或几条主要的交通线路沿带状轴向延伸，并且与一些垂直的次级交通线路组成类似方格状的交通网。放射状交通网常被用于连接主城和卫星城之间，而环形放射状城市骨架交通网由环形和放射交通线路组合而成，以放射状交通线路承担内外出行，并连接主城与卫星城。

传统城市路网地图生成方法主要依赖的技术路径有人工测绘与遥感影像联合解译、GPS 轨迹数据挖掘以及开源地图数据融合。在人工测绘阶段，测绘人员需要通过野外实地勘测记录道路几何属性和拓扑关系，并结合高分辨率遥感影像进行道路边界提取与验证。此方法虽能保证数据精度，但耗时耗力且更新周期长，难以适应城市扩张速度。

随着人工智能和机器学习技术的发展，人工智能生成模型的迅速发展，为城市路网图的自动生成提供了新的可能性。在本章研究中，将 AIGC 技术系统性应用于城市路网生成领域，突破了传统方法依赖人工规则与静态建模的局限；结合图生文及文生图技术实现城市路网地图生成方法。通过微调模型，让模型对可以针对特定的城市路网生成定制化的城市路网图，为城市规划者和交通工程师提供强大的工具。

中国知网 https://www.cnki.net

4.2 ComfyUI 工作流图像生成框架构建

4.2.1 图生文工作流

在 ComfyUI[65]框架下构造道路图像生成框架，框架包含三个主要部分，分别为：大模型反推提示词部分，Flux 模型微调部分，文生图部分，总体框架如图 4.1 所示。

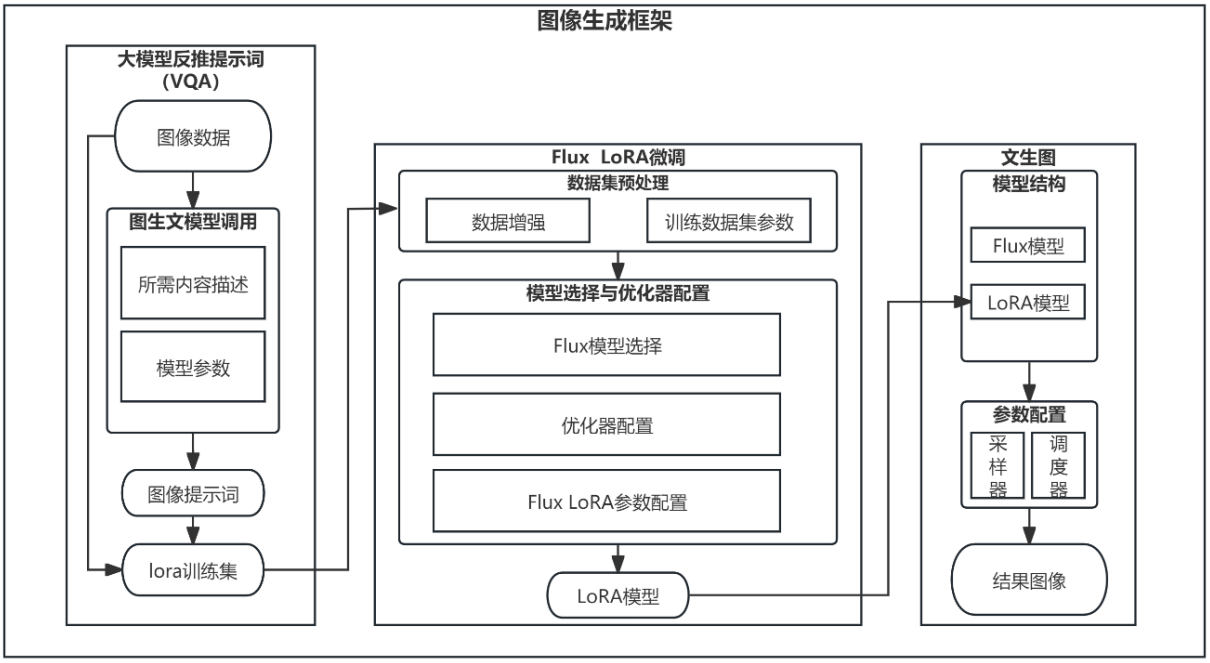

图 4.1 ComfyUI 工作流框架

视觉问答（VQA）是人工智能（AI）领域一项具有挑战性和快速发展的任务。它要求系统根据图像的视觉内容，对用自然语言提出的问题提供准确的答案。该问题通常依赖于图像中的各种细节，如物体、关系、动作或其他视觉属性，并要求系统集成视觉识别和语言理解，以生成能够正确表达图像含义的回答。这项任务集成了视觉和语言两个领域，需要模型运用推理和推理能力来得出准确的结论。

实验使用 MiniCPM-V 2.6[66]作为反推提示词的大模型，该模型在减少参数数量的同时，保持了强大的 OCR 和多模态功能。MiniCPM-V 2.6 的多模态能力构建于其深度融合的架构设计，通过 SigLIP 视觉编码器与 Qwen2 语言模型的协同工作，实现了图像、视频、文本的统一语义理解与生成。其基于 SigLIP 模型的视觉编码器处理高分辨率图像以提取视觉标记，使用最新的 qwen2-7b 架构，将压缩的视觉标记和文本输入馈送到 LLM 中，可以在资源受限环境下在不牺牲其理解深度或生成质量的情况下处理复杂的多模式输入。其在图像、视频和文本的理解与生成方面达到了 GPT-4V 级别。在单图像理解方面，MiniCPM-V 2.6 超越了 GPT-4o mini、Gemini 1.5 Pro 和 Claude 3.5

中国知网 https://www.cnki.net

Sonnet 等主流模型，能够处理任意长宽比的图像，最大像素可达 180 万，能够识别图像中的密集文本。MiniCPM-V 2.6 在 OpenCompass[67]的各项测试中均表现出色：图像识别准确率达到了 95%以上的高准确率，显示出模型在图像内容识别方面的强大能力。生成的文本不仅流畅，而且与图像内容高度相关，显示出模型在多模态理解方面的深度。

在实验中，通过使用 MiniCPM-V 2.6 作为反推提示词的底座模型，ComfyUI 框架下构建图生文工作流，将其对图像的理解作为后续微调模型所用的提示词。基于多模态模型的语义解析能力，结合节点化编排实现视觉内容到文本的精准转化。

通过图生文流程自动生成提示词，为无标注图像添加了语义标签，既弥补了人工标注的高成本缺陷，又为模型提供了监督信号：生成的文本不仅能够描述图像内容，还能引导模型在微调过程中聚焦关键特征，在风格化任务中强化关键词的权重。此外，LoRA 通过冻结原模型参数、仅训练低秩矩阵实现高效适配，而文本提示的存在使得模型能同时调整视觉编码器与文本解码器的交互路径，确保跨模态对齐能力在低秩空间中被针对性优化。即使图生文内容的质量会应所选模型质量存在差异，但仍可以通过进一步筛选，提取与图像内容更为切合的部分作为语义标签，对关键词进行过滤，仍能在数据稀缺场景下有效平衡成本与效果，最终让 LoRA 模型在特定任务场景中实现更精准的细节生成能力。

4.2.2 LoRA 训练工作流

对模型进行 LoRA 的作用在于通过参数高效的微调方式，使预训练模型能够快速适配特定任务或领域，同时保持核心架构的稳定性。LoRA 通过在模型的注意力层或全连接层中插入低秩矩阵分解模块，仅对少量新增参数进行训练从而显著降低计算成本和存储需求。通过这种方法，针对路网图像进行定制化优化，技术模型对交通道路图的理解，提高的细节生成能力。

在 ComfyUI 中对模型进行 LoRA 训练的过程可以分为多个关键部分，涵盖了从数据准备到模型训练和验证的完整流程。

在训练数据准备阶段，需收集并整理高质量的图像数据集，确保图像的分辨率、长宽比和清晰度符合模型要求。数据集需经过裁剪、自动标注及规范化存储等流程处理，以保障数据的多样性和标注一致性。数据集预处理环节包含两个核心功能模块：数据增强模块和数据集参数配置模块。在数据增强模块中，可通过多维调控实现精细化的数据增强策略：颜色增强功能可调节图像的色调、饱和度及对比度，增强模型对色彩变化的泛化能力；水平翻转增强通过随机镜像处理扩展样本多样性；标题随机化机制通过打乱图像-文本对应关系引入数据扰动，有效抑制过拟合现象。在数据集参数配置模块中，除基础参数图像分辨率、批次大小、训练轮次的设置外，还支持添加

中国知网 https://www.cnki.net

特定类别标记及生成触发词，这些语义引导标识可帮助模型控制生成方向。

对 FLUX 模型进行 LoRA 训练的关键在模型组件选择及模型参数初始化阶段。需要选定基本模型、VAE（变分自动编码器）、CLIP（对比语言-图像预训练）和 T5（文本到文本转换器）。这些模型构成了 FLUX 训练过程的骨干。

工作流中的优化器配置节点用于配置训练过程中的优化器参数，其核心功能包括选择优化器类型、学习率调度策略以及优化器相关参数的精细化调节。用户可在此节点中设置优化器基础类型，并选择适配的学习率调度器。此外，支持对优化器专有参数进行微调，例如设置预热步数（控制学习率初始阶段渐进增长）、调度器指数参数（调整学习率变化曲线形态），同时提供自定义参数接口以扩展配置灵活性。

在本次实验中，采用 Prodigy[68]作为优化器。该优化器基于 DAdaptation 技术实现无超参自适应学习率调整机制，尤其适用于 LoRA 微调场景：通过动态学习率调整显著加速模型收敛速度，其内置的二阶矩估计机制能在训练初期采用较大学习率快速逼近最优区域，后期自动降低学习率实现参数精细化调整；在处理 FLUX 等大模型时，能有效平衡训练效率与模型性能，通过梯度信息动态适配参数更新幅度；作为 LoRA 训练的推荐优化器，其无需预设学习率的特性可充分挖掘训练数据潜力，该特性已在视觉-语言多模态模型微调中验证并广泛应用。在完成优化器参数配置后，需设置训练全程的学习率参数并选定适配的调度策略。当选用 Prodigy 优化器时，通常将初始学习率设置为 1，并启用常数学习率调度器，使优化器能够基于训练动态自动适配学习率路径，无需手动干预即可自主探索最优学习率轨迹。

在训练执行阶段，可通过设置训练循环控制器，按预设训练步数间隔保存当前模型状态，搭建阶段性模型检查点。这些检查点可以加载特定训练步数对应的模型快照，对 LoRA 模块训练过程进行验证，生成示例图像以直观评估生成内容质量及任务适配效果。

4.2.3 文生图工作流

在完成 LoRA 模块的训练与验证后，模型针对特定领域的适配能力已通过低秩参数更新被编码至适配器中。然而，这种能力的有效激活需依赖与基底模型的动态协同机制，并通过生成流程的参数化调控实现最终目标。为此，实验中文生图工作流以 FLUX 模型为基底架构，通过模块化节点将训练完成的 LoRA 适配器无缝集成，同时构建包含采样器、调度器等可控参数的生成体系，形成从领域适配训练到可控图像生成的完整技术闭环。该设计不仅延续了 LoRA 训练阶段对模型语义空间的定向优化，更通过生成环节的多维度调控实现优化效果的最终落地。

通过将 FLUX 模型与训练完成的 LoRA 适配器结合，工作流构建出专用于道路交通路网图像生成的优化模型。除了通过 LoRA 与基底模型的参数融合实现核心行为优

中国知网 https://www.cnki.net

化外，还支持采样器（Sampler）与调度器（Scheduler）的组合配置，从生成过程维度提升图像质量。

采样器选择节点作为生成引擎的核心，基于模型学习的概率分布执行迭代去噪操作。调度器选择节点控制采样过程中的噪声减少策略，决定每一步骤中噪声的去除量，确保采样过程高效且图像质量的提升，通过特定的噪声计划，影响图像生成的多样性和细节。一个合适的调度器可以优化采样路径，使得在有限的采样步骤内达到最佳的图像质量。

在 ComfyUI 的可视化工作流框架下，用户可通过灵活配置采样器与调度器的组合参数，实现对生成过程的精细化控制。这种模块化设计优化了 LoRA 训练阶段对模型知识结构的定向修正的可视性，将参数空间的优化转化为高视觉上的精度路网图像呈现，最终实现模型生成交通道路图像满足实际城市场景中的道路拓扑关系。

4.3 图像优化

4.3.1 图像编码及逆编码

在经过微调后大模型生成的图片中，路网的网格化构造布局已经大致清晰，在所构造的图片基础上，实验中将通过对图像进行分割并对分割后的区域进行编码，在不改变模型生成图像中不同区域之间的连通性的基础上，对其进行优化。实现方式为：将大模型生成的交通道路图分割为大小相同的矩形区域。针对每个小区域，分析区域中的道路对区域四条边之间的道路连通性，四条边之间的连通性也对应着该区域与其相邻四区域的连通情况。在每个区域中四条边之间的连通关系一共有六种，分别为：上下，左右，右上，右下，左上，左下连通，所以在编码过程中将这六种连通关系转变为一个二进制的六位二进制编码，当任意两条边之间存在连通道路时，将连通编码置为1，否则为0，通过编码，使得最终所有区域的连通性都被转换为一个六位二进制编码。最终将每个区域的连通性信息转化为一个十进制数，最终构造出一个代表图片区域道路连通性的矩阵。在这个区域连通性矩阵中，存储了整个交通道路图像中的区域连通性信息。

在不改变各个区域内部道路连通性及区域之间的连通性的情况下，对各个区域之间的道路进行简化。把图像经过编码后得到的编码矩阵每个区域的十进制编码还原为原始的六位二进制编码。按照编码指示的连通关系，在对应的两条边之间构建连通道路，把每个区域简化为仅保留基本连通路径，最终将所有区域还原为一张简化交通道路网图片。图像编码及逆编码还原过程如图 4.2 所示。

中国知网 https://www.cnki.net

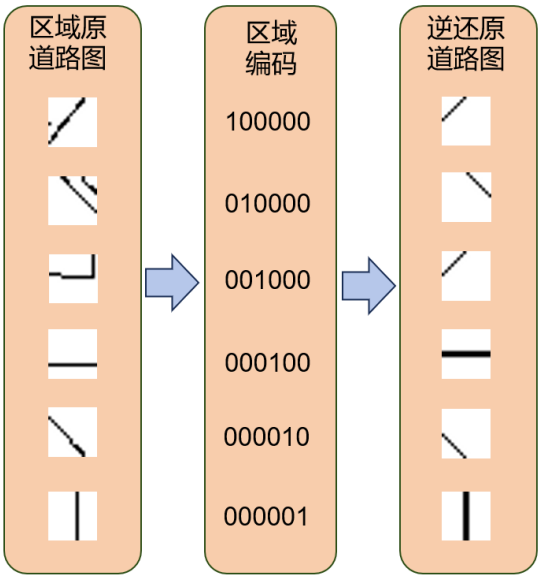

图 4.2 编码及逆编码构造

4.3.2 图像优化及连通性验证

在简化后的道路图像中可能存在结构性瑕疵，例如存在与其他道路完全断开的孤立路段。针对此类问题，可将道路图片当作二值像素图处理：首先沿图像边缘像素发起深度优先搜索，遍历所有连通像素并标记有效道路网络，随后删除未被标记的内部孤立道路，确保输出结果为严格连通的拓扑结构图。

最终，将简化后的道路图像与原始道路图进行对比，验证道路图像连通性的变化情况。在图像划分后的区域中随机选取两两区域作为起始区域和目标区域，使用编码过程中获取的区域连通关系寻找两区域之间的最短路径，通过对比图片转化前后在跨区域流动时所需经过的路径区域进行连通性的比对。连通性验证演示如图 4.3 所示

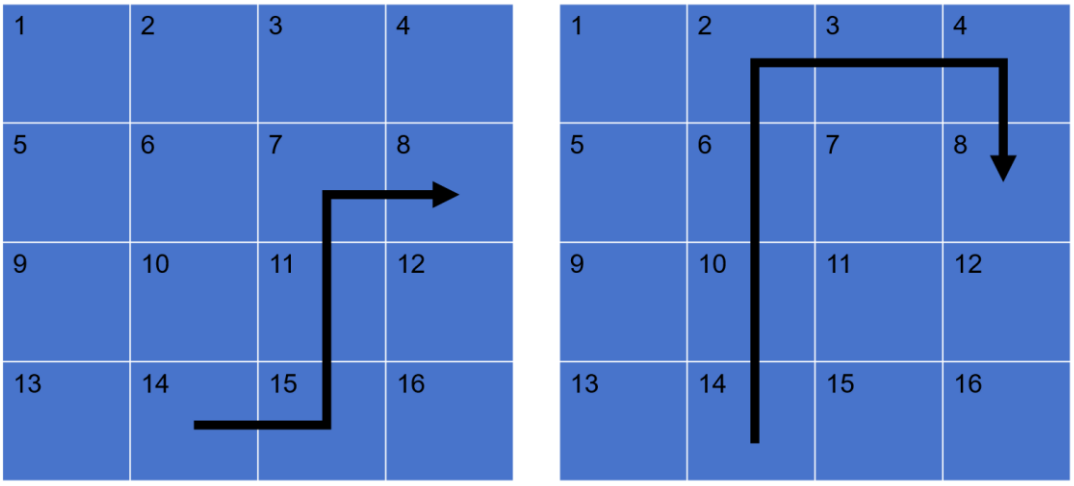

图 4.3 连通性验证演示

中国知网 https://www.cnki.net

4.4 实验设置及结果分析

4.4.1 模型反推提示词

通过 ComfyUI 框架构造 FLUX 模型 LoRA 训练工作流，通过使用 MiniCPM-V 2.6 模型对图像反推提示词，根据图像内容生成描述性文本，这些文本作为 LoRA 训练的标签，强模型在交通道路网图像上的语义理解能力，通过这种方式获得的标签更加多样化，能够帮助 LoRA 模型学习到更广泛的视觉-语言对应关系，提高模型的泛化能力。数据集为在 Openstreetmap 开源地图平台上收集的 30 张栅格状城市交通道路图片数据，在训练中对这些数据进行翻转增强提高数据集差异性。通过模型反推出的提示词结果如下图 4.4 所示:

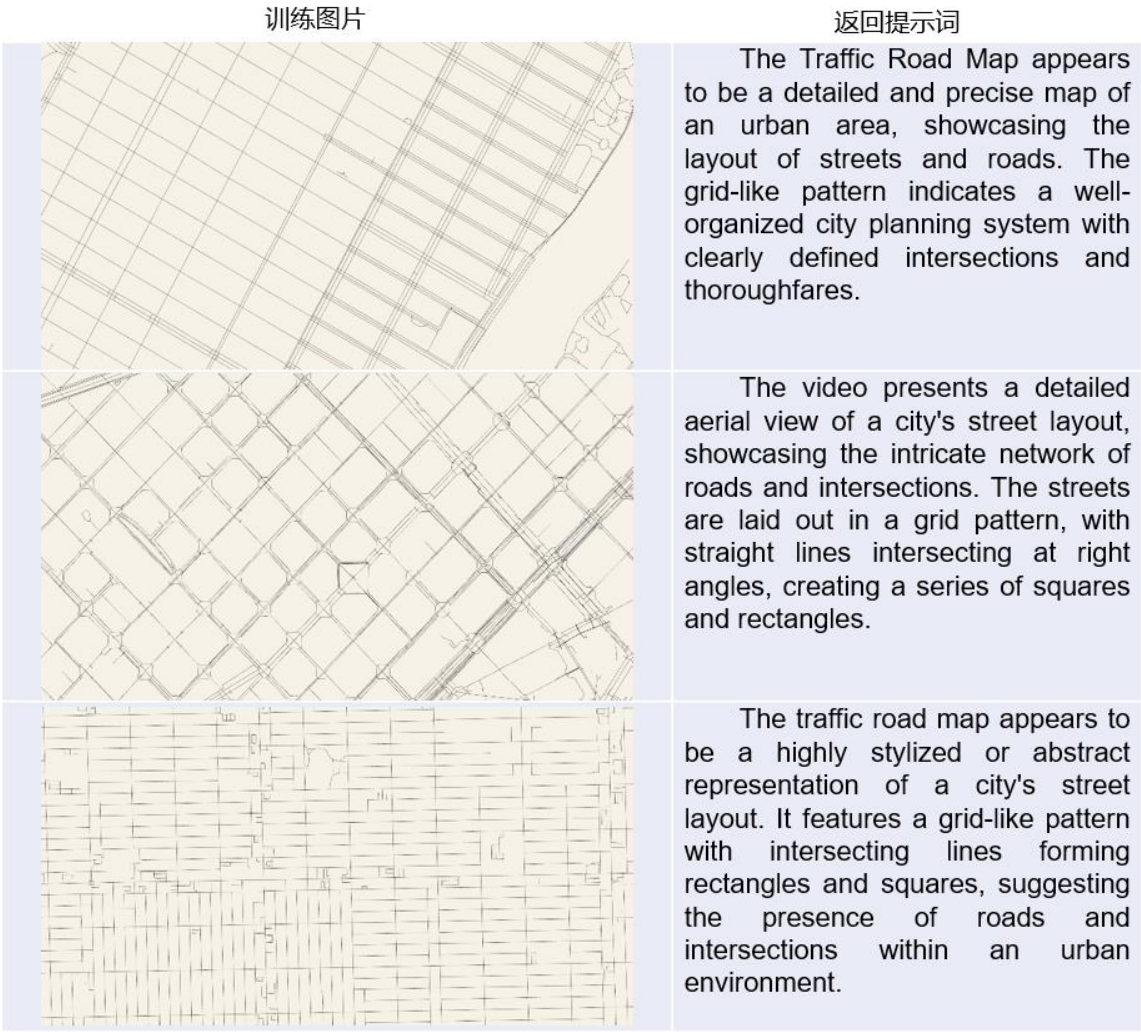

图 4.4 模型反推提示词结果展示

4.4.2 训练 LoRA 模型

在 LORA 工作流中选取 flux1-dev-fp8.safetensor 作为训练模型。将提示词作为图像

中国知网 https://www.cnki.net

的标签与图像一起作为训练输入，选取 prodigy 自适应优化器更新神经网络的权重，模型训练迭代次数为 1800 次，在每训练 450 轮次时设立一个检查点，检查点负责生成验证图像及记录 loss 曲线，验证模型训练效果并防止模型过拟合。每个检查点输出的图像如图 4.5 所示，loss 曲线如图 4.6 所示。

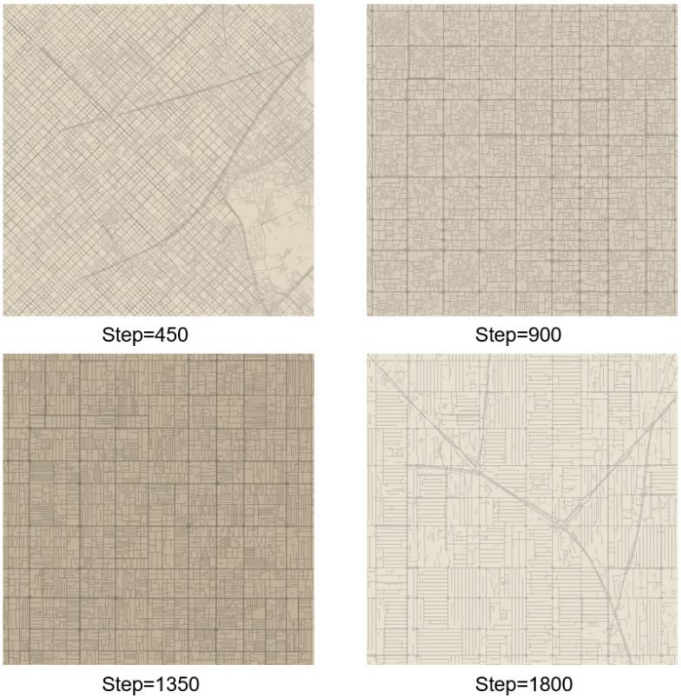

图 4.5 模型输出验证图像

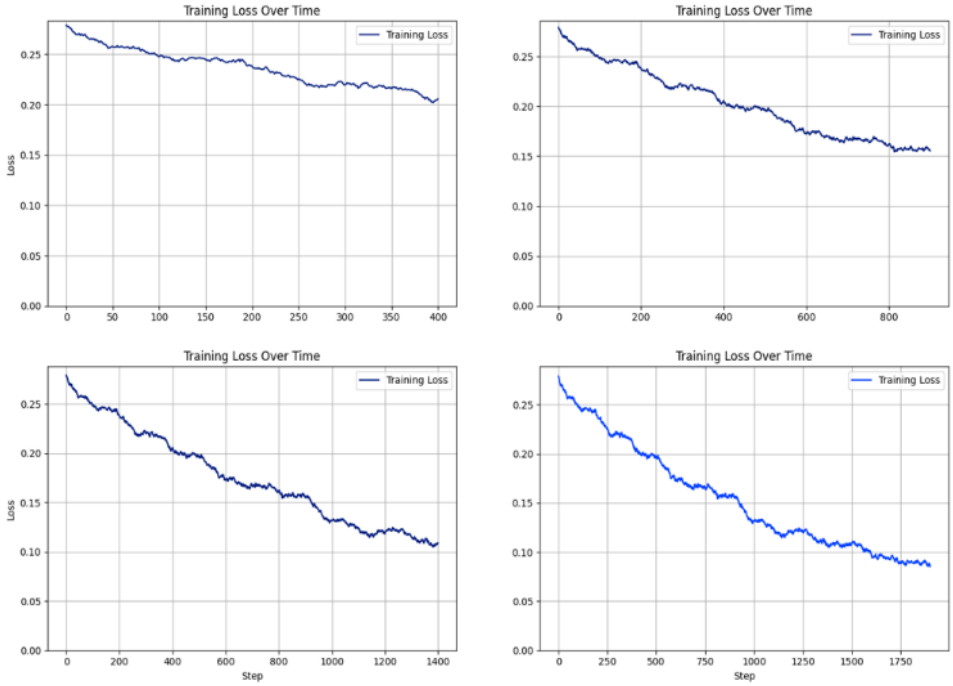

图 4.6 模型训练过程 loss 曲线

中国知网 https://www.cnki.net

在模型训练过程中，随着对道路图像特征提取能力的增强，路网结构的表征精度显著提升。道路形态从初始阶段的杂乱无章、结构复杂逐渐演化为线条简洁规整，同时道路间的拓扑连通关系同步增强。通过多层级特征的迭代优化，图像细节处理能力不断提升，当模型训练至约 1700 步时逐渐收敛。

4.4.3 模型整合生成图像

将 FLUX 基础模型与 LoRA 模型进行整合后，对比经过 LoRA 后的模型和不进行 LoRA 的模型的生成效果，并比较经过不同训练步数的 LoRA 模型生成效果。实验中对模型提出的图像需求设置为：Please generate a grid like urban traffic road map for me. 通过 LoRA 训练后的模型会不断优化道路，道路图像的网格拓扑特征会越来越清晰。

实验结果表明，在使用基础 FLUX 模型（未经 LoRA 微调）时，模型倾向于将输入问题理解为要求生成特定城市的地图图像；而在接入 LoRA 模块后，模型生成的图像则能准确呈现与训练样本相似的交通拓扑结构特征。模型效果如图 4.7 所示。

图 4.7 模型输出道路图

4.4.4 图像优化

在模型最终生成的图像中在不改变道路连通性的基础上对道路进行适当调整，降低图像中道路的复杂度。微调后的 FLUX 模型最终输出的图像分辨率为 1024*1024，对模型输出图像进行分割，依据分割后图像的连通性及制定的编码规则进行编码，得到的连通性矩阵如图 4.8 所示。

中国知网 https://www.cnki.net

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26
0	0	4	0	0	0	0	1	0	0	0	1	0	0	1	0	0	1	0	0	0	0	1	0	0	1	0	0
1	1	0	0	0	0	0	1	0	0	0	35	8	8	21	0	0	1	0	0	0	0	1	0	0	1	0	0
2	63	24	0	8	8	8	15	8	8	8	15	8	8	1	0	0	1	0	0	0	0	3	15	8	5	0	0
3	2	63	21	27	0	0	1	0	0	0	1	0	0	1	0	0	1	0	0	1	0	1	0	0	1	0	0
4	33	14	18	18	30	16	1	0	0	8	35	8	8	21	0	0	1	0	0	0	0	1	0	0	21	0	0
5	5	0	2	18	18	20	1	0	0	0	1	0	0	1	0	0	1	0	0	0	0	1	0	0	1	0	0
6	12	56	8	63	30	24	35	56	56	8	63	8	8	63	8	8	14	8	8	8	8	63	8	8	14	8	56
7	0	21	0	0	26	18	31	26	16	0	35	16	0	1	0	0	0	0	0	0	0	1	0	0	0	0	1
8	35	2	0	0	0	10	63	63	2	56	21	0	0	35	8	8	8	8	8	8	8	63	8	8	8	8	21
9	0	0	0	0	0	0	34	63	18	18	21	0	0	1	0	0	0	0	0	0	0	21	0	0	0	0	1
10	0	0	0	0	0	21	39	14	30	63	63	24	14	63	8	8	8	8	8	8	12	63	8	8	8	8	63
11	32	0	0	2	16	0	1	0	2	18	21	26	24	35	8	8	8	8	8	8	8	21	0	8	8	8	21
12	0	0	0	0	0	0	1	0	0	0	63	26	26	63	0	0	0	0	0	0	0	1	0	0	0	0	1
13	8	56	56	8	8	8	63	8	8	0	63	14	26	63	63	24	8	8	8	8	8	63	8	8	8	8	63
14	0	1	2	0	0	0	1	0	0	0	1	0	2	51	18	18	16	0	0	0	0	1	0	0	0	0	1
15	0	35	8	8	8	0	1	0	0	0	35	16	0	3	18	18	18	16	0	0	0	35	8	8	8	8	21
16	0	1	0	0	0	0	1	0	0	0	1	0	0	35	6	18	18	26	16	10	8	21	0	0	0	0	1
17	8	14	8	8	56	8	63	8	14	8	63	8	8	63	8	8	63	63	14	24	14	63	8	8	8	8	14
18	0	0	0	0	1	0	1	0	0	0	1	0	0	1	0	0	0	14	30	18	16	35	0	0	0	0	0
19	8	8	8	8	14	8	21	0	0	0	35	8	8	63	0	0	0	8	2	18	18	21	0	0	8	8	0
20	0	0	0	0	0	0	1	0	0	0	1	0	0	1	0	0	0	0	0	18	63	31	56	24	0	0	0
21	8	8	8	8	8	8	63	8	8	8	63	8	8	35	8	8	8	8	8	14	14	63	59	19	26	8	8
22	8	8	8	8	8	8	21	0	0	0	35	8	8	21	0	0	0	8	0	4	0	3	63	26	26	16	0
23	0	0	0	0	0	0	1	0	0	0	1	0	0	1	0	0	0	0	0	0	0	1	2	27	63	63	16
24	8	8	8	56	8	8	63	8	8	8	63	8	8	63	8	56	56	56	8	56	8	63	56	10	63	18	63
25	0	0	0	0	0	0	1	0	0	0	1	0	0	1	0	1	0	35	0	0	0	1	0	0	2	18	18
26	0	0	0	0	0	0	35	8	8	8	63	4	0	1	0	0	0	1	0	0	0	1	0	0	0	2	2

图 4.8 连通性矩阵

在连通性矩阵中，每一个元素都代表当前区域内部道路的连通关系，依据这些连通关系重新设计区域内道路帮助实现路网图片的重构，重构后的图片简化了道路但依旧保持原本的图像特征。通过连通性矩阵，将各个区域经过逆编码还原为简化道路图像，通过通路检测对图像中的断路进行筛除，实现图像的优化，结果如图 4.9 所示。随机构造了 10000 对起始及目标区域用以验证区域连通性的改变程度，道路图像前后的连通性相同度为 96.46%。

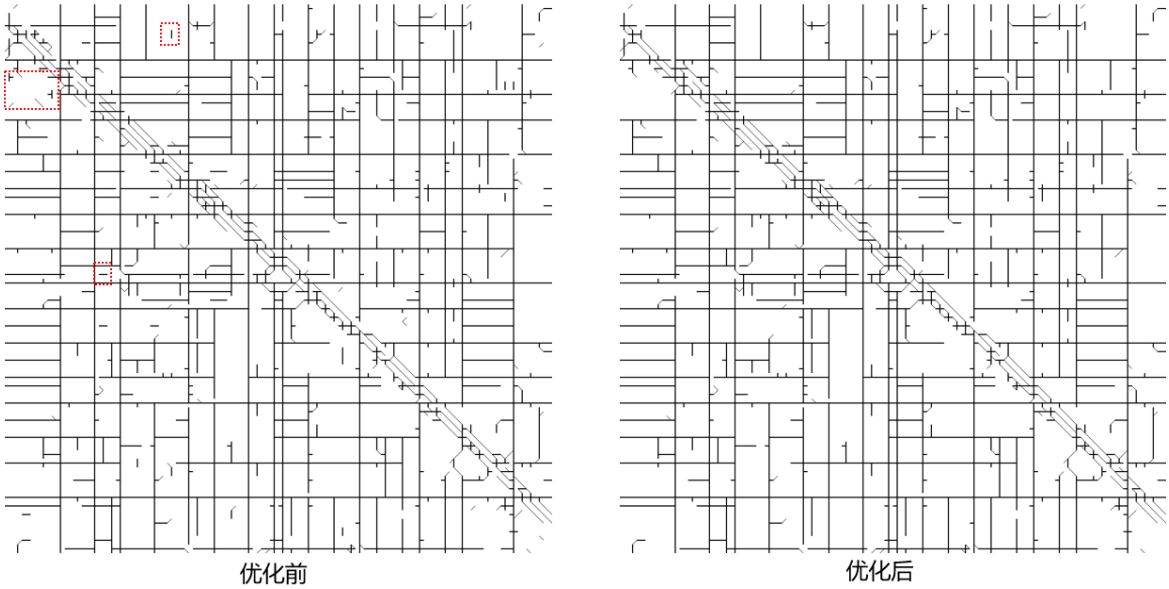

图 4.9 孤立路段筛除

中国知网 https://www.cnki.net

4.5 本章小结

本章详细讨论了城市路网地图生成技术的现代化进程，重点介绍了人工智能生成内容（AIGC）技术在自动生成城市路网地图中的应用。随着城市化进程的加速，传统的基于 GIS 和 CAD 的城市路网图生成方法已无法满足需求。因此，本研究提出了一种新的方法，该方法利用 AIGC 技术，特别是结合图生文及文生图技术，来改进城市路网地图的自动生成。通过在 ComfyUI 框架下构建包含大模型反推提示词、Flux 模型微调和文生图三个主要部分的工作流框架，实现了对城市路网地图的高效生成。

在实验部分，实验中采用了 MiniCPM-V 2.6 模型来反推提示词，增强了模型对交通道路网图像的语义理解能力。通过模型生成的高质量图像描述能够捕捉图像的关键特征和细节，通过 CLIP 将这些描述转换为语义特征向量后，可以为扩散模型提供丰富的语义信息，从而生成更逼真、更符合描述的图像，显著提升生成图像的质量和语义一致性。使得 LoRA 微调技术能够高效地调整扩散模型以适应新的任务，结合 MiniCPM 和 CLIP 提供的语义引导，可以减少训练时间和资源消耗，同时提升模型的泛化能力，使其更好地适应多样化的输入描述。此外，这种方法还可以减少对大规模标注数据的要求，通过高质量的描述输入，实现更高效的模型训练，适用于需要快速生成特定风格和语义一致性的图像生成任务。

通过 LoRA 训练工作流，对模型进行了参数高效的微调，使其能够快速适配特定任务，同时保持核心架构的稳定性。此外，还对生成的图像进行了编码和逆编码处理，以及连通性验证，确保了图像的质量和准确性。实验结果表明，经过优化的模型能够生成高连通性的道路图像，且道路图像前后的连通性相同度高，这证明了实验中提出的方法在实际应用中的有效性和潜力。这一研究不仅为城市规划者和交通工程师提供了新的工具，也为城市路网规划和设计领域带来了创新的思路。

中国知网 https://www.cnki.net

第五章 结论及展望

5.1 结论

随着城市化进程的加速和交通系统的复杂化，传统智能交通系统在动态决策与多源异构数据处理方面面临显著挑战。传统城市交通建设系统长期受限于人工经验主导的决策模式与静态数学模型的计算框架智能交通作为人工智能与城市治理深度融合的前沿领域，正经历着由大语言模型驱动的技术范式革新。人工智能在城市智能交通领域具有广泛的应用潜力，能够显著提升交通系统的效率、安全性和可持续性。本文以人工智能技术为核心，聚焦模型在交通领域的创新应用，提出了一套融合多模态数据处理与智能体协同决策的解决方案。

研究首先构建了基于 LangGraph 框架的交通智能体系统，通过集成地理信息、气象数据与用户反馈，实现动态路径规划与个性化出行建议的实时生成。该系统采用循环控制与状态持久化机制，利用大语言模型的语义解析能力动态调用高德地图 API 等工具，显著提升了复杂交通任务的执行效率与决策精准度。实验结果表明，单智能体架构可以在通过链式高效处理任务，而多智能体架构通过任务解耦与并行处理，可有效避免单智能体负载过载问题，在工具链式调用场景下，GPT-3.5 等模型展现出优于国产大模型的泛化能力。

针对传统路网生成方法依赖人工规则与静态建模的局限性，本文提出基于扩散模型与 LoRA 微调技术的路网生成框架。通过 MiniCPM-V 2.6 多模态模型实现图像-文本映射，结合 Flux 扩散模型生成高分辨率路网图像。研究创新性地引入结构化编码与拓扑优化算法，将路网连通性转化为六位二进制矩阵，通过 DFS 搜索剔除孤立道路，确保生成路网的强连接性。实验验证表明，经 LoRA 微调的模型在网格化路网生成任务中，图像质量与提示词匹配度显著提升，优化后保持路网连通性。这一方法突破了传统 GIS 建模的时空约束，为城市规划提供了高效、可扩展的自动化工具。

5.2 展望

在未来的研究和应用中，可以将大语言模型应用于更广泛的城市规划和建设领域。在利用大语言模型构造智能体时，传统 AI 应用需要为每个工具或数据源单独开发接口，导致开发成本高昂且效率低下，而最新的 MCP 技术通过标准化工具接口，使大模型能够轻松访问外部资源，避免了不同平台间 API 的不兼容问题，在后续研究中可以融合 MCP 技术来实现智能体的构建。其次针对路网设计的创新思路不仅适用于现

中国知网 https://www.cnki.net

实世界的城市规划，还可以拓展到虚拟世界的构建中。通过用户简单的描述，利用大语言模型的强大生成能力，能够快速生成虚拟城市的路网设计方案。这些方案还可以进一步整合到智能体中，作为其决策和行动的工具，使智能体在虚拟环境中更加高效地完成任务。

中国知网 https://www.cnki.net

参考文献

[1] Zhang S, Fu D, Liang W, et al. Trafficgpt: Viewing, processing and interacting with traffic foundation models [J]. 2024, 150: 95-105.

[2] 张磊,龚永刚,卢祎,等.面向全量认知的城市智慧交通数据赋能平台建设与应用研究[J].汽车与安全,2025,(03):83-87.

[3] DA L, LIOU K, CHEN T, et al. Open-TI: Open traffic intelligence with augmented language model[J]. International Journal of Machine Learning and Cybernetics, 2024, 15(10): 4761-4786.

[4] Chase Harrison. LangChain[EB/OL]. (2022-10-17)[2025-04-05]. https://github.com/lang-chain-ai/langchain.

[5] Wolf T, Debut L, Sanh V, et al. Transformers: State-of-the-art natural language processing; proceedings of the Proceedings of the 2020 conference on empirical methods in natural language processing: system demonstrations, F, 2020 [C].

[6] Kwon W, Li Z, Zhuang S, et al. Efficient memory management for large language model serving with pagedattention; proceedings of the Proceedings of the 29th Symposium on Operating Systems Principles, F, 2023 [C].

[7] Liu,J.LlamaIndex[EB/OL].(2022-11-01)[2025-04-05].https://github.com/jerryjliu/llama_in-dex.

[8] Marcondes F S, Gala A, Magalhães R, et al. Using Ollama[M]//Natural Language Analytics with Generative Large-Language Models: A Practical Approach with Ollama and Open-Source LLMs. Cham: Springer Nature Switzerland, 2025: 23-35.

[9] Ettore Di Giacinto. LocalAI: The free, Open source OpenAI alternative[CP/OL]. [2025-04-05]. https://github.com/go-skynet/LocalAI.

[10] Chase Harrison. LangGraph[EB/OL]. (2024-01-08)[2025-04-05]. https://github.com/lang-chain-ai/langgraph.

[11] Alzubaidi L, Zhang J, Humaidi A J, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions[J]. Journal of big Data, 2021, 8: 1-74.

[12] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.

[13] Han K, Wang Y, Chen H, et al. A survey on vision transformer[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(1): 87-110.

[14] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.

[15] Kingma P D ,Welling M .Auto-Encoding Variational Bayes.[J].CoRR,2013,abs/1312.6114.

[16] Ramesh A, Dhariwal P, Nichol A, et al. Hierarchical text-conditional image generation with clip latents[J]. arXiv preprint arXiv:2204.06125, 2022, 1(2): 3.

[17] Yang L, Zhang Z, Song Y, et al. Diffusion models: A comprehensive survey of methods and applications [J]. 2023, 56(4): 1-39.

中国知网 https://www.cnki.net

[18] Han Z, Gao C, Liu J, et al. Parameter-efficient fine-tuning for large models: A comprehensive survey[J]. arXiv preprint arXiv:2403.14608, 2024.

[19] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[20] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis, MN: Association for Computational Linguistics, 2019: 4171-4186.

[21] Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training[J]. arXiv preprint arXiv:1801.06146, 2018.

[22] Huang X, Liu W W, Chen X L, et al. Understanding the planning of LLM agents: A survey[J]. arXiv preprint arXiv:2402.02716, 2024.

[23] Cheng Y H, Zhang C Y, Zhang Z W, et al. Exploring large language model based intelligent agents: Definitions, methods, and prospects[J]. arXiv preprint arXiv:2401.03428, 2024.

[24] Zhao P Y, Jin Z J, Cheng N. An in-depth survey of large language model-based artificial intelligence agents[J]. arXiv preprint arXiv:2309.14365, 2023.

[25] Zhang Z, Bo X, Ma C, et al. A survey on the memory mechanism of large language model based agents[J]. arXiv preprint arXiv:2404.13501, 2024.

[26] 袁嵩,程芬,程鹏飞,等.基于 LLM 与多智能体协同的医疗对话机制研究[J/OL].计算机技术与发展,1-11[2025-04-06].https://doi.org/10.20165/j.cnki.ISSN1673-629X.2025.0076.

[27] 王一,曹秀丽,周建芳.基于大语言模型的图书馆知识服务智能体设计研究[J/OL].四川图书馆学报,1-10[2025-04-06].http://kns.cnki.net/kcms/detail/51.1073.g2.20250321.1728.002.html.

[28] 王路桥,周洋涛,李青山,等.基于大语言模型的多智能体协作代码评审人推荐[J/OL].软件学报,1-18[2025-04-06].https://doi.org/10.13328/j.cnki.jos.007326.

[29] 姜嘉伟.基于 Langchain-LLMs 框架的智能问答系统的设计与实现[D].延边大学,2024.DOI:10.27439/d.cnki.gybdu.2024.000002.

[30] Parish Y I H, Müller P. Procedural modeling of cities[C]//Proceedings of the 28th annual conference on Computer graphics and interactive techniques. 2001: 301-308.

[31] Chen G ,Esch G ,Wonka P , et al.Interactive procedural street modeling[J].ACM Transactions on Graphics (TOG),2008,27(3):1-10.

[32] Garcia-Dorado I, G. Aliaga D, V. Ukkusuri S. Designing large-scale interactive traffic animations for urban modeling[C]//Computer Graphics Forum. 2014, 33(2): 411-420.

[33] Sun J, Yu X, Baciu G, et al. Template-based generation of road networks for virtual city modeling[C]//Proceedings of the ACM symposium on Virtual reality software and technology. 2002: 33-40.

[34] Aliaga D G, Vanegas C A, Benes B. Interactive example-based urban layout synthesis[J]. ACM transactions on graphics (TOG), 2008, 27(5): 1-10.

[35] Wilkie D, Sewall J, Lin M C. Transforming GIS data into functional road models for large-scale traffic simulation[J]. IEEE transactions on visualization and computer graphics, 2011, 18(6): 890-901.

中国知网 https://www.cnki.net

[36] Karagiorgou S, Pfoser D, Skoutas D. Segmentation-based road network construction[C]//Proceedings of the 21st ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2013: 460-463.

[37] 张令涛.基于改进神经网络算法的大规模路网交通流短时预测[J].吉林大学学报(信息科学版),2025,43(02):432-438.DOI:10.19292/j.cnki.jdxxp.2025.02.021.

[38] 何前松,余小凤,陈建育,等.一种基于 AGCN-BiLSTM 模型的交通流量预测[J].中国科技信息,2025,(06):108-111.

[39] 张云菲,陈涛.基于网眼分割的轨迹数据增量式路网更新方法[J/OL].交通科学与工程,1-11[2025-05-29].https://doi.org/10.16544/j.cnki.cn43-1494/u.20241129001.

[40] 赖树坤,许宏科,林杉,等.基于车辆轨迹信息的高速公路路网拓扑结构动态生成方法研究[J].交通运输系统工程与信息,2025,25(01):212-220.DOI:10.16097/j.cnki.1009-6744.2025.01.020.

[41] Galin E, Peytavie A, Maréchal N, et al. Procedural generation of roads[C]//Computer Graphics Forum. Oxford, UK: Blackwell Publishing Ltd, 2010, 29(2): 429-438.

[42] Jepsen T S, Jensen C S, Nielsen T D. Relational fusion networks: Graph convolutional networks for road networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(1): 418-429.

[43] Hartmann S, Weinmann M, Wessel R, et al. Streetgan: Towards road network synthesis with generative adversarial networks[J]. 2017.

[44] Greff K, Srivastava R K, Koutník J, et al. LSTM: A search space odyssey[J]. IEEE transactions on neural networks and learning systems, 2016, 28(10): 2222-2232.

[45] Dey R, Salem F M. Gate-variants of gated recurrent unit (GRU) neural networks[C]//2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS). IEEE, 2017: 1597-1600.

[46] 洪季芳.Transformer 研究现状综述[J].信息系统工程,2022,(02):125-128.

[47] 史童月,王中卿.基于 Transformer 的自然语言处理预训练语言模型概述[J].信息与电脑(理论版),2022,34(10):52-56.

[48] Xi Z H, Chen W, Zhang X, et al. The rise and potential of large language model based agents: A survey[J]. Science China Information Sciences, 2025, 68(2): 121101.

[49] Yao S, Zhao J, Yu D, et al. React: Synergizing reasoning and acting in language models[C]//International Conference on Learning Representations (ICLR). 2023.

[50] Liu W, Huang X, Zeng X, et al. Toolace: Winning the points of llm function calling[J]. arXiv preprint arXiv:2409.00920, 2024.

[51] Kim S, Moon S, Tabrizi R, et al. An llm compiler for parallel function calling[C]//Forty-first International Conference on Machine Learning. 2024.

[52] Hao S, Liu T, Wang Z, et al. Toolkengpt: Augmenting frozen language models with massive tools via tool embeddings[J]. Advances in neural information processing systems, 2023, 36: 45870-45894.

[53] Sohl-Dickstein J, Weiss E, Maheswaranathan N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//International conference on machine learning. pmlr, 2015: 2256-2265.

[54] Du Y L, Mordatch I. Implicit generation and modeling with energy based models[C]//Advances in Neural Information Processing Systems 32. Vancouver, Canada: NeurIPS, 2019: 3608-3618.

中国知网 https://www.cnki.net

[55] Kobyzev I, Prince S J D, Brubaker M A. Normalizing flows: An introduction and review of current methods[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43(11): 3964-3979..

[56] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.

[57] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10684-10695.

[58] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.

[59] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer international publishing, 2015: 234-241.

[60] Black Forest Labs. flux[EB/OL]. : , 2024[2025-04-05]. https://github.com/black-forest-labs/flux.

[61] Kwon D H. Analysis of prompt elements and use cases in image-generating AI: Focusing on Midjourney, Stable Diffusion, Firefly, DALL· E[J]. Journal of Digital Contents Society, 2024, 25(2): 341-354.

[62] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. ICLR, 2022, 1(2): 3.

[63] 高德地图开放平台.开发|高德地图 API[EB/OL]. (2024-12-27)[2025-04-05]. https://lbs.amap.com/api

[64] 百度智能云, 千帆. 大模型 AI 原生应用开发平台-百度智能云千帆 AppBuilder[EB/OL]. (2023-05-20)[2025-04-05]. https://qianfan.cloud.baidu.com/appbuilder/

[65] comfyanonymous. ComfyUI: The most powerful and modular diffusion model GUI, api and backend with a graph/nodes interface[EB/OL]. (2024-08-15)[2025-04-05]. https://github.com/comfyanonymous/ComfyUI

[66] Hu S a T, Yuge and Han, Xu and He, Chaoqun and Cui, Ganqu and Long, Xiang and Zheng, Zhi and Fang, Yewei and Huang, Yuxiang and Zhao, Weilin and others. MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies [J]. arXiv preprint arXiv:240406395, 2024.

[67] Zhong W, Cui R, Guo Y, et al. Agieval: A human-centric benchmark for evaluating foundation models[J]. arXiv preprint arXiv:2304.06364, 2023.

[68] Mishchenko K, Defazio A. Prodigy: An expeditiously adaptive parameter-free learner[J]. arXiv preprint arXiv:2306.06101, 2023.

中国知网 https://www.cnki.net

學而知不足 楊振宇

中国知网 https://www.cnki.net