计算机科学与探索
Journal of Frontiers of Computer Science and Technology
1673-9418/2026/20(01)-0001-20
doi: 10.3778/j.issn.1673-9418.2504069

大语言模型压缩综述

郭晋阳[1,2],贺昌义[1],杨　戈[1,2],刘祥龙[1+]
1. 北京航空航天大学 复杂关键软件环境全国重点实验室,北京 100191
2. 北京航空航天大学 人工智能学院,北京 100191
+ 通信作者 E-mail: xlliu@buaa.edu.cn

摘　要:大语言模型由于强大的认知能力,在多个领域得到了广泛应用,成为人工智能领域的研究热点。然而,大语言模型对计算、存储资源的巨大需求,使其难以在资源受限的情境下使用。模型压缩与加速技术成为解决这一问题的关键手段,旨在保持模型性能的前提下,降低计算复杂度和存储成本。基于此,对大语言模型压缩与加速技术的前沿研究进行了全面的综述,旨在把握整个领域的发展现状与未来趋势,推动大语言模型压缩与加速技术的发展,助力其在工业界和学术界的应用落地。系统阐述了大语言模型在计算资源和存储成本方面面临的挑战;从模型剪枝、模型量化、知识蒸馏、低秩分解四个关键技术路径出发,梳理了各类方法的基本原理、典型方法和最新进展,并对主流技术进行了系统对比与总结。从推理效率、精度保持、部署难度等多个维度构建了评价体系,深入探讨了大语言模型压缩的评估指标和实验基准。最后,结合当前技术瓶颈,展望了大语言模型压缩的未来研究方向,为后续相关研究与工程实践提供了系统性参考。

关键词:人工智能;大语言模型;模型压缩与加速
文献标志码:A　　**中图分类号:**TP391

Survey of Model Compression for Large Language Model

GUO Jinyang[1,2], HE Changyi[1], YANG Ge[1,2], LIU Xianglong[1+]
1. State Key Laboratory of Complex and Critical Software Environment, Beihang University, Beijing 100191, China
2. School of Artificial Intelligence, Beihang University, Beijing 100191, China

Abstract: Large language models (LLMs) have attracted considerable attention in recent years due to their strong cognitive capabilities and widespread applications in various fields. However, their tremendous demand for computation and memory makes it difficult to deploy them in resource-constrained scenarios. Model compression and acceleration techniques have thus emerged as critical approaches to reduce computational complexity and memory usage while maintaining model performance. This paper presents a comprehensive survey of recent advances in LLM compression and acceleration methods, aiming to grasp the current development status and future trends of the entire field, promote the advancement of LLM compression and acceleration technologies, and facilitate their application and implementation in both industry and academia. It begins by outlining the challenges LLMs face in terms of computational and storage overhead. Then, it categorizes and reviews the main technical approaches, including model pruning, quantization, knowledge distillation, and low-rank decomposition, highlighting their core principles, representative methods, and cutting-edge developments. In addition, the paper provides a detailed discussion on evaluation metrics such as inference latency, accuracy retention, and deployment cost, establishing a multidimensional evaluation framework. Finally, it explores the promising future directions of LLM compression methods, aiming to guide future research and industrial deployment of compressed LLMs.

Key words: artificial intelligence; large language model; model compression and acceleration

基金项目:北京市科技计划项目(Z231100010323002);国家自然科学基金(62306025, 92367204);CCF-百度松果基金。
This work was supported by the Beijing Municipal Science and Technology Project (Z231100010323002), the National Natural Science Foundation of China (62306025, 92367204), and the CCF-Baidu Open Fund.
收稿日期:2025-04-22　　**修回日期:**2025-07-21

中国知网 https://www.cnki.net

人工智能技术引领着新一轮科技革命和产业变革，已成为各国科技竞争的核心领域，争夺战略制高点的关键手段。其中，大语言模型（large language model，LLM）因强大的智能能力，近年来备受关注。通过大规模预训练，大语言模型展现出卓越的性能，在公共安全、经济和国防等领域具有重要作用[1]。例如，2018年推出的基于Transformer架构的GPT大语言模型[2]，通过生成预训练显著提高了语言理解能力；2020年发布的GPT-3[3]进一步展现了其在多个自然语言处理任务上的卓越表现，甚至在某些任务上超越了人类水平；2022年，由OpenAI发布的ChatGPT[4]具备了出色的自然语言生成能力，得到了公众的广泛关注；近期，由我国深度求索公司研发的DeepSeek-V3[5]模型，在多项自然语言处理任务中表现出色，进一步推动了人工智能的发展。然而，由于算力和内存等资源限制，大语言模型的部署场景受到很大限制。例如，训练OPT-175B模型[6]需要992个80 GB A100 GPU，每个GPU的利用率高达147 TFLOP/s，而当前最先进的手机芯片GPU性能则不足3 TFLOP/s。因此，近年来大语言模型的压缩与加速技术受到广泛关注，以期在有限的资源条件下实现更高效的部署和应用。

为了解决这一问题，近年来针对大语言模型的模型压缩与加速方法层出不穷，逐步减少了大语言模型在使用时的资源消耗，从而拓宽了其应用场景。大语言模型的压缩与加速方法主要包括模型剪枝、模型量化、知识蒸馏和低秩分解等。例如，Frantar等人[7]提出了首个针对大语言模型的剪枝方法SparseGPT，有效减少了模型规模；GPTQ[8]对大语言模型进行了有效的量化操作；Gu等人[9]提出了MiniLLM，这是第一个针对大语言模型的知识蒸馏方法。尽管这些方法在压缩和加速LLM方面取得了显著进展，但学术界对相关技术的综述性研究仍然相对滞后。在此背景下，为了系统全面地梳理大语言模型压缩与加速方法的发展脉络，并进一步支持和推动大语言模型领域的发展，本文开展了针对大语言模型压缩与加速方法的系统综述。对该领域的发展现状和未来趋势进行了详细的讨论，旨在为研究人员提供参考和启示。

1 研究背景

自2017年Transformer模型被提出以来，该架构迅速成为自然语言处理（natural language processing，NLP）的主流范式。随着算力的提升和数据规模的增长，研究者进一步扩展了Transformer的规模。2022年，OpenAI发布了ChatGPT，大语言模型便成为了研究热点，吸引了学术界和工业界的广泛关注。这一章简要介绍关于Transformer、大语言模型、模型压缩和大语言模型压缩应用场景的研究背景。

1.1 Transformer模型

目前主流的LLM都采用了Transformer架构。Transformer最早在论文*Attention Is All You Need*[10]中被提出，被应用于机器翻译领域，随后成为自然语言处理（NLP）领域最为流行的模型之一。Transformer的基本结构包括编码器（encoder）和解码器（decoder）两部分。每个编码器和解码器又分别由注意力层和前馈神经网络组成。

注意力（attention）机制是Transformer中的主要组成部分。注意力层接收一个特征序列作为输入，对于输入序列中的每个特征，首先利用线性函数将其分别映射为查询（query，Q）、键（key，K）和值（value，V）向量，然后将单个 $\boldsymbol{Q}$ 向量与一组 $\boldsymbol{KV}$ 向量映射得到输出，其中输出为 $\boldsymbol{V}$ 向量的加权和，每个 $\boldsymbol{V}$ 向量的权重为 $\boldsymbol{Q}$ 向量和对应 $\boldsymbol{K}$ 向量的缩放点积（scaled-dot production），计算公式如下所示：

$$\mathrm{Attention}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V})=\mathrm{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\mathrm{T}}}{\sqrt{d_k}}\right)\boldsymbol{V}$$

其中，$\sqrt{d_k}$ 为缩放因子。

尽管Transformer模型在自然语言处理领域取得了显著的成果，但其在计算复杂性方面存在很大的缺陷。Transformer的主要组成部分是注意力机制，而注意力计算的时间复杂度和空间复杂度均为 $O(n^2)$，其中 n 代表序列长度。这意味着当序列长度增加时，注意力计算的开销会呈现平方级增长。这导致Transformer模型的训练和推理对计算资源的消耗极大，限制了Transformer模型在资源受限场景下的应用。

1.2 大语言模型

随着Transformer的成功，越来越多的语言模型被提出，模型的参数规模也不断增加。大语言模型（LLM）通常是指基于Transformer的参数规模达到数十亿甚至更多的语言模型。近年来，LLM呈蓬勃发展之势，海内外众多科研机构都投身于LLM的研究。例如，国际上有OpenAI的GPT系列（GPT3[3]、ChatGPT[4]、GPT4[11]），Google的PaLM[12]、PaLM2[13]、Gemini[14]，Meta的LLaMA系列（LLaMA[15]、LLaMA2[16]、LLaMA3[17]）等；国内有智谱清言的ChatGLM[18]，阿里云的Qwen[19]，深度求索的DeepSeek[5]等。LLM与以往的小型语言模型之间除了最直观的参数规模的差异外，其训练所用的数据量也远超小型语言模型，LLM使用了互联网上不同来源的海量数据进行训练，覆盖了各种领域的知识。此外，在功能方面，不同于传统的针对特定任务训练的语言模型，

中国知网 https://www.cnki.net

LLM具有更强的泛化能力，能够应用于文本生成、文本分类等各种NLP任务。

虽然LLM引领着人工智能的新浪潮，但其卓越能力是以巨大的资源需求为代价的。以Meta的LLaMA3模型为例，其中最大的700亿参数版本在训练过程中消耗了超过7.7百万GPU小时，显存需求高达数百GB。这些资源需求不仅体现在预训练阶段，还延伸至推理阶段。这种资源密集特性使得LLM的部署和应用成本极高，尤其是在移动设备或边缘计算场景等资源受限的环境中。因此，研究大语言模型的压缩方法是十分必要的。

1.3 模型压缩

21世纪初，随着硬件的发展、计算能力的提升，浅层神经网络的不足逐渐显露出来，研究人员开始将目光聚焦在深度神经网络上。近年来，随着深度神经网络的迅速发展，硬件的更新速度难以匹配复杂模型所需要的计算和存储资源的增长速度，这导致深度神经网络难以在实际应用中进行部署。为解决这一问题，模型压缩方向的研究便应运而生。

目前，模型压缩方法可大致分为模型剪枝、模型量化、知识蒸馏和低秩分解四种方法。模型剪枝技术通过识别并剪除深度神经网络中的冗余成分来减小模型的规模与计算复杂度，实现了模型压缩与加速。模型量化旨在将原本使用高精度浮点数（如FP32）表示的模型参数和激活值量化为较低比特位（如INT8、INT4等）的定点数表示，从而减小模型大小和计算量。知识蒸馏的核心思想是利用一个较大的教师模型指导一个较小的学生模型学习，使学生模型在参数量较小的情况下达到与教师模型相近的性能水平。低秩分解的目的是将原始的参数矩阵拆解为两个或多个矩阵的乘积，从而减少参数量和计算量。

1.4 大语言模型压缩应用场景

近年来，随着大语言模型在自然语言处理、知识问答、对话系统、代码生成等任务中展现出强大的能力，其在各类产业场景中的部署需求迅速增长。然而，这些模型通常拥有数十亿甚至上千亿的参数，训练与推理成本极高，严重制约了其在资源受限环境中的广泛应用。因此，如何在保持模型性能的同时降低计算与存储开销，成为当前学术界与工业界共同关注的关键问题。模型压缩作为解决这一挑战的重要技术路径，近年来在多个典型应用场景中得到了深入研究与实际落地：

（1）边缘设备推理：在物联网、移动终端和智能机器人等边缘计算场景中，设备普遍面临算力有限、功耗敏感和内存受限的问题，传统的百亿参数级LLM难以直接部署。通过剪枝、量化等技术，研究者可以将大型模型压缩为适配低功耗芯片的小模型。例如，有研究表明，结合4 bit量化和矩阵乘法优化，可在Android设备与Raspberry Pi等低功耗平台上实现2倍以上的推理加速，支持边缘侧LLM的本地部署。随着模型压缩与硬件协同设计的不断推进，未来LLM有望嵌入至智能车载系统、智能穿戴设备等更加微型化的终端中。

（2）工业实时推理：在金融风控、在线客服、搜索推荐等高并发、低延迟的实时系统中，模型的响应速度直接影响用户体验与系统吞吐量。压缩后的模型不仅显著降低了推理延迟，还能减轻对高端服务器资源的依赖，使得在中低端GPU甚至CPU集群上部署成为可能。

（3）多模型并行部署场景：在A/B测试、个性化问答系统、医疗与法律等对话应用中，往往需要同时运行多个模型副本，分别服务于不同的用户群体或任务需求。此类场景对模型体积和部署密度提出了更高要求。模型压缩技术通过减小每个模型的体积与计算成本，显著提升了系统的并行能力与可扩展性。

（4）低资源环境中的知识迁移：在教育、农业、法律等垂直行业，存在领域数据有限、算力受限、模型部署成本高等诸多困难，难以直接引入主流大模型。知识蒸馏技术可将通用LLM的知识迁移至小模型，从而实现定制化、轻量级的下游模型。

模型压缩不仅是提高大语言模型效率的关键路径，更是推动其广泛应用于工业界与边缘环境的核心技术。随着LLM从“研究模型”向“部署模型”过渡，模型压缩的应用价值和研究热度将持续上升。基于此，本综述旨在系统梳理当前大语言模型压缩领域的发展现状与关键技术路径，剖析其在实际应用中的典型挑战与解决策略，进而为今后的研究与工程部署提供参考框架与方法指导，推动大模型技术更加高效、公平地服务于千行百业。

2 大语言模型压缩技术

大语言模型压缩方法可大致分为模型剪枝、模型量化、知识蒸馏以及低秩分解。目前各种针对大语言模型的压缩方法依旧层出不穷，本文针对现有大语言模型压缩方法进行了梳理，具体方法及分类如图1所示。

2.1 模型剪枝

剪枝方法旨在通过移除模型中冗余的参数来压缩模型。根据剪枝粒度的不同，可以将剪枝分为非结构化剪枝（unstructured pruning）、结构化剪枝（structured pruning）和半结构化剪枝（semi-structured pruning）。不同粒度的剪枝方法分类如图2所示。

中国知网 https://www.cnki.net

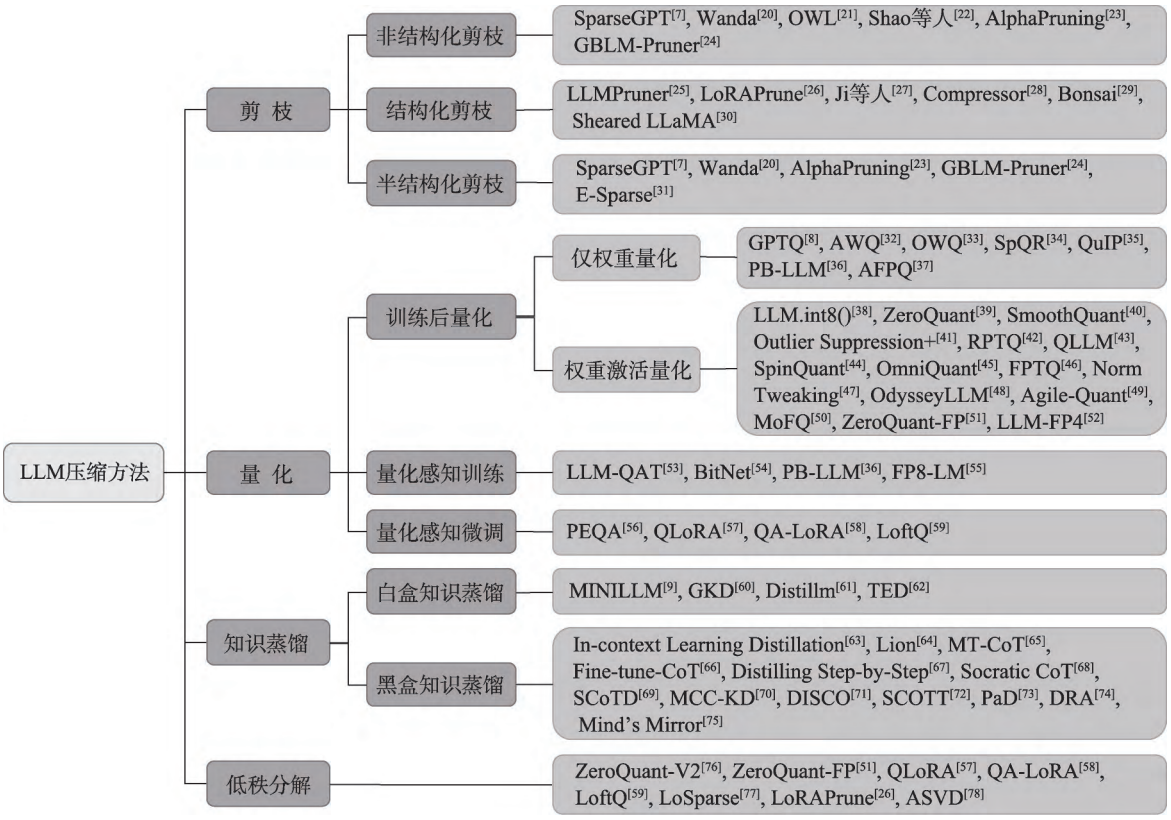

图1 大语言模型压缩方法分类

Fig.1 Taxonomy of compression methods for LLM

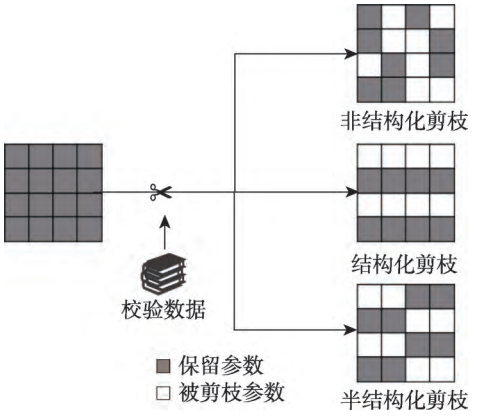

图2 大语言模型剪枝方法分类示意图

Fig.2 Illustration of pruning methods for LLM

2.1.1 非结构化剪枝

非结构化剪枝是一种通过移除模型中的单个权重来实现网络稀疏化的技术，其主要目的是通过将不重要的权重置零并跳过计算，来加速网络的推理过程，并减少存储需求。然而，对于大语言模型，这种方法在保持高性能的同时面临着显著的挑战，尤其是在如何有效执行剪枝、避免性能损失和降低计算负担等方面。为了解决这些问题，研究者提出了多种创新的方法，其中大多数工作都围绕如何减少剪枝过程中的计算和存储开销，尤其是在无需大规模重训练的情况下。

一般情况下，剪枝方法通常需要对压缩后的模型进行再训练，以恢复模型性能。然而，对于参数规模达数十亿的大语言模型而言，这种再训练过程将带来巨大的计算负担。为了解决此问题，Frantar等人[7]提出了首个专门针对大语言模型的剪枝方法SparseGPT。SparseGPT是一种无需重训练的一次剪枝方法，通过将剪枝问题转化为一个超大规模的稀疏回归问题，使用一个近似的稀疏回归求解器来求解。具体而言，SparseGPT包括掩码选择和权重重建两部分，首先基于最优脑手术（optimal brain surgeon，OBS）方法重构误差选择剪枝掩膜，然后利用OBS方法对未剪枝的权重进行优化，重构剪枝模型以补偿剪枝后的权重。SparseGPT算法伪代码如算法1所示。此外，作者发现越大的模型越容易被剪枝，即在固定的稀疏率下，规模更大的模型剪枝后的精度损失更小。SparseGPT实现了显著的非结构化稀疏性，可以在开源的大语言模型OPT-175B和BLOOM-176B上达到60%的稀疏率，并且几乎没有性能损失。

算法1 SparseGPT[7]算法

输入：权重 $\boldsymbol{W}$，逆海森矩阵 $\boldsymbol{H}^{-1}$，块大小 B。

输出：剪枝后权重 $\boldsymbol{W}$。

$\boldsymbol{M} \leftarrow \mathbf{1}_{d_{\text{row}} \times d_{\text{col}}}$ //剪枝掩码

中国知网 https://www.cnki.net

$\boldsymbol{E} \leftarrow \boldsymbol{0}_{d_{row} \times B}$ //块剪枝误差

$\boldsymbol{H}^{-1} \leftarrow \text{Cholesky}(\boldsymbol{H}^{-1})^{\mathrm{T}}$ //海森逆信息

for $i = 0, B, 2B, \cdots$ do

  for $j = i, \cdots, i + B - 1$ do

    if $j \bmod B_s = 0$ then

      $\boldsymbol{M}_{:,j:(j+B_s)} \leftarrow$ mask of $(1-p)\%$ weights $w_c \in$

      $\boldsymbol{W}_{:,j:(j+B_s)}$ with largest $w_c^2 / [\boldsymbol{H}^{-1}]_{cc}^2$

    end if

    $\boldsymbol{E}_{:,j-i} \leftarrow \boldsymbol{W}_{:,j} / [\boldsymbol{H}^{-1}]_{jj}$ //剪枝误差

    $\boldsymbol{E}_{:,j-i} \leftarrow (1 - \boldsymbol{M}_{:,j}) \cdot \boldsymbol{E}_{:,j-i}$ //冻结权重

    $\boldsymbol{W}_{:,j:(i+B)} \leftarrow \boldsymbol{W}_{:,j:(i+B)} - \boldsymbol{E}_{:,j-i} \cdot \boldsymbol{H}^{-1}_{j,j:(i+B)}$

  end for

  $\boldsymbol{W}_{:,(i+B)} \leftarrow \boldsymbol{W}_{:,(i+B):} - \boldsymbol{E} \cdot \boldsymbol{H}^{-1}_{i:(i+B),(i+B):}$

end for

$\boldsymbol{W} \leftarrow \boldsymbol{W} \cdot \boldsymbol{M}$ //剪枝权重置零

Sun等人[20]考虑到大语言模型中的离群值（outlier）对剪枝效果的影响，引入了一种同时考虑权重和激活的剪枝方法Wanda。具体来说，Wanda首先利用一个小的校准数据集来得到网络中的激活值，并根据权重大小和激活值L2范数的乘积来评估参数的重要性，然后利用该度量在每个线性层内进行比较，移除优先级较低的权重。Wanda的算法示意图如图3所示[20]。与SparseGPT[7]相比，Wanda无需模型重构，具有较小的计算代价且达到了与SparseGPT相媲美的性能。该工作从新的视角考虑了大模型压缩的核心问题，为参数重要性估计研究中加入了重要的新因素。

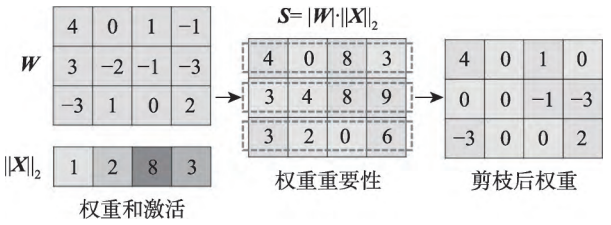

图3 Wanda算法示意图

Fig.3 Illustration of Wanda

Wanda[20]的有效性与大语言模型中离群特征的出现有关，这些离群特征往往显著大于一般特征，对优化大语言模型的性能至关重要。受此启发，Yin等人[21]对离群点进行了深入分析，发现了离群点在不同层之间的不均匀分布。基于此作者提出了一种离群值加权逐层稀疏方法（outlier weighed layerwise sparsity，OWL），该剪枝方法将稀疏率与每层的离群率对齐，采用了非均匀的逐层稀疏率，以更多关注离群点出现较多的层，在高稀疏水平下表现出显著的性能增益。该工作进一步阐明了模型压缩中离群特征的重要性。

随后，Shao等人[22]提出了一种Hessian敏感性感知的混合稀疏剪枝方法，利用Hessian矩阵来评估大语言模型每一层的敏感度，并根据敏感度自适应地分配稀疏率，最大程度减小剪枝带来的误差。

已有的层级剪枝方法多基于启发式策略，难以实现最优剪枝方案。针对这一问题，Lu等人[23]提出AlphaPruning，基于重尾自正则化（heavy-tail self-regularization，HT-SR）理论，通过分析权重矩阵的经验谱密度形态，采用线性映射函数分配剪枝比率，使训练充分的层保留更多参数，而训练不足的层承受更高的剪枝比率。该方法可无缝集成至现有剪枝技术，如SparseGPT[7]和Wanda[20]，实现更高剪枝率的同时保持较低困惑度，显著提升零样本任务性能。

此外，Das等人[24]探索了梯度信息在大语言模型剪枝中的作用，提出了一种新的基于梯度的剪枝方法GBLM-Pruner（gradient-based language model pruner）。该方法通过从少量校准数据集中获得归一化的梯度来确定剪枝的重要性分数，以无需训练的方式实现了非结构化稀疏。

尽管非结构化剪枝方法能够实现显著的压缩效果并减少计算负担，但生成的稀疏模型通常是非结构化的，因此无法充分利用现代硬件加速器的并行计算能力，导致推理效率较低。如何在非结构化剪枝和硬件加速器的计算优化之间取得平衡，仍然是该领域亟待解决的挑战。

2.1.2 结构化剪枝

与非结构化剪枝不同，结构化剪枝通过移除整个结构组件（如神经元、通道、层等）来实现模型稀疏化。由于剪枝的单位较大，结构化剪枝能够在硬件上获得更显著的推理加速效果，且无需特殊硬件支持，因此在实际应用中具有较大的潜力。然而，结构化剪枝也面临着一些独特的挑战，包括如何保证剪枝后模型性能以及如何高效地进行模型结构的选择和调整。

Ma等人[25]提出了首个针对大语言模型的结构化剪枝方法LLMPruner。与传统的针对特定领域或特定任务的压缩方法不同，LLMPruner旨在保留大语言模型通用任务求解能力的同时减小其大小，即一种任务无关的压缩。作者提出了一种依赖关系检测算法，用来识别模型中的耦合结构；然后采用了一种考虑一阶信息和近似Hessian信息的重要性估计方法，对耦合结构进行裁剪；最后利用低秩自适应（low-rank adaptation，LoRA）方法对剪枝后的模型进行快速恢复。该方法在三个大语言模型LLaMA-7B、Vicuna-7B和ChatGLM-6B上进行了

中国知网 https://www.cnki.net

性能验证，即使去除20%的参数，剪枝后的模型仍能保持原始模型90%以上的性能。LLMPruner开创性地在任务无关的情况下实现了大语言模型的结构化剪枝，扩展了大语言模型剪枝研究的新视角。

在此基础上，Zhang等人[26]提出了一种结合参数高效微调和结构化剪枝的压缩框架LoRAPrune。作者首先设计了一种LoRA引导的剪枝准则，使用LoRA的权重和梯度对参数进行重要性估计；然后基于该准则进行迭代的结构化剪枝，计算每一批次的重要性并利用移动平均法来更新，每隔几次迭代移除一部分不重要的结构化权重，直到达到目标稀疏率。

为进一步优化结构化剪枝的过程，Ji等人[27]将神经网络搜索（neural architecture search，NAS）和结构化剪枝相结合，提出了一种基于精度预测器的结构化剪枝方法。作者首先构建数百个模型架构与精度对的训练集，然后训练一个非神经网络模型作为精度预测器，利用该精度预测器进一步优化搜索空间和搜索过程，以自动识别最优剪枝模型。

Guo等人[28]提出一种基于训练的LLM剪枝方法Compresso。该方法利用可学习的二进制掩码来决定是否修建LLM中的每个子模块，然后利用L0正则化优化剪枝掩码，并将LoRA融入L0正则化中，解决了昂贵的训练成本的挑战。此外该方法还有一大创新性在于，不同于先前方法在剪枝过程中将LLM视为一个被剪枝的被动角色，该方法将LLM提升为与剪枝算法协作的对等角色。作者引入了一个协同剪枝提示，该提示解释了剪枝的概念和目的，并告知LLM正在进行剪枝，鼓励LLM更好地适应剪枝过程。通过引入这种信息提示，Compresso旨在增强LLM在剪枝过程中的理解和合作，从而提高性能并适应修改后的模型结构。消融实验表明，这种协同剪枝的方式具有一定的有效性。

针对现有的剪枝方法资源消耗昂贵的问题，Dery等人[29]提出了一种仅依赖前向传递的结构化剪枝方法Bonsai。该方法的核心创新是通过前向传递评估子模型的性能，而无需进行梯度计算。在剪枝过程中，Bonsai利用扰动生成子模型并评估其表现，进而估算每个模块的相关性，从而决定要剪枝的模块。与现有的基于梯度的剪枝方法（如LLM-Pruner、LoRAPrune）相比，Bonsai不仅显著降低了内存使用，还在推理速度上获得了更好的提升。

大多数结构化剪枝方法没有指定模型剪枝后的目标结构，可能会造成一些非常规的模型结构，为此Xia等人[30]提出了一种定向结构剪枝方法Sheared LLaMA。与传统的利用L0正则化直接优化剪枝掩码的方法不同，Sheared LLaMA指定了模型剪枝后的目标结构，通过端到端的方式移除层、注意力头和中间隐藏维度，将LLM剪枝到指定的目标结构，在保持给定约束的同时最大限度地保持性能。

总体而言，结构化剪枝方法通过移除大规模结构组件来减小模型的规模，能够在硬件上获得显著的加速效果，且相比非结构化剪枝更适用于实际应用中的推理加速。然而，结构化剪枝的粗粒度削减往往会带来较大的性能损失，如何在剪枝后有效恢复性能，保持较高的精度和推理效率，仍然是该领域面临的重要挑战。未来的研究可以进一步探索在大规模模型中如何结合多种优化策略，实现在模型压缩的同时尽可能减少性能损失。

2.1.3 半结构化剪枝

非结构化剪枝通过移除模型中的单个权重来稀疏模型，而结构化剪枝通过移除模型中整个结构组件（如神经元、通道、层等）来稀疏模型，即直接移除整组权重。半结构化剪枝是一种介于非结构化剪枝和结构化剪枝之间的稀疏方法，通常表示为$N:M$稀疏，表示在每M个连续权重中至多保留N个权重。半结构化剪枝利用了非结构化和结构化方式的优点，兼具一定的模型结构信息与更多的自由度，提供了一种灵活的模型压缩策略。

一些大语言模型的非结构化剪枝方法可以扩展至$N:M$稀疏，如SparseGPT[7]、Wanda[20]、AlphaPruning[23]和GBLM-Pruner[24]都可以实现2∶4和4∶8稀疏。在此基础上，Li等人[31]提出了一种专门针对$N:M$稀疏的基于熵的剪枝方法E-Sparse。作者首先发现大语言模型通道间的信息丰富程度存在显著差异，因此提出了一种基于信息熵的度量来评估参数的重要性。此外作者还发现通道间的信息分布往往高度集中，可能会对精度造成影响。基于此作者提出了通道重排机制，包括全局朴素重排和局部块内重排，使信息分布更加均匀，有助于在信息丰富的通道中保留更多的权重，减轻$N:M$对精度的影响。

半结构化剪枝在每M个权重中保留了N个权重，因此产生的压缩后模型仍具有结构化的特性，能够实现较好的加速效果。目前英伟达较新型号的GPU已经支持半结构化剪枝的实际加速。然而由于其结构不如结构化剪枝产生的压缩模型齐整，加速效果相比于结构化剪枝仍存在一定差距。

2.1.4 小结

本小节系统地介绍了大语言模型剪枝方法的最新进展。表1对比了现有大语言模型剪枝方法的主要区别。模型剪枝方法目前仍为压缩大语言模型的最有效方法之一，因此备受关注。

模型剪枝技术作为压缩大语言模型的主要手段之

中国知网 https://www.cnki.net

表1 LLM剪枝方法总结

Table 1 Summary of LLM pruning methods

方法	剪枝类型	剪枝依据	迭代/一次	剪枝后微调	全局/局部
SparseGPT[7]	非结构化剪枝	重构损失	一次剪枝	×	局部剪枝
Wanda[20]	非结构化剪枝	权重激活乘积	一次剪枝	×	局部剪枝
OWL[21]	非结构化剪枝	逐层离群率	一次剪枝	×	局部剪枝
Shao等人[22]	非结构化剪枝	Hessian敏感性	一次剪枝	×	局部剪枝
AlphaPruning[23]	非结构化剪枝	经验谱密度	一次剪枝	×	局部剪枝
GBLM-Pruner[24]	非结构化剪枝	归一化梯度	一次剪枝	×	局部剪枝
LLMPruner[25]	结构化剪枝	一阶信息和近似的Hessian信息	一次剪枝	√	全局剪枝
LoRAPrune[26]	结构化剪枝	LoRA梯度	迭代剪枝	√	局部剪枝
Ji等人[27]	结构化剪枝	一阶信息	一次剪枝	√	局部剪枝
Compressor[28]	结构化剪枝	L0正则化	迭代剪枝	√	全局剪枝
Bonsai[29]	结构化剪枝	模块相关性	迭代剪枝	√	全局剪枝
Sheared LLaMA[30]	结构化剪枝	L0正则化	一次剪枝	√	全局剪枝
E-Sparse[31]	半结构化剪枝	信息熵	一次剪枝	×	局部剪枝

一，主要分为非结构化剪枝、结构化剪枝和半结构化剪枝三种类型，各自具有不同的优势和应用场景。非结构化剪枝通过移除网络中的单个权重实现稀疏性，具有较高的灵活性和压缩率，但其剪枝后的模型结构较为不规则，难以在硬件上实现显著的推理加速效果。相比之下，结构化剪枝通过移除神经元、通道或层等更大的结构单元来压缩模型，生成的模型具有规则的稀疏性，易于在硬件上实现加速。尽管结构化剪枝的剪枝粒度较粗，灵活性较低，但在实际部署中其推理速度更快，适合需要高效推理的应用场景，例如边缘计算和移动设备上的推理任务。半结构化剪枝则结合了非结构化剪枝和结构化剪枝的优点，通过在每组权重中保留部分参数来实现稀疏化，兼具一定的灵活性和结构化稀疏性。虽然半结构化剪枝的压缩率和加速效果介于两者之间，但由于半结构化剪枝保留了模型的部分结构特征，使其在硬件加速器上能够获得一定程度的推理加速，适合需要在精度和推理速度之间取得平衡的场景。未来，随着硬件支持的不断进步，剪枝方法将更加注重剪枝后模型的实际推理效率。此外，剪枝技术与其他压缩方法（如量化、知识蒸馏）的结合也有望进一步提高模型压缩的效率和效果，使得大语言模型能够在更多资源受限的场景中得到应用。

2.2 模型量化

模型量化方法旨在将模型中32位浮点数表示的权重与激活用更低的比特位宽表示，比如8、6、4 bit等。根据量化操作在模型训练过程中的先后，量化方法主要可分为三类，分别为后训练量化（post-training quantization，PTQ）、量化感知训练（quantization aware training，QAT）和量化感知微调（quantization aware fine-tuning，QAF），其中后训练量化根据是否量化激活值还可分为仅权重量化（weight-only quantization）和权重激活量化（weight-activation quantization）。本文将对三类大语言模型的量化方法进行梳理。

2.2.1 后训练量化

后训练量化（PTQ）是一种使用少量校准数据对预训练模型进行量化的技术，具有较低的计算和存储开销，使其成为大语言模型高效部署的重要手段。相较于量化感知训练，PTQ不需要昂贵的反向传播优化，因此能够快速执行。然而，由于LLM具有高度非均匀的权重和激活分布，如何有效地降低量化误差、处理离群值（outliers）并提升低比特量化性能，是当前PTQ面临的核心挑战。现有PTQ方法可大致分为仅权重量化和权重-激活联合量化两类。

（1）仅权重量化

仅权重量化主要关注对LLM权重进行量化，以减少存储需求并保持计算精度。Frantar等人[8]提出的GPTQ是LLM量化研究中经典且有效的技术之一。该方法基于最优脑量化方法（optimal brain quantization，OBQ），利用近似二阶信息来进行逐层量化。GPTQ在OBQ的基础上提出了取消贪心算法、批次更新和Cholesky分解等改进措施，使量化过程更加快速且准确，其算法伪代码如算法2所示。GPTQ可以在大约4个GPU小时内将1 750亿参数大小的LLM量化至3 bit或4 bit，且几乎没有精度下降。

算法2 GPTQ[8]算法

输入：权重 $\boldsymbol{W}$，逆海森矩阵 $\boldsymbol{H}^{-1}$，块大小 B。

输出：量化后权重 $\boldsymbol{W}$。

$\boldsymbol{Q} \leftarrow \boldsymbol{0}_{d_{row} \times d_{col}}$ //量化输出

中国知网 https://www.cnki.net

$\boldsymbol{E} \leftarrow \boldsymbol{0}_{d_{row} \times B}$ // 块量化误差

$\boldsymbol{H}^{-1} \leftarrow \text{Cholesky}(\boldsymbol{H}^{-1})^{\text{T}}$ //海森逆信息

for $i = 0, B, 2B, \cdots$ do

  for $j = i, \cdots, i + B - 1$ do

    $\boldsymbol{Q}_{:,j} \leftarrow \text{quant}(\boldsymbol{W}_{:,j})$ //量化

    $\boldsymbol{E}_{:,j-i} \leftarrow (\boldsymbol{W}_{:,j} - \boldsymbol{Q}_{:,j}) / [\boldsymbol{H}^{-1}]_{jj}$ //量化误差

    $\boldsymbol{W}_{:,j:(i+B)} \leftarrow \boldsymbol{W}_{:,j:(i+B)} - \boldsymbol{E}_{:,j-i} \cdot \boldsymbol{H}^{-1}_{j,j:(i+B)}$ //更新块内权重

  end for

  $\boldsymbol{W}_{:,(i+B)} \leftarrow \boldsymbol{W}_{:,(i+B):} - \boldsymbol{E} \cdot \boldsymbol{H}^{-1}_{i:(i+B),(i+B):}$ //更新剩余权重

end for

Lin等人[32]指出一些与较大激活幅度相对应的权重通道，由于需要处理更重要的特征而更加显著，LLM中的权重并不同等重要，保护1%的显著权重可以极大地减少量化误差。基于这一观察，作者提出了一种激活感知权重量化方法AWQ，通过观测激活而不是权重来搜索每个通道最优的缩放因子。AWQ不依赖于任何反向传播或重建，可以较好地保留LLM的泛化能力。

Lee等人[33]进一步优化了这一思路，提出了离群点感知权重量化方法OWQ。该方法引入了混合精度量化方案，将更高的精度应用于由激活异常值引起的易受量化影响的权重。OWQ的思想与AWQ相似，都是通过考虑激活来量化权重，其不同之处在于OWQ采用的是混合精度量化，而AWQ对所有权重执行相同精度的量化。与OWQ类似的有Dettmers等人[34]提出的SpQR，二者都采用了混合精度量化，不同之处在于OWQ通过考虑激活中的离群值来量化权重，而SpQR考虑的是离群权重。该方法通过识别和隔离对量化敏感的离群权重，将其保存为更高的精度，同时将其他权重量化至3~4位，可以达到近乎无损的性能。

除了针对关键权重的选择优化外，一些研究尝试从数学优化角度改进PTQ。Chee等人[35]认为量化得益于不相干的权重和Hessian矩阵，即权重本身及其舍入方向在任何一个坐标中都不会过大。作者基于这一见解提出了不相干处理量化方法QuIP，包括一个最小化权重误差的自适应舍入过程以及一个高效的预处理和后处理过程，通过随机正交矩阵相乘来确保权重和Hessian矩阵的不相干性。该方法首次对LLM实现了有效的2 bit量化。

YUAN等人[36]进一步探索了LLM的极低比特量化，提出了部分二值化方法PB-LLM。作者指出现有的二值化算法不能很好地适用于LLM量化，并强调了显著权重在实现低比特量化上的重要作用；然后对显著权重的检测标准和粒度等方面进行了研究，提出了部分二值化矩阵，将较小比例的显著权重存储在更高的比特中。在PTQ方面，该方法结合GPTQ[8]的概念，重构了Hessian矩阵引导的二值化权重矩阵，成功恢复了PB-LLM在低比特上的推理能力。

除了上述的整数量化方法外，还有一些研究探索了LLM的浮点量化。Zhang等人[37]指出虽然浮点（floating point，FP）格式在LLM量化中具有良好的性能，但当量化分组较小或量化比特数低于4时其性能往往较差。作者发现其原因在于以往的FP量化为对称量化，不适合处理LLM权重张量的非对称分布，因此提出了非对称浮点量化方法AFPQ。该方法为正值和负值设置了不同的量化尺度，以匹配LLM权重张量中的非对称分布，带来了较大的精度提升。

（2）权重激活联合量化

权重激活联合量化旨在同时对权重和激活进行量化，以进一步提升计算加速效果。然而，LLM的激活值分布通常存在严重的离群现象，如图4[40]所示。这些离群值严重阻碍了LLM的量化性能，因此很多研究都致力于解决这一问题。

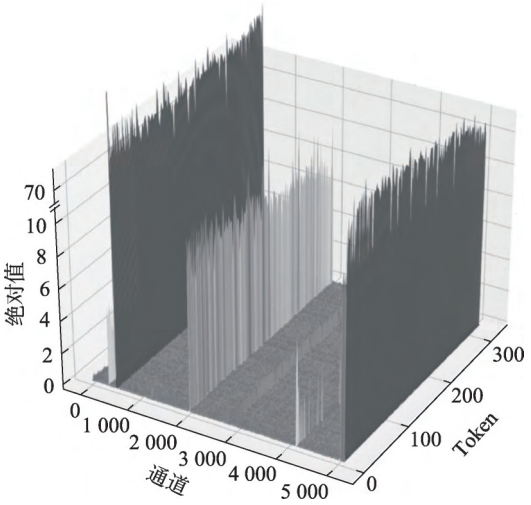

图4 大语言模型激活离群值示意图

Fig.4 Example of activation outliers in LLM

Dettmers等人[38]首先关注到随着模型规模的增大LLM激活中极端离群值的出现，提出了LLM.int8()。该方法对矩阵乘法中的每个向量内积进行独立的向量量化，同时还采用了混合精度分解，对异常特征维度执行16 bit矩阵乘法，而对其他的维度执行8 bit矩阵乘法，在保持性能的同时显著减少了推理过程中的内存使用。随后，Yao等人[39]提出了一种权重激活联合量化方法ZeroQuant。该方法采用了一种硬件友好的细粒度量化方案，即对权重和激活分别执行group-wise和token-wise的量化，同时还提出了一种逐层知识蒸馏方法以缓解模型量化导致的精度下降。ZeroQuant可以在200亿参数

中国知网 https://www.cnki.net

规模的模型上实现无损的8 bit量化，且获得了5.2倍的效率提升。

一些研究使用基于平滑的方法来减轻离群值对量化的影响。例如，Xiao等人[40]观察到，由于离群值的存在，对比权重而言激活值通常更难直接进行量化，如图4所示。基于此发现，作者提出了SmoothQuant方法。该方法通过一种数学上等价的逐通道缩放变换，以离线的方式将激活的尺度方差迁移到权重上，从而平滑了激活的幅值，将激活的量化难度转移到了权重上，使模型整体上更易于量化。Wei等人[41]进一步观察到激活中的离群值呈现非对称分布且集中在特定通道，因此提出了离群值抑制框架Outlier Suppression+。该方法引入了通道级的平移和缩放操作，以纠正不对称分布并减轻问题通道的影响，从而缓解量化困难。

一些研究使用基于通道重组的方法来缓解离群值问题。例如，Yuan等人[42]发现LLM中不同通道间的数值范围存在显著差异，使用相同的量化参数会导致较大的量化误差。为此，作者提出了一种基于重排序的量化方法RPTQ。该方法将具有相似值范围的通道进行聚类和重排，然后进行逐组量化，从而降低量化误差。类似地，Liu等人[43]提出QLLM，通过一种自适应的通道重组技术来处理激活中的离群值。该方法首先将异常通道分解成若干子通道，使激活呈现更易于量化的跨通道均衡分布，然后将相似的通道合并，以保持原始的通道数从而提高效率。

此外，还有一些研究使用基于旋转矩阵的方法来减少离群值。例如，Liu等人[44]提出了SpinQuant，通过引入可学习的旋转矩阵，有效减少了离群值并提高了量化的可行性，使得量化后的模型更加精准。此外，该方法的旋转矩阵优化过程能够通过标准的量化算法（如GPTQ[8]）与量化感知训练兼容，从而在保持网络结构不变的情况下优化量化性能。

除了针对离群值的研究，还有一些对于其他量化方法的探索。针对LLM量化方法通常手动设计量化参数从而导致性能较低的问题，Shao等人[45]提出了一种用于LLM的全向校准量化方法OmniQuant。具体而言，OmniQuant包括两个关键组件：可学习权重裁剪和可学习等效变换。前者通过优化裁剪阈值来调节权重的极值，后者通过学习Transformer编码器中的数学等价变换来处理激活离群值，进一步将量化的挑战从激活转移到权重。该工作开创性地引入可学习的LLM量化方法，为量化研究开拓新思路。

Li等人[46]提出了一种细粒度的量化方法FPTQ（fine-grained post-training quantization），该方法采用分层的策略来处理不同级别的量化难度，同时还提出了一种对数激活均衡方法，以非线性的形式调节激活分布，从而得到量化友好的激活分布。在另一项研究工作中，Li等人[47]观察到量化后模型输出的张量分布与原始浮点模型存在明显偏离，并且这一偏差还会逐层累加，而将量化的激活分布校正到与其浮点模型对应的位置可以很容易地恢复LLM的精度。因此作者提出了Norm Tweaking，该方法根据一个通道分布损失调整LayerNorm层的参数，以匹配量化模型的激活分布。

此外，一些研究探索量化方法在实际硬件上部署的可能性。例如，Li等人[48]认为先前的大部分LLM量化工作忽略了部署的可行性，得不到主流硬件的支持。作者以硬件为中心，提供了一个可部署的W4A8量化方案OdysseyLLM。该方案提供了一个对称的可学习权重裁剪，以获得更高的硬件效率，同时还包括了一个定制的4 bit整数矩阵乘法内核FastGEMM。Shen等人[49]探究了LLM在边缘设备上的量化工作，提出了一个激活引导量化框架Agile-Quant。作者首先引入了一个基本的激活量化策略来平衡任务性能和真实推理速度；然后提出了一个激活感知的令牌剪枝技术，以减少离群值和局部注意力对量化性能的负面影响；最后利用基于SIMD的4 bit乘法器和高效的TRIP矩阵乘法，在Android CPU和Raspberry Pi上实现了LLM的加速器，达到了2.55倍的加速比。

除了整数量化外，还有一些研究者对LLM的浮点量化进行了探索。Zhang等人[50]对用于量化LLM的整型（INT）和浮点（FP）格式进行了深入的比较分析。作者观察到由于LLM中张量分布的复杂性和多样性，对于所有的张量或层，没有一致最优的量化格式：对于静态分布的权重张量，INT量化在8 bit时优于FP量化，但在4 bit时该优势减弱；对于具有动态分布和显著离群值的激活张量，FP量化优于INT量化。受这一观察的启发，作者提出了混合格式量化方法MoFQ（mixture of formats quantization），该方法根据量化误差逐层地从INT和FP中选择最优的量化格式，保证了同一层内的张量共享相同的数据类型，并且所有的量化张量具有相同的位宽，有效利用了两种格式的互补优势。

Wu等人[51]进一步探讨了LLM浮点量化的适用性，发现FP8在激活量化方面始终优于INT8，而在权重量化方面FP4表现出与INT4相当的性能。基于此，作者提出了一种W4A8（即权重为4 bit，激活为8 bit）的浮点量化方法ZeroQuant-FP。该方法集成了低秩补偿（low rank compensation，LoRC）策略以增强量化方法，同时为了解决权重和激活之间的位数差异带来的挑战，提出了

中国知网 https://www.cnki.net

一种比特移位的方法，将FP4转换为FP8，有效地提高了推理效率。Liu等人[52]提出了LLM-FP4，对LLM的权重和激活都进行了4 bit浮点量化。该方法通过逐层重构来联合搜索最优的浮点量化参数，还引入了一种预移位指数偏置，用来解决激活的通道间高方差分布带来的量化挑战。

总体而言，PTQ方法的核心挑战在于如何降低低比特量化的误差，同时保持模型的泛化能力。仅权重量化方法主要通过优化关键权重选择和数学优化策略提升精度，而权重激活联合量化方法则致力于解决激活异常值问题，并通过自适应量化策略进一步提高稳定性。

2.2.2 量化感知训练

量化感知训练通过在训练过程中引入量化操作，使模型能够适应低比特数值表示，从而降低量化引起的精度损失。相比于后训练量化，QAT能够通过梯度优化调整权重量化误差，适用于高精度要求的应用场景。然而，QAT在LLM上的应用面临计算开销高、低比特量化困难等挑战。针对这些问题，研究者提出了一系列QAT优化方案。

Liu等人[53]提出了首个针对LLM的量化感知训练方法LLM-QAT，实现了对不同配置LLaMA模型的4 bit量化。LLM-QAT是一种无数据量化方法，利用原始LLM生成数据，然后在生成的数据上对LLM进行量化感知训练，以匹配原始LLM的输出分布，除了量化权重和激活，该方法还量化了KV（key-value）缓存，大大提高了模型吞吐量。LLM-QAT降低了数据依赖性，使其在闭源或数据受限环境下具有更广泛的应用潜力。

一些研究探索了1 bit或2 bit等极低比特量化，以最大限度降低存储和计算需求。例如，Wang等人[54]提出的BitNet是首个针对LLM的1 bit量化感知训练方案。该方法通过用BitLinear替换Transformer中的线性层，实现了权重二值化，同时保持激活和梯度的高精度计算，从而缓解了二值化导致的信息损失。PB-LLM[36]则采用部分二值化策略，仅对显著权重保留更高精度（如4 bit），而其他权重完全二值化。该方法在QAT过程中冻结显著权重，并优化二值化权重的缩放因子，提高了训练效率和收敛速度。

此外，还有一些研究探索了浮点量化感知训练方法。例如，Peng等人[55]提出了一种FP8混合精度训练框架FP8-LM。该框架以增量的形式融入了FP8的权重、梯度、优化器和分布式训练，并且提出了精确解耦和自动缩放以减小量化误差。

综上，QAT能够有效降低量化损失，但其计算开销和训练复杂度仍是应用于LLM的主要挑战。未来的研究方向可包括更高效的低比特量化优化、更智能的量化策略调整以及更适配硬件的量化方法，以推动LLM量化训练的进一步发展。

2.2.3 量化感知微调

量化感知微调通过引入额外的轻量化模块，使模型能够在低比特量化条件下保持较高性能，同时减少微调所需的计算和存储成本。与量化感知训练不同，QAF仅在微调阶段更新额外参数，而冻结预训练模型的主干权重，从而减少计算开销，提高适应性。然而，QAF在LLM上的应用仍然面临多个挑战，包括量化误差的补偿、适配器与量化自由度不匹配以及量化初始化的优化。近年来，研究者围绕高效参数调优和优化初始化等方向提出了一系列改进方法。

Kim等人[56]提出了一种参数高效的量化感知微调方法PEQA（parameter-efficient and quantization-aware adaptation）。该方法包括量化和微调两个步骤。首先在量化阶段，每个全连接层的参数矩阵被分解为一个低比特整数矩阵和一个量化缩放因子向量；然后在微调阶段，针对每个下游任务，在保持整数矩阵不变的情况下仅更新量化缩放因子。该方法结合了参数高效微调和量化的优势，不仅减少了微调过程中的内存消耗，而且大幅减少了模型大小，加快了推理速度。

一些研究探索了LoRA结合量化微调的方法。例如，Dettmers等人[57]使用LoRA来微调量化后的模型，提出了QLoRA。作者提出了一种在信息论上对正态分布数据最优的量化数据类型NormalFloat（NF）以及一种双量化（double quantization）操作，通过对量化系数进行量化以进一步减少内存使用。与标准的全模型微调相比，QLoRA在没有性能下降的情况下显著减少了微调过程中的内存使用。为了解决QLoRA中量化自由度和低秩自适应自由度不匹配的问题，Xu等人[58]提出了QA-LoRA，通过引入分组量化机制，在减少低秩自适应参数（每个组共享低秩自适应参数）的同时，提高了量化的灵活性（每个组进行单独量化），如图5[58]所示。QA-LoRA在减少适配器参数的同时增强了量化鲁棒性，优化了LoRA

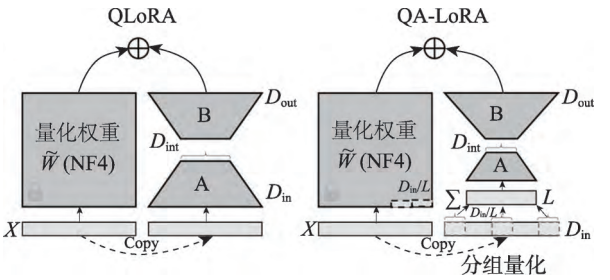

图5 QLoRA与QA-LoRA算法示意图

Fig.5 Illustration of QLoRA and QA-LoRA

中国知网 https://www.cnki.net

适配器与量化权重之间的匹配关系，从而降低了量化误差。

此外，Li等人[59]发现QLoRA中对低秩适配器使用的零初始化会对LoRA微调产生不利影响。作者提出了一种新的量化框架LoftQ，将模型量化与奇异值分解（singular value decomposition，SVD）相结合来逼近原始的高精度预训练权重，为LoRA微调提供了一个有利的初始化，缓解了QLoRA中的量化差异，并显著提高了下游任务的泛化性。

总体而言，量化感知微调方法在保持LLM高效微调能力的同时，有效降低了存储和计算开销。未来研究可进一步探索更鲁棒的量化适配策略、更灵活的量化格式以及与硬件友好的优化方案，以提升低比特LLM微调的精度和效率。

2.2.4 小结

本小节详细介绍了大语言模型量化方法的最新进展。表2对比了现有大语言模型量化方法的主要区别。模型量化方法目前仍为压缩大语言模型的最有效方法之一，因此备受关注。

大语言模型量化方法根据引入量化的时间主要分为后训练量化、量化感知训练、量化感知微调。这三类方法在提升模型的计算效率和存储效率方面展现出了显著的效果，同时在不同场景下有各自的优势与适用性。后训练量化（PTQ）因无需对模型进行额外训练或仅需少量数据进行微调，具有实现简单、计算开销低的优点，适用于资源有限的环境。然而，PTQ在极低比特位（如1 bit或2 bit）量化时，可能会面临较大的精度损失，因此更多应用于对精度要求不高的场景。量化感知

表2 LLM量化方法总结

Table 2 Summary of LLM quantization methods

方法	量化形式	量化数值类型	权重量化位数	激活量化位数	均匀量化	对称量化
GPTQ[8]	PTQ	整型	3/4	—	√	×
AWQ[32]	PTQ	整型	3/4	—	√	×
OWQ[33]	PTQ	整型	3/4	—	√	×
SpQR[34]	PTQ	整型	3/4	—	√	×
QuIP[35]	PTQ	整型	2	—	√	×
PB-LLM[36]	PTQ/QAT	整型	1	—	√	×
AFPQ[37]	PTQ	浮点型	3/4	—	×	×
LLM.int8()[38]	PTQ	整型	8	8	√	×
ZeroQuant[39]	PTQ	整型	4/8	8	√	√
SmoothQuant[40]	PTQ	整型	8	8	√	√
Outlier Suppression+[41]	PTQ	整型	6/8	6/8	√	×
RPTQ[42]	PTQ	整型	4	4/8	√	×
QLLM[43]	PTQ	整型	4/6	4/6	√	×
SpinQuant[44]	PTQ	整型	4	4/8	√	×
OmniQuant[45]	PTQ	整型	2/3/4	4	√	×
FPTQ[46]	PTQ	整型	4	8	√	√
Norm Tweaking[47]	PTQ	整型	2/4	8	√	√
OdysseyLLM[48]	PTQ	整型	4	8	√	√
Agile-Quant[49]	PTQ	整型	4	4/8	√	×
MoFQ[50]	PTQ	浮点型	4/8	8	×	×
ZeroQuant-FP[51]	PTQ	浮点型	4/8	8	×	√
LLM-FP4[52]	PTQ	浮点型	4/8	4/8	×	√
LLM-QAT[53]	QAT	整型	4	8	√	√
BitNet[54]	QAT	整型	1	8	√	√
FP8-LM[55]	QAT	浮点型	8	8	×	√
PEQA[56]	QAF	整型	3/4	—	√	×
QLoRA[57]	QAF	整型	4	—	×	√
QA-LoRA[58]	QAF	整型	2/3/4	—	√	×
LoftQ[59]	QAF	整型	2/4	—	×	√

中国知网 https://www.cnki.net

训练(QAT)通过在训练过程中引入量化操作,使模型能够在训练时适应低比特数表示,从而在较高压缩率下依然能够保持较高的模型性能。尽管QAT能够显著提升低比特量化模型的精度,但其训练成本较高,通常需要更长的训练时间和更多的计算资源,适合在对精度要求较高且资源充足的场景中应用。量化感知微调(QAF)则提供了一种折中的解决方案,它通过冻结大部分模型参数并只对少量的附加模块进行量化和微调,从而在降低计算成本的同时实现较好的压缩效果和性能恢复。这使得QAF适用于需要快速部署,并且对压缩率和精度都有一定要求的实际应用场景。

2.3 知识蒸馏

知识蒸馏旨在使用较大的教师模型指导较小的学生模型进行学习,从而提升学生模型的性能。根据蒸馏过程中是否需要教师模型的参数,知识蒸馏方法可以分为白盒知识蒸馏和黑盒知识蒸馏。如图6所示,白盒知识蒸馏将教师模型的参数与输出结果均作为知识供学生模型学习,而黑盒知识蒸馏则仅允许学生模型学习教师模型的预测输出结果,无法利用教师模型中的参数。本文将分别对两种方法进行梳理。

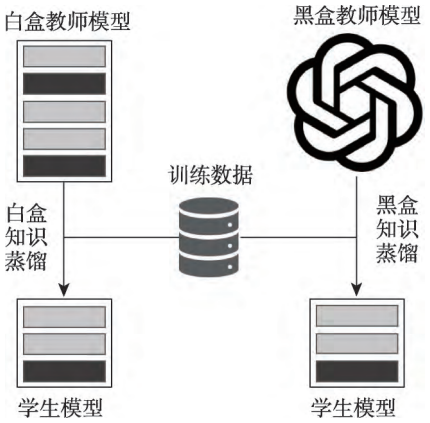

图6 大语言模型知识蒸馏方法分类图

Fig.6 Illustration of knowledge distillation methods for LLM

2.3.1 白盒知识蒸馏

白盒知识蒸馏通过直接访问教师模型的内部信息(如概率分布、隐藏层表示等),使学生模型能够在结构上更高效地学习教师的知识。这种方法能够提供更丰富的训练信号,减少蒸馏过程中的信息损失。近年来,研究者提出了多种优化策略,包括优化蒸馏目标以及逐层知识对齐等。

给定教师输出分布 $p(y|x)$ 和学生输出分布 $q_\theta(y|x)$,标准的知识蒸馏目标为最小化教师和学生分布之间的前向KL散度(Kullback Leibler divergence),记作 $\mathrm{KL}[p||q_\theta]$。然而,对于开放性文本生成任务,教师模型的输出空间比学生模型的输出空间更加复杂,学生模型分布的表达能力不足以覆盖教师分布的所有模式,此时最小化前向KL散度会导致 q_θ 将不合理的高概率分配给 p 的低概率区域,从而导致学生模型产生不合理的输出。为了解决这一问题,Gu等人[9]提出了首个针对白盒LLM的知识蒸馏方法MiniLLM。该方法提出最小化反向KL散度 $\mathrm{KL}[q_\theta||p]$,不强制 q_θ 去拟合教师分布 p,而是旨在利用教师提供的信息来辅助学生的训练,可以防止学生高估教师分布中的低概率区域,从而提高生成样本的质量。

对于训练过程中的固定输出序列与学生模型在推理时自回归产生的序列之间的分布不匹配这一问题,Agarwal等人[60]提出了GKD(generalized knowledge distillation)。该方法在训练集中引入了学生生成的序列,使用教师概率作为这些序列上的专家标签。同时该方法也提出了利用反向KL散度作为蒸馏目标,以解决学生模型表达能力不足的问题。

针对当前蒸馏方法存在的目标函数不稳定和训练推理不匹配问题,Ko等人[61]提出了一种高效知识蒸馏框架DistiLLM。该方法提出了一种偏斜KL散度,通过引入可控的偏斜参数,在理论上优化梯度稳定性并减少近似误差,使蒸馏目标函数更具泛化能力;该方法还采用了一种自适应离线策略以提升使用学生输出的训练效率,显著降低计算资源消耗。

除了基于输出对齐的蒸馏方法外,还有一些基于中间状态对齐的方法。例如,Liang等人[62]提出了一种逐层蒸馏方法TED(task-aware layer-wise distillation)。该方法为教师模型和学生模型的每一层设置一个特定任务的滤波器,用于从隐藏表示中提取对任务有用的知识,并对齐教师模型和学生模型每一层的隐藏表示。该方法分为两个阶段:第一阶段冻结教师和学生模型的参数,以特定任务的损失为目标训练教师模型和学生模型的滤波器,以提取隐藏表示中的知识;第二阶段保持教师模型和其滤波器不变,通过最小化教师模型和学生模型的隐藏表示之间的差异来训练学生模型及其滤波器。该方法通过滤波器从隐藏表示中抽取对目标任务有用的知识,不仅减少了两个模型之间的知识差距,而且帮助学生更好地适应目标任务。

综上,白盒知识蒸馏通过优化蒸馏目标和逐层知识对齐等策略,提高了大语言模型的蒸馏稳定性。未来的研究可探索如何更高效地结合这些方法,以提升LLM蒸馏的通用性和计算效率。

2.3.2 黑盒知识蒸馏

不同于白盒知识蒸馏,黑盒知识蒸馏指在无法访问教师模型内部权重和隐藏状态的情况下,仅利用其输出

中国知网 https://www.cnki.net

作为监督信号来训练学生模型。这种方法适用于闭源的大语言模型，如OpenAI的GPT-4，使得小模型能够继承教师模型的能力，同时降低计算和存储成本。目前大部分针对LLM的黑盒知识蒸馏方法专注于将LLM的涌现能力（emergent abilities）蒸馏到小模型中，具体包括上下文学习（in-context learning，ICL）、指令跟随（instruction following，IF）和思维链（chain of thought，CoT）。

（1）上下文学习

上下文学习是指在不更新模型参数的情况下，LLM基于一些示例执行新任务的能力。为了将LLM的上下文学习能力转移到学生模型中，Huang等人[63]提出了In-context Learning Distillation。该方法将上下文学习目标和语言建模目标相结合，其中上下文学习目标有助于学生基于上下文样例对任务进行推理，而语言建模目标则提供了关于训练任务的补充信息。

（2）指令跟随

指令跟随是指LLM遵循特定的指令，完成目标任务的能力。与上下文学习不同之处在于，指令跟随不包含示例输入。为了让学生模型在困难指令上学习进而提升性能（类似于人类学生在难题上加强训练），Jiang等人[64]提出了首个针对LLM的对抗蒸馏方法Lion。该方法包括三个阶段，不同阶段中LLM担任不同的角色：①模仿阶段，LLM充当教师的角色，通过最小化交叉熵损失来微调学生模型，使学生的输出向教师的输出对齐；②判别阶段，LLM充当判别器的角色，对教师模型和学生模型关于同一指令的输出进行打分，若分值差距超过某阈值，则该指令被识别为困难指令；③生成阶段，LLM充当生成器的角色，生成新的指令来匹配困难指令的数据分布，以升级对学生模型的挑战。通过三个阶段的迭代进行，该方法形成了一个正反馈回路，逐步利用困难指令增强学生模型的性能。

（3）思维链

思维链是指LLM在包含中间推理步骤的提示下，通过分布推理解决复杂任务的能力。当前有大量研究围绕如何利用LLM生成高质量的推理解释以及如何确保学生有效地利用这些推理解释进行微调或训练而展开。例如，Li等人[65]提出的MT-CoT采用混合策略，从LLM生成的少样本CoT提示中筛选高质量推理过程，确保学生模型学习到更可靠的推理路径。Ho等人[66]同样提出了利用LLM的思维链能力帮助小模型提升推理能力的方法Fine-tune-CoT。该方法使用零样本（zero shot）CoT提示从LLM中生成推理样本，并将其用于小模型的微调。此外，该方法还通过随机采样从LLM中生成多个推理解，以丰富学生模型的训练数据，实现多样化推理。与此类似的还有Distilling Step-by-Step[67]，该方法利用少样本CoT提示使大模型生成推理解释，并将其作为额外监督对小模型进行微调训练，且该方法在无标签数据上仍具有很好的有效性。此外，Socratic CoT[68]采用问题分解策略，将原始任务拆解为子问题-解决方案对，并分别训练问题分解器和求解器，使学生模型在学习推理链的同时提升推理的可解释性。

一些研究对LLM所生成的推理解释的多样性进行了探索。例如，Li等人[69]提出的SCoTD（symbolic chain-of-thought distillation）每次从教师模型中抽样多个推理解释及预测答案，而不是一个问题只采样一个推理解释和答案，过滤掉预测错误的样本后，将剩余的思维链解释和答案用于小模型的训练。Chen等人[70]提出的MCC-KD（multi-CoT consistent knowledge distillation）为每个问题生成多个推理解释，并过滤掉多样性不足的推理解释以提升小模型预测的多样性，随后通过最小化不同推理依据下答案分布之间的双向KL散度来确保相应预测之间的一致性。

一些研究对如何缓解LLM的幻觉问题并且提升蒸馏的鲁棒性进行了探索。例如，Chen等人[71]提出了一种基于LLM的反事实数据增强方法DISCO。该方法首先利用LLM生成短语扰动，然后通过特定任务的教师模型来过滤这些扰动，以提取高质量的反事实数据。Wang等人[72]发现，由于LLM的幻觉问题，教师模型生成的推理依据可能与答案并不相符，而学生模型可能忽略推理依据并作出不一致的预测。为了解决这两个挑战，作者提出了SCOTT（self-consistent chain-of-thought distillation）。该方法首先通过对比解码鼓励教师模型生成更符合正确答案的推理依据；然后使用教师模型生成的推理依据来训练学生模型进行反事实推理，防止学生忽略推理依据而作出不一致的预测。Zhu等人[73]提出了程序辅助的蒸馏方法PaD（program-aided distillation）。该方法主要针对算数推理任务，通过提示LLM使其生成能够解决问题的Python程序，然后利用一个Python解释器过滤掉无法编译或结果不正确的程序，最后利用合成的程序微调小模型。

此外，还有一些研究将学生模型的反馈纳入蒸馏过程。例如，Wang等人[74]提出了一种交互式多轮学习方法DRA，该方法首先利用小模型在训练集上进行预测，以收集小模型的错误；然后将小模型的错误反馈给LLM，利用LLM生成特定的训练数据；最后让小模型在LLM特定的数据上进行训练，并对自身错误进行自我反思学习，从而提升推理能力。为了减少思维链蒸馏过程中产生的错误推理的影响，Liu等人[75]提出了一种结

中国知网 https://www.cnki.net

合LLM自我评价能力的思维链蒸馏方法Mind's Mirror。该方法首先利用LLM生成问题的多个推理解释，然后通过文本提示使LLM生成关于每个推理解释的正误的自我评估，最后将多个推理解释及相应的自我评估共同用于小模型的训练，从而缓解小模型的幻觉问题。

总体而言，黑盒知识蒸馏在LLM能力迁移方面提供了一种计算资源友好的解决方案，但仍面临着蒸馏信号有限，推理解释质量难以保证，以及数据筛选效率低等问题。当前方法通过提升思维链推理质量和引入交互式学习策略，在一定程度上弥补了黑盒蒸馏的局限性。未来研究可进一步探索更高效的数据选择策略、更强的推理一致性约束以及结合外部知识增强的方法，以提升黑盒蒸馏的泛化能力和稳定性。

2.3.3 小结

本小节梳理并讨论了知识蒸馏在大语言模型压缩中的应用。知识蒸馏通过使用大型教师模型指导小型学生模型学习，使学生模型在保持较少参数的情况下，能够接近教师模型的性能。大语言模型的知识蒸馏方法主要分为白盒知识蒸馏与黑盒知识蒸馏。白盒知识蒸馏允许学生模型学习教师模型的内部结构及中间层特征表示，能够更全面地传递知识，因此通常能获得更好的压缩效果和性能提升。然而，白盒蒸馏的复杂性较高，要求对教师模型的参数和架构具有完全访问权限，在某些应用场景中受到限制。黑盒知识蒸馏则仅依赖于教师模型的输出结果进行训练，不需要访问教师模型的内部参数，因此在工业界和资源受限的环境中具有更好的实用性。总体而言，知识蒸馏在模型压缩中展现出了良好的效果，尤其是在模型参数规模大幅减少的情况下，依然能够维持较高的模型性能。然而知识蒸馏需要对学生模型进行训练，资源消耗较高，因此如何构建更高效的蒸馏框架，使得学生模型能够在更短的训练时间内学习到教师模型的能力，成为有待解决的重要问题。

2.4 低秩分解

在大语言模型中，Transformer的核心计算模块主要依赖于大规模矩阵运算，如注意力计算中的Query、Key和Value映射，以及前馈网络中的线性变换。这些权重矩阵通常具有显著的冗余性，即它们在高维空间中的表示存在较强的低秩结构。因此通过低秩分解可以将其表示为若干低秩矩阵的乘积，从而在保持近似表达能力的同时显著减少参数规模和计算量，如图7所示。在LLM压缩领域，低秩分解由于硬件支持较差，实际加速效果有限，因此相关研究较少。低秩分解方法通常与剪枝、量化等方法结合，可以分为基于量化的低秩分解、基于剪枝的低秩分解以及其他低秩分解方法。

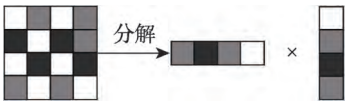

图7 低秩分解示意图

Fig.7 Illustration of low-rank decomposition

2.4.1 基于量化的低秩分解方法

在量化领域，Yao等人[76]结合低秩补偿（LoRC）和训练后量化，提出了ZeroQuant-V2。该方法使用一个低秩矩阵 $\hat{\boldsymbol{E}}$ 来近似量化误差矩阵 $\boldsymbol{E}$，其中 $\hat{\boldsymbol{E}}=\hat{\boldsymbol{U}}\hat{\boldsymbol{V}}$ 为两个低秩矩阵 $\hat{\boldsymbol{U}}$ 和 $\hat{\boldsymbol{V}}$ 的乘积，$\boldsymbol{E}=\boldsymbol{W}-\hat{\boldsymbol{W}}$ 为原始权重矩阵 $\boldsymbol{W}$ 和量化权重矩阵 $\hat{\boldsymbol{W}}$ 之间的误差。通过使用低秩补偿，$\hat{\boldsymbol{W}}+\hat{\boldsymbol{E}}$ 可以更好地近似原始权重 $\boldsymbol{W}$，从而减少量化误差。在ZeroQuant-FP[51]的工作中，研究者同样采用了低秩补偿技术以增强浮点量化算法。此外，QLoRA[57]将模型权重量化至4位，并使用16位的低秩适配器对量化后的模型进行微调，在没有性能下降的情况下显著减少了微调过程中的内存使用。QA-LoRA[58]通过引入分组操作，在减少低秩自适应参数的同时，提高了量化的灵活性，缓解了QLoRA中量化自由度和低秩自适应自由度之间的不平衡，有效减小了量化误差。LoftQ[59]将模型量化与奇异值分解相结合来逼近原始的高精度预训练权重，为LoRA微调提供了一个有利的初始化，显著提高了下游任务的泛化性。

2.4.2 基于剪枝的低秩分解方法

在剪枝领域，Li等人[77]结合低秩和稀疏逼近提出了LoSparse（low-rank and sparse approximation）。该方法利用一个低秩矩阵和一个稀疏矩阵来近似权重矩阵，即 $\boldsymbol{W}=\boldsymbol{UV}+\boldsymbol{S}$，其中 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 为两个低秩矩阵，$\boldsymbol{S}$ 为一个结构化稀疏矩阵。LoSparse结合了低秩近似和剪枝的优点，低秩近似压缩神经元中的重要部分，防止了剪枝过度移除重要的神经元，而剪枝去除神经元中的不重要部分，增强了低秩近似的多样性。而LoRAPrune[26]是结合低秩分解与剪枝的研究工作，该方法使用LoRA的权重和梯度对参数进行重要性估计，然后基于该准则进行迭代的结构化剪枝。

2.4.3 其他低秩分解方法

除了上述结合低秩分解与量化、剪枝等其他方法的压缩方法外，还有其他一些利用经典线性代数分解来压缩LLM的方法。例如，Yuan等人[78]提出了一种激活感知奇异值分解方法ASVD（activation-aware singular value decomposition）来压缩LLM。该方法首先根据输入通道中激活的分布来对权重矩阵进行缩放，然后对缩放后的矩阵进行奇异值分解，最后对原始权重矩阵进行重构近似。ASVD基于激活分布调整权重矩阵，减轻了

中国知网 https://www.cnki.net

激活中离群值的影响，提高了分解精度和效率。

2.4.4 小结

总体而言，低秩分解为LLM压缩提供了一种高效的降维方法，并能与量化、剪枝等技术结合，进一步提升模型压缩效果。然而，低秩分解仍面临较大挑战。例如秩选择困难：不同模型层的冗余程度差异显著，统一的秩设定难以适配所有层，如何自动确定最优秩仍是难题；表达能力受限：过于激进的低秩化可能损失关键特征，导致下游任务性能下降；硬件支持差：低秩张量乘法在主流硬件上并非天然高效，如何进行结构重构与内存优化仍是现实障碍。未来的研究可以进一步探索更精细的低秩矩阵分解策略，优化其与量化、剪枝等方法的协同作用，并且结合工程层面的探索，以提高LLM的压缩效率和推理性能。

2.5 不同压缩技术对比

模型剪枝、量化、知识蒸馏和低秩分解均旨在在性能损失最小的前提下，降低大语言模型的参数规模与推理成本。然而，不同压缩技术在具体方法和实施流程上各具特点。表3对比了当前主流模型压缩技术在压缩粒度、压缩对象、硬件友好性、性能影响等维度的异同。

从表3可以看出：模型剪枝与量化更适合结构压缩与推理加速，可直接作用于模型推理路径，尤其结构化剪枝+量化已广泛用于边缘部署；蒸馏适合能力迁移与精度保持，尤其在构建轻量学生模型方面具有优势；低秩分解更适合微调阶段的轻量化扩展，在训练阶段可与LoRA、Adapter等结合。

为了提升压缩效果与部署适应性，未来模型压缩研究的趋势之一正是多技术集成，根据应用场景动态组合不同压缩方式，以实现更优的效率-性能折中。

3 大语言模型压缩评价

在对大语言模型进行压缩时，合理的评价指标与数据集不仅能够衡量压缩方法的有效性，还能帮助研究者在不同应用场景下选择最优的压缩策略。本章将对大语言模型压缩评价指标及评测数据集进行介绍。

3.1 评价指标

大语言模型压缩评价指标通常涉及模型规模、计算复杂度、推理性能等多个方面，以便在存储、计算资源和性能损失之间找到最佳平衡。不同压缩方法在各项指标上的影响可能存在显著差异，因此综合考量这些指标对于评估模型压缩方案至关重要。以下是一些关键的压缩评价指标。

（1）参数量：是指模型中可学习的参数的总数。大语言模型的参数量通常“十亿”为单位。模型参数的数量直接影响了模型的大小和内存占用。通常情况下，参数量越多，模型的表示能力通常越强，但也意味着计算和存储的开销更大。压缩模型的一个主要目标是减少参数量，同时尽量保持模型性能。

（2）模型大小：是指模型文件在磁盘上所占的存储空间，包括模型权重、偏置和其他必要的组件，通常以MB（兆字节）或GB（吉字节）为单位。模型大小主要受参数量和数据类型（例如32位浮点数或8位整数）的影响。减少模型大小有助于降低存储成本，方便模型部署。

（3）浮点计算量：是指模型在一次推理过程中所需执行的浮点运算次数。浮点计算量是衡量计算复杂度的一个重要指标，通常用于评估模型的计算效率。浮点计算量与推理时间密切相关，较低的浮点计算量可以提高模型的推理速度。

（4）推理时间：是指大语言模型在推理时，从接收输入到生成输出结果所花费的时间。较短的推理时间意味着模型能够更快地处理输入数据，这对于面向用户的实时应用尤为重要。

（5）推理内存：是指大语言模型在进行推理时所占用的内存资源，其中包括模型参数、激活值以及中间计算结果所需的内存，通常以GB为单位。较小的推理内存要求有助于模型在资源受限的设备上运行，例如移动设备和嵌入式系统。

（6）吞吐量：是指单位时间内模型可以处理的输入数量，通常以“样本数/s”或“token/s”为单位。在批量处理、多任务并发或高频调用的应用场景中，吞吐量直接反映了模型的处理能力。相比于推理时间这一针对单个样本的指标，吞吐量更能体现系统整体的效率和可扩展性。压缩模型通常通过减少计算负载和内存访问开销，提高了单设备上的并发能力，从而有效提升吞吐

表3 不同LLM压缩技术对比

Table 3 Comparison of different compression technologies for LLM

压缩技术	压缩对象	压缩粒度	是否需要训练	硬件友好性	精度保持能力	代表方法
模型剪枝	权重/结构	通道/层/参数	可选	中	中	SparseGPT[7], LLMPruner[25]
模型量化	权重+激活	比特宽度	可选	高	高	GPTQ[8], AWQ[32], SmoothQuant[40]
知识蒸馏	模型	全模型/层	需要	高	高	MiniLLM[9], Distillm[61]
低秩分解	矩阵	矩阵块	可选	中	中	QLoRA[57], LoRAPrune[26]

中国知网 https://www.cnki.net

量。需要注意的是，吞吐量受模型结构、批大小、硬件带宽和并行机制等因素影响，因此在评价压缩效果时，应结合具体部署环境进行测量和优化。

（7）模型性能：是衡量压缩效果优劣的核心指标之一，通常是指模型在具体任务上的表现能力。常见的性能指标包括文本生成任务中的困惑度（Perplexity）、文本理解任务中的准确率，以及翻译任务中的BLEU分数等。在大语言模型的压缩评估中，常将压缩前后的模型性能进行对比，用于衡量压缩带来的性能损失程度。部分压缩策略（如剪枝、量化）在压缩比例较高时可能导致显著的性能下降，而知识蒸馏在保持或提升性能的同时也能实现参数或计算量的显著压缩。合理的压缩方案应在资源效率与模型性能之间找到平衡，确保模型在目标任务中的实际可用性。

压缩评价指标为人们提供了一个多维度的视角去评估和比较不同的模型压缩方法。这些指标的有效利用可以帮助人们在保持模型性能的同时，实现资源和性能的优化。在压缩评价中，上述指标往往需要综合考虑。例如，一个压缩方法可能大幅减少参数量和模型大小，但如果导致推理时间显著增加或推理内存需求过高，可能并不适合实际应用。因此，在实际选择压缩方法时，需要根据具体应用场景权衡各项指标，以找到最优的压缩方案。

3.2 评测数据集

为了系统评估大语言模型在压缩与加速后的性能表现，研究者通常采用多个具有代表性的评测数据集进行验证。这些数据集涵盖了语言建模、问答、推理、理解等多种任务，能够从不同维度衡量模型压缩带来的性能影响。表4总结了当前大语言模型压缩研究中常用的评测数据集，这些数据集是大语言模型评测的常用数据集，涵盖了多种大语言模型的能力评测。

上述数据集已成为近年来各类大语言模型压缩与加速方法的标准评估集合。例如，研究者[89]将GPTQ[8]、AWQ[32]和SparseGPT[7]等常用经典量化与剪枝方法在WikiText-2[79]、MMLU[81]和PIQA[82]等语言理解任务上进行了综合评估，其中LLaMa2模型上的评测结果如表5[89]所示。由表中结果可见，量化算法的性能大部分优于剪枝方法，且8 bit量化方法通常可实现无损压缩。此外，一些研究还构建了跨多个数据集的综合评估框架（如Open LLM Leaderboard），进一步推动了模型压缩方法的标准化评测。随着模型应用场景的拓展，未来压缩方法的评估也需涵盖更多维度，如安全性、多语言支持、低资源环境下的迁移能力等，以更全面地衡量压缩方法的实用价值。

表5 LLaMa2模型不同压缩方法语言理解性能对比

Table 5 Language understanding performance comparison of compression methods on LLaMa2 model

方法	压缩配置	困惑度	准确率/%	
		WikiText[79] ↓	MMLU[81]	PIQA[82]
原始模型	无	5.12	40.52	79.11
GPTQ[8]	8 bit	6.88	40.77	79.11
AWQ[34]	8 bit	5.12	40.90	79.05
SmoothQuant[40]	8 bit	5.53	39.02	78.18
Wanda[20]	50%	6.46	29.67	76.66
SparseGPT[7]	50%	6.51	34.62	76.44
LLMPruner[25]	50%	20.66	24.15	68.44

4 未来展望

虽然目前大语言模型压缩方法层出不穷，并取得了显著进展与应用，但仍存在一些局限性和挑战。本文认为，未来的研究有以下几个方向值得关注和探索。

（1）自适应压缩方法：现有压缩方法多为基于专家

表4 LLM压缩性能评测数据集

Table 4 Evaluation datasets for LLM compression performance

数据集名称	任务类型	语言类型	数据规模	数据集简介
WikiText-2[79]	语言建模	英文	1.80×10^6	由维基百科文章构成的大规模语言建模数据集，用于评估模型的困惑度
C4[80]	语言建模	英文	3.65×10^6	基于网页数据清洗得到的大规模文本语料
MMLU[81]	语言理解	英文	11.60×10^3	包含57个子任务，用于全面评估模型在人文、社会科学、理工等领域的表现
PIQA[82]	知识问答	英文	21.00×10^3	测试模型的物理常识掌握与选择能力
OpenBookQA[83]	知识问答	英文	5.96×10^3	基于开放性书本知识的问答任务，考察模型在零样本或小样本下的问答能力
ARC[84]	知识问答	英文	7.79×10^3	多项选择问答数据集，包含中小学科学考试题目
GSM8K[85]	数学推理	英文	8.79×10^3	用于评估模型的数学理解和推理能力的小学数学题
MATH[86]	数学推理	英文	12.50×10^3	具有挑战性的竞赛数学问题
C-Eval[87]	知识问答	中文	13.90×10^3	涵盖52个不同学科、4类不同难度的多项选择题，全面评估模型中文能力
CMMLU[88]	语言理解	中文	11.50×10^3	综合性中文评估基准，用于评估语言模型在中文语境下的知识和推理能力

中国知网 https://www.cnki.net

的经验手工进行压缩准则的设计，从而对网络进行轻量化。考虑到人工进行调优的繁杂流程，未来的研究可以探索更加自适应的模型压缩方法，使模型能够根据具体应用场景和硬件资源灵活调整结构和参数。例如，通过引入自适应剪枝和动态量化技术，模型可以在不同的运行环境中自动优化其性能和资源利用效率。

（2）针对低功耗目标的压缩方法：现有压缩方法大多忽略了能耗的考虑。未来的研究应更加注重模型的能效优化和环保性。通过发展低功耗计算和能效优化算法，减少大语言模型在训练和推理过程中的能源消耗，实现绿色AI的目标。

（3）综合评估框架：现有的压缩方法通常侧重于某一方面的优化，如计算速度或模型大小。然而，其他重要因素如压缩过程的资源消耗并未被大多数压缩方法作为评价指标之一。未来的研究应建立综合评估框架，全面衡量压缩方法在计算效率、模型性能、能耗以及应用适应性等方面的表现，为压缩方法的选择和改进提供依据。

（4）解释性与透明性：压缩模型的可解释性和透明性也是未来研究的重要方向之一。未来的研究应致力于开发能够提供解释性输出和透明决策过程的压缩方法，使得用户和开发者可以更好地理解和信任压缩后的模型。

5 结束语

本文对大语言模型压缩前沿研究进行了一次全面的综述。首先阐述了大语言模型时代的研究背景；然后介绍了大语言模型的必要背景知识；接下来分别从模型剪枝、模型量化、知识蒸馏和低秩分解各方面讨论和总结了大语言模型压缩与加速方法；随后介绍了大语言模型的压缩与加速评价指标与数据集；最后探讨了领域内的未来研究方向。希望通过对现有大语言模型压缩技术的梳理和总结，能够为未来的大语言模型压缩研究提供理论支持和技术参考，推动这一领域的发展与创新。

参考文献：

[1] ZHAO W X, ZHOU K, LI J Y, et al. A survey of large language models[EB/OL]. [2025-03-01]. https://arxiv.org/abs/2303.18223.

[2] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training [EB/OL]. [2025-02-05]. https://openai.com/index/language-unsupervised.

[3] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Proceedings of the 34th International Conference on Neural Information Processing Systems, ACM, 2020: 1877-1901.

[4] OpenAI. Introducing chatgpt[EB/OL]. [2025-02-05]. https://openai.com/blog/chatgpt.

[5] DeepSeek-AI, LIU A X, FENG B, et al. DeepSeek-V3 technical report[EB/OL]. [2025-02-07]. https://arxiv.org/abs/2412.19437.

[6] ZHANG S S, ROLLER S, GOYAL N, et al. OPT: open pre-trained transformer language models[EB/OL]. [2025-02-09]. https://arxiv.org/abs/2205.01068.

[7] FRANTAR E, ALISTARH D. SparseGPT: massive language models can be accurately pruned in one-shot[C]//Proceedings of the 40th International Conference on Machine Learning, 2023: 10323-10337.

[8] FRANTAR E, ASHKBOOS S, HOEFLER T, et al. GPTQ: accurate quantization for generative pre-trained Transformers [C]//Proceedings of the 11th International Conference on Learning Representations, 2023.

[9] GU Y X, DONG L, WEI F R, et al. MiniLLM: knowledge distillation of large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[10] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30, 2017: 5998-6008.

[11] OpenAI, ACHIAM J, ADLER S, et al. GPT-4 technical report [EB/OL]. [2025-02-15]. https://arxiv.org/abs/2303.08774.

[12] CHOWDHERY A, NARANG S, DEVLIN J, et al. PaLM: scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(1): 11324-11436.

[13] ANIL R, DAI A M, FIRAT O, et al. PaLM 2 technical report [EB/OL]. [2025-02-15]. https://arxiv.org/abs/2305.10403.

[14] TEAM G, ANIL R, BORGEAUD S, et al. Gemini: a family of highly capable multimodal models[EB/OL]. [2025-02-19]. https://arxiv.org/abs/2312.11805.

[15] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[EB/OL]. [2025-02-19]. https://arxiv.org/abs/2302.13971.

[16] TOUVRON H, MARTIN L, STONE K, et al. LLaMa 2: open foundation and fine-tuned chat models[EB/OL]. [2025-02-25]. https://arxiv.org/abs/2307.09288.

[17] GRATTAFIORI A, DUBEY A, JAUHRI A, et al. The LLaMa 3 herd of models[EB/OL]. [2025-02-25]. https://arxiv.org/abs/2407.21783.

[18] ZENG A H, LIU X, DU Z X, et al. GLM-130B: an open bilingual pre-trained model[EB/OL]. [2025-03-01]. https://arxiv.org/abs/2210.02414.

[19] BAI J Z, BAI S, CHU Y F, et al. Qwen technical report[EB/OL]. [2025-03-01]. https://arxiv.org/abs/2309.16609.

[20] SUN M J, LIU Z, BAIR A, et al. A simple and effective

中国知网 https://www.cnki.net

pruning approach for large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[21] YIN L, WU Y, ZHANG Z Y, et al. Outlier weighed layer-wise sparsity (OWL): a missing secret sauce for pruning LLMs to high sparsity[C]//Proceedings of the 41st International Conference on Machine Learning, 2024.

[22] SHAO H, LIU B, QIAN Y M. One-shot sensitivity-aware mixed sparsity pruning for large language models[C]//Proceedings of the 2024 IEEE International Conference on Acoustics, Speech and Signal Processing. Piscataway: IEEE, 2024: 11296-11300.

[23] LIU S W, LU H Q, MAHONEY M, et al. AlphaPruning: using heavy-tailed self regularization theory for improved layer-wise pruning of large language models[C]//Advances in Neural Information Processing Systems 37, 2024: 9117-9152.

[24] DAS R J, SUN M J, MA L Q, et al. Beyond size: how gradients shape pruning decisions in large language models[EB/OL]. [2025-03-05]. https://arxiv.org/abs/2311.04902.

[25] MA X Y, FANG G F, WANG X C. LLM-Pruner: on the structural pruning of large language models[C]//Advances in Neural Information Processing Systems 36, 2023: 21702-21720.

[26] ZHANG M Y, CHEN H, SHEN C H, et al. LoRAPrune: structured pruning meets low-rank parameter-efficient fine-tuning[C]//Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: ACL, 2024: 3013-3026.

[27] JI Y P, CAO Y B, LIU J C. Pruning large language models via accuracy predictor[EB/OL]. [2025-03-05]. https://arxiv.org/abs/2309.09507.

[28] GUO S, XU J H, ZHANG L L, et al. Compresso: structured pruning with collaborative prompting learns compact large language models[EB/OL]. [2025-03-07]. https://arxiv.org/abs/2310.05015.

[29] DERY L, KOLAWOLE S, KAGY J F, et al. Everybody prune now: structured pruning of LLMs with only forward passes[EB/OL]. [2025-03-09]. https://arxiv.org/abs/2402.05406.

[30] XIA M Z, GAO T Y, ZENG Z Y, et al. Sheared LLaMA: accelerating language model pre-training via structured pruning[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[31] LI Y, NIU L, ZHANG X P, et al. E-sparse: boosting the large language model inference through entropy-based N:M sparsity[EB/OL]. [2025-03-10]. https://arxiv.org/abs/2310.15929.

[32] LIN J, TANG J M, TANG H T, et al. AWQ: activation-aware weight quantization for on-device LLM compression and acceleration[C]//Proceedings of the 7th Annual Conference on Machine Learning and Systems, 2024.

[33] LEE C H, JIN J, KIM T, et al. OWQ: outlier-aware weight quantization for efficient fine-tuning and inference of large language models[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2024: 13355-13364.

[34] DETTMERS T, SVIRSCHEVSKI R, EGIAZARIAN V, et al. SpQR: a sparse-quantized representation for near-lossless LLM weight compression[EB/OL]. [2025-03-10]. https://arxiv.org/abs/2306.03078.

[35] CHEE J, CAI Y H, KULESHOV V, et al. QuIP: 2-bit quantization of large language models with guarantees[C]//Advances in Neural Information Systems 36, 2023: 4396-4429.

[36] YUAN Z H, SHANG Y Z, DONG Z. PB-LLM: partially binarized large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[37] ZHANG Y J, ZHANG S C, CAO S J, et al. AFPQ: asymmetric floating point quantization for LLMs[C]//Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: ACL, 2024: 28-36.

[38] DETTMERS T, LEWIS M, BELKADA Y, et al. Gpt3.int8 (): 8 bit matrix multiplication for transformers at scale[C]//Advances in Neural Information Processing Systems 35, 2022: 30318-30332.

[39] YAO Z W, AMINABADI R Y, ZHANG M J, et al. ZeroQuant: efficient and affordable post-training quantization for large-scale transformers[C]//Advances in Neural Information Processing Systems 35, 2022: 27168-27183.

[40] XIAO G X, LIN J, SEZNEC M, et al. SmoothQuant: accurate and efficient post-training quantization for large language models[C]//Proceedings of the 40th International Conference on Machine Learning, 2023: 38087-38099.

[41] WEI X Y, ZHANG Y C, LI Y H, et al. Outlier Suppression+: accurate quantization of large language models by equivalent and effective shifting and scaling[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 1648-1665.

[42] YUAN Z H, NIU L, LIU J W, et al. RPTQ: reorder-based post-training quantization for large language models[EB/OL]. [2025-03-10]. https://arxiv.org/abs/2304.01089.

[43] LIU J, GONG R H, WEI X Y, et al. QLLM: accurate and efficient low-bitwidth quantization for large language models [C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[44] LIU Z C, ZHAO C S, FEDOROV I, et al. SpinQuant: LLM quantization with learned rotations[EB/OL]. [2025-03-10]. https://arxiv.org/abs/2405.16406.

[45] SHAO W Q, CHEN M Z, ZHANG Z Y, et al. OmniQuant: omnidiretionally calibrated quantization for large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[46] LI Q Y, ZHANG Y F, LI L, et al. FPTQ: fine-grained post-training quantization for large language models[EB/OL]. [2025-03-11]. https://arxiv.org/abs/2308.15987.

[47] LI L, LI Q Y, ZHANG B, et al. Norm Tweaking: high-perfor-

中国知网 https://www.cnki.net

mance low-bit quantization of large language models[C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2024: 18536-18544.

[48] LI Q Y, MENG R, LI Y D, et al. A speed odyssey for deployable quantization of LLMs[EB/OL]. [2025-03-11]. https://arxiv.org/abs/2311.09550.

[49] SHEN X, DONG P Y, LU L, et al. Agile-Quant: activation-guided quantization for faster inference of LLMs on the edge [C]//Proceedings of the 38th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2024: 18944-18951.

[50] ZHANG Y J, ZHAO L R, CAO S J, et al. Integer or floating point? New outlooks for low-bit quantization on large language models[C]//Proceedings of the 2024 IEEE International Conference on Multimedia and Expo. Piscataway: IEEE, 2024: 1-6.

[51] WU X X, YAO Z W, HE Y X. ZeroQuant-FP: a leap forward in LLMs post-training W4A8 quantization using floating-point formats[EB/OL]. [2025-03-11]. https://arxiv.org/abs/2307.09782.

[52] LIU S Y, LIU Z C, HUANG X J, et al. LLM-FP4: 4-bit floating-point quantized transformers[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 592-605.

[53] LIU Z C, OGUZ B, ZHAO C S, et al. LLM-QAT: data-free quantization aware training for large language models[C]//Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: ACL, 2024: 467-484.

[54] WANG H Y, MA S M, DONG L, et al. BitNet: scaling 1-bit transformers for large language models[EB/OL]. [2025-03-11]. https://arxiv.org/abs/2310.11453.

[55] PENG H W, WU K, WEI Y X, et al. FP8-LM: training FP8 large language models[EB/OL]. [2025-03-01]. https://arxiv.org/abs/2310.18313.

[56] KIM J, LEE J H, KIM S, et al. Memory-efficient fine-tuning of compressed large language models via sub-4-bit integer quantization[C]//Proceedings of the 37th International Conference on Neural Information Processing Systems, 2023: 36187-36207.

[57] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: efficient finetuning of quantized LLMs[C]//Advances in Neural Information Systems 36, 2023: 10088-10115.

[58] XU Y H, XIE L X, GU X T, et al. QA-LoRA: quantization-aware low-rank adaptation of large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[59] LI Y X, YU Y F, Liang C, et al. LoftQ: LoRA-fine-tuning-aware quantization for large language models[C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[60] AGARWAL R, VEILLARD N, ZHOU Y C, et al. Generalized knowledge distillation for auto-regressive language models [C]//Proceedings of the 12th International Conference on Learning Representations, 2024.

[61] KO J, KIM S, CHEN T Y, et al. DistiLLM: towards streamlined distillation for large language models[C]//Proceedings of the 41st Conference on Machine Learning, 2024: 24872-24895.

[62] LIANG C, ZUO S M, ZHANG Q R, et al. Less is more: task-aware layer-wise distillation for language model compression[C]//Proceedings of the 40th International Conference on Machine Learning, 2023: 20852-20867.

[63] HUANG Y K, CHEN Y D, YU Z, et al. In-context learning distillation: transferring few-shot learning ability of pre-trained language models[EB/OL]. [2025-03-15]. https://arxiv.org/abs/2212.10670.

[64] JIANG Y X, CHAN C, CHEN M Y, et al. Lion: adversarial distillation of proprietary large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 3134-3154.

[65] LI S Y, CHEN J S, SHEN Y L, et al. Explanations from large language models make small reasoners better[EB/OL]. [2025-03-15]. https://arxiv.org/abs/2210.06726.

[66] HO N, SCHMID L, YUN S Y. Large language models are reasoning teachers[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 14852-14882.

[67] HSIEH C Y, LI C-L, YEH C K, et al. Distilling step-by-step! Outperforming larger language models with less training data and smaller model sizes[C]//Findings of the Association for Computational Linguistics: ACL 2023. Stroudsburg: ACL, 2023: 8003-8017.

[68] SHRIDHAR K, STOLFO A, SACHAN M. Distilling reasoning capabilities into smaller language models[C]//Findings of the Association for Computational Linguistics: ACL 2023. Stroudsburg: ACL, 2023: 7059-7073.

[69] LI L H, HESSEL J, YU Y, et al. Symbolic chain-of-thought distillation: small models can also "think" step-by-step[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 2665-2679.

[70] CHEN H Z, WU S Y, QUAN X J, et al. MCC-KD: multi-CoT consistent knowledge distillation[C]//Findings of the Association for Computational Linguistics: ACL 2023. Stroudsburg: ACL, 2023: 6805-6820.

[71] CHEN Z M, GAO Q Y, BOSSELUT A, et al. DISCO: distilling counterfactuals with large language models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 5514-5528.

中国知网 https://www.cnki.net

[72] WANG P F, WANG Z Y, LI Z, et al. SCOTT: self-consistent chain-of-thought distillation[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 5546-5558.

[73] ZHU X K, QI B Q, ZHANG K Y, et al. PaD: program-aided distillation can teach small models reasoning better than chain-of-thought fine-tuning[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2024: 2571-2597.

[74] WANG Z Y, HUANG S H, LIU Y X, et al. Democratizing reasoning ability: tailored learning from large language model [C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 1948-1966.

[75] LIU W Z, LI G C, ZHANG K, et al. Mind's mirror: distilling self-evaluation capability and comprehensive thinking from large language models[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2024: 6748-6763.

[76] YAO Z W, WU X X, LI C, et al. ZeroQuant-V2: exploring post-training quantization in LLMs from comprehensive study to low rank compensation[EB/OL]. [2025-03-17]. https://arxiv.org/abs/2303.08302.

[77] LI Y X, YU Y F, ZHANG Q R, et al. LoSparse: structured compression of large language models based on low-rank and sparse approximation[C]//Proceedings of the 40th International Conference on Machine Learning, 2023: 20336-20350.

[78] YUAN Z H, SHANG Y Z, SONG Y, et al. ASVD: activation-aware singular value decomposition for compressing large language models[EB/OL]. [2025-03-17]. https://arxiv.org/abs/2312.05821.

[79] MERITY S, XIONG C M, BRADBURY J, et al. Pointer sentinel mixture models[EB/OL]. [2025-03-17]. https://arxiv.org/abs/1609.07843.

[80] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(1): 5485-5551.

[81] HENDRYCKS D, BURNS C, BASART S, et al. Measuring massive multitask language understanding[EB/OL]. [2025-03-18]. https://arxiv.org/abs/2009.03300.

[82] BISK Y, ZELLERS R, LE BRAS R, et al. PIQA: reasoning about physical commonsense in natural language[C]//Proceedings of the 34th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI, 2020: 7432-7439.

[83] MIHAYLOV T, CLARK P, KHOT T, et al. Can a suit of armor conduct electricity? A new dataset for open book question answering[EB/OL]. [2025-03-18]. https://arxiv.org/abs/1809.02789.

[84] CLARK P, COWHEY I, ETZIONI O, et al. Think you have solved question answering? Try ARC, the AI2 reasoning challenge[EB/OL]. [2025-03-20]. https://arxiv.org/abs/1803.05457.

[85] COBBE K, KOSARAJU V, BAVARIAN M, et al. Training verifiers to solve math word problems[EB/OL]. [2025-03-20]. https://arxiv.org/abs/2110.14168.

[86] HENDRYCKS D, BURNS C, KADAVATH S, et al. Measuring mathematical problem solving with the MATH dataset [EB/OL]. [2025-03-20]. https://arxiv.org/abs/2103.03874.

[87] HUANG Y Z, BAI Y Z, ZHU Z H, et al. C-eval: a multi-level multi-discipline Chinese evaluation suite for foundation models [C]//Advances in Neural Information Processing Systems 36, 2023: 62991-63010.

[88] LI H N, ZHANG Y X, KOTO F, et al. CMMLU: measuring massive multitask language understanding in Chinese[C]//Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: ACL, 2024: 11260-11285.

[89] YANG G, HE C Y, GUO J Y, et al. LLMCBench: benchmarking large language model compression for efficient deployment[C]//Advances in Neural Information Processing Systems 38, 2024.

郭晋阳(1995—),男,北京人,博士,助理教授,主要研究方向为高效深度学习、模型压缩等。

GUO Jinyang, born in 1995, Ph.D., assistant professor. His research interests include efficient deep learning, mode compression, etc.

贺昌义(2001—),男,山西临汾人,硕士研究生,主要研究方向为高效深度学习、模型压缩等。

HE Changyi, born in 2001, M.S. candidate. His research interests include efficient deep learning, model compression, etc.

杨戈(2002—),男,辽宁沈阳人,硕士研究生,主要研究方向为高效深度学习、模型压缩等。

YANG Ge, born in 2002, M.S. candidate. His research interests include efficient deep learning, model compression, etc.

刘祥龙(1985—),男,山东日照人,博士,教授,主要研究方向为高效深度学习、可信赖人工智能等。

LIU Xianglong, born in 1985, Ph.D., professor. His research interests include efficient deep learning, trustworthiness in AI, etc.

中国知网 https://www.cnki.net