混合专家大语言模型的系统与架构优化技术综述

王泽昊 朱振华 谢童欣 汪 玉*
(清华大学电子工程系 北京 100084)

摘 要：混合专家已经成为当前进一步提升大语言模型推理能力的重要方法。当下，受限于算力与显存，通过扩大稠密大语言模型参数规模来提高模型推理能力的方法已经陷入瓶颈，即全参数激活带来了严重的显存与算力不足问题。混合专家机制通过构建由多个专家子网络组成的分布“知识库”，在提升大语言模型参数规模的同时，通过路由函数动态选择专家子网络来控制单次推理计算总量。然而，这种动态专家选择机制带来了显著的资源管理和调度问题，需要在加速系统和硬件架构层面有针对性地开展优化。该文将聚焦于混合专家大语言模型部署的系统与架构层：首先，概述了混合专家大模型的定义和发展趋势；之后，详细介绍了现有混合专家大语言模型的系统与架构优化技术并深入分析；最后，该文对混合专家大模型的优化技术进行总结和展望。

关键词：大语言模型；混合专家；加速系统；硬件架构
中图分类号：TN402; TP183 **文献标识码**：A **文章编号**：1009-5896(2025)11-4055-24
DOI: 10.11999/JEIT250407 **CSTR**: 32379.14.JEIT250407

1 引言

当下，大语言模型(Large Language Models, LLMs)在文本理解与生成任务中展现的杰出能力，深刻影响了人工智能(Artificial Intelligent, AI)的发展。从2017年Transformer架构[1]的提出，到GPT-4[2]、Gemini[3]和Qwen[4]等模型[5–8]的涌现，LLMs已经在文本写作[9,10]、代码生成[11]和复杂推理[12]等任务中表现出相当于人类专家的能力。同时，得益于LLMs的知识容量以及强大泛化能力，基于LLMs的视觉模型在计算机视觉[13,14]和多模态任务[15,16]都能取得不错的成绩。LLMs能获得上述的成绩，很大程度上归功于庞大的参数规模以及训练数据量，这种参数/计算规模与模型能力的缩放趋势得到了经验证据的支持，综合文献[17–19]的数据与观点，LLMs的综合能力与模型总参数以及训练计算量尺度相关，即对于参数全激活的稠密模型而言，其对计算量与数据量规模呈线性增长，而这种增长对现有硬件平台的带宽资源和计算能力都提出了重大挑战，以Meta-LLaMA3-70B模型[5]为例，其在FP16精度下的显存需求达168 GB，而训练时的峰值显存需求高达533 GB，总算力消耗3.8×10^{25} FLOPS。

混合专家架构(Mixture of Experts, MoE)是解决LLMs中模型规模与硬件资源尺度缩放不匹配问题的重要方法，其通过构建专家子网络实现知识表征的分布式存储，在训练时习得路由策略，为每个输入选择性地激活最佳的相关专家。这种方法在保持模型大量参数的同时，通过稀疏激活控制了端到端的计算总量，提高了训练推理时的效率。MoE思想最初作为一种在神经网络中学习子任务的方法，由Jacobs等人[20]于1991年提出。在过去几年里，基于MoE的模型发展迅速。2017年，Shazeer等人[21]首次将MoE引入到LLMs的训练推理中，经过一段时间的发展，MoE在处理不同文本场景任务中具备高性价比能力。在GLaM[22]报告中表明，在相同推理模型的训练需求下，采用MoE设计可以有效减少训练的计算总量与能耗(以GPT-3为基线，GLaM的训练总计算量为前者的51.4%，总能耗为前者的35.4%)；在推理层面，Mixtral 8×7 B[23]和DeepSeek-MoE[24]的报告表明，得益于MoE模型的专家容量广度，MoE大模型可以实现比等同参数稠密模型更好的推理性能(在相同训练数据量下，1.3 B静态参数 + 128专家子网络模型与6.7 B稠密模型性能基本一致)。同时，以MoE为设计基础的商业模型井喷，如Qwen2.5-72B[4], Phi-3.5[7]和Grok-1[25]等[26–34]，这也进一步“印证”了MoE架构将在未来大模型的发展中占据重要地位(表1汇总了截至2025年5月市面上公开的MoE大模型[22–169])。

然而，MoE模型在提升模型性能的同时，其动态路由机制也给训练推理系统带来了新的技术挑战。相较于传统稠密模型，基于输入特征动态激活特定专家子网络的特性，显著增加了系统资源调度与管理的复杂度[19,27]，具体表现在：(1)系统层面需要精细化管理计算、内存与带宽资源以实现负载均

收稿日期：2025-05-13；改回日期：2025-08-20；网络出版：2025-08-27
*通信作者： 汪玉 yu-wang@tsinghua.edu.cn
基金项目：国家自然科学基金(62325405)，北京信息科学与技术国家研究中心(BNR2024TD03001)
Foundation Items: The National Natural Science Foundation of China (62325405), Beijing National Research Center for Information Science and Technology (BNR2024TD03001)

中国知网 https://www.cnki.net

表 1 混合专家大模型参数表

模型名称	发行单位	发布时间	总参数量	稠密/混合专家层数	$\#D$	$\#D_{\text{FFN}}$	$\#D_{\text{Exp.}}$	专家参数量	总专家数	激活专家数(路由+共享)	激活参数量
Gshard*[31]	Google	2020.06	37.5 B	18/18	1024	8192	8192	-	128	2+0	1.5 B
			150 B	18/18	1024	8192	8192	-	512	2+0	1.5 B
			600 B	18/18	1024	8192	8192	-	2048	2+0	1.5 B
Switch Transformers*[28]	Google	2021.01	7 B	6/6	768	2048	2048	-	128	1+0	-
			26 B	12/12	1024	2816	2816	-	128	1+0	-
			395 B	12/12	4096	10240	10240	-	64	1+0	-
			1571 B	0/15	2080	6144	6144	1570.3 B	2048	1+0	1.6 B
M6-T[30]	Alibaba	2021.08	1.4 B	0/5	1024	4096	4096	1.34 B	32	2/4+0	0.14/0.23 B
			10.8 B	0/10	1024	4096	4096	10.74 B	128	2/4+0	0.14/0.23 B
			103.2 B	0/24	1024	4096	4096	103.09 B	512	2/4+0	0.14/0.23 B
			1002.7 B	0/24	1024	21248	21248	1002.63 B	960	2/4+0	2.2/4.3 B
GLaM[22]	Google	2021.12	1.9 B	6/6	768	3072	3072	1.81 B	64	2+0	0.145 B
			27 B	12/12	2048	8192	8192	25.77 B	64	2+0	1.88 B
			143 B	16/16	4096	16384	16384	137.44 B	64	2+0	9.8 B
			1200 B	32/32	8192	32768	32768	1099.53 B	64	2+0	96.6 B
ST-MoE[32]	Google	2022.02	4.1 B	0/27	1024	2816	2816	4.98 B	32	2+0	0.8 B
			269 B	0/27	5120	20480	20480	362.4 B	64	2+0	32 B
NLLB-MoE*[154]	FaceBook	2022.07	54.5 B	0/24	1024	8192	8192	51.54 B	128	2+0	3.8 B
Qwen2-57B-A14B[155]	Alibaba	2023.05	57.4 B	0/28	3584	18944	2560	49.33 B	64	8+0	14 B
Mixtral-8x7B[23]	Mistral AI	2023.12	46.7 B	0/32	4096	14336	14336	45.1 B	8	2+0	14 B
OpenMoE[33]	NUS et al.	2023.12	0.65 B	0/3	768	3072	3072	0.34 B	16	2+0	0.339 B
			8.7 B	0/4	2048	8192	8192	6.44 B	32	2+0	2.6 B
			34 B	0/8	3072	12288	12288	28.99 B	32	2+0	34 B
DeepSeek-MoE[24]	DeepSeek-AI	2024.01	1.89 B	0/9	1280	5120	1280	2.83 B	64	6+1	0.24 B
			16.4 B	3/28	2048	10944	1408	15.51 B	64	6+2	2.8 B
			145 B	3/59	4096	14336	1792	166.33 B	128	12+4	22 B
Qwen1.5-MoE[156]	Alibaba	2024.02	14.3 B	0/24	2048	5632	1408	12.46 B	60	4+4	2.7 B
JetMoE[34]	MIT et al.	2024.03	8.52 B	0/24	2048	5632	5632	6.64 B	8	2+0	2.2 B
Jamba**[26]	ai21labs	2024.03	51.6 B	0/32	4096	14336	14336	90.2 B	16	2+0	12 B
DBRX[157]	Databricks	2024.03	132 B	0/40	6144	10752	10752	126.84 B	16	4+0	36 B
Grok-1[25]	xAI	2024.03	314 B	0/64	6144	32768	32768	309.24 B	8	2+0	39 B
Arctic[158]	Snowflake	2024.04	482 B	0/35	7168	4864	4864	43.93 B	12	2+0	17 B
Mixtral-8x22B[23]	Mistral AI	2024.04	141 B	0/56	6144	16384	16384	135.29 B	8	2+0	39.5 B
DeepSeek-V2.5[159]	DeepSeek-AI	2024.04	236 B	3/59	5120	12288	1536	222.77 B	160	6+2	21 B
Skywork-MoE[160]	Kunlun Tech	2024.05	146 B	0/52	4608	12288	12288	141.34 B	16	2+0	22 B
Yuan2[161]	IEIT-Yuan	2024.05	40 B	0/24	2048	8192	8192	38.66 B	32	2+0	3.7 B
LLaMA-MoE[162]	Zhu *et al.*	2024.06	37 B	0/32	4096	11008	11008	34.63 B	8	2+0	3.8 B
OLMoE[163]	AllenAI	2024.07	6.92 B	0/16	2048	1024	1024	6.44 B	64	8+0	1.3 B
Phi-3.5[7]	MicroSoft	2024.08	41.9 B	0/32	4096	6400	6400	40.27 B	16	2+0	6.6 B
GRIN-MoE[164]	MicroSoft	2024.09	41.9 B	0/32	4096	6400	6400	40.27 B	16	2+0	6.6 B
Hunyuan-Large[165]	Tencent	2024.11	389 B	0/64	6400	18304	18304	359.88 B	16	1+1	52 B
DeepSeek-V3[27]	DeepSeek-AI	2024.12	671 B	3/58	7168	18432	2048	656.46 B	256	8+1	37 B
MiniMax-Text-01[166]	MiniMax-AI	2025.01	456 B	0/80	6144	9216	9216	434.88 B	32	2+0	45.9 B
Moonlight[167]	Moonshot AI	2025.02	16 B	0/26	2048	11264	1408	14.4 B	64	6+2	3 B
LLaMA4[168]	Meta	2025.04	109 B	0/48	5120	16384	8192	98.1 B	16	1+1	17 B
			400 B	24/24	5120	16384	8192	389.6 B	128	1+1	17 B
			2000 B	-	-	-	-	-	16	-	288 B
Qwen3-MoE[169]	Alibaba	2025.05	30 B	0/48	2048	6144	768	29 B	128	8+0	3 B
			235 B	0/94	4096	12288	1536	227 B	128	8+0	22 B

* 该模型为“编码器 - 解码器”结构

** 该模型为“Transformer–Mamba[121]”结构

中国知网 https://www.cnki.net

衡并减少数据搬移的显性开销；(2)硬件层面需要设计专门的加速架构来适配网络级别的动态稀疏计算特性。

本文将对近几年MoE加速系统与计算架构设计方案及方法进行具体介绍(图1展示了本文的讲述框架)，并为后续研究提供思路。具体贡献点如下。

(1)总结了现有MoE大模型的算法特点与部署难点：整理现有MoE大模型在模型结构与高效算法设计上与传统稠密大模型的差异，同时列举了MoE在应用层面的案例，分别梳理了MoE大模型在云-端侧部署的难题。

(2)整理了系统与硬件优化的技术框架：从通信开销、内存管理和计算负载等维度，系统梳理MoE模型在资源调度、负载均衡等场景下的核心挑战，提炼出加速系统优化与硬件架构设计的关键技术方法。

(3)明确MoE大语言模型在系统与硬件架构设计的未来优化方向，并提出未来MoE大语言模型发展，需要“算法-系统-硬件”跨层级联动设计的观点，为后续研究提供技术演进的理论基础与实践指导。

本文的具体章节安排如下：第2节提供了有关MoE模型的理论背景、发展概览以及现存的部署挑战。第3～5节分别详细介绍了面向MoE模型的系统和架构优化技术路线。第6节对上述工作思考与反思，并展望未来MoE系统与架构领域的发展方向。第7节总结调研的结果。

2　混合专家大模型背景

2.1　混合专家大模型的定义

与传统稠密模型的全参数激活机制不同，MoE采用动态门控网络实施选择性激活策略，如选择赋值权重前K个专家子网络(Top-K)策略，使得激活参数量与总参数规模呈现亚线性增长关系[21,31]。MoE网络主要由两大核心组件构成：路由门控函数(Gating Function)与专家子网络集。其中，门控函数通过解析输入特征语义实现任务模式识别，其数学表达可形式化为

$$\mathcal{G}(\boldsymbol{x}) = \mathrm{softmax}\left(\mathrm{TopK}\left(\boldsymbol{W}_{\mathrm{g}} \cdot \boldsymbol{x} + \boldsymbol{b}_{\mathrm{g}}\right)\right) \tag{1}$$

其中，$\boldsymbol{x}$为输入数据，$\boldsymbol{W}_{\mathrm{g}} \in R^{n \times d}$为门控权重矩阵，$\boldsymbol{b}_{\mathrm{g}}$为偏置项，$\mathrm{TopK}(\cdot)$为保留权重最高的前$k$个专家索引，$\mathrm{softmax}(\cdot)$为归一化指数函数。

路由门控函数输出一个概率分布向量，满足$\sum_{i=1}^{N} \mathcal{G}_i(\boldsymbol{x}) = 1$。结合专家子网络集，最终的MoE输出公式为

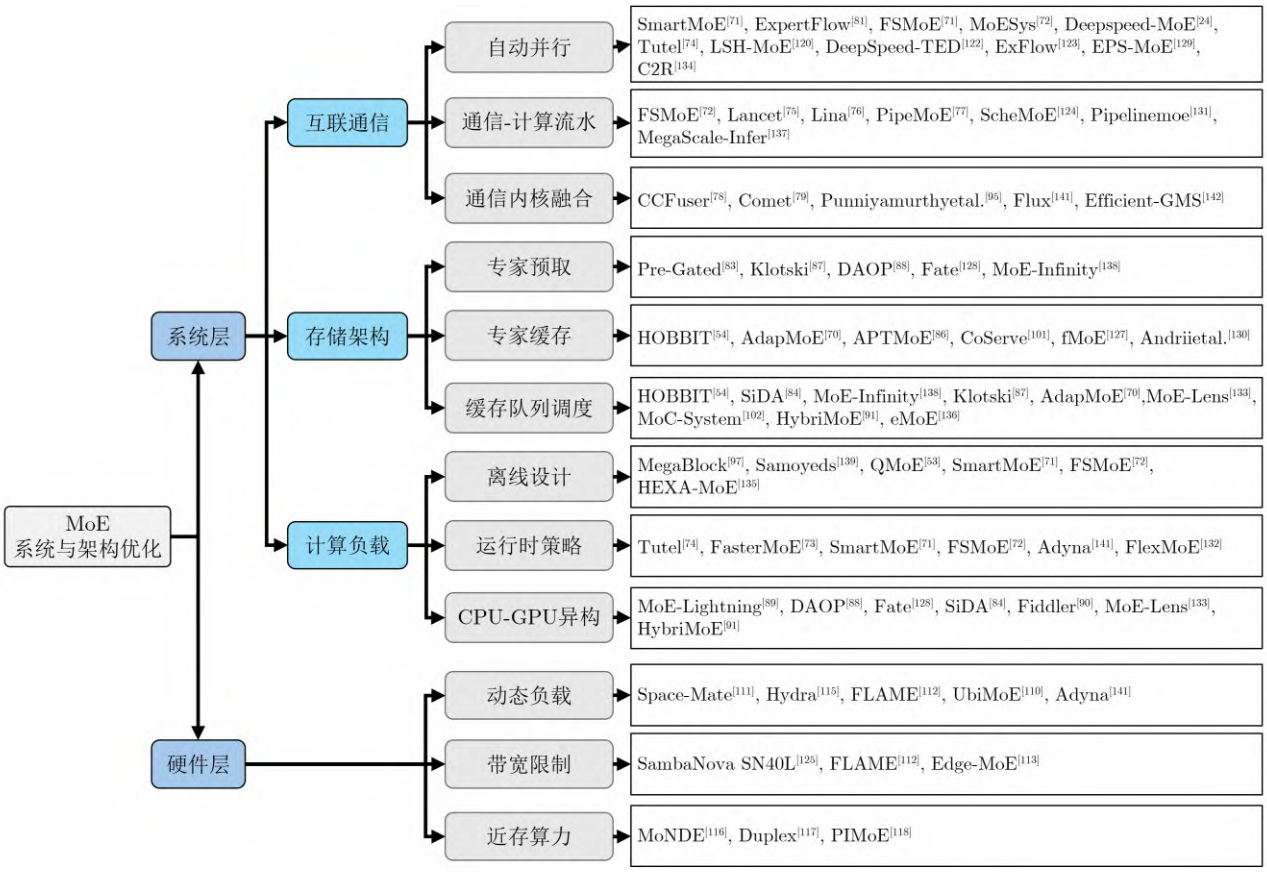

图 1 MoE 系统与架构优化技术结构框图

中国知网　https://www.cnki.net

$$y=\sum_{i=1}^{N}\mathcal{G}(\boldsymbol{x})\cdot E_i(\boldsymbol{x}) \tag{2}$$

其中，$\boldsymbol{x}$为输入数据，$E_i(\boldsymbol{x})$表示第i个专家，$\mathcal{G}(\boldsymbol{x})$为上述路由门控函数。

2.2 混合专家大模型的发展概览

近年来，MoE大模型的技术体系逐步从理论探索迈向工程实践，既有对模型结构重新设计的尝试，也有对系统部署平衡的追求。本章将从MoE大模型演进的视角切入，梳理其发展脉络，剖析模型结构设计思想与高效算法实现方法。

2.2.1 混合专家模型结构设计

基于Transformer架构的大语言模型主要由多头注意力机制层(Multi-head Attention)和前向传播网络层(Feed Forward Network, FFN)构成[35,36]。为了构建推理能力更强大的模型，同时保证计算的高效性，许多研究尝试对模型架构本身进行改进，衍生出多种结构变体的MoE大模型(如图2(a)所示)。

目前，现有研究主要采用FFN层专家扩张的策略[22,27–37]。Yang等人[30]发现相较于专家激活不均衡问题，稀疏激活专家数量与专家容量在TopK路由机制中呈更显著的影响，提出了专家原型化方法(Expert Prototyping)，通过将专家划分为不同的原型组合并采用Ktop-1路由策略，有效提升了模型的知识表达能力。在模型构建方法论层面，Pei等人[37]提出从稠密模型到MoE架构的转换范式，其核心在于将FFN分为共享专家(高激活率、通用知识处理)和路由专家(低激活率、特定任务处理)，并引入平衡线性分配算法实现专家分组优化，同时构建可微分路由机制以规避路由网络的重复训练成本。

在多头注意力层与MoE融合探索中，研究者也发现了多种设计可能[38–40]。Zhang等人[38]提出了混合注意力机制(Mixture of Attention, MoA)，其设计动态路由网络为每个词元选择K个最优注意力头，并计算它们的加权和作为输出。Jin等人[40]在此基础之上进一步完善了混合注意力头(Mixture of Heads, MoH)的概念，通过引入共享头机制与两阶段路由网络，使模型能够自适应选择与当前语义最相关的注意力头组合。

在长文本处理中，MoE的动态激活思想可以被应用于键值对缓存(KV Cache)优化[41–45]。Lu等人[44]通过构建门控网络实现查询词元(Query Token)与关键值块(KV Blocks)的关联性评估，仅保留TopK相关性块参与注意力计算，从而减少了不必要缓存序列的重复计算。

2.2.2 高效混合专家算法设计

在大语言模型的算法优化领域，高效算法设计始终是核心研究课题，其核心挑战为在保持模型性能的前提下实现参数规模的压缩。当前主流技术体系包括剪枝[46–52]、量化[53–57]和低秩分解[58–60](如图2(b)所示)，而针对MoE需聚焦专家子网络的高参数占比(>95%)[24–29]。然而，MoE专家激活情况具有显著时变特性，导致其与普通稠密模型在算法优化方面存在差异。

(1)在剪枝方面，传统稠密模型可基于静态评分阈值进行剪枝[61,62]，但动态路由可能导致每次专家激活不稳定，采用静态方法易导致错过重要的专家参数。针对上述问题，Lu等人[46]通过枚举不同专家组合，并采用最小化参数重建损失准则实现专家选择的动态优化，同时引入路由权重阈值判定的动态专家跳过机制，实现加速推理与精度的平衡；

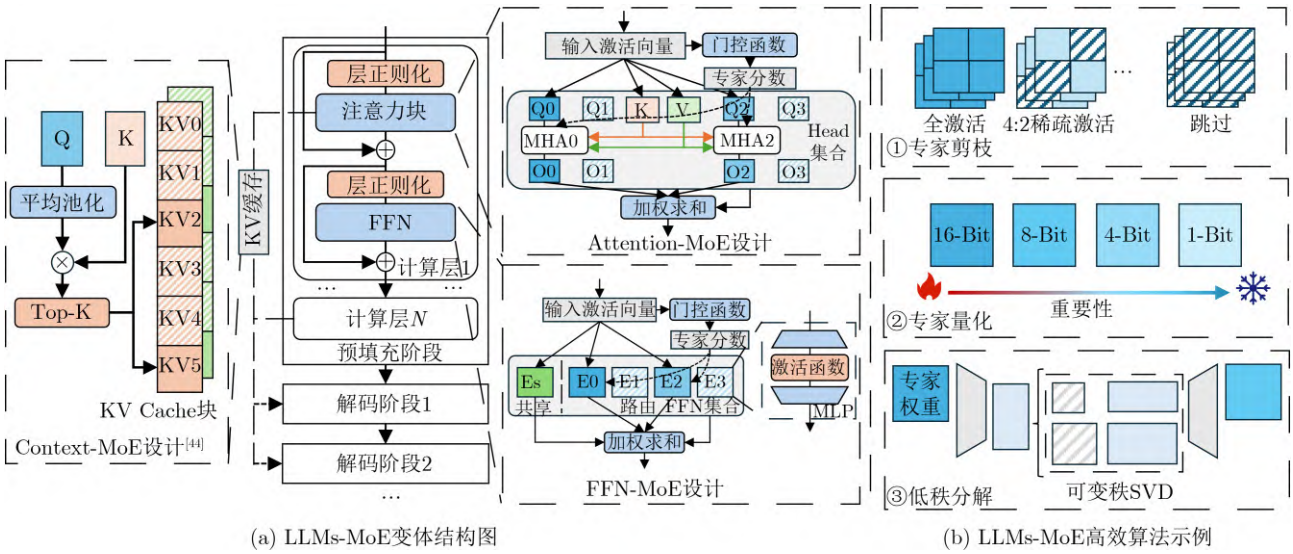

(a) LLMs-MoE变体结构图 (b) LLMs-MoE高效算法示例

图 2 混合专家大模型算法演进图

中国知网 https://www.cnki.net

Xie等人[47]利用MoE模型的动态路由策略信息来指导剪枝过程，通过计算每个权重的重要性分数，基于权重的大小、输入激活的范数以及路由权重，按照分数从低到高进行剪枝，并在剪枝后通过专家级的知识蒸馏恢复模型性能；

(2)在量化方面，与剪枝技术遇到的问题类似，对于静态量化方法，稠密模型量化可统一校准[63–65]，而MoE中专家子网络参数分布异质性与动态路由激活权重动态性，导致静态量化策略在不同数据集会有显著性能差异。Frantar等人[53]发现MoE模型对量化噪声具有高鲁棒性，可通过自定义压缩格式与GPU解码内核实现高效压缩推理，基于Hessian矩阵的层维度量化、利用自然稀疏性进行熵编码、字典设计与GPU内核协同设计实现高压缩比；Huang等人[57]观察到MoE模型中不同专家权重的敏感度差异，采用自适应秩选择策略和迭代优化算法来弥补量化带来的精度损失，并且开发了硬件友好的3 bit内核以实现高效的推理；

(3)在低秩分解方面，传统低秩分解方法依赖全局参数的低秩假设[66]，这与MoE架构的专家独立性原则存在本质冲突。Yang等人[58]提出专家特异性的分层秩分配策略：通过分析每个专家的重要性来分配不同的秩，然后应用奇异值分解(SVD)对单个专家参数进行局部压缩，这种方法通过非均匀的秩分配策略，使得重要专家保留更多参数；Gu等人[60]则从参数空间分解角度切入，提出基权重-增量权重(Base-Delta)分解框架：利用Fisher信息矩阵进行专家参数聚类生成共享基权重，通过低秩逼近压缩专家特异性的delta权重，最终引入半动态结构化剪枝实现参数削减，该方法无须额外训练即可实现高压缩比。

2.3 混合专家大模型的应用与挑战

MoE架构作为大语言模型领域的重要范式创新，已在多个应用维度展现出显著的技术突破。在自然语言处理领域，MoE通过专家网络的动态组合机制有效提升了模型的领域适应性。采用Top-2专家动态激活机制的Mixtral-8x7B[23]在知识问答、文本理解与多语言翻译等任务中展现出相较于Mixtral-7B基线的显著性能提升，同时在与LLaMA2-70B[8]模型的对比实验中，其推理效率提升约6倍，且任务精度保持统计无差异。在模型微调优化层面，MoE与参数高效微调技术的融合展现出独特优势。MoCLE[67]将MoE与LoRA专家和通用专家集成，根据指令集激活任务特定的模型参数，缓解了数据冲突。针对多模态学习场景，MoE框架被应用于处理和整合图像、文本等多种数据类型。LMoE[68]模型专为多模态学习设计，其中MoE采用对比损失和基于熵的正则化技术来解决多模推理系统固有的负载平衡挑战。

尽管MoE架构在算法层面展现出显著优势，但其动态激活特性对计算系统提出了多维挑战，在训练推理部署中的实际效能高度依赖底层系统对分布式集群、层次化存储和动态负载的精准调度。在服务器端，LLMs的训练推理需引入多卡并行策略，计算节点在运行时将引入大量的互联通信开销，而MoE模型将专家子网络分散在不同设备上，使训练推理的通信开销随模型规模、集群数量与输入数据量显著增长(通信开销占总延迟的30%～50%)[69]。在边缘端，显存容量限制而导致的计算效率下降问题也尤为突出[70]。通常，MoE模型需将所有专家参数加载至内存，导致内存需求远高于实际激活参数量。例如，Mixtral 8×7B虽激活部分专家，但其内存占用仍相当于47B参数的稠密模型，对于显存受限场景，需要频繁从CPU内存中搬移激活的专家权重，而这种权重拷贝操作可能占据推理时间的60%以上[70]。同时，专家负载的动态性与不均匀性也成为训练推理的瓶颈。MoE模型中专家动态分配的特性导致跨设备通信频繁，并行策略若设计不当易引发大量的通信开销[71–74]。

针对上述问题，已有许多工作在系统与架构层面开展了全面研究，本文将重点围绕数据通信优化、层次化存储优化以及计算负载优化3个核心方向展开系统分析，揭示不同技术路径间的耦合关系及其对MoE大模型部署应用的影响。

3　混合专家大模型部署优化策略概览

近年来，针对MoE模型已经出现了许多在部署方面的技术优化。相较于直接从算法结构本身进行优化，系统部署优化具有更高的实施效率和模型适配性，可在保持模型架构完整性的前提下实现计算效率与资源消耗的综合优化。当前主流的部署优化策略主要围绕分布式计算效率提升和硬件资源约束突破两个维度展开，形成了专家并行策略(expert parallelism)与专家卸载策略(expert offloading)两大技术体系。

值得注意的是，在系统部署环节，若无法有效协调专家并行、内存分配与硬件资源适配，模型的计算优势将被系统层面的低效抵消，甚至因通信瓶颈或负载不均导致性能劣化。图3(a)展示了专家并行策略的工作机制。在这一策略中，各个专家被分配到不同的计算节点进行并行计算，由于门控函数的分配和调度不均衡，部分GPU的计算资源未能充分利用，而部分计算节点可能会出现超负荷，影

中国知网　https://www.cnki.net

响了系统整体效率；图3(b)则展示了专家卸载策略的工作机制。在此策略下，部分专家权重将被卸载到CPU内存中，而某些专家可能仅被极少数序列张量激活，这就需要频繁从CPU内存中读取对应的专家权重到GPU进行计算。同时，由于计算任务的稀疏性，GPU计算资源并未得到充分利用，这导致了资源分配的不均衡，造成了性能的浪费和潜在的计算瓶颈。针对不同的部署策略，还需要有针对性的优化方法。

3.1 专家并行策略

专家并行策略旨在通过分布式专家网路计算，提升模型训练与推理效率。其核心在于将模型中不同专家子网络分配到多个计算设备(如GPU或服务器节点)上，通过动态路由机制实现专家间的协同计算，减少单台设备上专家反复读取带来的访问开销。这种策略的优化重点在于降低系统的互联通信开销，具体优化路径包括自动并行策略[71–74]、计算节点通信优化[72,74–79]、计算节点负载优化[80]等。

3.2 专家卸载策略

专家卸载策略聚焦于显存受限场景，通过层次化存储架构实现更大规模的MoE模型部署。该策略的优化对象为层级化资源的协调管理方法，需要考虑不同任务在不同层级的存储或计算资源利用效率，以及专家模块按需加载或迁移至不同层级硬件的开销，结合负载均衡以及内存压缩技术缓解算力以及显存带宽的压力。具体路径包括专家缓存[70,81–82]与预取[83–85]、专家队列调度设计[54,86,87]、CPU-GPU异构计算[88–91]等。

4 系统优化技术

MoE模型的系统优化技术是解决其规模化部署中通信、存储与计算资源矛盾的核心手段。本章从激活数据通信优化、权重搬移优化与计算负载均衡3个维度，剖析当前主流技术路径及其理论创新(图4展示了系统层优化的技术脉络)。同时，本章最后将介绍开源社区所贡献的部署优化工具。

4.1 激活数据通信优化

在MoE模型的分布式训练与推理过程中，跨计算节点的激活数据传输构成了系统性性能瓶颈。传输通信的主要原因在于输入与专家的差异化分布，

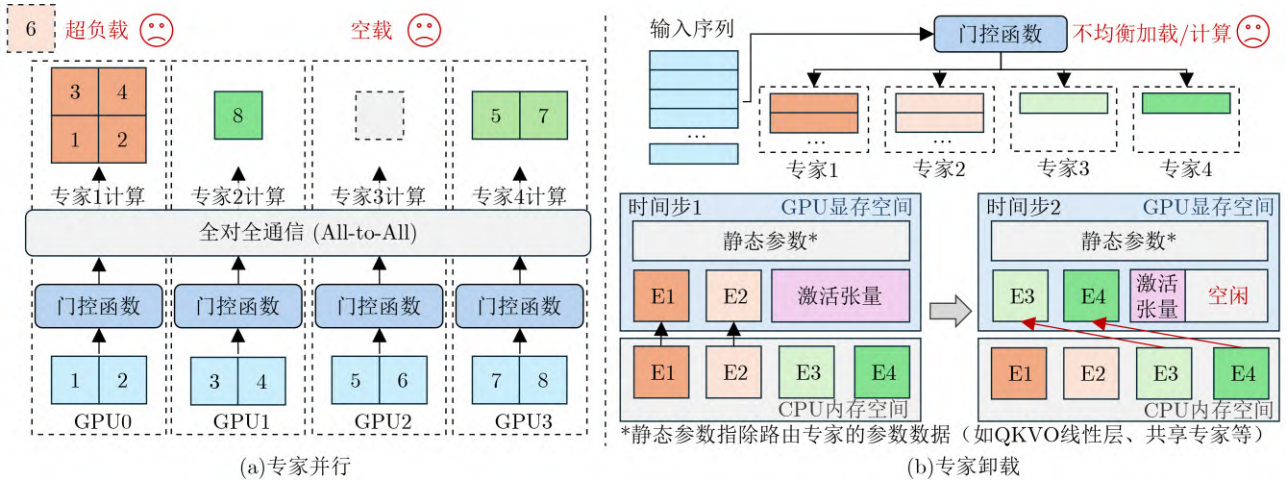

图 3 专家并行与专家卸载的系统瓶颈示意图

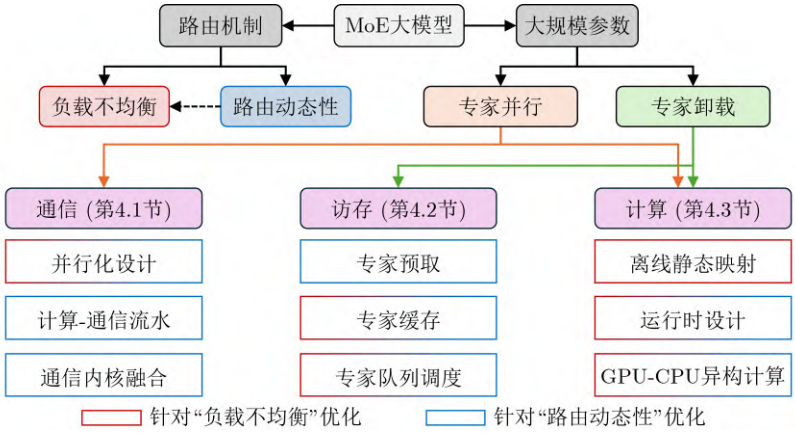

图 4 混合专家部署优化技术路径

中国知网 https://www.cnki.net

这种动态匹配关系导致各计算节点间必须通过频繁的激活数据同步来维持计算一致性。特别地，在专家并行中，这种“激活向量-激活专家”跨节点通信模式在工程实现中通常表现为全对全(All-to-All)通信，其在部署中时常占据主导。

以NVIDIA集群通信库(NCCL)的典型实现为例[92]，非线性增长的通信量在大规模分布式训练中极易引发拥塞，尤其当集群规模与专家数量同步扩张时，通信延时与资源竞争问题会显著拖累整体训练效率[93]。这种增长趋势对大规模分布式训练构成了显著的挑战，因为随着集群规模和专家数量的增加，通信开销会迅速变得难以管理。

针对上述挑战，当前研究方案主要从3个维度展开系统性优化(如图5所示)：

(1)自动并行策略：结合硬件拓扑结构(如服务器内与服务器间)与任务特征，分配专家组在计算节点的映射策略，优先在高速链路(如节点内NVSwitch)完成密集型通信，同时采用混合并行策略(如数据并行+专家并行)减少跨节点通信量；

(2)通信-计算流水化设计：在计算图中插入异步通信操作，通过完成流水线级数更大且更细致的数据流调度策略，使通信操作能被计算操作掩盖；

(3)通信算子融合：借助NCCL[92]、NVSHMEM[94]等通信库，将通信事务与算子融合到同一内核，减少独立通信启动开销[95]。如图5(c)所示，通过重写融合内核，有机会将不同通信和计算操作分解为更细粒度的操作，从而减少“计算-通信”流水气泡。

4.1.1 自动并行策略

在自动并行策略设计方面，针对现有系统的静态执行策略，如静态并行和流水线设计无法适应MoE模型在训练运行时动态变化的工作负载，Hwang等人[74]归纳了3种并行策略，即数据并行、张量并行与专家并行方法不同组合的理论通信开销上界，并设计一种动态自适应的并行和流水线策略，能够在每次迭代中动态切换并行策略，且无须额外的切换开销。Zhai等人[71]通过对工作负载性能建模，离线预测通信和计算开销，选择最优的专家放置策略，并结合运行时负载动态调整执行计划，使具有高效的训练效率。对于GPU数目远大于专家数目的场景，Pan等人[72]引入专家分片并行的概念(Expert Shard Parallelism, ESP)即单个专家被分发到多个GPU上，而ESP引入了ESP-All Gather和ESP-Reduce Scatter操作，能够与EP All-to-All操作重叠，从而减少了整体通信时间。

对于大规模集群设计，鉴于跨集群数据交互可能产生的消息路径拥挤和更高的流量成本问题，Yu等人[96]通过分层All-to-All通信策略解决了计算节点间的通信问题，其在同一节点内的GPU之间利用NVLink进行数据交换，确保数据快速传输，在不同节点的GPU之间传输数据时，其首先在节点内传输数据，然后在相同等级的NIC之间进行跨集群通信，避免通过高延迟的交换机或网络设备。在分层通信策略的基础上，Rajbhandari等人[24]开发了自定义的通信接口SCCL (Synthesizing Optimal Collective Algorithms)[99]替代传统的NCCL通信库，进一步降低通信事务启动的开销。类似地，DeepSeek-AI团队[27]设计了DeepEP专家并行通信库，通过适配NVLink与RDMA异构网络场景，显著提升了跨节点通信效率，并实现了面向MoE模型FP8低精度训练的All-to-All通信优化。

4.1.2 通信-计算流水设计

在通信-计算流水设计方面，考虑到张量并行中All-Reduce操作与专家并行中All-to-All操作可能

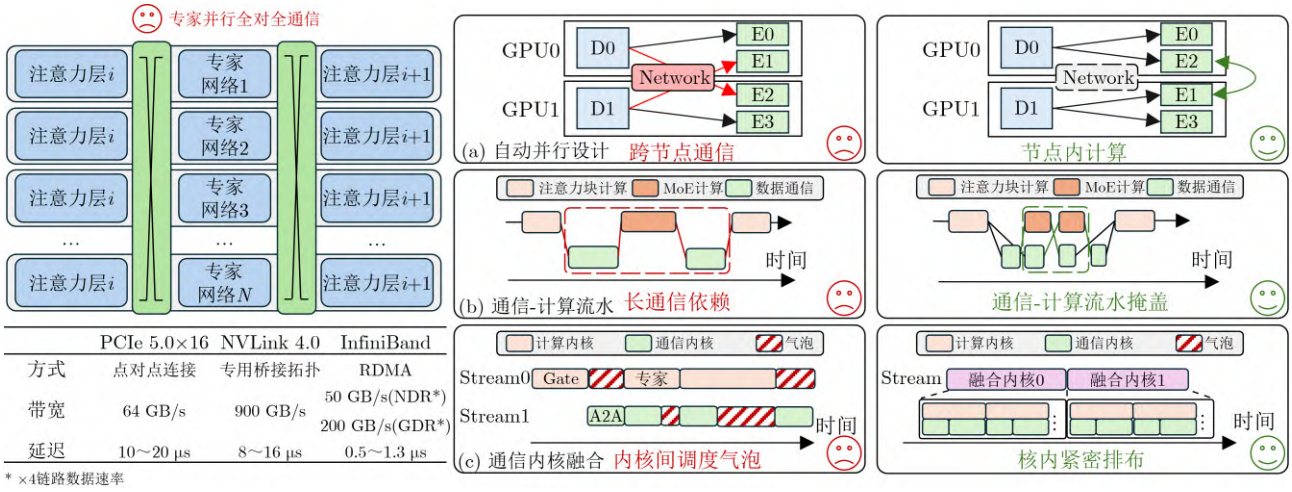

图 5 激活数据通信优化技术示意图

中国知网　https://www.cnki.net

的阻塞问题，Li等人[76]将通信操作分割成小的微操作(Micro-ops)，并使用流水线执行，确保All-to-All操作在执行过程中能够获得完整的网络带宽。Jiang等人[75]通过在正向传播中对非MoE计算进行分区和流水线处理，以及在反向传递中区分权重梯度与激活梯度计算，实现了与All-to-All通信的重叠。对于通信与计算流水线处理，Shi等人[77]发现配置固定流水线级数，导致系统在不同的计算和通信负载下存在操作气泡(Bubble)，文章通过性能模型来预测通信和计算时间，并根据这些模型选择最优的流水线级数，进一步减少通信开销。

4.1.3 通信内核融合

在通信内核融合方面，Punniyamurthy等人[95]指出CPU发起的通信方式在处理依赖性强的通信和计算时难以实现有效重叠，导致通信延迟暴露，于是通过在GPU内核中直接发起网络通信事务，即计算-通信融合实现计算和通信重叠，从而隐藏通信内核启动延迟。Wang等人[78]通过利用GPU间共享内存技术，使用NVSHMEM库[94]将通信和计算融合到CUDA核函数中，消除了传统All-to-All操作带来的跨GPU同步开销，并通过线程块间和线程块内的重叠机制隐藏远程数据访问开销，提升GPU利用率。Zhang等人[79]通过细粒度通信计算重叠解决MoE模型分布式训练中通信开销大的问题。其引入共享张量依赖解析和自适应工作负载分配机制，前者通过分解和重新调度共享张量消除通信计算的粒度不匹配，后者在融合GPU内核中动态平衡通信与计算工作负载以优化延迟隐藏。

4.2 专家权重搬移优化

在存储资源受限的应用场景中，MoE大语言模型的万亿级参数量对运行时显存管理构成挑战。常规解决方案将非激活专家参数卸载至CPU内存或固态存储介质(Solid State Disk, SSD)。然而，受限于MoE的动态稀疏激活特性，专家参数访问呈现不确定性和时间动态性特征。当请求所需的专家权重未驻留于GPU显存或CPU内存时，需触发跨存储层级的权重搬移。这种强数据依赖的串行拷贝成为性能瓶颈，如GPU因等待权重加载而空转[71]、CPU内存非连续访问[88]等，在模型专家参数量巨大的情况下，跨层级迁移在典型工作负载下可造成40%的端到端延迟增加[83,100]。

针对上述挑战，当前研究主要从以下3个维度展开优化(如图6所示)：

(1)专家预取：通过统计分析模型训练推理过程中专家激活的分布规律，并构建轻量激活预测模型，在训练推理时将高概率激活的专家参数提前加载至GPU显存；

(2)专家缓存：根据专家的使用频率、最近访问时间等因素，设计缓存中的专家权重替换策略，乃至设计可变的缓存容量占比，确保不同任务下常用专家能够快速被访问，提高系统的响应速度；

(3)缓存队列调度优化：通过构建优先级任务队列与并行加载流水线，优化权重搬移的调度粒度。例如，将预取任务拆分为高优先级(当前推理需立即加载的专家)与低优先级(预测未来可能激活的专家)，利用GPU DMA引擎实现异步传输。同时，结合硬件多队列机制(如GPU Direct Storage)，将SSD至GPU的数据流并行化，以掩盖存储访问延迟。

4.2.1 专家预取设计

在专家预取方面，Hwang等人[83]针对专家网络激活情况对门控函数的强依赖性，引入了预门控函数，通过微调与训练模型，将专家选择与专家执行阶段解耦，允许CPU-GPU数据传输与计算重叠，从而显著降低延迟。该设计使系统能够在使用单个

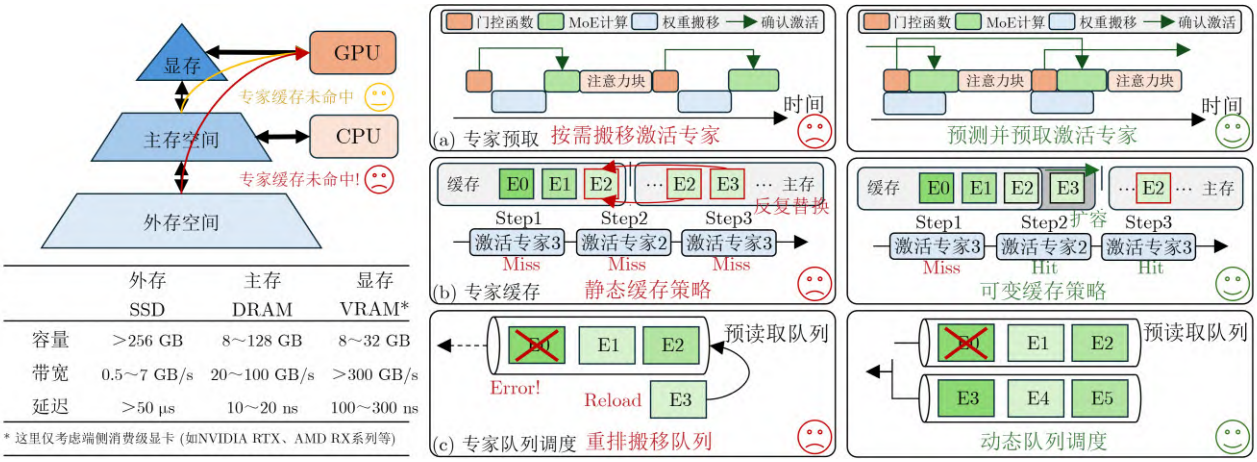

图 6 专家权重搬移优化技术示意图

中国知网 https://www.cnki.net

GPU的情况下实现高性能，并且没有影响模型精度。Du等人[84]通过数据感知的方式动态管理GPU显存和CPU内存中的专家权重，具体而言，设计了离线训练的哈希函数(Hash Function)来预测每个批次中需要激活的专家，并据此动态加载和卸载专家，从而显著提高了模型的推理效率和内存利用率。Song等人[85]发现现有缓存卸载方案因被动处理缓存未命中导致性能显著下降，于是通过利用中间结果预测后续专家使用情况，主动提前获取专家参数，消除被动缓存未命中，减少性能开销。同时采用学习型预测器结合步长预取机制，通过分块预取、早期抢占和重新排序推理等方法协调预取与推理过程。

4.2.2 专家缓存设计

在专家缓存设计方面，由于不同层和词元之间专家加载的异质性，Zhong等人[70]利用黑塞矩阵(Hessian Matrix)分析专家激活的敏感性来动态调整激活的专家数量，并提出了一种基于动态规划的缓存分配方法，按需加载每层的必要专家，并动态调整每层的缓存大小提高缓存命中概率。He等人[81]引入专家缓存引擎(ECE)，通过预测局部性感知的专家缓存策略提高缓存命中率，同时实施动态词元调度策略，将具有相似路由路径的输入词元序列重新分组以减少专家激活数量。Eliseev等人[82]设计了一种MoE特定的卸载策略，利用LRU缓存减少GPU-RAM通信，并通过投机专家提取(Speculative Expert Loading)提前猜测所需的专家以更好地重叠专家加载与计算。

4.2.3 专家队列调度优化

在队列调度优化方面，Fang等人[87]设计了一种通过专家感知的多批处理流水线范式，显著减少了推理过程中的延迟。具体方法是通过在多个批次之间共享权重，调整专家的计算顺序，以及根据专家的计算和I/O需求动态地进行专家预取，从而最小化流水线中的气泡。考虑到显存受限GPU节点的MoE模型微调需求，Wei等人[86]引入层次化加载策略和需求优先调度策略，通过利用专家的流行度和计算亲和性来分配优先的计算任务，减少GPU显存与CPU内存之间的数据传输量。

此外，结合算法压缩算法，能进一步缓解专家卸载队列的延迟问题。Tang等人[54]通过不同层级的混合精度专家卸载来加速MoE模型的推理过程，在词元级(Token-level)使用低精度版本替换不重要的缓存缺失专家以减少加载延迟，在层级(Layer-level)自适应地预取专家，利用混合精度预取优化计算与通信的重叠，在序列级(Sequence-level)采用多维专家缓存策略，结合模型特定策略和混合精度特性高效管理专家缓存。

4.3 混合专家计算负载优化

MoE模型在训练与推理过程中普遍面临负载不均衡的挑战，其本质源于动态路由特性与任务请求的时空差异。具体而言，该问题表现为两个层面：其一，稀疏路由机制导致专家激活频率呈现显著长尾分布，高频专家处于饱和状态而多数专家利用率不足；其二，推理请求的动态分布(如不同的任务请求或长尾任务分布)可能引发资源竞争，加剧设备间负载失衡。为应对上述挑战，负载均衡优化通常包括以下3方面(如图7所示)：

(1)离线策略设计：通过预分析专家激活模式与硬件拓扑特征，在算子设计与数据流映射阶段嵌入负载均衡约束，如基于先验预测的硬件感知的专家分组映射[71,101]、在分布式训练推理中采用专家分片(Expert Sharding)[72]策略等，结合显存与计算资源约束提前分配专家到不同设备；

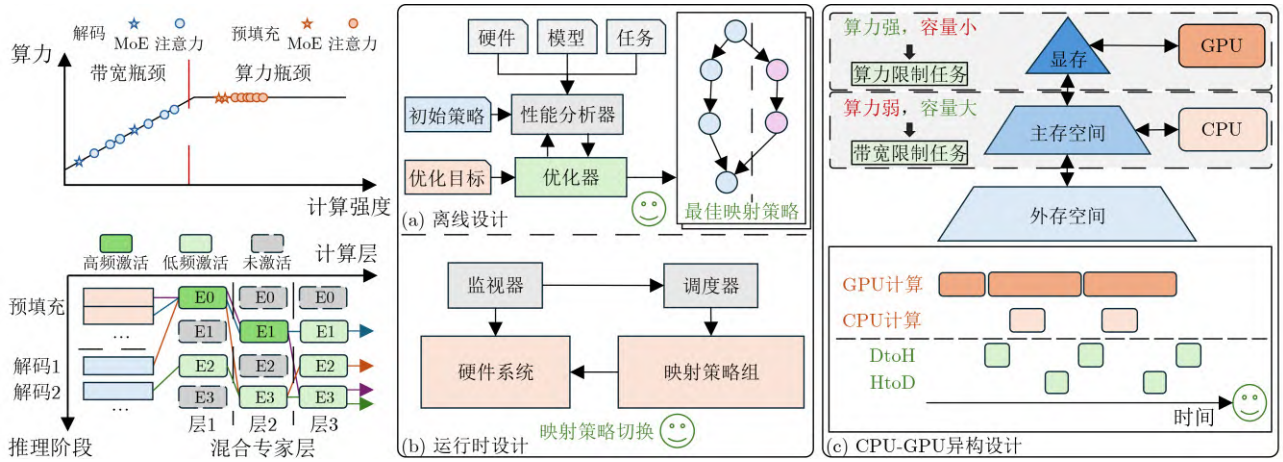

图 7 混合专家计算负载优化技术示意图

中国知网　https://www.cnki.net

(2)运行时专家分配策略：该层面聚焦于构建在线负载监测与弹性调度系统，如专家实例弹性扩缩容[101,102]、任务队列优先级调度[72]等，在计算过程中动态调整资源分配，优化专家分配和放置策略，避免出现某个专家网络被过度使用，而其他专家网络闲置的情况，提高计算资源的利用率；

(3)CPU-GPU异构计算卸载：针对边缘设备等资源受限环境，提出CPU-GPU协同计算框架：将高计算密度任务留在GPU中运行，低计算密度任务卸载至CPU处理。

4.3.1 离线策略设计

在离线设计方面，Go等人[80]利用整数线性规划(ILP)来建模专家放置问题，考虑了词元路由的依赖关系和跨层的路由模式，以最小化GPU之间的通信成本并平衡不同专家处理的计算负载。Yu等人[96]系统通过弹性训练策略，根据任务的负载动态调整训练节点的数量，以解决多任务训练中的负载不均衡问题。具体方法是，对于轻负载任务，合并多个节点以提高资源利用率；对于重负载任务，增加节点以分担计算压力，并采用数据并行来确保参数同步。考虑到MoE计算中的稀疏激活特性，Gale等人[97]基于cuBLAS[98]开发了新的块稀疏GPU计算内核，具体方法包括使用块稀疏矩阵乘法来处理MoE中的专家计算，通过混合阻塞压缩稀疏行(BCSR)和块坐标(BCOO)格式来提高稀疏矩阵乘法的效率，并引入转置索引以高效迭代块稀疏矩阵。

4.3.2 运行时策略设计

在运行时专家分配策略方面，Zhai等人[71]通过建立性能模型，分析了分布式训练中的挑战，如动态负载不平衡、同步执行效率低下和网络拥塞等问题，提出了动态影子策略与细粒度调度以及避免拥塞的专家选择策略等优化方法。在编译层面，Kossmann等人[103]设计了一种动态重编译的方法，根据每个专家实际需要的容量动态调整其张量大小，从而减少计算需求和内存使用。具体方法是通过测量每个专家被分配的样本数量，并根据这些数据动态调整容量因子。此外，文章还提出了样本分配缓存的优化方法，利用门控路由函数在训练早期对样本分配的收敛性，缓存样本分配以消除门控路由函数和专家之间的依赖，提高并行度。Li等人[104]提出了一种针对GPU上不规则工作负载的静态批处理框架，在MoE负载均衡优化方面，文献指出通过设计专家排序算法，将忙碌和非忙碌的专家交错排列，以平衡计算能力和内存带宽的使用。具体方法包括采用半区间策略等简单策略来优化专家的排列顺序，从而提高性能。此外，文献还引入了词元索引数组来消除词元序列复制开销，并利用最新的GPU优化技术，如异步WGMMA指令和两阶段流水线，以最大化Tensor Core的计算性能。

4.3.3 GPU-CPU异构设计

在GPU-CPU异构系统中，CPU可以承担部分的专家模型推理计算，Cao等人[89]基于Roofline模型扩展归纳了CPU-GPU-I/O分层性能模型，并总结出不同负载下I/O事务对CPU-GPU实际计算利用率的影响，帮助识别系统性能瓶颈，并指导调度策略的优化，在系统设计中通过交错GPU计算、CPU计算和I/O事件以达到更高的整体吞吐量。Kamahori等人[90]通过初始化阶段将非专家层和部分专家层权重分配到GPU内存，其余存储在CPU内存，并在执行阶段根据输入大小和设备处理延迟动态选择最优执行策略。系统还基于专家热度放置频繁使用的专家到GPU，并设计了专用的CPU计算内核。鉴于专家卸载导致的频繁数据迁移， Zhang等人[88]提出了一种CPU-GPU混合加速引擎，其核心在预填充阶段根据输入序列动态调整专家分配，以优化解码阶段的专家重用，并在解码阶段预测激活的专家情况，并在CPU中做预计算，从而减少I/O开销。

值得关注的是，除上述计算负载优化方法外，为了防止某些专家在路由过程中被过度加载，系统会对每个专家设置一个容量因子[31](capacity factor)，即该专家在一次路由中最多可处理的词元数量。超过容量因子的词元会被标记，并通过残差连接(skip connection)绕过 MoE 层，在不参与专家计算的情况下继续向后传播。这一词元丢弃(token drop)策略不仅有效避免了单个专家的过载，也在训练和推理时显著降低了尾部延迟(tail latency)，提高了整体吞吐量和系统稳定性。

4.4 开源社区建设

表2展示了针对MoE部署的开源项目。这些优化工具链从多角度出发，解决了实际模型训练与推理过程中的问题，总体呈现出分层次与强聚焦的特征，不同项目基于各自的技术路径，形成了互补的解决方案体系。

在基础框架层面，DeepSpeed[24], vLLM[106]和SGLang[107]等项目通过集成专家并行与动态路由技术，在原有成熟框架基础上进一步降低了MoE模型的部署难度。在通信优化层面，微软开源的Tutel[74]重构了NCCL通信协议，有效解决了MoE训练并行策略切换造成的通信开销瓶颈。计算效率优化方面，MegaBlock[97]深度优化cuBLAS库[98]实现不规则稀疏矩阵乘的高效计算，缓解单卡上专家激活不

中国知网 https://www.cnki.net

表 2　面向混合专家大模型系统优化开源项目表

名称	年份	组织/单位	通信优化	内存优化	计算优化	链接
EPLB[151]	2025	DeepSeek-AI			√	https://github.com/deepseek-ai/eplb
DeepEP[150]	2025	DeepSeek-AI	√			https://github.com/deepseek-ai/DeepEP
Flux[141]	2025	ByteDance	√		√	https://github.com/bytedance/flux
Ktransformer[108]	2025	KV-Cache		√	√	https://github.com/kvcache-ai/ktransformers
llama.cpp[149]	2024	GGML		√	√	https://github.com/ggml-org/llama.cpp
Megatron-LM-MoE[146]	2023	NVIDIA	√		√	https://github.com/NVIDIA/Megatron-LM
DeepSpeed-MoE[24]	2022	Microsoft	√		√	https://github.com/deepspeedai/DeepSpeed
Tutel[74]	2023	Microsoft	√		√	https://github.com/microsoft/Tutel
MegaBlocks[97]	2023	Stanford			√	https://github.com/databricks/megablocks
vLLM[106]	2023	vLLM		√	√	https://github.com/vllm-project/vllm
SGLang[107]	2023	UCB, Stanford			√	https://github.com/sgl-project/sglang
TensorRT-LLM[147]	2025	NVIDIA			√	https://github.com/NVIDIA/TensorRT-LLM
LMDeploy[148]	2023	InternLM		√	√	https://github.com/InternLM/lmdeploy
FastMoE[72]	2025	THU	√		√	https://github.com/laekov/fastmoe
Huggingface-MoE[152]	2023	Huggingface				https://huggingface.co
Fairseq-MoE[153]	2021	Meta				https://github.com/facebookresearch/fairseq

均衡计算带来的资源利用率下降问题。针对负载均衡问题，FasterMoE[72]基于影子进程的动态迁移机制，实现多GPU间的零拷贝负载切换。在资源受限部署优化方面，KTransformers[108]通过权重卸载与计算流重组，实现了如DeepseekV3-671B等超大规模模型在单卡GPU系统上的运行。值得注意的是，Awesome-MoE-Inference[109]项目构建了系统化的MoE推理优化知识框架，形成了较为完整的MoE技术生态图谱，为研究人员与开发者提供了可参考的指导。

综上，这些开源项目通过聚焦MoE技术栈不同层面的关键问题，形成相互支撑的协同创新网络，共同推动MoE大模型的工程化落地与广泛应用。

4.5　系统优化方法对比

表3展示了具体的系统优化方法与性能数据，其在MoE部署优化上各有侧重。得益于NVIDIA自身研发平台，TensorRT-LLM能很好地契合NVIDIA GPU特性，通过将混合并行与最新量化方案(FP8类型)相结合，在H100 GPU上可达到极高吞吐(约21k token/s)。DeepSpeed-MoE 着重在跨多GPU的并行策略和通信调度，除了对专家并行的增量支持外，还设计了融合的TopK门控核和通信优化策略，在多种GPU集群组合下都可获得2×以上的吞吐收益。vLLM 强调在线服务中的调度与资源利用，通过预填充分块(chunked prefill)、解码优先调度等策略改善延迟。值得注意的是，vLLM底层MoE计算使用基于Triton内核，对单节点和小规模多GPU部署进行了针对优化。在适用性上，TensorRT-LLM 对 NVIDIA 新硬件优化友好，但对非NVIDIA设备兼容性有限，而DeepSpeed-MoE和vLLM 目前已经支持AMD、Intel XPU、华为昇腾(Ascend NPU)等硬件架构，对异构节点适配良好。

在集群通信优化方面，Tutel在512卡NVIDIA A100 80GB平台上，单层推理速度比传统实现快8.49×，在端到端推理上可获得约40%的吞吐增益。Flux 库则聚焦通信-计算重叠，其在典型MoE层中实现了近2×速度提升。虽然Tutel和Flux 擅长对大规模集群并行通信进行优化，然而在实时推理服务场景不及前者框架。

5　硬件架构优化技术

MoE模型的计算架构优化旨在通过硬件-算法协同设计，解决大规模参数与动态路由带来的带宽-计算效率瓶颈。本节从激活动态性适配[110–112]、带宽限制突破[113–115]与面向存储计算硬件设计[116–118]三个维度，系统阐述当前硬件架构技术路径与创新方法(部分硬件设计方案如图8所示)。

5.1　针对专家激活动态性

在MoE模型中，专家的激活模式通常呈现高度的稀疏性，且随着输入数据的变化，激活的专家集也在不断变化。这种激活动态性导致了计算资源的浪费，因此需要针对专家激活模式进行动态适配和

中国知网　https://www.cnki.net

表 3 部分开源系统优化方法与性能数据

名称	实验硬件平台	基线	并行策略*	部分关键优化技术	性能表现
TensorRT-LLM[147]	2×NVIDIA H100 80 GB	-	TP+EP	混合并行模式	最高38.4 请求/秒
DeepSpeed-MoE[24]	8/16/32×NVIDIA V100 32 GB	PyTorch	DP+TP+EP	稀疏映射表简化TopK路由	端到端加速2–3.2×
vLLM[106]	4×NVIDIA A100 40 GB	PyTorch	DP+TP+PP+EP	解码优先调度，预填充分块	单层最大加速4.0×
Tutel[74]	512×NVIDIA A100 80 GB	Fairseq[153]	DP+TP+EP	并行策略随路由自适应切换	单层加速8.49×；端到端平均加速1.4×
Flux[141]	8×NVIDIA H100 80 GB	Megatron[146]	TP+EP	通信-计算内核细粒度融合	单层加速1.96×；端到端平均加速1.71×

* DP – 数据并行；PP – 流水线并行；TP – 张量并行；EP – 专家并行

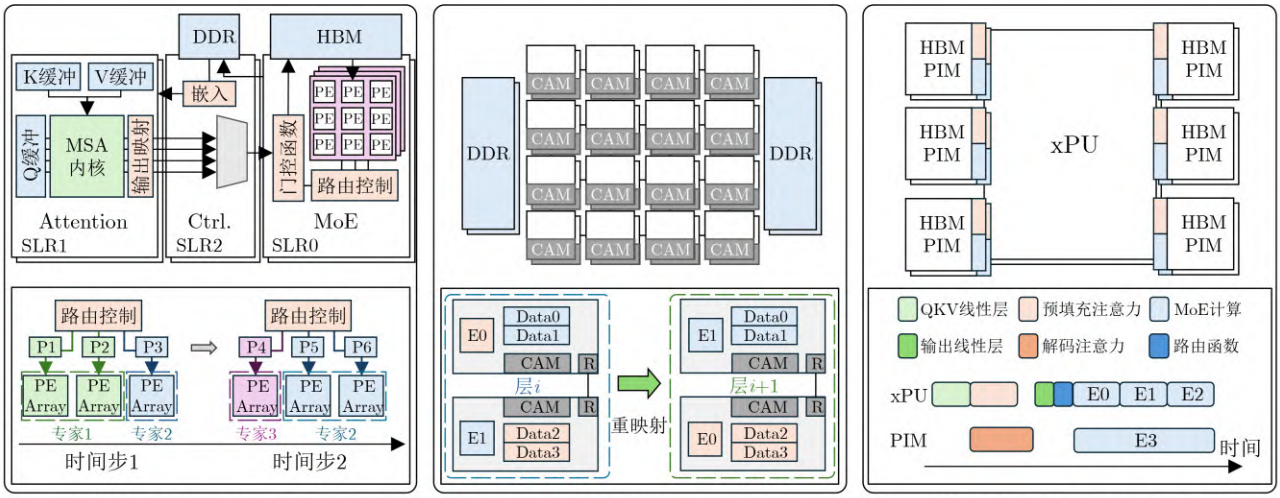

(a) FPGA适配MoE-ViT计算特性[110] (b) Chiplet与CAM缓解重排与通信开销[115] (c) xPU-PIM异构适配不同计算强度[117]

图 8 面向混合专家模型硬件架构设计示意图

优化。通过设计适应这种动态变化的硬件架构，可以提高计算效率并降低延迟。

Dong等人[110]采用了包含混合计算模式的异构架构，其中包括针对延迟优化的全流式注意力内核(Fully Streaming Attention Kernel)和针对资源效率优化的可重用线性内核(Reusable Linear Kernel)，如图8(a)所示，可重用线性内核通过路由控制将每一个块数据分配给独立的处理阵列(PE Array)，并载入对应的激活专家参数，这种设计能在MoE动态路由场景下保证计算单元的高利用率。Park等人[111]提出基于乱序执行的稀疏混合专家。设计了Out-of-Order SMoE路由器并结合单跳(SS)和双跳(DS)异构核心架构以降低MoE计算的延迟，该路由器包含专家决策SIMD单元、专家级批量路由调度器和内存管理单元，用于管理专家级批量路由调度、避免内存冲突和平衡计算核心的工作负载，以降低数据传输延迟。针对边缘计算场景下的部署需求，Lin等人[112]提出了稀疏感知的FPGA加速方案。研究揭示了专家激活路径高度偏斜的性质，其结合专家权重和激活路径的稀疏性，使其有效减少内存占用并提高推理速度。

5.2 针对参数带宽限制问题

在MoE模型中，专家参数庞大且高度稀疏，往往导致带宽瓶颈，尤其是在分布式计算或内存带宽有限的情况下。因此，需要通过创新的计算重排和数据调度方案，降低带宽消耗，并提高参数的重用率，从而提升计算效率。

Liang等人[114]提出一种计算重排方案，将MoE层的计算从按词元序列顺序执行改为按专家顺序执行，并引入双缓冲架构设计：当计算单元处理当前专家缓冲区时，预取单元同步加载下一专家参数，通过硬件级缓冲区切换实现零周期开销的任务调度，有效掩盖片外内存访问延迟。基于上述动态调度理念，Sarkar等人[113]提出面向视觉任务的专家分组执行策略。其通过建立图像块(Patch)与专家组的动态映射关系，通过空间维度的任务分组实现参数复用，避免在任务切换时频繁地加载和卸载专家权重。如图8(b)所示，He等人[115]结合内容寻址

中国知网 https://www.cnki.net

存储器(CAM)与专家热度预测模型加速推理。其中前者支持并行搜索机制消除显式数据重排操作，后者通过预判下一时间步跨芯片数据传输路径，并通过专家网络的重新映射，有效缓解了Chiplet间网络拥塞问题。

5.3 针对存储-计算架构限制问题

随着MoE模型推理任务的增多，计算和存储需求的不匹配，导致了传统计算架构难以应对大规模的内存访问。为了优化存储和计算资源的配置，设计专门针对存储计算的硬件架构成为关键。尤其是在推理服务中，不同层的算术强度差异显著，因此需要将计算任务按需分配给不同类型的处理单元。

Yun等人[117]针对推理服务中MoE层与注意力层的算术强度差异性，提出动态处理器分配框架：将高算术强度任务映射至xPU等传统处理器，而低算术强度操作则分配至逻辑存内处理存储(Logic-PIM)设备。通过三维堆叠技术增强存储与逻辑单元间的垂直通信带宽，Logic-PIM可有效处理频繁的轻量级计算。这种按需分配策略在降低DRAM访问开销的同时，实现了计算资源的优化配置(如图8(c)所示)。此外，Kim等人[116]提出基于专家热度的GPU-NDP协同架构。通过设定专家激活频率阈值，系统将高激活的“热”专家分配至GPU处理，低激活的“冷”专家则由近数据处理器(NDP)执行。针对多NDP设备场景，采用改进型轮询调度算法动态分配计算负载，通过量化负载均衡度指标实现资源的高效利用。Wu等人[118]通过设计感知瓶颈的任务卸载方法解决NPU和PIM之间的负载不平衡问题，并设计了一种近内存控制器的数据浓缩器以提高数据传输效率，包括利用PIM的全并行性处理内存受限的专家计算，并通过动态调度算法优化任务分配。

5.4 架构优化方法对比

表4展示了不同架构的参数与性能数据，各方案在技术路径上从软-硬协同到异构协同等方向优化了MoE推理性能。FLAME通过片上M:N剪枝和预取，在FPGA上充分利用MoE稀疏性加速Transformer推理，适合模型规模适中但硬件资源紧张的场景。MoNDE、Duplex和PIMoE都利用了存内或近存处理单元，旨在减少激活专家读取的额外开销，分别较仅GPU配置获得最多6.7×，2.67×与8.47×性能提升。Edge-MoE和UbiMoE专注于视觉Transformer的MoE加速，在Xilinx FPGA上均取得了明显的吞吐率和能效提升。值得注意的是，Duplex对推理服务场景做了针对性优化，更加适合指导数据中心级异构硬件的设计。

6 思考与展望

6.1 混合专家算法演进

MoE大语言模型的算法演进始终围绕两大核心矛盾展开：模型规模扩展的潜力与实际推理效率的瓶颈。传统MoE架构通过固定稀疏激活专家模块提升算法精度，而最新工作表明，对于充分训练模型，在合理激活量范围内，激活率越低(稀疏性越高)，计算效率理论上越高，揭示针对任务特征动态调整专家大小的可能[170]，而“按输入难度自适应激活专家数”的策略也被证明具有实际应用潜力[171]。

从应用角度出发，MoE模型可以用于更好的知识蒸馏(Knowledge Distillation)，研究者尝试将MoE模型的稀疏性优势迁移至轻量化模型中，例如通过教师-学生框架将多专家决策逻辑压缩为单一稠密模型的隐式多模态表征[143]。另外，研究者正在将参数高效微调(如LoRA)与MoE相结合，如Tensor-Trained Low-Rank Adaptation Mixture

表 4 优化架构参数与性能数据

名称	任务	硬件平台	峰值算力	峰值带宽	对比基线	推理加速比	能效比提升
FLAME[112]	文本生成	Xilinx Alveo U200	-	77GB/s*	NVIDIA 3090 GPU	1.49×	-
Edge-MoE[113]	视觉模型	Xilinx ZCU102	-	19.2GB/s*	NVIDIA RTX A6000 GPU	0.40×	2.24×
UbiMoE[110]	视觉模型	Xilinx ZCU102	304.84GOPS (INT16)	19.2GB/s*	NVIDIA Tesla V100S GPU	1.56×	7.85×
		Xilinx Alveo U280	789.72GOPS (INT16)	460GB/s*		3.88×	6.93×
MoNDE[116]	文本生成	NDP + GPU	312TFLOPS (GPU) 2TFLOPS (NDP)	512GB/s	NVIDIA A100 GPU	1.1～6.7×	-
Duplex[117]	文本生成	PIM + xPU	756.5TFLOPS (xPU) 106.5TFLOPS (PIM)	～12TB/s	NVIDIA H100 GPU	1.36～2.67×	4.61×
PIMoE[118]	文本生成	PIM + NPU	32.8TFLOPS (NPU) 2.5TFLOPS (PIM)	614GB/s	NVIDIA A100 GPU	1.6～8.47×	4.8～13.7×

*可编程逻辑(PL)单元的内存峰值带宽

中国知网 https://www.cnki.net

of Ex perts(TT-LoRA MoE)[172]框架通过分层专家融合，实现了比简单合并更优的LoRA集成效果。进一步，强化学习也可以被引入动态路由策略设计，例如通过策略梯度算法让门控网络学习长期推理效率与模型精度的权衡[144]。此外，MoE的思想还能启迪多智能体(Multi Agents)协同，如Mixture-of-Agents(MoA)[173]将多个LLM作为专家融合，实验表明其在数学推理等任务上优于任何单一模型。

综上，算法上的演进不断扩展MoE的规模和应用边界，但仍需解决高效路由、长尾专家利用和跨领域稳定性等挑战，以实现稀疏专家在更广泛场景下的有效部署。

6.2 面向动态推理服务场景的系统优化

在系统层面，推理服务将是未来MoE模型部署的主要优化场景，需解决动态专家计算与硬件资源分配问题，以及系统通信开销问题。

传统静态模型推理框架(如ONNX Runtime[119]等)难以高效处理MoE特有的条件激活计算图，每个输入样本激活的专家子图可能不完全相同，导致难以针对模型计算图做提前优化。对于服务场景，请求到来的时机以及推理任务分布具有随机性，更加剧了计算图优化与数据流映射的难题，导致GPU计算单元的利用率因负载波动而大幅下降。

目前，动态计算图优化方案通过运行时动态调度机制可以缓解部分动态任务问题[145]，但针对MoE大模型与集群服务场景仍存在以下挑战：(1)在资源管理层面，专家分配策略需要兼顾不同算子负载与服务等级目标(SLO)的动态约束(如大规模批处理将提升专家激活规模，进而挤压KV 缓存和激活值的存储空间，进而影响服务效率)，且同时需考虑资源动态迁移面临的状态同步开销问题[174,175]；(2)跨设备通信是多节点部署的性能瓶颈，尤其是专家路由产生的All-to-All数据搬运延迟，需考虑实际系统拓扑和互连架构的设计。

总之，未来MoE推理服务优化需要考虑运行时计算、内存资源调度策略以及通信拓扑的设计方案，以应对服务请求与专家激活负载变化带来的计算、内存与通信的挑战。

6.3 硬件设计新范式

硬件架构创新是释放MoE性能潜力的最终路径。近存储计算(Near-Memory Computing, NMC)技术为MoE的稀疏访存模式提供了新机遇，如三星的HBM-PIM[120](高带宽内存-存内计算)架构允许在DRAM芯片内部直接执行专家模块的矩阵乘加操作，将参数访存延迟从数毫秒缩减至微秒以内。可以预测，通过结合混合精度训练框架，将高精度专家网络置于传统高算力处理器中(如GPU、NPU等)，低精度专家下沉至存算一体设备将成为可能。

另一种方案是直接构建更适合MoE模型的存储层次体系。目前，内存层次优化逐渐成为研究热点，通过异构内存设计和数据置换机制迁移热/冷数据到不同层次来提升性能[175,176]。在端侧MoE推理时，对于高频激活的热专家，需确保其权重常驻高带宽内存，而对于低频激活的冷专家可以采用压缩存储和延迟加载，放置在低带宽内存中，这不仅要求系统能追踪监控专家的访问频度并调整数据布局，还需要在硬件架构层实现跨层次的管理框架(如专用的页计数器等)。

总体而言，未来面向内存层次的优化技术在支撑MoE推理部署中具有潜力，但必须从硬件、系统与编译器等多层协同优化。

6.4 算法、系统与架构优化挑战与趋势

面向未来的MoE设计范式，算法-系统-架构需协同优化突破关键瓶颈。从目标定位和优化边界上看，算法级优化侧重于从理论角度提升模型质量，其性能上界取决于可验证的模型规模，当下逐渐受限于实际的硬件资源。系统级优化主要关注软件层面的效率提升，目标是通过优化数据流、调度方法及提升资源利用率实现性能提升，具有较强的通用性但整体受硬件能力限制。架构级优化则专注于硬件层面的专用适配，其性能提升显著但移植性较差。

在具体方向上，本文给出以下观点：首先，以MoE为代表的混合模型已然成为趋势，在算法上根据任务特点切换模型架构的思想已经得到了验证；其次，通信负担仍将是未来的主要限制，MoE训练中通信时间占据正向传播时间超过40%[177]，这一开销在集群规模“横向”和“纵向”扩张过程中依旧无法忽视；最后，由MoE大模型的发展趋势可以看出，未来将面临越来受限的带宽与容量资源，架构设计应当逐步转向为以存储为中心的理念。

7 结束语

混合专家大语言模型的演进本质是算法、系统与硬件3个层面的协同优化。在算法层面，通过结合模型结构设计与高效算法技术，逐渐打破传统稀疏与稠密架构的严格划分；在系统层面，云端侧对训练推理效率的提升需求，推动从通信、存储与计算3个维度的创新；在硬件层面，定制加速器与存算一体等多样化架构共同发展，正在改变传统计算

中国知网 https://www.cnki.net

资源的设计方式。未来的混合专家大语言模型发展，需要软-硬件跨层级联动设计。这种跨层协作能力，将帮助混合专家大语言模型从学术实验阶段，真正落地到实际应用场景。

参 考 文 献

[1] VASWANI A, SHAZEER N, PARMAR N, *et al.* Attention is all you need[C]. Proceedings of the 31st International Conference on Neural Information Processing Systems, Long Beach, USA, 2017: 6000–6010.

[2] OpenAI. GPT-4 technical report[J]. arXiv preprint arXiv: 2303.08774, 2024. doi: 10.48550/arXiv.2303.08774.

[3] Gemini Team Google. Gemini: A family of highly capable multimodal models[J]. arXiv preprint arXiv: 2312.11805, 2025. doi: 10.48550/arXiv.2312.11805.

[4] Qwen Team. Qwen2.5 technical report[J]. arXiv preprint arXiv: 2412.15115, 2025. doi: 10.48550/arXiv.2412.15115.

[5] DUBEY A, JAUHRI A, PANDEY A, *et al.* The LLAMA 3 herd of models[J]. arXiv preprint arXiv: 2407.21783, 2024. doi: 10.48550/arXiv.2407.21783.

[6] DU Zhengxiao, QIAN Yujie, LIU Xiao, *et al.* GLM: General language model pretraining with autoregressive blank infilling[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Dublin, Ireland, 2022: 320–335. doi: 10.18653/v1/2022.acl-long.26.

[7] ABDIN M, ANEJA J, AWADALLA H, *et al.* Phi-3 technical report: A highly capable language model locally on your phone[J]. arXiv preprint arXiv: 2404.14219, 2024. doi: 10.48550/arXiv.2404.14219.

[8] TOUVRON H, MARTIN L, STONE K, *et al.* LLAMA 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv: 2307.09288, 2023. doi: 10.48550/arXiv.2307.09288.

[9] OUYANG Long, WU J, JIANG Xu, *et al.* Training language models to follow instructions with human feedback[C]. Proceedings of the 36th International Conference on Neural Information Processing Systems, New Orleans, USA, 2022: 27730–27744.

[10] BOCKLISCH T, WERKMEISTER T, VARSHNEYA D, *et al.* Task-oriented dialogue with in-context learning[J]. arXiv preprint arXiv: 2402.12234, 2024. doi: 10.48550/arXiv.2402.12234.

[11] TSAI Y D, LIU Mingjie, and REN Haoxing. Code less, align more: Efficient LLM fine-tuning for code generation with data pruning[J]. arXiv preprint arXiv: 2407.05040, 2024. doi: 10.48550/arXiv.2407.05040.

[12] NLLB Team, COSTA-JUSSÀ M R, CROSS J, *et al.* No language left behind: Scaling human-centered machine translation[J]. arXiv preprint arXiv: 2207.04672, 2022. doi: 10.48550/arXiv.2207.04672.

[13] BORDES F, PANG R Y, AJAY A, *et al.* An introduction to vision-language modeling[J]. arXiv preprint arXiv: 2405.17247, 2024. doi: 10.48550/arXiv.2405.17247.

[14] LIU Haotian, LI Chunyuan, WU Qingyang, *et al.* Visual instruction tuning[C]. Proceedings of the 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 34892–34916.

[15] WANG Peng, BAI Shuai, TAN Sinan, *et al.* Qwen2-VL: Enhancing vision-language model's perception of the world at any resolution[J]. arXiv preprint arXiv: 2409.12191, 2024. doi: 10.48550/arXiv.2409.12191.

[16] YAO Yuan, YU Tianyu, ZHANG Ao, *et al.* MiniCPM-V: A GPT-4V level MLLM on your phone[J]. arXiv preprint arXiv: 2408.01800, 2024. doi: 10.48550/arXiv.2408.01800.

[17] KAPLAN J, MCCANDLISH S, HENIGHAN T, *et al.* Scaling laws for neural language models[J]. arXiv preprint arXiv: 2001.08361, 2020. doi: 10.48550/arXiv.2001.08361.

[18] HOFFMANN J, BORGEAUD S, MENSCH A, *et al.* Training compute-optimal large language models[J]. arXiv preprint arXiv: 2203.15556, 2022. doi: 10.48550/arXiv.2203.15556.

[19] ANIL R, DAI A M, FIRAT O, *et al.* PaLM 2 technical report[J]. arXiv preprint arXiv: 2305.10403, 2023. doi: 10.48550/arXiv.2305.10403.

[20] JACOBS R A, JORDAN M I, NOWLAN S J, *et al.* Adaptive mixtures of local experts[J]. *Neural Computation*, 1991, 3(1): 79–87. doi: 10.1162/neco.1991.3.1.79.

[21] SHAZEER N, MIRHOSEINI A, MAZIARZ K, *et al.* Outrageously large neural networks: The sparsely-gated mixture-of-experts layer[J]. arXiv preprint arXiv: 1701.06538, 2017. doi: 10.48550/arXiv.1701.06538.

[22] DU Nan, HUANG Yanping, DAI A M, *et al.* GLaM: Efficient scaling of language models with mixture-of-experts[C]. Proceedings of the 39th International Conference on Machine Learning, Maryland, USA, 2022: 5547–5569.

[23] JIANG A Q, SABLAYROLLES A, ROUX A, *et al.* Mixtral of experts[J]. arXiv preprint arXiv: 2401.04088, 2024. doi: 10.48550/arXiv.2401.04088.

[24] RAJBHANDARI S, LI Conglong, YAO Zhewei, *et al.* DeepSpeed-MoE: Advancing mixture-of-experts inference

中国知网 https://www.cnki.net

and training to power next-generation AI scale[C]. Proceedings of the 39th International Conference on Machine Learning, Maryland, USA, 2022: 18332–18346.

[25] X-AI. Grok-1[EB/OL]. https://github.com/xai-org/grok-1, 2024.

[26] LIEBER O, LENZ B, BATA H, *et al*. Jamba: A hybrid transformer-mamba language model[J]. arXiv preprint arXiv: 2403.19887, 2024. doi: 10.48550/arXiv.2403.19887.

[27] DeepSeek-AI. DeepSeek-V3 technical report[J]. arXiv preprint arXiv: 2412.19437, 2025. doi: 10.48550/arXiv.2412.19437.

[28] FEDUS W, ZOPH B, and SHAZEER N. Switch Transformers: Scaling to trillion parameter models with simple and efficient sparsity[J]. arXiv preprint arXiv: 2101.03961, 2022. doi: 10.48550/arXiv.2101.03961.

[29] MiniMax. MiniMax-01: Scaling foundation models with lightning attention[J]. arXiv preprint arXiv: 2501.08313, 2025. doi: 10.48550/arXiv.2501.08313.

[30] YANG An, LIN Junyang, MEN Rui, *et al*. M6-T: Exploring sparse expert models and beyond[J]. arXiv preprint arXiv: 2105.15082, 2021. doi: 10.48550/arXiv.2105.15082.

[31] LEPIKHIN D, LEE H J, XU Yuanzhong, *et al*. GShard: Scaling giant models with conditional computation and automatic sharding[J]. arXiv preprint arXiv: 2006.16668, 2020. doi: 10.48550/arXiv.2006.16668.

[32] ZOPH B, BELLO I, KUMAR S, *et al*. ST-MoE: Designing stable and transferable sparse expert models[J]. arXiv preprint arXiv: 2202.08906, 2022. doi: 10.48550/arXiv.2202.08906.

[33] XUE Fuzhao, ZHENG Zian, FU Yao, *et al*. OpenMoE: An early effort on open mixture-of-experts language models[J]. arXiv preprint arXiv: 2402.01739, 2024. doi: 10.48550/arXiv.2402.01739.

[34] SHEN Yikang, GUO Zhen, CAI Tianle, *et al*. JetMoE: Reaching Llama2 performance with 0.1M dollars[J]. arXiv preprint arXiv: 2404.07413, 2024. doi: 10.48550/arXiv.2404.07413.

[35] CAI Weilin, JIANG Juyong, WANG Fan, *et al*. A survey on mixture of experts[J]. arXiv preprint arXiv: 2407.06204, 2025. doi: 10.48550/arXiv.2407.06204.

[36] VATS A, RAJA R, JAIN V, *et al*. The evolution of MoE: A survey from basics to breakthroughs[J]. 2024.

[37] PEI Zehua, ZOU Lancheng, ZHEN Huiling, *et al*. CMoE: Converting mixture-of-experts from dense to accelerate LLM inference[J]. arXiv preprint arXiv: 2502.04416, 2025. doi: 10.48550/arXiv.2502.04416.

[38] ZHANG Xiaofeng, SHEN Yikang, HUANG Zeyu, *et al*. Mixture of attention heads: Selecting attention heads per token[J]. arXiv preprint arXiv: 2210.05144, 2022. doi: 10.48550/arXiv.2210.05144.

[39] WANG K C, OSTASHEV D, FANG Yuwei, *et al*. MoA: Mixture-of-attention for subject-context disentanglement in personalized image generation[C]. SIGGRAPH Asia 2024 Conference Papers, Tokyo, Japan, 2024: 3. doi: 10.1145/3680528.3687662.

[40] JIN Peng, ZHU Bo, YUAN Li, *et al*. MoH: Multi-head attention as mixture-of-head attention[J]. arXiv preprint arXiv: 2410.11842, 2025. doi: 10.48550/arXiv.2410.11842.

[41] ZHANG Zhenyu, SHENG Ying, ZHOU Tianyi, *et al*. H_2O: Heavy-hitter oracle for efficient generative inference of large language models[C]. Proceedings of the 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 34661–34710.

[42] ZANDIEH A, HAN I, MIRROKNI V, *et al*. SubGen: Token generation in sublinear time and memory[J]. arXiv preprint arXiv: 2402.06082, 2024. doi: 10.48550/arXiv.2402.06082.

[43] DONG H, YANG Xinyu, ZHANG Zhangyang, *et al*. Get more with LESS: Synthesizing recurrence with KV cache compression for efficient LLM inference[J]. arXiv preprint arXiv: 2402.09398, 2024. doi: 10.48550/arXiv.2402.09398.

[44] LU Enzhe, JIANG Zhejun, LIU Jingyuan, *et al*. MoBA: Mixture of block attention for long-context LLMs[J]. arXiv preprint arXiv: 2502.13189, 2025. doi: 10.48550/arXiv.2502.13189.

[45] YUAN Jingyang, GAO Huazuo, DAI Damai, *et al*. Native sparse attention: Hardware-aligned and natively trainable sparse attention[J]. arXiv preprint arXiv: 2502.11089, 2025. doi: 10.48550/arXiv.2502.11089.

[46] LU Xudong, LIU Qi, XU Yuhui, *et al*. Not all experts are equal: Efficient expert pruning and skipping for mixture-of-experts large language models[J]. arXiv preprint arXiv: 2402.14800, 2024. doi: 10.48550/arXiv.2402.14800.

[47] XIE Yanyue, ZHANG Zhi, ZHOU Ding, *et al*. MoE-Pruner: Pruning mixture-of-experts large language model using the hints from its router[J]. arXiv preprint arXiv: 2410.12013, 2024. doi: 10.48550/arXiv.2410.12013.

[48] LIU Enshu, ZHU Junyi, LIN Zinan, *et al*. Efficient expert pruning for sparse mixture-of-experts language models: Enhancing performance and reducing inference costs[J]. arXiv preprint arXiv: 2407.00945, 2024. doi: 10.48550/arXiv.

中国知网 https://www.cnki.net

2407.00945.

[49] ZHANG Zeliang, LIU Xiaodong, CHENG Hao, *et al.* Diversifying the expert knowledge for task-agnostic pruning in sparse mixture-of-experts[J]. arXiv preprint arXiv: 2407.09590, 2025. doi: 10.48550/arXiv.2407.09590.

[50] CHOWDHURY M N R, WANG Meng, EL MAGHRAOUI K, *et al.* A provably effective method for pruning experts in fine-tuned sparse mixture-of-experts[J]. arXiv preprint arXiv: 2405.16646, 2024. doi: 10.48550/arXiv.2405.16646.

[51] SARKAR S, LAUSEN L, CEVHER V, *et al.* Revisiting SMoE language models by evaluating inefficiencies with task specific expert pruning[J]. arXiv preprint arXiv: 2409.01483, 2024. doi: 10.48550/arXiv.2409.01483.

[52] ZHUANG Yan, ZHENG Zhenzhe, WU Fan, *et al.* LiteMoE: Customizing on-device LLM serving via proxy submodel tuning[C]. Proceedings of the 22nd ACM Conference on Embedded Networked Sensor Systems, Hangzhou, China, 2024: 521–534. doi: 10.1145/3666025.3699355.

[53] FRANTAR E and ALISTARH D. QMoE: Sub-1-Bit compression of trillion-parameter models[C]. Proceedings of the 5th MLSys Conference, Santa Clara, USA, 2024: 439–451.

[54] TANG Peng, LIU Jiacheng, HOU Xiaofeng, *et al.* HOBBIT: A mixed precision expert offloading system for fast MoE inference[J]. arXiv preprint arXiv: 2411.01433, 2024. doi: 10.48550/arXiv.2411.01433.

[55] KIM Y J, HENRY R, FAHIM R, *et al.* Who says Elephants can't run: Bringing large scale MoE models into cloud scale production[J]. arXiv preprint arXiv: 2211.10017, 2022. doi: 10.48550/arXiv.2211.10017.

[56] KIM Y J, FAHIM R, and AWADALLA H H. Mixture of quantized experts (MoQE): Complementary effect of low-bit quantization and robustness[J]. arXiv preprint arXiv: 2310.02410, 2023. doi: 10.48550/arXiv.2310.02410.

[57] HUANG Beichen, YUAN Yueming, SHAO Zelei, *et al.* MiLo: Efficient quantized MoE inference with mixture of low-rank compensators[J]. arXiv preprint arXiv: 2504.02658, 2025. doi: 10.48550/arXiv.2504.02658.

[58] YANG Cheng, SUI Yang, XIAO Jinqi, *et al.* MoE-I^2: Compressing mixture of experts models through inter-expert pruning and intra-expert low-rank decomposition[J]. arXiv preprint arXiv: 2411.01016, 2024. doi: 10.48550/arXiv.2411.01016.

[59] GAO Zefeng, LIU Peiyu, ZHAO W X, *et al.* Parameter-efficient mixture-of-experts architecture for pre-trained language models[J]. arXiv preprint arXiv: 2203.01104, 2022. doi: 10.48550/arXiv.2203.01104.

[60] GU Hao, LI Wei, LI Lujun, *et al.* Delta decompression for MoE-based LLMs compression[J]. arXiv preprint arXiv: 2502.17298, 2025. doi: 10.48550/arXiv.2502.17298.

[61] FRANTAR E and ALISTARH D. SparseGPT: Massive language models can be accurately pruned in one-shot[C]. Proceedings of the 40th International Conference on Machine Learning, Honolulu, USA, 2023: 10323–10337.

[62] MA Xinyin, FANG Gongfan, and WANG Xinchao. LLM-pruner: On the structural pruning of large language models[C]. Proceedings of the 37th International Conference on Neural Information Processing Systems, New Orleans, USA, 2023: 21702–21720.

[63] XU Yuzhuang, HAN Xu, YANG Zonghan, *et al.* OneBit: Towards extremely low-bit large language models[J]. arXiv preprint arXiv: 2402.11295, 2024. doi: 10.48550/arXiv.2402.11295.

[64] LIN Ji, TANG Jiaming, TANG Haotian, *et al.* AWQ: Activation-aware weight quantization for on-device LLM compression and acceleration[C]. Proceedings of the 5th MLSys Conference, Santa Clara, USA, 2024: 87–100.

[65] FRANTAR E, ASHKBOOS S, HOEFLER T, *et al.* GPTQ: Accurate post-training quantization for generative pre-trained transformers[EB/OL]. https://arxiv.org/abs/2210.17323, 2023.

[66] KAUSHAL A, VAIDHYA T, and RISH I. LORD: Low rank decomposition of monolingual code LLMs for one-shot compression[J]. arXiv preprint arXiv: 2309.14021, 2023. doi: 10.48550/arXiv.2309.14021.

[67] GOU Yunhao, LIU Zhili, CHEN Kai, *et al.* Mixture of cluster-conditional LoRA experts for vision-language instruction tuning[J]. arXiv preprint arXiv: 2312.12379, 2024. doi: 10.48550/arXiv.2312.12379.

[68] MUSTAFA B, RIQUELME C, PUIGCERVER J, *et al.* Multimodal contrastive learning with LIMoE: The language-image mixture of experts[C]. Proceedings of the 36th International Conference on Neural Information Processing Systems, New Orleans, USA, 2022: 9564–9576.

[69] HUANG Haiyang, ARDALANI N, SUN Anna, *et al.* Towards MoE deployment: Mitigating inefficiencies in mixture-of-expert (MoE) inference[J]. arXiv preprint arXiv: 2303.06182, 2023. doi: 10.48550/arXiv.2303.06182.

[70] ZHONG Shuzhang, LIANG Ling, WANG Yuan, *et al.* AdapMoE: Adaptive sensitivity-based expert gating and management for efficient MoE inference[C]. Proceedings of

中国知网 https://www.cnki.net

the 43rd IEEE/ACM International Conference on Computer-Aided Design, New York, USA, 2024: 51. doi: 10.1145/3676536.3676741.

[71] ZHAI Mingshu, HE Jiaao, MA Zixuan, *et al*. SmartMoE: Efficiently training Sparsely-Activated models through combining offline and online parallelization[C]. 2023 USENIX Annual Technical Conference, Boston, USA, 2023: 961–975.

[72] PAN Xinglin, LIN Wenxiang, ZHANG Lin, *et al*. FSMoE: A flexible and scalable training system for sparse mixture-of-experts models[C]. Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 1, Rotterdam, Netherlands, 2025: 524–539. doi: 10.1145/3669940.3707272.

[73] HE Jiaao, ZHAI Jidong, ANTUNES T, *et al*. FasterMoE: Modeling and optimizing training of large-scale dynamic pre-trained models[C]. Proceedings of the 27th ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming, Seoul, Republic of Korea, 2022: 120–134. doi: 10.1145/3503221.3508418.

[74] HWANG C, CUI Wei, XIONG Yifan, *et al*. Tutel: Adaptive mixture-of-experts at scale[C]. Proceedings of the 6th MLSys Conference, Miami Beach, USA, 2023: 269–287.

[75] JIANG Chenyu, TIAN Ye, JIA Zhen, *et al*. Lancet: Accelerating mixture-of-experts training via whole graph computation-communication overlapping[C]. Proceedings of the 7th MLSys Conference, Santa Clara, USA, 2024: 74–86.

[76] LI Jiamin, JIANG Yimin, ZHU Yibo, *et al*. Accelerating distributed MoE training and inference with Lina[C]. 2023 USENIX Annual Technical Conference, Boston, USA, 2023: 945–959.

[77] SHI Shaohuai, PAN Xinglin, CHU Xiaowen, *et al*. PipeMoE: Accelerating mixture-of-experts through adaptive pipelining[C]. IEEE INFOCOM 2023-IEEE Conference on Computer Communications, New York City, USA, 2023: 1–10. doi: 10.1109/infocom53939.2023.10228874.

[78] WANG Hulin, XIA Yaqi, YANG Donglin, *et al*. Harnessing Inter-GPU shared memory for seamless MoE communication-computation fusion[C]. Proceedings of the 30th ACM SIGPLAN Annual Symposium on Principles and Practice of Parallel Programming, Las Vegas, USA, 2025: 170–182. doi: 10.1145/3710848.3710868.

[79] ZHANG Shulai, ZHENG Ningxin, LIN Haibin, *et al*. Comet: Fine-grained computation-communication overlapping for mixture-of-experts[J]. arXiv preprint arXiv: 2502.19811, 2025. doi: 10.48550/arXiv.2502.19811.

[80] GO S and MAHAJAN D. MoETuner: Optimized mixture of expert serving with balanced expert placement and token routing[J]. arXiv preprint arXiv: 2502.06643, 2025. doi: 10.48550/arXiv.2502.06643.

[81] HE Xin, ZHANG Shunkang, WANG Yuxin, *et al*. ExpertFlow: Optimized expert activation and token allocation for efficient mixture-of-experts inference[J]. arXiv preprint arXiv: 2410.17954, 2024. doi: 10.48550/arXiv.2410.17954.

[82] ELISEEV A and MAZUR D. Fast inference of mixture-of-experts language models with offloading[J]. arXiv preprint arXiv: 2312.17238, 2023. doi: 10.48550/arXiv.2312.17238.

[83] HWANG R, WEI Jianyu, CAO Shijie, *et al*. Pre-gated MoE: An algorithm-system co-design for fast and scalable mixture-of-expert inference[C]. 2024 ACM/IEEE 51st Annual International Symposium on Computer Architecture (ISCA), Buenos Aires, Argentina, 2024: 1018–1031. doi: 10.1109/isca59077.2024.00078.

[84] DU Zhixu, LI Shiyu, WU Yuhao, *et al*. SIDA: Sparsity-inspired data-aware serving for efficient and scalable large mixture-of-experts models[C]. Proceedings of the 7th MLSys Conference, Santa Clara, USA, 2024: 224–238.

[85] SONG Xiaoniu, ZHONG Zihang, and CHEN Rong. ProMoE: Fast MoE-based LLM serving using proactive caching[J]. arXiv preprint arXiv: 2410.22134, 2025. doi: 10.48550/arXiv.2410.22134.

[86] WEI Yuanxin, DU Jiangsu, JIANG Jiazhi, *et al*. APTMoE: Affinity-Aware pipeline tuning for MoE models on bandwidth-constrained GPU nodes[C]. SC24: International Conference for High Performance Computing, Networking, Storage and Analysis, Atlanta, USA, 2024: 1–14. doi: 10.1109/sc41406.2024.00096.

[87] FANG Zhiyuan, HUANG Yuegui, HONG Zicong, *et al*. K_{LOTSKI}: Efficient mixture-of-expert inference via expert-aware multi-batch pipeline[C]. Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2, Rotterdam, Netherlands, 2025: 574–588. doi: 10.1145/3676641.3716261.

[88] ZHANG Yujie, AGGARWAL S, and MITRA T. DAOP: Data-aware offloading and predictive pre-calculation for efficient MoE inference[C]. 2025 Design, Automation & Test in Europe Conference (DATE), Lyon, France, 2025:

中国知网 https://www.cnki.net

1–7. doi: 10.23919/DATE64628.2025.10992741.

[89] CAO Shiyi, LIU Shu, GRIGGS T, *et al*. MoE-Lightning: High-throughput MoE inference on memory-constrained GPUs[C]. Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 1, Rotterdam, Netherlands, 2025: 715–730. doi: 10.1145/3669940.3707267.

[90] KAMAHORI K, TANG Tian, GU Yile, *et al*. Fiddler: CPU-GPU orchestration for fast inference of mixture-of-experts models[J]. arXiv preprint arXiv: 2402.07033, 2025. doi: 10.48550/arXiv.2402.07033.

[91] ZHONG Shuzhang, SUN Yanfan, LIANG Ling, *et al*. HybriMoE: Hybrid CPU-GPU scheduling and cache management for efficient MoE inference[J]. arXiv preprint arXiv: 2504.05897, 2025. doi: 10.48550/arXiv.2504.05897.

[92] NVIDIA. NCCL[EB/OL]. https://developer.nvidia.com/nccl, 2025.

[93] XU Yuanzhong, LEE H J, CHEN Dehao, *et al*. GSPMD: General and scalable parallelization for ML computation graphs[J]. arXiv preprint arXiv: 2105.04663, 2021. doi: 10.48550/arXiv.2105.04663.

[94] NVIDIA. NVSHMEM[EB/OL]. https://docs.nvidia.com/nvshmem/api/, 2025.

[95] PUNNIYAMURTHY K, HAMIDOUCHE K, and BECKMANN B M. Optimizing distributed ML communication with fused computation-collective operations[C]. SC24: International Conference for High Performance Computing, Networking, Storage and Analysis, Atlanta, USA, 2024: 1–17. doi: 10.1109/sc41406.2024.00094.

[96] YU Dianhai, SHEN Liang, HAO Hongxiang, *et al*. MoESys: A distributed and efficient mixture-of-experts training and inference system for internet services[J]. *IEEE Transactions on Services Computing*, 2024, 17(5): 2626–2639. doi: 10.1109/tsc.2024.3399654.

[97] GALE T, NARAYANAN D, YOUNG C, *et al*. MegaBlocks: Efficient sparse training with mixture-of-experts[C]. Proceedings of the 6th MLSys Conference, Miami Beach, USA, 2023: 288–304.

[98] NVIDIA. cuBLAS[EB/OL]. https://developer.nvidia.com/cublas, 2025.

[99] CAI Zixian, LIU Zhengyang, MALEKI S, *et al*. Synthesizing optimal collective algorithms[C]. Proceedings of the 26th ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming, Virtual Event, 2021: 62–75. doi: 10.1145/3437801.3441620.

[100] ZENG Zhiyuan and XIONG Deyi. SCoMoE: Efficient mixtures of experts with structured communication[C]. The Eleventh International Conference on Learning Representations, Kigali, Rwanda, 2023.

[101] SUO Jiashun, LIAO Xiaojian, XIAO Limin, *et al*. CoServe: Efficient Collaboration-of-Experts (CoE) model inference with limited memory[C]. Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2, Rotterdam, Netherlands, 2025: 178–191. doi: 10.1145/3676641.3715986.

[102] CAI Weilin, QIN Le, and HUANG Jiayi. MoC-System: Efficient fault tolerance for sparse mixture-of-experts model training[C]. Proceedings of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2, Rotterdam, Netherlands, 2025: 655–671. doi: 10.1145/3676641.3716006.

[103] KOSSMANN F, JIA Zhihao, and AIKEN A. Optimizing mixture of experts using dynamic recompilations[J]. arXiv preprint arXiv: 2205.01848, 2022. doi: 10.48550/arXiv.2205.01848.

[104] LI Yinghan, LI Yifei, ZHANG Jiejing, *et al*. Static batching of irregular workloads on GPUs: Framework and application to efficient MoE model inference[J]. arXiv preprint arXiv: 2501.16103, 2025. doi: 10.48550/arXiv.2501.16103.

[105] LMDeploy Contributors. LMDeploy: A toolkit for compressing, deploying, and serving LLM[EB/OL]. https://github.com/InternLM/lmdeploy, 2023.

[106] KWON W, LI Zhouhan, ZHUANG Siyuan, *et al*. Efficient memory management for large language model serving with *PagedAttention*[C]. Proceedings of the 29th Symposium on Operating Systems Principles, Koblenz, Germany, 2023: 611–626. doi: 10.1145/3600006.3613165.

[107] ZHENG Lianmin, YIN Liangsheng, XIE Zhiqiang, *et al*. SGLang: Efficient execution of structured language model programs[C]. Proceedings of the 38th International Conference on Neural Information Processing Systems, Vancouver, Canada, 2025: 62557–62583.

[108] KVCache-AI. A flexible framework for experiencing cutting-edge LLM inference optimizations[EB/OL]. https://github.com/kvcache-ai/ktransformers, 2025.

[109] LIU Jiacheng, TANG Peng, WANG Wenfeng, *et al*. A survey on inference optimization techniques for mixture of experts models[J]. arXiv preprint arXiv: 2412.14219, 2025.

中国知网 https://www.cnki.net

doi: 10.48550/arXiv.2412.14219.

[110] DONG Jiale, LOU Wenqi, ZHENG Zhendong, *et al*. UbiMoE: A ubiquitous mixture-of-experts vision transformer accelerator with hybrid computation pattern on FPGA[J]. arXiv preprint arXiv: 2502.05602, 2025. doi: 10.48550/arXiv.2502.05602.

[111] PARK G, SONG S, SANG Haoyang, *et al*. 20.8 spacemate: A 303.5mW real-time sparse mixture-of-experts-based NeRF-SLAM processor for mobile spatial computing[C]. 2024 IEEE International Solid-State Circuits Conference (ISSCC), San Francisco, USA, 2024: 374–376. doi: 10.1109/isscc49657.2024.10454487.

[112] LIN Xuanda, TIAN Huinan, XUE Wenxiao, *et al*. FLAME: Fully leveraging MoE sparsity for transformer on FPGA[C]. Proceedings of the 61st ACM/IEEE Design Automation Conference, San Francisco, USA, 2024: 248. doi: 10.1145/3649329.3656507.

[113] SARKAR R, LIANG Hanxue, FAN Zhiwen, *et al*. Edge-MoE: Memory-efficient multi-task vision transformer architecture with task-level sparsity via mixture-of-experts[C]. 2023 IEEE/ACM International Conference on Computer Aided Design (ICCAD), San Francisco, USA, 2023: 1–9. doi: 10.1109/iccad57390.2023.10323651.

[114] LIANG Hanxue, FAN Zhiwen, SARKAR R, *et al*. M^3ViT: Mixture-of-experts vision transformer for efficient multi-task learning with model-accelerator co-design[C]. Proceedings of the 36th International Conference on Neural Information Processing Systems, New Orleans, USA, 2022: 28441–28457.

[115] HE Siqi, ZHU Haozhe, ZHENG Jiapei, *et al*. Hydra: Harnessing expert popularity for efficient mixture-of-expert inference on Chiplet system[C]. Proceedings of the 62nd ACM/IEEE Design Automation Conference (DAC), San Francisco, USA, 2025: 1–6.

[116] KIM T, CHOI K, CHO Y, *et al*. MoNDE: Mixture of near-data experts for large-scale sparse models[C]. Proceedings of the 61st ACM/IEEE Design Automation Conference, San Francisco, USA, 2024: 221. doi: 10.1145/3649329.3655951.

[117] YUN S, KYUNG K, CHO J, *et al*. Duplex: A device for large language models with mixture of experts, grouped query attention, and continuous batching[C]. 2024 57th IEEE/ACM International Symposium on Microarchitecture (MICRO), Austin, USA, 2024: 1429–1443. doi: 10.1109/micro61859.2024.00105.

[118] WU Lizhou, ZHU Haozhe, HE Siqi, *et al*. PIMoE: Towards efficient MoE transformer deployment on NPU-PIM system through throttle-aware task offloading[C]. Proceedings of the 62nd ACM/IEEE Design Automation Conference (DAC), San Francisco, CA, USA, 2025: 1–6.

[119] Microsoft. ONNX Runtime[EB/OL]. https://onnxruntime.ai/, 2025.

[120] LEE S, KANG S H, LEE J, *et al*. Hardware architecture and software stack for PIM based on commercial DRAM technology: Industrial product[C]. 2021 ACM/IEEE 48th Annual International Symposium on Computer Architecture (ISCA), Valencia, Spain, 2021: 43–56. doi: 10.1109/isca52012.2021.00013.

[121] GU A and DAO T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv: 2312.00752, 2024. doi: 10.48550/arXiv.2312.00752.

[122] NIE Xiaonan, LIU Qibin, FU Fangcheng, *et al*. LSH-MoE: Communication-efficient MoE training via locality-sensitive hashing[C]. Proceedings of the 38th International Conference on Neural Information Processing Systems, Vancouver, Canada, 2025: 54161–54182.

[123] SINGH S, RUWASE O, AWAN A A, *et al*. A hybrid tensor-expert-data parallelism approach to optimize mixture-of-experts training[C]. Proceedings of the 37th International Conference on Supercomputing, Orlando, USA, 2023: 203–214. doi: 10.1145/3577193.3593704.

[124] SHI Shaohuai, PAN Xinglin, WANG Qiang, *et al*. ScheMoE: An extensible mixture-of-experts distributed training system with tasks scheduling[C]. Proceedings of the Nineteenth European Conference on Computer Systems, Athens, Greece, 2024: 236–249. doi: 10.1145/3627703.3650083.

[125] PRABHAKAR R, SIVARAMAKRISHNAN R, GANDHI D, *et al*. SambaNova SN40L: Scaling the AI memory wall with dataflow and composition of experts[C]. 2024 57th IEEE/ACM International Symposium on Microarchitecture (MICRO), Austin, USA, 2024: 1353–1366. doi: 10.1109/micro61859.2024.00100.

[126] YAO Jinghan, ANTHONY Q, SHAFI A, *et al*. Exploiting inter-layer expert affinity for accelerating mixture-of-experts model inference[C]. 2024 IEEE International Parallel and Distributed Processing Symposium (IPDPS), San Francisco, USA, 2024: 915–925. doi: 10.1109/ipdps57955.2024.00086.

[127] YU Hanfei, CUI Xingqi, ZHANG Hong, *et al*. fMoE: Fine-grained expert offloading for large mixture-of-experts serving[J]. arXiv preprint arXiv: 2502.05370, 2025. doi:

中国知网 https://www.cnki.net

10.48550/arXiv.2502.05370.

[128] FANG Zhiyuan, HONG Zicong, HUANG Yuegui, *et al.* Fate: Fast edge inference of mixture-of-experts models via cross-layer gate[J]. arXiv preprint arXiv: 2502.12224, 2025. doi: 10.48550/arXiv.2502.12224.

[129] QIAN Yulei, LI Fengcun, JI Xiangyang, *et al.* EPS-MoE: Expert pipeline scheduler for cost-efficient MoE inference[J]. arXiv preprint arXiv: 2410.12247, 2025. doi: 10.48550/arXiv.2410.12247.

[130] SKLIAR A, VAN ROZENDAAL T, LEPERT R, *et al.* Mixture of cache-conditional experts for efficient mobile device inference[J]. arXiv preprint arXiv: 2412.00099, 2025. doi: 10.48550/arXiv.2412.00099.

[131] CHEN Xin, ZHANG Hengheng, GU Xiaotao, *et al.* Pipeline MoE: A flexible MoE implementation with pipeline parallelism[J]. arXiv preprint arXiv: 2304.11414, 2023. doi: 10.48550/arXiv.2304.11414.

[132] NIE Xiaonan, MIAO Xupeng, WANG Zilong, *et al.* FlexMoE: Scaling large-scale sparse pre-trained model training via dynamic device placement[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(1): 110. doi: 10.1145/3588964.

[133] YUAN Yichao, MA Lin, and TALATI N. MoE-Lens: Towards the hardware limit of high-throughput MoE LLM serving under resource constraints[J]. arXiv preprint arXiv: 2504.09345, 2025. doi: 10.48550/arXiv.2504.09345.

[134] ZHANG Mohan, LI Pingzhi, PENG Jie, *et al.* Advancing MoE efficiency: A collaboration-constrained routing (C2R) strategy for better expert parallelism design[J]. arXiv preprint arXiv: 2504.01337, 2025. doi: 10.48550/arXiv.2504.01337.

[135] LUO Shuqing, PENG Jie, LI Pingzhi, *et al.* HEXA-MoE: Efficient and heterogeneous-aware training for mixture-of-experts[J]. arXiv preprint arXiv: 2411.01288, 2025. doi: 10.48550/arXiv.2411.01288.

[136] TAIRIN S, MAHMUD S, SHEN Haiying, *et al.* eMoE: Task-aware memory efficient mixture-of-experts-based (MoE) model inference[J]. arXiv preprint arXiv: 2503.06823, 2025. doi: 10.48550/arXiv.2503.06823.

[137] ZHU Ruidong, JIANG Ziheng, JIN Chao, *et al.* MegaScale-Infer: Serving mixture-of-experts at scale with disaggregated expert parallelism[J]. arXiv preprint arXiv: 2504.02263, 2025. doi: 10.48550/arXiv.2504.02263.

[138] XUE Leyang, FU Yao, LU Zhan, *et al.* MoE-infinity: Offloading-efficient MoE model serving[J]. arXiv preprint arXiv: 2401.14361, 2025. doi: 10.48550/arXiv.2401.14361.

[139] WU Chenpeng, GU Qiqi, SHI Heng, *et al.* Samoyeds: Accelerating MoE models with structured sparsity leveraging sparse tensor cores[C]. Proceedings of the Twentieth European Conference on Computer Systems, Rotterdam, Netherlands, 2025: 293–310. doi: 10.1145/3689031.3717455.

[140] LI Zhiyao, YANG Bohan, LI Jiaxiang, *et al.* Adyna: Accelerating dynamic neural networks with adaptive scheduling[C]. 2025 IEEE International Symposium on High Performance Computer Architecture (HPCA), Las Vegas, USA, 2025: 549–562. doi: 10.1109/hpca61900.2025.00049.

[141] Bytedance. Flux[EB/OL]. https://github.com/bytedance/flux, 2025.

[142] LIAN Yaoxiu, GOU Zhihong, HAN Yibo, *et al.* A cross-model fusion-aware framework for optimizing (gather-matmul-scatter)s workload[C]. Proceedings of the 62nd ACM/IEEE Design Automation Conference (DAC), San Francisco, CA, USA, 2025: 1–6.

[143] XUE Fuzhao, HE Xiaoxin, REN Xiaozhe, *et al.* One student knows all experts know: From sparse to dense[C]. The Eleventh International Conference on Learning Representations (ICLR), Kigali, Rwanda, 2023.

[144] CERON J S O, SOKAR G, WILLI T, *et al.* Mixtures of experts unlock parameter scaling for deep RL[C]. Proceedings of the 41st International Conference on Machine Learning, Vienna, Austria, 2024: 38520–38540.

[145] ZHENG Zhen, PAN Zaifeng, WANG Dalin, *et al.* BladeDISC: Optimizing dynamic shape machine learning workloads via compiler approach[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(3): 206. doi: 10.1145/3617327.

[146] NVIDIA. Megatron-LM[EB/OL]. https://github.com/NVIDIA/Megatron-LM, 2023.

[147] NVIDIA. TensorRT-LLM[EB/OL]. https://github.com/NVIDIA/TensorRT-LLM, 2025.

[148] InternLM. LMDeploy. [EB/OL]. https://github.com/InternLM/lmdeploy, 2023.

[149] GGML. llama. cpp[EB/OL]. https://github.com/ggml-org/llama.cpp, 2024.

[150] DeepSeek-AI. DeepEP: An efficient expert-parallel communication library[EB/OL]. https://github.com/deepseek-ai/DeepEP, 2025.

[151] DeepSeek-AI. Expert parallelism load balancer[EB/OL]. https://github.com/deepseek-ai/EPLB, 2025.

[152] SANSEVIERO O, TUNSTALL L, SCHMID P, *et al.*

中国知网 https://www.cnki.net

Mixture of experts explained[EB/OL]. https://huggingface.co/blog/moe, 2023.

[153] Facebook Al Research. Sequence-to-sequence toolkit written in python[EB/OL]. https://github.com/facebookresearch/fairseq, 2021.

[154] NLLB Team, COSTA-JUSSÀ M R, CROSS J, *et al*. No language left behind: Scaling human-centered machine translation[J]. arXiv preprint arXiv: 2207.04672, 2022. doi: 10.48550/arXiv.2207.04672.

[155] YANG An, YANG Baosong, HUI Binyuan, *et al*. Qwen2 technical report[J]. arXiv preprint arXiv: 2407.10671v4, 2024. doi: 10.48550/arXiv.2407.10671.

[156] Qwen Team. Qwen1.5-MoE: Matching 7B model performance with 1/3 activated parameters[EB/OL]. https://qwenlm.github.io/blog/qwen-moe/, 2024.

[157] The Mosaic Research Team. Introducing DBRX: A New State-of-the-Art Open LLM[EB/OL]. https://www.databricks.com/blog/introducing-dbrx-new-state-art-open-llm, 2024.

[158] Snowflake Team. Arctic: Open, efficient foundation language models from snowflake[EB/OL]. https://www.snowflake.com/en/blog/arctic-open-efficient-foundation-language-models-snowflake, 2024.

[159] DeepSeek-AI. DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model[J]. arXiv preprint arXiv: 2405.04434, 2024. doi: 10.48550/arXiv.2405.04434.

[160] WEI Tianwen, ZHU Bo, ZHAO Liang, *et al*. Skywork-MoE: A deep dive into training techniques for mixture-of-experts language models[J]. arXiv preprint arXiv: 2406.06563, 2024. doi: 10.48550/arXiv.2406.06563.

[161] WU Shaohua, LUO Jiangang, CHEN Xi, *et al*. Yuan 2.0-M32: Mixture of experts with attention router[J]. arXiv preprint arXiv: 2405.17976, 2024. doi: 10.48550/arXiv.2405.17976.

[162] ZHU Tong, QU Xiaoye, DONG Daize, *et al*. LLaMA-MoE: Building mixture-of-experts from LLaMA with continual pre-training[J]. arXiv preprint arXiv: 2406.16554, 2024. doi: 10.48550/arXiv.2406.16554.

[163] MUENNIGHOFF N, SOLDAINI L, GROENEVELD D, *et al*. OLMoE: Open mixture-of-experts language models[J]. arXiv preprint arXiv: 2409.02060, 2025. doi: 10.48550/arXiv.2409.02060.

[164] LIU Liyuan, KIM Y J, WANG Shuohang, *et al*. GRIN: GRadient-INformed MoE[J]. arXiv preprint arXiv: 2409.12136, 2024. doi: 10.48550/arXiv.2409.12136.

[165] SUN Xingwu, CHEN Yanfeng, HUANG Yiqing, *et al*. Hunyuan-Large: An open-source MoE model with 52 billion activated parameters by tencent[J]. arXiv preprint arXiv: 2411.02265, 2024. doi: 10.48550/arXiv.2411.02265.

[166] MiniMax. MiniMax-01: Scaling foundation models with lightning attention[J]. arXiv preprint arXiv: 2501.08313, 2025. doi: 10.48550/arXiv.2501.08313.

[167] LIU Jingyuan, SU Jianlin, YAO Xingcheng, *et al*. Muon is scalable for LLM training[J]. arXiv preprint arXiv: 2502.16982, 2025. doi: 10.48550/arXiv.2502.16982.

[168] Meta-AI. LLaMA4[EB/OL]. https://www.llama.com/models/llama-4/, 2025.

[169] YANG An, LI Anfeng, YANG Baosong, *et al*. Qwen3 technical report[J]. arXiv preprint arXiv: 2505.09388, 2025. doi: 10.48550/arXiv.2505.09388.

[170] TIAN Changxin, CHEN Kunlong, LIU Jia, *et al*. Towards greater leverage: Scaling laws for efficient mixture-of-experts language models[J]. arXiv preprint arXiv: 2507.17702, 2025. doi: 10.48550/arXiv.2507.17702.

[171] HUANG Quzhe, AN Zhenwei, ZHUANG Nan, *et al*. Harder tasks need more experts: Dynamic routing in MoE models[J]. arXiv preprint arXiv: 2403.07652, 2024. doi: 10.48550/arXiv.2403.07652.

[172] KUNWAR P, VU M N, GUPTA M, *et al*. TT-LoRA MoE: Unifying parameter-efficient fine-tuning and sparse mixture-of-experts[J]. arXiv preprint arXiv: 2504.21190, 2025. doi: 10.48550/arXiv.2504.21190.

[173] WANG Junlin, WANG Jue, ATHIWARATKUN B, *et al*. Mixture-of-agents enhances large language model capabilities[J]. arXiv preprint arXiv: 2406.04692, 2024. doi: 10.48550/arXiv.2406.04692.

[174] YUN S, PARK S, NAM H, *et al*. The new LLM bottleneck: A systems perspective on latent attention and mixture-of-experts[J]. arXiv preprint arXiv: 2507.15465, 2025. doi: 10.48550/arXiv.2507.15465.

[175] AL MARUF H, WANG Hao, DHANOTIA A, *et al*. TPP: Transparent page placement for CXL-enabled tiered-memory[C]. Proceedings of the 28th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 3, Vancouver, Canada, 2023: 742–755. doi: 10.1145/3582016.3582063.

[176] ZHOU Zhe, CHEN Yiqi, ZHANG Tao, *et al*. NeoMem: Hardware/software co-design for CXL-native memory tiering[C]. 2024 57th IEEE/ACM International Symposium on Microarchitecture (MICRO), Austin, USA: IEEE, 2024: 1518–1531. doi: 10.1109/MICRO61859.2024.00111.

[177] JIN Chao, JIANG Ziheng, BAI Zhihao, *et al*. MegaScale-

中国知网 https://www.cnki.net

MoE: Large-scale communication-efficient training of mixture-of-experts models in production[J]. arXiv preprint arXiv: 2505.11432, 2025. doi: 10.48550/arXiv.2505.11432.

王泽昊：男，硕士生，研究方向为领域专用计算架构设计等.
朱振华：男，博士，研究方向为存内计算与近存储计算架构设计等.
谢童欣：男，博士生，研究方向为近存储计算架构与编译器设计等.
汪　玉：男，教授，研究方向为智能芯片以及高能效电路与系统等.

责任编辑：陈　倩

A Survey on System and Architecture Optimization Techniques for Mixture-of-Experts Large Language Models

WANG Zehao　　ZHU Zhenhua　　XIE Tongxin　　WANG Yu

(*Department of Electronic Engineering*, *Tsinghua University*, *Beijing* 100084, *China*)

Abstract: The Mixture-of-Experts (MoE) framework has become a pivotal approach for enhancing the knowledge capacity and inference efficiency of Large Language Models (LLMs). Conventional methods for scaling dense LLMs have reached significant limitations in training and inference due to computational and memory constraints. MoE addresses these challenges by distributing knowledge representation across specialized expert sub-networks, enabling parameter expansion while maintaining efficiency through sparse expert activation during inference. However, the dynamic nature of expert activation introduces substantial challenges in resource management and scheduling, necessitating targeted optimization at both the system and architectural levels. This survey focuses on the deployment of MoE-based LLMs. It first reviews the definitions and developmental trajectory of MoE, followed by an in-depth analysis of current system-level optimization strategies and architectural innovations tailored to MoE. The paper concludes by summarizing key findings and proposing prospective optimization techniques for MoE-based LLMs.

Significance　The MoE mechanism offers a promising solution to the computational and memory limitations of dense LLMs. By distributing knowledge representation across specialized expert sub-networks, MoE facilitates model scaling without incurring prohibitive computational costs. This architecture alleviates the bottlenecks associated with training and inference in traditional dense models, marking a notable advance in LLM research. Nonetheless, the dynamic expert activation patterns inherent to MoE introduce new challenges in resource scheduling and management. Overcoming these challenges requires targeted system- and architecture-level optimizations to fully harness the potential of MoE-based LLMs.

Progress　Recent advancements in MoE-based LLMs have led to the development of various optimization strategies. At the system level, approaches such as automatic parallelism, communication-computation pipelining, and communication operator fusion have been adopted to reduce communication overhead. Memory management has been improved through expert prefetching, caching mechanisms, and queue scheduling policies. To address computational load imbalance, both offline scheduling methods and runtime expert allocation strategies have been proposed, including designs that leverage heterogeneous CPU-GPU architectures. In terms of hardware architecture, innovations include dynamic adaptation to expert activation patterns, techniques to overcome bandwidth limitations, and near-memory computing schemes that improve deployment efficiency. In parallel, the open-source community has developed supporting tools and frameworks that facilitate the practical deployment and optimization of MoE-based models.

Conclusions　This survey presents a comprehensive review of system and architectural optimization techniques for MoE-based LLMs. It highlights the importance of reconciling parameter scalability with computational

中国知网　https://www.cnki.net

efficiency through the MoE framework. The dynamic nature of expert activation poses significant challenges in scheduling and resource management, which are systematically addressed in this survey. By evaluating current optimization techniques across both system and hardware layers, the paper offers key insights into the state of the field. It also proposes directions for future work, providing a reference for researchers and practitioners seeking to improve the performance and scalability of MoE-based models. The findings emphasize the need for continued innovation across algorithm development, system engineering, and architectural design to fully realize the potential of MoE in real-world applications.

Prospects Future research on MoE-based LLMs is expected to advance the integration of algorithm design, system optimization, and hardware co-design. Key research directions include resolving load imbalance and maximizing resource utilization through adaptive expert scheduling algorithms, refining system frameworks to support dynamic sparse computation more effectively, and exploring hardware paradigms such as near-memory computing and hierarchical memory architectures. These developments aim to deliver more efficient and scalable MoE model deployments by fostering deeper synergy between software and hardware components.

Key words: Large language models; Mixture of experts; System acceleration; Hardware architecture

中国知网 https://www.cnki.net